

PolicyKG: 把制度文件翻译成可校验约束的流水线

PolicyKG: Translating Institutional Policies into SHACL Knowledge Graphs

本篇范围说明：源文档是一篇 23 页的学术论文（arXiv:2608.09028）。下面「全文翻译」按论文的章节推进，覆盖摘要、引言、相关工作定位、方法、四阶段流水线、Corpus Adapter、评测结果与失败分析、以及作者自己声明的局限；**不含参考文献列表与形式化语法的符号定义细节。**

核心内容

Q: 这篇论文要解决的是什么问题？ A: 制度政策（学校、医院、政府机构管学生、员工、业务流程的那些规章）是用自然语言写给人读的，而检查「实际做法有没有符合政策」这件事越来越自动化——选课流程、支付系统、认证报告消费的都是机器可读的数据。今天这两头之间靠人工解读接起来：教务员读一段话，决定它是什么意思，然后去系统里配一条规则。作者指出这个做法三个毛病：不可规模化、政策一改就失效、而且没有审计链把一次系统检查追回到它执行的那条文字义务。

Q: PolicyKG 是什么？ A: 一条四阶段的 agentic 大模型流水线，把政策文件翻译成经 SHACL 校验的知识图谱。四个阶段是：文档抽取、道义规则分类、一阶逻辑加道义算子的形式化、SHACL 翻译。四个阶段由一个 LangGraph 状态机编排，每个阶段配自己的校验器，局部失败就触发自我纠正。

Q: 作者说主要技术贡献是哪一件？ A: Corpus Adapter——一个由配置驱动的「词汇接地层」。它做两件事：把大模型生成的谓词约束到目标本体里已有的那些，以及让同一条流水线通过换注册表而不是重训模型来切换领域。作者点明了自己填的是哪个空白：让大模型生成结构化输出的「句法侧」（schema 约束、语法引导）文献里做得多，而**「语义侧」——保证生成的谓词对齐到目标本体、而不是编一个英文属性名出来——研究得少**。

Q: 效果如何？ A: 在亚洲理工学院全套政策文件上评测（1663 个句子，产出 443 条规则）：道义类型分类准确率 86.9%；SHACL 形状正确性 $F1 = .866$ ；端到端形式化产出率 79.2%（351/443），剩下的 20.8% 回落到「自然语言直接到 SHACL」那条路。换领域那个实验最能说明 Corpus Adapter 的价值：15 条 GDPR 规则上，精确属性对齐从 1/15 提到 11/15。

Q: 作者报了哪个负面结果？ A: 报得很坦白。拿外部基准 LexDeMod（租赁合同，200 条）验证时，宏平均 $F1$ 从 .810 掉到 .370，其中「许可」这一类的 $F1$ 只有 .038（几乎全错）。作者指出失败机制是词汇先验不匹配——租赁合同的英文用 `shall be entitled` 表达许可，而模型学到的先验里许可长得不是这样。作者说这恰好是 Corpus Adapter 设计来修的那一类问题，换个注册表就能修。

Q: Corpus Adapter 比 RAG 好在哪？作者自己怎么说？ A：这一段值得单独记。作者做了和 RAG 的正面对比，结论是：**RAG 把词汇对齐的差距基本补上了**。Corpus Adapter 剩下的优势不在准确率，而在**部署性质**——不依赖向量嵌入、结果确定、换配置就能换领域。作者原话是「the Corpus Adapter's remaining advantage is in deployment properties rather than raw accuracy」。

Q: 那个「一阶逻辑够不够用」的问题，作者怎么回答的？ A：**用审计而不是用证明**。对全部 443 条规则跑一遍自动化的正则检查表，再由第一作者人工复核那 92 条回落案例（高阶构造最可能藏在这里），两遍都是零命中。作者据此给出一个精确置信上界：真实的高阶需求率不超过 0.67%。**但他明确说这是「针对这个语料的一条审计发现，不是对一阶逻辑普遍够用的证明」。**

背景补充 / 点评

几个名词得先摆清楚，不然后面看不懂。

- **SHACL** (Shapes Constraint Language) 是 W3C 的一个标准，用来对 RDF 知识图谱做声明式校验：你写一份「形状」，它去检查图里的数据符不符合。合规检查越来越用它。
- **道义逻辑** (deontic logic) 是逻辑学里专门处理「应当、允许、禁止」这三种模态的分支，发展了半个多世纪。政策文字的规范性内容正好落在这三个算子上。
- **LangGraph** 是把大模型调用编排成状态机的框架。这里用它是为了让每个阶段能有自己的校验器和自我纠正回路。
- **Fleiss κ / Cohen κ** 是标注一致性指标：多个人独立标同一批数据， κ 衡量他们的一致程度超出随机一致的部分有多少。文中 Fleiss $\kappa = .844$ 属于很高的一致度，说明那份金标准不是一个人拍的。
- **Clopper - Pearson 置信区间**是对「零命中」这种极端计数给置信上界的精确方法。零命中不能说成「概率是 0」，但可以说「真实概率不超过 0.67%」——作者用的正是这个分寸。

这篇论文最值钱的地方，是它对自己的克制。 三处：

第一，把「**一阶逻辑够不够**」这件事称作**审计发现而不是证明**。它完全可以吹成「我们证明了一阶逻辑对制度政策是充分的」——那样引用会更好看。作者选择给出置信上界并且说清适用范围只到这个语料。

第二，**主动报出 LexDeMod 上的崩盘** (F1 从 .810 掉到 .370，许可类 .038)。这个数字放在论文里对作者没有好处，而它是全文信息量最高的一个数——它说明这条流水线的能力**依赖领域的措辞习惯**，换个文本就断。

第三，**承认 RAG 在准确率上追平了自己的主要贡献**。作者没有含糊过去，而是把优势重新界定到部署性质上。

留白的地方。「换注册表就能修」这句话在 GDPR 那个实验上被验证了 (1/15 到 11/15)，但在**真正崩掉的 LexDeMod 上没有验**——作者说那类失败正是 Corpus Adapter 设计来修的，却没有报「换上租赁领域的注册表之后 F1 回到多少」。这是全文最该补而没补的一个实验。另外 443 条规则里那 20.8% 的回落案

例，作者归因于「结构性」原因（长的并列复合句、嵌入的项目符号），但没有给出这些结构在语料里的分布，读者判断不了这个 20.8% 是不是能靠工程手段压下去。

对我自己的启示，这篇是这批里最直接的一篇。

一、Corpus Adapter 和我做的是同一件事，这是一次独立验证。 他们的做法是「把大模型生成的谓词约束到目标本体里已登记的那些」，我的做法是给路由调用带一份严格 schema、把指标 id 的取值域声明成注册表里那几十条的枚举，端点在解码阶段就把编出来的名字挡掉。**同一个模式在两个互不相关的项目里被独立选中，说明它不是巧合。** 他们还给这个模式起了名字，我以后跟人讲这件事可以直接借「vocabulary grounding」这个说法。

二、他们那句「优势在部署性质而不是准确率」，我应当直接拿去用。 我一直在论证「LLM 不写 SQL、取数只走声明」，而我的论证重心时常滑到「这样更准」。这篇论文的对比给出了更站得住的说法：**RAG 能把准确率补上，补不上的是确定性、不依赖嵌入、以及换配置就能换领域。** 我这边对应的正是「同一份声明编出逐字节相同的 SQL」——前两天我拿 90 条编译产物逐字节相同验证过这件事。**跟 Ethan 讲的时候，重心该放在可回放与可审计上，不该放在准确率上，因为准确率这条战线是守不住的。**

三、LexDeMod 那个崩盘是给我的一记警告，而且指向我已知的那个缺口。 他们的流水线在本领域好用、换文体就崩，根因是词汇先验不匹配。我的本体现在只服务一条问答链路，没有第二个消费者。哪天 MCE 或者 APP 编排要复用同一套口径，换的不只是问法，是**整套措辞习惯**——而按这篇论文的经验，那时暴露的会是某一类的召回崩到接近零（他们是许可类 .038），而不是整体缓慢下降。**整体指标看不出单类崩盘**，这一点我要在那之前就把分类别的指标准备好。

四、「审计发现而不是证明」这个分寸，值得我在写结论时照着学。 我这两天做的事里有好几处是「实测 N 次全部通过」，我在报告里得学他这个写法：给出实测次数与适用范围，不把「没观察到」写成「不会发生」。

文中金句

"The gap between human-authored policy and machine-checked compliance is bridged today by manual interpretation: a registrar reads a paragraph, decides what it means, and configures a system rule." 人写的政策与机器检查的合规之间，今天靠人工解读接起来：一个教务员读一段话，决定它是什么意思，然后去配一条系统规则。

"This process does not scale, does not survive policy revisions, and offers no audit trail linking a system check back to the textual obligation it enforces." 这个过程不可规模化，政策一改就失效，而且没有任何审计链能把一次系统检查追回到它所执行的那条文字义务。

"The semantic side of constructing that graph, that is, ensuring LLM-generated predicates align with a target ontology rather than hallucinated English property names, receives less

direct treatment in the literature." 构建那张图的语义那一侧——也就是保证大模型生成的谓词对齐到目标本体，而不是一串凭空编出来的英文属性名——在文献里被直接讨论得少。

"The Corpus Adapter's remaining advantage is in deployment properties (no embedding dependency, deterministic, config-swappable) rather than raw accuracy." Corpus Adapter 剩下的优势在于部署性质（不依赖嵌入、结果确定、换配置即可切换），而不是原始准确率。

"We report this as an audit finding for this corpus, not a proof of FOL sufficiency in general." 我们把这一条作为针对本语料的审计发现来报告，而不是对「一阶逻辑普遍够用」的证明。

全文翻译

摘要

Institutional policies are written in natural language, but verifying compliance increasingly demands executable constraints, leaving organisations to bridge that gap by hand. We present PolicyKG, an agentic LLM pipeline that translates institutional policy documents into SHACL-validated knowledge graphs via a first-order deontic intermediate representation, orchestrated as four self-correcting stages over a LangGraph state machine.

制度政策是用自然语言写的，而验证合规性越来越需要可执行的约束，于是各个机构只能靠人工去接这个缺口。我们提出 PolicyKG，一条 agentic 大模型流水线，它经由一个「一阶逻辑加道义算子」的中间表示，把制度政策文件翻译成经 SHACL 校验的知识图谱；四个能自我纠正的阶段由一个 LangGraph 状态机编排。

The main technical contribution is the Corpus Adapter, a configuration-driven vocabulary-grounding layer that constrains LLM-generated predicates to a target ontology and enables cross-domain transfer by swapping registries rather than retraining models.

主要的技术贡献是 Corpus Adapter：一个由配置驱动的词义接地层，它把大模型生成的谓词约束到目标本体上，并且让跨领域迁移通过[更换注册表](#)而不是重训模型来完成。

Evaluated on the full Asian Institute of Technology Policies & Procedures corpus (1,663 sentences yielding 443 rules), PolicyKG achieves 86.9% deontic-type classification accuracy and SHACL shape correctness of $F1 = .866$ on a 69-shape evaluation subset. End-to-end formalisation yield is 79.2% (351/443) via the FOL path; the remaining 20.8% fall back to a direct NL→SHACL path whose failure modes are predominantly structural (long compound conjunctions, embedded bullets), not expressiveness-bounded.

在亚洲理工学院全套《政策与流程》语料上评测（1663 个句子，产出 443 条规则），PolicyKG 的道义类型分类准确率为 86.9%，在一个 69 个形状的评测子集上 SHACL 形状正确性 $F1 = .866$ 。走一阶逻辑那条路的端到端形式化产出率是 79.2% (351/443)；剩下的 20.8% 回落到「自然语言直接转 SHACL」那条路，而这些失败的形态主要是**结构性的**（长的并列复合句、嵌入的项目符号），不是表达力不够。

A two-pass audit flagged zero second- or higher-order constructs. We report this as an audit finding for this corpus, not a proof of FOL sufficiency in general.

一遍自动化检查加一遍人工复核，两遍都没有发现二阶或更高阶的构造。我们把这一条作为针对本语料的审计发现来报告，而不是对「一阶逻辑普遍够用」的证明。

A controlled cross-domain experiment on $N = 15$ GDPR rules raises exact property alignment from 1/15 to 11/15 with the Corpus Adapter. External validation on the LexDeMod lease-contract benchmark ($N = 200$) drops Macro F1 from .810 to .370, with permission $F1 = .038$; the failure mechanism is a vocabulary-prior mismatch (lease English uses "shall be entitled" for permission) precisely of the class the Corpus Adapter is designed to repair by registry swap.

一个受控的跨领域实验（15 条 GDPR 规则）显示，加上 Corpus Adapter 后精确属性对齐从 1/15 提升到 11/15。在外部基准 LexDeMod（租赁合同，200 条）上验证时，宏平均 F1 从 .810 掉到 .370，其中许可类的 F1 只有 .038；失败机制是**词汇先验不匹配**（租赁合同的英文用 `shall be entitled` 表达许可），而这恰好属于 Corpus Adapter 设计来通过换注册表修复的那一类。

We release the gold standard, both vocabulary registries, evaluation scripts, and pipeline configuration; repeated runs on the same host produce hash-identical SHACL outputs.

我们公开了金标准、两份词汇注册表、评测脚本与流水线配置；在同一台主机上重复运行会产出**哈希完全相同**的 SHACL 输出。

一、引言：人工解读接不住的那个缺口

Institutional policies, which govern students, staff, and operations in universities, hospitals, and government agencies, are written as natural-language documents and read by humans. Yet the work of verifying that institutional practice conforms to those policies is increasingly automated: enrolment workflows, payment systems, and accreditation reports all consume machine-readable data.

制度政策管的是大学、医院、政府机构里的学生、员工与业务流程，它们被写成自然语言文件、由人来读。然而「验证机构的实际做法是否符合这些政策」这项工作正越来越自动化：选课流程、支付系统、认证报告，消费的都是机器可读的数据。

The gap between human-authored policy and machine-checked compliance is bridged today by manual interpretation: a registrar reads a paragraph, decides what it means, and configures a

system rule. This process does not scale, does not survive policy revisions, and offers no audit trail linking a system check back to the textual obligation it enforces.

人写的政策与机器检查的合规之间，今天靠人工解读接起来：一个教务员读一段话，决定它是什么意思，然后去配一条系统规则。这个过程不可规模化，政策一改就失效，而且没有任何审计链能把一次系统检查追回到它所执行的那条文字义务。

Three lines of research speak to this problem. Policy and legal NLP have produced rule-extraction systems based on patterns, classical classifiers, and recently large language models, reporting accuracies between 75% and 85% on isolated extraction tasks. Deontic logic offers operators of obligation, permission, and prohibition that capture the normative content of policy text. SHACL encodes validation constraints over RDF knowledge graphs and is increasingly used for compliance checking. Each of these threads has matured in isolation.

有三条研究线索与这个问题相关。政策与法律自然语言处理产出过基于模式的、基于经典分类器的、以及近来基于大模型的规则抽取系统，在孤立的抽取任务上报出 75% 到 85% 的准确率。道义逻辑提供「义务、许可、禁止」三个算子，正好抓住政策文字的规范性内容。SHACL 把校验约束编码在 RDF 知识图谱之上，越来越多地被用于合规检查。[这三条线索各自成熟，彼此没有接起来。](#)

What is missing is an empirically validated, end-to-end pipeline that connects natural-language policy to executable SHACL, together with a satisfying answer to the open theoretical question of whether first-order logic with deontic extensions is sufficient for institutional policy.

缺的是一条经过实证验证的端到端流水线，把自然语言政策连到可执行的 SHACL；以及对一个悬着的理论问题给出令人满意的回答：带道义扩展的一阶逻辑对制度政策够不够用。

二、相关工作：四条线索各自到哪儿了

Pattern-based extraction was the first generation of automated policy NLP, applying regular expressions and keyword templates to privacy policies, reporting around 77% accuracy but struggling with syntactic variation. SVM classifiers over hand-crafted features reached 82% on financial regulation but at a feature-engineering cost that did not transfer across document types. The common limitation is reliance on bespoke features or hand-built ontologies; none draws on the semantic priors of pre-trained language models.

第一代自动化政策 NLP 是基于模式的抽取：对隐私政策套用正则与关键词模板，准确率约 77%，但[在句法变化上撑不住](#)。后来用支持向量机加人工特征，在金融监管文本上到 82%，代价是特征工程的成本[换个文档类型就迁移不过去](#)。共同的局限是依赖定制特征或人工建的本体，都没有用上预训练语言模型的语义先验。

Deontic logic provides a mathematically rigorous account of obligation, permission, and prohibition. It was argued on theoretical grounds that first-order deontic logic supplies sufficient expressiveness for normative systems. The open question, whether real institutional policies

actually stay within FOL+deontic or reach into higher-order territory, had been addressed only at the theoretical level; we provide the first empirical audit finding on a real institutional corpus.

道义逻辑对义务、许可、禁止给出了数学上严格的说明。此前有人从理论上论证过，一阶道义逻辑对规范系统的表达力是够的。而**真实的制度政策到底是否真的落在一阶范围内、还是会伸到高阶去**，这个悬着的问题此前只在理论层面被讨论过；我们在一个真实的制度语料上给出第一条实证审计发现。

Standard Deontic Logic is known to be subject to the Chisholm and Ross paradoxes, and to handle conditional exceptions (contrary-to-duty obligations, waiver clauses) only awkwardly. PolicyKG does not attempt a full defeasible account; it records override relations via a custom annotation as a stepping stone that a downstream defeasible layer could consume.

标准道义逻辑有已知的两个悖论（Chisholm 悖论与 Ross 悖论），而且处理条件性例外（违反义务时的义务、豁免条款）时很别扭。PolicyKG **不打算做一套完整的可推翻推理**，它用一个自定义注解记下「覆盖」关系，作为一块垫脚石，供下游的可推翻层去消费。

A growing body of work uses LLMs to construct or query knowledge graphs. Schema-constrained and grammar-guided generation forces LLM outputs into well-typed structures, addressing the syntactic side of structured output. Retrieval-augmented generation is the mainstream approach for grounding LLM outputs in an external knowledge source, and GraphRAG extends the pattern to knowledge-graph retrieval, but it assumes the target graph already exists.

用大模型构建或查询知识图谱的工作在增多。受 schema 约束的生成、受语法引导的生成，把大模型输出强制成类型正确的结构，处理的是结构化输出的**句法那一侧**。检索增强生成是把大模型输出接地到外部知识源的主流做法，GraphRAG 把这个模式扩展到知识图谱检索，**但它假设目标图已经存在了**。

The semantic side of constructing that graph, that is, ensuring LLM-generated predicates align with a target ontology rather than hallucinated English property names, receives less direct treatment in the literature. The Corpus Adapter is our answer to this semantic gap: constrained selection from a configuration artefact in place of either fine-tuning or open generation.

构建那张图的**语义那一侧**——也就是保证大模型生成的谓词对齐到目标本体，而不是一串凭空编出来的英文属性名——在文献里被直接讨论得少。Corpus Adapter 就是我们对这个语义缺口的回答：**从一份配置产物里做受约束的选择**，取代微调，也取代放开生成。

We report a head-to-head comparison against top-K RAG on the ontology property list, showing that RAG closes most of the vocabulary-alignment gap; the Corpus Adapter's remaining advantage is in deployment properties (no embedding dependency, deterministic, config-swappable) rather than raw accuracy.

我们报告了与「在本体属性列表上做 top-K 检索增强」的正面对比：**检索增强把词汇对齐的差距补上了大部分**；Corpus Adapter 剩下的优势在于部署性质（不依赖嵌入、结果确定、换配置即可切换），而不是原始准确率。

三、定位

The gap PolicyKG addresses sits at the intersection of these four threads: an empirically validated, end-to-end pipeline that combines LLM-based rule identification and formalisation, FOL+deontic semantics with an empirical audit-finding of sufficiency on a real institutional corpus, SHACL as the operational compliance target, and a portable vocabulary-grounding mechanism that mediates between LLM-natural predicates and target ontologies.

PolicyKG 要填的空白位于这四条线索的交点：一条经实证验证的端到端流水线，它把四件东西合起来——基于大模型的规则识别与形式化；一阶加道义的语义，配上在真实制度语料上关于「够用」的实证审计发现；把 SHACL 作为可运行的合规目标；以及一套可移植的词汇接地机制，在「大模型自然会写的谓词」与「目标本体」之间做中介。

No prior system unifies these four components, and no prior empirical work has audited the FOL-sufficiency question on a real corpus.

此前没有系统把这四个部件统一起来，也没有实证工作在真实语料上审计过「一阶逻辑够不够」这个问题。

四、方法与四个阶段

The pipeline runs four orchestrated stages: document extraction, deontic rule classification, FOL+deontic formalisation, and SHACL translation. A LangGraph state machine coordinates them, with per-stage validators that trigger self-correction on local failure.

流水线跑四个被编排起来的阶段：文档抽取、道义规则分类、一阶加道义的形式化、SHACL 翻译。一个 LangGraph 状态机负责协调，**每个阶段配自己的校验器，局部失败时触发自我纠正**。

We work in first-order logic extended with three deontic modal operators. The syntax assumes constants, predicates of arity one or more, the quantifiers for-all and exists, the connectives and/or/implies/not, and three modal operators applied to closed formulas.

我们在一阶逻辑的基础上扩展三个道义模态算子。语法上包含常量、元数为一或更多的谓词、全称与存在量词、合取／析取／蕴含／否定这几个联结词，以及作用在闭公式上的三个模态算子。

五、审计：一阶逻辑在这个语料上够不够

A two-pass audit — an automated regex checklist over all 443 rules plus a first-author manual review of the 92 FOL-fallback cases where higher-order constructs could otherwise hide — flagged zero second- or higher-order constructs.

两遍审计：先对全部 443 条规则跑一遍自动化的正则检查表，再由第一作者人工复核那 92 条回落到「自然语言直接转 SHACL」的案例——高阶构造最可能藏在这些解析失败的案例背后。**两遍都是零命中**。

Exact Clopper - Pearson upper 95% CI on the true HOL requirement rate: 0.67%. We report this as an audit finding for this corpus, not a proof of FOL sufficiency in general.

对「真实的高阶逻辑需求率」给出精确的 Clopper - Pearson 95% 置信上界：0.67%。我们把这一条作为针对本语料的审计发现来报告，而不是对「一阶逻辑普遍够用」的证明。

六、跨领域与外部验证

A controlled cross-domain experiment on $N = 15$ GDPR rules raises exact property alignment from 1/15 to 11/15 with the Corpus Adapter (Fisher's exact $p < .001$; Cohen's $h = 1.53$, large effect).

一个受控的跨领域实验（15 条 GDPR 规则）显示，加上 Corpus Adapter 后精确属性对齐从 1/15 提到 11/15（Fisher 精确检验 $p < .001$ ；效应量 Cohen's $h = 1.53$ ，属于大效应）。

External validation on the LexDeMod lease-contract benchmark ($N = 200$) drops Macro F1 from .810 to .370, with permission F1 = .038; the failure mechanism is a vocabulary-prior mismatch — lease English uses "shall be entitled" for permission — precisely of the class the Corpus Adapter is designed to repair by registry swap.

在外部基准 LexDeMod（租赁合同，200 条）上验证时，宏平均 F1 从 .810 掉到 .370，其中许可类的 F1 只有 .038。失败机制是**词汇先验不匹配**——租赁合同的英文用 `shall be entitled` 来表达许可——而这恰好属于 Corpus Adapter 设计来通过换注册表修复的那一类。

七、可复现性

We release the gold standard, both vocabulary registries, evaluation scripts, and pipeline configuration; repeated runs on the same host produce hash-identical SHACL outputs.

我们公开了金标准、两份词汇注册表、评测脚本与流水线配置；在同一台主机上重复运行会产出**哈希完全相同**的 SHACL 输出。

参考链接

- [arXiv:2608.09028](#) — 本文的 arXiv 页面（PolicyKG, 2026 年 8 月 10 日）
- [SHACL \(W3C 标准\)](#) — 文中作为合规校验目标的那个标准
- [LangGraph](#) — 把大模型调用编排成状态机的框架，四阶段流水线用它
- [LegalRuleML](#) — 文中提到的法律规则交换格式，支持可推翻性与时间范围元数据
- [LexGLUE](#) — 法律语言理解基准，文中作为相关工作提到
- [LegalBench](#) — 162 项法律推理任务的基准