

光看可疑的单步不够：长程 agent 的本体性信任 Beyond Suspicious Steps: Ontological Trust in Long-Horizon Agents

本篇范围说明：源文档是一篇 52 页的论文 (arXiv:2608.17718)。下面「全文翻译」按论文正文章节推进，覆盖摘要、引言、信任的形式化、威胁模型、单步信号的前置分析、方法的四个步骤、实验主结果与结论；**不含参考文献列表、八个附录、以及公式的完整推导与超参表。**

核心内容

Q：这篇论文要抓的是什么样的失败？ A：每一步单看都没问题，而整条轨迹已经不是用户授权的那件事了。作者开篇的话很准：一个长程 agent 可以在「孤立看没有任何一步像是错的」的情况下失败。它用了对的工具、产出了看起来合理的最终交付物，却读了从没被要求读的文件、为了核实「相关」上下文而扩大了自己的角色、或者在用户的请求已经被满足之后继续行动。**每一步在它之前那些步的基础上都说得通，而整条轨迹合起来不再说得通。**

Q：这和「安全违规」或者「任务没完成」是一回事吗？ A：不是。作者特别强调：这既不一定是通常意义上的安全违规，也不是单纯的任务完成失败——**最终交付物可能是正确的**。问题在于那条演进中的前缀已经不再是被授权的任务，尽管每一个单步都局部有效。

Q：现有的监督工具为什么抓不到？ A：作者逐类点了一遍：运行期监控器检查动作有没有破规矩；任务与 agent 基准检查最终结果或任务完成度；安全基准暴露显式的提示注入模式；局部异常检测标记不寻常的单步；全记录的裁判或审计方法给出一个非结构化的风险判断。**它们都没有直接问那个问题：到目前为止这条轨迹还是用户授权的那个任务吗。**

Q：那把单步诊断做得更细能不能补上？作者的答案是什么？ A：不能，而且他们用数据把这条路堵死了。他们评了 9 个快照指标（覆盖词元级不确定性、语义一致性、因果接地）乘 3 个评估模型，在一个「每一步都用合法工具、而前缀已经偏离授权任务」的语料上：**最好的组合只有 73.49% AUC**；预测熵这一项在三个评估器上全都接近随机（47 - 56%）。良性步与漂移步在他们测过的每一个指标下都严重重叠。结论是：**前缀与授权任务之间的关系，不是任何单独一步能暴露的性质。**

Q：那什么能抓到？ A：把信任分解成三个轴——Role（角色）、Goal（目标）、Evidence（证据）。同一批轨迹，用这三个坐标打分，轨迹级 AUC 达到 **97.67% / 97.45% / 98.86%**（三个不同的评估模型），远高于同一批轨迹上 73.49% 的单步天花板。作者那句总结值得记住：

「这些轨迹没有变得更容易，是表示变了。」

Q：这三个轴为什么是这三个，不是随便挑的？ A：作者说它们不是按惯例选的，而是从 **agent 与环境交互的结构本身推出来的**。在标准的部分可观测马尔可夫决策过程视角下，偏离只能出现在三个地方：动作选择、目标追求、观测接地。Role 对应「动作落在被授权的动作子集之外」，Goal 对应「继续追求一个被改写过的或者相邻的目标」，Evidence 对应「作出观测历史支撑不了的声称」。**三者可以各自独立地失效**——一个 agent 可以守在角色内而追错目标，可以目标正确而依赖没有支撑的证据，也可以证据扎实而越出授权角色。

Q：这套监控器的架构关键在哪？ A：大模型只用来产出结构化的任务表示与单步表示；信任状态的更新、投影、以及干预决策全部是确定性的。所以输出是一条可回放、可审计的信任轨迹，而不是一次端到端的裁判结论。

Q：把三个轴合成一个分数时，有一个细节值得看。 A：线性加权在「漂移集中在某一个轴上」时够用，但会漏掉**联合情形**——角色、目标、证据各自只有轻微偏离，而三者的组合已经违反了授权。所以他们加了一个**结构耦合项**，这一项只在三个轴同时都超过各自阈值时才激活（用几何平均把它约束在 0 到 1 之间）。而且他们声明：**权重与阈值在所有领域、所有估计模型上都用同一套固定默认值，不做按领域调参。**

Q：作者承认哪个限制？ A：「伪一致性」这一类更难抓——也就是任务其实已经完成、agent 还在继续动作那种情形。检测得不到得取决于**任务的完成状态在外部是否可见**。作者把这一条明确定性为「一个结构性的限制」，并且用实测把它刻画出来，而不是含糊过去。

背景补充 / 点评

先说几个名词。

- **长程 agent** (long-horizon agent) 指要跨很多步、很多工具、很多次观测才完成一件事的 agent。步数一多，「每一步都对」与「整件事还是那件事」就分开了。
- **轨迹前缀** (trajectory prefix) 是「到目前这一步为止发生过的全部事情」。这篇论文的整个立论是：要监督的对象是**前缀与授权任务之间的关系**，不是单步。
- **AUC** 是判别能力的一个指标：随机猜是 50%，完美区分是 100%。所以「最好的单步指标 73.49%」意味着它比瞎猜好一些，但离可用差很远；而三轴表示的 97% 以上才是可用的量级。
- **Living-off-the-Land** (就地取材) 本来是安全领域的说法，指攻击者只用系统里本来就有的合法工具，不引入任何恶意程序，因此传统的特征检测抓不到。作者把这个概念搬到 agent 上：**每一步都在用合法工具，所以查「有没有用坏工具」查不出任何东西。**
- **OSWorld / FinanceBench / EICU-AC** 是三个不同领域的基准（桌面操作、金融问答、重症监护数据访问控制），作者用它们构造跨领域的轨迹语料。

这篇论文最有价值的地方，是它先花一整节把一条看起来最自然的路堵死。 面对「整条轨迹漂了」这个问题，几乎所有人的第一反应都是「那就把单步检测做得更细、更准」。作者没有争论这条路对不对，而是去测：9 个指标乘 3 个模型，27 个组合，最好的 73.49%。一个否定结果，先把方向定下来，再谈自己的方法。这个顺序比大部分论文严谨。

而那句「The trajectories do not become easier; the representation changes」是全文最锐的一句，也是最有迁移价值的一句：同一批数据，换一种表示，从测不出变成测得出。难度没变，是你看它的坐标系变了。

留白与我怀疑的地方有三处。

第一，三个轴的打分仍然由大模型给。作者的架构承诺是「大模型只产出结构化表示、下游全确定性」，这在工程上确实买到了可回放与可审计，但那三个分数本身的稳定性没有被报告。同一条轨迹让同一个模型打两次，三个坐标会差多少？这个数字缺了，而它直接决定「可回放」这个承诺有多实——下游确定性只保证「给定同一份分数，结论一样」，不保证「同一条轨迹，分数一样」。

第二，那个结构耦合项的阈值 0.40 与权重 0.25 是「固定默认值、不按领域调参」。作者把这一点当作优点声明（我认同这是对的纪律），但没有报告这套默认值有多敏感。如果 0.40 换成 0.35 结果就大变，那「不调参」只是把调参这件事藏进了默认值。

第三，伪一致性那个限制的描述停在「取决于完成状态是否外部可见」。作者把这条当结构性限制，我同意；但没有讨论「让完成状态可见」需要环境提供什么接口，只在结论里提了一句「留待未来」。而这恰恰是这个限制唯一的出路。

对我自己的启示

一、这篇论文描述的失败形态，和我系统里最危险的那一类是同一个。

他们的表述是：每一步局部有效、最终交付物可能正确，而整条轨迹已经不是被授权的那件事。我的系统里对应的是：每个数字都有证据行支撑、数字对账全部通过，而回答的不是用户问的那件事。前两天那个例子——一个裸编号被判成考试号，如果这个号在考试目录里恰好也存在，就会答出一个完全正确的数字、答的是另一件事。

我现在的把关全部落在「证据」这一个轴上：gates 验的是「回答里的数字有没有证据行支撑」。按他们的三轴分解，我缺的是另外两个：

- **Goal 轴**：这次取数与作答，回答的还是用户问的那个问题吗？（我有「复合提问被拆」「口径判不清」这些点状检查，但没有一个统一的「目标还对不对」的判据。）
- **Role 轴**：这次动作落在被授权的范围内吗？（我的隔离检查算是这一轴的一部分，但只覆盖企业边界。）

这不是说我该照抄一套 RGE 进来——我的链路只有六步，不是几十步的长程 agent，套一个在线信任状态机是过度设计。有价值的是那个分解本身：它让我看清「我的把关只覆盖了三个轴里的一个」，而这件事我此前没有一个说法能讲清楚。

二、「难度没变，是表示变了」这句话，正好总结了我这几天做的事。

我删掉的那九处定制，本质上全是换表示：从「按问句里出现哪个词判这个数字属于哪个概念」换成「模型填哪个 schema 槽位就是一次概念声明」；从「拿人写的名字去和列的说明做子串匹配」换成「那句话由声明生

成、人写不进去」。问题的难度一点没变，是判据从文字挪到了结构。以后我跟人解释这类改动，用他们这句话最省力。

三、他们那个「先用数据把一条自然的路堵死」的做法，我该学。

我这几天几次面对「要不要加一道检查」的选择，比如 caveats 那件事。我当时的做法是想清楚判据然后去实测——实测出来 10 个误报 0 个真阳性，那条路当场就否了。这个顺序是对的，但我是碰巧做对的，不是有意识地把它当方法。他们把「先测最自然的那条路」写成了论文的第 4 节，摆在方法之前。以后我提方案时，该主动先测那条最自然的路，而不是等到实现完才发现它不成立。

四、「所有领域、所有模型用同一套固定默认值，不按领域调参」这条纪律，和我那条判据是同一件事。

我的判据是「一个设计如果在实现通用能力，就不该和某个具体的指标、维度、主题绑定」。他们的表达方式是超参层面的：阈值不按领域调。两者是同一条纪律的两个说法——按领域调参就是「同类需求再来一个要再写一段」的连续版本。

五、他们那个诚实的结构性限制，提醒我把自己那条缺口写在同一个位置。

他们说伪一致性抓不到，取决于完成状态在外部是否可见，并且把这一条明确写成限制。我有一条对应的缺口：线上统一数仓还没部署，所以功能正确性目前只在 dev 这一份样本上验证过——样本形态齐全能挡住绝大多数机制失效，挡不住「只有生产规模才会出现的形态」。这条我写在了项目纪律里，但没有写在每次汇报结论的旁边。他们的做法是写在结论那一节，和结果并列。这个位置比藏在文档里强。

文中金句

"A long-horizon agent can fail without doing anything that looks wrong in isolation." 一个长程 agent 可以在「孤立地看，它没做任何一件看起来是错的事」的情况下失败。

"Each step remains plausible given what came before. The trajectory, taken as a whole, no longer does." 每一步在它之前那些步的基础上都说得通。而整条轨迹合起来，不再说得通。

"The final deliverable may be correct. The problem is that the evolving prefix has stopped being the authorized task, even though each individual step remains locally valid." 最终交付物可能是正确的。问题在于那条演进中的前缀已经不再是被授权的任务——尽管每一个单步都仍然局部有效。

"The relation between a prefix and its authorized task is not a property any single step can expose." 一条前缀与它被授权的任务之间的关系，不是任何单独一步能暴露出来的性质。

"The trajectories do not become easier; the representation changes." 这些轨迹并没有变得更容易；是表示变了。

"RGE uses LLMs only to derive structured task and step representations; trust-state updates, projections, and intervention decisions are deterministic, so the output is a replayable and auditable trust trajectory rather than a single end-to-end judge verdict."
RGE 只用大模型来产出结构化的任务表示与单步表示；信任状态的更新、投影与干预决策都是确定性的，所以输出是一条可回放、可审计的信任轨迹，而不是一次端到端的裁判结论。

"Long-horizon oversight cannot stop at suspicious steps; it must ask whether the trajectory is still the task the user authorized." 长程监督不能停在「可疑的单步」上；它必须问：这条轨迹还是用户授权的那个任务吗。

全文翻译

摘要

Long-horizon agents increasingly operate across many steps, tools, and observations. In this setting, the relevant oversight question is not only whether each action is locally valid, but whether the evolving trajectory still corresponds to the task the user authorized.

长程 agent 越来越多地跨很多步、很多工具、很多次观测来运作。在这种场景下，需要监督的问题不只是「每一个动作是否局部有效」，还有「这条演进中的轨迹是否仍然对应用户授权的那个任务」。

Drift can accumulate quietly: an agent may call the right tool with plausible arguments at every step, while its prefix moves toward a broader role, an adjacent objective, or evidence the user never supplied.

漂移会静静地累积：一个 agent 可能在每一步都用对的工具、传合理的参数，而它的前缀却在朝一个更宽的角色、一个相邻的目标、或者用户从未提供过的证据挪动。

Existing monitors mostly check local compliance, deliver final-trace verdicts, or score generic risk; they do not directly estimate this prefix-level relation. We introduce ontological trust, a task-conditioned property of trajectory prefixes, and instantiate it as RGE, an online monitor that decomposes trust along Role, Goal, and Evidence.

现有的监控器大多检查局部合规、给出最终轨迹的裁决、或者打一个泛泛的风险分；**它们不直接估计这个前缀层面的关系**。我们提出「本体性信任」——一个以任务为条件的、关于轨迹前缀的性质——并把它实例化为 RGE：一个沿着角色、目标、证据三个方向分解信任的在线监控器。

RGE uses LLMs only to derive structured task and step representations; trust-state updates, projections, and intervention decisions are deterministic, so the output is a replayable and auditable trust trajectory rather than a single end-to-end judge verdict.

RGE 只用大模型来产出结构化的任务表示与单步表示；信任状态的更新、投影与干预决策都是确定性的，所以输出是一条可回放、可审计的信任轨迹，而不是一次端到端的裁判结论。

We construct a cross-domain trajectory corpus from OSWorld, FinanceBench, and EICU-AC, covering benign executions, prefix-paired drift, and pseudo-consistency failures. On this corpus, RGE outperforms adapted rule-, judge-, and shield-style baselines on prefix-paired drift detection. With the two larger estimator models, it exceeds 93% Drift F1 on every benchmark while keeping benign coverage at or above 95.8%.

我们用 OSWorld、FinanceBench、EICU-AC 构造了一个跨领域的轨迹语料，覆盖良性执行、前缀配对的漂移、以及伪一致性故障。在这个语料上，RGE 在前缀配对漂移检测上超过了改编过的规则式、裁判式、盾式基线。用两个较大的估计模型时，它在每一个基准上的漂移 F1 都超过 93%，同时把良性覆盖率保持在 95.8% 及以上。

Pseudo-consistency is harder: detection depends on whether task completion is externally visible, a structural limit we characterize empirically.

伪一致性更难：能不能检测出来，取决于任务的完成状态在外部是否可见——这是一个**结构性的限制**，我们用实测把它刻画出来。

一、引言：一种不做任何看起来错的事的失败

A long-horizon agent can fail without doing anything that looks wrong in isolation. Asked to complete a delegated task, it may use the right tools, produce a plausible final deliverable, and still read files it was never asked to read, expand its role to verify "related" context, or continue acting after the user's request has already been satisfied.

一个长程 agent 可以在「孤立地看，它没做任何一件看起来是错的事」的情况下失败。被要求完成一件委派的任务时，它可能用了对的工具、产出了一份合理的最终交付物，却仍然读了从没被要求读的文件、为了核实「相关的」上下文而扩大了自己的角色、或者在用户的请求已经被满足之后继续行动。

Each step remains plausible given what came before. The trajectory, taken as a whole, no longer does. This kind of failure is not necessarily a safety violation in the usual sense, nor simply a task-completion failure. The final deliverable may be correct. The problem is that the evolving prefix has stopped being the authorized task, even though each individual step remains locally valid.

每一步在它之前那些步的基础上都说得通。而整条轨迹合起来，不再说得通。这类失败不一定是通常意义上的安全违规，也不只是任务完成上的失败。**最终交付物可能是正确的**。问题在于那条演进中的前缀已经不再是

被授权的任务——尽管每一个单步都仍然局部有效。

Current oversight tools rarely test this relation directly. Runtime monitors check whether actions break rules. Task and agent benchmarks check final outcomes or task completion. Security benchmarks expose explicit prompt-injection patterns. Local anomaly detectors flag unusual steps, and full-record judge or auditor methods often return an unstructured risk judgment or verdict. These checks miss the central question for long-horizon delegation. They do not ask whether the trajectory so far is still the task the user authorized.

当前的监督工具很少直接检验这个关系。运行期监控器检查动作有没有破规矩。任务与 agent 基准检查最终结果或任务完成度。安全基准暴露显式的提示注入模式。局部异常检测标记不寻常的单步，而全记录的裁判或审计方法往往返回一个非结构化的风险判断或裁决。[这些检查都没碰到长程委派的核心问题：它们没有问「到目前为止这条轨迹还是用户授权的那个任务吗」。](#)

One might hope that finer-grained step-level diagnostics could close this gap. They do not.

也许有人会希望，把单步级的诊断做得更细就能补上这个缺口。[它们补不上。](#)

二、把信任形式化成「有界的授权」

Long-horizon execution is a form of constrained delegation. When a user delegates task x , the authorization has explicit boundaries on what the agent may do, what objective it should pursue, and what evidence it may rely on. We formalize this bounded authorization as $D(x) = (R(x), G(x), E(x))$, where $R(x)$ is the authorized role, $G(x)$ the delegated objective, and $E(x)$ the evidence basis.

长程执行是一种受约束的委派。当用户委派任务 x 时，这份授权对三件事有明确的边界：agent 可以做什么、它该追求什么目标、它可以依赖什么证据。我们把这种有界授权形式化为三元组：被授权的角色、被委派的目标、证据基础。

We call the property ontological because the monitor tracks task identity under bounded authorization: whether the prefix still preserves the delegated role, goal, and evidence relation. These components are not chosen by convention; they follow from the structure of the agent - environment interaction itself.

我们把这个性质称作「本体性的」，因为监控器追踪的是[有界授权之下的任务同一性](#)：前缀是否仍然保持了被委派的角色、目标与证据关系。[这三个成分不是按惯例挑的，它们是从 agent 与环境交互的结构本身推出来的。](#)

In a standard POMDP view, deviation can arise in action selection, objective pursuit, or observation grounding. Role corresponds to actions outside the authorized subset of A , Goal to continued pursuit of a rewritten or adjacent objective, and Evidence to claims not supported by observed history.

在标准的部分可观测马尔可夫决策过程视角下，偏离只能出现在三处：动作选择、目标追求、观测接地。Role 对应「动作落在被授权的动作子集之外」，Goal 对应「继续追求一个被改写过的或相邻的目标」，Evidence 对应「作出观测历史支撑不了的声称」。

Each can fail independently: an agent may stay within role while pursuing the wrong objective, remain goal-directed while relying on unsupported evidence, or stay evidence-grounded while exceeding its authorized role.

三者可以各自独立地失效：一个 agent 可以守在角色之内而追错目标，可以保持目标导向而依赖没有支撑的证据，也可以证据扎实而越出它被授权的角色。

Because $D(x)$ is not directly observable, the monitor cannot verify it exactly. It instead estimates from the task and the history so far whether the execution still stays within the delegated role, continues the delegated objective, and remains grounded in the authorized evidence.

因为这份授权本身不可直接观测，监控器没法精确验证它。它只能从任务与到目前为止的历史出发去**估计**：这次执行是否还守在被委派的角色内、是否还在继续那个被委派的目标、是否还扎在被授权的证据上。

三、前置分析：单步的正常不能确立本体性信任

We evaluate nine snapshot metrics, covering token-level uncertainty, semantic consistency, and causal grounding, across three evaluator models on a Living-off-the-Land trajectory corpus. In this corpus, every step uses legitimate tools, but the prefix departs from the user's authorized task.

我们在一个「就地取材」式的轨迹语料上，评估了九个快照指标（覆盖词元级不确定性、语义一致性、因果接地）乘三个评估模型。在这个语料里，**每一步都在使用合法工具**，而前缀已经偏离了用户授权的任务。

The best of all 9×3 combinations of snapshot metric and evaluator model reaches 73.49% AUC, achieved by Causal Grounding with Llama-3-8B-Instruct. No other configuration exceeds this, and most fall well below. Predictive Entropy in particular stays close to random (47 - 56%) across all three evaluators.

在全部 9 乘 3 个「快照指标乘评估模型」的组合里，最好的一个达到 **73.49% AUC**（因果接地配 Llama-3-8B-Instruct）。没有别的配置超过它，而大多数远低于它。**预测熵这一项在三个评估器上都接近随机（47 - 56%）。**

Benign and drifting steps overlap heavily under every metric we tested, consistent with the introduction's core diagnosis: the relation between a prefix and its authorized task is not a property any single step can expose.

在我们测过的每一个指标下，良性的步与漂移的步都严重重叠——这与引言里的核心判断一致：**一条前缀与它被授权的任务之间的关系，不是任何单独一步能暴露出来的性质。**

四、三轴坐标把信号找回来了

If step-local features miss the prefix-task relation, the next question is whether the Role - Goal - Evidence coordinates recover it. We ask a zero-shot LLM evaluator to score each trajectory along the three axes and take its maximum-deviation step as a point in the resulting space.

如果单步局部特征抓不到「前缀与任务的关系」，下一个问题是：角色－目标－证据这三个坐标能不能把它找回来。我们让一个零样本的大模型评估器沿这三个轴给每条轨迹打分，取偏离最大的那一步作为这个空间里的一个点。

Benign executions cluster near the trust origin, while drifting executions spread outward as one or more coordinates grow large. In the original three dimensions, the same (R, G, E) scores reach 97.67%, 97.45%, and 98.86% trajectory AUC on Qwen3-4B, Llama-8B, and GPT-4o-mini, well above the 73.49% snapshot ceiling on the same trajectories.

良性执行聚在「信任原点」附近，而漂移的执行随着一个或多个坐标变大而向外散开。在原始的三维空间里，同一批 (R, G, E) 分数在三个模型上分别达到 97.67%、97.45%、98.86% 的轨迹级 AUC，[远高于同一批轨迹上 73.49% 的单步天花板](#)。

Removing any one coordinate reduces AUC on every evaluator. The trajectories do not become easier; the representation changes. Step-local metrics fail because they do not encode the prefix-task relation, while the three RGE coordinates do.

去掉任何一个坐标，在每一个评估器上 AUC 都会下降。[这些轨迹并没有变得更容易；是表示变了](#)。单步局部指标失效，是因为它们没有编码「前缀与任务的关系」，而 RGE 那三个坐标编码了。

五、方法：把三个偏离合成一个决策

At each step the monitor combines the three deviation coordinates into an instantaneous deviation score. A linear combination is often sufficient when drift concentrates on one axis, but it can miss joint regimes in which Role, Goal, and Evidence each show only modest departures whose combination already violates the authorization.

在每一步，监控器把三个偏离坐标合成一个瞬时偏离分数。当漂移集中在某一个轴上时，线性组合往往就够了；[但它会漏掉「联合情形」——角色、目标、证据各自只有轻微偏离，而三者的组合已经违反了授权](#)。

We therefore add a structural coupling term that activates only when all three axes exceed their axis-level thresholds. The geometric mean keeps the term between zero and one. We use fixed defaults across all domains and estimator models, with no per-domain tuning.

因此我们加了一个[结构耦合项](#)，它只在三个轴同时都超过各自的轴级阈值时才激活。几何平均把这一项约束在 0 到 1 之间。我们在所有领域、所有估计模型上使用同一套固定默认值，不做按领域的调参。

The monitor then maintains a compact temporal state: sustained accumulated deviation, whether that accumulation is still increasing, and a short-horizon exponential moving average of recent deviation. The intervention severity rule uses the latter two to distinguish persistent deterioration from transient spikes.

监控器随后维护一个紧凑的时间状态：持续累积的偏离、这个累积是否还在增长、以及近期偏离的短程指数移动平均。[干预的严重度规则用后两个来区分「持续恶化」与「一次性尖峰」。](#)

六、结论

We define ontological trust as a task-conditioned property of trajectory prefixes and instantiate it as RGE, an online monitor that uses LLMs only to derive structured task and step representations; trust-state updates and intervention decisions are deterministic.

我们把「本体性信任」定义为一个以任务为条件的、关于轨迹前缀的性质，并把它实例化为 RGE：一个在线监控器，只用大模型产出结构化的任务表示与单步表示；信任状态的更新与干预决策都是确定性的。

Across OSWorld, FinanceBench, and EICU-AC, RGE detects prefix-paired drift with high benign coverage, with remaining errors concentrated where task closure is hidden.

在 OSWorld、FinanceBench、EICU-AC 三个领域上，RGE 以很高的良性覆盖率检测出前缀配对的漂移，[剩下的错误集中在「任务是否已经收尾」被隐藏起来的那些情形。](#)

Long-horizon oversight cannot stop at suspicious steps; it must ask whether the trajectory is still the task the user authorized. RGE tracks that relation online without an end-to-end LLM verdict, leaving open what evidence interfaces future agent environments should expose to make closure, authorization, and surplus action monitorable.

长程监督不能停在「可疑的单步」上；它必须问：这条轨迹还是用户授权的那个任务吗。RGE 在线追踪这个关系，而不依赖一次端到端的大模型裁决；[至于未来的 agent 环境该暴露什么样的证据接口，才能让「收尾、授权、多余动作」这三件事变得可监控，这个问题留着没有回答。](#)

参考链接

- [arXiv:2608.17718](#) — 本文的 arXiv 页面 (Beyond Suspicious Steps, 2026 年 8 月 18 日)
- [OSWorld](#) — 多模态 agent 在真实桌面环境里的基准，本文三个语料来源之一
- [AgentSpec](#) — 本文作为「规则式运行期监控」基线对比的工作
- [FinanceBench](#) — 金融问答基准，本文语料来源之一