

知识图谱是高风险 AI 的问责层 Knowledge Graphs Are the Accountability Layer for High-Stakes AI

本篇范围说明：这是 Neo4j 开发者博客 2026-06-15 的一篇文章（作者 Konrad Kaliciński，标称 9 分钟阅读）。下面「全文翻译」一节覆盖文章正文全部小节；文末的站内导航、相关文章推荐、以及资源清单里的链接标题不逐条翻译，有信息价值的链接汇总在「参考链接」。

核心内容

Q：这篇文章的主张是什么？

A：在制药、法律、保险、国防这些「一个错答案会造成真实损害」的领域，能真正跑起来的 AI 系统有一个共同点——**它们都能把自己的推理过程摊出来给人看**。而做不到这一点的系统正在成批出事。作者的结论是：知识图谱不是一种架构偏好，在这些领域里它是承重结构。

Q：作者用什么证据说「这些系统已经在真实运行」？

A：他举了四个已经上生产的例子，覆盖四个行业。这张表回答一个问题：每个系统解决的是什么问题、规模多大。「为什么用图」一列是原文给的理由，不是我的推断。

系统	行业与规模	为什么用图
上海「206 系统」	司法。每一起刑事案件都过一遍；最高人民法院已在全国法院强制推行，法官一键自动生成超过 70% 的判决书草稿	文革之后中国大约 10 亿人口只有约 2000 名执业律师，这个缺口从未真正填上，案件量暴涨而司法培训不均衡，政府转向自动化
阿斯利康 BIKG	制药。1090 万个节点、22 种节点类型、1.18 亿条边，跑在 Neo4j 上	现代生物医学数据散落在几十个数据库、格式和内部孤岛里，没有任何人类团队能把它全装在脑子里
苏黎世保险	保险。2000 万节点、3500 万关系，Neo4j 加 Linkurious 做可视化	原先基于规则的系统把调查员淹没在互不相关的告警和误报里；每年省下 5 万小时，分流时间降低 30%
以色列 Lavender	国防。给加沙 230 万居民每人打一个 1 到 100 的「武装关联度」分	目标是以任何分析团队都达不到的速度处理情报；架构在功能上就是一张社交网络图

读法：拿第二行走一遍。阿斯利康建 BIKG 不是因为图数据库时髦，而是因为它要连的数据本来就分散在几十个来源里，而**药物发现的监管要求就是要看到「这个化合物作用于这个基因、这个基因关联这个疾病、由这些论文和这次实验支撑」这条链**。那条链不是一个功能特性，是监管的硬要求。

Q：失败的那些系统，共同点是什么？

A：它们没法把自己的工作过程摊出来。作者给了一串数字：全球已有 486 起法庭案件涉及 AI 编造的内容，其中美国 324 起、牵连 128 名律师和 2 名法官。有一位洛杉矶律师被罚款，因为他上诉状里 23 条引文有 21 条是 ChatGPT 编的。

作者对语言模型编造的描述很准：它们编造的时候不会打折扣，它们用和真引文完全一样的语气交付编造出来的判例——没有不确定，没有免责声明，只是把错答案打扮成对答案。

另外两个例子是政府层面的：澳大利亚的 Robodebt 项目基于有缺陷的收入平均法自动生成了几十万人的福利欠款通知，很多欠款根本是错的，有人失去住房、有人自杀；荷兰政府 2021 年倒台，起因是一个算法把大约 26000 名家长标记为儿童福利欺诈者，而且不成比例地针对非荷兰姓氏的人——那个算法直接把国籍当成了打分变量，国际特赦组织称这些系统是「排外机器」。

每一起失败都走同一条弧线：AI 系统做了一个有后果的决定；没人能重建它是怎么做出来的；损害不断累积，直到有人终于问出那个第一天就该问的问题——这个答案是从哪来的？

Q：「图支撑的检索增强」和普通的检索增强，差别在哪？

A：普通做法是按向量相似度取回文本块交给语言模型。你拿到一个答案，也许还拿到一个来源列表，而答案和来源之间的联系是「感觉」——模型觉得这几块看起来相关。作者的原话是：拿这个去跟审计员解释，祝你好运。

图支撑的做法不同：从问题到答案的路径是一个可以查询的东西。文章给了一段 Cypher 查询作为例子，意思是「这个回答由哪些事实支撑、每个事实从哪份文档抽出来、置信度多少」。每个事实是一个节点，每条引用是一条边，推理不藏在注意力权重里，而是一个你可以跑、可以检查、可以反驳的数据库查询。

作者接着说了一句很实在的话：这听起来比「自主智能体自己写代码」无聊得多——而这正是重点。当一个错答案意味着一款药基于错误证据进入临床试验、或者一次欺诈索赔毁掉某人一年时，无聊是一个优点。

Q：监管方面发生了什么？

A：过去 18 个月出了四份重要框架，作者说它们「用不同的字体说同一件事」：

框架	时间	关键要求
NIST AI 600-1	2024 年 7 月	把「虚构」（他们用这个词代替「幻觉」）列为生成式 AI 十二项核心风险之一，明确要求接地控制：来源白名单、引用策略、检索约束
欧盟 AI 法案	2026 年 8 月生效	高风险 AI 要求准确性、透明性、文档、人工监督；制药 AI 被明确划为高风险。如果你的模型证明不了答案从哪来，就是不合规——不是含糊意义上的，是「你不能部署」意义上的
FDA 加 EMA 联合原则	2026 年 1 月	十条药品全生命周期 AI 原则，可解释性、可说明性、稳健性都是必需。这是全球两大药监机构第一次就 AI 发联合立场

框架	时间	关键要求
澳大利亚 APRA	2026 年 4 月	要求 AI 工具清单、全生命周期问责、高风险决策的人在环、董事会成员真正懂 AI。而在澳大利亚的金融问责制度下， 高管对 AI 相关后果承担个人责任

这些不是思想领导力文章，它们有合规截止日期。

背景补充 / 点评

先说这篇文章里那个最值得记的数字，以及为什么要对它保持怀疑。

作者说：在面向 KPI、预测、合规检查这类「受监管行业真正关心的、绑定模式的查询」上，**纯向量检索在某些测试中的准确率基准是 0%，而 GraphRAG 超过 90%**。他的评价是「这不是边际改进，是另一个类别」。

这个数字要打折看，理由有两条。 第一，这是 Neo4j 自己的开发者博客，而 GraphRAG 是它的产品方向——**利益相关方给出的对照，方向可信但幅度不可引用**。第二，「某些测试中 0%」这个表述本身可疑：一个方法在某类查询上完全归零，通常说明那类查询压根不在它的设计范围内（比如需要多跳连接和精确聚合的结构化查询，向量相似度本来就不做这件事），而不是它「不如」另一个方法。**拿一个方法的设计边界外的表现去和另一个方法比，得出的差距会被放大。**

再说这篇文章的一个真洞察。 它最后一节的标题是「没人愿意谈的那部分」，内容是：

最可靠的 AI 架构，也是最不激动人心的那些。 它们不即兴发挥，不从无到有生成洞察，它们在一个精心维护的知识库里查东西，然后把凭据一起给你。任何建过搜索引擎的人一眼就能认出来——**这就是检索，只是数据结构更好。**

作者紧接着写：**如果这让魔法感消退了一点，那很好。魔法不是你想在一个批准抗癌药的系统里看到的東西。**

这一段的价值在于它把话说反了过来：通常的叙述是「知识图谱能让 AI 更聪明」，而这篇说的是**知识图谱让 AI 更笨，而这正是它在高风险场景里被选中的原因。**

这篇文章的留白。 它通篇在论证「能追溯的架构才可靠」，但它举的国防那个例子（Lavender）恰恰说明**追溯性不等于正确性**——那个系统的架构在功能上就是一张社交网络图，实体链接、关系遍历、邻近度打分，该有的可追溯性都有，而争议在于误报和战争中的自动化目标选定。作者提了一句「争议很激烈，而且理由充分」，但没有回到自己的论点上去处理它：**一个每一步都可追溯的系统，仍然可以在每一步都追溯得清清楚楚的情况下造成大规模错误。** 可追溯性解决的是「事后能不能查」，不解决「事前对不对」。这个区分文章没有做。

对我自己的启示。 有两点，一点是直接可用的，一点是提醒。

直接可用的那一点：那四份监管框架里，**欧盟 AI 法案的高风险义务是 2026 年 8 月生效——就是这一个月。** 如果 UMU 的产品要面向欧洲的企业客户，而其中有涉及员工评估、能力认定这类决定的功能，那「模型给

出的结论能不能追溯到具体证据」这件事的性质就从「做得好」变成了「能不能部署」。**这一条我需要去确认：我们现在有哪些功能会落进它的高风险清单。这篇文章没有给答案，但它给了要去查的那个日期。**

而这一点直接连着 prove 那个项目现在的两个机制。 prove 里有一道叫 gates 的数字对账——回答里出现的每个数字都必须能在证据表里找到对应的行。这篇文章里那段 Cypher 查询做的是同一件事的图版本：从回答出发，沿着「由什么支撑」这条边走到事实，再走到文档。**两者的形状一样，都是「答案到证据的路径必须是一个可查询的东西，不是一段感觉」。**我原本把 gates 当成一道防幻觉的闸，这篇文章提醒我它同时是合规资产——它产出的正是审计需要的那条链。

提醒那一点：可追溯不等于对。 Lavender 那个例子对我是个具体的警告。prove 的 gates 能保证「这个数字来自这一行」，但保证不了「这一行是不是该被用来回答这个问题」——那正是 8 月中旬反复撞到的那类错误（数字真实、口径不是要的那个、对账全过）。**这篇文章把可追溯性说成了问责层，但它自己举的例子说明：问责层能让你事后查清责任，不能替你在事前做对。**我不该把「gates 全绿」读成「答案对」。

文中金句

"LLMs don't hedge when they hallucinate. They deliver invented case law in the exact same tone as real citations — no uncertainty, no disclaimers. Just wrong answers dressed up as right ones." 语言模型编造的时候不会打折扣。它们用和真引文完全一样的语气交付编造出来的判例——没有不确定，没有免责声明，只是把错答案打扮成对答案。

"The link between the two is vibes where the model thought these chunks seemed relevant. Good luck explaining that to an auditor." 答案和来源之间的联系是「感觉」——模型觉得这几块看起来相关。拿这个去跟审计员解释，祝你好运。

"I realize this sounds aggressively boring next to autonomous agents writing their own code. That's the point. Boring is a feature when a wrong answer means a drug goes to trial on bad evidence." 我知道这跟「自主智能体自己写代码」比起来无聊得刺眼。这正是重点。当一个错答案意味着一款药基于错误证据进入临床试验时，无聊是一个优点。

"Pick 'I can show you exactly why' over 'I'm 94% confident.'" 在「我能确切地告诉你为什么」和「我有 94% 的置信度」之间，选前者。

全文翻译

一、AI 早就不是实验性的了

This isn't speculation. These systems are live.

这不是推测。这些系统正在运行。

In Shanghai, every criminal case runs through System 206, an AI assistant that flags evidence gaps, checks sentencing consistency, and recommends severity. The backstory matters: after the Cultural Revolution, China had roughly 2,000 practicing lawyers for a population of a billion. That vacuum never fully closed. Caseloads exploded, judicial training stayed uneven, and the government reached for automation. Today, the Supreme People's Court has mandated AI across all courts. Judges auto-generate over 70% of judgment drafts with one click.

在上海，每一起刑事案件都要过一遍「206 系统」——一个会标出证据缺口、检查量刑一致性、并给出严重程度建议的 AI 助手。它的来龙去脉是要紧的：文革之后，中国大约 10 亿人口只有约 2000 名执业律师。那个真空从未真正填上。案件量暴涨，司法培训始终不均衡，于是政府转向自动化。今天，最高人民法院已经在全国法院强制推行 AI。法官一键自动生成超过 70% 的判决书草稿。

AstraZeneca's Biological Insights Knowledge Graph connects 10.9 million nodes and 118 million edges for drug discovery and target identification. They built it because modern biomedical data is scattered across dozens of databases, formats, and internal silos, and no human team can hold it all in their head.

阿斯利康的「生物学洞察知识图谱」为药物发现与靶点识别连接了 1090 万个节点和 1.18 亿条边。他们建它的原因是：现代生物医学数据散落在几十个数据库、格式和内部孤岛里，没有任何人类团队能把它全部装在脑子里。

Zurich Insurance uses a 20-million-node graph to catch fraud rings. Before that? Their rule-based system drowned investigators in disconnected alerts and false positives. Mapping the actual relationships between claimants, accounts, and policies as a graph cuts through the noise. 50,000 hours saved per year.

苏黎世保险用一张 2000 万节点的图来抓欺诈团伙。在那之前呢？他们基于规则的系统把调查员淹没在互不相关的告警和误报里。把索赔人、账户、保单之间真实的关系映射成一张图，就能穿透这些噪音。每年省下 5 万小时。

And then there's defense. Israel's Lavender system scored every one of Gaza's 2.3 million residents on a 1 - 100 scale of militant affiliation. It cross-referenced phone metadata, WhatsApp groups, social connections, and movement patterns. The architecture is functionally a social network graph — entity linking, relationship traversal, proximity scoring. The controversy around false positives and automated targeting in warfare is intense, and for good reason.

然后是国防。以色列的 Lavender 系统给加沙 230 万居民每一个人打了一个 1 到 100 的「武装关联度」分。它交叉比对了电话元数据、WhatsApp 群组、社交关系和移动模式。这个架构在功能上就是一张社交网络图——实体链接、关系遍历、邻近度打分。围绕误报和战争中自动化目标选定的争议非常激烈，而且理由充分。

These aren't research demos. They're production systems making calls about freedom, health, money, and lives.

这些不是研究演示。它们是生产系统，在对自由、健康、金钱和生命做出判断。

二、失败的那些有一个共同点：它们没法把工作过程摊出来

486 court cases globally now involve AI-hallucinated content. 324 in the US alone — 128 lawyers implicated, two judges. A Los Angeles attorney got fined after 21 of 23 quotes in an appellate brief turned out to be invented by ChatGPT.

全球现在有 486 起法庭案件涉及 AI 编造的内容。仅美国就有 324 起——牵连 128 名律师和 2 名法官。一位洛杉矶律师被罚款，因为他上诉状里 23 条引文有 21 条被查出是 ChatGPT 编的。

LLMs don't hedge when they hallucinate. They deliver invented case law in the exact same tone as real citations — no uncertainty, no disclaimers. Just wrong answers dressed up as right ones. These aren't edge cases anymore. There's a database tracking them.

语言模型编造的时候不会打折扣。它们用和真引文完全一样的语气交付编造出来的判例——没有不确定，没有免责声明，只是把错答案打扮成对答案。这些已经不再是边缘案例了。已经有一个数据库在追踪它们。

Australia's Robodebt program auto-generated welfare debt notices for hundreds of thousands of people based on flawed income averaging. Many debts were simply wrong. People lost homes. Some took their lives.

澳大利亚的 Robodebt 项目基于有缺陷的收入平均法，自动为几十万人生成了福利欠款通知。很多欠款根本就是错的。有人失去了住房。有人自杀了。

The Dutch government collapsed in 2021 after it came out that an algorithm had flagged around 26,000 parents as childcare benefits cheats, disproportionately targeting people with non-Dutch last names. Amnesty International called the systems "xenophobic machines." That's not hyperbole. The algorithm literally used nationality as a scoring variable.

荷兰政府在 2021 年倒台，起因是曝出一个算法把大约 26000 名家长标记为儿童福利欺诈者，并且不成比例地针对非荷兰姓氏的人。国际特赦组织称这些系统是「排外机器」。这不是夸张。那个算法真的把国籍当成了一个打分变量。

Every one of these failures follows the same arc. An AI system makes a consequential decision. Nobody can reconstruct how. The damage compounds until someone finally asks the question that should have been asked on day one: where did this answer come from?

这些失败每一起都走同一条弧线。一个 AI 系统做出了一个有后果的决定。没有人能重建它是怎么做出来的。损害不断累积，直到终于有人问出那个第一天就该问的问题：[这个答案是从哪来的？](#)

三、知识图谱已经在哪些地方解决了这个问题

The organizations getting high-stakes AI right didn't all read the same whitepaper. But they converged on the same architecture: ground the AI in a knowledge graph. Not because it's fashionable, but because every relationship in a graph is explicit, traceable, and queryable.

那些把高风险 AI 做对了的组织，并不是都读了同一份白皮书。但它们收敛到了同一个架构：把 AI 接地到一张知识图谱上。不是因为这时髦，而是因为**图里的每一条关系都是显式的、可追溯的、可查询的**。

When the system flags a potential drug target, you don't get a probability score and a shrug. You get: this compound targets this gene, which is linked to this disease, supported by these papers and this experiment. That chain isn't a feature. In drug discovery, it's what regulators require.

当系统标出一个潜在的药物靶点时，你拿到的不是一个概率分加一个耸肩。你拿到的是：这个化合物作用于这个基因，这个基因关联这个疾病，由这些论文和这次实验支撑。**那条链不是一个功能特性。在药物发现里，它是监管方要求的东西。**

An investigator asking "why was this flagged?" gets a visible path, not a number. Triage time down 30%.

一个调查员问「这条为什么被标出来了？」，他得到的是一条看得见的路径，不是一个数字。分流时间降低 30%。

四、图接地的 AI 在实践中是什么样

Standard RAG retrieves text chunks by vector similarity and hands them to an LLM. You get an answer. Maybe you get a source list. The link between the two is vibes where the model thought these chunks seemed relevant. Good luck explaining that to an auditor.

标准的检索增强按向量相似度取回文本块，交给语言模型。你得到一个答案。也许你还得到一个来源列表。而这两者之间的联系是「感觉」——模型觉得这几块看起来相关。拿这个去跟审计员解释，祝你好运。

Graph-backed RAG is different. The path from question to answer is a thing you can query. Every fact is a node. Every citation is an edge. The reasoning isn't hidden in attention weights, but it's a database query you can run, inspect, and argue with.

图支撑的检索增强不同。从问题到答案的路径是一个**你可以查询的东西**。每个事实是一个节点，每条引用是一条边。推理不藏在注意力权重里，而是一个你可以运行、可以检查、可以反驳的数据库查询。

I realize this sounds aggressively boring next to autonomous agents writing their own code. That's the point. Boring is a feature when a wrong answer means a drug goes to trial on bad evidence or a fraud claim ruins someone's year.

我知道这跟「自主智能体自己写代码」比起来无聊得刺眼。这正是重点。当一个错答案意味着一款药基于错误证据进入临床试验、或者一次欺诈索赔毁掉某人一年时，无聊是一个优点。

On schema-bound queries for KPIs, forecasts, compliance checks, the stuff regulated industries actually care about, vector-only RAG benchmarks at 0% accuracy in some tests. GraphRAG: over 90%. Not a marginal improvement. A different category.

在面向 KPI、预测、合规检查这些「受监管行业真正关心的东西」的、绑定模式的查询上，纯向量检索在某些测试里的准确率基准是 0%。GraphRAG 超过 90%。这不是边际改进，是另一个类别。

五、监管方追上来了

Four major frameworks dropped in the past 18 months. They all say the same thing in different fonts.

过去 18 个月里出了四份重要框架。它们用不同的字体说同一件事。

NIST AI 600 - 1 (July 2024) identified "confabulation" (their word for hallucination) as one of 12 core GenAI risks. They specifically call for grounding controls: source allow-lists, citation policies, and retrieval constraints. This is the US government saying "RAG isn't optional."

NIST AI 600-1 (2024 年 7 月) 把「虚构」（他们用这个词代替「幻觉」）列为生成式 AI 十二项核心风险之一。他们明确要求接地控制：来源白名单、引用策略、检索约束。这相当于美国政府在说「检索增强不是可选项」。

EU AI Act (high-risk obligations kick in August 2026) requires accuracy, transparency, documentation, and human oversight for high-risk AI. Pharma AI is explicitly classified as high-risk. If your LLM can't prove where its answers came from, it's non-compliant. Not in a hand-wavy way. In a "you can't deploy this" way.

欧盟 AI 法案（高风险义务 2026 年 8 月生效）要求高风险 AI 具备准确性、透明性、文档和人工监督。制药 AI 被明确划为高风险。**如果你的语言模型证明不了它的答案从哪来，它就是不合规的。不是含糊意义上的不合规，是「你不能部署这个东西」意义上的不合规。**

FDA + EMA (January 2026) jointly published 10 principles for AI in the medicines lifecycle. Interpretability, explainability, robustness are all required. First time the two biggest drug regulators on the planet issued a joint position on AI.

FDA 加 EMA (2026 年 1 月) 联合发布了药品生命周期中 AI 的十条原则。可解释性、可说明性、稳健性都是必需的。这是全球两大药监机构第一次就 AI 发出联合立场。

APRA (April 2026). Australia's prudential regulator published its first AI-specific expectations. AI inventory of all tools, lifecycle accountability, human-in-the-loop for high-risk decisions, board

members who actually understand AI. And under Australia's Financial Accountability Regime, executives are personally liable for AI-related outcomes. Personally.

APRA (2026 年 4 月)。澳大利亚审慎监管局发布了它第一份针对 AI 的预期要求：所有工具的 AI 清单、全生命周期问责、高风险决策的人在环、以及真正懂 AI 的董事会成员。而在澳大利亚的金融问责制度下，[高管对 AI 相关的后果承担个人责任。个人责任。](#)

These aren't thought leadership pieces. They have compliance dates.

这些不是思想领导力文章。[它们有合规截止日期。](#)

六、没人愿意谈的那一部分

The most reliable AI architectures are also the least exciting ones.

最可靠的 AI 架构，也是最不激动人心的那些。

They don't improvise. They don't generate insights from nothing. They look things up in a curated knowledge base and hand you the receipts. Anyone who's built a search engine will recognize this immediately. It's retrieval with better data structures. If that deflates the magic a bit, good. Magic is not what you want in a system approving cancer drugs.

它们不即兴发挥。它们不从无到有生成洞察。它们在一个精心维护的知识库里查东西，然后把凭据一起给你。任何建过搜索引擎的人一眼就能认出这是什么——[这就是检索，只是数据结构更好](#)。如果这让魔法感消退了一点，那很好。魔法不是你想在一个批准抗癌药的系统里看到的東西。

AstraZeneca, Zurich, the CLAKG researchers — they all made the same bet. Trade some generative flexibility for full traceability. Pick "I can show you exactly why" over "I'm 94% confident."

阿斯利康、苏黎世保险、CLAKG 的研究者——他们都下了同一个注：[用一部分生成灵活性去换完整的可追溯性。在「我能确切地告诉你为什么」和「我有 94% 的置信度」之间，选前者。](#)

Knowledge graphs are what makes that trade-off work. Not the only piece, but the layer that turns "the AI said so" into a graph you can walk from question to evidence, edge by edge. If your industry is regulated, or if a wrong answer has worse consequences than a thumbs-down button, this isn't an architecture preference. It's load-bearing infrastructure.

知识图谱是让这个交换成立的东西。它不是唯一的零件，但它是那一层——[把「AI 说是这样」变成一张你可以从问题一条边一条边走到证据的图](#)。如果你所在的行业受监管，或者一个错答案的后果比「点个不喜欢」更严重，那这就不是一种架构偏好。它是承重的基础设施。

参考链接

- [阿斯利康 BIKG \(bioRxiv\)](#) — 1090 万节点的生物学洞察知识图谱，文中制药案例的原始论文
- [苏黎世保险欺诈检测 \(Neo4j 客户案例\)](#) — 2000 万节点抓欺诈团伙，每年省 5 万小时那个数字的出处
- [CLAKG: 知识图谱加语言模型做中国法条推荐 \(arXiv\)](#) — 相对朴素检索增强把准确率推高 26% 的那篇
- [XAI4Wind 多模态知识图谱 \(arXiv\)](#) — 风机维护，把 SCADA 数据、告警日志、技师报告和照片放进同一张图
- [NIST AI 600-1 生成式 AI 风险画像](#) — 把「虚构」列为十二项核心风险之一并要求接地控制
- [欧盟 AI 法案](#) — 高风险义务 2026 年 8 月生效，这是本文里离我们最近的一个合规日期
- [FDA 与 EMA 的 AI 联合原则](#) — 两大药监机构第一次联合立场
- [APRA 致业界关于 AI 的信](#) — 高管个人担责那一条的出处
- [AI 幻觉法庭案件数据库 \(Damien Charlotin\)](#) — 486 起案件那个数字的来源，可持续追踪
- [Lavender 调查报道 \(+972 Magazine\)](#) — 国防那个例子的调查原文
- [荷兰儿童福利丑闻 \(国际特赦组织\)](#) — 「排外机器」这个说法的出处