

结构内化的规则语言模型：让知识图谱推理忠于图

Structure-Internalized Rule Language Model for Faithful Knowledge Graph Reasoning

本篇范围说明：这是一篇 arXiv 论文 (2608.17443v1, 2026-08-18, 合肥工业大学与南京理工大学)。下面「全文翻译」一节覆盖摘要、引言里那个核心问题的定义与案例、方法的三个组件、以及实验的主要发现与结论；数学推导、超参数敏感性图表、以及附录里的数据集描述和伪代码不逐段翻译。

核心内容

Q：这篇论文识别出了什么问题？

A：一个它命名为「**推理证据感知漂移**」的问题。意思是：让大语言模型在知识图谱上做推理时，**模型会按自己预训练时形成的语义偏好去挑证据，而不是严格遵循知识图谱本身能推出的结构约束**。结果是模型生成的推理逻辑看起来语义上说得通，但在知识图谱里落不了地。

Q：这个问题的具体样子是什么？

A：论文的图 1 给了一个案例，问的是「变形金刚的发行地区是哪里？」正确答案是瑞士。

模型倾向于接受的是这条断言：「由同一家公司出品或发行的电影，很可能在同一地区发行」。它因此把证据空间锚定在一个子图上——《阿甘正传》和《怪物的某种形态》与《变形金刚》共享同一家电影公司或发行商，而这两部片子的发行地区明确指向瑞士。

而知识图谱里能显式推出的那条结构规则是另一条： $\text{发行地区}(X, Y) = \text{语言}(X, Z) \wedge \text{使用语言}(X, Z)$ 。模型把这条判成了「弱相关的证据空间」。

还有第三层，我认为是这个案例里最尖锐的一处：知识图谱里有些关系路径是用匿名标识符表示的（比如 Wikidata 的属性编号 **P530**）。模型在推理时明说了「推理条件里含有我无法识别的标识符 P530」——因为这些标识符没有自然语言语义，模型会故意忽略这部分结构证据，而那部分证据本来可能支撑正确的推理。

Q：这个问题的根子在哪？

A：论文的说法是「知识图谱结构表示」与「语言模型参数化知识」之间的**表示不一致**。语言模型是在自然语言语料上预训练的，它理解「语言」「使用语言」这种词，不理解 **P530**；它对「同公司发行 → 同地区发行」这种符合常识的因果链有偏好，而对「语言 $\wedge$ 使用语言 → 发行地区」这种在图里成立但常识上不顺的规则没有偏好。于是它对结构线索的忽略和对语义线索的偏好，共同把推理过程推离了正确的证据空间。

Q：论文提出的方法由哪几部分组成？

A：整体叫 SIRLM（结构内化的规则语言模型），三个组件。这张表回答一个问题：每个组件解决上面那个问题的哪一层。

组件	做什么	解决哪一层
KG tokenizer（基于结构不变性学习）	把知识图谱的元素编码成通用的结构表示，让语言模型以新 token 的形式接住它们，不需要特定的文字标注	那个 P530 无法识别的问题——不再依赖关系有没有可读名字
SIRG（结构内化规则生成器）	带一个「结构关系记忆」机制的上下文学习块，在生成规则时让预训练知识与结构上下文对齐	语义偏好压倒结构约束的问题
神经符号推理器（基于规则约束的消息传播）	作为规则执行器，把「规则忠实度」这个由推理结论构成的指标反馈给 SIRG	形成闭环，强化结构一致的推理

读法：拿第一行走一遍。传统做法是把关系名当文本喂给模型，于是关系叫 `speak in` 模型能懂、叫 `P530` 就懵。这个组件把结构本身编码成表示，让模型认的是结构位置而不是名字，于是有没有可读名字这件事不再决定模型愿不愿意用它。

Q：效果怎么样？

A：在 36 个数据集上和 17 个方法比。数据集分三类：4 个直推式（FB15k-237、WN18RR、CoDEx-M、NELL995）、12 个归纳式实体、20 个全归纳式。四种训练范式都跑了：从零端到端、预训练、监督微调、GRPO 后训练。

平均增益（相对所有基线里的最优值）：直推式的四个数据集上，平均倒数排名提升 4.13% 到 6.92%，前十命中率提升 5.11% 到 6.01%；而在 20 个全归纳式数据集上，两项分别提升 10.30% 和 12.05%。

这个分布本身是结论的一部分：全归纳式指的是测试时的实体和关系都是训练时没见过的。提升幅度在最难的那一类上最大，说明这套方法解决的确实是「模型面对不熟悉的图时不知道该信什么证据」这个问题，而不是在熟悉的图上多背了一些事实。

背景补充 / 点评

先解释三个术语，它们是读懂这篇的前提。

知识图谱推理（KGR）：知识图谱把真实世界的事实存成「实体—关系—实体」的三元组，但图总是不完整的，很多事实没被记录。知识图谱推理就是利用图里已有的上下文去推断缺失的事实。

直推式与归纳式：直推式指测试时遇到的实体和关系在训练时都见过；归纳式指测试时会遇到新实体；全归纳式指实体和关系都是新的。传统的嵌入方法（把实体和关系映射成向量）在归纳式场景下压根不适用——论文的对照表里那些格子直接标 NA，因为一个训练时没见过的实体没有向量。

平均倒数排名 (MRR) 与 **前十命中率 (Hit@10)**：这类任务的评法是给一个不完整的三元组（比如「变形金刚，发行地区，？」），让模型对所有候选实体排序。前十命中率是正确答案落在前十名里的比例；平均倒数排名是「正确答案排名的倒数」的平均值——排第一得 1 分，排第二得 0.5 分，排第十得 0.1 分。**所以平均倒数排名比前十命中率更看重「排得多前」，而不只是「进没进前十」。**

再说这篇论文里我认为最有价值的一处，它不在方法里，在问题定义里。

「推理证据感知漂移」这个命名把一件模糊的事说清楚了。此前谈语言模型在知识图谱上出错，通常归因于「幻觉」或者「上下文太长」。这篇指出的是第三种机制：**模型没有编造任何东西，它用的每一条证据都真实存在于图里，它只是挑错了哪些证据该用。**图 1 那个案例里，「同公司发行的电影可能同地区发行」这条推理不是幻觉——它在现实里经常成立，只是在这张图里，能真正推出答案的是另一条路径。

而它挑错的原因是可预测的：它偏好在自然语言里读起来顺的路径。这一点让这个问题比幻觉更麻烦——幻觉可以靠核对证据是否存在来挡，而这个错误挡不住，因为证据确实存在。

那个 **P530** 的细节值得单独拿出来。模型在推理输出里明说自己认不出这个标识符，于是忽略了它。这是一个非常干净的失效展示：**模型对证据的取用，取决于那条证据有没有一个它能读懂的名字。**一个用 Wikidata 属性编号存关系的知识图谱，和一个用可读英文短语存关系的知识图谱，在信息量上完全一样，但在模型眼里前者的一部分证据是隐形的。

这篇论文的留白与要保持怀疑的地方。

第一，那些增益幅度的量级要放在合适的参照里看。平均倒数排名从 0.379 到 0.429 这种改进，在这个领域的论文里属于正常的一代进步，不是量级差别。论文自己用的措辞是「显著优越性」，而 5% 到 12% 的相对增益，读的时候要记住基数——直推式 FB15k-237 上最好的基线是 0.415，SIRLM 的监督微调版是 0.429。

第二，四种训练范式之间不一致，而论文没有解释。看 WN18RR 那一列：端到端 0.552、预训练 0.461、监督微调 0.556、GRPO 0.523。预训练那一版在这个数据集上比基线里的多数方法还差（基线最好是 KG-FIT 的 0.553）。而在 CoDEx-M 上 GRPO 是最好的（0.383）。同一套方法在不同数据集上最优范式不同，而论文的「平均增益」是取四种范式里的最优值去和基线比的——这个算法会系统性地高估。它在表格脚注里说明了这一点，属于诚实披露，但读者容易忽略。

第三，论文没有报推理成本。三个组件里有一个神经符号推理器要做消息传播，还有一个闭环反馈要把忠实度指标回传给规则生成器。这套东西相对纯提示词的方法贵多少，论文没有说。对要落地的人来说这是必须知道的一项。

对我自己的启示。这篇对我手上两件事都有直接含义，而且它描述的那个失效我已经撞到过，只是当时没有这个名字。

第一件，也是最直接的一件：prove 那个项目上周撞到的问题，就是这篇论文命名的那个问题。

上周有一道题反复答不出来：问「测评小节 6589717 的课程完成率是多少」，系统三轮全拒答。而当时做了一个只换叫法的实验——把「测评小节 6589717」改成「考试 6589717」，同一件事、同一个数字，**模型立刻正确选中了指标**。

当时我的结论是「模型不接受『测评小节』指的是一场考试」。而这篇论文给了这个现象一个更一般的描述：模型对证据的取用取决于那条证据有没有一个它能读懂的名字。那个案例里的「测评小节」和这篇论文里的 P530 是同一个形状——一个在系统里成立、但在模型的语言直觉里不成立的对应关系，会被模型忽略，而不是被它接受。

这也解释了为什么当时那个修法没用。我试过把「你手上有 exam_id」和「course_id 可由 exam_id 解析」这两段拼好了直接给模型，没有改善。按这篇论文的框架，原因是：**问题不在于信息缺失，而在于模型不肯用那条它读不懂的对应关系**。补更多文字说明，补的是同一种它不采信的东西。

而这篇给的方向和我们后来选的方向是一致的：我们后来做的是给概念加一层「用户会怎么称呼它」的结构化声明，让「测评小节 = Exam」这件事从散文变成机器可读的声明。这篇论文做的是更彻底的一步——**把结构本身编码成 token，让模型认结构位置而不认名字**。我们那一步是让名字对上，这篇是让名字不再重要。我们的做法工程上便宜得多，但它治的是症状；这篇治的是机制，代价是要训练。

第二件，用户画像那个项目。昨天调研时缺的那一段是「什么条件下一条记忆升格成画像」。这篇论文没有回答那个问题，**但它提醒了一个我原本没想到的风险**：如果画像的维度是用内部编码而不是自然语言短语命名的（比如某个维度叫 attr_0417 而不是「学习偏好」），那么下游让模型消费画像时，**模型会系统性地忽略那些它读不懂名字的维度**——而且它不会报错，只是不用。

这条直接推出一个可执行的约束：画像的维度名、辅助词、取值域，全部要用模型能读懂的自然语言短语，不能用内部编码。这是一条很便宜就能守住的纪律，而违反它的后果是静默的。

文中金句

"LLMs are inclined to generate reasoning logic that appears semantically plausible but is difficult to ground in a KG." 大语言模型倾向于生成那种「语义上看起来说得通、但在知识图谱里落不了地」的推理逻辑。

"for relation paths represented by anonymized identifiers, the absence of natural language semantics often leads LLMs to deliberately ignore this structural evidence that could potentially support correct reasoning." 对于用匿名标识符表示的关系路径，由于缺少自然语言语义，大语言模型往往会**故意忽略**这部分结构证据——而这部分证据本来可能支撑正确的推理。

"This preference for pre-trained semantic cues and the neglect of structural context cause the LLM's reasoning process to deviate from the correct KG-grounded evidence space." 这

种对预训练语义线索的偏好、以及对结构上下文的忽视，共同使得大语言模型的推理过程偏离了正确的、以知识图谱为根据的证据空间。

全文翻译

摘要

Knowledge Graph Reasoning (KGR) aims to discover latent facts by leveraging the structural evidence available in KGs, posing a challenge to the structural semantic understanding capability of KGR models.

知识图谱推理的目标是利用知识图谱里已有的结构证据去发现潜在的事实，这对推理模型的结构语义理解能力构成了挑战。

Recent studies have demonstrated that Large Language Models (LLMs) can achieve remarkable progress on KGR tasks via flexible in-context learning. However, the inherent representation inconsistency between KG structural context and LLM parametric knowledge remains inadequately addressed.

近期研究表明，大语言模型可以借助灵活的上下文学习在知识图谱推理任务上取得显著进展。然而，[知识图谱的结构上下文与大语言模型参数化知识之间那种固有的表示不一致，仍然没有被充分处理。](#)

This limitation prevents LLMs from effectively perceiving reasoning evidence that aligns with KG constraints, which undermines both the effectiveness and faithfulness of reasoning. We refer to this problem as reasoning evidence perception drift of LLMs over KGs.

这个局限使得大语言模型无法有效地感知那些与知识图谱约束相符的推理证据，从而同时损害了推理的有效性和忠实性。我们把这个问题称为[大语言模型在知识图谱上的「推理证据感知漂移」](#)。

To address this problem, we propose a Structure-Internalized Rule Language Model (SIRLM), which centers on structural rule generation to couple the parametric learning of structural knowledge with the faithfulness evaluation of reasoning logic, enabling LLMs to anchor tightly to KG-grounded evidence.

为了解决这个问题，我们提出结构内化的规则语言模型（SIRLM）。它以结构规则的生成为中心，把「结构知识的参数化学习」与「推理逻辑的忠实度评估」耦合起来，使大语言模型能够紧紧锚定在以知识图谱为根据的证据上。

Extensive experiments against 17 state-of-the-art KGR methods on 36 datasets demonstrate the significant superiority of SIRLM.

在 36 个数据集上与 17 个当前最先进的知识图谱推理方法做的大量实验，展示了 SIRLM 的显著优越性。

一、引言：这个问题为什么存在

Knowledge Graphs represent real-world facts through structural triplets composed of entities and relations, maintaining a unified framework for storing and querying large-scale knowledge. However, KGs are generally incomplete, which leaves many potential facts unobserved.

知识图谱通过由实体和关系组成的结构三元组来表示真实世界的事实，为存储和查询大规模知识维持了一个统一的框架。然而，知识图谱通常是不完整的，这让很多潜在的事实处于未被观察到的状态。

Traditional KGR methods mainly focus on knowledge embedding and logical rule learning. However, these methods generally rely on specific contextual instances within a KG. When confronted with an unfamiliar KG, they often require complex rule mining or model retraining, which makes it difficult for these methods to generalize.

传统的知识图谱推理方法主要集中在知识嵌入和逻辑规则学习上。然而这些方法通常依赖某个知识图谱内部的特定上下文实例。**面对一个不熟悉的知识图谱时，它们往往需要复杂的规则挖掘或者重新训练模型**，这让它们很难泛化。

LLMs select reasoning evidence from a KG based on their pre-trained semantic preferences, rather than strictly following the structural constraints induced from the KG. As a result, LLMs are inclined to generate reasoning logic that appears semantically plausible but is difficult to ground in a KG, leading to the reasoning bias and the faithfulness degradation of results.

大语言模型是根据它们预训练形成的语义偏好去从知识图谱里挑选推理证据的，而不是严格遵循从知识图谱推导出来的结构约束。结果是，它们倾向于生成那种语义上看起来说得通、但在知识图谱里落不了地的推理逻辑，导致推理偏差和结果忠实性的下降。

We refer to this issue as the reasoning evidence perception drift problem of LLMs over KGs, meaning that inconsistencies in knowledge representation hinder LLMs from identifying reasonable evidence from KGs.

我们把这个问题称为大语言模型在知识图谱上的推理证据感知漂移问题，意思是：**知识表示上的不一致，妨碍了大语言模型从知识图谱里识别出合理的证据。**

二、图 1 那个案例：漂移具体长什么样

In this case, LLMs tend to accept the assertion "films produced or distributed by the same company are likely to be released in the same region" based on their semantic preferences. As a result, the evidence space is anchored to the sub-KG marked in red.

在这个案例里，大语言模型基于自己的语义偏好，倾向于接受这条断言：「由同一家公司出品或发行的电影，很可能在同一地区发行」。结果，证据空间被锚定到了图中标红的那个子图上。

However, the structural rule that can be explicitly induced from the KG, namely $\text{release region}(X, Y) = \text{language}(X, Z) \wedge \text{speaks in}(X, Z)$, is instead misjudged as a weakly related evidence space.

然而，那条可以从知识图谱显式推导出来的结构规则——也就是「发行地区(X, Y) = 语言(X, Z) $\wedge$ 使用语言(X, Z)」——**反而被误判成了一个弱相关的证据空间**。

In addition, for relation paths represented by anonymized identifiers, the absence of natural language semantics often leads LLMs to deliberately ignore this structural evidence that could potentially support correct reasoning.

另外，对于用匿名标识符表示的关系路径，**由于缺少自然语言语义，大语言模型往往会故意忽略这部分结构证据——而这部分证据本来可能支撑正确的推理**。

This preference for pre-trained semantic cues and the neglect of structural context cause the LLM's reasoning process to deviate from the correct KG-grounded evidence space, ultimately producing erroneous results.

这种对预训练语义线索的偏好、以及对结构上下文的忽视，共同使得大语言模型的推理过程偏离了正确的、以知识图谱为根据的证据空间，最终产生错误的结果。

三、方法：三个组件与它们的分工

Overall, SIRLM consists of a KG tokenizer, a Structure-Internalized Rule Generator (SIRG) and a neuro-symbolic reasoner. In this framework, SIRG serves as the core module to generate structurally grounded rules.

整体上，SIRLM 由一个 KG tokenizer、一个结构内化规则生成器（SIRG）、和一个神经符号推理器组成。在这个框架里，SIRG 是生成「有结构根据的规则」的核心模块。

Therefore, we propose an in-context learning block based on a Structural Relation Memory (SRM) mechanism, which allows SIRG to align pre-trained knowledge with structural context during rule generation.

因此我们提出一个基于「结构关系记忆」机制的上下文学习块，**它让 SIRG 在生成规则的过程中把预训练知识与结构上下文对齐**。

Complementing SIRG, the KG tokenizer is built upon the Structural Invariance Learning (SIL) principle, which encodes KG elements into universal structure representations, enabling LLMs to grasp them in the form of new tokens without specific textual annotations.

作为 SIRG 的补充，KG tokenizer 建立在「结构不变性学习」原则之上。它把知识图谱的元素编码成通用的结构表示，**让大语言模型能以新 token 的形式接住它们，而不需要特定的文字标注**。

Furthermore, we design the neuro-symbolic reasoner as a rule executor based on Rule-Constraint Message Propagation (RCMP), which feeds back a rule faithfulness metric composed

of reasoning conclusions to SIRG, forming a closed-loop optimization that reinforces structurally consistent reasoning.

此外，我们把神经符号推理器设计成一个基于「规则约束消息传播」的规则执行器。它把一个由推理结论构成的「规则忠实度」指标反馈给 SIRG，形成一个强化结构一致推理的闭环优化。

In terms of model training, SIRLM can seamlessly integrate with standard Supervised Fine-Tuning (SFT) and post-training frameworks of LLMs. This capability endows SIRLM with significant transferable advantages across a wide range of cross-scenario KGR tasks.

在模型训练方面，SIRLM 可以与标准的监督微调和后训练框架无缝集成。这个能力让 SIRLM 在广泛的跨场景知识图谱推理任务上具有显著的可迁移优势。

四、实验：数据集、对照方法与结果

实验围绕四个研究问题：SIRLM 能否在广泛的直推式与归纳式场景下取得显著表现；核心模块是否各自起了关键作用；对超参数是否敏感；是否适用于不同的语言模型底座。

数据集共 36 个：4 个直推式 (FB15k-237、WN18RR、CoDEX-M、NELL995)、12 个归纳式实体数据集 (从 FB15k237、WN18RR、NELL995 划分出来)、20 个全归纳式数据集 (从 FB15k237、NELL995、Wikidata68K、MTDEA 构造)。

对照方法共 17 个，分四类：传统知识嵌入方法 (TransE、RotatE、TuckER)；规则方法 (NeuralLP、DRUM、RNNLogic)；图神经网络方法 (NBFNet、RED-GNN、ULTRA、MOTIF)；以及基于语言模型的方法 (KICGPT、LSA、ChatRule、MKGL、KG-FIT、FtG、KRLM)。

四种训练范式都跑了：从零端到端训练、预训练、监督微调、GRPO 后训练。

主要结果 (平均倒数排名 / 前十命中率的平均增益，相对所有基线里的最优值)：

数据集类别	平均倒数排名增益	前十命中率增益
FB15k237 (直推式)	+6.66%	+5.90%
CoDEX-M (直推式)	+4.13%	+5.77%
WN18RR (直推式)	+6.92%	+5.11%
NELL995 (直推式)	+5.45%	+6.01%
12 个归纳式实体数据集	+6.84%	+6.64%
20 个全归纳式数据集	+10.30%	+12.05%

读法：最后一行是提升最大的一行，而全归纳式是最难的一类——测试时的实体和关系都是训练时没见过的。提升幅度在最难那一类上最大，说明这套方法解决的是「面对不熟悉的图时该信什么证据」这个问题。

一处论文自己披露的算法细节：上面的「平均增益」是拿 SIRLM 四种训练模式里的最优值去和所有基线比的。这一点写在表格脚注里。

五、结论

This paper identifies a pervasive issue in LLM-based KGR, termed reasoning evidence perception drift, caused by the misalignment between KG structural representations and LLM parametric knowledge, which undermines both reasoning effectiveness and faithfulness.

本文识别出基于大语言模型的知识图谱推理中一个普遍存在的问题，称为推理证据感知漂移。它由「知识图谱的结构表示」与「大语言模型的参数化知识」之间的错配引起，同时损害推理的有效性和忠实性。

SIRLM aligns parametric knowledge with KG structure through structural representation learning, rule generation, and faithfulness feedback, enabling evidence-grounded reasoning over KGs.

SIRLM 通过结构表示学习、规则生成、以及忠实度反馈，把参数化知识与知识图谱结构对齐，使得在知识图谱上进行「有证据根据的推理」成为可能。

Extensive experiments with 17 baselines on 36 KGR benchmarks show that SIRLM consistently outperforms existing methods across end-to-end training, pre-training, supervised fine-tuning, and post-training settings.

在 36 个知识图谱推理基准上与 17 个基线做的大量实验表明，SIRLM 在端到端训练、预训练、监督微调、以及后训练这几种设置下都一致优于现有方法。

参考链接

- [SIRLM 源码](#) — 论文对应的实现，附录 F 有算法伪代码
- [ULTRA](#) — 论文里「结构不变性学习」原则的主要来源之一，也是对照表里在全归纳式场景上表现最好的图神经网络基线之一