

重看 Agentic-SQL 按自主度分类，以及一份带来源的排行榜

Agentic-SQL Revisited: Autonomy-Based Taxonomy and Empirical Benchmark Analysis for LLM Text-to-SQL

本篇范围说明：这是一篇 arXiv 论文 (2608.15389v1, 2026-08-15)。下面「全文翻译」一节覆盖摘要、引言、自主度轴的五档定义、方法目录、以及聚合结果与四个发现；三个基准（Spider / BIRD / Spider 2.0）的完整数字表格只译表头与关键行，逐格数字不重复搬运。

核心内容

Q：这篇论文为什么要写？

A：作者的判断是：基于大模型的自然语言转 SQL 这件事，已经过了「一个基准上的一个数字能概括一个系统」的阶段。同一篇论文现在可能同时报 Spider 的执行准确率、BIRD 的有效效率分、Spider 2.0 的成功率、以及一些非正式的延迟说法——而每一个数字都是在不同的底座模型和不同的推理协议下拿到的。

后果是两句很实在的话：

两个头条数字相近的系统，推理成本可能差一个数量级；两个协议相近的系统，在那个专门压测该协议盲区的基准上可能差十个点。

Q：现有综述是怎么分类的，作者为什么不满意？

A：现有综述按训练范式分（上下文学习 / 微调 / 强化式后训练）。作者说这有信息量，但它没有把「推理时的结构」隔离出来——而正是推理时的结构越来越主导基准表现。

Q：作者提出的「自主度轴」是什么？

A：按一个系统在「问题」与「最终 SQL」之间外化了多少结构化推理来分类。关键在于它可测：从回答一个问题所用的模型调用的数量与种类就能定出档位。

这张表回答一个问题：五档各自的推理形态是什么、代表系统是哪些。「调用形态」一列是判档的依据。

档	名称	调用形态	代表系统
L0	受约束的单轮	一次前向传播，带 语法级解码约束	PICARD
L1	上下文单轮	一次前向传播，只靠提示词里的结构（指令与示例）	DAIL-SQL；本文案例研究里的 DeepSeek V3 / GLM-4 少样本基线
L1.5	推理内化	推理时仍是一次前向传播 ，但模型被监督成在 同一条轨迹内 吐出中间阶段（schema 链接、分解、草稿、修订）	STaR-SQL、RevDecomp-SFT、本文的 CoT-SFT 行
L2	迭代精化	沿 一条固定流水线 的多次模型调用（链接 → 分解 → 生成 → 修订）， 没有动态路由	DIN-SQL、DART-SQL、DTS-SQL、TS-SQL
L3	智能体协作	多次调用， 由一个控制器协调 ，并在中间产出 上分支	MAC-SQL、ExeSQL、CHESS；EllieSQL 加了成本感知路由，BAP-SQL 加了预算感知路由

读法：拿 L1.5 和 L2 的差别走一遍。两者都做了「链接、分解、生成、修订」这四步，**差别在于 L2 把这四步拆成四次模型调用、由外部流水线串起来，而 L1.5 把四步压进一次调用里、靠训练让模型自己按顺序吐出来**。所以 L1.5 的编号插在 L1 和 L2 之间——它的调用次数像 L1，结构化程度像 L2。

Q：四个发现是什么？

- A：
- 一、Spider 上的提升不均匀地迁移到 BIRD 和 Spider 2.0。** 在一个基准上调好的方法，换到另一个基准上收益不成比例。
 - 二、自主度买到的是稳健性，而代价不小——**在 token、延迟、编排三方面都要付。**这一条把「要不要上智能体」从原则问题变成了成本问题。**
 - 三、推理内化在「自主度—成本」这条前沿上占一个独立的点，**位于「只解码答案」和「外部编排的智能体」之间。
 - 四、思维链监督的收益集中在 Hard 和 Extra-Hard 查询上，不是在各难度上均匀分布。**

这第四条有具体数字支撑（案例研究，Spider 测试集 2147 个样例）：

系统	底座	档	精确匹配 EM	执行准确率 EX
DeepSeek V3 (3-shot)	DeepSeek V3	L1	19.56	51.47
GLM-4 (3-shot)	GLM-4	L1	20.49	66.28
无思维链微调	LLaMA3.1-8B + LoRA	L1	31.35	76.01
无思维链微调	Qwen3-8B + LoRA	L1	47.60	77.04

系统	底座	档	精确匹配 EM	执行准确率 EX
思维链微调	LLaMA3.1-8B + LoRA	L1.5	29.02	76.01
思维链微调	Qwen3-8B + LoRA	L1.5	44.67	82.24

这张表里有一处很值得注意的反常：Qwen3 那两行，加了思维链之后精确匹配从 47.60 降到 44.67，而执行准确率从 77.04 升到 82.24。两个指标反向。

为什么会这样：精确匹配要求生成的 SQL 和标准答案逐字符一致，执行准确率只要求跑出来的结果一致。思维链让模型写出更多「结果对但写法不同」的 SQL——于是精确匹配下降、执行准确率上升。而对实际使用来说，执行准确率才是那个有意义的指标。

Q：这篇论文有一个方法论上的选择很不寻常，是什么？

A：它不重跑任何先前的系统。理由写得很直白：

重跑十四个系统是昂贵的、部分不可行的（闭源 API 每个月都在变），而且产出的数字在底座一更新的那一刻就漂了。

一个每个格子都带一条引用的排行榜，就目前而言是更诚实的那个对象。

配套的规则是：每一个数字格子都追溯到一条引用，不确定的格子留空、而不是靠推断填上。源文档里的数字原样录入；任何需要我们在不同评分协议下重新推导的数字，一律不录。

Spider 2.0 那一栏整个省掉了——理由是这份目录里的系统还没有发表过在它的评分协议下直接可比的成功率数字。作者说排行榜的 CSV 格式已经预留了位置，等有直接可比的报告再填。

背景补充 / 点评

先解释三个基准，它们的差别决定了「迁移不均匀」那条发现的含义。

Spider 是这个领域最经典的基准，它的特点是跨库——测试时用的数据库在训练时没见过，所以考的是「schema 泛化」。BIRD 加了两样东西：真实脏数据（值不规范、有噪声）和外部知识（有些问题必须结合数据库之外的常识才能答对），它还引入了「有效效率分」这个指标来同时衡量正确性与查询效率。Spider 2.0 又往前一步，做的是 workflow 真实性——一个任务可能要多轮、要用到多个工具、要写几百行 SQL。

所以「Spider 上的提升不均匀地迁移」这件事有具体含义：在 Spider 上调好的东西主要提升的是 schema 泛化能力，而 BIRD 考的是脏数据与外部知识，Spider 2.0 考的是 workflow 编排——这三样是不同的能力。

「精确匹配」与「执行准确率」的区别也要说清：前者比字符串，后者比执行结果。一个 SQL 用 JOIN 还是子查询写、列的顺序如何、有没有多余的括号，都会让精确匹配失败而执行准确率通过。

再说这篇论文里我认为最有价值的一处，它不是那四个发现，是那个「不重跑」的决定。

作者面对的困境是：要做一份可比的排行榜，最“正确”的做法是把所有系统在统一协议下重跑一遍。而他们判断这做不到，于是选择了「每格带引用、不可比就留空」。

这个选择的实质是：宁可承认不可比，也不要造一个假的可比性。如果强行重跑，得到的数字会因为底座版本、API 变动、提示词细节而漂移，而漂移过的数字看起来仍然像是可比的——那比留空更有害。

这一条对我手上的项目直接适用，而且我此前的做法偏向错的那一侧。prove 那个项目的评测集有 47 道题，跑一轮 10 分钟以上，而模型底座是一个路由别名（8 月 17 日查实它当时指向 gpt-5.2）。我此前在跨周比较通过率时，没有在结果里记下那一轮用的是哪个模型——直到 8 月 17 日才把「本次跑见过哪些模型」做成集合落盘。那之前的历史数字，严格说彼此不可比，而我当时是当可比在用的。

按这篇论文的判据，正确做法不是回头重跑（做不到，路由已经变了），而是给那些历史数字标上「模型未记录」，让它们不参与跨周比较。这比假装可比更诚实。

第三处值得记的是那个自主度轴本身，因为它给了一个我一直缺的坐标。

prove 现在的形态是：路由（一次模型调用选指标）→ 编译 → 执行 → 派生计算 → 对账 → 作答（一次模型调用）。按这篇的分档，它是 L2——多次调用沿固定流水线，没有动态路由。

而昨天讨论过的那个方向（在路由之前先把能补的 ID 查出来）会让它往 L3 靠一点，因为那引入了一次条件性的数据库查询。这篇论文的第二个发现正好回答了那个方向的代价：自主度买到的是稳健性，但要在 token、延迟、编排三方面付账。

而它的第三个发现给了另一条路：L1.5「推理内化」——把中间步骤压进一次调用、靠训练让模型自己吐出来，而不是靠外部编排。这条路 prove 走不了（我们不训练模型），但值得知道它存在，因为它说明「把步骤外化成流水线」不是唯一的选择。

这篇论文的留白与该保持怀疑的地方。

第一，案例研究只在 Spider 上做。论文自己说了案例研究的模型没在 BIRD 上跑，所以 BIRD 表里没有它们。那么第一个发现（迁移不均匀）依赖的是文献里其他系统的数字，而那些数字来自不同协议——正是这篇论文自己要解决的那个问题。这不是自相矛盾，但它意味着第一个发现的证据强度不如第四个（第四个有自己的对照实验）。

第二，只有 8B 规模的开源底座做了对照。两个 8B 模型（Qwen3-8B、LLaMA3.1-8B）加 LoRA，对照的是 DeepSeek V3 和 GLM-4 的少样本。「思维链收益集中在难题上」这个结论在更大的模型上会不会成立，这篇答不了。

第三，那个「自主度买到稳健性但成本不小」的发现，没有给出成本的量化。它说要在 token、延迟、编排三方面付，但没有像 Quipu 那篇给出「1.54 到 2.07 倍」这样的具体倍数。这一条目前是定性的。

对我自己的启示，一句话版本：这篇给了我两样东西——一个坐标（自主度五档，用来说清 prove 现在在哪、往哪走要付什么），和一条纪律（不可比就留空，不要靠重跑造假的可比性）。

而第二样对我更急，因为它指向一笔已经存在的账：[prove 评测集在 8 月 17 日之前的历史通过率](#)，没有记录模型版本，严格说不可比。这不是要去修的东西，是要标注的东西。

文中金句

"two systems with similar headline numbers can differ by an order of magnitude in inference cost, and two systems with similar protocols can differ by ten points on whichever benchmark stresses the protocol's blind spot." 两个头条数字相近的系统，推理成本可能相差一个数量级；两个协议相近的系统，在那个专门压测该协议盲区的基准上可能相差十个点。

"re-running fourteen systems is expensive, partially infeasible (closed APIs change monthly), and produces numbers that drift the moment a backbone updates. A leaderboard whose every cell carries a citation is, for now, the more honest object." 重跑十四个系统是昂贵的、部分不可行的（闭源 API 每个月都在变），而且产出的数字在底座一更新的那一刻就漂了。[一个每个格子都带一条引用的排行榜，就目前而言是更诚实的那个对象。](#)

"every numeric cell traces to a single citation, and uncertain cells are left blank rather than filled by inference." 每一个数字格子都追溯到一条引用，[不确定的格子留空，而不是靠推断填上。](#)

"The axis makes a measurable property — number and structure of inference-time calls — the variable along which results are organized." 这条轴把一个[可测的属性](#)——推理时调用的数量与结构——变成了组织结果的那个变量。

全文翻译

摘要

LLM-based Text-to-SQL progress is reported across heterogeneous benchmarks, backbones, and inference protocols, making cross-system comparison fragile.

基于大模型的自然语言转 SQL 的进展，是在互不相同的基准、底座模型和推理协议下被报告出来的，[这让跨系统的比较变得脆弱。](#)

We reframe the field as a leaderboard aggregation: we collect the metrics authors themselves report and organize them along an inference-autonomy axis spanning constrained, in-context,

iterative, agentic, and reasoning-internalized generation, with traceable provenance for every cell.

我们把这个领域重新框定为一次**排行榜聚合**：我们收集作者们自己报告的指标，并把它们沿一条**推理自主度轴**组织起来——这条轴横跨受约束生成、上下文生成、迭代生成、智能体生成、以及推理内化生成——**每一个格子都有可追溯的来源**。

Four patterns emerge: Spider gains transfer unevenly to BIRD and Spider 2.0; autonomy buys robustness at non-trivial cost; reasoning internalization sits between answer-only decoding and externally orchestrated agents; and CoT gains concentrate on Hard and Extra-Hard queries.

浮现出四个规律：Spider 上的提升不均匀地迁移到 BIRD 和 Spider 2.0；**自主度买到的是稳健性，代价不小**；推理内化位于「只解码答案」与「外部编排的智能体」之间；以及**思维链的收益集中在 Hard 与 Extra-Hard 查询上**。

一、引言：为什么一个数字不够了

LLM-based Text-to-SQL has moved past the point where a single number on a single benchmark can summarize a system.

基于大模型的自然语言转 SQL，**已经过了「一个基准上的一个数字能概括一个系统」的阶段**。

The same paper may now report Spider execution accuracy, BIRD valid efficiency score, Spider 2.0 success rate, and informal latency claims, each obtained under a different backbone and inference protocol.

同一篇论文现在可能同时报 Spider 的执行准确率、BIRD 的有效效率分、Spider 2.0 的成功率、以及一些非正式的延迟说法——**而每一个都是在不同的底座与推理协议下拿到的**。

As a result, two systems with similar headline numbers can differ by an order of magnitude in inference cost, and two systems with similar protocols can differ by ten points on whichever benchmark stresses the protocol's blind spot.

结果是：**两个头条数字相近的系统，推理成本可能相差一个数量级；两个协议相近的系统，在那个专门压测该协议盲区的基准上可能相差十个点**。

Existing surveys organize this literature by training paradigm (ICL vs. fine-tuning vs. reinforcement-style post-training), which is informative but does not isolate the inference-time structure that increasingly dominates benchmark behavior.

现有综述按训练范式来组织这些文献（上下文学习、微调、强化式后训练）。这有信息量，**但它没有把那个越来越主导基准表现的东西隔离出来——推理时的结构**。

We take a different stance: treat the literature itself as the benchmark, and let the contribution be the aggregation protocol rather than a new model.

我们采取一个不同的立场：**把文献本身当成基准，让贡献是那套聚合协议，而不是一个新模型。**

The harness does not re-run any prior system; re-running fourteen systems is expensive, partially infeasible (closed APIs change monthly), and produces numbers that drift the moment a backbone updates. A leaderboard whose every cell carries a citation is, for now, the more honest object.

这套装置**不重跑任何先前的系统**。重跑十四个系统是昂贵的、部分不可行的（闭源 API 每个月都在变），而且产出的数字在底座一更新的那一刻就漂了。一个每个格子都带一条引用的排行榜，就目前而言是更诚实的那个对象。

二、自主度轴的五档

We classify a system by inference autonomy: the amount of structured reasoning, feedback, and coordination introduced between the input question and the final SQL. The axis has five levels and is operationally measurable from the number and kind of model calls in a single answered question.

我们按**推理自主度**给系统分类：在输入问题与最终 SQL 之间引入了多少结构化推理、反馈与协调。**这条轴有五档，而且可以从「回答一个问题所用的模型调用的数量与种类」上操作性地测出来。**

L0 — 受约束的单轮。 One forward pass with grammar-level decoding constraints (PICARD).

一次前向传播，带**语法级的解码约束**（PICARD）。

L1 — 上下文单轮。 One forward pass conditioned on prompt-only structure: instructions and demonstrations.

一次前向传播，**只以提示词里的结构为条件**：指令与示例。代表是 DAIL-SQL，以及本文案例研究里的 DeepSeek V3 / GLM-4 少样本基线。

L2 — 迭代精化。 Multiple model calls along a fixed pipeline (link→decompose→generate→revise) without dynamic routing.

沿一条**固定流水线**的多次模型调用（链接、分解、生成、修订），**没有动态路由**。DIN-SQL、DART-SQL、DTS-SQL、TS-SQL 在这一档。

L3 — 智能体协作。 Multiple calls coordinated by a controller that branches on intermediate outputs.

多次调用，**由一个控制器协调，而这个控制器会在中间产出上分支**。代表系统有 MAC-SQL、ExeSQL、CHESS；EllieSQL 加了成本感知的路由，BAP-SQL 加了预算感知的路由。

L1.5 — 推理内化。 A single forward pass at inference time, but the model has been supervised to emit intermediate stages (schema links, decomposition, draft, revision) inside one trajectory.

推理时仍是一次前向传播，但模型已被监督成在**同一条轨迹内**吐出中间阶段（schema 链接、分解、草稿、修订）。STaR-SQL、RevDecomp-SFT、以及本文的思维链微调行占这一档。

The axis makes a measurable property — number and structure of inference-time calls — the variable along which results are organized, so the leaderboard can be sliced by autonomy level without re-running any code.

这条轴把一个可测的属性——推理时调用的数量与结构——变成了组织结果的那个变量，**于是排行榜可以按自主度切片，而不需要重跑任何代码。**

三、聚合规则：不确定就留空

We adopt one rule throughout the leaderboard: every numeric cell traces to a single citation, and uncertain cells are left blank rather than filled by inference.

整个排行榜遵循同一条规则：**每一个数字格子都追溯到一条引用，不确定的格子留空，而不是靠推断填上。**

Numbers from source documents are entered as-is; numbers that would require us to re-derive a metric under a different scoring protocol are not entered.

源文档里的数字**原样录入**；任何需要我们在不同评分协议下重新推导的数字，一律不录。

关于 Spider 2.0:

Spider 2.0 establishes the workflow-realism axis ... but the systems in this catalog have not yet published directly-comparable success-rate numbers under its scoring protocol. We therefore omit a Spider 2.0 results table from v1 of the leaderboard.

Spider 2.0 确立了 workflow-realism 这条轴……**但这份目录里的系统还没有发表过在它的评分协议下直接可比的成功率数字。因此我们在排行榜 v1 里省掉了 Spider 2.0 的结果表**（装置的 CSV 格式已经预留了逐任务成功率的位置）。

四、案例研究：思维链的收益落在哪里

案例研究在 Spider 上做：两个 8B 开源底座（Qwen3-8B、LLaMA3.1-8B）分别在**带与不带思维链推理轨迹**的情况下微调，加上 DeepSeek V3 与 GLM-4 的 3-shot 基线。**这产出六行直接可比的精确匹配与执行准确率数字，并按难度分层。**

四个规律里第四条是这次案例研究直接得出的：

CoT supervision concentrates its gains on Hard and Extra-Hard queries rather than uniformly across difficulty.

思维链监督把它的收益集中在 Hard 与 Extra-Hard 查询上，而不是在各难度上均匀分布。

参考链接

- [llm-text2sql-taxonomy](#) — 论文配套的 Python 装置，加一个适配器文件加一个配置文件就能把新系统加进排行榜
- [Spider 基准](#) — 跨库自然语言转 SQL，考 schema 泛化
- [BIRD 基准](#) — 加了真实脏数据与外部知识，并引入「有效效率分」
- [PICARD](#) — LO 档的代表，用语法级解码约束