

不接知识图谱的准确率最高但什么都没证明 Grounding Healthcare LLMs in a Causal Knowledge Graph

本篇范围声明：这是一篇 18 页的 arXiv 论文（作者 Ummara Mumtaz、Aimen Noor、Awais Ahmed），提出一套以图为中心的评测框架，用来测大模型在医疗场景下「面向干预的推理」，并在一个心血管试点上做了压力测试。下面的「全文翻译」按章节推进，覆盖摘要、引言、框架四个组件（物化断言、子图抽取、四种 grounding 条件、自动打分流水线）、实验设置与全部结果表；相关工作综述与参考文献不逐段译。注意这是单模型试点（gpt-5.4），作者自己反复声明不下临床性能结论。

核心内容

Q：这篇要解决什么问题？ A：现在的医疗大模型评测，奖励的是「单个答案对不对」，而不是「对干预、机制、危害、证据和不确定性的推理」。

作者的原话是：这些评测「仍然奖励单答案准确率（single-answer accuracy），而不是关于干预、机制、危害、证据与不确定性的推理」。

Q：框架由哪四个组件构成？

组件	做什么
领域因果知识图谱	断言是一等的、保留来源的节点，带稳定标识符
场景条件化的子图抽取	给定任何一个临床场景，检索出相关的物化断言子图
四种受控的 grounding 条件	改变「抽出的子图如何组装进模型的上下文」
自动打分流水线	以断言标识符为锚，一次遍历算出干预准确率等全部指标

Q：什么是「断言物化」？为什么要这样做？ A：核心设计决策是：每一条生物医学关系不只被表示成一条 Neo4j 的直接边，还被额外表示成一个物化的断言节点。

传统属性图里，「某类药降低血压」这样一条断言只会存成一条边：

```
(Drug)-[:CAUSES_DECREASE_IN]->(Outcome)
```

这篇的图里，同一条断言还额外存成一个带稳定标识符的 Assertion 节点：

```
(:Assertion {assertion_id: "ASR_0033"})
(:Assertion)-[:HAS_SUBJECT]->(:Drug)
(:Assertion)-[:HAS_OBJECT]->(:Outcome)
```

每个断言节点带一组结构化属性: predicate (谓词)、relation_class (关系类别)、direction (方向)、causal_status (因果状态)、evidence_level (证据等级)、confidence (置信度)、validated (是否已验证)、context (上下文)、population_id (适用人群)、temporality (时间性)、source_databases_json (来源数据库)。

作者给了物化的四条理由，都直接影响这项研究：

- 1. 一条断言不能只由它连接的那对实体刻画。它还有因果状态、置信度、验证状态、适用人群和时间范围。这些东西活在断言本身上，而不是被复制到一堆平行的边上。
- 2. 证据链接挂在具体的断言上，而不是挂在一条不透明的边上，可以表达 (:EvidenceSource)-[:SUPPORTS]->(:Assertion) 这样的模式。
- 3. 当多个来源支持同一条关系时，纯边模型会累积一堆近似重复的边；物化保留一个规范的断言节点，让多条证据链接指向它，图保持紧凑，来源可审计。
- 4. 对评测最关键的一条：稳定的 assertion_id 让金标准结构变得精确且可引用——一条金标准因果通路可以表达成一个有序列表 ["ASR_0019", "ASR_0010", "ASR_0011", "ASR_0013"]，直接被打分流水线消费。

Q: 物化之后原来的直接边还留着吗？ A: 留着，而且这是刻意双表示。

Direct typed edges are retained alongside the reified assertions. This dual representation is deliberate: direct edges support fast traversal and simple Cypher retrieval, while assertion nodes carry provenance, validation, and gold-path referencing. 带类型的直接边与物化断言并存。这个双表示是刻意的：直接边支撑快速遍历和简单的 Cypher 检索，而断言节点承载来源、验证与金标准路径引用。

并且有一条不变式：图中每一条直接边都配一个对应的断言节点，两者共享同样的主语、谓词和宾语。

图的规模：257 个断言、15 个证据源（含 11 条研究级记录）；直接边包括 82 条 CAUSES_DECREASE_IN、65 条 CAUSES_INCREASE_IN、26 条 MAY_CAUSE_ADVERSE_EFFECT、18 条 ASSOCIATED_WITH、15 条 TARGETS、15 条 INDICATED_FOR、14 条 PARTICIPATES_IN、13 条 CONTRAINDICATED_FOR、9 条 MODIFIES_EFFECT_OF。

Q: 四种 grounding 条件是什么？

条件	上下文里放什么
C1 (无 grounding)	只有场景和干预任务。它绕过子图抽取，是基线
C2 (知识图谱)	场景 + 知识图谱上下文 + 证据来源，不强调完整因果通路
C3 (因果图)	场景 + 已验证的因果通路，上下文证据细节有限

条件

上下文里放什么

C4（整合）

场景 + 整合的因果结构 + 机制上下文 + 证据来源 + 禁忌 + 不良反应信息 + 与不确定性相关的上下文

这里有一个实验设计上的关键控制：

The conditions vary the type of retrieved context rather than its volume, so that observed differences can be attributed to context organisation rather than to prompt style. 这些条件改变的是所检索上下文的类型，而不是它的体量，这样观察到的差异才能归因于上下文的组织方式，而不是提示词风格。

Q：结果是什么？这是全文最值得记的一段。

心血管试点（gpt-5.4）的完整指标面板：

指标	C1	C2	C3	C4
干预准确率	0.948	0.873	0.808	0.886
因果边精度	NA（没产生任何因果边）	0.522	0.808	0.806
因果边召回	0.000	0.785	0.808	0.886
因果边 F1	NA	0.579	0.808	0.838
不良反应 F1	NA	0.733	0.822	0.833
禁忌召回	1.000	1.000	1.000	0.800
证据准确率	NA	0.705	0.679	0.738
无支撑断言率（越低越好）	NA	0.259	0.192	0.114
不确定性正确率	0.130	0.114	0.115	0.114

核心发现：不接图谱的 C1 拿到最高的原始干预准确率 0.948，三个接了图谱的条件反而更低（C2 0.873、C3 0.808、C4 0.886）。

但在因果与证据这两条轴上，排序完全不同：C4 拿到最高的因果边 F1、最高的不良反应 F1、最高的证据准确率、最低的无支撑断言率。

作者的结论一句话：

Ranking the conditions by intervention accuracy alone would have placed C1 first, but that ordering carries no information about mechanism fidelity, evidence use, or unsupported claim generation. 单按干预准确率给这些条件排名，会把 C1 排在第一，但那个排序不携带任何关于机制保真度、证据使用或无支撑断言生成的信息。

Q：还有一个分离现象值得记。 A：在「证据不完整或不确定」这一类场景上，三个 grounded 条件的干预准确率全部是 0.000，而不确定性正确率在所有条件下都是 1.000。

这个分离说的是：模型正确识别出了「证据不足」，但没有给出金标准里的那个干预决策。

作者认为这正是多指标面板要暴露的东西，**并且它给社区提出了一个明确的基准设计选择：**

whether abstention and uncertainty acknowledgment should be scored as separate targets from final action selection. 弃答与承认不确定性，是否应该作为独立于「最终动作选择」的评分目标。

背景补充 / 点评

「C1 准确率最高」这个结果，是一个「指标选错会得出相反结论」的干净实例

这条值得单独记住，因为它的形状可以直接迁移。

如果只报一个数字——干预准确率——这项研究的结论会是「**接知识图谱反而降低了准确率**」，进而推出「不该接图谱」。

加上另外六个指标之后，结论反过来：C1 的高准确率建立在它根本没产出任何可核查的因果链条之上——它的因果边精度是 **NA**（没有边可算）、因果边召回是 **0.000**、无支撑断言率无法计算（因为它压根不引用证据）。

换句话说，C1 答对了但说不出为什么。 在一个需要解释和可审计的场景里，「答对了但说不出为什么」不是一个可接受的状态。

这和「零信号基准」是同一类问题：一个看起来很好的数字，要先问「它是在什么条件下取得的、那个条件本身有没有毁掉这个数字的意义」。

物化断言的四条理由里，第三条和第四条最值得抄

第三条解决的是「重复边」问题：当五份研究都支持「A 降低 B」时，纯边模型会怎么办？要么存五条几乎一样的边（图变脏、遍历时要去重），要么把五个来源塞进一条边的属性里（那就没法对单个来源做断言）。

物化的解法是：一条规范的断言节点 + 五条 **SUPPORTS** 边指向它。图是紧凑的，每个来源是可寻址的。

第四条是这套评测框架能成立的前提：因为断言有稳定 ID，金标准通路才能写成 `["ASR_0019", "ASR_0010", ...]` 这样一个有序列表，并被程序直接消费。

如果没有物化，金标准怎么表达？ 只能写成一串「主语-谓词-宾语」三元组，然后打分时做字符串匹配——而字符串匹配对同义表述、大小写、别名全都脆弱。稳定 ID 把「匹配」变成了「比对标识符」，这是一个从模糊到精确的跃迁。

双表示不是冗余，是两种访问模式各取所需

「每条直接边都配一个断言节点」这个不变式看起来是数据冗余，**但两边服务的是不同的访问模式**：

直接边

支撑什么 **快速遍历、简单 Cypher** 来源、验证状态、金标准路径引用

谁在用 C2/C3/C4 的子图检索 打分流水线

断言节点

代价是要维护一致性——两边必须共享同样的主语、谓词、宾语。作者没有说他们怎么保证这个一致性（是导入时同时写、还是有校验），**这是文中一个没交代的工程细节**。

「变类型不变体量」是实验设计上的正确做法

C1 到 C4 的差别是「上下文里放什么类型的东西」，**不是「放多少」**。作者明确说这样做的目的是让差异能归因于上下文的组织方式，**而不是提示词风格或长度**。

如果不控制体量，这个实验就废了：C4 的上下文显然最长，如果它表现更好，你无法区分是「整合的因果结构有用」还是「上下文更长有用」——而后者已经被大量文献证明常常是有害的（上下文越长表现越差）。

我认为要打折扣的三处

第一，单模型、单领域、小规模。全部结果来自一个模型（gpt-5.4）、一个心血管试点、**257 个断言的图**。作者自己反复声明「不从这个排序下临床性能结论」「是否跨模型泛化留给多模型阶段」。**这是诚实的，但也意味着表里那些数字不能当结论用，只能当「这个框架能区分出不同条件」的证据**。

第二，禁忌召回那一格是异常的，作者的解释不够。C4 的禁忌召回是 **0.800**，比 C1/C2/C3 的 1.000 都低。作者把它归因于「少数场景下的输出模式语义（output-schema semantics），而非图里缺少安全知识」。

在一个安全相关的指标上退步，「输出格式问题」这个解释需要更多证据——比如给出那几个失败场景的具体形态。文中只说了这一句。

第三，样本量在部分格子里很小。不良反应 F1 的 n 是 C2 的 20、C3 的 30、C4 的 40；禁忌召回的 n 全是 10。**n=10 的 1.000 和 0.800 的差别是两个场景，这个量级上的比较基本没有区分力**。作者报了 n，**这是对的**，但读的人容易只看均值不看 n。

对我的启示

第一条，物化断言的四条理由，可以直接用来加固学员画像事实行的设计。

学员画像的事实表一行是「〈学员〉〈动作〉〈宾语〉，in 〈取值域〉is 〈取值〉」，**它本身就是一个物化**——一条陈述有四五个成分，二元关系装不下，所以陈述本身成为一个个体（这是判据 J5）。

这篇给了这个做法四条我之前没完整说出来的理由：

理由	学员画像的对应
断言有自己的属性（置信度、适用人群、时间范围）	<code>versions</code> 表的 <code>valid_from</code> 、 <code>valid_to</code> 、 <code>source</code> 、 <code>evidence</code> 、 <code>method</code>
证据链接挂在具体断言上	<code>evidence</code> 字段挂在 <code>version</code> 上，不挂在学员或宾语上
多来源支持同一断言时不产生重复	<code>facts</code> 表一行是不可变身份， <code>versions</code> 表多行指向它——这正是「一个规范节点 + 多条证据」的形状
稳定 ID 让金标准可精确引用	<code>fact_id</code> 、 <code>version_id</code> 已有，但还没有被用于任何评测

第四条是我们缺的那一块：`fact_id` 现在只是主键，没有被用来表达「这次抽取应该产出哪几条事实」这种金标准。如果要评测学员画像的抽取质量，这是现成的抓手。

第二条，「单指标会给出相反排序」这一条要写进 `prove` 的评测设计。

昨天我在 `memory` 里记了「竞争力查询应该补进样例文档」。这篇补上了另一半：光有竞争力查询也不够，还要想清楚每个查询的结果怎么评分，以及会不会有单个指标掩盖真实行为的情况。

具体到 `prove` 的指标编译：如果只测「编译出的 SQL 跑出来的数字对不对」，那就是这篇说的 `single-endpoint accuracy`。至少还要测另外两件事：

- 用到的实体和关系对不对（对应「因果边 F1」）——数字对了但走的路径不对，换个数据就错
- 有没有用到没登记过的东西（对应「无支撑断言率」）——编译器如果绕过本体直接拼 SQL，数字可能对，但那条路径不可审计

这两条正好对应基石 B10（引用完整性）和 B7（规则存一份在事实侧），只是从「校验」变成了「评测」。

第三条，「变类型不变体量」这个控制手法可以用在合规检查的方案对比上。

我给的三条路线（甲全文直判、乙检索加判定、丙入库时读成表）在上下文体量上差别巨大：甲把整份文档塞进去，丙只放某个维度的几条。

所以如果直接对比三者的准确率，我分不清是「结构化更好」还是「上下文更短更好」。这篇的做法提示我：要么在对比时把体量拉平，要么明确承认「体量」是这三条路线差异的一部分而不是干扰项。

后者可能更诚实——对合规检查来说，体量本来就是方案选择的一部分（丙能撑住大文档正是它的卖点）。但这一点要写明，不能让读的人以为对比是控制变量的。

第四条，那个「分离现象」提醒我一件事：评测目标要拆开定。

「正确识别出证据不足」和「给出正确的干预决策」在这篇里是分离的——前者满分，后者零分。作者把它当成一个待社区决定的基准设计问题。

对应到合规检查：「正确判出这条 claim 无支撑」和「给出正确的合规判定」也可能分离。一个系统可能很擅长说「文档里查不到这一条」，但在「查不到之后该判违规还是该判范围外」这一步上出错。

这两件事应该分开评分，否则一个在前一步很强、后一步很弱的系统，和一个两步都中等的系统，总分可能一样。

文中金句

"Their evaluations still reward single-answer accuracy rather than reasoning about interventions, mechanisms, harms, evidence, and uncertainty." 它们的评测**仍然奖励单答案准确率**，而不是关于干预、机制、危害、证据与不确定性的推理。

"A biomedical claim is not fully characterised by the pair of entities it connects; it also has a causal status, a confidence, a validation state, an applicable population, and a temporal scope. These live on the claim itself rather than being duplicated across parallel edges." **一条生物医学断言不能由它所连接的那对实体完全刻画**；它还有因果状态、置信度、验证状态、适用人群和时间范围。这些活在断言本身上，而不是被复制到一堆平行的边上。

"Stable assertion_ids make gold structures precise and referable: a gold pathway can be expressed as an ordered list." **稳定的断言 ID 让金标准结构变得精确且可引用**：一条金标准通路可以表达成一个有序列表。

"The conditions vary the type of retrieved context rather than its volume, so that observed differences can be attributed to context organisation rather than to prompt style." 这些条件改变的是**所检索上下文的类型而不是它的体量**，这样观察到的差异才能归因于上下文的组织方式而非提示词风格。

"Ranking the conditions by intervention accuracy alone would have placed C1 first, but that ordering carries no information about mechanism fidelity, evidence use, or unsupported claim generation." **单按干预准确率排名会把 C1 排第一，但那个排序不携带任何关于机制保真度、证据使用或无支撑断言生成的信息。**

"This dissociation between correctly recognising evidential insufficiency and producing the gold intervention decision is precisely the kind of finding the multi-metric panel is designed to expose." **「正确识别证据不足」与「产出金标准干预决策」之间的这种分离，正是多指标面板被设计来暴露的那类发现。**

摘要

Large language models are increasingly proposed for healthcare decision support, but their evaluations still reward single-answer accuracy rather than reasoning about interventions, mechanisms, harms, evidence, and uncertainty.

大模型越来越多地被提议用于医疗决策支持，但对它们的评测仍然奖励单答案准确率，而不是关于干预、机制、危害、证据与不确定性的推理。

作者提出一个可复现的、以图为中心的评测框架，针对医疗场景下面向干预的大模型行为，并在一个心血管试点上做压力测试。框架有四个组件（见「核心内容」一节）。

为检验这个框架，作者构建了一个跨八种推理失败模式的、类别均衡的场景生成器，并在一个心血管图上实例化。

The metric panel discriminates conditions along interpretable, non-redundant axes.

这套指标面板沿着可解释的、非冗余的轴线区分开了这些条件。

一、引言

大模型正越来越多地被整合进临床决策支持场景，但对于什么才是恰当的评测，尚无共识。

（作者随后论证：现有医疗大模型评测多数以问答准确率为核心，无法区分「答对了」和「基于正确的机制与证据答对了」。）

三、框架

3.1 断言物化：每一条断言都是一等节点

（完整内容与四条理由见「核心内容」一节。）

3.2 领域因果与证据知识图谱

图中保留带类型的直接边以支撑遍历效率，同时通过稳定标识符与断言对象保持链接。扩展后的图包含 257 个断言与 15 个证据源，其中 11 条是研究级记录。

Together with the reified layer, this representation supports efficacy, safety, contextual applicability, and evidence provenance, each addressable independently by the scoring pipeline.

加上物化层，这个表示同时支撑疗效、安全性、上下文适用性与证据来源四个方面，每一个都能被打分流水线独立寻址。

3.3 Grounding 条件（四条见「核心内容」一节）

3.4 场景条件化的子图抽取与提示词执行

给定一个场景，系统检索相关的物化断言子图；**提示词随后被确定性地构造**（deterministically constructed），以保证同一条件下的可复现性。

3.5 - 3.7 评测方法论、评测工具与自动打分流水线

打分流水线**以断言标识符为锚**，一次遍历算出干预准确率与其他全部评测指标。主要结局是干预准确率、因果边精度/召回/F1、不良反应 F1、禁忌召回、证据准确率、无支撑断言率、不确定性正确率。

四、结果

（完整指标面板见「核心内容」一节。）

The metric panel separates the four conditions along interpretable, non-redundant axes, which is the property the framework is intended to have.

这套指标面板沿可解释的、非冗余的轴线把四个条件分开了，而这正是该框架意图具备的性质。

作者特别说明表中 **n** 列的含义：它是该指标有定义的被打分场景数。例如因果边精度对 C1 无定义，因为没有 grounding 就不会产出任何因果边；不良反应 F1 只有在有金标准不良反应目标的场景上有定义。

4.3 指标面板在类别层面的行为

The scenario categories produced distinct metric profiles, supporting the framework's design premise that intervention reasoning is not a single competency and should not be measured with a single number.

不同场景类别产生了不同的指标剖面，这支持了框架的设计前提：干预推理不是单一能力，不应该用单一数字来衡量。

- **多通路场景**：C4 取得完美的干预准确率与因果召回，证据准确率 1.000，**无支撑断言率 0.000**
- **不良反应通路场景**：C4 取得完美的干预准确率、完美的因果精度与召回，不良反应 F1 为 1.000
- **禁忌敏感场景**：C4 保持完美的干预准确率与完美的因果通路恢复
- **证据不完整或不确定的类别**：三个 grounded 条件的干预准确率全部为 0.000，而不确定性正确率在所有条件下都是 1.000（分离现象，见「核心内容」）
- **C3 在多通路场景上有一个明显不同的剖面**：干预准确率 0.400、因果精度 0.400、因果召回 0.400、证据准确率 0.400、**无支撑断言率 0.600**

作者对每一条都加了限定：「这些有用，是作为『框架的类别结构与 grounding 操纵之间存在有意义的交互』的证据；**它们不是临床性能保证。**」

4.4 配对条件对比示例（C4 相对 C2）

指标	C2 均值	C4 均值	Δ (C4 - C2)	方向对 C4 有利吗
干预准确率	0.873	0.886	+0.013	是
因果边精度	0.522	0.806	+0.284	是
因果边召回	0.785	0.886	+0.101	是
因果边 F1	0.579	0.838	+0.259	是
不良反应 F1	0.733	0.833	+0.100	是
证据准确率	0.705	0.738	+0.033	是
无支撑断言率	0.259	0.114	-0.145	是 (越低越好)
禁忌召回	1.000	0.800	-0.200	否 (见诊断一节)

作者说明这个对比的目的：[展示框架的「配对差值层」端到端可用，并产出指标专属而非笼统的信号。它不是在主张「整合式 grounding 对临床使用优于知识图谱式 grounding」，那个主张需要多模型阶段。](#)

[关于禁忌召回下降的诊断](#)：作者归因于少数场景下的输出模式语义，而不是图里缺少安全知识。

参考链接

- [arXiv 论文页](#) — 本文原文 (Grounding Healthcare LLMs in a Causal Knowledge Graph: Framework, Metrics, and a Cardiovascular Pilot)
- [Neo4j 属性图模型](#) — 本文图存储所用
- [RDF 物化 \(reification\) W3C 说明](#) — 物化这个做法在 RDF 侧的标准形态，可与本文的属性图物化对照