

把「位于」拆成七个关系名的城市本体 RTSKG: Building a Rail Transit Station Knowledge Graph Dataset

本篇范围说明：这是一篇 21 页的资源型论文（东南大学计算机学院朱书通、吴天星等，与建筑学院朱渊，arXiv 2608.11080v1，2026-08-11）。下面「全文翻译」按原文章节推进，覆盖摘要、§1 引言、§2 相关工作（两小节）、§3 知识图谱构建（数据采集、本体构建与事实抽取）、§4 知识图谱嵌入、§5 站域门店推荐、§6 知识增强客流预测、§7 结论与资源可用性声明。参考文献列表（51 条）与各 KGE 模型的原始定义细节不译；11 个嵌入模型和 5 个时空预测模型只说它们是什么，不展开各自的数学形式。

核心内容

Q: RTSKG 是什么？它要解决的问题是什么？ A: RTSKG 是「轨道交通站点知识图谱」（Rail Transit Station Knowledge Graph）数据集，包含纽约和芝加哥两个子图，发布成 Linked Data，地址 <https://w3id.org/rtskg/>。

它要解决的问题不是「数据不够」，而是**数据的组织方式丢掉了实体之间的相互作用**。作者举的例子很清楚：A 站和 B 站在同一条线上相邻，某个 POI（point of interest，兴趣点，就是商店、餐馆、办公楼这类具体地点）到两站的步行时间差不多。从这个 POI 出发的乘客可能选任一站上车，**所以两站的客流会互相影响**——A 站客流涨，B 站客流可能就跌。现有研究把站点、POI 各自当独立实体处理，这层互相影响就表达不出来，客流预测自然做不准。

Q: 它的本体是怎么建的？ A: 走的是本体工程的标准流程，四步：

1. **确定 domain 和 scope**（领域与范围）：明确这个本体是为「建模城市实体之间的交互」和「支撑城市级轨交站点任务」而建的。
2. **制定 competency questions**（能力问题）：从城市分析的具体需求出发，写出一组问题，用来**指定本体需要覆盖哪些重要概念**。这些问题列在项目的 GitHub 仓库里。
3. **考虑复用现有词汇**：复用了 RDF、RDFS、OWL 和 Dublin Core 的标准词汇——`rdf:type` 把实例连到类、`rdfs:label` 记类和属性的标签、`owl:versionIRI` 标本体版本、`dcterms:description` 给本体一段文字描述、`rdfs:domain` 和 `rdfs:range` 规定关系两端的类型。
4. **定义类、关系、属性**：10 个类、19 个关系，属性用来描述城市实体的基本时空信息（如 POI 的坐标）。

Q: 10 个类和 19 个关系分别是什么？ A: **10 个类**：Borough（行政区，城市的高层行政边界）、Functional Area（功能区，按功能划分的城市子区域，如居住区）、Station（轨交站点）、Station Area

(站域，从站点出发在指定步行时间内可达的区域)、Line (轨交线路，表示成一串相连站点的抽象序列)、Road (路段)、Block (街块，比站域更细的空间单元)、POI、POI Category、Road Category。

19 个关系按语义类型分成四组，这个分组方式值得注意——它是按关系本身的语义分的，不是按端点类型分的：

关系类型	数量	例子
地理位置（一个实例位于另一个实例内）	7	<code>poi_locates_at_station_area</code> 、 <code>station_area_locates_at_borough</code> 、 <code>functional_area_locates_at_borough</code>
地理邻接（两个多边形实例相邻）	2	<code>borough_is_adjacent_to_borough</code> 、 <code>functional_area_is_adjacent_to_functional_area</code>
地理相交	6	<code>road_intersects_borough</code> 、 <code>station_area_intersects_station_area</code> 、 <code>block_intersects_station_area</code>
非地理关系	4	<code>station_area_belongs_to_station</code> 、 <code>station_belongs_to_line</code> 、 <code>poi_has_poi_category</code> 、 <code>road_has_road_category</code>

这里有一个重要的建模决定：那 7 个「位于」关系本质上是同一个语义谓词。作者没有用一个通用的 `locatesAt` 加 `rdfs:domain / rdfs:range` 去区分端点类型，而是为每一对端点类型造一个专门的关系名。相交那 6 个同理。这个选择有代价也有理由，下面点评里展开。

Q：数据是怎么抽出来的？站域这种「不存在于原始数据里」的实体从哪来？ A：原始数据分四类：轨交数据（站点、线路、出入口）、行政区划数据（行政区、功能区）、道路数据（路段、道路类别、路基）、POI 数据（直接取自另一个城市知识图谱 UUKG）。来源是纽约和芝加哥的政府开放数据门户加 OpenStreetMap。

抽取用的是 GeoPandas（一个处理地理空间数据的 Python 库），从 shapefile 格式的地理空间数据里抽出实体和它们的空间位置，再算出所有的位置、邻接、相交关系。

有两类实体是算出来的、不是采集来的：

- **Station Area（站域）**：对每个站的每个出入口，用 Mapbox 的等时圈 API（Isochrone API）根据坐标生成一个「N 分钟步行可达」的区域，再把这个站所有出入口的区域取并集。论文取了 5 分钟和 10 分钟两个固定步行时间，理由是这两个是 TOD（transit-oriented development，公共交通导向开发）和站域研究里的常用阈值。
- **Block（街块）**：定义为「城市中除去路基之后的区域」。也就是先有路，剩下的空地按路网切开就是街块。

规模：纽约 238,839 个实例、1,113,638 条关系三元组、239,090 条属性三元组；芝加哥 151,845 个实例、448,716 条关系三元组、151,943 条属性三元组。两边都是 19 个关系。

Q：怎么证明这个图有用？ A：两个下游任务，都和现有的两个开放城市知识图谱（UUKG、HUSK）对比。

先选嵌入模型：跑了 11 个知识图谱嵌入（KGE）模型做链接预测，**GIE 在两个城市、所有指标上都最好**（纽约 MRR 0.417、芝加哥 0.397）。作者给的理由很具体：**本体里同时存在层次结构和环状结构**——Station Area、Functional Area、Borough 之间是层次，Station Area、POI、Block 之间构成环——而 GIE 是设计来同时捕捉这两种结构的（它在欧氏、双曲、超球面空间的乘积空间里学表示）。

任务一，站域门店推荐：给定一个位于某站域内的 POI，预测它应该属于哪个类别（形式上就是查询 `(POI, poi_has_poi_category, ?)` 的链接预测）。用途是判断站点周边最适合开什么店。结果 RTSKG 全面领先：纽约 MRR 0.782 对 HUSK 0.770、UUKG 0.757；芝加哥差距更大，0.570 对 0.524、0.455。

任务二，知识增强客流预测：用过去 12 天的客流预测下一天。分两条路：

- **传统路线：**把 KG 嵌入当成外部知识特征，直接和历史客流拼在一起喂给模型。测了 5 个时空图卷积模型。
- **LLM 路线：**把每条时序实例**语言化**成自然语言问句（「从 9 月 5 日到 9 月 16 日，位于 Bushwick North 功能区的 Myrtle-Wyckoff Aves 站每天的客流是 18030、12496……18461。9 月 17 日的客流会是多少？」），把每条关系三元组也语言化成陈述句（「Myrtle-Wyckoff Aves 站属于 Canarsie 线」），用预训练语言模型把问句和三元组都编码成向量，按余弦相似度检索出 top-50 条最相关的三元组，**用一个 LLM 把它们摘要成一段 abstract**，再把问句和这段 abstract 拼成 prompt 喂给另一个 LLM 做预测。基座是 GPT-4o。

结果最显眼的是 STGCN 在纽约：不做知识增强 MAE 是 1490.229，用 RTSKG 的 Station 类增强后降到 **735.471，降了 50.6%**。

Q：有一个对照设置特别值得学，是哪个？ A：因为 UUKG 和 HUSK **都不含轨交站点**，所以拿它们做增强时只能用双方共有的 Functional Area 类。为了公平比较，作者**额外用 RTSKG 自己的 Functional Area 类也做了一版**（记作 w/RTSKG-F），和用 Station 类的那版（w/RTSKG-S）并列报出来。

这个设置把两个因素分开了：**「我的数据集建模质量更好」和「我多了一类实体」**。结果两条都成立——w/RTSKG-F 也比 w/UUKG、w/HUSK 好（说明建模质量确实更高，作者的解释是 RTSKG 建了实体间交互，使 Functional Area 的嵌入隐含地吸收了站点的特征），而 w/RTSKG-S 又比 w/RTSKG-F 更好（说明显式建站点确实额外有用）。

背景补充 / 点评

几个概念的位置

competency question（能力问题） 是本体工程里的一个标准做法，出自 Grüninger 和 Fox 1995 年的方法论：在建本体之前先写一组「这个本体建好之后必须能回答」的自然语言问题，用它们来界定范围、也用它们来验收。它的价值在于把「本体够不够用」这个模糊判断变成一份可检查的清单。这篇论文的 CQ 放在 GitHub 仓库里，正文没列——这是资源论文的常见做法（正文篇幅给数据统计和实验），但对想学方法的读者来说是个损失。

Linked Data 的四个要求（Tim Berners-Lee 提出）在这篇里被完整满足了，这在数据集论文里不算普遍：用 URI 命名事物、URI 用 HTTP、访问 URI 能拿到有用信息、包含指向其他数据的链接。具体做法是所有类和实例的 URI 都在 `w3id.org` 这个永久标识服务下**可解引用**（dereferenceable，意思是你把这个 URI 丢进浏览器或 curl，服务器会真的返回这个资源的描述，而不是 404）、RDF dump 放在 Zenodo 上有 DOI、数据用 CC BY-SA 4.0、代码用 Apache 2.0。

GIE 全称 Geometry Interaction knowledge graph Embeddings，2022 年的模型。它的做法是同时在三种几何空间里学表示——欧氏空间（适合表达平移类关系）、双曲空间（适合表达树状层次，因为双曲空间的体积随半径指数增长，正好装得下指数增长的树）、超球面空间（适合表达环状和对称结构）——然后让三者交互。这解释了为什么它在这个数据集上赢：这个本体确实两种结构都有。

洞察在哪、代价在哪

最值得记的是那 19 个关系的命名方式，而它的代价论文一句没提。

把「位于」拆成 7 个专门的关系名（`poi_locates_at_station_area`、`poi_locates_at_block`、`station_area_locates_at_borough`、`station_area_locates_at_functional_area`、`block_locates_at_borough`、`block_locates_at_functional_area`、`functional_area_locates_at_borough`），好处有两条，都很实在：

1. **每个关系的 domain 和 range 天然确定**，不需要额外约束就不会出现「POI 位于某条路」这种类型错误的三元组。
2. **KGE 能给每个特化学一个独立的向量**。「POI 位于街块」和「功能区位于行政区」在几何上是不同性质的关系（点对多边形 vs 多边形对多边形，粒度差好几个数量级），共用一个向量会互相干扰。这大概是作者真正的动机——毕竟整篇论文的下游任务全靠嵌入。

代价有三条：

1. **查询要写 union**。想问「所有位于某个 borough 里的东西」，得把三个关系（`station_area_locates_at_borough`、`block_locates_at_borough`、`functional_area_locates_at_borough`）并起来查，而不是一个 `locatesAt` 搞定。
2. **加一个新类要新增 $O(n)$ 个关系**。如果以后要加「公交站」这个类，它和现有的行政区、功能区、街块、站域都可能有「位于」关系，一次要加四个关系名。本体的关系数会随类数平方级增长。
3. **「位于」的传递性表达不出来**。语义上，POI 位于街块、街块位于行政区，应该能推出 POI 位于行政区。用一个通用的 `locatesAt` 可以声明 `owl:TransitiveProperty` 让推理机自己补；拆成 7 个之后，这条推理规则没有地方挂——它跨越了三个不同的关系名。论文里 POI 到 Borough 确实没有直接关系，也没有说这是有意的还是没考虑到。

这不是说作者选错了。为嵌入服务的图和为查询/推理服务的图，最优形状本来就不一样。**问题是论文把这个当成理所当然的设计，没有把权衡写出来**，读者容易照抄形式而不知道自己在换什么。

第二处留白：GIE 胜出的解释是事后的，而且领先幅度不稳。「本体同时有层次和环，所以 GIE 赢」这个解释合理，但它是看到结果之后给的，没有做验证（比如构造一个只有层次的子图、一个只有环的子图，看 GIE 的优势是否随之消失）。而且 GIE 领先第二名 ATTH 只有 0.005 MRR（纽约 0.417 vs 0.412）、0.005（芝加哥 0.397 vs 0.392）——**单次运行、没有多随机种子、没有置信区间**，这个差距说不上稳。选 GIE 作为基座模型这个决定影响了后面所有实验，它建立在一个 0.005 的差上。

第三处：链接预测的绝对水平其实不高，作者没评论。 纽约 MRR 0.417 意味着正确答案平均排在第 2 到 3 位。对一个 schema 严格、每个关系的端点类型都被关系名锁死了的图来说，这个数字偏低。两个可能的原因论文都没讨论：负采样只有 50 个（这会让指标偏**乐观**，真实排名应该更差）、嵌入维度只有 32。维度定为 32 的理由是「following previous work [22]」，也就是为了和 UUKG 的实验设置可比——这可以理解，但也意味着这批数字反映的是「在 UUKG 的设置下」的表现，**不是 RTSKG 的上限**。资源论文的读者最想知道的恰恰是上限（我用这个数据集能做到多好），这篇给的是可比性。

第四处：客流预测的提升幅度差异巨大，没被解释。 纽约 MAE 的降幅：STGCN 降 50.6% (1490 → 735)、ASTGCN 降 30.0% (101 → 70.8)、MSTGCN 降 15.4% (209 → 177)、TGCN 降 13.5% (3725 → 3222)、STPGCN 降 8.4% (1100 → 1008)。同时注意 Vanilla 基线本身的差距离谱——ASTGCN 是 101，TGCN 是 3725，**差 37 倍**，这五个模型显然不在同一个调参水平上。

规律是：**基线越差的模型（相对而言），知识增强的提升越大**。这提示知识增强在这里可能部分起了「补充特征让弱模型少犯错」的作用，而不是纯粹的知识价值。作者只报了「一致提升」这个事实，没解释这个梯度。要把「一致提升」这个结论坐实，更该报的是**同一个模型在充分调参之后的提升幅度**，而不是五个调参水平不一的模型都涨了。

对我的启示

一、competency questions 这一步我没有显式做过，该补。 我在 prove 项目里建 tbox/rbox 时，判断「本体够不够用」的标准一直是模糊的——写到觉得够了就停。这篇的流程给了一个可操作的替代：**先写一组「建好之后必须能回答」的具体问题，用它们定范围、也用它们验收。**

我在 UMU 那份统一模型 spec 里已经写了「模型要回答的三个问题（是什么 / 什么关系 / 学到什么程度）」，那是三个 CQ 的雏形，但**粒度太粗**——它们是元问题，不是可执行的查询。要真起验收作用，得落到这种粒度：「给定一个员工和一个岗位，列出他缺哪些能力、每项差几级」「给定一门课，列出它教的知识单元里哪些是认知型、哪些是技能型」「给定一个知识单元，它在哪些课里是主线、在哪些课里是装饰」。写成这样之后，每加一个产品进模型，就拿这份清单过一遍——**答不出来的那条，就是模型还缺的东西。**

二、它对 `rdfs:domain` 的措辞是我那个发现的独立佐证。 我之前踩过一个坑：以为写了 `rdfs:domain` 就能拦住类型不对的数据，实际上 RDFS 的语义是推理——它不拦，反而给违规数据**补上**一个类型。

这篇论文的原话是：`rdfs:domain` "specifying that any resource that has a given relation or attribute **is** an instance of one or more classes"。用的是 **is**，不是 must be。一篇正经发表的资源论文这样写，说明这不是我的误读，而是规范本身的意思。所以那条判据可以定下来了：**凡是要表达「必须是」「不能超过」「至少一个」，`rdfs:domain / rdfs:range` 永远不够，要上 SHACL 或者应用层校验。** 我的 `rbox.yaml` 里如果有靠 domain/range 暗示约束的地方，都要复查。

顺带注意：这篇之所以不需要约束，是因为它用**关系命名**把类型锁死了——

`poi_locates_at_station_area` 这个名字本身就不允许接错端点。这是「用命名代替约束」的一种做法，能work，但代价就是上面说的那三条。

三、「一个通用关系 + 类型字段」还是「展开成多个专门关系」，我马上要面对这个选择。UMU 的 `knowledge_relation` 表现在设计的是通用路线：一张关系表带 `relation_type` 字段区分 `requires` / `part_of` / `illustrates` / `same_as`。这篇选了展开路线。

我该选通用，理由是**查询模式**：我的主要查询是「给定一个知识单元，找它的前置 / 包含 / 装饰」，通用路线一次能查完，展开路线要 union；而且我不做嵌入，所以展开路线最大的好处（给每个特化学独立向量）对我是零收益。

但这篇的代价清单给了我一份反向检查表，记下来：**如果哪天要做嵌入、或者要让推理机自动补传递闭包，通用路线更好；如果要靠命名自动保证端点类型，展开路线更好。** 我现在两个需求都不成立，所以选择站得住。要是以后要做知识单元的向量检索，这个决定要重新审。

四、w/RTSKG-F 那个对照设置是个可以直接搬的范式。它把「我的东西更好」拆成两问：**同类对照**（用双方共有的那部分做，赢了说明质量更高）和**增量对照**（用我独有的那部分做，赢了说明覆盖面有用）。

我做数仓迁移验证时正好需要这个。前几天设计的方案是把 `knowledge_point_resource` 拆两层加拉链，怎么证明新模型正确？按这个范式拆成两问：**同类对照**——在「绑定从未变过的那些题」上，新老模型算出的正确率必须完全一致（因为拉链表退化成单条记录，两条路径应该重合）；**增量对照**——在「绑定改过的那些题」上，新模型算出来的应该等于「按答题时刻的绑定」，老模型算出来的会因出题方式而分裂。第二问才是新模型的价值所在，而第一问是它没有引入回归的证明。**光对总行数是两问都没答。**

五、本体的图结构形状会约束下游算法的选择。作者是先建了本体、然后发现里面既有层次又有环、于是选了能同时处理两者的模型。这个顺序值得注意：**结构形状是本体设计的产物，但它会限制下游能用什么算法。**

对着我的 spec 检查一遍：`requires`（前置）应该是有向无环——如果出现环就是数据错误，值得加个检测；`part_of`（包含）也是有向无环；`illustrates`（装饰）有向，但装饰对象和被装饰对象之间还可能有 `requires`，所以这两种边叠起来会不会成环需要验；`same_as`（跨产品对齐）是**对称的**，一旦有它，图里就必然有二元环。这个混合形状说明：**我的图不是纯树，任何假设树结构的算法（比如层次遍历、最近公共祖先）都不能直接用在全图上，只能用在单一边类型的子图上。** 这一条该写进 spec 的第 5 节（建模难点）。

文中金句

"they often treat rail transit stations, points of interest (POIs), and etc. as independent entities, neglecting complex interactions among various urban entities, which limits their application in real-world scenarios." 它们往往把轨交站点、兴趣点 (POI) 等当作彼此独立的实体，忽略了各类城市实体之间的复杂交互，这限制了它们在真实场景中的应用。

"we formulate a set of competency questions to specify the important concepts to be covered by the ontology." 我们制定了一组能力问题（competency questions），用来指定本体需要覆盖哪些重要概念。

"rdfs:domain specifying that any resource that has a given relation or attribute is an instance of one or more classes" `rdfs:domain` 规定的是：任何拥有某个给定关系或属性的资源，**就是**一个或多个类的实例。（注意这里用的是「是」而不是「必须是」——这是推理语义，不是约束语义。）

"This is mainly because our ontology contains both hierarchical structures and cyclic structures." 这主要是因为我们的本体里同时包含层次结构和环状结构。

"the models enhanced with the instances in the class Station outperform those enhanced with the instances in the class Functional Area, suggesting that explicitly modeling stations in the KG can capture the mutual influence between the ridership of different stations." 用 Station 类实例做增强的模型优于用 Functional Area 类实例做增强的模型，这说明在知识图谱里显式建模站点，能够捕捉不同站点客流之间的相互影响。

全文翻译

摘要

Rail transit systems play a vital role in urban mobility and economic development. As key components of such systems, rail transit stations function as critical transport hubs that enhance urban accessibility and stimulate development in surrounding areas. City-level rail transit station related tasks (e.g., ridership prediction) require large-scale urban data, but current studies often neglect complex interactions among various urban entities in terms of data organization.

轨道交通系统在城市流动性和经济发展中扮演关键角色。作为这类系统的核心组成，轨交站点是重要的交通枢纽，提升城市可达性并带动周边地区发展。城市级的轨交站点相关任务（如客流预测）需要大规模城市数据，但当前研究在数据组织层面往往忽略了各类城市实体之间的复杂交互。

In this paper, to address the above issue, we build a Rail Transit Station Knowledge Graph (RTSKG) dataset which explicitly models the spatial and semantic interactions among different kinds of urban entities, to benefit city-level rail transit station related tasks. RTSKG integrates heterogeneous urban entities, such as rail transit stations, road segments, and points of

interest, with a specially designed unified schema, and is accessible as Linked Data at <https://w3id.org/rtskg/>. Evaluations on station-area store recommendation and knowledge-enhanced ridership prediction demonstrate the effectiveness of RTSKG.

为解决上述问题，本文构建了轨道交通站点知识图谱（RTSKG）数据集，它**显式建模**不同类城市实体之间的空间与语义交互，以服务城市级轨交站点相关任务。RTSKG 用一套专门设计的统一 schema 整合了异构的城市实体（轨交站点、路段、兴趣点等），并作为 Linked Data 发布在 <https://w3id.org/rtskg/>。在站域门店推荐和知识增强客流预测两个任务上的评测证明了 RTSKG 的有效性。

1. 引言：两个相邻车站的客流会互相抢

As key components of rail transit systems, rail transit stations are critical transport hubs which have been widely studied for their impact on urban development. Traditional research on rail transit stations often relies on manually collected data and focuses on a limited number of stations, thus fails to capture common features of the stations across the entire rail transit system, and cannot support city-level rail transit station related tasks. Consequently, recent studies have shifted toward using large-scale data sources to conduct rail transit station analysis. However, they often treat rail transit stations, points of interest (POIs), and etc. as independent entities, neglecting complex interactions among various urban entities, which limits their application in real-world scenarios.

作为轨交系统的核心组成，轨交站点是重要的交通枢纽，其对城市发展的影响已被广泛研究。传统的站点研究往往依赖人工采集的数据、只覆盖有限数量的站点，因此无法捕捉整个轨交系统内站点的共性特征，也无法支撑城市级的站点相关任务。因此近期研究转向使用大规模数据源做站点分析。但它们往往把轨交站点、POI 等**当作彼此独立的实体**，忽略了各类城市实体之间的复杂交互，这限制了它们在真实场景中的应用。

For example, station A and station B are adjacent on the same rail transit line, and the walking times from a certain POI to both stations are similar. Passengers departing from the POI may choose either station for boarding. Therefore, the ridership of both stations mutually influences each other, i.e., an increase in the ridership of station A may probably cause a corresponding decrease in the ridership of station B. Explicitly modeling such interactions among the POI and both stations could benefit the task of ridership prediction.

举例来说，A 站和 B 站在同一条轨交线路上相邻，某个 POI 到两站的步行时间相近。从这个 POI 出发的乘客可能选择任一站上车。因此**两站的客流会相互影响**——A 站客流上升，很可能导致 B 站客流相应下降。显式建模 POI 与这两个站之间的这类交互，能够改善客流预测任务。

Actually, rail transit station related urban entities are distributed across heterogeneous data sources, and it is non-trivial to integrate different kinds of entities and model their interactions. Recently, knowledge graphs (KGs) have been adopted for organizing urban data due to their ability to model complex relations among urban entities, but current studies do not involve rail transit stations, which prevents their application in city-level rail transit station related tasks.

实际上，与轨交站点相关的城市实体分散在异构数据源中，整合不同类型的实体、建模它们的交互并非易事。近期知识图谱因其建模城市实体间复杂关系的能力，被用于组织城市数据，但**现有研究不涉及轨交站点**，这使它们无法应用于城市级的站点相关任务。

贡献三条。 We propose RTSKG, the first rail transit station knowledge graph dataset, which explicitly models the spatial and semantic interactions among different urban entities with a specially designed ontology as its unified schema. We design two representative city-level rail transit station related tasks: station-area store recommendation and knowledge-enhanced ridership prediction. We conduct comprehensive experiments; the results show that leveraging RTSKG for the above tasks has the best performance compared with using existing urban KGs.

我们提出 RTSKG，**第一个**轨交站点知识图谱数据集，它以一套专门设计的本体作为统一 schema，显式建模不同城市实体之间的空间与语义交互。我们设计了两个代表性的城市级轨交站点任务：站域门店推荐、知识增强客流预测，用来评估 RTSKG 的实用价值。我们做了全面的实验，结果显示在这两个任务上使用 RTSKG 的表现优于使用现有的城市知识图谱。

2.1 站点分析：从人工采集到大规模数据源

Traditional research often relies on manually collected data and covers a limited number of stations. Such small-scale data cannot support city-level rail transit station related tasks. Recent studies try to use large-scale data sources for rail transit station analysis. However, these data often simply treat urban entities like POIs as independent entities, neglecting complex interactions among heterogeneous urban entities.

传统研究往往依赖人工采集的数据、覆盖有限数量的站点。这类小规模数据无法支撑城市级的站点任务。近期研究尝试用大规模数据源做站点分析：有的采集大量 POI 数据来刻画城市尺度上的站点，有的从乘客的智能卡数据预测站点客流，有的基于 POI 构建站点的环境因子用于客流预测。然而这些数据往往只是把 POI 这类城市实体当作独立实体，忽略了异构城市实体之间的复杂交互。

2.2 城市建模的已有资源：城市知识图谱与本体

Urban KGs model relations among urban entities, providing a structured way to integrate and organize such heterogeneous urban data. For example, among non-public urban KGs, STKG jointly models category information of venues and temporal information, and is used for mobility prediction; Knowsite constructs a KG which captures cities' key elements and complex relationships for site selection; KG-MUP builds a KG with domain entities and applies it for user profile inference. Recently, several open urban KGs have been built. UUKG is the first open urban KG dataset for knowledge-enhanced urban spatiotemporal predictions, and HUSK further designs a function zone construction method to capture fine-grained semantic information between POIs and areas. However, these urban KGs do not involve rail transit station related information.

城市知识图谱建模城市实体之间的关系，为整合和组织异构城市数据提供了结构化的方式。在非公开的城市 KG 中，STKG 联合建模场所的类别信息与时间信息，用于移动性预测；Knowsite 构建了一个捕捉城市关键要素与复杂关系的 KG，用于选址；KG-MUP 构建带领域实体的 KG 用于用户画像推断。近期出现了几个开放的城市 KG：UUKG 是第一个面向知识增强的城市时空预测的开放城市 KG 数据集，HUSK 进一步设计了一套功能区构建方法，以捕捉 POI 与区域之间细粒度的语义信息。然而这些城市 KG **都不涉及轨交站点相关信息**。

Alongside these urban KGs, several resources provide representations of knowledge about public transport, geography, and urban infrastructure. For example, the NEPTUNE and Passim datasets are represented in RDF format based on specially developed ontologies and published as Linked Data, describing public transport routes and relevant information on transport services, respectively. LinkedGeoData transforms and represents OpenStreetMap data adhering to the RDF data model. GeoKG uses schema and data layers to represent and integrate geographical knowledge from multi-source data. City Infrastructure Ontologies represent city infrastructure assets and their interdependencies in OWL 2. LibCity-Dataset standardizes urban spatial-temporal data storage using atomic files. However, these resources either focus on public transport knowledge with limited coverage of other urban entities relevant to rail transit stations, or represent urban knowledge in a generic manner without specifically organizing entities and relations around rail transit systems.

除这些城市 KG 之外，还有若干资源提供了关于公共交通、地理和城市基础设施的知识表示。例如 NEPTUNE 和 Passim 数据集基于专门开发的本体以 RDF 格式表示、作为 Linked Data 发布，分别描述公交线路和交通服务的相关信息；LinkedGeoData 把 OpenStreetMap 数据转换成符合 RDF 数据模型的表示；GeoKG 用 schema 层和数据层来表示与整合多源地理知识；City Infrastructure Ontologies 用 OWL 2 表示城市基础设施资产及其相互依赖；LibCity-Dataset 用原子文件标准化城市时空数据的存储。然而这些资源**要么聚焦公共交通知识、对其他相关城市实体覆盖有限，要么以通用方式表示城市知识、没有专门围绕轨交系统组织实体和关系**。RTSKG 通过在一套专门设计的 schema 下整合不同类型的城市实体来填补这一空缺。

3.1 采集了哪四类城市数据

轨交数据。 The rail transit data involve the information of key components of rail transit systems and it contains the data of rail transit stations, rail transit lines, and rail transit station entrances & exits.

轨交数据涉及轨交系统关键组成的信息，包含站点、线路、以及站点出入口的数据。站点和线路来自 Open NY 和芝加哥数据门户；出入口分别来自 Open NY（纽约）和 OpenStreetMap（芝加哥）。

行政区划数据。 Administrative divisions represent hierarchical geographic regions created by governments. We collect two types: administrative boroughs represent large-scale administrative divisions that support city management and public service delivery. Functional areas refer to the subdivisions of a city according to their functions, such as residential areas.

行政区划代表政府划定的层次化地理区域。采集两类：**行政区**代表支撑城市管理与公共服务的大尺度行政划分；**功能区**指按功能对城市的细分，如居住区。

道路数据。 Road data involves information about the urban road network including road segments, road categories and roadbeds. Roadbeds are the regions representing the width of road segments, which can be applied to generate urban entities like urban blocks for analysis.

道路数据涉及城市路网信息，包括路段、道路类别和路基。**路基**是表示路段宽度的区域，可以用来生成街块这类城市实体供分析使用。纽约的路基直接来自 NYC OpenData，芝加哥的路基则基于自定义的路段宽度生成。

POI 数据。 POIs are specific places where people gather and conduct daily activities and they are widely used to support city-level urban tasks. The POI data are obtained from the famous urban KG dataset UUKG.

POI 是人们聚集和进行日常活动的具体场所，被广泛用于支撑城市级任务。POI 数据取自知名的城市 KG 数据集 UUKG。

3.2 本体构建与事实抽取

本体构建。 We build the RTSKG ontology as the schema to guide extracting and integrating factual knowledge from different kinds of urban data. Following the broadly accepted procedure, we first determine the domain and scope of the ontology. RTSKG is designed to model the interactions among different kinds of urban entities and support city-level rail transit station related tasks. Based on concrete needs in urban analysis, we formulate a set of competency questions to specify the important concepts to be covered by the ontology.

我们构建 RTSKG 本体作为 schema，用来引导从不同类型的城市数据中抽取和整合事实知识。遵循广泛接受的流程，**首先确定本体的领域与范围**：RTSKG 的设计目标是建模不同类城市实体之间的交互、支撑城市级轨交站点任务。**基于城市分析中的具体需求，我们制定了一组能力问题（competency questions），用来指定本体需要覆盖哪些重要概念**（清单列在 GitHub 仓库中）。

We then consider reusing existing vocabularies. For example, we reuse the standard RDF, RDFS, OWL and Dublin Core vocabularies, including `rdf:type` linking from instances to classes, `rdfs:label` recording the labels of classes, relations (i.e., object properties) and attributes (i.e., data properties), `owl:versionIRI` identifying the IRI used to identify the version of the ontology, `dcterms:description` providing a textual description of the ontology, `rdfs:domain` specifying that any resource that has a given relation or attribute is an instance of one or more classes, and `rdfs:range` specifying that the values of a relation or attribute are instances of one or more classes. We then define the classes, relations, and attributes in the RTSKG ontology, where attributes are used to describe basic spatiotemporal information of urban entities.

接着考虑复用已有词汇：复用了标准的 RDF、RDFS、OWL 和 Dublin Core 词汇，包括 `rdf:type`（把实例连接到类）、`rdfs:label`（记录类、关系（即 object properties）和属性（即 data properties）的标签）、`owl:versionIRI`（标识本体版本的 IRI）、`dcterms:description`（给本体一段文字描述）、`rdfs:domain`（规定任何拥有某个给定关系或属性的资源**就是**一个或多个类的实例）、`rdfs:range`（规定某个关系或属性的取值**是**一个或多个类的实例）。**然后定义** RTSKG 本体中的类、关系和属性，其中属性用于描述城市实体的基本时空信息（如 POI 的坐标）。

We define ten classes as follows. (1) Borough refers to administrative borough describing high-level administrative boundaries of a city; (2) Functional Area represents the subdivision of a city. Along with Borough, it enables urban entities from different data sources to be aligned according to administrative divisions; (3) Station refers to the rail transit station; (4) Station Area refers to the region accessible from a rail transit station within a specified walking time, providing a local area around the station for analysis; (5) Line refers to the rail transit line, which is represented as an abstract sequence of connected stations along the route; (6) Road denotes the road segment in a city, which forms the traffic network and provides a basis for human mobility; (7) Block refers to the urban block, which is a finer-grained spatial unit that constitutes the fundamental element of the physical structure of urban areas; (8) POI represents the basic functional units in a city; (9) POI Category refers to category of POI, which characterizes the function of POI; (10) Road Category is the category determined by the hierarchy or function of the road.

定义了十个类：（1）**Borough** 行政区，描述城市的高层行政边界；（2）**Functional Area** 功能区，城市的子划分——它和 Borough 一起，**使来自不同数据源的城市实体能够按行政区划对齐**；（3）**Station** 轨交站点，乘客上下车的交通枢纽；（4）**Station Area** 站域，从站点出发在指定步行时间内可达的区域，为站点周边提供一个供分析的局部范围；（5）**Line** 轨交线路，表示为沿路线相连站点的抽象序列；（6）**Road** 城市中的路段，构成交通网络、为人的移动提供基础；（7）**Block** 街块，构成城市区域物理结构基本要素的更细粒度空间单元；（8）**POI** 城市中的基本功能单元；（9）**POI Category** POI 的类别，刻画 POI 的功能；（10）**Road Category** 由道路的等级或功能决定的类别。

We also define nineteen relations, which are further categorized into four types.

还定义了十九个关系，进一步分成四种类型。

Geographic Location. This relation type models that one instance locates at another instance. We define seven geographic location relations. Specifically, `poi_locates_at_station_area` and `poi_locates_at_block` represent location relations between point and polygonal instances. `station_area_locates_at_borough`, `station_area_locates_at_functional_area`, `block_locates_at_borough`, `block_locates_at_functional_area` and `functional_area_locates_at_borough` represent location relations between two polygonal instances.

地理位置。 这一关系类型建模「一个实例位于另一个实例之内」，共定义七个。其中

`poi_locates_at_station_area` 和 `poi_locates_at_block` 表示点实例与多边形实例之间的位置关系；`station_area_locates_at_borough`、`station_area_locates_at_functional_area`、`block_locates_at_borough`、`block_locates_at_functional_area` 和 `functional_area_locates_at_borough` 表示两个多边形实例之间的位置关系。

Geographic Adjacency. This relation type models that one instance is adjacent to another instance: `borough_is_adjacent_to_borough` and `functional_area_is_adjacent_to_functional_area`. Both relations enable the ontology to model the adjacency between two polygonal instances.

地理邻接。 这一类型建模「一个实例与另一个实例相邻」，两个关系：

`borough_is_adjacent_to_borough` 和 `functional_area_is_adjacent_to_functional_area`。两者都让本体能表达两个多边形实例之间的邻接。

Geographic Intersection. We define six geographic intersection relations.

`road_intersects_borough`, `road_intersects_functional_area`, and `road_intersects_station_area` model the intersections between linear and polygonal instances, characterizing the spatial distribution of the road network across geographic regions. `station_area_intersects_block`, `station_area_intersects_station_area`, and `block_intersects_station_area` represent intersections between two polygonal instances, capturing potential interactions through their shared spatial regions (e.g., the region of overlap between two station areas).

地理相交。 定义六个。`road_intersects_borough`、`road_intersects_functional_area`、`road_intersects_station_area` 建模线状实例与多边形实例的相交，刻画路网在各地理区域上的空间分布；`station_area_intersects_block`、`station_area_intersects_station_area`、`block_intersects_station_area` 表示两个多边形实例之间的相交，通过它们共享的空间区域捕捉潜在的交互（例如两个站域之间的重叠区域）。

Non-Geographic Relation. We define four non-geographic relations:

`station_area_belongs_to_station`, `station_belongs_to_line`, `poi_has_poi_category`, and `road_has_road_category`. These relations do not capture spatial interactions between instances, but are still important in rail transit station analysis.

非地理关系。 定义四个：`station_area_belongs_to_station`、`station_belongs_to_line`、`poi_has_poi_category`、`road_has_road_category`。这些关系不捕捉实例间的空间交互，但在轨交站点分析中同样重要。

事实抽取。 To handle heterogeneous urban data, we employ the GeoPandas, a Python library for dealing with geospatial data, to extract urban entities and facts. Specifically, we use GeoPandas to extract the instances belonging to the classes Borough, Functional Area, Station, Road, and POI, together with their spatial locations, from the geospatial data in the shapefile format. We also obtain the instances belonging to the classes Line, POI Category, and Road Category directly from the tabular data with the comma-separated values format.

为处理异构的城市数据，采用 GeoPandas（一个处理地理空间数据的 Python 库）抽取城市实体和事实。具体地，用 GeoPandas 从 shapefile 格式的地理空间数据中抽出属于 Borough、Functional Area、Station、Road、POI 这几个类的实例及其空间位置；Line、POI Category、Road Category 三个类的实例直接从 CSV 格式的表格数据中获得。

For the instances in the class Station Area, we construct a station area for each station based on the isochrone regions (i.e., the region can be reached within a certain walking time) of its entrances or exits. For each entrance or exit, we generate an isochrone region using the Mapbox Isochrone API based on its geographic coordinates. The station area of a station is then obtained by taking the union of the isochrone regions of all the entrances and exits. In this paper, we construct station areas with two fixed walking times, i.e., 5 minutes and 10 minutes, which are common thresholds in transit-oriented development (TOD) and station-area studies.

对 Station Area 类的实例，[按站点各出入口的等时圈区域](#)（即在一定步行时间内可到达的区域）来构造每个站的站域。对每个出入口，用 Mapbox Isochrone API 根据其地理坐标生成一个等时圈区域；该站的站域即为所有出入口等时圈区域的**并集**。本文构造了两个固定步行时间的站域，即 5 分钟和 10 分钟——这是 TOD（公共交通导向开发）和站域研究中的常用阈值。

For the instances in the class Block, we define them as the regions in the city excluding roadbeds. The KG construction process can be extended to other cities by collecting the required urban data and adapting the Python scripts to handle differences in data formats. All class URIs in the namespace <https://w3id.org/rtskg/ontology/class/> and all instance URIs are dereferenceable.

对 Block 类的实例，定义为[城市中除去路基之后的区域](#)。整个 KG 构建过程可以扩展到其他城市，只需采集所需的城市数据并调整 Python 脚本以处理数据格式差异。命名空间

<https://w3id.org/rtskg/ontology/class/> 下的所有类 URI 以及所有实例 URI 都是可解引用的 (dereferenceable)。

城市	实例数	关系数	关系三元组	属性三元组
纽约	238,839	19	1,113,638	239,090
芝加哥	151,845	19	448,716	151,943

4. 知识图谱嵌入：为什么 GIE 赢

Given a KG G , KGE is to learn vector representations (i.e., embeddings) for instances and relations in a dense and low-dimensional space. We compared the performance of different KGE models on link prediction which aims to predict the missing tail or head instance for a query $(h, r, ?)$ or $(?, r, t)$.

给定一个 KG G ，KGE 的目标是在稠密的低维空间中为实例和关系学习向量表示（嵌入）。我们在链接预测任务上比较不同 KGE 模型的表现——链接预测的目标是为查询 $(h, r, ?)$ 或 $(?, r, t)$ 预测缺失的尾实体或头实

体。

评测指标是 Hits@k ($k=1,3$, 正确实例出现在前 k 名中的比例) 和 MRR (平均倒数排名)。测了 11 个模型: TransE (经典的基于平移的模型)、DistMult (张量分解的双线性模型)、ComplEx (DistMult 在复空间的扩展)、RotatE (把每个关系定义为复向量空间中的旋转)、MuRE (带对角关系矩阵的平移距离模型)、TuckER (基于三元组二值张量表示的 Tucker 分解)、QuatE (引入更具表达力的超复数表示)、AttH (把双曲反射与旋转和注意力结合)、RefH/RotH (AttH 的反射版与旋转版变体)、GIE (乘积空间模型, 在欧氏、双曲、超球面空间之间交互式地学习空间结构)。所有模型用 PyTorch 实现, 在一张 RTX 3090 上跑, 负采样规模固定 50、嵌入维度固定 32 (沿用前人工作 UUKG 的设置)。

Experimental results indicate that GIE outperforms other KGE models across all link prediction metrics on both sub-KGs. This is mainly because our ontology contains both hierarchical structures and cyclic structures. The relations among Station Area, Functional Area, and Borough form a hierarchical structure, and the relations among Station Area, POI, and Block form a cyclic structure. GIE is designed to capture such structures simultaneously. Motivated by GIE's superior KGE ability, we chose GIE as the base model.

实验结果表明 GIE 在两个子图的所有链接预测指标上都优于其他 KGE 模型。[这主要是因为我们的本体里同时包含层次结构和环状结构](#): Station Area、Functional Area、Borough 之间的关系构成层次结构, 而 Station Area、POI、Block 之间的关系构成环状结构。GIE 的设计目标就是同时捕捉这两类结构。基于 GIE 更强的嵌入能力, 我们选它作为基座模型。

(纽约子图上 GIE 的 Hits@1 / Hits@3 / MRR 为 0.326 / 0.467 / 0.417, 第二名 ATTH 是 0.319 / 0.463 / 0.412; 芝加哥子图上 GIE 为 0.317 / 0.438 / 0.397, ATTH 为 0.310 / 0.432 / 0.392。表现最差的是 RotatE, 芝加哥上 MRR 只有 0.169。)

5. 任务一: 站域门店推荐

Station-area store recommendation can be formally modeled as a special link prediction task. Given a POI instance located in a station area, station-area store recommendation aims to predict the category through the query $(h_p, r_p, ?)$, where r_p denotes the relation `poi_has_poi_category`.

站域门店推荐可以形式化为一个特殊的链接预测任务: 给定一个位于某站域内的 POI 实例, 通过查询 $(h_p, \text{poi_has_poi_category}, ?)$ 预测它的类别。

For each city, we sampled POIs located at station areas with 5-minute walking time, and ensured that each sampled POI appears as an instance in each of the three KG datasets (i.e., RTSKG, UUKG, and HUSK). We then constructed the validation and test sets by extracting relation triples with the relation `poi_has_poi_category` whose head instances are these sampled POIs. All remaining relation triples were used as the training set for each KG dataset.

对每个城市，采样位于 5 分钟步行站域内的 POI，并确保每个采样到的 POI 在三个 KG 数据集（RTSKG、UUKG、HUSK）中都作为实例出现。随后抽出以这些 POI 为头实体、关系为 poi_has_poi_category 的三元组构成验证集和测试集（随机采 2,500 条，500 条验证、2,000 条测试），各数据集其余的关系三元组作为训练集。

KG	纽约 Hits@1	纽约 Hits@3	纽约 MRR	芝加哥 Hits@1	芝加哥 Hits@3	芝加哥 MRR
UUKG	0.698	0.775	0.757	0.264	0.533	0.455
HUSK	0.705	0.785	0.770	0.356	0.615	0.524
RTSKG	0.720	0.794	0.782	0.380	0.694	0.570

By performing the task of station-area store recommendation with RTSKG, we can more accurately identify the most suitable development directions for stores in station areas, which enables more efficient resource allocation and contributes to the economic development of the surrounding areas of the stations.

用 RTSKG 做站域门店推荐，能更准确地识别站域内门店最合适的发展方向，从而支持更高效的资源配置，促进站点周边地区的经济发展。

6. 任务二：知识增强客流预测

Ridership prediction is typically formulated as time series prediction, which aims to predict the station ridership on the next day based on the past station ridership sequence. Knowledge-enhanced ridership prediction aims to perform ridership prediction by incorporating the KG for knowledge enhancement.

客流预测通常被表述为时间序列预测：基于过去的客流序列预测下一天的站点客流。知识增强的客流预测则是在预测时纳入 KG 做知识增强。分两类：

Traditional Knowledge-Enhanced Ridership Prediction. Traditional knowledge-enhanced ridership prediction typically performs knowledge enhancement by using KG embeddings as external knowledge features and directly concatenating them with past ridership observations as the input of the model.

传统的知识增强客流预测通常把 KG 嵌入当作外部知识特征，直接和历史客流观测拼接起来作为模型输入。

LLM-based Knowledge-Enhanced Ridership Prediction. Specifically, we verbalized each time series instance into a natural language query, e.g., "From September 05 to September 16, 2025, the rail transit station 'Myrtle-Wyckoff Aves' located at the 'Bushwick North' functional area recorded the following ridership numbers: 18030 12496 ... 18461 on each day. What is the ridership going to be on September 17, 2025?". Meanwhile, we verbalized each KG relation triple into a natural language statement, e.g., "The rail transit station 'Myrtle-Wyckoff Aves' belongs to the rail transit line 'Canarsie'". We then encoded all the queries and verbalized relation triples as

embeddings with a pretrained language model, and computed similarity scores between the queries and relation triples by cosine similarities of their embeddings. For each query, we retrieved the top-n most relevant verbalized relation triples from the KG. Next, we used an LLM to summarize the retrieved relation triples into an abstract, which serves as external knowledge for the query. Finally, we concatenated the query with the abstract to form a prompt and fed it into another LLM to perform knowledge-enhanced ridership prediction.

基于 LLM 的知识增强客流预测：把每条时序实例**语言化**成一个自然语言问句，例如「从 2025 年 9 月 5 日到 9 月 16 日，位于 Bushwick North 功能区的轨交站点 Myrtle-Wyckoff Avs 每天记录的客流为：18030 12496 …… 18461。2025 年 9 月 17 日的客流会是多少？」同时把每条 KG 关系三元组语言化成陈述句，例如「轨交站点 Myrtle-Wyckoff Avs 属于轨交线路 Canarsie」。然后用预训练语言模型把所有问句和语言化后的三元组编码成嵌入，通过嵌入的余弦相似度计算问句与三元组之间的相似度分数。对每个问句，从 KG 中检索出 top-n 条最相关的语言化三元组（本文 n=50，编码器用 MiniLM）。**接着用一个 LLM 把检索到的三元组摘要成一段 abstract**，作为该问句的外部知识。最后把问句和这段 abstract 拼成 prompt，喂给另一个 LLM（GPT-4o）做预测。

客流数据来自美国政府开放数据，人工过滤掉可能含糊或错误的记录后，纽约 343,368 条、芝加哥 114,456 条，时间跨度 2023-01-01 至 2025-09-30。用过去 12 天预测下一天，训练/验证/测试按 7:1:2 划分，优化器 Adam、batch size 64。LLM 路线从测试集随机采 500 条评测。

对照设置。 We compared the models enhanced by RTSKG with the variants without knowledge enhancement (denoted as Vanilla). For traditional knowledge-enhanced ridership prediction, since neither existing KG contains rail transit stations, we applied their instances from commonly adopted class (i.e., Functional Area) for knowledge enhancement. For fair comparison, we additionally enhanced the model with instances in the class Station and the class Functional Area from RTSKG, denoted as w/RTSKG-S and w/RTSKG-F, respectively.

把 RTSKG 增强的模型与不做知识增强的版本（记作 Vanilla）对比。**由于两个现有 KG 都不含轨交站点，只能用它们共同采用的 Functional Area 类的实例做知识增强。为公平比较，我们额外用 RTSKG 中 Station 类和 Functional Area 类的实例分别做了增强**，记作 w/RTSKG-S 和 w/RTSKG-F。

The experimental results indicate that knowledge enhancement with instances in either the Station class or the Functional Area class from RTSKG consistently improves the performance of models on ridership prediction compared to the models without enhancement. Furthermore, the models enhanced with the instances in the class Station outperform those enhanced with the instances in the class Functional Area, suggesting that explicitly modeling stations in the KG can capture the mutual influence between the ridership of different stations. Additionally, the model enhanced with the instances in the class Functional Area from RTSKG achieves better performance compared with those enhanced by the instances in the class Functional Area from other KGs, as RTSKG models the interactions between different kinds of urban entities, allowing the embeddings of instances in the class Functional Area to implicitly include features from stations.

实验结果表明，用 RTSKG 的 Station 类或 Functional Area 类实例做知识增强，都能一致地改善模型在客流预测上的表现。此外，[用 Station 类增强的模型优于用 Functional Area 类增强的](#)，说明在 KG 中显式建模站点能够捕捉不同站点客流之间的相互影响。再者，[用 RTSKG 的 Functional Area 类增强的模型也优于用其他 KG 的同一类实例增强的](#)——因为 RTSKG 建模了不同类城市实体之间的交互，使 Functional Area 实例的嵌入[隐含地包含了站点的特征](#)。

(纽约 MAE 的代表性数字：STGCN 从 Vanilla 的 1490.229 降到 w/RTSKG-S 的 735.471；ASTGCN 从 101.066 降到 70.766；MSTGCN 从 208.735 降到 176.531；TGCN 从 3724.667 降到 3222.358；STPGCN 从 1100.163 降到 1007.729。芝加哥的降幅普遍小一些。)

Experimental results show that our RTSKG, as an external knowledge base for knowledge enhancement, achieves better performance than directly applying LLMs for ridership prediction and consistently outperforms leveraging other KGs. This demonstrates that RTSKG is a high-quality dataset for city-level rail transit station analysis, and it maintains effectiveness even in the rapidly evolving field of LLM applications. In the future, RTSKG can be used to support more LLM-based applications, such as city-level rail transit station related Q&A.

实验结果显示，RTSKG 作为知识增强的外部知识库，表现优于直接用 LLM 做客流预测，也一致优于使用其他 KG 做增强。这证明 RTSKG 是一个高质量的城市级轨交站点分析数据集，[即使在快速演进的 LLM 应用领域也保持有效](#)。未来 RTSKG 可以支撑更多基于 LLM 的应用，例如城市级轨交站点相关的问答。

7. 结论与资源可用性

In this paper, we propose RTSKG, a new rail transit station knowledge graph dataset, which is designed to explicitly model rail transit stations and the complex spatial and semantic interactions among different kinds of urban entities for city-level rail transit station related tasks. By providing a reusable dataset for city-level rail transit station related tasks, our study has potential applications not only in rail transit systems but also in other urban infrastructure systems.

本文提出 RTSKG，一个新的轨交站点知识图谱数据集，其设计目标是为城市级轨交站点任务显式建模轨交站点以及各类城市实体之间复杂的空间与语义交互。通过为这类任务提供一个[可复用的](#)数据集，本研究不仅在轨交系统、也在其他城市基础设施系统中有潜在应用。

All classes, relations and instances in RTSKG are identified by permanent dereferenceable URIs in w3id. All data are available as RDF dump files on Zenodo, and the basic information and source code of the RTSKG project can be accessed at GitHub. The data resources are released under the CC BY-SA 4.0 License, and the source code is released under the Apache License 2.0.

RTSKG 中所有的类、关系和实例都由 w3id 上的[永久可解引用 URI](#) 标识。全部数据以 RDF dump 文件形式发布在 Zenodo (记录号 21778005)，项目基本信息与源码在 GitHub ([seucoin/RTSKG](#))。数据资源采用 CC BY-SA 4.0 许可，源码采用 Apache License 2.0。

生成式 AI 使用声明。 During the preparation of this work, generative AI tools were used exclusively for providing ideas of creating illustrative figures. The authors reviewed and approved all figures and take full responsibility for the content of the publication.

在本工作的准备过程中，生成式 AI 工具仅被用于提供绘制示意图的思路。作者审阅并批准了所有图，并对本出版物的内容负全部责任。

参考链接

- <https://w3id.org/rtskg/> — RTSKG 的 Linked Data 入口，所有类和实例的 URI 都在这个永久标识命名空间下且可解引用
- <https://w3id.org/rtskg/ontology> — RTSKG 本体的完整定义（论文正文只列了 10 个类和 19 个关系，属性部分在这里）
- <https://github.com/seucoin/RTSKG> — 源码仓库，**competency questions 的完整清单和 LLM 的 prompt 都在这里，正文没列**
- <https://zenodo.org/records/21778005> — RDF dump 文件，带 DOI，包含论文表 1 之外的标准词汇三元组
- <https://data.ny.gov/> — 纽约州开放数据门户，轨交站点、线路、出入口的来源
- <https://data.cityofchicago.org/> — 芝加哥数据门户，芝加哥侧的对应数据源
- <https://opendata.cityofnewyork.us/> — NYC OpenData，行政区划、路段、路基的来源
- <https://www.openstreetmap.org/> — OpenStreetMap，芝加哥站点出入口的来源
- <https://www.mapbox.com/> — Mapbox，其 Isochrone API 用来生成「N 分钟步行可达」的等时圈，是站域这个类的算法来源
- <https://data.gov/> — 美国政府开放数据，日客流记录的来源