

用三个 agent 把百万商品分成价格线与价格梯 Lines and Ladders: A Context-Aware Multi-Agent Framework for Large-Scale Retail Price Taxonomy

源文档：Ravi Teja Chunduri 等六人，[沃尔玛全球技术部](#)（Walmart Global Tech，本顿维尔 / 桑尼维尔 / 西雅图）。arXiv 2608.12674v1，2026-08-13 提交。这是一篇生产系统论文：已在沃尔玛线上部署，处理数万活跃商品，并给出了上线 13 周后的业务指标。本文的「全文翻译」一节按原文小节推进，覆盖摘要、§1 引言、§3 方法（问题定义、双路属性发现、综合 agent、多模态抽取、标准化、分组逻辑、人在环）、§4 规模化部署、§5 实验评估（架构消融、人工评测、对照评测、上线影响）、§6 局限与未来工作。§2 相关工作中的零售定价经济学文献、图 1 - 8 的版式细节、参考文献条目不译。

核心内容

Q: 「价格线」和「价格梯」是什么？ A: 这是零售定价的两级结构，论文给了严格定义。**线 (Line)** 是一组功能等价、必须同价的商品——比如同一款蜡烛只是香型或颜色不同，形式化写作「同属一条线 $\Rightarrow$ 价格相同」。 **梯 (Ladder)** 是若干条线按用量串起来的阶梯——包装越大，单价越低，形式化写作「用量更大 $\Rightarrow$ 单位价格更低」。一条梯就是它所含各条线的并集。

Q: 为什么这件事非做不可？ A: 沃尔玛执行「天天低价」策略，而目录有数百万活跃商品。同一款商品的不同变体价格不一致，会扭曲顾客的价值感知，并且互相蚕食销量。传统上这套结构靠人工维护，在百万级目录上不可行。

Q: 三个 agent 各干什么？为什么非要三个？ A: 核心洞见是把「相似」和「差异」拆成两个方向相反的发现任务：

- Agent 1 找相似属性**——那些定义了「同价即功能等价」的特征。采样方式是**按密度**：取最频繁的 K 个（品牌，厂商建议零售价）组合，每组抽 15 条商品描述，于是每个语料就是一簇**同价商品**，从中提取它们共有的核心属性（蜡烛的例子：净重盎司、高度英寸、燃烧小时数）。
- Agent 2 找差异属性**——那些**证成价格分层**的高端特征。采样方式是**分层**：取前 5 个高频品牌 $\times$ 每个品牌前 5 个价格点 = 最多 25 组，每组抽 5 件，然后**对比低价组与高价组**找差异特征（灯芯数量、蜡的种类、是否带装饰容器）。
- Agent 3 综合**——前两个 agent 的输出**语义上会重叠**，它做三件事：合并同义词（把「watts」并到「motor power」，「flavor」和「taste」合并）、过滤掉全局属性（品牌、颜色）和空泛词（「features」「style」）、以及**把数值与单位拆开**（每个数量属性生成一个配套的单位字段）。

为什么必须三个：消融实验很干净——单 agent 同时干相似和差异两件事会**认知过载**，线的 F1 只有 0.64；两个 agent 升到 0.77；**加上综合 agent 才到 0.83**，跨过生产所需的 80% 线。

Q：有哪个设计决定是反直觉的？ A：有两个，都值得单独记。

第一，不给 agent 看历史分类。 这两个属性发现 agent **刻意不使用任何历史分类法的少样本示例**。理由是：**既有的商家结构常常反映的是临时性的运营策略**（比如「把同一个供应商的商品归成一组」）**而不是严格的属性等价**，把它们注入提示词会引入**策略噪声**、干扰算法化的属性抽取。

第二，给的数据越多，效果越差。 参数调优表明这是一条真实的帕累托前沿：

配置（组数/每组件数）	50/15	80/15	50/30	80/30	本文采用
线 F1	0.77	0.75	0.78	0.77	0.83
梯 F1	0.80	0.76	0.78	0.75	0.82

本文采用的是 Agent 1 用 30 组 / 每组 15 件，Agent 2 用 25 组 / 每组 5 件。**扩大广度**（80 组）会引入长尾目录噪声和小众品牌，扰乱 schema 生成；**扩大深度**（每组 30 件）会导致上下文膨胀，让模型**基于细微无关的差异幻想出差异属性**。而且 80/30 那档的流水线平均耗时涨到 155 分钟，本文配置只要约 65 分钟。

Q：效果到底怎么样？ A：分两套评测。**对照商家既有结构**（食品与消耗品，14 个品类）：线的精确率 **98%**、召回 **75%**；梯的精确率 **92%**、召回 **81%**。**人工审核**（通用商品，11 个品类、1000 件随机抽样，由领域专家评）：加权平均分配准确率 **80.0%**。

Q：召回只有 75%，为什么作者说这是好事？ A：**这是刻意设的护栏**。高召回的分组意味着**把价格变更施加到不相关的商品上**——论文举的例子是：某个高召回做法会把 11 种不同的「Prego 酱料」错误地归成一组，而本系统保守地只把 4 种完全相同的 Alfredo 酱归在一起。

召回缺口的**成因也很清楚**：商家常常按**促销策略或宽泛的「风味家族」过度归组**，而**算法严格按物理属性分组**，于是自然会把商家的大组拆开。所以高标准化的品类（除臭剂 F1=1.00）完全对齐，而依赖主观营销描述品类（猫粮 F1=0.64，要区分「海洋白鱼酱」和「酱汁金枪鱼片」）就差得多。

背景补充 / 点评

这篇里有一句话值得抄下来当验收标准：在多数失败案例里，**分组逻辑方向是对的，只是漏掉了单独一个区分性属性**。作者据此说：**这个系统不会幻想出随机的分组，它只是离完美对齐差一个特征**。这是一种非常有用的错误刻画方式——它把「错得离谱」和「差一点」分开了，而这两者对是否敢上线的意义完全不同。

人在环的反馈是按错误类别路由的，这一点比「收集反馈」这个笼统说法有用得多。商家在界面上的修正会发到消息总线，一个**反馈分类器**按类别分派：

错误类别	路由到哪
缺属性	触发 agent 优化

错误类别 路由到哪

抽取错误 更新抽取器提示词

标准化错误 更新 SQL 缓存

策略决定 更新持久记忆 Pcontext

四类错误各有各的修复位点，混成一个「反馈池」就会全都改不动。

规模数字：约 1700 个 ProductType（约 100 万件商品）在 10 个工作节点上 30 分钟跑完，每件约 4K token。**模型是分层路由的**——推理重的任务（schema 生成、冲突消解）走前沿大模型（作者因企业保密不能公开具体型号，只说规模可比于 >100B 参数的指令微调「思考型」模型），而**海量的属性抽取走 7B - 13B 的视觉语言模型**。全部 agent 温度设为 0。

上线影响：为超过 90% 此前完全无人管理的目录首次生成了结构化的线与梯；13 周的端到端遥测显示现有工作流的**任务耗时下降 86.1%**。这个数字的算法作者也写明了：自动抽取把人工目录清理减少 35 - 40%（剩余工作量约 0.625），自动分组加界面复核比手工创建快 4 - 5 倍（剩余时间约 0.222）， $0.625 \times 0.222 = 0.138$ ，即只需原来 13.9% 的工时。**把复合口径写出来，比只报一个 86.1% 诚实得多。**

我的判断——洞察在哪：最有价值的是**把一个分类任务拆成两个方向相反的发现任务**这个动作。「什么使得两件东西同价」和「什么使得两件东西不同价」听起来是一个问题的正反面，但它们的**采样方式完全不同**——前者要按密度取同价簇（看共性），后者要按价格分层取跨价组（看差异）。用一个 agent 同时干这两件事，采样策略就只能二选一，这才是「认知过载」的实质。**F1 从 0.64 到 0.77 那一跳，跳的其实是采样策略而不是提示词。**

留白在哪：三处，作者自己认了两处。第一，**他们主张传统的稠密向量聚类不适合这个任务**（理由是向量聚类靠的是语义语言相似性，而定价分类要的是严格的物理属性等价和多模态业务上下文）——**但这只是论证，没有做实证对比**，作者把「与非 LLM 基线的实证基准测试」列为未来工作。这是全文最大的空洞：整套多 agent 架构相对一个调好的聚类基线到底值多少，没有数字。第二，**温度设为 0 仍然无法严格复现**，LLM 的非确定性使可复现性成问题。第三，**依赖特定 LLM 家族**，模型一更新就要重新验证以防幻觉风险。

另外有一处作者没提但我认为是隐患：**对照评测用的「商家既有结构」本身就是他们说的那种「反映临时运营策略而非属性等价」的东西**。他们一边在方法里说不能拿历史结构训练（有策略噪声），一边又拿它当评测基准（虽然注明是「方向性基准」并预处理去掉了统计离群值）。**召回 75% 里有多少是算法错、多少是基准本身不严格，这两者在这个设计下分不开。**

对我的启示：这篇和我正在 user_profile 上做的**受控词表**是同一类问题，而且有几处可以直接搬。

第一，「判重用哪几列」和「分类用哪几列」应该是两套。论文里线和梯的生成逻辑差别只有一处：线按**全部属性**（类别属性 U 数值属性）分组，梯**放松约束、排除数值属性**，只按类别属性分组。这正好对应我们 8/27 敲定的那条——**field 作为类别保留，但判重是跨分类的**。论文给的是同一个形状另一个实例：**同一批属性，按不同子集分组，得到不同粒度的结构。**

第二，数值与单位必须拆成两列。论文的「属性—单位解耦」是为每个数量属性生成一个配套的单位字段（oz 与 g 的问题），然后做归一化到基准单位，并且**留 5% 的数值容差**防止「12.0 盎司」和「12.3 盎司」

被人为拆成两条。我们 spec 里的取值域 (scale) 讨论一直没落到这个具体层面——「取值域」到底是装单位、装范围、还是装体系名，论文这里给了一个可操作的答案：至少单位得单列。

第三，也是最该记的一条——不要把 PM 现有的分类当成训练信号。 论文明确说：既有商家结构反映的是临时运营策略而非严格属性等价，把它注入提示词会引入策略噪声。这跟我们遇到的 PM 把「岗位」和「职级」合成一件事是完全同构的情形。当时的结论是「按她的口径只留一个值是对的，但要写明这是 PM 的合并」——论文给了更进一步的做法：在抽取阶段刻意不看历史结构，把 PM 的口径留到人在环那一层去纠正，而不是让它污染属性发现本身。

第四，剪枝阈值可以直接借。 论文的启发式是：空值率 >65% 或基数 >70% 的属性直接丢掉，因为保留更稀疏的特征「持续造成产品线的人为碎片化」。我们的五个类别现在没有任何这类闸门。

第五，高精确率 / 低召回可以有意的。 这条对我做股票统计也成立。论文说得很直白：高召回的分组会把价格变更施加到不相关商品上，所以宁可漏、不可错。我一直在做的「宁可说不确定也不给方向判断」是同一个取舍，只是我没把它明确表述成一个可以写进验收标准的护栏。

文中金句

"Because legacy merchant structures often reflect ad-hoc operational strategies (e.g., grouping all items from a single supplier) rather than strict attribute equivalence, injecting them into the prompts would introduce strategic noise and confuse the algorithmic extraction." 由于既有的商家结构常常反映的是临时性的运营策略（例如把同一供应商的全部商品归成一组），而不是严格的属性等价，把它们注入提示词会引入策略噪声，干扰算法化的抽取。

"As shown in Table I, providing more data to the LLM degrades performance." 如表一所示，给大模型更多数据反而会降低表现。

"This high-precision/low-recall profile is an intentional guardrail. High-recall groupings risk applying price changes to unrelated items." 这种高精确率、低召回的形态是一道刻意设置的护栏。高召回的分组有把价格变更施加到不相关商品上的风险。

"In most failure cases, the grouping logic was directionally correct but missed a single differentiating attribute. This indicates the system does not hallucinate random groups, but rather is just one feature away from perfect alignment." 在多数失败案例里，分组逻辑的方向是对的，只是漏掉了单独一个区分性属性。这说明系统并不会幻想出随机的分组，它只是离完美对齐差一个特征。

"This divergence highlights a fundamental divergence between algorithmic strictness and human strategic intent." 这种分歧凸显了**算法的严格性与人的策略意图之间的根本差异**。

全文翻译

覆盖范围：摘要、§ 1 引言、§ 3.1 问题定义与范围、§ 3.2 双路属性发现、§ 3.3 综合 agent、§ 3.4 多模态属性抽取、§ 3.5 数据标准化、§ 3.6 自适应分类构建、§ 3.7 人在环、§ 4 规模化部署、§ 5.1 - 5.4 实验评估、§ 6 局限与未来工作。§ 2 相关工作中的定价经济学文献综述、图 1 - 8 的版式细节、参考文献条目不译。

摘要 Abstract

Maintaining price consistency and executing an Every Day Low Price strategy is critical for global retailers. However, with catalogs spanning millions of active items, manual governance of price relationships is infeasible. Inconsistent pricing across item variants distorts customer value perception and cannibalizes sales.

对全球零售商而言，**维持价格一致性、执行「天天低价」策略是关键**。然而，当目录横跨数百万活跃商品时，**人工治理价格关系是不可行的**。商品变体之间定价不一致会扭曲顾客的价值感知，并蚕食销量。

To address this, we present a scalable, context-aware Multi-Agent Framework designed to automate the construction of "Lines and Ladders" pricing taxonomies. Our framework employs specialized LLM agents to construct these coherent pricing structures by identifying key attributes, extracting multi-modal values, and applying hierarchical grouping logic.

为此我们提出一个**可扩展的、上下文感知的多 agent 框架**，用于自动构建「线与梯」定价分类法。框架使用专门化的大模型 agent，通过**识别关键属性、抽取多模态取值、施加层级分组逻辑**来构建这些连贯的定价结构。

Evaluated on real-world enterprise data and deployed in production, our 3-Agent system achieves an F1-score of 0.83 for Lines, outperforming single-agent baselines by mitigating cognitive overload. The system achieves > 90% precision and > 75% recall in Food & Consumables, and 80.2% assignment accuracy in the unstructured General Merchandise catalog.

在真实企业数据上评测并已投入生产部署，我们的**三 agent 系统在「线」上取得 0.83 的 F1**，通过缓解认知过载而超过单 agent 基线。系统在食品与消耗品上达到 **>90% 精确率、>75% 召回**，在非结构化的通用商品目录上达到 **80.2% 的分配准确率**。

引言：策略上的「为什么」已有文献，运营上的「怎么做」没有 Introduction

Retail pricing directly dictates the core profitability of a retailer. To maintain consistency, retailers structure products into "lines and ladders" — a logical hierarchy grouping items by features, quality, and business context.

零售定价直接决定零售商的核心盈利能力。为维持一致性，零售商把商品组织成「线与梯」——一种**按特征、品质和业务上下文分组的逻辑层级**。

To address this scalability challenge, we propose a context-aware multi-agent framework. Unlike traditional rule-based systems, our approach leverages specialized agents to automatically cluster products into meaningful "Lines & Ladders". This system automates the identification and extraction of key attributes, customized for each ProductType. We utilize this architecture to simulate and replicate the decision-making logic of a human expert at scale.

为应对这个可扩展性挑战，我们提出一个上下文感知的多 agent 框架。**与传统的基于规则的系统不同**，我们的方法利用专门化的 agent 自动把商品聚成有意义的「线与梯」。该系统自动完成关键属性的识别与抽取，并为**每一个 ProductType（商品类型）定制**。我们用这套架构在规模上**模拟并复现人类专家的决策逻辑**。

Although these concepts explain the strategic "why", they fail to address the operational "how" for massive, unstructured datasets. Pre-LLM approaches relied on structured tabular data and extensive feature engineering, a workflow rendered impractical by the heterogeneity of modern retail catalogs. The manual effort required to standardize attributes across millions of items is practically impossible.

尽管这些（经济学）概念解释了策略上的「**为什么**」，它们**没有回答面对海量非结构化数据集时运营上的「怎么做」**。大模型之前的方法依赖结构化表格数据和大量特征工程，而现代零售目录的异质性使这套流程变得不切实际。**在数百万件商品上标准化属性所需的人力，实际上是不可能的**。

方法一：问题定义与范围 Problem Formulation & Scoping

Let $C = \{i_1, \dots, i_N\}$ be a catalog of N items, each with raw metadata R_i (title, description, image). We map each item to a Line (L_k): a subset of items sharing functional equivalence (e.g., identical items differing only in flavor or color), where $\forall i_a, i_b \in L_k \Rightarrow \text{Price}(i_a) = \text{Price}(i_b)$. Lines aggregate into a Ladder (M_j): a collection of Lines linked by value-based differentiation (e.g., volume, pack size), enforcing a tiered pricing logic where $\text{Volume}(L_a) > \text{Volume}(L_b) \Rightarrow \text{UnitPrice}(L_a) < \text{UnitPrice}(L_b)$.

设 C 是一个含 N 件商品的目录，每件带有原始元数据 R_i （标题、描述、图片）。我们把每件商品映射到一条**线** L_k ：**共享功能等价性**的商品子集（例如仅在香型或颜色上不同的相同商品），满足「同属一条线 $\Rightarrow$ 价格相同」。线聚合成**梯** M_j ：由**基于价值的差异化**（如容量、包装数量）串联起来的一组线，执行分层定价逻辑「用量更大 $\Rightarrow$ 单位价格更低」。

We use ProductType (e.g., "Candles") as our granular anchor. Scoping the analysis to items with shared structural characteristics ensures the extracted attributes are highly relevant, allowing the framework to generate precise, tailored taxonomies rather than relying on generic, one-size-fits-all rules.

我们用 **ProductType** (商品类型, 例如「蜡烛」) 作为细粒度锚点。把分析范围限定在具有共同结构特征的商品上, 确保抽取出的属性高度相关, 使框架能生成**精确的、量身定制的分类法**, 而不是依赖通用的一刀切规则。

方法二: 双路属性发现 Dual-Pronged Attribute Discovery

Constructing effective taxonomies requires distinguishing between Similarity Attributes (features defining functional equivalence at the same price point) and Variance Attributes (features driving price differentiation). We achieve this using two specialized LLM agents. To ensure the generated taxonomy is strictly based on physical attributes, these agents operate without few-shot examples of historical taxonomies.

构建有效的分类法需要区分**相似属性** (在同一价格点上定义功能等价性的特征) 与 **差异属性** (驱动价格差异化的特征)。我们用两个专门化的大模型 agent 来做这件事。**为确保生成的分类法严格基于物理属性**, 这两个 agent 在运行时不使用任何历史分类法的少样本示例。

Because legacy merchant structures often reflect ad-hoc operational strategies (e.g., grouping all items from a single supplier) rather than strict attribute equivalence, injecting them into the prompts would introduce strategic noise and confuse the algorithmic extraction.

因为既有的商家结构常常反映的是临时性的运营策略 (例如把同一供应商的全部商品归成一组) **而不是严格的属性等价**, 把它们注入提示词会引入**策略噪声**, 干扰算法化的抽取。

Agent 1 (相似属性) 的采样与约束:

- **按密度采样**: 从该 ProductType 的数据中, 找出最频繁的 K 个 (品牌, 厂商建议零售价 MSRP) 组合。严格使用**基准 MSRP** 以避免促销噪声。
- **语料生成**: 每个组合抽 15 条商品描述, 得到 K 个语料, 各自代表一簇**同价商品**。
- **迭代抽取**: Agent 1 处理每个语料以提取一致的核心属性, 并利用一份**持久记忆**迭代优化自己的逻辑。对「蜡烛」这个类型, 输出可能是 {净重盎司, 高度英寸, 燃烧小时数}。

它的提示词约束有四条: **只要可量化的** (拒绝类别型特征, 聚焦可测规格); **一致性** (属性取值在组内必须不变); **证据分级** (第 1 层「文本明说」→接受, 第 2 层「可逻辑推得」→接受, 第 3 层「推测性、无证据」→拒绝); **标准化** (强制输出 schema, 并复用持久记忆中的名称)。

Agent 2 (差异属性) 的采样与约束:

- **分层采样**：取该类型下前 5 个高频品牌，每个品牌取其前 5 个高频 MSRP 价格点，构成最多 25 组的分层集合。**经验试验表明，品牌数超过 5 会引入过多的命名差异，淹没 ProductType 的核心信号。**
- **语料生成**：每组抽 5 件。**与 Agent 1 不同，Agent 2 把整个分层数据集作为单一输入摄入，以便分析一个横跨品质与价格的宽光谱。**
- **对比分析**：Agent 2 对比低价组与高价组以识别差异化特征（如 {灯芯数量, 蜡的种类, 是否带装饰容器}）。它同样配有记忆模块，可根据具体业务要求吸收反馈、优化属性。

它的提示词让 agent **扮演定价策略师**，并要求做**类型分类**：**第 1 类（差异化的）**——组内一致、跨价格层变化（主要）；**第 2 类（基础的）**——无论是否影响价格都属必要规格。

参数选择：Agent 1 用 30 组/15 件、Agent 2 用 25 组/5 件，这些常数是通过参数调优得到的，**优化的是「信噪比与大模型 token 成本」之间的帕累托前沿。**

表 1：样本量的影响（组数 / 每组件数，14 个品类的均值）

指标	50/15	80/15	50/30	80/30	本文采用*
线 (F1)	0.77	0.75	0.78	0.77	0.83
梯 (F1)	0.80	0.76	0.78	0.75	0.82

*Agent 1 用 30 组/15 件，Agent 2 用 25 组/5 件。

As shown in Table I, providing more data to the LLM degrades performance. Expanding sample breadth (e.g., 80 groups) introduces long-tail catalog noise and niche brands that confuse schema generation. Expanding depth (e.g., 30 items) causes context bloat, leading the LLM to hallucinate variance attributes based on minor, irrelevant differences. Furthermore, average pipeline runtimes were scaled up to 155 minutes for the 80/30 configuration, compared to ~65 minutes for our proposed thresholds.

如表 1 所示，**给大模型更多数据反而会降低表现。** 扩大样本**广度**（如 80 组）会引入长尾目录噪声与小众品牌，扰乱 schema 生成。扩大**深度**（如每组 30 件）会导致上下文膨胀，**使大模型基于细微、无关的差异幻想出差异属性。**此外，80/30 那档配置的流水线平均耗时涨到 **155 分钟**，而本文采用的阈值约 **65 分钟**。

方法三：综合 agent Synthesis Agent

The similarity and variance agents yield distinct attribute sets, A_sim and A_var, which often exhibit semantic overlap. To resolve these dualities, a Synthesis Agent performs a mapping function Φ to produce a canonical schema S_pt.

相似 agent 与差异 agent 产出两组不同的属性集合，二者**常有语义重叠**。为消解这种二重性，**综合 agent** 执行一个映射函数 Φ ，产出一份**规范 schema**。它保证 schema 完整性的三个顺序操作是：

- **属性合并与语义消解**：聚合前两个 agent 的原始输出，**消除冗余、解决同义**（例如合并「flavor」与「taste」）、强制标准化命名约定。合并同义词时**以相似性 agent 的输出为优先**。

- **过滤**：移除全局属性（品牌、颜色）与空泛词（如「features」「style」）。
- **属性—单位解耦**：为解决计量单位不一致（如盎司 vs 克）并支持可比分析，框架**显式地把数值与单位拆开**，为每一个数量属性定义一个标量取值字段和一个单位字段。这产出一份精简、高保真的 schema 蓝图供下游抽取使用。

最终 schema 中每个属性形式化为一个四元组<名称, 数据类型, 默认值, 提示词>。论文给的「蜡烛」示例：

属性名：wax_type 类型：String 默认值：paraffin

提示词：从图片或描述中识别蜡烛所用蜡的类型（如大豆蜡、石蜡、蜂蜡、椰子蜡）。

属性名：is_decorative 类型：Boolean 默认值：False

提示词：若蜡烛带有特定艺术图案、主题或雕塑造型，标为 True。

方法四：多模态抽取，抽取器本身就是清洗引擎 Multi-Modal Attribute Extraction

This multi-modal capability is critical for retail catalogs, where key specifications (e.g., "4-pack" or "organic") often appear only on packaging images. Unlike traditional methods requiring thousands of specific NER models, this approach utilizes a single generalized agent to extract arbitrary attributes defined by the dynamic schema, resolving the scalability bottleneck.

多模态能力对零售目录是关键——**关键规格（如「4 件装」或「有机」）常常只出现在包装图片上**。与需要成千上万个专用命名实体识别模型的传统方法不同，这个做法**用单一的通用 agent 抽取由动态 schema 定义的任意属性**，解决了可扩展性瓶颈。

Because traditional pre-sanitization (e.g., regex) fails on missing or unstructured catalog data, this Multi-Modal Extractor acts as the sanitization engine itself. Initial experiments with smaller open-weight models (e.g., Nemotron VLM 2B/8B/12B) failed to achieve production accuracy without large-scale labeled data tailored to our complex schema, necessitating our reliance on frontier models.

由于传统的预清洗手段（如正则）在缺失或非结构化的目录数据上会失效，**这个多模态抽取器本身就充当了清洗引擎**。用较小的开源权重模型（如 Nemotron VLM 2B/8B/12B）做的初期实验，在没有针对我们复杂 schema 的大规模标注数据的情况下**达不到生产精度**，这迫使我们依赖前沿模型。

方法五：标准化——防止人为碎片化 Data Standardization

Raw extraction yields structured data, but inconsistencies impede grouping.

原始抽取产出的是结构化数据，但**不一致会阻碍分组**。后处理流水线做四件事：

- **数值标准化（单位）**：把原始取值与单位转换到标准基准单位，例如 (12, 磅) → 192 (盎司)。**强制施加 5% 的数值容差**以吸收单位换算中的浮点误差，**防止相同商品被人为拆开**。

- **类别语义聚类**：为解决语义碎片化（如「Soy」与「Soy Blend」），用一个大模型聚类函数把原始取值映射到规范术语，**防止人为碎片化**。
- **品牌归一化**：用一个混合函数把抽取出的品牌与目录主数据的品牌调和，基于 **Jaccard 相似度与品牌频次** 设一道安全栏——当抽取出的品牌与一个已确立的实体**完全不相交**（Jaccard = 0）**且**该内部品牌在目录中的频次 ≥ 5 时，采信内部记录系统的品牌，**防止幻觉性覆盖**。

方法六：分组逻辑——线与梯只差一个属性子集 Adaptive Taxonomy Construction

Grouping is scoped at the brand level to respect attribute applicability, as brands within a ProductType often employ distinct conventions (e.g., weight vs. burn time).

分组**在品牌层级上做范围限定**，以尊重属性的适用性——因为同一 ProductType 内不同品牌常采用不同的约定（有的标净重、有的标燃烧时长）。

剪枝启发式：Through iterative deployment and experimentation across diverse catalog samples, we established operational heuristics to drop attributes with $> 65\%$ nullity or $> 70\%$ cardinality; retaining sparser features consistently caused artificial fragmentation of product lines.

通过在多样化目录样本上的迭代部署与实验，我们确立了运营启发式：**丢弃空值率 $> 65\%$ 或基数 $> 70\%$ 的属性**；保留更稀疏的特征会持续造成产品线的人为碎片化。保留下来的属性中的空缺用 schema 默认值填补。

数值分箱：应用 ϵ 邻域聚类，按严格的业务要求，**5% 容差内的取值**（如 12.0 盎司与 12.3 盎司）归入同一个离散值。

分层分组逻辑（这是全文最简洁的一处设计）：

- **生成线**：按**完整属性集合**（类别属性 $\cup$ 数值属性）分组，每个唯一组合构成一条线，并分配一个持久 UUID。
- **生成梯**：**放松约束，排除数值属性**，只按类别属性分组，从而把线聚成梯，串起那些**仅在尺寸或包装数量上不同的商品**。

因此一条梯被定义为它所含各条线的并集。这套逻辑自动地组织目录：把功能等价的商品放进线，再用基于用量的梯把它们连起来。

方法七：人在环 Human-in-the-Loop

While the multi-agent framework provides a robust baseline, the inherent stochasticity of LLMs and the specificity of business strategy (e.g., pricing soft drinks at the parent brand level) necessitate human intervention.

尽管多 agent 框架提供了一个稳健的基线，**大模型固有的随机性与业务策略的特殊性**（例如软饮料按母品牌层级定价）**使人工介入成为必需**。商家的修正被捕获为高质量的标注信号，更新一份 ProductType 特定的上

下文记忆 Pcontext:

- **策略对齐**: Agent 1 与 Agent 2 将学会根据商家偏好优先或忽略某些属性。
- **Schema 优化**: Agent 3 将更新其合并逻辑, 以尊重业务特定的命名约定并优化抽取提示词。

As Pcontext accumulates, agents recall these corrections to ensure subsequent runs align with established business logic, allowing the system to progressively evolve into a domain-adapted expert. While this HITL architecture successfully captures immediate strategic intent, quantifying the system's long-term convergence toward expert-level behavior remains an ongoing area of empirical validation.

随着 Pcontext 积累, agent 会回忆这些修正以确保后续运行与既定业务逻辑对齐, **使系统逐步演化成一个领域适配的专家**。虽然这套人在环架构成功捕获了即时的策略意图, **但量化该系统向专家级行为的长期收敛, 仍是一个正在进行中的实实验证课题**。

(作者在这里没有把话说满——「会逐步变成专家」是设想, 「有没有真的收敛」他们承认还没测出来。)

规模化部署 Deployment at Scale

Decomposing the pipeline by Department → ProductType enables independent failure domains.

把流水线按「部门 → 商品类型」分解, 形成互相独立的故障域。编排器支持两种执行模式: **全量刷新** (重算属性 schema) 与 **增量刷新** (复用已持久化的 schema 做稳态更新)。

多模型路由策略 (在推理能力与成本之间平衡):

- **多 agent 属性识别器**: 协调三个 agent。**推理重的任务 (schema 生成、冲突消解)** 路由到企业托管的**前沿大模型** (规模与能力可比于 >100B 参数的指令微调「思考型」模型)。一个低延迟关系数据库实现持久记忆, 用确定性 SQL 查询把历史商家规则取出并注入提示词。**为防止上下文溢出, 注入的历史被严格截断到上次全量刷新之后收集的反馈**。因企业保密不能披露确切的商用模型名称, 但所有 agent **温度严格设为 0** 以最大化确定性。
- **多模态属性抽取器**: 为处理数百万件商品, 抽取路由到同家族中一个**高效、成本优化的多模态模型** (规模可比于 7B - 13B 参数的视觉语言模型), 面向高吞吐、低延迟执行。
- **属性清洗与标准化器**: 一个**基于 SQL 的语义缓存**存储同义词映射 (「Soy」→ 「Soy Wax」), 以优化延迟并减少增量刷新期间的冗余大模型调用。

异步反馈回路: 商家界面上的修正向分布式消息总线发出事件, 一个**智能反馈分类器**按错误类别路由——**缺属性**触发 agent 优化; **抽取错误**更新抽取器提示词; **标准化错误**更新 SQL 缓存; **策略决定**更新记忆 Pcontext。

性能: 约 1700 个 ProductType (约 100 万件商品) 在 **10 个工作节点上 30 分钟**处理完。吞吐随工作节点线性扩展 (在可用的大模型配额内)。**大模型推理主导开销 (约每件 4K token)**, 微批处理与识别阶段的采样带来显著的成本下降。结构化日志支持部分重跑与 ProductType 级别的回归分析。

实验一：架构消融——三个 agent 是必需的 Architecture Ablation

作者特意说明：评测的是零样本的大模型架构，而不是传统的有监督命名实体识别模型（如微调过的 BERT）。理由是零售目录需要动态 schema 生成（蜡烛要抽「蜡的种类」，搅拌机要抽「电机功率」），因此为成千上万个不断演化的 ProductType 训练并维护静态模型，在企业规模上运营不可行。

表 2：不同 agent 架构的对比（部分品类）

ProductType	线 F1 (1 agent)	(2 agent)	(3 agent)	梯 F1 (1 agent)	(2 agent)	(3 agent)
除臭剂与止汗剂	0.63	0.90	1.00	0.63	0.90	1.00
预制包装汤品	0.60	0.92	0.96	0.60	0.79	0.92
果汁	0.66	0.69	0.90	0.69	0.69	0.92
冰淇淋棒/甜筒	0.50	0.70	0.88	0.73	0.70	0.95
非处方药	0.70	0.75	0.87	0.72	0.70	0.75
卫生纸	0.54	0.52	0.79	0.67	0.31	0.76
猫粮	0.53	0.74	0.64	0.55	0.61	0.66
14 个品类平均	0.64	0.77	0.83	0.69	0.70	0.82

A single LLM tasked with simultaneous similarity and variance discovery suffers severe cognitive overload (0.64 Lines F1). While a 2-Agent system improves performance (0.77 F1), utilizing a Synthesis Agent to resolve semantic overlaps was strictly necessary to achieve the > 80% accuracy required for production.

一个同时承担相似发现与差异发现的大模型会遭受严重的认知过载（线 F1 仅 0.64）。两 agent 系统把表现提升到 0.77，而用一个综合 agent 来消解语义重叠，是达到生产所需 >80% 精度的严格必要条件。

（表里有反例值得注意：猫粮和可冲洗清洁湿巾在三 agent 下反而低于两 agent。作者没有单独讨论这几个格子。）

实验二：人工审核 Quantitative Manual Evaluation

To measure "Assignment Accuracy" (the percentage of items correctly grouped without requiring manual edits) in unstructured General Merchandise, domain experts evaluated 1000 randomly sampled items across 11 diverse ProductTypes. Because evaluating placement requires reviewing multi-modal data and historical pricing strategies, this represents tens of hours of specialized annotation.

为衡量非结构化通用商品目录上的「分配准确率」（无需人工编辑即被正确分组的商品百分比），领域专家评测了横跨 11 个不同 ProductType 的 1000 件随机抽样商品。由于评估归位需要审阅多模态数据与历史定价策略，这代表数十小时的专业标注工作。

表 3：人工审核结果

ProductType	样本量	准确率
豆袋沙发	100	100%
化妆镜	38	100%
空调	100	88%
电涌保护器	100	86%
加湿器	100	84%
肥料	100	82%
缝纫机	100	80%
吊扇	100	72%
台灯	100	69%
办公白板	62	68%
旅行袋	100	61%
加权平均	1000	80%

三类错误：技术粒度——偶尔漏掉具体的技术变体，如加湿器的「超声波」与「蒸发式」、吊扇的「延长杆」与「贴顶式」、肥料的「除草型」与「施肥型」。**审美与主观细微差别**——台灯或旅行袋的差异化常依赖无形品质（如「轮廓的优雅」或「材质档次」），**需要默会的领域知识**，凸显了人在环中商家直觉的必要性。**数据完整性与复杂度**——缝纫机的错误与描述稀疏相关，办公白板则受困于复杂的捆绑组合（白板 + 马克笔），印证了性能上界受目录数据质量约束。

Synthesizing these observations, in most failure cases, the grouping logic was directionally correct but missed a single differentiating attribute. This indicates the system does not hallucinate random groups, but rather is just one feature away from perfect alignment.

综合这些观察：**在多数失败案例里，分组逻辑的方向是对的，只是漏掉了单独一个区分性属性。这说明系统并不会幻想出随机的分组，而只是离完美对齐差一个特征。**

实验三：对照商家既有结构 Comparative Evaluation

In Food & Consumables, we utilized merchant-generated pricing structures across 14 ProductTypes as a directional benchmark, noting that merchants often construct lines based on ad-hoc strategies rather than strict attribute equivalence. We pre-processed reference data to remove statistical outliers.

在食品与消耗品上，我们把商家生成的定价结构（14 个 ProductType）用作**方向性基准**，同时注明**商家常常基于临时策略而非严格属性等价来构建线**。我们对参考数据做了预处理以去除统计离群值。

Because our algorithm generates novel UUIDs, direct mapping to legacy IDs is infeasible. We utilized a maximum F1 score optimization approach (similar to bipartite matching) to align generated lines with merchant lines.

由于我们的算法生成全新的 UUID，**直接映射到既有 ID 是不可行的**。我们使用**最大 F1 优化方法**（类似二部图匹配）把生成的线与商家的线对齐，再计算精确率与召回。

表 4：对照商家参考结构的表现（14 个品类）

ProductType	线 F1	线 精确率	线 召回	梯 F1	梯 精确率	梯 召回
除臭剂与止汗剂	1.00	1.00	1.00	1.00	1.00	1.00
预制包装汤品	0.96	1.00	0.93	0.92	0.93	0.93
果汁	0.90	1.00	0.85	0.92	1.00	0.88
冰淇淋棒/甜筒	0.88	1.00	0.83	0.95	1.00	0.92
非处方药	0.87	0.99	0.81	0.75	0.73	0.91
卫生纸	0.79	0.97	0.71	0.76	0.82	0.78
洗衣液	0.75	1.00	0.63	0.63	0.87	0.59
猫粮	0.64	0.99	0.50	0.66	0.99	0.54
平均	0.83	0.98	0.75	0.82	0.92	0.81

高精确率：agent 达到接近完美的精确率，确认它在**不幻想关系的前提下把物理上相同的商品归组**，保证部署安全。

召回缺口：This high-precision/low-recall profile is an intentional guardrail. High-recall groupings risk applying price changes to unrelated items (e.g., incorrectly grouping 11 distinct "Prego Sauces"). Our system conservatively groups only the 4 identical Alfredo sauces, safely protecting the customer experience.

这种高精确率、低召回的形态是一道刻意设置的护栏。高召回的分组有把价格变更施加到不相关商品上的风险（例如错误地把 11 种不同的「Prego 酱料」归成一组）。**我们的系统保守地只把 4 种完全相同的 Alfredo 酱归在一起，安全地保护了顾客体验。**

召回偏低说明 agent **因缺少策略上下文而频繁地把线切得过细**。这解释了 F1 的方差：高度标准化的品类（除臭剂 F1=1.00）完美对齐，而依赖主观的、营销驱动描述的品类（猫粮 F1=0.64，要区分「海洋白鱼酱」与「酱汁金枪鱼片」）则差得多。**商家常常基于促销策略或宽泛的「风味家族」过度归组，而我们算法严格的物理分组自然会把这些宽泛的商家分组拆开，导致召回偏低。**

This divergence highlights a fundamental divergence between algorithmic strictness and human strategic intent. While the agent provides a safe, high-precision cold-start state, continuous merchant feedback enables the persistent memory to learn these strategic nuances.

这种分歧凸显了算法的严格性与人的策略意图之间的根本差异。agent 提供的是一个安全的、高精确率的冷启动状态，而持续的商家反馈使持久记忆能学到这些策略上的细微差别。

实验四：上线业务影响 Post-Launch Business Impact

This fully launched production system processes tens of thousands of active items, generating structured Lines and Ladders for > 90% of the previously un-managed catalog for the first time. End-to-end telemetry tracking merchant UI workflows over a 13-week period indicates an 86.1% reduction in time-on-task for existing workflows.

这套已全面上线的生产系统处理数万件活跃商品，**首次为超过 90% 此前无人管理的目录生成了结构化的线与梯**。跟踪商家界面工作流的端到端遥测显示，13 周内现有工作流的**任务耗时下降 86.1%**。

计算方式是：新工时 = 旧工时 × 剩余工作量 × 剩余时间。其中**工作量下降**——自动抽取把人工目录清理减少 35 - 40%（剩余工作量 ≈ 0.625 ）；**速度提升**——自动分组加界面复核比手工创建快 **4 - 5 倍**（剩余时间 ≈ 0.222 ）。取中间情形 $0.625 \times 0.222 = 0.138$ ，即 workflow 只需原工时的 **13.9%**，使商家能完全专注于高层定价策略。

局限与未来工作 Limitations and Future Work

Despite a temperature of 0, LLM non-determinism complicates strict reproducibility. The system is sensitive to sampling bias, where poor catalog quality can skew attribute discovery. Furthermore, compute costs currently restrict the framework to batch processing. In addition, reliance on specific LLM families necessitates re-validation upon model updates to mitigate hallucination risks.

尽管温度设为 0，大模型的非确定性仍使严格的可复现性变得复杂。 系统对**采样偏差敏感**——目录质量差会扭曲属性发现。此外，**计算成本目前把框架限制在批处理模式**。再者，**对特定大模型家族的依赖意味着模型一更新就必须重新验证**，以缓解幻觉风险。

Finally, while we argue that traditional embedding-based clustering lacks the contextual reasoning required for this task, future work will include empirical benchmarking against these non-LLM baselines to rigorously quantify the multi-agent system's added value.

最后，**虽然我们论证了传统的基于向量的聚类缺乏这项任务所需的上下文推理能力，未来工作将包括与这些非大模型基线的实证基准对比**，以严格量化多 agent 系统带来的增量价值。

（这是全文最诚实也最关键的一处自认：**「向量聚类不行」目前只是论证，没有实验支撑**。整套架构相对一个调好的传统基线值多少，本文没有回答。）

参考链接

- [arXiv 2608.12674](#) — 本文预印本
- [Generative Agents: Interactive Simulacra of Human Behavior](#) — 本文引用的第 6 篇文献,「在规模上模拟人类专家决策逻辑」这一思路的来源
- [Modeling Consumer Choice Among SKUs](#) — 本文引用的 SKU 层级消费者选择建模工作
- [The Price Is Unfair! A Conceptual Framework of Price Fairness Perceptions](#) — 价格公平感知的概念框架, 本文「定价不一致扭曲顾客价值感知」的理论依据