

把 domain 和 range 当检查器用 Ontology-Driven Structural Regularization for Document-Level Relation Extraction

本篇范围说明：这是一篇 18 页的 arXiv 论文（2608.20856v1，2026-08-21，帕多瓦大学信息工程系 Laura Menotti、Stefano Marchesin、Gianmaria Silvello）。下面「全文翻译」按原文章节推进，覆盖摘要、§1 引言、§2 相关工作、§3 方法（四类结构规则的形式定义）、§4 数据集一致性评估与无效三元组成因分析、§5 训练效果（清洗策略、实验设置、预测的结构一致性、性能影响）、§6 结论、§7 局限。附录 A/B/C 的逐关系 domain/range 表、逆关系表、基数表不译；四条 Definition 的数学记号只译其含义不逐符号展开。

核心内容

Q: DocRE 是什么？这篇论文要解决的问题是什么？ A: DocRE 是 Document-Level Relation Extraction，文档级关系抽取——从一整篇文档里找出所有实体对之间的语义关系，抽成关系三元组，用来构建知识图谱。

它的困境是数据：人工标注的 DocRED 只有 5,053 篇文档，而远程监督（Distant Supervision）生成的 DocRED distant 有 **101,873 篇文档、150 万条三元组**，但因为噪声太大**基本闲置**，主流模型只拿它做预训练或蒸馏。

远程监督的噪声来自一个很强的假设：**如果知识图谱断言两个实体之间有某个关系，那么每一篇提到这对实体的文档都在表达那个关系。**在文档级更糟——同一篇文档里共同出现的两个实体，比同一句话里的实体更不可能真有关系。

Q: 这篇论文发现的是哪一类噪声？它和已有的去噪工作有什么不同？ A: 这是全文的立论所在。**已有的去噪方法全都盯「语义正确性」**——用不确定性估计过滤低置信伪标签、用主动学习改善长尾关系、用多任务框架做提及-实体匹配。这些都是 **model-centric**（以模型为中心）的：让模型自己去判断哪个标签更可信。

这篇走的是 **data-centric**（以数据为中心）的路：**除了语义噪声，DocRE 数据集里还有一类被完全忽略的「结构不一致」**——三元组违反了本体约束、或者彼此逻辑矛盾。四种形态：违反 domain/range、缺失逆关系、非对称关系矛盾、基数冲突。

作者的原话把这个视角说得很清楚：与其把每个预测当成独立的分类决策，**不如把 DocRE 看成「在 OWL 公理诱导出的局部良构性条件下构建知识图谱」**——这个视角能发现标准训练目标看不见的结构不一致。

Q: 一个非常重要的界定：什么叫「结构一致性」？ A: 论文有一个脚注专门界定它，这句话是全文对做语义建模的人最有价值的一句：

我们用「结构一致性」这个词指的是 RDF 三元组在本体施加的约束下的良构性 (well-formedness), 而不是完整的本体可满足性 (ontology satisfiability)。

区别在哪: **本体可满足性**问的是「这套公理加这批数据在逻辑上能不能同时成立」, 要靠推理机 (reasoner) 去判, 而且推理机的做法通常是**补全**而不是**拒绝**。**良构性**问的是「这条三元组符不符合我写下的那几条检查规则」, 用普通代码就能查, 违规就是违规。

这篇论文把 OWL 的四个构造子全部当成「可检查的断言」用, 而不是「可推理的公理」用——

`owl:ObjectProperty` 的 domain/range 当类型检查器、`owl:inverseOf` 当补全规则、`owl:AsymmetricProperty` 当矛盾检测器、`owl:FunctionalProperty` 当计数上限。这是一种非常务实的用法。

Q: 四条规则具体怎么定义? A: 实体类型集合固定为 6 个: $T = \{\text{PER, ORG, LOC, TIME, NUM, MISC}\}$ (人、组织、地点、时间、数值、其他)。

规则一, 无效三元组 (invalid triple): 把每个关系 r 看成一个 `owl:ObjectProperty`, 它有允许的主语类型集合 $\text{dom}(r)$ 和宾语类型集合 $\text{ran}(r)$ 。三元组 $\langle \text{主语}, r, \text{宾语} \rangle$ 有效的条件是主语类型属于 $\text{dom}(r)$ 且宾语类型属于 $\text{ran}(r)$, 否则无效。

domain 和 range 从哪来? 从 Wikidata 属性描述的元数据字段抓——`subject type constraint` 给 domain、`value type constraint` 给 range; 再补上 ReDocRED 训练集里该关系最常见的主语/宾语类型。为避免约束过严, 所有关系的 domain 和 range 都额外包含 MISC 类型。例子: P19 (place of death, 死亡地点) 的 domain 是 `PER|MISC`、range 是 `LOC|MISC`; 所以 $\langle \text{Emily(PER)}, \text{P19}, \text{1987(TIME)} \rangle$ 是无效三元组, 因为 TIME 不在 P19 的 range 里。

规则二, 缺失逆关系 (missing inverse relation): 用 `owl:inverseOf`。这里采文档级的局部封闭世界假设——如果关系 r 在这篇文档里成立, 那它声明的逆关系也应该出现在这篇文档抽出的图里。逆关系对也从 Wikidata 的 `inverse property` 元数据字段拿。例子: P1376 (capital of, 是……的首都) 是 P36 (capital, 首都) 的逆。若 r 和 r' 相同, 那它是 `owl:SymmetricProperty`, 谓词必须双向都成立。

规则三, 非对称关系矛盾: 用 `owl:AsymmetricProperty`。按 Wikidata 元数据判定, DocRED 里只有两个对称关系——P26 (spouse, 配偶) 和 P3373 (sibling, 兄弟姐妹)——其余全部当非对称。如果同一篇文档里 $\langle A, r, B \rangle$ 和 $\langle B, r, A \rangle$ 同时出现 (且 $A \neq B$), 那就是逻辑矛盾, 因为非对称属性不可能是自己的逆。

规则四, 基数违规: 用 `owl:FunctionalProperty` (当上限 $kr=1$) 或 qualified cardinality restriction ($kr>1$)。给定主语和关系, 宾语的不同实体数不能超过 kr 。

这条规则的实证调整值得单记: 领域知识说有 11 个关系应该严格函数式 ($kr=1$), 但对 ReDocRED 训练集的实证分析发现这些关系的实例里有 7% 的最大基数是 2。原因不是模型错, 是同一个事实被标成了两个实体——ground truth 里同时存在完整日期 (「2 July 1931」) 和单独的年份 (「1931」), 算作两个不同的宾语。P570 (date of death) 有 15% 的训练实例 $kr>1$ 。所以作者把这类关系的上限放宽到 $kr=2$ 。

Q: 测出来的结构噪声有多严重? A: 这是全文最硬的一张表。

数据集	三元组数	无效三元组 δ	缺失逆关系 σ	非对称矛盾 γ	基数违规 θ
DocRED 人工训练集	38,180	602 (1.58%)	2,696 (64.36%)	154 (0.41%)	10 (0.28%)
ReDocRED 训练集	85,932	810 (0.94%)	947 (7.89%)	284 (0.34%)	20 (0.40%)
ReDocRED 开发集	17,284	122 (0.71%)	243 (8.92%)	56 (0.33%)	3 (0.32%)
ReDocRED 测试集	17,448	141 (0.81%)	242 (9.27%)	82 (0.48%)	6 (0.65%)
DocRED 远程监督	1,505,638	46,211 (3.07%)	85,065 (40.26%)	12,408 (0.84%)	²⁵ (0.01%)

相比 ReDocRED 人工训练集，远程监督数据有**三倍的无效三元组、近五倍的缺失逆关系、两倍的非对称矛盾**。

两个反常之处，作者都给了解释：

- **缺失逆关系最差的是 DocRED 人工训练集 (64.36%)**，不是远程监督数据。这是文献已知的问题（原始 DocRED 漏标了约 65% 的正例关系），ReDocRED 修正后降到不足 8%。
- **基数违规最少的是远程监督数据 (0.01%)**。因为它是拿 Wikipedia 文档对齐 Wikidata 三元组生成的，把 Wikidata 本身的基数保留了下来。

Q: **无效三元组是怎么产生的?** A: 作者做了一次方法论上很干净的成因分析。全标 46,211 条无效三元组不可行，所以用**二项比例估计**：简单随机抽样 (SRS) 抽 400 条，人工二分类标注——(i) 关系标注错误（实体类型对，关系类型给错了）、(ii) 实体标注错误（一个或两个实体类型标错，导致关系无效）。例子：
〈France(LOC), P16(capital), Paris(PER)〉属于实体标注错误，因为「Paris」被误分成了人。

不确定性用 **HPD 可信区间** (Highest Posterior Density, 最高后验密度区间) 而不是频率派置信区间， $\alpha=0.05$ 得 95% 区间。作者的理由是 HPD 直接在概率空间里操作、避免常见的解释陷阱，适合这种一次性评估场景。

结果：69% (±4.5%) 的无效三元组来自实体标注错误，只有 31% 来自关系标注错误。

作者由此推出一个更大的结论：**实体抽取是关系抽取的瓶颈**。端到端流水线里，实体识别的不准会传播到关系预测，给整个 RE 系统的性能设了一个上限。而本文不改实体抽取、只在抽出的三元组上强制结构一致性，所以**观察到的性能提升应当被解读为保守估计**。

Q: **怎么清洗? 清洗后效果如何?** A: 清洗策略是**保守且可扩展的**，核心取舍是「删」而不是「修」：

- **无效三元组**：人工修 46,211 条太贵，改为**把违规涉及的实体从训练集里删掉**，连带删掉该文档中所有与该实体相关的三元组。删掉 208,665 条三元组 + 3 篇文档。
- **缺失逆关系**：自动补上，加了 72,609 条。
- **非对称矛盾**：同样删实体，删掉 31,178 条。

- **基数违规**：太罕见 (0.01%)，不处理。
- 结果：corrected 数据集 1,338,404 条训练实例（比原来少 167,234 条）、101,870 篇文档。

在两个 SOTA 模型（ATLOP 和 DREEAM，各配 BERT 和 RoBERTa 两个 backbone）上训练：

一、预测里的结构违规大幅下降。 无效三元组平均降 **62.92%**；缺失逆关系 ATLOP-RoBERTa 降 **87.44%**、ATLOP-BERT 降 86.97%、DREEAM 降 74.13%；非对称违规几乎消除（ATLOP-RoBERTa 从 0.60% 降到 **0.00%**）。

二、一个很直接的观察：结构噪声几乎线性地传到预测里。 数据集里 40.6% 的逆关系缺失，预测里是 41.18% - 45.22%；数据集 0.84% 的非对称违规，预测里 0.53% - 0.79%。唯一的例外是无效三元组——预测里只有 0.85% - 1.61%，约为训练数据（3.07%）的三分之一。

三、性能提升。 ATLOP 全部指标都涨（precision +1.65%、recall +3.10%、F1 +2.69%，忽略指标下 IgnPrec +3.83%、IgnF1 +4.59%）。DREEAM 除 precision 略降 0.45% 外全涨，其中 **recall 平均 +14.07%**（DREEAM-BERT 达 **+19.32%**）、F1 +10.02%、IgnF1 +10.67%。总体平均 F1 +6.36%、IgnF1 +7.62%。

四、一个必须有的对照组。 清洗后数据少了 167,234 条，那性能提升会不会只是「数据少了反而好」？作者**随机删除同样数量的三元组**（10 个不同随机种子，报均值，标准差始终低于 1%）。结果：随机删除只带来边际提升，甚至在几个指标上**变差**——ATLOP-RoBERTa 的 recall 和 F1、两个 DREEAM 变体的 precision、DREEAM-BERT 的 IgnPrec。所以提升确实来自结构错误的修正，不是数据量减少。

工具已开源（github.com/mtlra/DocRE-StructuralConsistency），兼容任何 DocRED 格式的数据集，自带为 DocRED 开发的本体规则，也允许自定义约束。

背景补充 / 点评

几个术语和它们的来历

远程监督 (Distant Supervision) 出自 Mintz 等 2009 年的工作，是构建大规模关系抽取数据集的标准手法：拿一个已有的知识图谱（这里是 Wikidata），把它断言的实体对去文本里匹配，凡是同时提到这对实体的句子/文档就标上那个关系。省了人工，代价是那个「每一篇提到就都在表达」的假设很脆。

ReDocRED 是 DocRED 的修订版。Huang 等 2022 年发现原始 DocRED 的标注里约 **65% 的正例关系被漏标了**（构造时用的是 recommend-revise 范式，标注者只从推荐列表里选，没被推荐的就漏了），Tan 等 2022 年据此发布了修订的训练集和开发集。这解释了表里那个 64.36% 的缺失逆关系——漏标的关系里包含大量逆关系。

ATLOP 与 DREEAM 是两个 transformer 系的 DocRE 模型。ATLOP (Zhou 等 2021) 用 BERG 编码器表示实体对、配局部上下文池化，预测时用自适应阈值处理多标签分类。DREEAM (Ma 等 2023) 是师

生模型，架构基于 ATLOP 再加证据感知蒸馏。作者选 transformer 系而不是图神经网络系，理由很实在：图模型撑不住远程监督数据集的规模。

IgnPrec / IgnF1（论文里的 "ignored metrics"）是 DocRED 基准的标准指标：计算 precision 或 F1 时排除训练中见过的实体对。它测的是泛化而不是记忆，所以这篇里 IgnF1 的提升（+7.62%）比 F1（+6.36%）更有说服力。

这篇的洞察在哪

最值得记的是那个脚注给出的界定：结构一致性 $\neq$ 本体可满足性。

这句话解决了一个常见的困惑。很多人给数据写了 OWL 本体、开了推理机，然后发现「违规数据还是进来了」。原因就在这里——**OWL 的语义是开放世界的推理语义，不是封闭世界的约束语义。**

`rdfs:domain / owl:ObjectProperty` 的 domain 声明的是「凡是有这个属性的资源，就是这个类的实例」，推理机看到类型不符不会报错，它会**给这个资源补上一个类型**。

这篇的做法是把 OWL 只当**词汇表和形式化语言**用，不当**执行引擎**用：从 Wikidata 抓 domain/range 元数据、自己写代码逐条查违规、违规就删或补。四条规则全是这个模式。**这是我见过的对「OWL 有什么用」最务实的一种回答**——它有用，但用在「你想检查什么」这一侧，不是「让它替你检查」这一侧。

第二个洞察是「结构噪声几乎线性传到预测」。数据里 40.6% 的逆关系缺失，预测里 41 - 45%。这个数字说明**模型不会自己纠正训练数据里的结构错误，它会照抄**。这一点看起来平淡，但它推翻了一个常见的乐观假设——「数据有点噪声没关系，模型会平均掉」。对逻辑约束这类噪声，模型平均不掉，因为它学到的正是「这种关系不需要有逆」。

第三个是那个随机删除对照组。这是全篇方法论上最硬的一处。删了 16 万条三元组之后性能涨了，最容易被质疑的就是「是不是数据少了反而好」。作者用同量随机删除、10 个种子、报均值和标准差把这条堵掉了，而且随机组在几个指标上还变差——这比「随机组也涨但涨得少」更有说服力。

留白与可疑之处

一、评测集本身有噪声，作者承认但没解决，而有一个他没做的替代方案。 ReDocRED test 有 0.81% 无效三元组、9.27% 缺失逆关系、0.48% 非对称矛盾、0.65% 基数违规（基数违规还是全部数据集里最高的）。**用一个带噪的尺子去量「减少噪声的效果」，测出来的只能是下界。**作者给的理由是重标 test 集会招致「为自己的方法定制」的偏见嫌疑——这个顾虑成立。但还有一条路他没走：**在 test 集的「结构干净子集」上单独报一次指标。**这不需要重标、只需要过滤，而且正好能回答「在干净数据上到底提升多少」。论文里连这个子集有多大都没给。

二、删实体的牵连代价没被算过。无效三元组 46,211 条 + 非对称矛盾 12,408 条 = 58,619 条问题三元组，但清洗一共删掉了 239,843 条（208,665 + 31,178）。**牵连比约 4:1——每删掉 1 条问题三元组，就有 3 条本来正确的被连坐。**论文没算这个比例，也没讨论被误删的那些正确三元组是否携带有用信号。

随机对照组能证明「不是因为数据变少」，但它证明不了「不是因为删掉的恰好是难样本」。涉及类型标注混乱的实体，很可能同时是那些语义上也最模糊的实体——把它们整批移走，模型面对的分布就更干净、更简单了。这两个解释（「结构噪声被清掉」vs「难样本被移走」）在现有实验里区分不开。

三、DREEAM 的 precision 下降被一句话带过。两个 backbone 上 precision 都降（-0.56%、-0.33%），而 recall 大涨（+19.32%、+8.81%）。这个形状说明清洗后的模型**更敢预测了**——阈值行为变了，而不一定是判别能力变强了。ATLOP 有自适应阈值机制、DREEAM 也继承了它，所以这个变化完全可能来自阈值。论文没报预测数量或阈值的变化，所以「学得更准」和「决策边界移动」这两个解释分不开。

四、统计显著性作者自己承认没做，而这直接影响 ATLOP 那组数字的可信度。局限里明说「没有量化不同结构违规来源的统计显著性」。注意一个细节：那句「标准差始终低于 1%」说的是**随机对照组**的标准差（10 个种子）。**清洗组只跑了一次，没有标准差**。而 ATLOP 的提升是 +1.65% 到 +4.59% 这个量级，随机对照的提升是 +0.09% 到 +1.63%——两者的区间是**挨着的**。所以 ATLOP 那几个 1% - 4% 的提升有多稳，论文答不了。DREEAM 的 +14% recall 量级足够大，那个可信。

换句话说：这篇的结论强度是不均匀的。「结构噪声大量存在」（表 1）和「模型会照抄结构噪声」（表 2）这两条是结实的，因为它们是直接测量、不涉及训练随机性。「清洗能提升性能」这一条，在 DREEAM 上结实、在 ATLOP 上还差一组重复实验。

对我的启示

一、这篇正好是我昨天在做的那件事的方法论。我在从 Roleplay 的语义点里抽知识点和关系（CN 去重后 8,305 个语义点是候选知识点池），下一步要把它们归到知识域和技能域、建立跨企业的 `same_as` 边。这篇讲的就是「关系抽取的数据里有一类结构噪声，用本体约束能量化和清掉」，而且给了可直接抄的四条规则。

具体能搬的：等我建出 `knowledge_relation` 之后，`requires`（前置）应该是有向无环、`part_of`（包含）也是、`same_as` 是对称的、`illustrates` 是有向的。这四种边各自对应这篇的一条检查规则——`same_as` 缺了反向边就是「缺失逆关系」，`requires` 出现双向就是「非对称矛盾」，一个知识单元的 `part_of` 父节点超过 1 个就是「基数违规」。**这些检查我现在一条都没写**。应该在 spec 的第 5 节（建模难点）之后加一节「结构一致性检查规则」，每条边类型一条规则。

二、它给了我那个 `rdfs:domain` 发现的正面用法。我之前踩过坑：以为写了 `rdfs:domain` 就能拦住类型不对的数据，实际 RDFS 的语义是推理——它不拦，反而给违规数据补上一个类型。昨天读 RTSKG 那篇时，从它对 domain 的措辞（用 is 不是 must be）拿到了独立佐证。

这篇补上了第三块：既然推理机不拦，那就自己写代码查。它把 domain/range 从 Wikidata 元数据里抓出来当类型检查器用，一条一条对着查。**判据可以定完整了**：想表达「必须是」，① 不要指望 RDFS/OWL 推理；② 要么用 SHACL（它就是为约束设计的），③ 要么像这篇一样把约束写成代码里的检查规则。第三条的好处是**约束的严格度可调**——这篇给所有关系的 domain/range 都加了 MISC 兜底，就是为了不过严。我建 `knowledge_relation` 的类型约束时可以留一个「未知/其他」的 `unit_type` 做同样的兜底。

三、基数从 1 放宽到 2 的原因，我昨天刚在别的地方见过同一个病。这篇发现 11 个「应该函数式」的关系里 7% 的实例基数是 2，原因是**同一个事实被标成了两个实体**（完整日期「2 July 1931」和年份

「1931」)。这和 AI-ready data 那篇讲的「运行时拼身份」是同一个病——同一个人在 CRM 是字符串 ID、计费系统是整数、客服工单是 UUID。

沉淀成一条判据：约束报警的时候，先怀疑实体归一化没做好，再怀疑约束写错了，最后才怀疑数据真的违规。 这篇的处理是放宽约束（kr 从 1 到 2），那是权宜之计——根本解是把日期和年份归并成一个实体。我在建 `same_as` 之前如果不先做实体归一化，任何基数约束都会大面积误报。

四、「69% 的无效三元组来自实体标注错误」这条对我的第一难点有直接含义。 我在 spec 里写过「跨产品的 `same_as` 边现在没有任何自动来源，这是第一难点」。这篇说明**实体层的错误会给关系层设一个上限**——如果 `same_as` 不准，后面所有跨产品的关系都不可信，而且这个上限**不是靠改进关系抽取能突破的**。

所以顺序不能反：**先解决实体识别（哪些知识单元是同一个），再谈关系。** 昨天从测评那个 App 拿到的「合并方案映射表」是 `same_as` 的第一个现成来源，这条的价值比我当时估的更高——它不只是「多了一个数据源」，它是在**打破那个上限**。

五、随机对照组这个设计我要加进数仓迁移验证的清单。 前天我给自己列了「同类对照 + 增量对照」两问，这篇提供了第三问：**等量随机对照**。具体到 `knowledge_point_resource` 拆两层加拉链这件事——新模型比老模型少了千万级的实例复制行，如果新模型算出来的口径「更对」，怎么证明不是「数据少了噪声也少了」？答案就是随机删掉同样数量的行、跑十次、看会不会也「更对」。

六、这篇的结论强度不均匀，这个形状本身是个提醒。 直接测量的结论（结构噪声有多少、模型照抄多少）结实，需要训练随机性的结论（性能提升多少）就要看重复次数。我写研究报告时也有同类问题——从代码和 DDL 直接读出来的事实（表结构、写入口、消费方）是结实的，从数据样本推出来的结论（比如我前两天用 COM 站 42 条数据推「数仓没有医药版能力分」）就脆。**报告里应该把这两类分开标，别让读者以为强度一样。**

文中金句

"We use the term structural consistency to denote the well-formedness of RDF triples under ontology-imposed constraints, rather than full ontology satisfiability." 我们用「结构一致性」这个词指的是 RDF 三元组在本体施加的约束下的**良构性**，而不是完整的**本体可满足性**。

"Rather than treating these predictions as independent classification decisions, we interpret DocRE as the construction of a KG focusing on local well-formedness conditions induced by OWL axioms. This perspective allows us to detect structural inconsistencies that are invisible to standard training objectives." 与其把这些预测当成彼此独立的分类决策，我们把文档级关系抽取解读为「在 OWL 公理诱导出的局部良构性条件下构建知识图谱」。这个视角让我们能发现**标准训练目标看不见的**结构不一致。

"Missing inverse triples in the training set propagate almost linearly to the predictions." 训练中缺失的逆关系三元组，**几乎线性地**传播到模型预测里。

"these findings emphasize that entity extraction is a bottleneck for relation extraction. In end-to-end pipelines, inaccuracies in entity recognition propagate to relation prediction, thereby imposing an upper bound on the overall performance of RE systems." 这些发现强调：**实体抽取是关系抽取的瓶颈**。在端到端流水线里，实体识别的不准会传播到关系预测，从而给关系抽取系统的整体性能**设定一个上限**。

"These findings indicate that the observed performance gains stem from the correction of structural errors rather than from the mere reduction in the number of training triples or documents." 这些发现表明，观察到的性能提升来自**结构错误的修正**，而不是仅仅因为训练三元组或文档数量减少了。

全文翻译

摘要

Document-Level Relation Extraction (DocRE) relies heavily on costly manually annotated datasets, while large distant supervision resources such as DocRED distant remain underexploited due to noise. We show that a critical yet overlooked source of noise lies in structural inconsistencies within relational triples, including violations of ontology constraints and logical contradictions.

文档级关系抽取（DocRE）严重依赖成本高昂的人工标注数据集，而 DocRED distant 这类大规模远程监督资源却因噪声而未被充分利用。我们指出，**一个关键但被忽视的噪声来源在于关系三元组内部的结构不一致**，包括对本体约束的违反和逻辑矛盾。

We introduce an ontology-driven framework to quantify and enforce structural consistency in DocRE datasets. Our analysis reveals substantial structural noise in DocRED distant and demonstrates that such inconsistencies propagate to model predictions. Enforcing structural well-formedness during training significantly reduces logical contradictions and consistently improves generalization performance. These findings establish structural consistency as a missing axis of supervision in DocRE and highlight structural regularization as an effective strategy for leveraging distant data at scale.

我们提出一个本体驱动的框架，用于量化并强制 DocRE 数据集的结构一致性。我们的分析揭示 DocRED distant 中存在大量结构噪声，并证明这类不一致会**传播到模型预测**。在训练期间强制结构良构性显著减少了

逻辑矛盾，并一致地改善了泛化性能。这些发现把结构一致性确立为 DocRE 中一个缺失的监督维度，并指出结构正则化是大规模利用远程数据的一条有效策略。

1. 引言：远程监督为什么闲置，以及被漏掉的那一类噪声

Document-Level Relation Extraction (DocRE) aims to identify all semantic relations holding between entity pairs within a full document. By extracting relational triples, DocRE enables the construction of Knowledge Graphs (KGs), which provide structured, machine-readable knowledge to support downstream tasks such as information retrieval, question answering, data mining, and recommendation systems. Building accurate KGs therefore depends on reliable DocRE models trained on high-quality data.

文档级关系抽取（DocRE）的目标是识别一整篇文档内实体对之间成立的所有语义关系。通过抽取关系三元组，DocRE 使知识图谱（KG）的构建成为可能——知识图谱提供结构化、机器可读的知识，以支撑信息检索、问答、数据挖掘、推荐系统等下游任务。因此，构建准确的知识图谱依赖于在高质量数据上训练的可靠 DocRE 模型。

The reference benchmark for general-domain DocRE is DocRED, constructed from Wikipedia articles. DocRED includes both manually annotated datasets and a large distantly supervised dataset. The manually curated split follows a recommend-revise paradigm and contains 5,053 documents, divided into 3,053 for training and 1,000 each for development and testing. In contrast, the DocRED distant dataset comprises 101,873 documents, annotated via Distant Supervision (DS) by aligning Wikidata triples with Wikipedia text and leveraging BERT-based named entity annotations.

通用域 DocRE 的参考基准是 DocRED，由 Wikipedia 文章构建。DocRED 同时包含人工标注数据集和一个大规模远程监督数据集。人工整理的部分遵循 recommend-revise 范式，含 5,053 篇文档（3,053 训练、开发与测试各 1,000）。相比之下，**DocRED distant 数据集有 101,873 篇文档**，通过远程监督（DS）标注——把 Wikidata 三元组与 Wikipedia 文本对齐，并借助基于 BERT 的命名实体标注。

While distant supervision enables large-scale data construction, it relies on the strong assumption that if a KG asserts a relation between two entities, then every document mentioning the pair expresses that relation. This assumption adds substantial noise. In DocRE, the issue is worse because entities co-occurring in a document are less likely to express a true relation than those in the same sentence. As a result, most state-of-the-art models rely mainly on manually annotated data or use distant data only for pre-training or distillation.

远程监督使大规模数据构建成为可能，但它依赖一个**很强的假设**：如果知识图谱断言两个实体之间存在某个关系，那么每一篇提到这对实体的文档都在表达那个关系。这个假设带来大量噪声。在 DocRE 里问题更严重，因为**同一篇文档里共同出现的实体，比同一句话里的实体更不可能表达真实关系**。结果是，多数最先进的模型主要依赖人工标注数据，或者只把远程数据用于预训练或蒸馏。

Recent analyses have further revealed annotation issues even in the manually curated splits. In particular, around 65% of positive relations were missing in the original DocRED annotations, leading to the release of ReDocRED, a revised version of the training and development datasets. Although existing denoising approaches attempt to mitigate DS noise through uncertainty estimation or active learning for long-tail relations, they focus primarily on semantic correctness and model-driven pseudo-label refinement.

近期分析进一步揭示，即便人工整理的部分也存在标注问题。特别是，[原始 DocRED 标注中约 65% 的正例关系被漏标](#)，这促成了 ReDocRED（训练集与开发集的修订版）的发布。虽然已有的去噪方法尝试通过不确定性估计、或针对长尾关系的主动学习来缓解远程监督噪声，[它们关注的主要是语义正确性和模型驱动的伪标签精炼](#)。

In contrast to model-centric denoising strategies, we adopt a data-centric approach, focusing on improving the structural quality of training data itself. We argue that beyond semantic noise, DocRE datasets suffer from structural inconsistencies in the extracted triples, such as violations of ontology constraints, missing inverse relations, asymmetric contradictions, and cardinality conflicts. These inconsistencies represent a previously overlooked source of supervision noise that might propagate during model training.

与以模型为中心的去噪策略不同，我们采取[以数据为中心](#)的方法，聚焦于改善训练数据本身的结构质量。我们主张：除了语义噪声，DocRE 数据集在抽出的三元组中还存在**结构不一致**——违反本体约束、缺失逆关系、非对称矛盾、基数冲突。这些不一致构成一个此前被忽视的监督噪声来源，可能在模型训练过程中传播。

（脚注：[我们用「结构一致性」这个词指的是 RDF 三元组在本体施加的约束下的良构性，而不是完整的本体可满足性。](#)）

Concretely, we operationalize structural consistency by leveraging the formal semantics of the Web Ontology Language (OWL) to define explicit structural constraints over entity types and relations. Our methodology evaluates the well-formedness of relational triples under ontology axioms and quantifies structural violations in both DocRED and ReDocRED, with particular emphasis on the DocRED distant dataset.

具体做法是：借助 Web 本体语言（OWL）的形式语义，在实体类型与关系之上定义显式的结构约束，从而把结构一致性[可操作化](#)。我们的方法在本体公理下评估关系三元组的良构性，并量化 DocRED 与 ReDocRED 中的结构违规，重点是 DocRED distant。

We show that structural noise is substantially more prevalent in distantly supervised data than in manually curated datasets. In particular, compared to the ReDocRED manual training split, the DocRED distant dataset contains three times more invalid triples, nearly five times more missing inverse relations, and twice as many asymmetric inconsistencies. To mitigate this effect, we introduce a lightweight, model-agnostic pre-processing pipeline that enforces structural consistency prior to training. The pipeline cleans and augments the dataset without altering

model architectures, loss functions, or inference procedures, ensuring seamless integration with existing DocRE systems - whether sequence-based or graph-based.

我们表明结构噪声在远程监督数据中远比人工整理数据普遍。特别是，相比 ReDocRED 人工训练集，DocRED distant 含有**三倍的无效三元组、近五倍的缺失逆关系、两倍的非对称不一致**。为缓解这一影响，我们引入一个**轻量、与模型无关的预处理流水线**，在训练前强制结构一致性。该流水线清洗并增强数据集，**不改动物理架构、损失函数或推理过程**，因此能无缝接入现有的 DocRE 系统——无论是序列式还是图式。

Our main contributions are: (1) We propose an ontology-driven framework that uses OWL constraints to rigorously diagnose ontology-level structural consistency in DocRE datasets; (2) We deliver the first in-depth quantitative study of structural inconsistencies in DocRED distant and its denoised variants, uncovering extensive, previously unreported violations; (3) We show that enforcing structural well-formedness as a pre-processing step markedly reduces logical contradictions in model predictions and consistently boosts generalization performance across state-of-the-art DocRE models.

主要贡献三条：（1）提出一个本体驱动的框架，用 OWL 约束严格诊断 DocRE 数据集在本体层面的结构一致性；（2）给出对 DocRED distant 及其去噪变体中结构不一致的**首次深入定量研究**，揭示大量此前未被报告的违规；（3）表明把结构良构性作为预处理步骤强制执行，能显著减少模型预测中的逻辑矛盾，并在多个最先进 DocRE 模型上一致地提升泛化性能。

工具已开源，兼容任何 DocRED schema 格式的数据集，包含我们为 DocRED 开发的本体规则，同时允许定义其他自定义约束。

2. 相关工作：已有的去噪和约束方法都缺了哪一块

To address this issue, several works have proposed denoising strategies for DocRE. Xiao et al. introduced a multi-task framework incorporating mention-entity matching and fact alignment. Sun et al. proposed uncertainty-guided label denoising using Monte Carlo dropout to filter low-confidence pseudo-labels. Menotti et al. developed an active learning pipeline tailored to improve long-tail relation predictions. These approaches focus primarily on improving the semantic reliability of distant labels through model-driven refinement. In contrast, our work targets a complementary and largely unexplored dimension: structural consistency of relational triples under ontology-imposed constraints.

为解决噪声问题，已有若干 DocRE 去噪策略：Xiao 等提出结合提及-实体匹配和事实对齐的多任务框架；Sun 等提出用 Monte Carlo dropout 做不确定性引导的标签去噪，过滤低置信伪标签；Menotti 等开发了针对长尾关系预测的主动学习流水线。**这些方法关注的主要是通过模型驱动的精炼来改善远程标签的语义可靠性**。相比之下，我们的工作瞄准一个互补且基本未被探索的维度：**本体约束下关系三元组的结构一致性**。

Logical rules have been explored in DocRE to enhance relation prediction. Ru et al. introduced a probabilistic framework that learns logic rules as latent variables and optimizes them via Expectation Maximization (EM). Zhang et al. proposed a Secondary Reasoning Framework that

leverages first-stage predictions as contextual signals to infer additional relations among neighboring entities. Zhang et al. developed GREP, which models interdependencies between entity pairs. These approaches incorporate logical or reasoning mechanisms within the prediction process, focusing on improving semantic inference. In contrast, our work addresses a complementary dimension: the structural well-formedness of triples under ontology-imposed constraints, independently of the model architecture or inference strategy.

DocRE 领域也探索过用逻辑规则增强关系预测：Ru 等提出把逻辑规则当作隐变量学习、用 EM 优化的概率框架；Zhang 等提出二次推理框架，把第一阶段的预测当作上下文信号来推断邻近实体间的额外关系；Zhang 等开发的 GREP 建模实体对之间的相互依赖。**这些方法把逻辑或推理机制放进预测过程内部，重点是改善语义推断。**我们的工作面对的是一个互补维度：**本体约束下三元组的结构良构性，与模型架构或推理策略无关。**

Constraint-based approaches have also been explored in sentence-level RE. Liu et al. leveraged entity type information to introduce fine-grained type constraints. Ji et al. incorporated Freebase entity descriptions as background knowledge. Liang et al. proposed a constraint graph constructed from entity type constraints, providing an additional supervision signal within a constraint-aware attention module. While these methods integrate external knowledge to guide sentence-level inference, they have not been extended to DocRE, nor do they explicitly enforce ontology-level structural consistency.

基于约束的方法也在**句子级**关系抽取中被探索过：Liu 等利用实体类型信息引入细粒度类型约束；Ji 等把 Freebase 实体描述作为背景知识引导注意力机制；Liang 等提出由实体类型约束构建的**约束图**，在约束感知的注意力模块中提供额外监督信号。虽然这些方法整合外部知识来引导句子级推断，**它们既没有扩展到文档级，也没有显式强制本体层面的结构一致性。**

3. 方法：四条规则的形式定义

Given a document d and a set of entities E , each entity is associated with a set of mentions. The task of DocRE is to predict a subset of relations from $R \cup \{na\}$ between entity pairs, where R is a pre-defined set of semantic relations and na represents the absence of a relation. Rather than treating these predictions as independent classification decisions, we interpret DocRE as the construction of a KG focusing on local well-formedness conditions induced by OWL axioms. This perspective allows us to detect structural inconsistencies that are invisible to standard training objectives.

给定文档 d 和实体集合 E ，每个实体关联一组提及（mention）。DocRE 的任务是为实体对预测关系集合 $R \cup \{na\}$ 的一个子集，其中 R 是预定义的语义关系集合、 na 表示无关系。**与其把这些预测当成彼此独立的分类决策，我们把 DocRE 解读为「在 OWL 公理诱导出的局部良构性条件下构建知识图谱」。**这个视角让我们能发现标准训练目标看不见的结构不一致。

3.1 无效三元组。 Each entity mention is classified into a specific type from the set $T = \{\text{PER}, \text{ORG}, \text{LOC}, \text{TIME}, \text{NUM}, \text{MISC}\}$. Since all mentions in a set identify the same entity, we assume consistent typing across the set; thus we use the first mention as representative.

每个实体提及被归入类型集合 $T = \{\text{PER}, \text{ORG}, \text{LOC}, \text{TIME}, \text{NUM}, \text{MISC}\}$ 中的某一类。由于同一组内的所有提及标识同一个实体，我们假设组内类型一致，因此用第一个提及作为代表。

In this context, the entity pair and their predicted relation form an RDF triple $\langle s, p, o \rangle$. Beyond simple triple extraction, we can leverage OWL to define formal semantics. Each relation r can be viewed as an owl:ObjectProperty with specific domain and range constraints. Specifically, for a triple to be semantically valid, the entity types must satisfy: $t(es) \in \text{dom}(r)$ and $t(eo) \in \text{ran}(r)$. Triples that violate these constraints are considered invalid triples within the defined ontology. By treating R as a set of restricted properties rather than arbitrary labels, we can filter out noise and improve the logical consistency of the extracted document graph.

在这个框架下，实体对与其预测关系构成一个 RDF 三元组 $\langle s, p, o \rangle$ 。除了简单的三元组抽取，我们可以用 OWL 定义形式语义：**每个关系 r 可以看作一个 owl:ObjectProperty，带有特定的 domain 与 range 约束。**具体地，三元组语义有效的条件是实体类型满足 $t(es) \in \text{dom}(r)$ 且 $t(eo) \in \text{ran}(r)$ 。违反这些约束的三元组在所定义的本体内被视为**无效三元组**。把 R 当作一组受限属性而不是任意标签，我们就能过滤噪声、改善抽出的文档图的逻辑一致性。

Each relation in DocRED is mapped to a Wikidata property. Thus, we leverage the Wikidata property descriptions to identify the domain (metadata field "subject type constraint") and the range of each property ("value type constraint"), if present. We also use the ReDocRED training dataset to extract the most popular entity types of the subject and object entities of each relation and include them in the domain and range. To avoid overly restrictive criteria, the domain and range of all relations include entity type "MISC". For instance, relation P19 (place of death) has domain "PER|MISC" and range "LOC|MISC".

DocRED 中每个关系都映射到一个 Wikidata 属性。因此我们利用 Wikidata 的属性描述来识别每个属性的 domain（元数据字段 `subject type constraint`）和 range（`value type constraint`），如果存在的话。我们也用 ReDocRED 训练集提取每个关系的主语和宾语实体最常见的实体类型，并把它们纳入 domain 和 range。**为避免过于严苛的判据，所有关系的 domain 和 range 都包含实体类型 "MISC"。**例如关系 P19（place of death）的 domain 是 "PER|MISC"、range 是 "LOC|MISC"。

定义 3.1（无效三元组）：给定实体对及其类型，关系 r 对该实体对是「无效」的，当且仅当主语实体类型不在该属性的 domain 中、或宾语实体类型不在其 range 中。关系 r 无效的三元组称为**无效三元组**。例如 $\langle \text{Emily}(\text{PER}), \text{P19}, 1987(\text{TIME}) \rangle$ 是无效三元组，因为宾语实体类型 TIME 不被 P19（死亡地点）允许。

3.2 缺失逆关系。 Inverse properties in OWL allow for the formal definition of bidirectional relationships. Within each document-level extracted graph, we adopt a local closed-world

assumption with respect to inverse relations: if a relation r holds between two entities in the document, its declared inverse should also be present in the extracted graph. To identify these pairs, we leverage the "inverse property" metadata field from the Wikidata properties description.

OWL 中的逆属性允许形式化定义双向关系。在**每个文档级抽出的图内部**，我们对逆关系采取「**局部封闭世界假设**」：如果关系 r 在该文档中的两个实体之间成立，那么它声明的逆关系也应当出现在抽出的图中。逆关系对通过 Wikidata 属性描述的 `inverse property` 元数据字段识别。例如 P1376 (capital of) 是 P36 (capital) 的逆。

定义 3.2 (缺失逆关系)：设 r' 在本体中被声明为 `owl:inverseOf r`。按 `owl:inverseOf` 的定义，文档 d 中三元组 $\langle es, r, eo \rangle$ 的存在蕴含逆三元组 $\langle eo, r', es \rangle$ 的存在。因此，若前者在 d 中而后者不在，则该实体对存在**缺失逆关系**。

Note that r and r' are not required to be distinct; if $r = r'$, the relation is defined as an `owl:SymmetricProperty`, where the predicate must hold in both directions.

注意 r 和 r' 不要求相异；若 $r = r'$ ，则该关系被定义为 `owl:SymmetricProperty`，谓词必须双向成立。

3.3 非对称关系矛盾。 A relation is considered asymmetric if the existence of a relationship in one direction precludes its existence in the opposite direction. Formally, leveraging the "inverse property" metadata from Wikidata, we identify that the DocRED dataset contains only two symmetric relations: P26 (spouse) and P3373 (sibling), both of which satisfy $r \equiv \text{owl:SymmetricProperty}$. All other relations are treated as asymmetric.

若一个关系在一个方向上存在就排除了反方向存在的可能，则该关系被视为非对称。借助 Wikidata 的 `inverse property` 元数据，我们识别出 DocRED 数据集只包含两个对称关系：P26 (配偶) 和 P3373 (兄弟姐妹)，两者都满足 $r \equiv \text{owl:SymmetricProperty}$ 。其余所有关系都被当作非对称。

定义 3.3 (非对称关系违规)：设 r 是一个 `owl:AsymmetricProperty`。若文档 d 中同时存在 $\langle es, r, eo \rangle$ 和 $\langle eo, r, es \rangle$ (且 $s \neq o$)，则 d 包含一个**非对称关系违规**。这种状态在 OWL 的非对称性定义下构成**逻辑矛盾**，因为除非该属性是对称的，它不可能是自己的逆。

3.4 基数违规。 Given an entity subject, the maximum cardinality of a relation r is defined as the largest possible number of distinct entity objects such that triples of that form can be instantiated. While domain knowledge initially suggests that a subset of 11 relations should be strictly functional ($kr = 1$), empirical analysis of the ReDocRED training set reveals that 7% of these relation instances exhibit a maximum cardinality of 2. This is often due to ground truth comprising both full dates (e.g., "2 July 1931") and separate year mentions (e.g., "1931") as distinct entities. For example, 15% of training instances of P570 (date of death) present $kr > 1$.

Consequently, to avoid overly restrictive criteria, we relax the maximum cardinality of such relations to $kr = 2$.

给定主语实体，关系 r 的最大基数定义为可实例化的不同宾语实体的最大可能数目。虽然领域知识最初提示有 11 个关系应当严格函数式 ($kr = 1$)，对 ReDocRED 训练集的实证分析显示这些关系实例中有 7% 表现出最大基数为 2。这通常是因为 ground truth 把完整日期（如「2 July 1931」）和单独的年份提及（如「1931」）当成了两个不同实体。例如 P570（死亡日期）有 15% 的训练实例呈现 $kr > 1$ 。因此，为避免判据过于严苛，我们把这类关系的最大基数放宽到 $kr = 2$ 。

定义 3.4 (基数违规)：给定最大基数为 kr 的关系 r ，设 $O(es, r)$ 是文档 d 中与主语 es 和关系 r 关联的宾语实体集合。若抽出的不同三元组数超过阈值 ($|O(es, r)| > kr$)，则主语 es 发生**基数违规**。

In OWL terms, if $kr = 1$, the relation is treated as an `owl:FunctionalProperty`; for $kr > 1$, it is treated as a qualified cardinality restriction.

用 OWL 的术语说： $kr = 1$ 时该关系被当作 `owl:FunctionalProperty`； $kr > 1$ 时被当作 `qualified cardinality restriction` (受限基数约束)。

4. DocRE 数据集的结构一致性

We analyzed several DocRE datasets from different domains (especially biomedical), but none of them was suitable for the study. BioRED and BC5CDR are two well-known biomedical DocRE datasets, but they only include one relation type ("associated_with") between different entity types. While GutBrainIE includes a sufficient variety of entity types and relations, its preprocessing to remove structural inconsistencies before release renders our analysis infeasible.

我们分析了来自不同领域（尤其是生物医学）的若干 DocRE 数据集，但都不适合本研究。BioRED 和 BC5CDR 是两个知名的生物医学 DocRE 数据集，但它们在不同实体类型之间**只有一种关系类型** ("associated_with")。GutBrainIE 虽然包含足够多样的实体类型和关系，但它在发布前的预处理已经移除了结构不一致，使我们的分析无从下手。

4.1 数据集一致性评估。 四个百分比的分母各不相同，这一点值得留意：无效三元组的百分比 δ 是「结构无效三元组数 ÷ 数据集三元组总数」；缺失逆关系的百分比 σ 是「缺失逆三元组数 ÷ 涉及有逆关系的关系的三元组数」；非对称不一致的百分比 γ 是「不一致数 ÷ 涉及非对称关系的三元组数」；基数违规的百分比 θ 是「违规的（主语，关系）对数 ÷ 涉及有界最大基数的关系的所有此类对数」。

（表 1 数据见「核心内容」部分。）

As expected, DocRED distant presents much more inconsistencies than the manual datasets. The only exception is on the missing inverse relations, where the worst is the DocRED manual training dataset. This is a known issue in the literature and has been corrected in ReDocRED, as

demonstrated by the reduction in missing inverse between the DocRED and ReDocRED manual training dataset (from around 64% to less than 8%).

如预期，DocRED distant 比人工数据集呈现出多得多的不一致。**唯一的例外是缺失逆关系——最差的是 DocRED 人工训练集。**这是文献中已知的问题，并已在 ReDocRED 中被修正，其证据就是 DocRED 与 ReDocRED 人工训练集之间缺失逆关系的下降（从约 64% 降到不足 8%）。

About cardinality violations, DocRED distant is the dataset containing less errors (0.01%), while the other datasets range between 0.28% and 0.65% of violations. This phenomenon can be attributed to the distant supervision methodology employed in constructing the DocRED distant dataset, which aligns Wikipedia documents with Wikidata triples and thereby preserves their cardinalities.

关于基数违规，**DocRED distant 反而是错误最少的数据集 (0.01%)**，其余数据集在 0.28% 到 0.65% 之间。这一现象可归因于构建 DocRED distant 所用的远程监督方法——它把 Wikipedia 文档与 Wikidata 三元组对齐，**因而保留了后者的基数。**

Also ReDocRED datasets exhibit structural violations, with a small but non-negligible proportion of errors in all splits. Given the presence of structural violations in the evaluation datasets, models trained to generate well-formed triples may exhibit degraded performance.

ReDocRED 数据集同样呈现结构违规，所有划分中都有一小部分但不可忽略的错误。**鉴于评测数据集中存在结构违规，被训练成生成良构三元组的模型可能表现出性能下降。**

4.2 无效三元组成因分析。 We classify each invalid triple into one of two mutually exclusive categories: (i) relation annotation errors, where, given a correctly typed entity pair, the wrong relation type is assigned, and (ii) entity annotation errors, where one or both entities are incorrectly typed, thereby inducing an invalid relation. For example, the triple $\langle \text{France(LOC)}, \text{P16(capital)}, \text{Paris(PER)} \rangle$ is considered an entity annotation error because "Paris" is mistakenly classified as a person.

我们把每个无效三元组归入两个互斥类别之一：(i) **关系标注错误**——实体对类型正确，但被赋予了错误的关系类型；(ii) **实体标注错误**——一个或两个实体类型标错，从而诱发了无效关系。例如 $\langle \text{France(LOC)}, \text{P16(capital)}, \text{Paris(PER)} \rangle$ 属于实体标注错误，因为「Paris」被错误地归为人。

Since annotating all invalid triples within DocRED distant would be infeasible in terms of time and cost, we instead rely on binomial proportion estimation techniques. Specifically, we draw a sample using Simple Random Sampling (SRS) of size 400 from the population of invalid triples. To quantify sampling uncertainty, we employ Highest Posterior Density (HPD) intervals, which are well suited for uncertainty quantification in KG evaluation settings. Unlike (frequentist) confidence intervals, HPD intervals operate directly in the probabilistic space and avoid common interpretational pitfalls, making them appropriate for one-shot evaluation scenarios. We set $\alpha = 0.05$, yielding a 95% credible interval.

由于标注 DocRED distant 内所有无效三元组在时间和成本上不可行，我们改用**二项比例估计**技术。具体地，用简单随机抽样（SRS）从无效三元组总体中抽取规模 400 的样本。为量化抽样不确定性，我们采用**最高后验密度（HPD）区间**——它非常适合知识图谱评估场景下的不确定性量化。与**（频率派的）置信区间不同**，HPD 区间**直接在概率空间中操作，避免了常见的解释陷阱**，因而适合这种一次性评估场景。取 $\alpha = 0.05$ ，得到 95% 可信区间。

The analysis shows that 69% ($\pm 4.5\%$) of invalid triples stem from errors in entity annotation, while the remaining 31% are attributable to incorrect relation annotations. This pronounced disparity demonstrates that entity-related mistakes are the dominant source of invalid triples. More broadly, these findings emphasize that entity extraction is a bottleneck for relation extraction. In end-to-end pipelines, inaccuracies in entity recognition propagate to relation prediction, thereby imposing an upper bound on the overall performance of RE systems. Consequently, improvements in relation extraction are inherently capped by the quality of entity annotations.

分析显示 **69% ($\pm 4.5\%$) 的无效三元组源于实体标注错误**，其余 31% 归因于关系标注错误。这一显著差距表明实体相关的错误是无效三元组的主导来源。更广泛地说，这些发现强调**实体抽取是关系抽取的瓶颈**：在端到端流水线里，实体识别的不准会传播到关系预测，**从而给关系抽取系统的整体性能设定一个上限**。因此，关系抽取的改进本质上受实体标注质量的封顶。

In this work, we do not modify or refine entity extraction; our intervention is limited to enforcing structural consistency over the extracted triples. As a result, the performance gains we observe should be interpreted as conservative estimates. Moreover, since entity misannotations are also present in the evaluation data, correcting structurally inconsistent relations may correspond to semantically correct predictions in real-world settings, yet still be penalized under the current benchmark due to pre-existing entity annotation errors.

本工作不修改或精炼实体抽取；我们的干预仅限于在抽出的三元组上强制结构一致性。**因此我们观察到的性能增益应当被解读为保守估计**——联合处理实体级错误可以取得进一步改善。此外，由于实体误标也存在于评测数据中，**修正了结构不一致的关系在真实场景中可能对应语义正确的预测**，但在当前基准下仍会因既有的实体标注错误而被惩罚。

5. 训练效果

5.1 清洗数据集。 Correcting invalid triples would require manual inspection and revision of both entity types and relation labels. Given the large number of invalid triples (46,211), fully correcting them would entail extensive manual effort and substantial annotation cost. Instead, we adopt a conservative and scalable strategy: for each invalid triple, we remove the entity involved in the violation from the training set, thereby eliminating all triples associated with that entity within the document. This approach is significantly cheaper than manual correction, as it avoids entity re-labeling while ensuring that no structurally invalid triples remain. Overall, this procedure results in the removal of 208,665 triples and 3 documents.

修正无效三元组需要人工检查和修订实体类型与关系标签。鉴于无效三元组数量庞大（46,211 条），全部修正意味着巨大的人工投入和标注成本。**因此我们采取一个保守且可扩展的策略：对每个无效三元组，把违规涉及的实体从训练集中移除，从而消除该文档内与该实体关联的所有三元组。**这一做法比人工修正便宜得多，因为它避免了实体重标，同时确保不留下任何结构无效的三元组。整个过程共移除 **208,665 条三元组和 3 篇文档**。

Missing inverse relations are added automatically, resulting in the addition of 72,609 triples. Similarly to invalid triples, solving asymmetric inconsistencies requires the manual evaluation of 12,408 triples. Thus, we remove all entities involved in at least one asymmetric violation, resulting in the removal of 31,178 triples. As a result, the corrected distant dataset contains 1,338,404 training instances (–167,234 than DocRED distant) and 101,870 documents.

缺失的逆关系被自动补上，新增 72,609 条三元组。与无效三元组类似，解决非对称不一致需要人工评估 12,408 条三元组，因此我们移除所有至少涉及一次非对称违规的实体，共移除 **31,178 条三元组**。最终 corrected 数据集含 1,338,404 条训练实例（比 DocRED distant 少 167,234 条）、101,870 篇文档。

5.2 实验设置。 We leverage two DocRE models with leading performance and open-source implementations: ATLOP and DREEAM. We chose two transformer-based models because graph-based models cannot scale to the size of distant datasets. ATLOP exploits a BERT encoder to represent entity pairs enriched with localized context pooling; during prediction, adaptive thresholding is introduced to better handle multi-label classification. DREEAM is a teacher-student model, whose architecture is based on ATLOP enriched with an evidence-aware distillation mechanism.

我们使用两个性能领先且有开源实现的 DocRE 模型：ATLOP 和 DREEAM。**选择两个 transformer 系模型的原因是图式模型无法扩展到远程数据集的规模。** ATLOP 用 BERT 编码器表示实体对并辅以局部上下文池化；预测时引入自适应阈值以更好处理多标签分类。DREEAM 是师生模型，架构基于 ATLOP 并加入证据感知的蒸馏机制。

5.3 预测中的结构一致性。 Training DocRE models on structurally inconsistent data results in noisy predictions, with ATLOP appearing slightly more sensitive than DREEAM. The greater robustness of DREEAM may stem from its self-training procedure, which combines distant data with weak supervision signals provided by a teacher model trained on manual data.

在结构不一致的数据上训练 DocRE 模型会导致噪声预测，**ATLOP 看起来比 DREEAM 略微更敏感。** DREEAM 更强的鲁棒性可能源自它的自训练过程——把远程数据与一个在人工数据上训练的教师模型提供的弱监督信号结合起来。

The proportion of invalid triples in the predictions ranges from 0.85% to 1.61%, about one third of the rate observed in the training data. Missing inverse triples in the training set propagate almost linearly to the predictions: while 40.6% of inverse triples are missing in the dataset, the corresponding figures in the predictions range from 41.18% to 45.22%. A similar pattern holds

for asymmetric violations, where the 0.84% rate observed in the training data closely matches the 0.53%–0.79% range found in the predictions.

预测中无效三元组的比例在 0.85% 到 1.61% 之间，**约为训练数据中该比例的三分之一**。训练集中缺失的**逆关系三元组几乎线性地传播到预测中**：数据集中 40.6% 的逆三元组缺失，而预测中的对应数字在 41.18% 到 45.22% 之间。非对称违规呈现类似模式——训练数据中的 0.84% 与预测中 0.53% - 0.79% 的区间高度吻合。

In contrast, training DocRE models without logical inconsistencies consistently improves their ability to generate well-formed triples. On average, the proportion of invalid triples is reduced by –62.92%. The most substantial improvement is observed in inverse relation prediction: for ATLOP-RoBERTa, the percentage of missing inverse relations drops by –87.44%, and for ATLOP-BERT by –86.97%. DREEAM also benefits, with a reduction of –74.13%. In both architectures, asymmetric violations are nearly eliminated; training ATLOP-RoBERTa on structurally consistent data reduces asymmetric violations from 0.60% to 0.00%.

相反，在没有逻辑不一致的数据上训练能一致地改善模型生成良构三元组的能力。平均而言，**无效三元组的比例下降 62.92%**。最显著的改进出现在逆关系预测：ATLOP-RoBERTa 的缺失逆关系比例下降 **87.44%**、ATLOP-BERT 下降 86.97%、DREEAM 下降 74.13%。两种架构下**非对称违规都几乎被消除**——在结构一致数据上训练的 ATLOP-RoBERTa 把非对称违规从 0.60% 降到 **0.00%**。

5.4 对模型性能的影响。 We recall that the corrected dataset contains 167,234 fewer triples than DocRED distant. To ensure that any performance differences are not merely due to this reduction in training data, we additionally trained the models on a randomly subsampled variant obtained by removing the same number of triples from DocRED distant. This random subsampling was repeated with ten different seeds, and the mean performance is reported. The standard deviation is always below 1%.

需要提醒：corrected 数据集比 DocRED distant 少 167,234 条三元组。**为确保性能差异不仅仅来自训练数据量的减少，我们额外在一个随机下采样的变体上训练模型——从 DocRED distant 中随机移除同样数量的三元组。这一随机下采样用十个不同随机种子重复，报告均值，标准差始终低于 1%。**

Training ATLOP on the corrected distant dataset improves performance across all metrics and both transformer backbones. Relative to DocRED distant, structural correction yields average gains of +1.65% in precision, +3.10% in recall, and +2.69% in F1. The improvements are even more pronounced under ignored metrics, where entity pairs seen during training are excluded: on average, IgnPrec increases by +3.83%, and IgnF1 by +4.59%.

在 corrected 数据集上训练 ATLOP，在所有指标和两个 transformer backbone 上都提升了性能。相对于 DocRED distant，结构修正带来的平均增益是 precision +1.65%、recall +3.10%、F1 +2.69%。在**「忽略指标」下改进更明显**（该指标排除训练中见过的实体对）：IgnPrec 平均提升 +3.83%、IgnF1 提升 +4.59%。

DREEAM exhibits a similar overall trend, with improvements in all metrics except precision. Although precision decreases slightly (by -0.45% on average), this drop is compensated by major gains in the other metrics. Recall improves by $+14.07\%$ on average, with DREEAM-BERT achieving a boost of $+19.32\%$, while F1 rises by $+10.02\%$ on average. Under the ignored setting, IgnPrec increases by $+1.96\%$ and IgnF1 by $+10.67\%$.

DREEAM 呈现类似的总体趋势，除 precision 外所有指标都改善。虽然 precision 略微下降（平均 -0.45% ），这一下降被其他指标的大幅增益补偿。**recall 平均提升 $+14.07\%$ ，其中 DREEAM-BERT 达到 $+19.32\%$ ，F1 平均上升 $+10.02\%$ 。**忽略设定下，IgnPrec 提升 $+1.96\%$ 、IgnF1 提升 $+10.67\%$ 。

Random removal of triples leads to only marginal improvements in most metrics and even degrades performance in several cases: recall and F1 for ATLOP-RoBERTa, precision for both DREEAM variants, and IgnPrec for DREEAM-BERT. These findings indicate that the observed performance gains stem from the correction of structural errors rather than from the mere reduction in the number of training triples or documents.

随机移除三元组在多数指标上只带来边际改进，在若干情形下甚至使性能下降：ATLOP-RoBERTa 的 recall 和 F1、两个 DREEAM 变体的 precision、DREEAM-BERT 的 IgnPrec。**这些发现表明观察到的性能增益来自结构错误的修正，而不是仅仅因为训练三元组或文档数量减少了。**

6. 结论

We formalized the DocRE task as the construction of a KG under the RDF model and defined a set of logical constraints in OWL to detect inconsistencies. In particular, we identified invalid triples through domain and range constraints on object properties; missing inverse relations via `owl:inverseOf`; asymmetric violations using `owl:AsymmetricProperty`; and relation cardinality violations through qualified cardinality restrictions.

我们把 DocRE 任务形式化为 RDF 模型下的知识图谱构建，并在 OWL 中定义了一组逻辑约束以检测不一致。具体来说：通过对象属性的 domain 与 range 约束识别**无效三元组**；通过 `owl:inverseOf` 识别**缺失逆关系**；通过 `owl:AsymmetricProperty` 识别**非对称违规**；通过受限基数约束识别**关系基数违规**。

To better understand the cause of invalid triples, we conducted a qualitative analysis on a representative sample. Manual annotation revealed that almost 70% of invalid triples stem from named entity misannotations. This finding suggests that effective denoising strategies should not only target relation labels but also explicitly address entity-level errors.

为更好理解无效三元组的成因，我们在一个代表性样本上做了定性分析。人工标注揭示**近 70% 的无效三元组源于命名实体误标**。这一发现提示：**有效的去噪策略不应只针对关系标签，还必须显式处理实体层面的错误。**

Training DocRE models on structurally consistent data systematically lowers the number of structural violations in the predictions and leads to improved performance across nearly all metrics, with an average gain of $+6.36\%$ in F1 and $+7.62\%$ in IgnF1. These results highlight the

importance of structural data quality for both the reliability and the generalization ability of DocRE systems.

在结构一致的数据上训练 DocRE 模型系统性地降低了预测中的结构违规数量，并在几乎所有指标上带来性能提升，**平均 F1 增益 +6.36%、IgnF1 增益 +7.62%**。这些结果凸显了结构数据质量对 DocRE 系统的**可靠性与泛化能力**两方面的重要性。

7. 局限（作者自述）

To evaluate the performance gains resulting from structural noise removal, we rely on the ReDocRED test set, which itself contains (a limited number of) logical inconsistencies. An ideal evaluation benchmark for isolating the effects of ill-formed training triples would be entirely free of structural noise. However, re-annotating the ReDocRED test set could raise concerns about annotation bias, as such modifications might be perceived as being tailored to favor our approach.

为评估移除结构噪声带来的性能增益，我们依赖 ReDocRED 测试集，**而它本身就含有（数量有限的）逻辑不一致**。理想的评测基准应当完全没有结构噪声。然而重标 ReDocRED 测试集可能引起标注偏见的质疑，因为这类修改**可能被视为是为偏向我们的方法而定制的**。

Our noise mitigation strategy prioritizes entity removal rather than direct error correction. Correcting all ill-formed triples would require extensive manual revision of 58,619 instances, which would be prohibitively expensive. Instead, we chose to discard the affected entities, ensuring structural consistency while avoiding large-scale manual intervention. Future work could explore systematic re-annotation efforts to preserve a greater portion of the data.

我们的噪声缓解策略优先选择**移除实体**而不是直接纠错。修正所有病态三元组需要对 **58,619 个实例**做大规模人工修订，成本高到不可承受。因此我们选择丢弃受影响的实体，在避免大规模人工介入的同时确保结构一致性。未来工作可以探索系统性的重标工作，以保留更大比例的数据。

Since we interpret the performance gains from structural correction as the removal of an irreducible noise term in the supervision signal, our error analysis is primarily empirical and does not yet quantify the statistical significance of the observed improvements across different sources of structural violation.

由于我们把结构修正带来的性能增益解读为「移除了监督信号中一个不可约的噪声项」，**我们的误差分析主要是经验性的，尚未量化不同结构违规来源上所观察到的改进的统计显著性**。

参考链接

- github.com/mntrlra/DocRE-StructuralConsistency — 论文的开源工具包，含质量评估、数据清洗、预测结构分析三部分代码；兼容任何 DocRED 格式的数据集与任何自定义约束规则

- [Wikidata Property:P26](#) — 论文举的属性元数据例子 (spouse/配偶)。domain 从 `subject type constraint` 字段拿、range 从 `value type constraint` 拿、逆关系从 `inverse property` 拿, 这三个字段是本文所有约束的数据来源