

用知识图谱给行为去噪，但先要让证据可比 Adapting Knowledge Graphs for Behavior Denoising in Sequential Recommendation

本篇范围说明：这是一篇短论文（ISWC 2026 海报与演示分会，2026 年 10 月 27 - 29 日于意大利巴里；东北大学（沈阳）；许可 CC BY 4.0）。正文约四页。下面「全文翻译」一节覆盖正文全部五节——摘要、引言、相关工作、方法、实验结果与结论；数学公式的逐符号推导不译，只把每个式子在做什么用中文说清。

核心内容

Q：这篇论文要解决什么问题？

A：序贯推荐（根据一个用户的交互历史预测他下一个会点什么）面对的一个基本困难：

真实世界的日志混合了长期偏好、短期需求、探索行为和偶然行为，使得单条交互对序列建模的价值参差不齐。

换句话说：不是每一次点击都同样地代表这个人的偏好。一条与同序列中其他交互关联很弱的交互，既会扰乱历史表示，又会在被当作训练目标时提供不稳定的监督。

Q：已有的「行为去噪」方法是怎么判断哪条交互不可靠的？

A：主要靠三样——共现、顺序、或模型自己的预测。论文对这三样的批评是一句话：

这些从日志导出的信号并不直接提供用于评估一条交互的上下文支撑的、外部的、有类型的关系证据。

也就是说：它们都是在日志内部自我循环，没有引入外部知识。

Q：那用知识图谱不就行了吗？

A：这是这篇论文真正的贡献所在——它指出直接用图会引入一个系统性偏差。

图中更丰富的路径连通性并不必然意味着物品之间有更相关的关系。流行度更高、图上度数更高、或覆盖更广的物品天然就允许更多路径，而被许多物品共享的实体也会诱导出宽泛的连接。直接使用这些连

接，会让可靠性估计偏向连接丰富的物品和常见的关系模式。

结论那一句是全篇的方法论核心：

一条路径是否为当前这次交互提供了独特的支撑，必须对照结构上可比的参照物来评估。

Q：它怎么做的？

A：方法叫 **AdaptedKG**。它不把图的表示注入推荐模型，而是用两个**结构匹配**阶段，顺序执行，把全局图里的连接转换成针对单个行为样本的证据。

第一阶段：用「匹配的零假设上下文」做局部图适配。

给定一个上下文（用户的一段交互序列），要判断某个两跳关系模式在这个上下文里是不是「显著」。**难点在于：高覆盖本身说明不了问题，因为结构属性相近的上下文里可能出现同样的覆盖。**

做法是**造一批对照上下文**：把每个位置替换成一个**训练流行度、图上度数、连接状态都相近**的物品，**同时保持长度与顺序不变**。然后：只有当这个模式在真实上下文里的覆盖**超过对照组的中位数**时才保留它；而它在对照分布里排名越高，给的权重越大。

保留下来的加权路径构成**这个样本专属的局部图视图**。

第二阶段：用「匹配的参照物品」校准支撑度。

论文点出即使过滤了路径，**一个容易连接的物品仍然可能匹配上许多被保留的路径**。所以再按流行度、图度数、连接状态给待评估的物品匹配一批参照物品。

这里有一处顺序上的讲究：这些参照物品只在局部图视图固定之后才被打分，因此它们不能反过来改变被选中的路径。

最终得出一个**留存系数**（0 到 1）：历史交互的系数用来**缩放它的嵌入向量**，目标交互的系数用来**给它的损失重新加权**。

Q：怎么验证「校准」这件事真的起作用了？

A：**这是我认为这篇最漂亮的一处实验设计**：固定目标查询、局部路径视图、参照物品的数量，**只改变参照物品的采样方式**（均匀采样 vs 结构匹配采样），看留存系数与物品结构属性之间的相关性。

结构属性 均匀采样下的相关系数 结构匹配采样下

图上度数 0.286 0.057

物品流行度 0.200 0.068

相关性降到原来的五分之一到三分之一。这直接说明：估计出来的留存系数不再那么依附于物品自身的**结构曝光度**——也就是说，一个物品得分低，是因为它在这个上下文里确实缺乏支撑，而不是因为它冷门或度数

低。

Q：推荐效果如何？

A：在 Steam Games 数据集上（25389 用户、4089 物品、328278 条交互、462016 条图三元组、6 种关系），套在四个不同的骨干模型上，**每一项指标都有提升**。

骨干模型	HR@5（原→加持后）	NDCG@10（原→加持后）
SASRec（标准序贯推荐）	72.0 → 85.9	61.3 → 74.3
STEAM（去噪）	85.1 → 96.2	73.0 → 79.2
BirDRec（去噪）	78.3 → 86.0	66.5 → 71.6
SSDRec（去噪）	75.5 → 87.7	67.4 → 77.4

（数值均为原文的 $\times 10^{-3}$ 口径。HR 是命中率，NDCG 是带位置折扣的排序质量。）

两条解读值得记：在 SASRec 上的提升说明它**对一个本身没有去噪机制的标准模型也有效**；在另外三个上的提升说明它的图导出信号与**那些从日志学出来的去噪机制是兼容的、不是替代关系**。

消融实验的排序：去掉整个局部适配阶段掉得最多；去掉匹配零假设、或去掉匹配参照，掉得较少。**三者都掉**，说明两个匹配阶段各自有贡献而不是冗余。

Q：工程上有什么好性质？

A：**所有图处理都在离线完成**，用训练期交互和一份固定的图算出留存系数。**骨干架构不变，推理时完全不需要访问知识图谱**。

论文还写了退化处理：上下文长度不足 2、构造不出有效的对照组或参照集、或者没有路径被保留时，**留存系数取 1**（即不做任何调整），并跳过未定义的量。

背景补充 / 点评

先把两个术语落地。

序贯推荐就是「根据你最近看过/买过什么，猜你下一个要什么」。它和普通推荐的区别在于**顺序有意义**。

留存系数这个名字容易误解——它不是「保留还是删除」的二值决定，**是一个 0 到 1 的连续权重**，用来温和地压低不可靠交互的影响。论文自己用的词是「保守的」。

再说这篇对学员画像项目的用处，因为它指出的那个偏差我们的设计里可能也有。

学员画像的核心机制是**验证次数**：同一件事被独立观察到 N 次才进入活跃画像，供教学决策读取。8/24 定下的门槛还没定数（Ethan 说「三五次」，三还是五待定）。

这篇论文指出的偏差，翻译到我们的场景是这样的：

有些能力类别天然更容易被观察到。「框架型判断」这类宽泛的能力，几乎每个教学段都有机会表现；而某个窄的认知动作（比如「自评」）可能十段课才出现一次。用同一个固定门槛（比如 3 次）去卡这两者，等于假设它们的观察机会是可比的——而它们不可比。

后果和论文说的完全同形：宽泛的条目更容易攒够次数进入活跃画像，窄的条目长期卡在门槛下。而这不是因为窄的那件事不成立，是因为它的「曝光度」低。

这篇给的解法思路可以直接借：不要拿原始次数去比固定门槛，而是拿它和「结构上可比的参照」比——比如同一个 field 下、在同样多的教学段里出现过的其他 predicate，它们的次数分布是多少，当前这条排在什么位置。

但我不建议现在就做，理由有三条，而且第三条是最实在的：

其一，我们现在的数量根本不支持。论文那个匹配采样需要一个分布来做对照——它有 32 万条交互。我们现在是几十条记录，造不出对照组。

其二，论文自己的退化处理给了正确的过渡形态：构造不出有效对照时，系数取 1、不做调整。对应到我们这边就是「数据不够时就用固定门槛」，这正是现在的做法，它不是错的，是这个阶段的正确做法。

其三，也是最该记的一条——这个偏差现在就存在，只是还没到能测量的规模。所以正确的动作不是现在改机制，是现在把「每个 predicate 出现过多少个教学段」这个数记下来。它是将来做校准的必需输入，而如果不记，将来想做的时候历史数据补不回来。这和那份设计里已经用过的手法一样（来源字段先建空列、并把回填规则写死）。

第三处，那个「参照物品只在局部视图固定之后才打分、因此不能反过来改变被选中的路径」的顺序讲究，是一条通用的实验纪律。

它防的是用来做校准的东西反过来影响了被校准的对象——一种自证循环。同类形状在评测里很常见：用模型自己的输出去筛选测试样本、用被测系统导出问题和标准答案（8/23 读的那篇 agent 项目记忆论文里，「标准答案从一手来源撰写、绝不从图里来，因此图不能给自己打分」说的是同一件事）。判据一句话：校准物必须在校准对象确定之后才参与，且不能回流。

第四处，这篇和 8/23 读的那篇论文合起来，指向同一个更一般的判断。

那篇（Ontology-Grounded Project Memory）说：向量记忆的失败不是因为它不知道，是因为 top-k 检索一次只交出一个排序切片。这篇说：直接用图连通性的失败不是因为图不对，是因为连通性本身被流行度和度数污染了。

两者的共同形状是：一个看起来是「信息不足」的问题，实际是「度量口径不可比」的问题。而两者的解法也同形——不要改进那个度量本身，要给它换一个可比的基准（一个换成结构化枚举，一个换成结构匹配的对照组）。

最后说这篇该保持怀疑的地方，而且限制不少。

第一，它是海报与演示分会的短论文，不是完整的研究论文。四页，评测只有一个数据集。

第二，只在 Steam Games 一个数据集上验证。 4089 个物品、6 种关系，这是个小图。「结构匹配」这套做法在关系类型多得多、实体共享更严重的大图上是否还成立，这篇答不了。

第三，提升幅度需要看清口径。 SASRec 的 HR@5 从 0.0720 涨到 0.0859，看着是 19% 的相对提升，但绝对值是从 7.2% 到 8.6%。在这个绝对水平上，任何结论的实际意义都要打折，而论文没有讨论这一点，也没有给置信区间或多次运行的方差——四个骨干、每个一组数字，看不出这些差异是否稳定。

第四，没有报告计算成本。 论文强调所有图处理离线完成、推理不受影响，但离线那部分要为每个训练样本造一批对照上下文、再造一批参照物品，这个开销有多大没写。在 32 万条交互上可行，规模再大是否可行不清楚。

一句话版本：这篇的技术贡献不是「用知识图谱做去噪」（那是已有的方向），而是指出「图连通性本身被流行度和度数污染，不能直接当证据用」，并给出一个可验证的校正——用结构匹配的对照组把留存系数与结构曝光度的相关性从 0.286 压到 0.057；而它对学员画像的启示是：验证次数的固定门槛隐含了「各条目的观察机会可比」这个前提，那个前提不成立，现在该做的是把观察机会记下来、而不是改门槛。

文中金句

"Real-world logs reflect a mixture of long-term preferences, short-term needs, exploration, and incidental behavior, making individual interactions unevenly valuable for sequence modeling." 真实世界的日志混合了长期偏好、短期需求、探索行为和偶然行为，使得单条交互对序列建模的价值参差不齐。

"Existing denoising methods mainly rely on co-occurrence, order, or model predictions to identify such interactions, but lack evidence from explicit inter-item relations for making this judgment." 已有的去噪方法主要靠共现、顺序或模型预测来识别这类交互，却缺少来自显式物品间关系的证据来做这个判断。

"richer path connectivity in the graph does not necessarily imply more relevant relations between items." 图中更丰富的路径连通性，并不必然意味着物品之间有更相关的关系。

"Using these connections directly may bias reliability estimation toward richly connected items and common relational patterns." 直接使用这些连接，会让可靠性估计偏向连接丰富的物品和常见的关系模式。

"Whether a path provides distinctive support for the current interaction must therefore be assessed against structurally comparable references." 因此，一条路径是否为当前这次交互提供了独特的支撑，必须对照结构上可比的参照物来评估。

"They are scored only after g^*_C is fixed, so they cannot change the selected paths." 参照物品只在局部图视图固定之后才被打分，因此它们不能改变已被选中的路径。

"The substantially weaker correlations under matched sampling indicate that the estimated retention coefficients are less coupled to item-side structural exposure." 匹配采样下显著更弱的相关性表明，估计出的留存系数与物品侧的结构曝光度耦合更小。

全文翻译

摘要

序贯推荐从用户的交互历史预测下一个物品，但并非每一次交互都同等地有信息量。（真实日志的混合成分、以及已有去噪方法只依赖共现/顺序/模型预测的批评，见「核心内容」。）

Knowledge graphs offer this evidence, but item popularity, graph degree, uneven coverage, and widely shared entities can inflate connectivity and bias reliability estimates.

知识图谱能提供这种证据，但物品流行度、图上度数、覆盖不均、以及被广泛共享的实体，都会抬高连通性并使可靠性估计产生偏差。

本文提出 **AdaptedKG**，它为每个训练样本导出经过校准的图证据，而不向推荐模型中加入任何图表示。它先把观察到的上下文与结构上匹配的替代上下文相比较，识别出那些异常突出的关系路径并用它们构建一个局部图视图；再把每一次交互与结构匹配的参照物品相比较，在那个视图内校准它的支撑度。得到的留存系数用来门控历史表示、并给目标损失重新加权。

All sample-specific scores are computed offline using training interactions and a fixed KG, so the backbone remains unchanged and no KG access is required at inference.

所有样本相关的分数都用训练期交互与一份固定的图离线算出，因此骨干模型保持不变，推理时不需要访问图谱。

一、引言

（问题设定、三种已有信号的局限、以及「连通性不等于相关性」这一核心观察，见「核心内容」。）

论文对自己方法的定位是：**不是把图表示注入推荐骨干**，而是用两个角色不同、顺序执行的结构匹配阶段，把全局图里的连接转换成针对单个行为样本的「图一致性证据」，并导出保守的留存系数来调制训练信号。

二、相关工作

行为去噪这条线的三个代表：**STEAM** 从人工构造的被污染序列中学习逐物品的保留、删除、插入操作；**BirDRec** 用双向推荐器的预测来纠正不可靠的历史与目标，并带理论误差保证；**SSDRec** 利用交互导出的序列间关系来引导自增强与分层去噪。

论文对这三者的共同批评：

尽管机制各异，**这些方法的纠正证据都来自交互日志**——无论是通过合成监督、推荐器预测、还是学到的行为关系。这些从日志导出的信号，并不直接提供用于评估一条交互的上下文支撑的外部的、有类型的关系证据。

而基于图的推荐系统通常把图导出的表示整合进预测模型；**AdaptedKG 则是在推荐优化之前，用结构匹配的图证据离线导出以样本为条件的留存系数。**

三、方法

开篇一句点明整章的动机：

原始的图连通性在样本之间不可直接比较。 一个包含流行物品或高度数物品的上下文可能含有许多常见路径，而一个容易连接的候选物品也会因为同样的原因获得高支撑。

处理顺序是：**匹配的零假设上下文**先选出那些相对可比上下文而言脱颖而出的路径；**在这些路径固定之后，匹配的参照物品**再把支撑度转换成交互层面的留存系数。

3.1 以样本为条件的交互可靠性。 定义留存系数：历史位置上的每条交互，用**排除它自身所在位置之后**的上下文来给它打分（避免自我包含）；目标物品则对照完整的前缀来打分。前者缩放历史嵌入，后者缩放目标损失。

3.2 用匹配的零假设做局部图适配。 一个有向的、有类型的两跳模式通过一个连接体把一对有序物品连起来。在一个上下文里覆盖率高，本身并不使这个模式有信息量，因为结构属性相近的上下文里也可能出现相当的覆盖。

因此构造**匹配的零假设上下文**：把每个位置替换成一个**训练流行度、图度数、连接状态都相近的物品**，同时保持**长度与顺序**。

权重的两项含义：括号里那一项**只在覆盖率超过零假设中位数时才保留这条路径**；分位数那一项**在该覆盖率于零假设分布中排名更高时给出更大的权重**。权重为正的路径构成局部图视图。

3.3 匹配的支撑校准与训练适配。

即便经过路径过滤，一个容易连接的物品仍可能匹配上许多被保留的路径。

所以按同样三个结构属性给待评估物品匹配参照物品，并强调它们在**局部视图固定之后才打分**。支撑度是「连接该物品与上下文的、被保留路径权重的平均占比」；留存系数则把这个支撑度与参照物品的支撑度作分位比较——**排名在半数以下的给出小于 1 的系数，排在半数或以上的取 1。**

训练时，每个历史嵌入乘以其系数后再做序列编码；批内损失按目标系数加权平均（分母为正时），否则退回无权平均。

退化处理：上下文长度小于 2、构造不出有效的匹配背景或参照集、或保留路径集为空时，**图这条通道取系数为 1 并跳过未定义的量**。全局匹配统计使用训练分区；样本相关的留存系数离线算出，**并与推荐优化过程分离**。

四、实验结果

设置：Steam Games 数据集，规模与四个骨干模型见「核心内容」；全部在 RecBole 框架内实现。**每个骨干与其 AdaptedKG 增强版使用相同的数据划分、候选集与骨干超参数**。留存系数与交互导出的匹配统计只用训练期交互计算。

图侧校准（那个只改参照采样方式的对照实验）与**推荐性能、消融**的结果见「核心内容」。

五、结论

论文的收束是：用图关系来评估一次交互的上下文支撑；把观察到的上下文与结构相似的替代物比较，以识别并加权那些脱颖而出的路径；再用相似的参照物品校准交互支撑；得到的留存系数在训练时调整历史表示与目标损失。**所有图处理离线完成，推荐骨干与推理流程保持不变。**

参考链接

- ISWC 2026 — 国际语义网大会，本文在其海报与演示分会
- SASRec — 作为标准序贯推荐骨干的自注意力模型
- RecBole — 四个骨干模型的统一实现框架
- Steam — 数据集来源平台