

让答案「生来可审计」 Auditable by Construction: An Ontology-Driven Framework for Trustworthy LLM Analytics in Enterprise Finance

本篇范围说明：这是一篇预印本／工作稿（作者 Sergiy Lunyakin，独立研究者，IEEE 高级会员，西雅图；[未标注发表在哪个会议或期刊](#)）。下面「全文翻译」一节按章节覆盖摘要、引言的动机与缺口、六个阶段的机理、CARP 算法的四步、评测设置与五条结果解读、以及局限；[参考文献列表](#)、RDF 与属性图的完整代码清单、以及附录里的逐题数据不逐段译。

核心内容

Q：这篇论文的中心主张是什么？

A：一句话——[企业金融里采用大模型，卡住的不是流利度，是信任。](#)

在财务规划与分析以及其他受监管的工作流里，[一个答案只有在可追溯到权威来源、能用领域术语解释、并且事后可审计时，才是可用的。](#)

所以它主张：[面向企业金融的检索增强生成，应当在准确率之外、同时按「可审计性」来评估。](#)

Q：这个要求是论文自己提的，还是外部强加的？

A：[是监管强加的，这一点它举了具体依据。](#) 美联储与货币监理署 2011 年的模型风险管理指引要求：模型的文档必须详细到一个独立方能理解它如何运作、输入输出必须可追溯、并且要经得起「有效挑战」（由客观且知情的评审者做批判性分析，能指出局限并迫使改变）。而 NIST 2023 年针对人工智能的指引把同一逻辑延伸：把「能解释系统输出」当成管理其风险的前提条件，而不是可选的增强项。

[它还引了一条人机信任的研究结论](#)：恰当的信任取决于操作者能否把自己的信心校准到系统的实际能力上，而这又取决于系统是否暴露了足以支撑这种校准的信息；隐藏自身依据的系统，产生的要么是错置的依赖、要么是全盘拒绝。

Q：框架长什么样？

A：叫 [KDFAF](#)（知识驱动分析框架），六个阶段，顺序但可迭代。

阶段	做什么	关键点
一、以问题为中心的界定	从一个业务问题出发，而不是数据问题。把「Q2 运营费用为什么涨了」这类挑战转成一组能力问题	保证后续每个模型部件都对齐业务价值，防止造出脱节的或纯技术性的 schema
二、本体自举	把能力问题拆成实体、指标、关系，形成一张最小可行图；再与已有上层本体（金融业务本体 FIBO）交叉引用	专治冷启动——没有既有 schema 时怎么从异构数据建起
三、schema 引导的知识抽取	大模型在 schema 约束下工作，把文本映射到预定义的本体类，而不是做自由抽取	抽取中发现的新实体可触发本体演化
四、带上上下文的知识表示	给关系加上上下文相关性类型（因果驱动／支持性证据／相关性）、置信度、来源引用	让图能表达「这条事实为什么要紧」，而不只是陈述它
五、混合式知识校验	自动一致性检查（如生效日期必须晚于发布日期） + 低置信度关系标为「待校验」+ 领域专家在专门界面上复核	决策带财务与监管后果的场景里必需
六、CARP 检索	见下	把检索轨迹作为一等输出

Q：第四阶段那个「上下文相关性类型」具体解决什么？

A：它让系统能区分「某个差异的成因」和「只是和它同时出现的事实」——而这个区分是扁平检索表达不了的，因为那里的相关性只有一个不加区分的相似度分数。

三种类型带不同的传播权重：**因果驱动 1.00、支持性证据 0.60、相关性 0.30**。相关性那一档的权重低到通常在第一跳之外就被边界检测剪掉。

还有一处设计值得单独说：来源被建模成一等的、可遍历的结构，而不是检索之后再贴上去的元数据。 每个证据节点都能通过一条显式的 **实体 → 申报文件 → 页 → 证据** 链到达——这正是检索轨迹之所以可能的原因。

Q：为什么同时用 RDF 和属性图两套表示？

A：这一段的说法很干净：

RDF 规格是那个可移植、对齐标准的产物：它使得与 FIBO 对齐、跨金融领域复用、以及独立于任何数据库厂商的检查成为可能。**因为 RDF 不能直接给一条三元组加注解，**那条关系被具体化成一个一等的「上下文关系」资源。**属性图的物化则把同样的信息原生表达成边上的属性，**这使得遍历时加权很便宜——CARP 直接从边上读相关性类型与置信度，而不必在每一跳去解析一个具体化节点。

结论一句：**规格管意义，物化管遍历。**

Q：CARP 是什么？

A: **上下文感知的相关性传播**，一个基于图的证据检索算法。它与标准图遍历的区别是：**按本体定义的关系语义与硬性分析边界来约束扩展，并且保留产生该结果的决策记录。**

四步：

- 1. **种子节点识别**——找出与查询相关的实体，**每个都记下它的匹配理由与置信度**
- 2. **加权传播**——用本体定义的关系权重向外扩展
- 3. **上下文边界检测**——按一个**动态的、逐深度**的相关性阈值限制遍历
- 4. **证据选择**——对可达且合格的证据排序，把有限数量的条目连同它们的来源链序列化，作为大模型的上文输入

遍历阶段被完整序列化成一份检索轨迹：哪些实体做了种子、走了哪些有类型的路径、阈值在哪里做了决定、以及端到端的来源。

Q：评测结果如何？

A：在 **FinanceBench 的 145 道题**上，对比五个条件：零上下文推断、BM25 稀疏检索、在文本与表格上做概念加权的词法检索、无本体约束的图遍历、以及 KDAF。

五条结论，其中第二条是负面的、而论文把它和正面结论同等醒目地报了出来。

第一，检索是必需的。 零上下文推断只有 **4.1%** 的自动正确率（人工复核 16.7%），而每一个检索增强条件都在 10 - 12%。而且它完全不产生引用——一个不能引用的系统，原则上就无法被审计。

第二（这条是负面结果）：在这个基准上，图结构不能靠答案正确率养活自己。

四个检索条件的自动正确率跨度是 0.103 到 0.117，区间大幅重叠，**KDAF 与 BM25 的配对比较是 -0.007（95% 区间 [-0.021, 0.000]；0 胜 1 负 144 平）。**

论文自己给的解释：**FinanceBench 的问题以单文档的证据查找为主、候选池又小，在这种情形下词法匹配已经接近够用，关系结构没有发挥余地。** 它进一步写道：

「图检索能普遍改善答案准确率、优于稀疏检索」这类主张在此得不到支持，为文档查找类工作负载选架构的实践者应当掂量这一点。

第三，在引用可追溯性上排序反转，而且差异有统计支持。

条件	引用可追溯性 F1	与 KDAF 的差
KDAF	0.515	—
无本体约束的图遍历	—	-0.027（区间 [+0.006, +0.050]，11 胜 3 负 131 平）
BM25	—	-0.052（区间 [+0.024, +0.083]，23 胜 4 负 118 平）

两个区间都不含零。

而论文对这个 0.515 的解读格外诚实：这个指标按精确的证据标识计算，所以接近 0.5 意味着评审者需要核对的引用里大约有一半与权威集合对得上——控制人员会发现相当一部分被引证据正确，另有相当一部分缺失或多余。

这里测的任何一个条件，都产不出「引用可以不经检查就接受」的答案，本文也不作此宣称；这个比较确立的是：以本体为根基的检索降低了核验负担，而不是消除了它。

这一条的形状论文自己点破了，而且很有教益：

在「答案对不对」上不可区分的那些系统，在「答案可不可归因」上是明显可区分的。

原因也说清了：本体定义的关系权重作用在「哪些证据被浮出、以及它们如何被链接」上，而不作用在最终的答案字符串上——所以效应出现在可追溯性而不是正确率上。更具体地：词法相似度在最终证据选择里占最大的单项权重，所以 KDAF 与一个强词法检索器的答案内容会收敛；本体导出的那些项（传播分、概念覆盖、周期覆盖）加上硬性的实体资格，只是在词法上可信的那个集合内部重新排序。

第四，图结构强加了一种词法打分无从表达的「实体纪律」。

条件	选到「问题主体公司之外」的证据
KDAF	0 / 426
无本体约束的图遍历	0 / 424
BM25	16.8%
词法混合	20.2%

论文的措辞很准：图条件里的公司边界是一条被强制的约束，而不是一种倾向；在词法基线里公司对齐是涌现出来的，而且它们的打分函数里没有任何东西能表达这条约束、哪怕你想要它。

报告期那一栏同样的模式但没那么绝对：KDAF 返回跨期证据的比例 20.5%，BM25 23.0%、混合 25.3%、无约束遍历 28.2%——KDAF 是所有条件里最好的，但远不是零，因为报告期在 CARP 里是一个软打分项、不是硬过滤。

另外：每个被选中的条目都能解析到一条完整的来源链，零解析失败；145 道题的检索在多次独立执行下逐题重放一致。

第五，审计轨迹不是免费的，而且有一条效率宣称没能通过测量。

KDAF 组装的检索上下文是所有条件里最大的（平均 1581 token，词法混合是 1402），端到端延迟中位数也最高（8.3 秒对 6.6 秒）。

因此「检索上下文更精简」这个读法得不到支持：组装出来的上下文是有界的、连贯的，但它并不比词法检索提供的更小，我们不为它作任何效率宣称。

但成本要拆开看：检索本身可忽略不计——中位数 4.1 毫秒，不到响应时间的 0.1%。所以多出来的延迟归因于在更大的上下文上做生成，而不是检索。

背景补充 / 点评

先解释三个词，否则上面那些结论落不了地。

FP&A 是「财务规划与分析」，企业里做预算、预测、差异分析、并给管理层写解释的那条职能。它是受监管的工作流，所以「答案要能被审计」不是一句漂亮话，是硬要求。

FinanceBench 是一个金融问答基准，题目基于上市公司的公开申报文件。它的性质决定了这篇论文那个负面结果——论文自己指出它以单文档的证据查找为主。

引用可追溯性 F1 衡量的是「系统给出的引用」与「权威证据集合」之间的重合度，按精确标识匹配。这里有一个必须注意的口径细节：论文写明匹配是精确且未归一化的，引用到了正确的页但用了不同的标识粒度会算作未命中，所以这些值是人类评审者能认可的对齐度的下界。

再说这篇对手上两个项目的直接用处，先说 prove，因为几乎是同一个问题。

prove 做的是把自然语言问题编译成对数据仓库的查询并作答。这篇论文的核心论点——「准确率不是结构化检索赚回建设成本的那根轴，可审计性才是」——如果成立，对 prove 是一个方向性的提示。

但要小心，它的证据只支持一半。它证明了「本体接地的检索在可追溯性上显著更好」，但它同时证明了「在答案正确率上无差别」，而且那是在一个单文档查找为主的基准上。prove 面对的问题形态不同（跨表、带口径定义、需要派生计算），在那种形态下关系结构有没有正确率上的贡献，这篇答不了。直接把它的结论搬过来会搬错。

真正可以立刻搬的是它那套「轨迹作为一等输出」的做法。CARP 把四样东西序列化下来：哪些实体做了种子以及每个种子的匹配理由与置信度、走了哪些有类型的路径、阈值在哪一步做了决定、端到端的来源链。prove 现在的日志里有执行过程，但「为什么选了指标 A 而不是 B」这个决定的理由是不是被结构化记下来了，是一个可以马上去查的问题。如果没有，那么当一个答案出错时，排查只能靠重跑和猜。

第二处能搬的是那个「硬约束 vs 软打分」的区分，它比听起来更有分量。

这篇的实体边界是 0/426，因为公司归属是一条被强制的约束；而报告期是 20.5%，因为它只是一个软打分项。同一个系统里，两个看起来同类的限制，一个做到了零、一个还有两成——差别就在硬和软。

这一条对 user_profile 的判重键设计直接对应。8/24 定下的判重键是 (learner_id, field, predicate, scale, condition) 在 status='active' 上唯一——那是一条硬约束（数据库层面的唯

一索引)，所以它做得到零。而如果当时选的是「在服务里比较相似度再决定算不算同一条」，那就是软打
分，会有一个永远消不掉的错误率。这篇给了那个决定一个外部的、量化的支持。

第三处，那个「六阶段」里第一阶段的措辞值得记下来。

从一个业务问题出发，而不是数据问题……这一步保证后续每个模型部件都直接对齐业务价值，防止造
出脱节的或纯技术性的 schema。

这和 user_profile 那边正在做的事同形——受控词表提案要 PM 填的是「学员的能力类别」这类业务条目，
而不是让工程侧先设计一套结构再请业务往里填。两边独立走到同一处。

第四处，一个可以直接用的连带发现：这是我一周内读到的第三篇「主动否掉自己头条卖点」的论文。

论文	被否掉的卖点	价值被挪到哪
Agentic-SQL Revisited (8/22 读)	不重跑任何系统、不造可比性	每格带引用、不确定就留空
给写代码的 agent 一份有类型的项目记忆 (8/23 读)	检索精度不是区分点 (斜率置信区间跨零)	完备性、不存在、取代链——top-k 按形状答不了的三类问题
本篇	答案正确率上与 BM25 不可区分 (-0.007, 区间含零)	引用可追溯性、实体边界、来源链完整性

三篇的共同形状是：把一个「更好」的笼统宣称，换成「在某一根轴上明显更好、在另一根轴上明确更不好」。而三篇都是先给出否定的那一半。这个写法本身值得学——它让读者能判断这个东西适不适合自己的场景，而笼统的「更好」做不到。

最后说这篇该保持怀疑的地方，而且这一篇的保留意见比前两篇多。

第一，它是预印本／工作稿，作者是独立研究者，没有标注同行评审的发表去向。前面读的 Agentic-SQL 是 CIKM 会议论文、项目记忆那篇是 NeSy 会议论文，这一篇没有这层背书。

第二，六个阶段里只有三个被评测了。论文自己在图注里写明：阶段三、四、六在评测中被实例化；阶段一、二、五需要领域专家与组织语境，公开基准提供不了，因此没有被执行。也就是说**「以问题为中心的界定」「本体自举」「混合式校验」这三样——恰好是这个方法论最费人力的三样——一个都没验过。**

第三，第四阶段那个最漂亮的机制根本没被实例化。上下文相关性类型（因果驱动／支持性证据／相关性）在被评测的那张图里不存在，因为基准里没有叙述性评论可供指派因果或支持角色。论文诚实地标注了这一点，但这意味着「区分成因与巧合」这个核心卖点是设计层面的、未经检验的。

第四，绝对正确率低到需要提醒。最好的条件也只有 11.7% 的自动正确率、30.0% 的人工复核正确率。在这个量级上讨论「哪个架构更好」，任何差异的实际意义都要打折。论文没有回避这个数，但也没有正面讨论它对结论强度的影响。

一句话版本：这篇主张「可审计性、而非答案准确率，才是本体接地的检索赚回其建设成本的那根轴」，并且用一个明确的负面结果（与 BM25 在正确率上差 -0.007、区间含零）和一个明确的正面结果（可追溯性 F1 高 0.052、区间不含零，且跨公司证据 0/426 对 16.8%）把这个主张钉住；但它是未经同行评审的工作稿，六阶段里三阶段未验，最漂亮的那个机制在评测图里根本没实例化。

文中金句

"Enterprise adoption of large language models in finance is constrained less by fluency than by trust." 企业在金融领域采用大模型，受到的约束与其说来自流利度，不如说来自信任。

"an answer is usable only if it is traceable to authoritative sources, explainable in domain terms, and auditable after the fact." 一个答案只有在可追溯到权威来源、能用领域术语解释、并且事后可审计时，才是可用的。

"systems that conceal their basis produce either misplaced reliance or wholesale rejection." 隐藏自身依据的系统，产生的要么是错置的依赖、要么是全盘拒绝。

"a system that cannot cite cannot be audited even in principle." 一个不能给出引用的系统，原则上就无法被审计。

"Claims that graph-based retrieval generically improves answer accuracy over sparse retrieval are not supported here." 「图检索能普遍改善答案准确率、优于稀疏检索」这类主张在此得不到支持。

"the same systems that are indistinguishable on whether the answer is right are clearly distinguishable on whether the answer is attributable." 在「答案对不对」上不可区分的那些系统，在「答案可不可归因」上是明显可区分的。

"No condition measured here produces an answer whose citations can be accepted without inspection, and the paper does not claim otherwise." 这里测的任何一个条件，都产不出引用可以不经检查就接受的答案，本文也不作此宣称。

"The company boundary in the graph conditions is an enforced constraint rather than a tendency; in the lexical baselines company alignment is emergent, and nothing in their

scoring function could express the constraint even if it were wanted." 图条件里的公司边界是**一条被强制的约束、而不是一种倾向**；在词法基线里公司对齐是涌现出来的，而且它们的打分函数里没有任何东西能表达这条约束、哪怕你想要它。

"Provenance annotations are modeled as first-class, traversable structure rather than as metadata attached after retrieval." **来源注解被建模成一等的、可遍历的结构，而不是检索之后再贴上去的元数据。**

"The specification governs meaning; the materialization governs traversal." **规格管意义，物化管遍历。**

"A minimality reading of the retrieved context is therefore not supported ... we make no efficiency claim for it." 因此**「检索上下文更精简」这个读法得不到支持……我们不为它作任何效率宣称。**

全文翻译

摘要

（要点见「核心内容」，此处只补三处原文表述。）

论文把 KDAF 描述为通过六个迭代阶段构建以本体驱动的知识系统：**以能力问题做问题中心的界定、通过最小可行图做本体自举、schema 引导的知识抽取、带有类型化相关性与来源注解的上下文知识表示、混合的人在环校验、以及用于基于图的证据检索的上下文感知相关性传播**——使得每一条被检索到的事实都携带它的关系类型、置信度与来源谱系。

三条发现构成结果：**第一，检索是必需的**；第二，在答案正确率上各检索条件在统计上不可区分……所以单靠准确率并不足以在单文档申报类问题上证明结构化检索的成本是值得的，我们把这个负面结果明确报告出来；第三，在可审计性所依赖的那些属性上，排序反转了。

一、引言

1.1 动机。用于财务决策的分析模型在明确的监管期待下运作（2011 年模型风险管理指引、NIST 2023 年可信人工智能框架的具体要求见「核心内容」）。一个在没有可复核的证据说明的情况下产出财务分析的系统，无论它的输出多么流利，都不满足这些期待。

论文强调这个要求**不只是程序性的**，并引了人机信任与可解释性两条研究线：可解释性的工作区分了**「满足真实评估需求的解释」与「仅仅看起来令人满意的解释」**。而在一个承担审计责任的场景里，**这个评估需求**

是具体的：评审者必须能够判定哪些证据支撑了某个结论，以及那些证据为什么被选中。

1.2 科学语境与缺口。 知识图谱已成为企业信息系统的基礎；在金融领域，它的使用主要集中在欺诈检测、信用风险评估、反洗钱与合规。而把知识图谱整合进财务规划与分析的工作流——具体说是对规划周期、差异分析与叙述性解释做分析推理——在研究文献里基本还未被探索。

关于文本转 SQL 那条线，论文的批评是：这些方法以 schema 驱动为主、缺少内嵌的语义上下文，因而削弱了它们产出「一致、可追溯、且对财务决策者有意义」的解释的能力。

而标准的向量式检索增强生成缺少揭示因果链与多跳关系所需的结构化关系推理。

论文点出的那个更少被检视的问题是：

同样重要、而检视得更少的，是一个检索架构能就它自身的行为暴露些什么。扁平的检索器——不论稀疏还是稠密——用一个相似度分数来为它的选择辩护，而那不是一个财务控制人员或审计师能据以行动的解释。

1.3 三个研究问题：以问题为中心的本体驱动方法论能否可靠地指导从异构企业财务数据构建语义连贯的知识图谱；本体接地的图检索是否比无接地的检索基线产出更完整、更可追溯的回答；本体接地的检索在多大程度上暴露出一条可审计的推理路径——种子实体、有类型的遍历、来源——而扁平检索架构在结构上无法提供这条路径。

1.4 贡献。 三条，其中第三条的措辞值得原样记下：在 145 道题上对四个基线做概念验证评测，以同等的醒目程度报告一个负面结果和一个正面结果。

二、KDAF 的六个阶段

（六个阶段的内容、上下文相关性类型的三档权重、RDF 与属性图两级表示的分工，均见「核心内容」一节，不重复。）

关于第六阶段 CARP 与标准图遍历的区别，原文的说法是：它按本体定义的关系语义与硬性的分析边界来约束扩展，并且保留产生其结果的决策记录。四个步骤及其记录的内容见「核心内容」。

论文另外说明了一处评测中未启用的能力：在本文评测的配置里，第四步返回的是一个有序的证据块集合，而不是一个连通的子图；在明确上下文预算下做连通性感知的组装，属于另一个配置，本文没有执行。

三、案例与设计场景

论文用一个财务规划与分析的差异分析场景说明第四阶段那套表示：把控制人员的叙述性评论与一个已报告的差异之间的关系具体化，使它能够携带自己的相关性类型、置信度、校验状态与来源。这个子图组装出来的解释，能把一个差异的驱动因素与仅仅和它同时出现的事实区分开——而这个区分是扁平检索无法表示的。

四、评测

4.1 设置。 基准是 FinanceBench 的 145 道题；五个条件是零上下文推断、BM25、在文本与表格上的概念加权词法检索、无本体约束的图遍历、KDAF。

论文在这里做了一处重要的范围声明：图注明阶段三、四、六在评测中被实例化；阶段一、二、五预设了领域专家与组织语境，而一个公开基准提供不了这些，因此没有被执行。同时说明上下文相关性类型虽已在规格中定义且在开发中，但没有在被评测的那张图里实例化，因为基准里没有可供指派因果或支持角色的叙述性评论。

4.2 与 4.3 结果与解读。 五条结论的数字与措辞见「核心内容」一节。

4.4 试点的局限。（与第 5.2 节的局限一并见下。）

五、讨论

5.1 科学含义。 论文的落点是：**可审计性、而不是原始的问答准确率，才是以本体为根基的检索赚回其建设成本的那根轴**，并据此提出它所推动的、对齐财务规划与分析的评测方式。

5.2 局限。 除了前面已明确报告为「发现」的负面结果之外，论文列出的主要限制包括：基准的问题形态（单文档证据查找为主、候选池小）限制了关系结构的发挥余地；可追溯性指标按精确标识匹配、不做归一化，因而是下界；以及六阶段中三个阶段未被执行。

5.3 未来工作。 包括对上下文相关性类型做实际实例化后的评测。

5.4 参考实现与采用路径。 描述了一个「预算化组装」配置——在明确的上下文预算下做连通性感知的组装，本文未执行。

5.5 代码与数据可得性。（原文给出，此处不转述。）

参考链接

- [FinanceBench](#) — 本文评测所用的金融问答基准，145 道题
- [FIBO 金融业务本体 \(EDM Council\)](#) — 第二阶段做交叉引用的上层本体
- [美联储与货币监理署 2011 年模型风险管理监管指引 \(SR 11-7\)](#) — 「可追溯、经得起有效挑战」这些要求的出处
- [NIST 人工智能风险管理框架 \(2023\)](#) — 把「能解释输出」定为管理风险的前提条件
- [GraphRAG \(Edge et al., 2024\)](#) — 图检索增强生成那条线的代表工作