

先判哪些值该有独立身份 Automated Construction of FAIR Digital Object Knowledge Graphs from Flat Cultural Heritage Records

本篇范围说明：这是一篇 6 页的会议论文（弗劳恩霍夫应用信息技术研究所 FIT，Zeyd Boukhers 等四人，arXiv 2608.23263v1，2026-08-24，从代码仓库名看投的是 CIKM）。下面「全文翻译」按原文章节推进，覆盖摘要、§ 1 引言、§ 2 相关工作（五小节）、§ 3 系统总览（四个阶段）、§ 4 评估（两个研究问题 + 讨论 + 局限）、§ 5 结论。表 1、表 2 的完整数值在「核心内容」里给，翻译部分只取结论句；参考文献 28 条不译。

核心内容

Q: FDO 是什么？这篇要解决的问题是什么？ A: FDO (FAIR Digital Object, FAIR 数字对象) 是一个让数字资源无需人类中介就能被机器发现、访问、互操作、复用的操作性架构。它的一条核心要求是：**元数据的属性值要表达为持久标识符 (PID) 而不是纯字符串**，目标是产生一个完全机器可操作的图，其中每个引用都能被算法解析、类型化、遍历。**只有终端叶值**（数值测量、自由文本注释、日期、校验和）**可以保留为字面量**。

问题在于：**Europeana Data Model (EDM) 的设计远早于 FDO 规范，它把大多数元数据值存成纯文本**。作者的原话很准：「这对人浏览够用，但给自动化 agent 留下了任何可跟随的东西都没有。」

具体到字段层面：一条记录的 `dcterms:spatial` 字段里通常是字符串「Bracara Augusta」而不是解析到 Place FDO 的 PID；`dcCreator` 存的是「Cristina Braga」而不是 VIAF 或 ORCID 引用。后果是**没有自动化 agent 能从一个物件走到它的发现地、或把同一次发掘的所有物件关联起来**。作者举了一个特别具体的例子：它甚至无法知道「Braga」和「Bracara Augusta」指的是同一个地方。

Q: 这篇的核心技术挑战被定义成什么？ A: **不是实体链接**。作者把它明确定义为「自动执行 FDO 规定的那条边界」——哪些值**必须**成为 PID 引用（可解析实体），哪些**可以**保留为字面量（终端叶：注释、测量、日期）。

这条边界由 FDO 架构本身定义，而不是由某个基准定义：

一个值是 PID 引用，当且仅当它指代一个可复用的真实世界实体（地点、材料、行动者、事件、概念）。否则它保留为字面量。

作者在相关工作里把这个区别说得很清楚：那些已有的流水线「**链接的是已经作为实体交给它们的提及；而我们必须先决定哪些值根本不算实体**」。

Q: 流水线是什么样的? A: 四个阶段。

阶段 1 · 槽位抽取与先验赋值。 从 Europeana Search API 的 rich profile 取记录，分解成 (field, value) 槽位。每个字段带一个先验语义类 (dctermsSpatial → PLACE、edmTimespan → PERIOD)，LLM 可以覆盖它。

有一个绕过设计：值已经是 Europeana 富化流水线产出的 URI 的槽位，直接按 URI 域名分类并跳过 LLM (Getty TGN → PLACE、AAT → OBJECT_TYPE、ULAN → ACTOR)。

阶段 2 · PID/字面量边界分类。 对每个非预链接的槽位，给 LLM (field, value) 加记录上下文 (title、type、country)，一次结构化 JSON 调用输出三样东西：

- 1. 一个 16 类分类法里的语义类型
- 2. 一个二元 **resolvable** 决定（这就是 PID/字面量边界的实现）
- 3. 解析的目标词表 (AAT、Wikidata、VIAF、PeriodO)

阶段 3 · 实体解析与链接。 用 LLM 生成的搜索串查目标词表的 API。有**词表回退链**保证鲁棒性：VIAF → Wikidata、AAT → Wikidata、PeriodO → AAT → Wikidata。PLACE 值路由到 Wikidata——**GeoNames 没用，因为没有 endpoint 凭据**（作者直接写了这个实际原因）。多个候选置信度相近时，LLM 用记录上下文重排。

阶段 4 · FDO 图构建。 解析出的实体被实例化为完整 FDO，分两层：

- **Kernel Record (内核记录)：** 一个精简的结构外壳，只含 PID——本 FDO 的 PID、FDO Type PID、FDO Profile PID、Metadata FDO PID、Content PID、适用的 Operation PID、时间戳、校验和。内核里不驻留任何领域语义。
- **Metadata FDO：** 一个单独的 FDO，承载 CIDOC-CRM 属性断言。Object FDO (E22_Human-Made_Object) 通过 CRM 属性链到实体 FDO：

CRM 属性	指向	CIDOC-CRM 类
P53_has_former_or_current_location	Place FDO	E53
P45_consists_of	Material FDO	E57
P14_carried_out_by	Person FDO	E21
P50_has_current_keeper	Group FDO	E74
P2_has_type	Type FDO	E55
P10_falls_within	Period FDO	E4

P14 和 P50 分开是刻意的：把「行动的那个行动者」与「持有物件的那个机构」分开。

两个架构决定值得单记：

一、属性的宾语是其他 FDO 的 PID，不是词表 URI 本身。外部 URI（如 `http://vocab.getty.edu/tgn/...`）只作为实体 FDO 自身上的 `owl:sameAs` 出现。

二、自描述基础设施。FDO Type（Place、Material、Actor 等）和 FDO Operation（Resolve、GetMetadata、Validate、Link）它们自己也是带 PID 的 FDO，注册在类型/操作注册表里。这让图可以被机器导航，而不需要带外文档（out-of-band documentation）。

Q：数据和结果是什么？ A：637 条考古记录，来自五个 Europeana 数据提供者、横跨四个国家，产生 12,720 个元数据槽位。其中 9,197 已经带有 Europeana 富化的词表 URI，只有 3,523 是纯字符串。

LLM 是一个 1,200 亿参数的指令调优模型（`gpt-oss-120b`），temperature 0，每个响应都缓存，使重跑确定性。637 条记录全部由 LLM 处理。

槽位级解析率（作者全文都把这两个数分开报）：

Europeana 预链接 URI $9,197 / 9,197 = 100\%$ （构造所致，非测量）
流水线自己解析的 $1,798 / 3,075 = 58.5\%$
合并 $10,995 / 12,272 = 89.6\%$

内容承载字段上，流水线产出 800 个实体 FDO 和 9,054 条 CIDOC-CRM 边。

Q：连通性这个指标说明了什么？这部分是全篇最诚实的地方 A：作者把「机器可操作性」操作化为图连通性——两条记录之间机器 agent 能遍历，当且仅当它们共享至少一个节点。比较 `G_flat`（记录通过在 ≥ 2 条记录里出现的字节相同字符串连接）与 `G_FDO`（记录通过共享实体 FDO 连接）。

他们先说了必须加两个控制：

- 1. 两个图必须从同一槽位总体构建——一个排除了 FDO 图所计入的 URI 值槽位的基线，在构造上就更弱。
- 2. 连通性会饱和。一个 Creative Commons 权利 URI 出现在 637 条记录中的 589 条里，单靠它就把 flat 图连通了；聚合器的 `organization` URI 对 FDO 图做同样的事。有了这些枢纽，三个图都塌成单个分量，指标什么都区分不出。所以把两个图都限制在内容承载字段，并丢掉任何在超过 10% 的记录里出现的值。

结果（表 1）：

指标	G_flat+（全部内容值）	G_flat=（同槽位）	G_FDO
使用槽位	12,720	10,995	10,995
不同共享节点	479	359	369
连通分量	8	32	20
最大分量（占记录%）	71.6%	69.4%	73.6%
跨提供者桥	13	12	13

指标	G_flat+ (全部内容值)	G_flat= (同槽位)	G_FDO
带可解析 URI 的节点	63.8%	63.8%	100% (构造所致)
合并的表面形式	0	0	176

同样的 10,995 个槽位下，实体解析把分量从 32 降到 20、最大分量从 69.4% 升到 73.6%。但给定全部 12,720 个内容值，字符串匹配达到 8 个分量——流水线未链接的那些值仍然作为字节相同的字符串把记录连起来。

作者的结论写得非常直接：「连通性因此无法以稳定的方式区分这两种方法，而且它的方向取决于一个指标本身并不固定的槽位总体选择。」原因也说清了：Europeana 已经为 65% 的槽位提供词表 URI，而那些 URI 在记录之间字节相同，所以字符串匹配无需任何解析步骤就能恢复它们。

Q：那到底什么把 FDO 图和字符串匹配区分开了？ A：两个属性，都不是连通性：

一、每个节点都带一个可解析的外部标识符和一个语义类型（G_FDO 是 100%，而 G_flat 只有 63.8% 的节点恰好是 URI 字符串，其余是裸字面量、不支持任何进一步解析）。

二、33 个实体 FDO 吸收了 176 个字节相同匹配所分开的不同表面形式。

作者人工复核了全部 33 个合并：17 个正确、16 个不正确。而且两组的形状完全不同：

- 正确的那 17 个吸收 34 个表面形式，但附着到 327 条记录——都是地点和组织的跨语言或变体对齐：Athens / 「Αθήνα」跨 135 条记录、National Theatre of Greece / 「Εθνικό Θέατρο」跨 29 条、Epidauros / 「Επίδαυρος」跨 12 条。
- 不正确的那 16 个吸收 142 个形式，但只跨 163 条记录，而且集中在 PERIOD 类：59 个形如 share3d:*/TMP.1 的内部记录标识符解析到一个标为「Human parainfluenza virus 1」（人副流感病毒 1 型）的概念，另 47 个解析到 ISO 2 数字。

作者用一句话总结了形状：「失败很多但很浅；成功很少但很深。」

PERIOD 也是唯一一个类型-词表一致性可测的类（62.5%），而且全部 124 个观察到的类型错误都落在它里面。

Q：有一个被排除的字段，它的失败方式特别值得看 A：作者排除了五个字段，两种理由。organizations（637 条记录里只有六个不同的聚合器标识符）、rights、edmIsShownAt 承载的是来源而非内容。

但 dcLanguage 被排除是因为分类器在它上面失败了，而失败方式是一个教科书案例：

语言代码被标为「可解析」并链接到不相关的艺术史概念——「en」和「English」都在 334 条记录里解析到 AAT 概念「English Baroque」（英国巴洛克），而「ro」在 148 条里解析到「Romanian (Cyrillic）」（罗马尼亚语西里尔字母）。

关键在下一句：「这些通过了类型-词表检查，因为那个检查验证的是一个 URI 的域名，而不是 URI 背后的实体。」

它们占**流水线链接**的 28%，而且作者明确性：这是**边界分类的失败**，不是路由的失败。

Q：作者拒绝报告了两个指标，理由是什么？ A：这两处是全篇最值得学的方法论表态。

一、拒绝报标签相似度。 源值与其解析标签之间的模糊字符串重叠是链接质量的常用代理，**但它在多语言语料上无效：它给正确的跨语言链接打零分。**「Α θ η ν α」→「Athens」和「Ε π ι δ α υ ρ ο ς」→「Epidaurus」是对的却得 0.00。在这个语料上均值是 0.493、**43.6% 的链接低于 0.3**，而低分被正确的希腊语和罗马尼亚语解析主导。

这个指标恰恰惩罚了那些把解析与字符串匹配区分开的对齐，所以我们不报它的数字。

二、拒绝报含回退的路由准确率。 严格词表路由是 **73.1%** (1,315/1,798)。含回退的数字也能算，但它把任何落到 Wikidata 的贯穿都算作正确，因此是被设计而不是被测量所限定的，所以省略。

同理，类型-词表一致性只对流水线解析的槽位报，因为**预链接槽位的类型是从那个检查随后要验证的同一个 URI 域名推出来的**（会变成自证）。而它只对 PERIOD 可测（331 槽位 62.5%）：其余类主要路由到 Wikidata，那里任何语义类型都可接受，检查是空洞的（vacuous）。

Q：跨提供者的桥有多可靠？ A：13 个实体 FDO 跨提供者共享。一个从布加勒斯特国家遗产研究所的记录出发的机器 agent，能通过一个共享的 **Type FDO** (AAT 300192802) 到达荷兰 Huis van Hilde 藏品的记录；**没有 Place FDO 连接这两个提供者**，而语料里所有 Place 桥都是罗马尼亚境内的。

两个折扣：**13 个里有 1 个是假的**（就是那个标为「Human parainfluenza virus 1」、被类型化为 PERIOD 的 AAT 概念，跨 59 条记录、两个国家）；**13 个里有 12 个把一个原始 URI 作为它们的标签**，因为预链接 URI 没有被解引用取规范标签——**这限制了这类桥能被自动审计到什么程度。**

背景补充 / 点评

几个概念的位置

CIDOC-CRM（国际博物馆协会概念参考模型）是文化遗产领域的 ISO 标准本体（ISO 21127），特点是以**事件为中心**：不是直接说「这个物件属于某个人」，而是建模「一个获取事件，它把物件的所有权从 A 转给 B」。这让它能整合跨机构的复杂历史信息。本文用的 **E22**（人造物）、**E53**（地点）、**E57**（材料）、**E21**（人）、**E74**（群体）、**E55**（类型）、**E4**（时期）都是它的类。

Europeana 是欧盟的文化遗产聚合器，持有数百万条记录。它的 EDM 是**面向聚合**的模型，为发布和富化藏品记录设计。本文提到 Europeana 自己有一条富化流水线，已经给 65% 的槽位打上了 Getty TGN / AAT / ULAN 的 URI——**这个事实后来成了连通性比较失效的原因。**

四个受控词表的分工：**Getty AAT**（艺术与建筑叙词表，管物件类型和材料）、**Wikidata**（多语言、持续更新、社群审编、广泛连接到外部权威文件，本文的兜底）、**VIAF**（虚拟国际权威文件，管人名）、**PeriodO**（管历史时期）。作者说 Wikidata 在文化遗产里特别重要正是因为那四个属性。

「带外文档」(out-of-band documentation) 指不在数据本身里、要另外查手册才能知道的东西。FDO 把类型和操作也做成 FDO，就是为了消掉这一层——机器拿到一个 PID，能先解析出它的类型和 profile，再取领域元数据或可用操作。

这篇最不寻常的地方：它自己拆掉了自己的主要指标

绝大多数论文会报「连通分量从 32 降到 20」然后宣布胜利。这篇做了三件很少见的事：

一、主动加了两个控制并说明理由。「一个排除了 FDO 图所计入的 URI 值槽位的基线，在构造上就更弱」；「连通性会饱和」，所以丢掉任何在 >10% 记录里出现的值。这两个控制都是对自己不利的。

二、报告了一个对自己不利的结果。给定全部内容值，字符串匹配达到 8 个分量，比 FDO 图的 20 个更连通。论文没有把这个数字藏在附录里，而是放进了摘要和贡献列表。

三、在结论里明确降级自己的主张。「测得的好处是节点有类型、可解析、能合并表面变体，而不是更多记录可达。」以及未来工作的第三条：「用一个下游遍历或发现任务替代图连通性，因为连通性会在平凡的共享值上饱和。」

再加上前面那两处「拒绝报某个指标并说明理由」，这篇的自我批评密度在我读过的这批论文里是最高的。它的诚实本身就是可学的东西——尤其是「拒绝报一个会让自己好看但无效的指标」这个动作。

四处该打折扣的地方

一、89.6% 这个数字的分母是分类器自己的决定，作者说了但没充分展开后果。原文：「12,720 个槽位里分类器标了 12,272 个可解析，其中 10,995 个被链接，得 89.6%。那个分母是分类器自己的决定，所以一个被错判为字面量的值对这个度量是不可见的。」

这句话是对的，但它的分量比作者给的更重。89.6% 度量的是「在分类器认为该解析的东西里，解析成功了多少」，不是「该解析的东西里解析了多少」。而 dcLanguage 那个失败正好证明分类器的边界判断会大面积出错——那 28% 是反方向的错（不该解析的被解析了）。两个方向的错都存在，而这个指标一个也测不到。

二、17/33 的合并正确率被「失败很多但很浅，成功很少但很深」这个措辞柔化了。这句话本身是对的（正确的 17 个覆盖 327 条记录，错误的 16 个只覆盖 163 条），但它掩盖了一个更直接的事实：51.5% 的合并是错的。如果这套东西要自动跑，每两个合并里有一个需要人来撤销。

而且错误集中在 PERIOD，而 PERIOD 恰好是唯一可测的类、一致性只有 62.5%、全部 124 个类型错误都在里面。这说明 PERIOD 这一类根本没做对，但论文把它描述成一个「集中的失败模式」，而不是「一个必须先修的前置问题」。

三、gpt-oss-120b 这个模型选择完全没有理由。没说为什么用它、没和更强的模型比较、也没做消融。而整条流水线的核心决定（PID/字面量边界）全靠它。既然作者自己说「这个边界决定是我们的贡献」，那这个决定对模型的敏感性就是必须报的东西。对比昨天读的那篇（选 MedCPT 而非 BiomedBERT 给了 94.8% vs 34.4% 的实测理由），这里的差距很明显。

四、跨提供者桥这个卖点基本没被验证。13 个桥里 1 个确认是假的（7.7% 假阳性），12 个把原始 URI 当标签、无法自动审计（92%）。作者说这「限制了自动审计」，但后果更实际：你无法知道一个桥是不是有意义的，除非手工去解析那个 URI。在只有 13 个桥的规模上，这个数字支撑不了「机器 agent 能跨提供者遍历」这个主张。

对我的启示

一、PID/字面量边界这个划分，正是我在语义点准入规则上做的事，而且 FDO 的判据里有一个我漏掉的关键词。

FDO 的判据很干净：「一个值是 PID 引用当且仅当它指代一个可复用的真实世界实体。否则保留为字面量。」我的准入规则是「能改写成『什么条件下给出什么响应』的完整命题才建叶子节点」。两者是同一个形状：都在判「这个东西该不该有独立身份」。

但 FDO 的判据里有一个词我没有：可复用（reusable）。我的判据只看「是不是完整命题」，没看「能不能跨记录复用」。

这正好解释了我前几天遇到的一类问题：「可转诊心内科王主任」「本院设有 AE 管理专家组，可随时转诊」这类具名情境事实——它们是完整命题，但只在一家医院成立、不可复用。我当时把它们标成「否」，但判据没覆盖，只能凭直觉。

现在有依据了，可以加一条准入规则：「不可跨企业或跨场景复用的具名情境事实，保留为字面量（附着在关键信息上），不建独立节点」。这条要写进 v0.3 的准入规则那一节。

二、「验证层次错位」这个失败模式我要防，而且我的金标一致率有同构的问题。

dcLanguage 那个案例的要害是：检查验证的是「URI 来自正确的词表吗」，而不是「URI 指的是正确的东西吗」，结果「en」链到「English Baroque」还通过了检查。

对应到我：金标一致率检查的是「两个标注者给的标签一致吗」，不是「标签对不对」。两个人可以一致地错——尤其当他们用同一份判据、而判据本身有缺口时。K2/K3 边界就是这样：10 条分歧后我们发现是判据缺口不是谁错；而没有分歧的那些，也可能是两人一致地按有缺口的判据判错了。

沉淀一条：一致率是必要不充分的。裁定金标那一步（引入第三方判断、修判据）正是在补这个，但我该把这一句明确写进打标 SOP，避免下一轮只看一致率就放行。

三、「连通性会饱和」这条对我的图有直接含义，而且我昨天定的一条规则因此多了一个理由。

作者的例子：一个出现在 589/637 条记录里的 CC 权利 URI，单靠自己就把图连通了。处理办法是丢掉任何在超过 10% 的记录里出现的值。

我的图里对应的是覆盖类评分要点（「能够传达所有关键信息的语义点」）——它出现在几乎每个信息传递环节里。我昨天定的规则是「覆盖类不进节点」，当时的理由是「它是评分规则不是知识」；现在有了第二个独立理由：它会让任何连通性或相似度度量饱和。同理还有通用类要点（「关键信息与本次拜访目标相关」这类整体判断）。

而且这给了我一个可操作的阈值：以后做节点归并或图分析时，先丢掉出现频率超过某个比例的节点，否则度量出来的「连通」全是这些枢纽贡献的。

四、「拒绝报一个无效指标并说明理由」这个动作，我在 `same_as` 上会立刻需要。

这篇拒绝报标签相似度的理由是：它在多语言语料上给正确的跨语言链接打零分，「这个指标恰恰惩罚了那些把解析与字符串匹配区分开的对齐」。

我在跨企业 `same_as` 上会遇到完全同构的问题：如果用字符串相似度来找 `same_as` 候选，它会漏掉所有「同一个知识点用不同措辞表达」的情况——而那正是 `same_as` 存在的理由。比如「腹透液葡萄糖吸收增加会导致糖负荷增加」和「艾考糊精可减少每日腹膜葡萄糖暴露」讲的是同一件事的两面，字符串相似度接近零。

昨天我的归并草案里有 92 个「同事事实归并候选」，如果那些候选是按文本相似度找出来的，那我漏掉的比找到的多。这条要去核实我的归并是怎么找候选的。

五、kernel / metadata 两层分离这个架构，对一个还在改判据的模型特别有价值。

FDO 把一个对象分成两层：Kernel Record 只含 PID（自己的 PID、类型 PID、profile PID、元数据 FDO 的 PID、内容 PID、操作 PID、时间戳、校验和），内核里不驻留任何领域语义；Metadata FDO 单独承载 CIDOC-CRM 断言。

对应到我的统一模型：`knowledge_unit` 现在混着身份（id、owner）和语义（K 域、ktype、applies_to、comparator、qualifier）。

分成两层的好处对我很实际：语义层可以随判据修订而重写，身份层不动。我刚做了 13 条判据修订——如果已经灌了数，那些修订会要求重标全部节点的语义字段。身份稳定、语义可重写，正是我现在这个阶段需要的。建议给 spec 加一节，把 `knowledge_unit` 拆成身份表 + 语义表。

六、「属性的宾语是其他 FDO 的 PID，不是词表 URI」这个决定我该照做。

外部 URI 只作为实体 FDO 自身上的 `owl:sameAs` 出现。意思是换一个外部词表不需要改任何关系断言，只需要改那个实体的 `sameAs`。

对应到我：如果我把 K 域直接写成 ESCO 或 O*NET 的 URI，换分类体系就要改所有节点。正确做法是：节点有自己的本地 id，K 域是本地受控词表的值，本地词表项再 `sameAs` 到 ESCO / O*NET / Merrill 的对应概念。这样 v0.4 改判据时只动词表，不动节点。

七、它的规模提醒我控制期望。637 条记录、12,720 槽位，其中只有 3,523 是纯字符串需要流水线自己解析（其余 9,197 已经是 URI）。流水线真正做的工作是在 3,075 个槽位里解析了 1,798 个。

而我的语义点是 8,305 个去重、全部是纯文本、没有任何预链接。规模比它大得多，难度也大得多——它至少有 Getty AAT / VIAF / PeriodO 这些成熟的目标词表可以链，而我的目标词表（K1 - K8 / S1 - S12 加四类）是这周刚定的、还在改判据。

所以：别拿这篇的 58.5% 当参照预期。它的任务是「链到一个已有的成熟词表」，我的任务是「同时建词表和链」。

文中金句

"The Europeana Data Model was designed long before the FDO specification, and it stores most metadata values as plain text. This serves human browsing well enough, but gives an automated agent nothing to follow across records or collections." Europeana Data Model 的设计远早于 FDO 规范，它把大多数元数据值存为纯文本。这对人浏览够用，但给自动化 agent 留下了任何可跟随的东西都没有。

"It cannot, for example, tell that 'Braga' and 'Bracara Augusta' name the same place." 举例来说，它无法知道「Braga」和「Bracara Augusta」指的是同一个地方。

"a value is a PID reference if and only if it denotes a reusable real-world entity (place, material, actor, event, concept). Otherwise, it remains a literal." 一个值是 PID 引用，当且仅当它指代一个可复用的真实世界实体（地点、材料、行动者、事件、概念）。否则它保留为字面量。

"Those pipelines link mentions that are given to them as entities; ours must first decide which values are entities at all, because the FDO specification, not a benchmark, fixes what may remain a literal." 那些流水线链接的是已经作为实体交给它们的提及；而我们的必须先决定哪些值根本算不算实体，因为决定什么可以保留为字面量的是 FDO 规范而不是某个基准。

"These pass the type - vocabulary check, which validates a URI's domain rather than the entity behind it." 这些通过了类型-词表检查，因为那个检查验证的是一个 URI 的域名，而不是 URI 背后的实体。

"Failures are numerous but shallow; successes are few but deep." 失败很多但很浅；成功很少但很深。

"Connectivity therefore does not separate the two approaches in a stable way, and its direction depends on a choice of slot population that the metric itself does not fix." 因此连通性无法以稳定的方式区分这两种方法，而且它的方向取决于一个指标本身并不固定的槽位总体选择。

"The metric penalises precisely the alignments that distinguish resolution from string matching, so we report no figure for it." 这个指标恰恰惩罚了那些把解析与字符串匹配区分开的对齐，所以我们不报它的数字。

"That denominator is the classifier's own decision, so a value wrongly ruled literal is invisible to this measure." 那个分母是分类器自己的决定，所以一个被错判为字面量的值对这个度量是不可见的。

"The measured benefit is that nodes are typed, resolvable, and merge surface variants, not that more records are reachable." 测得的好处是节点有类型、可解析、能合并表面变体，而不是更多记录可达。

全文翻译

摘要

The FAIR Digital Object (FDO) framework mandates that metadata attribute values be expressed as persistent identifiers (PIDs) wherever possible, to produce a fully machine-actionable graph in which every reference is resolvable. The Europeana Data Model was designed long before the FDO specification, and it stores most metadata values as plain text. This serves human browsing well enough, but gives an automated agent nothing to follow across records or collections.

FAIR 数字对象（FDO）框架要求元数据属性值尽可能表达为持久标识符（PID），以产生一个每个引用都可解析的、完全机器可操作的图。Europeana Data Model 的设计远早于 FDO 规范，它把大多数元数据值存为纯文本。这对人浏览够用，但给自动化 agent 留下了任何可跟随的东西都没有。

We present a pipeline that transforms flat Europeana records into an FDO-compliant knowledge graph structured with CIDOC-CRM. Following the FDO specification, we model every heritage entity as a discrete FDO with its own PID, type, profile, and metadata layer. The core technical challenge is automating the FDO-prescribed distinction between values that must become PID references (resolvable entities) and those that may remain literals (terminal leaves such as notes, measurements, and dates).

我们提出一条流水线，把扁平的 Europeana 记录转换成一个以 CIDOC-CRM 结构化的、符合 FDO 的知识图谱。遵循 FDO 规范，我们把每个遗产实体建模为一个离散的 FDO，带自己的 PID、类型、profile 和元数据层。核心技术挑战是自动化 FDO 所规定的那个区分：哪些值必须成为 PID 引用（可解析实体），哪些可以保留为字面量（注释、测量、日期这类终端叶）。

We address this with a large language model that classifies each metadata value, routes it to a controlled vocabulary (Getty AAT, Wikidata, VIAF, PeriodO), and links it to a shared entity FDO. We evaluate using 637 archaeological records from five Europeana providers, processing each with the LLM. The pipeline links 86% of metadata slots, resolving 58.5% of values Europeana had not already enriched. It also merges cross-lingual surface forms that byte-identical matching keeps apart, where 17 of 33 such merges are correct on manual review. Graph connectivity does not separate this from string matching; what distinguishes the FDO graph is that every node is typed and resolvable.

我们用一个大语言模型来处理这个问题：它分类每个元数据值、把它路由到一个受控词表（Getty AAT、Wikidata、VIAF、PeriodO）、并把它链接到一个共享的实体 FDO。我们用来自五个 Europeana 提供者的 637 条考古记录评测，每条都由 LLM 处理。流水线链接了 **86%** 的元数据槽位，解析了 **58.5%** 的 Europeana 尚未富化的值。它还合并了字节相同匹配所分开的跨语言表面形式，**33 个这样的合并里 17 个在人工复核下是正确的**。图连通性并不能把这套方法与字符串匹配区分开；区分 FDO 图的是每个节点都有类型且可解析。

1. 引言：机器拿不到任何可跟随的东西

A core requirement of the FDO specification is that metadata attribute values are expressed as persistent identifiers (PIDs) rather than plain strings. The goal is to produce a fully machine-actionable graph in which every reference can be resolved, typed, and traversed algorithmically. Only terminal leaf values (i.e. numeric measurements, free-text notes, dates, checksums) may remain as literals.

FDO 规范的一条核心要求是**元数据属性值表达为持久标识符（PID）而不是纯字符串**。目标是产生一个完全机器可操作的图，其中每个引用都能被算法解析、类型化和遍历。**只有终端叶值**（数值测量、自由文本注释、日期、校验和）**可以保留为字面量**。

Cultural heritage aggregators such as Europeana hold millions of records, yet the majority of metadata values remain expressed as plain-text strings rather than PID references. This is a gap between current practice and the degree of machine-actionability that the FDO framework envisions.

Europeana 这类文化遗产聚合器持有数百万条记录，**然而大多数元数据值仍然表达为纯文本字符串而不是 PID 引用。这是当前实践与 FDO 框架所设想的机器可操作程度之间的一道差距。**

A record's `dcterms:spatial` field typically contains the string "Bracara Augusta" rather than a PID resolving to a Place FDO. A `dcCreator` field stores "Cristina Braga" rather than a VIAF or ORCID reference. Machine actionability is therefore limited and no automated agent can traverse from an object to its findspot or relate all objects from the same excavation. It cannot, for example, tell that "Braga" and "Bracara Augusta" name the same place.

一条记录的 `dcterms:spatial` 字段通常包含字符串「Bracara Augusta」而不是一个解析到 Place FDO 的 PID。`dcCreator` 字段存的是「Cristina Braga」而不是一个 VIAF 或 ORCID 引用。因此机器可操作性受限，没有自动化 agent 能从一个物件遍历到它的发现地、或关联同一次发掘出的所有物件。举例来说，它无法知道「Braga」和「Bracara Augusta」指的是同一个地方。

To maximise machine actionability in compliance with the FDO specification, metadata values that denote reusable entities must be replaced by PID references to shared FDOs. The technical challenge, then, is not merely one of entity linking. It is rather the automated enforcement of the FDO-prescribed boundary between PID-expressed values (entities that can and should be shared across records) and literal-expressed values (terminal leaves that cannot be meaningfully shared).

为在符合 FDO 规范的前提下最大化机器可操作性，**指代可复用实体的元数据值必须被替换为指向共享 FDO 的 PID 引用**。于是技术挑战不仅仅是实体链接，而是自动执行 FDO 所规定的那条边界：一边是以 PID 表达的值（能够并且应该跨记录共享的实体），另一边是**以字面量表达的值**（无法被有意义地共享的终端叶）。

This boundary is defined by the FDO architecture itself: a value is a PID reference if and only if it denotes a reusable real-world entity (place, material, actor, event, concept). Otherwise, it remains a literal.

这条边界由 FDO 架构本身定义：一个值是 PID 引用，当且仅当它指代一个可复用的真实世界实体（地点、材料、行动者、事件、概念）。否则它保留为字面量。

三条贡献。（1）一条 LLM 驱动的流水线，把扁平元数据自动转换为符合 FDO 的 PID 引用，在它必须自己解析的值上达到 58.5%，算上 Europeana 预链接的 URI 后总体 89.6%，全文分开报告。（2）一个由流水线自动实例化的 FDO 原生知识图谱，其中每个解析出的实体都是一个完整 FDO（自描述、PID 可解析、携带声明的操作）。（3）在来自五个提供者的 637 条记录上的实证评估，每条记录都由 LLM 处理。在相同的槽位总体上，实体解析把不连通分量从 32 降到 20；而给定全部内容值（包括流水线未链接的那些），字符串匹配达到 8。连通性结果的方向取决于槽位总体，这限定了连通性能对机器可操作性建立什么结论。

2. 相关工作

FAIR 数字对象与机器可操作性。 FAIR 原则把数据管理实践从人可读的文档转向能被机器发现、访问、解释和复用的资源。FDO 通过**把数字资源当作持久的、类型化的、自描述的单元**（带机器可解析的标识符和显式元数据）来把这个目标操作化。近期 FDO 工作进一步强调**最小 PID/内核层与更丰富的语义描述之间的分离**，以便机器能先解析一个对象、检查它的类型和 profile、再取领域特定的元数据或操作。

We adopt this architecture, but address a different problem: given flat cultural-heritage records, how can the system decide which metadata values should become PID references to reusable entities and which values should remain literals? This PID/literal boundary is central to producing machine-actionable FDO graphs, yet it is not addressed by existing FDO infrastructure alone.

我们采用这个架构，但面对一个不同的问题：给定扁平的文化遗产记录，系统如何决定哪些元数据值应该成为指向可复用实体的 PID 引用、哪些应该保留为字面量？这条 PID/字面量边界对产生机器可操作的 FDO 图是核心的，然而仅靠现有的 FDO 基础设施并不解决它。

文化遗产元数据、CIDOC-CRM 与链接数据。 EDM 提供面向聚合的模型用于发布和富化藏品记录，而 CIDOC-CRM 提供以事件为中心的本体用于跨机构整合复杂的遗产信息。已有工作表明两者能捕捉博物馆数据的互补侧面，但也表明真实的机构记录仍然难以建模，因为它们异构、不完整、历史累积、而且常常表达为弱结构化的字符串。Zeri 照片档案、史密森美国艺术博物馆、Beyond 2022 知识图谱这些项目展示了 RDF、CIDOC-CRM、命名图和外部权威链接的价值，然而这些努力通常依赖大量手工建模、项目专属映射或人工审编的转换规则。相比之下，我们的流水线瞄准聚合器规模的 Europeana 记录，并自动化从扁平元数据槽位到 FDO 实体和 CIDOC-CRM 关系的转换。

实体链接与文化遗产权威控制。 Wikidata 变得尤其重要，因为它多语言、持续更新、社群审编、并广泛连接到外部权威文件。文化遗产领域的 Heritage Connector 用机器学习从博物馆目录构建链接开放数据、对 Wikidata 做记录链接、并从文本藏品描述里抽新实体。

These approaches are close to our goal, but they optimise primarily for linking or graph construction. Our task is narrower and more FDO-specific: before linking, the system must determine whether a metadata value denotes a reusable entity that should be represented by a PID, or a terminal attribute that should remain a literal. This makes our problem not only entity linking, but specification-driven metadata normalisation for machine-actionable FDO construction.

这些方法接近我们的目标，但它们主要为链接或图构建优化。我们的任务更窄也更 FDO 专属：在链接之前，系统必须判定一个元数据值是指代一个应由 PID 表示的可复用实体、还是一个应保留为字面量的终端属性。这使我们的问题不只是实体链接，而是为机器可操作的 FDO 构建所做的、规范驱动的元数据规范化。

面向文化遗产的 AI 语义富化。 近期一条线用 AI 生成的识别、实体链接和图结构来富化文化资源：CulturAI 用语义技术和机器学习增强文化记录；对社群生成的文化内容上最先进实体链接器的比较评估报告说**现成模型在领域词汇和多语言提及上性能退化**；多模态系统结合语言与视觉模型扩展遗产知识图谱；LLM 结合本体工程被用来从文化遗产文本生成知识图谱。

These systems target richer or more accurate links than we do, and several are stronger entity linkers. What differs here is the decision the system is asked to make. Those pipelines link mentions that are given to them as entities; ours must first decide which values are entities at all, because the FDO specification, not a benchmark, fixes what may remain a literal.

这些系统瞄准比我们更丰富或更准确的链接，其中几个是更强的实体链接器。这里不同的是系统被要求做的那个决定。那些流水线链接的是已经作为实体交给它们的提及；而我们的必须先决定哪些值根本算不算实体，因为决定什么可以保留为字面量的是 FDO 规范而不是某个基准。我们的贡献是那个边界决定以及用它来填充一个 FDO 图，而不是链接准确率——那一项我们并不与专用链接器做基准比较。

LLM 用于数据集成与知识图谱构建。 近期数据管理研究表明，当经典数据任务（schema 匹配、数据清洗、实体解析）被表述为提示或结构化输出时，基础模型能泛化到它们。我们的流水线把这个新兴的 LLM - KG 范式应用到文化遗产元数据上，但带一个来自 FDO 模型的显式架构约束：LLM 不只是被用来生成三元组，而是用来执行 PID/字面量决定、把可解析的值路由到合适的权威词表、并把由此产生的实体实例化为通过 CIDOC-CRM 属性连接的 FDO。

3. 系统总览

（四个阶段的细节见「核心内容」。）设计受三条原则支配：1) 每个遗产实体都是一个离散的 FDO；2) 只要值指代一个可复用实体，元数据值就是 PID；3) 字面量只保留给终端叶。

关键的一句（阶段 4）：Crucially, property objects are PIDs of other FDOs—not vocabulary URIs directly. External URIs (e.g., `http://vocab.getty.edu/tgn/...`) appear only as `owl:sameAs` on the entity FDO itself.

至关重要的是，属性的宾语是其他 FDO 的 PID，而不是词表 URI 本身。外部 URI（如 Getty TGN 的）只作为实体 FDO 自身上的 `owl:sameAs` 出现。

自描述基础设施。 FDO Types (Place, Material, Actor, etc.) and FDO Operations (Resolve, GetMetadata, Validate, Link) are themselves FDOs with PIDs, registered in a type/operations registry. This makes the graph navigable by machines without out-of-band documentation.

FDO 类型（Place、Material、Actor 等）和 FDO 操作（Resolve、GetMetadata、Validate、Link）**它们自己也是带 PID 的 FDO**，注册在一个类型/操作注册表里。这让图可以被机器导航，而不需要带外文档。

The result is a knowledge graph where every node is a PID-resolvable FDO, every metadata edge is a typed CIDOC-CRM relation, and every entity can be traversed, queried, and composed by automated agents. Whether this constitutes machine actionability in the sense the FDO specification intends is what Section 4 sets out to test.

结果是一个知识图谱，其中每个节点都是一个 PID 可解析的 FDO、每条元数据边都是一个类型化的 CIDOC-CRM 关系、每个实体都能被自动化 agent 遍历、查询和组合。**这是否构成 FDO 规范所意指的那种机器可操作性，正是第 4 节要检验的。**

4. 评估

数据与设置。 我们从五个 Europeana 数据提供者、横跨四个国家收获 637 条考古记录，在内容承载字段上产生 12,720 个元数据槽位；其中 9,197 已经带有 Europeana 富化的词表 URI，3,523 是纯字符串。LLM 是一个 1,200 亿参数的指令调优模型（`gpt-oss-120b`），**temperature 0、每个响应都缓存，这使重跑具有确定性。** 637 条记录每一条都由 LLM 处理。附带的测试套件覆盖记录解析器、FDO 内核与序列化层、以及图度量。

字段限制。 五个字段被排除，理由有两种。`organizations`（全部 637 条记录里只有六个不同的聚合器标识符）、`rights` 和 `edmIsShownAt` 承载的是来源而非内容。

`dcLanguage` is excluded because the classifier fails on it: language codes are marked resolvable and linked to unrelated art-historical concepts—"en" and "English" both resolve to the AAT concept English Baroque across 334 records, and "ro" to Romanian (Cyrillic) across 148. These pass the type - vocabulary check, which validates a URI's domain rather than the entity behind it. They are 28% of pipeline links and are a boundary classification failure, not a routing failure.

dcLanguage 被排除是因为分类器在它上面失败：语言代码被标为可解析并链接到不相关的艺术史概念——「en」和「English」都在 334 条记录里解析到 AAT 概念「English Baroque」，「ro」在 148 条里解析到「Romanian (Cyrillic)」。

这些通过了类型-词表检查，因为那个检查验证的是一个 URI 的域名而不是 URI 背后的实体。它们占流水线链接的 28%，是边界分类的失败而不是路由的失败；我们在此报告它们并把它们从下面的数字里排除。

RQ1 · 连通性捕捉了什么。（两个控制与表 1 结果见「核心内容」。）

Connectivity therefore does not separate the two approaches in a stable way, and its direction depends on a choice of slot population that the metric itself does not fix. Europeana already ships vocabulary URIs for 65% of slots, and those URIs are byte-identical across records, so string matching recovers them without any resolution step.

因此连通性无法以稳定的方式区分这两种方法，而且它的方向取决于一个指标本身并不固定的槽位总体选择。Europeana 已经为 65% 的槽位提供词表 URI，而那些 URI 在记录之间是字节相同的，所以字符串匹配无需任何解析步骤就能恢复它们。

表面形式合并。 Connectivity counts reachable records; it does not distinguish a node that is a resolved entity from one that is a shared string. Two properties do. Every node in `G_FDO` carries a resolvable external identifier and a semantic type, against 63.8% of `G_flat` nodes that happen to be URI strings, the remainder being bare literals that support no further resolution. And 33 entity FDOs absorb 176 distinct surface forms that byte-identical matching keeps apart.

连通性数的是可达的记录；它不区分一个节点是解析出的实体还是一个共享的字符串。有两个属性做这个区分。 `G_FDO` 里每个节点都带一个可解析的外部标识符和一个语义类型，而 `G_flat` 只有 63.8% 的节点恰好是 URI 字符串，其余是裸字面量、不支持任何进一步的解析。而且 33 个实体 FDO 吸收了 176 个字节相同匹配所分开的不同表面形式。

（33 个合并的人工复核结果、正确与错误两组的形状对比、以及那个「人副流感病毒 1 型」的失败案例，见「核心内容」。）

Failures are numerous but shallow; successes are few but deep. PERIOD is also the only class where type - vocabulary consistency is measurable, at 62.5%, and all 124 observed type errors fall in it.

失败很多但很浅；成功很少但很深。PERIOD 也是唯一一个类型-词表一致性可测的类，为 62.5%，而且全部 124 个观察到的类型错误都落在它里面。

RQ2 · 类型化与路由的一致性。

不报标签相似度。 Fuzzy string overlap between a source value and its resolved label is a common proxy for link quality, but it is invalid on a multilingual corpus: it scores correct cross-lingual links at zero. Over this corpus, the mean is 0.493 with 43.6% of links below 0.3, and the low scores are dominated by correct Greek and Romanian resolutions. The metric penalises precisely the alignments that distinguish resolution from string matching, so we report no figure for it.

源值与其解析标签之间的模糊字符串重叠是链接质量的常用代理，**但在多语言语料上是无效的：它给正确的跨语言链接打零分。**「Αθῆναις」→「Athens」和「Ἐπίδωρος」→「Epidaurus」是对的却得 0.00。在这个语料上均值是 0.493，43.6% 的链接低于 0.3，而这些低分被正确的希腊语和罗马尼亚语解析所主导。这个指标恰恰惩罚了那些把解析与字符串匹配区分开的对齐，所以我们不报它的数字。

类型化与路由。 类型-词表一致性只对流水线解析的槽位报告，**因为对预链接的槽位来说，类型是从那个检查随后要验证的同一个 URI 域名推出来的。**它只对 PERIOD 一类可测，在 331 个槽位上是 62.5%；其余类主要路由到 Wikidata，那里任何语义类型都可接受，检查是空洞的。严格词表路由是 73.1% (1,315/1,798)。含回退的数字也可以计算，但它把任何落到 Wikidata 的贯穿都算作正确，因此是被设计而不是被测量所限定的，所以我们省略它。

讨论 · 连通性度量的是什么。 Connectivity is a weak discriminator here. It saturates on values that denote no entity—a rights statement shared by 589 records connects the graph as effectively as a resolved place—and its verdict reverses with the choice of slot population. What separates the graphs is not how many records are reachable but what the nodes are: typed, resolvable identifiers rather than strings.

连通性在这里是一个弱的区分器。它在不指代任何实体的值上饱和——一个被 589 条记录共享的权利声明，连通图的效果和一个解析出的地点一样好——**而且它的判决随槽位总体的选择而反转。区分这些图的不是有多少条记录可达，而是节点是什么：类型化的、可解析的标识符而不是字符串。**

The denominators are as follows: of 12,720 slots the classifier marks 12,272 resolvable and 10,995 of those are linked, giving 89.6%. That denominator is the classifier's own decision, so a value wrongly ruled literal is invisible to this measure.

分母是这样的：12,720 个槽位里分类器标了 12,272 个可解析，其中 10,995 个被链接，得 89.6%。**那个分母是分类器自己的决定，所以一个被错判为字面量的值对这个度量是不可见的。**

跨提供者的桥。 (13 个桥的细节、1 个假阳性、12 个无法自动审计见「核心内容」。)

局限。 The current evaluation uses automatic quality proxies rather than human-annotated gold; a full annotation study is planned. This is the main limitation, and it bounds every number above: none of these measures verifies that a link is the right entity, that a literal was correctly left

unresolved, or that a bridge is meaningful. Type - vocabulary consistency is agreement with a URI-domain rule, not with a human judgement, and it is measurable for one class only.

当前评估用的是自动质量代理而不是人工标注的金标；一项完整的标注研究在计划中。这是主要局限，而且它限定了上面每一个数字：这些度量里没有一个验证了一个链接是正确的实体、一个字面量被正确地留作未解析、或者一个桥是有意义的。类型-词表一致性是与一条 URI 域名规则的一致，而不是与人类判断的一致，而且只对一个类可测。

另有两条针对本语料的局限。Search API 的投影不带 material 或 medium 字段，所以流水线不产生 MATERIAL 实体，P45_consists_of 关系从未被实例化；边分布被 P2_has_type (4,701) 和 P53 (4,658) 主导，其余是 P10 (1,278)、P14 (245)、P50 (113)。而且全部结果来自一个领域（考古）、一个聚合器，所以我们不作任何泛化到其他藏品或聚合器的声明。

5. 结论

The central contribution is the automated enforcement of the FDO PID/literal boundary. Specifically, values that denote reusable cultural heritage entities are resolved to persistent identifiers, while terminal attributes remain literals.

核心贡献是自动执行 FDO 的 PID/字面量边界。具体说：指代可复用文化遗产实体的值被解析到持久标识符，而终端属性保留为字面量。

This work shows that FDO principles can be operationalised over heterogeneous aggregator metadata without requiring fully manual modelling. The measured benefit is that nodes are typed, resolvable, and merge surface variants, not that more records are reachable. It also rests on automatic proxies rather than human judgement.

这项工作表明 FDO 原则可以在异构的聚合器元数据上被操作化，而不需要完全手工建模。测得的好处是节点有类型、可解析、能合并表面变体，而不是更多记录可达。它也建立在自动代理而非人类判断之上。

Future work will prioritise a human-annotated gold set, which is the prerequisite for every quality claim above; compare against dedicated entity-linking and record-linkage systems; replace graph connectivity with a downstream traversal or discovery task, since connectivity saturates on trivial shared values; and extend the pipeline to additional Europeana domains and aggregators to test whether any of this generalises.

未来工作将优先做：一个人工标注的金标集，这是上面每一条质量声明的前提；与专用的实体链接和记录链接系统比较；用一个下游遍历或发现任务替代图连通性，因为连通性会在平凡的共享值上饱和；以及把流水线扩展到更多 Europeana 领域和聚合器，以检验这些结论是否有任何泛化。

资助：欧盟 Horizon Europe 的 ARXIVE 项目 (101233418) 与 ARGUS 项目 (101132308)，以及德国研究基金会 (DFG) 的 NFDI4DataScience (项目号 460234259)。

生成式 AI 使用声明： 作者使用生成式 AI 工具协助语言编辑、段落重构、非技术性解释文本的起草，也用于支持软件开发，包括代码起草、调试等。

参考链接

- github.com/ZResearch/aFDO_CIKM — 代码、配置与评估输出；测试套件覆盖记录解析器、FDO 内核与序列化层、图度量
- [Europeana](#) — 欧盟文化遗产聚合器，本文数据来源；它自己的富化流水线已给 65% 的槽位打上词表 URI，**这个事实后来成了连通性比较失效的原因**
- [CIDOC-CRM](#) — 文化遗产的 ISO 标准本体 (ISO 21127)，**以事件为中心**；本文用的 E22 / E53 / E57 / E21 / E74 / E55 / E4 和 P2 / P10 / P14 / P45 / P50 / P53 都来自它
- [Getty AAT \(艺术与建筑叙词表\)](#) — 管物件类型与材料，本文的目标词表之一
- [VIAF \(虚拟国际权威文件\)](#) — 管人名，回退链 VIAF → Wikidata
- [PeriodO](#) — 管历史时期，回退链 PeriodO → AAT → Wikidata；**它对应的 PERIOD 类恰好是本文全部 124 个类型错误的所在**
- [Wikidata](#) — 全部回退链的终点；作者选它的理由是多语言、持续更新、社群审编、广泛连接外部权威文件。但也正因为「任何语义类型都可接受」，落到它的类型检查是空洞的