

对齐要往结构更好的那个空间投 Aligning Biomedical Texts and Knowledge Graphs: A Systematic Comparison of Lightweight Alignment Strategies

本篇范围说明：这是一篇 21 页的工作坊论文（曼海姆大学数据与网络科学组，Artem Bisliouk 等五人，发表于 ISWC 2026 的第三届知识图谱与神经符号 AI 工作坊 KG-NeSy 2026）。下面「全文翻译」按原文章节推进，覆盖摘要、§1 引言、§2 相关工作（三小节）、§3 方法（数据表示、对齐方法、检索任务）、§4 语料与数据集构建、§5 实验设置、§6 结果与讨论（四小节）、§7 局限与未来工作、§8 结论。超参搜索空间表（表 2）、关系类型分布图（图 2）的逐项数值不译，只取结论；参考文献 78 条不译。

核心内容

Q：这篇要解决什么问题？ A：生物医学知识以两种互补但根本不同的形态存在——一边是 PubMed 这类非结构化的科学文献，一边是 CTD、Hetionet 这类人工审编、持续更新的结构化知识图谱（KG）。两者描述大量重叠的事实，但表示方式完全不同：文献用自然语言，KG 用符号三元组。

结果是：一篇科学文档（或它的某一段）和它所描述的那个关系之间，没有显式的对应关系。

而很多应用恰恰需要这种对应：把 LLM 的回答锚定在 KG 信息上以减少幻觉、检索支持或反驳某条 KG 事实的文本证据、从文献里抽关系来丰富或补全 KG。**但现有方法都不显式对齐自由文本证据与 KG 三元组。**

Q：现有方法差在哪？ A：作者把已有工作分两类，各有一个明确的短板：

一类是表示集成（ERNIE、KnowBERT、K-BERT、KEPLER、DRAGON 把预对齐的 KG 嵌入注入语言模型；KG-BERT、SimKGC 反过来用语言模型做 KG 补全）。**它们都是为下游任务或 KG 补全优化的，不是为学习「自由文本证据 ↔ 结构化三元组」这个显式映射。**

另一类是文本-图对齐（ConGraT、JointGT）。它们的问题是**对齐单个节点而不是完整事实**，或者把三元组线性化成文本从而丢掉图结构；而且都在通用域数据上开发和评测，那里的词汇、实体类型、关系语义与生物学差别很大。

Q：这篇的做法是什么？ A：一个统一的模块化框架，骨干很简单：给定一个生物医学文本编码器和一个 KG 嵌入模型，**两者都冻结（frozen）**，只训练两个嵌入空间之间的一个**轻量投影**，用对比目标 InfoNCE。这个目标鼓励配对的文档和三元组在共享嵌入空间里占据相邻位置。

因为两个编码器都冻结，框架是模块化的：任何预训练的文本或 KG 编码器都可以替换，只需重训对齐层，成本是微调任一编码器的零头。所有对齐实验在 CPU 上跑，每个作业分配 50 GB 内存。

骨干固定后，**一次只变一个组件**，从而把性能差异直接归因到某个设计维度。六个维度：

维度	备选
文本编码器	BioBERT、PubMedBERT（都用 mean pooling 得 768 维）
KG 嵌入模型	RotatE（复向量空间旋转）、TuckER（Tucker 分解的双线性）、RDF2Vec（图上随机游走 + Word2Vec）
三元组组合算子 ϕ	拼接 [s;p;o] （3d 维）、Hadamard sepo 、L1`
投影头	Linear （单个线性变换，无隐层、无非线性、无归一化、无 dropout）、MLP、cross-attention
训练方向	text →KG、KG→text、bidirectional
硬负样本	腐坏谓词 / 宾语 / 主语 / 两个实体，或 None / All

评测方式是**双向检索**：D2T（document→triple，给一篇证据文档找出正确的 KG 三元组）和 T2D（triple→document，给一个三元组找出描述它的文档）。**每个查询都在完整候选池里排名**，不是在采样的负例子集里。

Q：数据集是怎么造的？这部分方法论最值得学 A：作者构建了 **CTD-Align**，22,293 个一对一「三元组-文档」对，把 CTD 的化学-基因交互与 PubMed 的支持证据配起来，带完整 provenance（来源 PMID）。四步筛选，每一步都有明确理由：

第一步，只保留单动作交互。从 300 多万条原始化学-基因交互里丢掉约 120 万条多动作记录（**40.5%**）。理由：像 **(increases-phosphorylation, decreases-degradation)** 这样的复合动作**没有无歧义的 KG 表示**，保留会降低对齐数据的语义质量。剩 1,546,310 条唯一单动作三元组。

第二步，不强求「一篇论文对一个三元组」。那样做只有 **23.6%** 的三元组能成功，因为论文通常同时讨论多个交互。所以收集阶段允许一篇文档对多个三元组。从这些三元组引用的 63,274 篇文章下载 63,239 篇摘要（走 PubTator 3.0 API，实体提及已归一化到 CTD 标识符），对每个三元组抽出**同时提到其化学和基因的段落**作为候选证据，得到 45,684 个至少有一个候选的三元组。

第三步，共现是必要但不充分的。一句话可能同时提到两个实体却不描述它们的关系——作者的例子是「Both aspirin and COX-2 were measured at baseline」。所以要按语义相关性给候选段落排序：把三元组**语言化**成一句短查询（拼接主语名 + 谓词的人类可读措辞 + 宾语名，如「Dichlorvos decreases activity of ACHE」），用一个生物医学 **cross-encoder** 给每个候选段落打分（在查询和段落之间做完整的 cross-attention），取最高分的段落作为支持文档。

用的是 **MedCPT re-ranker**（从 PubMedBERT 初始化，在 PubMed 搜索日志挖出的 1,830 万查询-文章对上对比训练）。**选它的理由有实测**：在 1,000 个按谓词分层抽样的三元组上比较 MedCPT 与 BiomedBERT Reranker 2（一个更新的、同样从 PubMedBERT 微调的 cross-encoder），**MedCPT 在 94.8% 的情况下保留了两个实体提及，而 BiomedBERT 在 34.4% 的情况下至少丢掉一个实体。**

第四步，强制一对一。同一段落被多个三元组选中时，**保留谓词最不频繁（信息量最大）的那个三元组**，丢掉其余。最终得到 22,293 对（删了 794 个碰撞，连带丢掉 3 种关系类型），来自 17,530 篇源出版物，文档平均长度 303 字符。

Q: 图是怎么建的？ 有一步叫「去具体化」，是什么？ **A:** **去具体化 (Dereification)** 这一步值得单独记。

CTD 像很多 RDF 资源一样，用**具体化 (reification)** 表示 **n 元交互**——引入一个中间节点，元数据挂在它上面。一个化学-基因交互被编码成三个三元组：`chemical → interaction_node`、`interaction_node → action`、`interaction_node → gene`。

问题是：**标准 KG 嵌入模型倾向于独立处理每个三元组，穿过辅助节点的多跳路径不好捕捉。** 所以作者在抽取时**去具体化**，把这个三三元组模式塌成一条带交互动作类型标签的直接边（如 `increases expression`）。

图的扩张方式也有讲究：从有文本证据的化学-基因交互（core 集）向外迭代生长——把化学或基因已在图里的化学-疾病、基因-疾病、基因-通路关联都挂上，**让新加进来的疾病和通路节点充当枢纽，连接原本彼此孤立的化学和基因。**重复到无法再加或达到目标规模，最后保留最大连通分量（丢掉 10 个小孤立分量）。

	关系数	边数	化学	基因	疾病	通路	节点总数
core	11	22,293	4,179	3,431	—	—	7,610
enriched	14	1,048,611	13,773	50,709	7,292	2,363	74,137

KG 嵌入在 **enriched** 图上预训练（含完整的 core 三元组），以得到领域适配的嵌入。

Q: 结果是什么？ **A:** **最佳配置 = text→KG 方向 + linear 投影头 + 三元组拼接。** 相对更强的那个基线（BioBERT 语言化），D2T 的 MRR 提升 **90%**、T2D 提升 **64%**。

在完整排名上的提升更大：正确项的中位排名从 **927 降到 38**（D2T，24 倍）、从 **845 降到 55**（T2D，15 倍），Hits@10 在两个设定里大致翻倍。

模型	配置	D2T MRR	D2T Hits@1	D2T Rank	T2D MRR	T2D Rank
语言化基线	BioBERT	8.41	5.47	927	7.41	845
语言化基线	PubMedBERT	4.43	2.81	4,826	2.83	5,066
对齐 (text→KG)	PubMedBERT / RDF2Vec	15.99	8.74	38	12.13	55
对齐 (KG→text)	BioBERT / RotatE	3.75	1.34	349	5.89	147
对齐 (bidirectional)	PubMedBERT / RotatE	15.15	8.51	48	5.74	159

作者还检查了结果是否被少数高频谓词主导：最佳模型的**关系平均 (macro) MRR 超过实例级 (micro) 值**（D2T 上 18.00 vs 15.99），说明性能在关系类型间是平衡的。

Q: 六个维度里哪个重要？ **A:** 这是全篇最有迁移价值的一段。作者用一元 η^2 （组间平方和除以总平方和）量化每个因子解释的方差份额：

- 三元组组合算子单独解释 D2T 的 87%、T2D 的 62% 的 MRR 方差
- KG 嵌入模型再解释 6% 和 3%

- 投影头、文本编码器、负采样方案各解释不到 1%

几乎全部方差都归于一个因子。所以作者先分析三元组组合，把它固定到最佳值（拼接），再研究其余因子的条件效应。

Q: 为什么方向不能任选？text→KG 和 KG→text 差那么多？ A: 这是全篇解释得最漂亮的一处。两个方向都远不对称：bidirectional 在 D2T 上匹配 text→KG (15.15 vs 15.99)，但在 T2D 上崩掉 (5.74 vs 12.13)；KG→text 在两个设定里都远差，甚至低于强基线。

作者的解释是**两个映射在相反方向上是不良设定的 (ill-posed)**：

- text→KG 是归约 (reduction)：一篇文档编码的信息比它的三元组多（额外实体、表面形式、句法），模型只需丢掉那些一旦关系被识别就变得冗余的信息。
- KG→text 是添加 (addition)：从一个紧凑、去语境化的三元组出发，必须重建正是那些缺失的语境和表面实现。这个逆问题是欠定的——一个三元组可能适配很多文档——而且恢复缺失的信息本质上比丢弃信息更难。

两个空间的几何还在强化这个不对称：预训练文本嵌入是各向异性的 (anisotropic)、占据一个狭窄的锥体（有三篇文献支持），所以在文本空间里检索意味着要分离紧密堆积的邻居，而 KG 空间提供更有区分度的目标。

把结构更好的那个空间定为目标，这与跨模态对齐里已被证明有效的「锁定编码器」配方 (LiT) 一致。

bidirectional 没带来额外收益：在每个评测设定里它只是镜像了对应的单向投影（D2T 镜像 text→KG、T2D 镜像 KG→text），**继承了后者的弱点**。

Q: 还有哪些具体发现？ A: 四条：

一、拼接大幅胜出。 text→KG 里 D2T 达 14.0 MRR，而 L1、L2、Hadamard 都 ≤ 3.9 。作者的解释是拼接在 3d 维向量里保留了可分离的主谓宾结构，另三个把三元组塌成 d 维——Hadamard 用固定的乘性形式（如 DistMult）、L1/L2 用平移形式（如 TransE）——可能丢掉了投影恢复关系所需的信息。基线比较里也能看到这个差距：**只有基于拼接的模型超过了语言化基线**。

二、KG 嵌入与三元组组合强交互，而边际平均会误导。 按所有算子平均，RotatE 看起来最好，但那只是因为它被表现差的算子伤害得最少——这是平均化伪影。固定拼接后排名反转：RDF2Vec 和 TuckER（都 14.4 MRR）超过 RotatE (13.1)；T2D 上差距急剧扩大，RotatE 崩到 4.2，而 RDF2Vec 是 10.6。

解释：**RDF2Vec 建立在图游走上的 Word2Vec，产生的分布式几何最接近语言模型的**（关系嵌入语义上有意义），所以最容易也最稳健地作为对齐目标。TuckER 的张量分解几何和 RotatE 的旋转几何**是为链接预测优化的，不是为与文本做余弦相似度**。

三、投影头是「边际视图会完全错过条件效应」的教科书例子。 线性投影在两个检索设定里都超过 MLP 和 cross-attention (15.4 / 14.1 / 12.4 MRR on D2T)。但**边际视图把这个效应完全藏住了**——按所有算子平均时，投影头只解释不到 0.4% 的 MRR 方差。一旦三元组组合固定为拼接，投影头就成了 D2T 上最大的单一因素，解释 69% 的方差。

四、硬负样本毫无用处，文本编码器在对齐后基本无关。

- 硬负样本：**in-batch 负样本就够了**。任何基于腐坏三元组的硬负策略都没有有意义的收益。唯一可见的偏离是只腐坏谓词，它**略差**。
- 文本编码器：基线里 BioBERT 远超 PubMedBERT (D2T 8.41 vs 4.43)，**对齐后这个差距反转**，PubMedBERT 略好并给出最佳整体配置。这说明**基线里观察到的编码器级差异，大部分可能由语言化表示而不是编码器本身解释**，一旦学了投影就基本无关了。

背景补充 / 点评

几个概念的位置

InfoNCE 是对比学习的标准损失 (van den Oord 等 2018)。对每个锚点 (一篇文档或一个三元组)，它的配对项是正例、同一 mini-batch 里的其他项是 in-batch 负例。本文温度设 0.07。

这个「**冻结两个编码器、只训一个轻量投影**」的方案有明确的谱系，作者交代得很清楚：源头在跨语言工作 (用一个线性映射对齐分别训练的词嵌入)，**CLIP** 用 InfoNCE 对齐图像和文本编码器，**LiT** 表明「冻结一个编码器、只调投影」往往就够了，近期工作用只训轻量投影器对齐两个冻结的单模态编码器，**用一小部分数据和算力就达到了对比训练模型的水平**。所以这不是本文发明的，本文的贡献是**把它系统化地用到「三元组级」的文本-图对齐上并做完整消融**。

MRR 与 Hits@k：MRR 是正确项排名倒数的平均值，Hits@k 是正确项落在前 k 名的比例。本文还额外报了**绝对中位排名**——这个指标比 MRR 更能看出「离可用还有多远」，因为 MRR 被前几名主导，而中位排名反映典型情况。

各向异性 (anisotropy) 指预训练语言模型的嵌入不是均匀分布在球面上，而是聚集在一个狭窄的锥体里。这是一个被反复观察到的现象，后果就是余弦相似度的区分度差——所有向量彼此都「有点像」。

这篇好在哪

最大的贡献不是那个 90% 的提升，而是「冻结骨干 + 一次只变一个组件」这个实验设计。六个维度能被公平比较，因为骨干固定；性能差异能被直接归因，因为一次只动一个。这在一堆「我们提出了 XXX，比基线好 Y%」的论文里是难得的。作者在结论里也把这个当成主要诉求：「我们希望这些发现能激励更透明的评估，包括**揭示是哪些组件在驱动性能的系统性消融**」。

「**edge case**」讲得最好的是**方向不对称那段**。「归约 vs 添加」这个框架不只解释了数据，还给出了一个**可操作的先验**：对齐两个空间时，**把信息更少、结构更好的那个定为目标**。而且它有两层论证——信息论上的 (逆问题欠定) 和几何上的 (文本嵌入各向异性)，后者还有文献支持。这比「实验表明 A 比 B 好」有用得多。

「**平均化伪影**」这一条是**全篇最该被记住的方法论警告**。RotatE 在边际平均下看起来最好，实际是「被差算子伤害最少」；投影头在边际下 <0.4%，固定组合后跳到 69%。**两个方向的错都出自同一个操作：在有强交**

互的因子上做边际平均。

四处该打折扣的地方

一、拼接的优势与维度不可分离，而作者只用一个脚注承认了。 原文脚注 9：「我们注意到拼接的优势与它更大的输出维度不可分离」。这是一个真实的混淆——拼接是 3d 维，其余三个是 d 维。**要分离这两个因素本来有办法**：给 Hadamard/L1/L2 的输出接一个升维层，或者把拼接降维到 d，两者论文都没做。

所以「保留可分离的主谓宾结构」这个解释是猜测而不是证明——同样的性能差完全可以纯粹由「投影的目标空间维度大三倍、容量更大」来解释。而三元组组合解释了 87% 的方差，也就是说**全篇最重要的那个结论，建立在一个未被排除的混淆上**。

二、一对一强制引入了已知方向的偏差，而作者用一个循环论证掩过去了。 为了得到配对数据集，同一段落被多个三元组选中时保留「谓词最不频繁（最有信息量）」的那个。**这系统性地偏向罕见谓词**，删了 794 个碰撞、还连带丢了 3 种关系类型。

然后作者用「macro MRR (18.00) 超过 micro (15.99)」来论证「结果不被少数高频谓词主导」。**这个论证是循环的**：数据集本身就被构造造成偏向罕见谓词，所以罕见谓词表现好并不说明模型对关系类型鲁棒，只说明数据集里罕见谓词的样本质量更高（它们是碰撞里的胜者）。

三、采样率 1.4%，评的可能是最容易的那一小块。 从 1,546,310 条单动作三元组到最终 22,293 对，采样率 1.4%。而更根本的数字是那个 **23.6%**——只有 23.6% 的三元组能一对一配到论文。

这个数字揭示了一件比论文说的更重要的事：「一个事实对应一段证据」这个假设在真实文献里大多数时候不成立。 论文选择限制在这一小块来简化评测（并且这与 InfoNCE 的单正例假设正好重合），代价是**评的可能是最好对齐的那部分**。作者在局限里提到了一对多和多对一，但没有讨论 1.4% 这个采样率对结论外推的影响。

四、MRR 15.99 的绝对水平不高，引用时不能读成「问题解决了」。 MRR 0.16 意味着正确答案平均排在第 6 位左右；Hits@1 只有 8.74%——十次里有九次第一名是错的。中位排名从 927 降到 38（在 22,293 个候选里）确实是巨大改进，但「典型情况下排第 38」离能直接用还很远。

论文的定位是「systematic comparison」而不是「SOTA」，所以这不算缺陷。但它和最后一条局限叠在一起就要紧了：**整篇的动机是知识锚定、证据检索、KG 补全三个下游用途，而检索 MRR 与这三者的实际收益之间没有建立任何联系**。作者自己承认「只做内在评估」，但这一条比它看起来更重——一个 Hits@1 只有 8.74% 的检索器，拿去给 LLM 做知识锚定，减少幻觉的效果是完全未知的。

对我的启示

一、这篇正对着我的第一难点，而且给了一个可以直接搬的架构。 我在统一模型 spec 里写过「跨产品的 `same_as` 边现在没有任何自动来源，这是第一难点」。这篇解决的是同一类问题的一个特例：**把自由文本证据与结构化三元组对齐**。

可搬的核心是「**两个编码器都冻结、只训一个轻量投影**」。这对我特别合适——我不需要重训任何模型，只需要一个投影层，而且全部能在 CPU 上跑（作者的对齐实验就是 CPU + 50GB 内存）。

具体到 Roleplay：我手里有 8,305 个去重语义点（自由文本）要对到 K1 - K8 / S1 - S12 的分类节点上，还要在跨企业之间找 `same_as`。这篇的 text→KG 方向正好对应「把语义点投到节点空间」。而昨天的批量初标是靠 LLM 逐条打标签——一个学好的投影可以给出「这个语义点最像哪几个已有节点」的排序，这正是 `same_as` 候选的自动来源。

二、「往结构更好的那个空间投」这条判据可以直接用。 作者的推理是双层的：信息论上 text→KG 是归约（丢冗余）、KG→text 是添加（重建缺失语境、逆问题欠定）；几何上文本嵌入各向异性、占狭窄锥体，在文本空间检索要分离紧密堆积的邻居。

所以对齐方向不是任选的。 我做语义点对齐时，方向必须是「语义点 → 节点空间」而不是反过来。这也解释了一件我之前没想清的事：为什么「给一个知识节点找出所有描述它的语义点」（T2D 方向）会比「给一个语义点找它属于哪个节点」（D2T 方向）难——**因为一个节点可以对应很多语义点，那是欠定的。**

三、 η^2 方差分解这个工具我该马上用在金标一致率上。 昨天我逐维度算了一致率（语义点五个维度全过线、评分要点的「七类」 $\kappa=0.60$ 和 `skill_kind` $\kappa=0.56$ 不过线），但只算了边际，没算维度之间的交互。

这篇的教训直接对应：**边际视图会完全错过条件效应**。如果「七类」和 `skill_kind` 这两个不过线的维度强相关（比如一旦七类判成「复合」、`skill_kind` 就必然跟着分歧），那它们**其实是一个问题不是两个**，改判据的方式也完全不同——应该先把七类判准，再看 `skill_kind` 的条件一致率。**下一轮金标要加一个七类 × `skill_kind` 的交叉表**，别再只报边际。

四、「平均化伪影」这个陷阱我今年已经踩过一次同类的。 2026-08-05 那次是「当日巨量组的个股次 5 日 +2.591%，看着远高于基准 +1.230%，但按交易日配对后差值只剩 +0.032%」——因为巨量的日子集中在市场大涨那几天。这篇是「RotatE 按所有算子平均看起来最好，但那只因为它被差算子伤害最少」。

共同结构：在有强交互的因子上做边际平均，会得到反的结论。

判据可以定下来了：**报任何边际效应之前，先看有没有一个因子解释了大部分方差；有的话，把它固定住再报其余因子的条件效应。** 这条对我的股票统计和知识点归类都适用。

五、数据集构建那四步，每一步都对应我的一个待解问题。

- 「只保留单动作交互、丢掉 40.5% 的多动作记录」，理由是「复合动作没有无歧义的 KG 表示」→ 这和我「一句一个命题，否则拆」准入规则、以及「复合类评分要点要拆成技能 + 知识两个节点」是同一个道理。作者的处理更激进：直接丢，不拆。我的场景里丢不掉（那是客户配置的全部内容），所以必须拆——但要记住拆是有代价的，作者认为拆不干净不如丢。
- 「共现是必要但不充分」（一句话可能同时提到两个实体却不描述它们的关系）→ 我的语义点归类里有完全同构的问题：一条评分要点提到了某个产品名，不等于它是那个产品的知识节点。昨天分出来的「指向某条信息」和「内容」两类，边界就在这里。
- 「用 cross-encoder 打分选证据，而且选工具有实测理由」（MedCPT 保留两个实体 94.8% vs BiomedBERT 丢掉至少一个 34.4%）→ 选工具有要有实测理由，不是选最新的那个。BiomedBERT 更

新，但在这个具体任务上差得多。

- 「一对一强制时保留谓词最不频繁的」 → 这一步引入了已知方向的偏差。我要避免同类操作：归并同企业同文的语义点时，如果按某个属性挑「保留哪一条」，那个属性就会被系统性放大。

六、Dereification 这一步我可能马上要面对。 CTD 用 reification（引入中间节点挂元数据）表示 n 元交互，一个交互变三个三元组；但标准 KG 嵌入模型独立处理三元组、穿过辅助节点的多跳路径不好捕捉，所以作者在抽取时把三三元组塌成一条带标签的直接边。

对应到我的统一模型：`learner_unit_state` 带 `scale_id`、`course_knowledge_unit` 带 `weight` 和 `kp_nature` ——这些都是 reified assertion（把关系变成节点或表以挂属性）。这个设计对人读和对查询是对的（昨天 FZI 那篇讲的「本体的用处是规定必须填哪些字段」就是这个价值）。

但如果以后要做嵌入，同样要面对「多跳路径不好捕捉」这个问题。 记一笔：reification 对人读、对 SQL 查询、对图嵌入，三者的代价完全不同。需要嵌入时可能要生成一份去具体化的视图。

七、注意它的采样率，别在干净子集上验证完就宣布可行。 $22,293 / 1,546,310 = 1.4\%$ ；更要紧的是只有 23.6% 的三元组能一对一配到论文。

我的语义点对齐会遇到完全同样的问题：**大部分语义点没有干净的一对一证据**——一次练习的对话会同时覆盖多条关键信息，一条关键信息也会在多次练习里被反复观测。这就是多对多。所以：**在干净的一对一子集上验证完，不等于方法可行。** 报结果时必须同时报「这个子集占全量的百分之几」。

文中金句

"Although these resources describe many overlapping facts, they represent them fundamentally differently... Consequently, there is no explicit correspondence between a scientific document (or one of its sections) and the relation that it describes." 尽管这些资源描述了大量重叠的事实，它们的表示方式却根本不同……因此，一篇科学文档（或它的某一段）和它所描述的那个关系之间，并不存在显式的对应关系。

"Projecting text into the KG space is a reduction: a document encodes more information than its triple counterpart... The reverse mapping is an addition: from a compact, decontextualized triple, $KG \rightarrow text$ must reconstruct precisely this missing context and surface realization. This inverse problem is under-determined... and recovering absent information is inherently harder than discarding it." 把文本投影到 KG 空间是一次归约：文档编码的信息比它对应的三元组更多……反向映射则是一次添加：从一个紧凑、去语境化的三元组出发， $KG \rightarrow text$ 必须重建正是那些缺失的语境和表面实现。这个逆问题是欠定的……而且恢复缺失的信息本质上比丢弃信息更难。

"pretrained text embeddings are anisotropic, occupying a narrow cone, so retrieving in text space means separating tightly packed neighbors, whereas the KG space offers more discriminative targets." 预训练文本嵌入是**各向异性的、占据一个狭窄的锥体**，所以在文本空间里检索意味着要分离紧密堆积的邻居，而 **KG 空间提供更有区分度的目标**。

"Averaged over all operators, RotatE appears best, but only because it is the least harmed by the poorly performing operators (i.e., averaging artifact)... Marginal averages over the composition operator are thus misleading." 按所有算子平均，RotatE 看起来最好，**但那只是因为它被表现差的算子伤害得最少（即平均化伪影）**……因此在组合算子上取边际平均是有误导性的。

"Co-occurrence is necessary but not sufficient, as a sentence may name both entities without describing their relationship." **共现是必要但不充分的**，因为一句话可能同时点出两个实体却并不描述它们之间的关系。

"Overall, simple choices win: projecting text into the KG space with a linear head over concatenated subject, predicate, and object embeddings performs best." 总体上**简单的选择胜出**：用一个线性头、在拼接后的主语、谓词、宾语嵌入之上，把文本投影到 KG 空间，表现最好。

全文翻译

摘要

Biomedical knowledge exists in two complementary but distinct forms: unstructured scientific literature and structured knowledge graphs (KGs). Aligning them is essential for knowledge grounding, evidence retrieval, and KG completion, yet existing methods do not explicitly align free-text evidence with KG triples.

生物学知识以两种互补但截然不同的形态存在：非结构化的科学文献与结构化的知识图谱（KG）。对齐两者对**知识锚定、证据检索、KG 补全**都是必需的，**然而现有方法并不显式对齐自由文本证据与 KG 三元组**。

We present a unified framework for systematically studying design choices for aligning biomedical text and KGs. With a text encoder and a KG embedding model both frozen, we learn only a lightweight projection between their spaces via a contrastive objective. This enables a fair comparison across six design dimensions: text encoder, KG embedding model, projection head, triple composition, training direction, and hard-negatives sampling.

我们提出一个统一框架，用于系统研究对齐生物学文本与 KG 的设计选择。**在文本编码器和 KG 嵌入模型都冻结的前提下，我们只通过一个对比目标学习两者空间之间的一个轻量投影。**这使得跨六个设计维度的公平比较成为可能：文本编码器、KG 嵌入模型、投影头、三元组组合、训练方向、硬负样本采样。

We construct CTD-Align, a corpus of over 22K one-to-one triple-document pairs linking chemical-gene interactions from the Comparative Toxicogenomics Database to supporting PubMed passages. We evaluate alignment on it in two retrieval settings: document-to-triple and triple-to-document.

我们构建了 **CTD-Align**，一个包含 2.2 万多个一对一「三元组-文档」对的语料库，把比较毒理基因组学数据库（CTD）里的化学-基因交互与支持它们的 PubMed 段落连接起来。我们在两个检索设定下评测对齐质量：文档到三元组、三元组到文档。

We find that the triple composition and the training direction (i.e., shared retrieval space) have the greatest impact, whereas the text encoder and hard-negatives sampling matter little. Overall, simple choices win: projecting text into the KG space with a linear head over concatenated subject, predicate, and object embeddings performs best. These findings establish lightweight contrastive alignment as an effective, practical foundation for bridging biomedical text and KGs.

我们发现**三元组组合与训练方向（即共享检索空间）影响最大，而文本编码器和硬负样本采样影响很小。**总体上**简单的选择胜出**：用一个线性头、在拼接后的主语、谓词、宾语嵌入之上，把文本投影到 KG 空间，表现最好。这些发现确立了**轻量对比对齐**作为连接生物学文本与 KG 的一个有效、实用的基础。

1. 引言：两种形态之间没有显式对应

Large language models (LLMs) have showcased impressive natural language understanding and generation capabilities... Despite their fluency, however, LLMs remain prone to hallucinating convincing yet unsupported or factually incorrect answers and to relying on outdated knowledge. These limitations are particularly concerning in knowledge-intensive domains that require specialized expertise, such as biomedicine and healthcare, where incorrect claims about chemicals, genes, or diseases may have direct clinical and toxicological consequences.

大语言模型展现了令人印象深刻的自然语言理解与生成能力……然而尽管流畅，**LLM 仍然倾向于产生令人信服却无依据或事实错误的答案，也倾向于依赖过时的知识。**这些局限在需要专业知识的知识密集型领域尤其令人担忧，例如生物学与医疗健康——**关于化学品、基因或疾病的错误论断可能带来直接的临床与毒理学后果。**

Biomedical knowledge is available in two complementary forms. The biomedical literature, through repositories such as PubMed, PMC, or Europe PMC, provides a vast but unstructured collection of scientific publications that LLMs can easily process. In parallel, biomedical knowledge graphs (KGs) provide structured, manually curated, and continually updated facts about biomedical entities (e.g., chemicals, genes, diseases) and their relationships.

生物医学知识以两种互补的形态存在。生物医学文献通过 PubMed、PMC、Europe PMC 这类仓库，提供了一个庞大但非结构化的科学出版物集合，LLM 可以轻易处理。与此并行，生物医学知识图谱提供**结构化、人工审编、持续更新**的关于生物医学实体（化学品、基因、疾病等）及其关系的事实。

Although these resources describe many overlapping facts, they represent them fundamentally differently: biomedical literature expresses knowledge in natural language, whereas KGs encode it as symbolic triples. Consequently, there is no explicit correspondence between a scientific document (or one of its sections) and the relation that it describes.

尽管这些资源描述了大量重叠的事实，**它们的表示方式却根本不同**：文献用自然语言表达知识，而 KG 把它编码为符号三元组。因此，一篇科学文档（或它的某一段）和它所描述的那个关系之间，并不存在显式的对应关系。

Yet many biomedical applications, such as grounding LLM-generated responses in KG information to mitigate hallucinations, retrieving textual evidence supporting or contradicting a given KG fact, and extracting relations from the literature to enrich or complete KGs as new findings are published, require precisely such correspondences. However, existing methods do not explicitly align biomedical free-text evidence with KG triples.

然而许多生物医学应用**恰恰需要这样的对应关系**：把 LLM 生成的回答锚定在 KG 信息上以缓解幻觉、检索支持或反驳某条 KG 事实的文本证据、以及随着新发现的发表从文献中抽取关系来丰富或补全 KG。但**现有方法并不显式对齐生物医学自由文本证据与 KG 三元组**。

Existing approaches for integrating language models (LMs) and KGs suffer from two major limitations. First, representation integration approaches either inject pre-aligned KG entity or triple embeddings into an LM to enrich its representations or leverage LMs for KG-specific tasks, such as link prediction or KG completion, by encoding entities and relations using their textual descriptions. Consequently, these methods are optimized for downstream tasks (i.e., question answering, relation extraction), rather than for learning an explicit mapping between free-text evidence and structured triples.

现有的语言模型与 KG 集成方法有两大局限。**第一，表示集成方法**要么把预对齐的 KG 实体或三元组嵌入注入 LM 以丰富其表示，要么用实体和关系的文本描述来编码它们、从而借 LM 做链接预测或 KG 补全这类 KG 专属任务。**因此这些方法是为下游任务（问答、关系抽取）优化的，而不是为学习自由文本证据与结构化三元组之间的显式映射。**

Second, text-graph alignment methods typically align individual nodes instead of complete facts or ignore graph structure by linearizing triples into text. Moreover, these techniques are developed and evaluated on general-domain data, whose vocabulary, entity types, and relation semantics differ significantly from those found in biomedicine.

第二，文本-图对齐方法通常**对齐单个节点而不是完整事实**，或者通过把三元组线性化成文本而忽略图结构。此外这些技术是在通用域数据上开发和评测的，那里的词汇、实体类型和关系语义与生物医学中的差别很大。

三条贡献。 1) 引入一个统一、模块化的框架来系统比较 LM 与 KG 之间的对齐策略。框架围绕一个简单的骨干构建：给定一个生物医学文本编码器和一个 KG 嵌入模型，**两者都保持冻结**，只用对比 (InfoNCE) 目标训练它们嵌入空间之间的一个轻量投影。**保持骨干固定、每次只变一个组件、在共同的调参与评测协议下比较，我们就能把性能差异直接归因到每个设计维度。** 2) 据我们所知，**没有现存资源把生物医学三元组与表达它们的文档配对**，因此我们构建了 CTD-Align，一个 22,293 个一对一「三元组-文档」对、带完整 provenance 的可复用语料库。3) 我们发现**三元组组合算子与训练方向影响最大**，而文本编码器与硬负样本采样策略在空间对齐之后影响很小；并进一步表明**更简单的设计选择胜过更复杂的替代方案。**

2. 相关工作

2.1 语言模型与 KG 的集成。 One line of work injects structured knowledge into LMs to improve downstream tasks such as relation classification or question answering: ERNIE and KnowBERT fuse linked entity embeddings into contextual word representations, K-BERT inserts relevant triples into the input as a soft-positioned sentence tree, KEPLER jointly optimizes a knowledge embedding and a masked language modeling objective, and DRAGON fuses a text encoder and a graph neural network through joint pretraining.

一条线是**把结构化知识注入 LM** 以改善关系分类、问答这类下游任务：ERNIE 和 KnowBERT 把链接后的实体嵌入融进上下文词表示，K-BERT 把相关三元组作为**软位置句树**插入输入，KEPLER 联合优化知识嵌入与掩码语言建模目标，DRAGON 通过联合预训练融合文本编码器与图神经网络。

A complementary line uses LMs for KG-specific tasks, most prominently KG completion. Early works learned a shared text-KG embedding space from scratch, aligning word and entity embeddings through co-occurrence and entity names or encoding entity descriptions directly into the KG model. Later approaches, such as KG-BERT, fine-tune BERT as a cross-encoder over a triple's concatenated component descriptions to score its plausibility, whereas SimKGC recasts this as a contrastive learning with a bi-encoder.

互补的一条线是**用 LM 做 KG 专属任务**，最突出的是 KG 补全。早期工作从零学习一个共享的文本-KG 嵌入空间，通过共现和实体名对齐词嵌入与实体嵌入，或把实体描述直接编码进 KG 模型。后来的方法如 KG-BERT 把 BERT 微调成一个 cross-encoder、在三元组各成分描述的拼接上打可信度分，而 SimKGC 用 bi-encoder 把它重构为对比学习。

All of these approaches primarily train the underlying encoders for a downstream task or for KG completion. We instead keep both the KG and the text encoder frozen, learn only a lightweight projection between their output spaces, and target the retrieval between evidence documents and triples rather than knowledge injection or completion.

所有这些方法主要是为某个下游任务或为 KG 补全而训练底层编码器。我们则让 KG 编码器和文本编码器都保持冻结，只学习它们输出空间之间的一个轻量投影，并且瞄准的是证据文档与三元组之间的检索，而不是知识注入或补全。

2.2 嵌入空间对齐与检索。 We study an alignment scheme from a broader family that maps two independently trained embedding spaces onto one another with a lightweight transformation, an idea rooted in cross-lingual work, where a linear map aligns separately trained word embeddings. The same principle underpins cross-modal alignment. CLIP aligns image and text encoders with an InfoNCE objective, LiT shows that freezing one encoder and tuning only the projection often suffices, and recent work aligns two frozen unimodal encoders by training only lightweight projectors, matching contrastively trained models at a fraction of the data and compute.

我们研究的对齐方案来自一个更大的家族：**用一个轻量变换把两个独立训练的嵌入空间映射到彼此之上**。这个想法**源于跨语言工作**——用一个线性映射对齐分别训练的词嵌入。同样的原理支撑着跨模态对齐：**CLIP** 用 InfoNCE 目标对齐图像与文本编码器，**LiT 表明冻结一个编码器、只调投影往往就够了**，而近期工作通过只训练轻量投影器来对齐两个冻结的单模态编码器，**用一小部分数据和算力就达到了对比训练模型的水平**。

Several works align natural language with graph structure. ConGraT contrastively aligns node-associated text with graph representations, and JointGT learns joint graph-text representations with an alignment objective for KG-to-text generation. In contrast to our approach, these models train their encoders rather than keeping them frozen, and align individual nodes or general graph-structured inputs rather than KG triples.

有若干工作对齐自然语言与图结构。ConGraT 对比式地对齐节点关联文本与图表示，JointGT 为 KG-to-text 生成学习带对齐目标的联合图-文本表示。**与我们的方法不同，这些模型训练它们的编码器而不是保持冻结，并且对齐的是单个节点或一般的图结构输入而不是 KG 三元组**。

我们的设定与另一项把 RDF 图线性化成 token 序列、训练孪生 Transformer 编码器加 in-batch 对比损失的工作有三点不同：**我们保留一个独立训练的结构化 KG 嵌入空间**而不是把线性化的图重新当作文本编码；**只在冻结编码器之上学一个轻量投影**；而且**把每篇文档与一个精确的主谓宾三元组配对**，而不是与一个可能包含多个三元组的图配对。

2.3 生物医学领域的文本-KG 对齐。 Aligned-LLM aligns frozen KG entity embeddings with an LM's space via a learned projection to improve factual grounding, and BALI contrastively aligns an LM with a UMLS graph encoder using linked concept mentions. At the mention level, biomedical bi-encoders such as SapBERT link text spans to single KG concepts. These approaches operate at the entity or concept level and target improved generation or classification.

Aligned-LLM 通过一个学到的投影把冻结的 KG 实体嵌入与 LM 的空间对齐以改善事实锚定，BALI 用链接的概念提及对比式地对齐 LM 与 UMLS 图编码器。在提及层面，SapBERT 这类生物医学 bi-encoder 把文本片段链接到单个 KG 概念。**这些方法都在实体或概念层面运作，目标是改善生成或分类**。

In contrast, we align triples with their evidence documents, evaluate bidirectional retrieval between them, and study the effect of different encoders and alignment components under a controlled frozen-encoder framework. To the best of our knowledge, such a systematic study of triple-level biomedical text-KG alignment has not yet been conducted.

相比之下，我们把三元组与其证据文档对齐、评测两者之间的双向检索、并在一个受控的冻结编码器框架下研究不同编码器与对齐组件的效果。据我们所知，这样一项三元组级的生物医学文本-KG 对齐的系统研究此前尚未开展。

3. 方法

3.1 数据表示。 In a knowledge graph with entity set E and relation set R , a fact is represented as a triple $t = (s, p, o)$. In the biomedical literature, the same fact is described by a document, namely a passage of an article (i.e., sentence or paragraph), that states the relation between s and o . We embed the two modalities separately with a frozen text encoder and a frozen KG embedding model.

在实体集 E 、关系集 R 的知识图谱里，一个事实表示为三元组 $t = (s, p, o)$ 。在生物医学文献里，同一个事实由一篇文档描述——即文章中陈述 s 与 o 之间关系的一个段落（句子或自然段）。我们用一个冻结的文本编码器和一个冻结的 KG 嵌入模型分别嵌入这两个模态。

四个三元组组合算子 ϕ : (i) 拼接 $t = [s;p;o]$ 、(ii) Hadamard 积 $t = s \odot p \odot o$ 、(iii) 逐元素 L1 组合 $t = |s+p-o|$ 、(iv) 逐元素 L2 组合 $t = (s+p-o)^2$ 。

3.2 对齐方法。 The alignment stage learns a lightweight projection that maps one modality into the embedding space of the other, such that a document and its corresponding triple become nearest neighbors under cosine similarity. The triple-composition operator determines the triple embedding dimension: concatenation yields $3d$, whereas the Hadamard product and the L1 and L2 approaches yield d .

对齐阶段学习一个轻量投影，把一个模态映射到另一个模态的嵌入空间，使得一篇文档与它对应的三元组在余弦相似度下成为最近邻。三元组组合算子决定三元组嵌入的维度：拼接得到 $3d$ ，而 Hadamard 积与 L1、L2 方法得到 d 。

投影头。 The Linear head applies a single linear transformation without any hidden layer, nonlinearity, normalization, and dropout. The MLP head is a feed-forward network whose hidden layers each apply a linear transformation, layer normalization, a GELU activation, and dropout. Finally, the cross-attention head projects the document embedding into a single key-value vector, to which three learnable query vectors - one per triple element - attend through a multi-head attention layer.

Linear 头只做一次线性变换，没有任何隐层、非线性、归一化和 dropout。MLP 头是一个前馈网络，每个隐层做线性变换、层归一化、GELU 激活和 dropout，最后一层线性映射到目标维度。**cross-attention** 头把文档嵌入投影成单个 key-value 向量，三个可学习的查询向量（每个三元组成分一个）通过多头注意力层关注它，输出拼接后线性映射到目标维度。由于 key-value 序列只是一个向量，这实际上是文档嵌入的一次学到的多查询投影，而不是对词的 token 级注意力。

训练方向。 三种设定：(i) **text→KG** 把文档嵌入投影到 KG 三元组空间；(ii) **KG→text** 把三元组嵌入投影到文档空间；(iii) **bidirectional** 随机把每个 batch 分配给两个方向之一。由于输入输出维度不同，**每个方向训练一个独立的投影网络。**

训练目标。 全部用 InfoNCE 损失。对每个锚点（一篇文档或一个三元组），其配对项是正例、mini-batch 内其他项是 in-batch 负例。可选地，通过在 KG 空间腐坏一个正例三元组来增加硬负样本，四种腐坏方案分别替换 (i) 谓词、(ii) 宾语、(iii) 主语、(iv) 两个实体。由于腐坏发生在 KG 三元组空间里，它们天然适用于 **text→KG** 方向；在 **KG→text** 方向目标是文档嵌入，无法生成硬负样本。

3.3 检索任务。 给定一个查询（文档或三元组），通过学到的映射投影它，按余弦相似度对目标模态的所有候选排名。两个互补任务：**D2T**（为一篇证据文档检索正确的 KG 三元组）与 **T2D**（为一个三元组检索描述它的文档）。

4. 语料与数据集构建

4.1 CTD 知识图谱。 CTD 是一个公开资源，从科学文献中人工审编化学品、基因、表型与人类疾病之间的关系。它是生命科学 Bio2RDF 链接数据项目的一部分，包含约 380 万条审编的直接交互。**对我们的目的至关重要的是：每一条直接交互都标注了报告它的文章的 PubMed 标识符 (PMID)，从而给每个事实一个显式的文本来源。**

去具体化 (Dereification)。 Like many other RDF resources, CTD represents each n-ary interaction through reification, i.e., an intermediate node to which metadata can be attached. Standard KG embedding models, however, tend to treat each triple independently, which makes multi-hop paths through auxiliary nodes less straightforward to capture. We therefore dereify CTD during extraction, collapsing each three-triple pattern into a single direct edge labeled with the interaction's action type.

和许多其他 RDF 资源一样，CTD 通过「具体化」表示每个 n 元交互，即引入一个可以挂元数据的中间节点。（脚注：一条化学-基因交互被编码为三个三元组：`chemical→interaction_node`、`interaction_node→action`、`interaction_node→gene`。）然而标准 KG 嵌入模型倾向于独立处理每个三元组，这使得穿过辅助节点的多跳路径不那么容易被捕捉。因此我们在抽取时对 CTD 去具体化，把每个三元组模式塌成一条以交互动作类型为标签的直接边（如 `increases expression`）。

图构建。 We build the enriched CTD KG by iteratively growing it outward from the chemical-gene interactions linked to textual evidence: we attach every chemical-disease, gene-disease, and gene-pathway association whose chemical or gene is already in the graph, so that the added disease and pathway nodes act as hubs linking otherwise-isolated chemicals and genes.

我们从**有文本证据的化学-基因交互**（即 core 集）出发迭代地向外生长来构建 enriched CTD KG：把化学品或基因已在图中的每一条化学-疾病、基因-疾病、基因-通路关联都挂上，**从而让新加入的疾病和通路节点充当枢纽，连接起原本彼此孤立的化学品和基因。**重复此过程直到无法再加入任何连通的关联或达到目标图规模，最后保留最大连通分量、丢弃 10 个小的孤立分量。

4.2 PubMed 语料。 用 PubTator (NCBI 的一项服务, 自动标注 PubMed 上的生物医学实体及其关系) 的 3.0 API, 为 CTD 交互中记录的每个 PMID 取回摘要和标题, 其化学品与基因提及已归一化到 CTD 标识符, 从而可以直接在文本中定位每个三元组的实体。

4.3 CTD-Align 数据集。 (四步构建详见「核心内容」。) 最终数据集来自 17,530 篇源出版物, 含 22,293 个「三元组-文档」对, 每个包含一个化学品、一个基因、一个单动作关系、一篇支持文档 (平均长度 303 字符)、以及供完整溯源的源 PMID。

5. 实验设置

KG 嵌入。 三个捕捉图结构不同侧面的模型: RotatE (在复向量空间嵌入实体和关系, 把每个关系建模为从主语到宾语的逐元素旋转, 从而捕捉对称/反对称、逆、组合等模式)、TuckER (基于主谓宾二值张量的 Tucker 分解的双线性模型, 产生一个完全可表达的因子分解)、RDF2Vec (不优化三元组打分目标, 而是在图上抽取随机游走、在游走上训练 Word2Vec 来得到实体嵌入)。

三个模型都在 enriched CTD KG 上预训练 (含完整的 core 三元组), 以得到领域适配的 KG 嵌入。RotatE 和 TuckER 的超参用 TPE 采样在 51,289 条验证三元组 (enriched 图的 5%) 上按链接预测调, RDF2Vec 的超参用网格搜索按实体类型预测调。

文档嵌入。 两个领域专用预训练 LM: BioBERT (从 BERT 初始化, 再在 PubMed 摘要和 PMC 全文上继续预训练) 和 PubMedBERT (完全从零、只在生物医学语料上训练)。两者都通过对 token 级表示做 mean pooling 得到 768 维文档嵌入。

对齐模型。 对每一个 (文本编码器 $\times$ KG 嵌入 $\times$ 投影头 $\times$ 三元组组合 $\times$ 硬负样本策略 $\times$ 训练方向) 的组合分别做超参优化。投影器隐层维度在 {256, 512} 里搜到 256 最好 (线性投影器不用这个超参), dropout 0.273, 权重衰减 1.33×10^{-3} , 学习率 1.05×10^{-3} 。InfoNCE 温度 0.07。用 AdamW 优化, 最多 100 轮、早停耐心 15 轮、batch size 256、梯度裁剪 1.0。

基础设施。 RotatE 和 TuckER 在单张 NVIDIA A100 (80 GB) 和 H100 (94 GB) 上训练, RDF2Vec 在 48 核 CPU、128 GB RAM 的机器上训练, 所有对齐实验在 CPU 上进行, 每个作业分配 50 GB RAM。

5.2 评测协议。 除完整网格比较外, 还包含一个简单基线: 把每个三元组用其主语名、谓词标签、宾语名语言化 (如「Cyclophosphamide metabolic processing CYP2B6」), 用与文档相同的文本编码器嵌入结果文本, 然后按余弦相似度排名候选。这个基线只依赖文本编码器、完全不用 KG 嵌入。

评测用按 PubMed 论文分组的 5 折交叉验证, 以确保同一篇文章的文档绝不同时出现在训练集和测试集里。每折内留出 15% 训练样本做验证。报告五折的均值与标准差, 指标为 MRR、Hits@k 以及在完整候选池上计算的正确项中位排名——也就是说每个查询都对目标模态的整个候选池排名 (D2T 是全部 KG 三元组、T2D 是全部文档), 而不是对采样的负例子集排名。

6. 结果与讨论

6.1 总体检索性能。 Learning a projection between the two frozen text and KG embedding spaces substantially outperforms the baseline in both retrieval settings. The best model projects text into the KG space with a linear head over the concatenation of the subject, predicate, and object embeddings; it improves MRR by 90% on D2T and 64% on T2D over the stronger (BioBERT) baseline.

在两个冻结的文本与 KG 嵌入空间之间学一个投影，在两个检索设定里都大幅超过基线。 最佳模型用一个线性头、在主语、谓词、宾语嵌入的**拼接**之上把文本投影到 KG 空间；相对更强的（BioBERT）基线，它在 D2T 上把 MRR 提升 **90%**、在 T2D 上提升 **64%**。

在完整排名上的收益更大：正确项的中位排名在 D2T 上从 927 降到 38 (**24 倍改进**)、在 T2D 上从 845 降到 55 (**15 倍改进**)，Hits@10 在两个设定里大致翻倍。

Performance is also balanced across relation types. For the best model, relation-averaged (macro) MRR exceeds the instance-level (micro) value (18.00 vs. 15.99 on D2T), indicating that the results are not dominated by a few frequent predicates. Notably, the strongest baseline uses BioBERT, whereas the best alignment model uses PubMedBERT, indicating that once the projection is learned, retrieval becomes largely independent of the text encoder that a purely text-based approach depends on.

性能在关系类型之间也是平衡的。 最佳模型的关系平均（macro）MRR 超过实例级（micro）值（D2T 上 18.00 vs 15.99），表明结果**不是由少数高频谓词主导**。值得注意的是，最强的基线用 BioBERT，而最佳对齐模型用 PubMedBERT，**这表明一旦投影被学到，检索就在很大程度上独立于纯文本方法所依赖的那个文本编码器。**

6.2 对齐的目标空间。 Crucially, projecting text into the KG space outperforms the other training directions in both evaluation settings. The alternative strategies are strongly asymmetric: the bidirectional approach matches text→KG on D2T (15.15 vs. 15.99 MRR), but collapses on T2D (5.74 vs. 12.13 MRR), while KG→text heavily underperforms in both settings, falling below the strong (BioBERT) verbalization baseline.

至关重要的是，把文本投影到 KG 空间在两个评测设定里都优于其他训练方向。 替代策略强烈不对称：**bidirectional** 在 D2T 上匹配 text→KG (15.15 vs 15.99 MRR)，**但在 T2D 上崩塌** (5.74 vs 12.13 MRR)；而 **KG→text** 在两个设定里都严重欠佳，落到强（BioBERT）语言化基线之下。

We hypothesize that this asymmetry stems from the two mappings being ill-posed in opposite ways... The geometry of the two spaces reinforces this asymmetry... Fixing the better-structured space as the target resembles the locked-encoder recipe that has proven effective in cross-modal alignment.

我们假设这个不对称源于**两个映射在相反方向上是不良设定的**（归约 vs 添加的完整论证见「核心内容」）。两个空间的几何强化了这个不对称……把结构更好的那个空间定为目标，与跨模态对齐中已被证明有效的「**锁定编码器**」配方类似。

最后我们发现 **bidirectional 策略没有带来进一步收益**：在每个评测设定里它都镜像了对应的单向投影（D2T 镜像 text→KG、T2D 镜像 KG→text），**继承了后者的弱点**。因此 T2D 仍然是在区分度较低的文本空间里排名。

6.3 各设计维度的影响。 For each factor, we average MRR over all configurations that share a given level of that factor (its marginal effect) and quantify the factor's share of the variance with a one-way η^2 . Almost all of the variance can be attributed to a single factor. Specifically, the triple composition alone explains 87% of the D2T and 62% of the T2D MRR variance, and the KG embedding a further 6% and 3%, respectively. The projection head, text encoder, and negative sampling scheme, have a negligible impact, each explaining less than 1%.

对每个因子，我们在共享该因子某一水平的所有配置上平均 MRR（其**边际效应**），并用一元 η^2 量化该因子占方差的份额。**几乎全部方差都可归于单一因子：三元组组合单独解释 D2T 的 87%、T2D 的 62% 的 MRR 方差，KG 嵌入再分别解释 6% 和 3%。投影头、文本编码器、负采样方案影响可忽略，各解释不到 1%。**

注意各因子的主效应不必加起来等于一：**余下部分反映的是交互作用**（尤其是 KG 嵌入与三元组组合之间的交互）与残差方差。**因此我们先分析三元组组合算子的效应，然后把它固定到最佳值（拼接），再把其余因子作为条件效应研究。**

三元组组合。 Concatenation preserves the separable subject-predicate-object structure in a 3d vector, whereas the other three operators collapse the triple into a d-dimensional vector - the Hadamard product via a fixed multiplicative form (as in DistMult), and the L1/L2 operators via a translation one (as in TransE) - potentially discarding the information needed by the projection to recover the relation.

拼接在一个 3d 向量里保留了可分离的主谓宾结构，而另外三个算子把三元组塌成一个 d 维向量——Hadamard 积通过一个固定的乘性形式（如 DistMult）、L1/L2 算子通过一个平移形式（如 TransE）——可能舍弃了投影恢复关系所需的信息。（脚注：我们注意到拼接的优势与它更大的输出维度不可分离。）

KG 嵌入与三元组组合的交互。 RDF2Vec, built from Word2Vec over graph walks, yields a distributional geometry closest to that of LMs (i.e., semantically meaningful relation embeddings). This plausibly makes it the easiest and most robust alignment target across retrieval settings. In contrast, TuckER's tensor-factorization geometry and RotatE's rotational one are optimized for link prediction rather than cosine similarity with text.

RDF2Vec 建立在图游走之上的 Word2Vec，产生的分布式几何最接近语言模型的（即关系嵌入在语义上有意义）。这可能使它成为跨检索设定最容易也最稳健的对齐目标。**相比之下，TuckER 的张量分解几何与 RotatE 的旋转几何是为链接预测优化的，而不是为与文本做余弦相似度。**

6.4 次要设计选择。 The marginal view hides this effect entirely, as the projection head explains under 0.4% of MRR variance when averaged over all operators. However, once the triple

composition is fixed to concatenation, the projection head becomes the single largest factor on D2T, explaining 69% of the variance among concatenation-based configurations.

边际视图把这个效应完全藏住了——在所有算子上平均时，投影头解释不到 0.4% 的 MRR 方差。然而一旦三元组组合被固定为拼接，投影头就成为 D2T 上最大的单一因素，在基于拼接的配置中解释 69% 的方差。

硬负样本采样。 对比配对的文档与三元组和 in-batch 负例就足以训练对齐模型。任何基于腐坏三元组的硬负策略在 text→KG 或 bidirectional 方向上都没有提供任何有意义的收益。唯一可见的偏离是只腐坏谓词，它在两个设定里略差。

文本编码器。 一旦学了投影，BioBERT 与 PubMedBERT 之间的选择影响很小。这与语言化基线形成鲜明对比——那里 BioBERT 远超 PubMedBERT (D2T 上 8.41 vs 4.43, T2D 上 7.41 vs 2.83)。对齐之后这个差距反转，PubMedBERT 略好并给出最佳整体配置。这指向一个事实：基线中观察到的编码器级差异，大部分可能由语言化表示而不是编码器本身解释，而一旦学了投影就基本无关了。

7. 局限与未来工作（作者自述）

Our analysis trades breadth for a controlled comparison of design dimensions. First, we evaluate a single relation family (chemical-gene interactions) from one resource (CTD). Replicating the comparison on broader biomedical KGs with richer relation sets would test whether the findings transfer to other relation types.

我们的分析以广度换取对设计维度的受控比较。 第一，我们只评测了来自一个资源（CTD）的单一关系族（化学-基因交互）。在更广的、关系集更丰富的生物学 KG（如 Hetionet、PrimeKG）上复现这个比较，才能检验发现是否迁移到其他关系类型。

Second, we restrict evaluation to one-to-one triple-document pairs, whereas in practice a document may describe several interactions (one-to-many) and multiple documents may support the same triple (many-to-one). This isolates the core alignment signal and simplifies evaluation, but it also coincides with the single-positive assumption of InfoNCE. A natural extension is many-to-many alignment via a multi-positive (supervised) contrastive objective that treats all valid document-triple matches as positives.

第二，我们把评测限制在一对一的「三元组-文档」对上，**而实践中一篇文档可能描述多个交互（一对多）、多篇文档可能支持同一个三元组（多对一）**。这样做隔离了核心对齐信号并简化了评测，但它也正好与 InfoNCE 的单正例假设重合。一个自然的扩展是通过**多正例（有监督）**对比目标做多对多对齐，把所有有效的文档-三元组匹配都当作正例。

Finally, we assess alignment intrinsically through retrieval. Evaluating the learned representations on a downstream task, such as KG completion or evidence-grounded retrieval, would more directly measure their practical utility.

最后，我们[只通过检索做内在评估](#)。在下游任务（如 KG 补全或证据锚定检索）上评测学到的表示，才能更直接地衡量它们的实用价值。

8. 结论

We introduce a unified framework to systematically compare lightweight strategies for aligning biomedical text and KGs across six key design dimensions. Through extensive retrieval experiments on CTD-Align, we find that the triple-composition operator and the shared retrieval space (i.e., training direction) have the greatest impact, whereas the text encoder and hard-negatives selection matter comparatively little. Simpler approaches consistently outperform more complex ones. We hope these findings will inspire more transparent evaluation, including systematic ablations that uncover the components driving performance.

我们引入一个统一框架，跨六个关键设计维度系统比较对齐生物学文本与 KG 的轻量策略。通过在 CTD-Align（一个超过 2.2 万对一对一化学-基因三元组-文档的新语料库）上的广泛检索实验，我们发现[三元组组合算子与共享检索空间（即训练方向）影响最大，而文本编码器与硬负样本选择相对影响很小](#)。更简单的方法一致地优于更复杂的方法。我们希望这些发现能激励[更透明的评估](#)，包括揭示是哪些组件在驱动性能的系统性消融。

生成式 AI 使用声明（原文照录）：在本工作的准备过程中，作者使用了 Opus 4.8 与 Codex (GPT 5.5)，用于：生成图片、生成摘要、改写与措辞、改进写作风格、语法与拼写检查、[同行评审模拟](#)、以及代码支持。使用这些工具后，作者审阅并按需编辑了内容，并对本出版物的内容负全部责任。

参考链接

- github.com/ritatsousa/bio-text-kg-alignment — 论文的完整实现，含六个维度的网格实验代码
- [CTD-Align 数据（同一仓库的 CTD_to_PubTator/kg_data）](#) — 22,293 个一对一「三元组-文档」对，带源 PMID 的完整 provenance
- [Comparative Toxicogenomics Database \(CTD\)](#) — 结构化事实的来源，约 380 万条人工审编的直接交互，[每条都标注了报告它的 PMID](#)，这是本文能配对的前提
- [PubTator 3.0](#) — NCBI 的实体标注服务，本文用它把摘要里的化学品与基因提及归一化到 CTD 标识符
- [MedCPT](#) — 用来选证据段落的 cross-encoder，从 PubMedBERT 初始化、在 1,830 万 PubMed 查询-文章对上对比训练。选它而非 BiomedBERT Reranker 2 有实测依据（保留两个实体 94.8% vs 丢失至少一个 34.4%）
- [gensim Word2Vec 文档](#) — RDF2Vec 的 Skip-gram 用的是这里的默认参数