

用布鲁姆分类法给推理轨迹做认知画像 Cognitive Profiling of LRMs' Reasoning Traces Using Bloom's Taxonomy

本篇范围说明：这是一篇 arXiv 论文 (2608.23205v1, 2026-08-24, 希腊雅典娜研究中心语言与语音处理研究所 / 雅典国立技术大学)。下面「全文翻译」一节按章节覆盖摘要、引言、方法（标注流水线与人机一致性）、四个研究问题的结果、结论与局限；参考文献列表、附录里的提示词模板与逐图坐标不译。

核心内容

Q: 这篇论文问的是什么问题？

A: 一句话——不是问「推理的每一步在做哪道工序」，而是问「模型在这一步用的是哪一类思维」。

论文自己把这个区分讲得很清楚。已有工作（用 Schoenfeld 的情节理论）把数学解题拆成阅读、规划、实施、探索、验证这类过程性阶段；而这篇换了一个抽象层次：

我们的框架把逐字复述题目（记忆）与通过改述或推断题意来构建含义（理解）区分开，而 Schoenfeld 把两者都归为「阅读」。反过来，我们把「回忆一条相关定理」和「回忆题目本身」都归入记忆，而 Schoenfeld 把前者归为分析、后者归为阅读。

Q: 布鲁姆分类法是什么？

A: 教育学里把认知目标分层的一套框架，六个层级由低到高：记忆、理解、应用、分析、评价、创造。这篇用的是 Anderson 与 Krathwohl 2001 年的修订版。

Q: 怎么给推理轨迹打标签的？

A: 三步流水线：生成思维链 → 自动切分成推理步骤并逐步标注布鲁姆层级 → 分析。

标注器是 Llama-3.3-70B-Instruct，被要求同时做三件事：把轨迹切成离散的认知步骤、给每步指派层级、并给出指派该标签的理由。

为什么用大模型切分而不是按句切分，论文给了理由：单个思维过程可能跨多个句子，更结构化的做法会人为地把一个认知功能切碎，反而降低标注准确度。作者明说这是「标注一致性与语义保真度之间的权衡」。

Q: 这个自动标注可信吗？

A: **这是全篇方法论上最结实的一处。** 两名人类标注者（一位作者、一位由作者训练的非作者，都有 AI 背景且熟悉布鲁姆分类法）独立标注了 100 个样本、共 **1633 个推理步骤**，与大模型标注对比：

一致性	科恩 Kappa
人类 H1 与 H2 之间	0.8928
大模型与 H1	0.9173
大模型与 H2	0.9132

大模型与任一个人的一致性，都高于两个人彼此之间的一致性。 这个结果值得停一下——它说明在这个任务上，自动标注不只是「够用」，而是比人类标注者之间的分歧还小。

一处诚实的限定：评估只针对标签质量、没有评估切分质量；切分只由一位作者对 50 个样本做了定性检查。

Q: 数据规模？

A: 三个数学数据集共 **3138 个样本**：GSM8K（小学水平，1319）、GSM-hard（把小数字换成大数字、计算量更大，1319）、MATH500（竞赛级，500）。七个模型：DeepSeek-R1 及其三个蒸馏版、Qwen3 两个思考版、Phi-4-Reasoning。

四个发现

一、应用占绝对主导，创造几乎为零

各模型内部推理轨迹里六个层级的步骤占比：

模型	记忆	理解	应用	分析	评价	创造
DeepSeek-R1	11.8	24.0	32.9	12.5	18.6	0.2
R1-Distill-Llama-8B	13.5	18.7	44.2	14.1	9.3	0.3
R1-Distill-Qwen-7B	11.5	17.7	43.9	12.8	14.1	0.1
R1-Distill-Qwen-1.5B	10.9	18.8	35.6	13.5	21.0	0.1
Qwen3-30B-A3B-Thinking	9.4	18.8	33.4	12.7	25.6	0.1
Qwen3-4B-Thinking	9.0	20.8	32.5	14.3	23.1	0.2
Phi-4-Reasoning	28.4	21.0	26.9	10.1	12.7	0.9

应用占 26.9% 到 44.2%，而创造在每个模型上都不到 1%。 论文对创造的解释很克制——它说这与**所用基准的性质一致**，也就是说这可能是任务决定的，不是模型能力的定论。

理解（17.7% - 24.0%）和分析（10.1% - 14.3%）在所有模型上都占稳定的中间带，论文称之为「认知的结缔组织」。

二、蒸馏会改变思维风格，而且不随规模单调变化

这是我认为最有价值的一条发现。

教师模型 DeepSeek-R1 是 32.9% 应用 / 18.6% 评价。三个蒸馏版：

蒸馏版	应用	评价	与教师比
Llama-8B	44.2	9.3	更偏执行、评价大幅减少
Qwen-7B	43.9	14.1	同上
Qwen-1.5B	35.6	21.0	反而更像教师

最小的 1.5B 比更大的 7B、8B 更接近教师。论文的推测是：应用偏重这个倾向可能随着蒸馏学生变大而加剧。

Qwen3 家族是评价重的：两个变体的评价占比最高（25.6%、23.1%），同时记忆占比最低（9.0% - 9.4%）——论文形容为「偏好检查与批判、而非事实回忆」的认知风格。

Phi-4-Reasoning 是明显的异类：记忆占比最高（28.4%，是多数模型的两倍以上）、分析最低、应用最低、创造最高（虽然仍只有 0.9%）。它不把认知努力集中在应用上，而是较均匀地分布在各层级。论文在附录里论证了这是模型自身的性质、不是系统提示词造成的。

三、一条没人明确要求、却自己涌现出来的认知弧线

按步骤在轨迹中的相对位置（归一化到 0 - 100，分十档）看各层级占比：

在几乎所有模型上，各认知层级的时间动态遵循一条连贯的 记忆—理解—应用—评价 弧线，这条弧线映照了布鲁姆分类法自身的层级顺序——一个从未被显式强制、却与经典布鲁姆序列一致的涌现排序。

逐个看：

- 记忆前置：多数模型从 0.2 - 0.45 起步，在轨迹前 20% 内急剧衰减。Phi-4-Reasoning 是显著例外——它的曲线是 U 形，在末段急升到约 0.55，远高于任何其他模型
- 理解快速衰减但末尾回弹：从 0.3 - 0.45 起步、前 20% 内塌陷。DeepSeek-R1 是唯一全程维持高位的，论文称这是「持续重新诠释、而非完全投入执行」的认知风格
- 应用主导中段：从 0.1 - 0.3 升到 0.4 - 0.6 的持续平台期
- 分析早峰：在 5% - 20% 处达峰后逐渐下降
- 评价末端拉升：起点近零、单调爬升到末尾。Qwen3 两个变体的爬坡最陡（约 0.48 - 0.52）
- 创造全程接近零，只有 Phi-4 在末尾有一个尖峰

四、内部轨迹与输出轨迹是两种东西

层级 内部推理轨迹 最终输出的思维链

记忆 13.3%	27.8%
理解 21.0%	14.7%
应用 33.9%	44.9%
分析 12.7%	7.1%
评价 18.8%	5.4%

输出把认知的丰富度压缩成了回忆加执行——记忆与应用两项合起来占了近四分之三，而评价从 18.8% 掉到 5.4%。

论文的解释是这符合预期：最终思维链的角色是简洁的分步解答，而内部推理轨迹更像出声思考的过程，包含中间推敲、重访假设、评价与探索性推理。

补充：难度与任务类型都会改变认知画像

难度上升，努力从执行转向分析：应用的平台期在 GSM8K 上最高（约 0.47）、在 GSM-hard 上变平（约 0.40）、在 MATH500 上衰减最陡。而分析在 MATH500 上维持在约 0.18 - 0.20 而不像在 GSM8K 上那样早早衰减。

跨任务差别更大（拿 BBH 的两个任务对照）：数学是应用重的；形式谬误任务强调分析与理解（要把自然语言前提翻译成逻辑结构）；倒装句任务则是记忆与理解早期主导、应用全程偏低，反映的是范畴性而非程序性的推理。

但有一条跨任务不变：末端拉升的验证是大模型推理的一个普遍性质。

这个框架有什么用：布鲁姆特征与正确性相关

这一节是论文自称的「实用价值」，也是最该按其真实强度来读的一节。

做法：构造一个平衡数据集（9132 个样本），训练一个 L1 正则的逻辑回归，用 43 个特征预测答案是否正确——总 token 数、六个层级的 token 占比、以及展平的 6×6 转移矩阵（按转移总数归一化）。用嵌套交叉验证（外层 5 折、内层 3 折）。

系数排下来最值得看的几条：

特征	系数	含义
应用 → 评价	+0.1769	最强的正系数：正确解答常从执行导向的推理转入对中间结果的显式评估
记忆 → 理解	+0.1290	成功轨迹常从回忆到的信息里显式构建含义
总 token 数	-0.4373	最强的错误预测因子——轨迹越长，解答质量普遍越低
评价 → 分析	-0.1271	失败轨迹在分析与评价之间来回振荡而不收敛

特征	系数	含义
分析	→ 评价	-0.1236 同上

但性能提升必须按真实幅度读：

模型	AUC	准确率	F1
只用长度的基线	0.613 ± 0.008	0.623	0.666
全部 43 个特征	0.676 ± 0.012	0.631	0.667

AUC 提升 0.063 是实在的（区间不重叠），但准确率只提升 0.008、F1 只提升 0.001。论文自己的措辞也很克制——「在准确率和 F1 上增益更小」。

换句话说：布鲁姆特征确实带来了长度之外的额外信息，但那个额外信息很薄；而「越长越可能错」这一条，单独一个特征就贡献了绝大部分预测力。

背景补充 / 点评

先把三个词落到地面。

大型推理模型（LRM）指的是那种在给出最终回答之前会先显式做一段推理的模型（DeepSeek-R1 那一类）。**内部推理轨迹**是它「想」的那一段，**输出轨迹**是它最后给出的解答。这两段是分开的，而这篇论文的第二个发现说的正是这两段的认知构成完全不同。

科恩 Kappa 衡量两个标注者超出随机一致的一致程度，0.8 以上通常被视为「几乎完全一致」。这篇的三个值都在 0.89 以上。

「涌现」这个词在第三个发现里用得很谨慎——论文说的是那条弧线「从未被显式强制」，而不是说模型「学会了布鲁姆分类法」。这两个说法差别很大，论文没有越界。

再说这篇对学员画像项目的直接用处，因为它落在一个刚定下的决策上。

8 月 23 日那份设计里，**决策三把「学情两档」绑定到了布鲁姆刻度**——「已有基础」对应布鲁姆的「应用」级，判据是 PM 提示词原有的那句「是不是已经不需要教练带、能不能不看示范独立完成」，而那句话与布鲁姆「应用」级的定义是同一句话。

这篇论文对那个决策提供了一个外部的、量化的支撑，但支撑的是可行性、不是正确性。

它证明了什么：布鲁姆层级可以被自动标注，而且质量很高——大模型与人的一致性（0.9173、0.9132）高于两个人之间的一致性（0.8928）。这一条直接回应了画像抽取器要做的事：让大模型判断一段学员表现落在哪个认知层级，这件事在技术上是可靠的。

它没有证明什么：这篇标注的对象是模型自己的推理步骤，而画像标注的对象是学员在对话里的表现。两者的输入形态、噪声水平、以及标注者能看到的上下文都不同。不能把 0.91 这个数字直接搬过去当成画像标注的预期一致性。

第二处能借的，是那个「大模型切分优于按句切分」的理由，它对抽取器的设计直接适用。

论文的理由是：单个思维过程可能跨多个句子，按句切会人为地把一个认知功能切碎。

画像抽取器面对的是同一个形状——学员的一段表现可能跨好几轮对话（教练问、学员答、教练追问、学员补充）。如果按轮次机械切分，一个完整的能力表现会被切成几段、每段各记一次。而这正好连上 8 月 25 日读到的那条：次数机制的前提是「同一件事被反复印证」，切碎会让一次表现被记成多次，把次数机制打穿。

所以设计上要保的是：切分的单位是「一个完整的认知表现」，不是「一个对话轮次」。而 PM 提示词里那条「相互独立证据」的计数规则（不同问题下的独立表现、不同时刻的主动提及各算一次；同一个意思换说法接连复述只算一次）说的正是这件事——两边独立走到同一处。

第三处，那个「输出轨迹压缩掉了评价」的发现，对 prove 有一个具体提醒。

内部轨迹里评价占 18.8%，输出里只剩 5.4%。也就是说模型在「想」的时候做了大量自我检查，但在最终答案里几乎不呈现。

prove 的形态是把用户问题编译成查询并作答。如果只看最终答案，你看不到它在中间做过哪些检查、否决过哪些候选。而 8 月 25 日读的那篇《让答案生来可审计》主张的正是把检索轨迹做成一等输出——两篇合起来指向同一件事：可审计性要求把「想」的那一段留下来，而模型默认不会留。

第四处，那条「总 token 数是最强的错误预测因子」值得单独记，因为它的方向反直觉。

系数 -0.4373 ，是所有 43 个特征里绝对值最大的。推理越长，答对的概率越低。论文在引言里提到过这个现象有个名字叫「过度思考」——长度不保证正确性。

但要注意因果方向没有被论证：可能是「难题需要更长推理，而难题本来就更容易错」，也可能是「模型陷入振荡所以变长」。那两条负系数（评价↔分析来回振荡）支持后一种解释，但这仍是相关、不是因果。论文自己在局限里说了：这项工作没有显式地去强制或塑造这些结构模式来改进推理，那是未来工作。

最后说这篇该保持怀疑的地方。

第一，标注质量的评估只覆盖了标签、没覆盖切分。论文自己写明了这一点——切分质量只由一位作者定性检查了 50 个样本。而切分是标注的上游：切错了，标签再准也没用。这个缺口比看起来重要。

第二，只有数学任务做了完整的多模型分析。跨任务那一节只用了 BBH 的两个任务、各 250 个样本，而且是所有模型汇总的，看不出模型间差异。论文在局限里承认需要扩展到更广更多样的任务。

第三，用一个大模型去标注另一批大模型的推理，存在潜在的同源偏差。标注器是 Llama-3.3-70B，被标注的是 DeepSeek、Qwen、Phi 三个家族。如果标注器自身对某类表述有系统性偏好，这个偏好会渗进所有模型的画像里，而人类一致性检查只能发现「标注器和人不一致」、发现不了「标注器和人共享同一个偏见」。

第四，那个正确性模型的实用价值被 AUC 那个数字美化了。0.676 的 AUC 意味着随机取一对正确和错误的轨迹、模型把正确那条排在前面的概率是 67.6%——比抛硬币好，但离可用还远。而准确率只比长度基线高 0.008。论文说「提升了性能」是事实，但说它能「改进推理」目前只是展望。

一句话版本：这篇的最硬的成果不是那四个发现，是那个人机一致性数字——布鲁姆层级的自动标注与人类的一致性（0.917）高于两个人之间（0.893），这让「用大模型判断认知层级」这件事从可疑变成了可靠；而它对学员画像的直接含义是，「学情两档绑布鲁姆刻度」这个决策在技术可行性上有了外部支撑，但那 0.91 不能直接搬过去当画像标注的预期。

文中金句

"rather than asking what process occurs at each reasoning step, we ask what type of thinking or cognitive function the model employs at each step." 我们不问每个推理步骤发生的是哪道工序，而问模型在这一步用的是哪一类思维、哪一种认知功能。

"individual thinking processes may span multiple sentences. More structured approaches can therefore artificially fragment a single cognitive function" 单个思维过程可能跨多个句子。因此更结构化的做法会人为地把一个认知功能切碎。

"the temporal dynamics of cognitive levels follow a coherent Remember-Understand-Apply-Evaluate arc that mirrors Bloom's hierarchy itself—an emergent ordering that, despite never being explicitly enforced, aligns with the canonical Bloom progression." 各认知层级的时间动态遵循一条连贯的**记忆—理解—应用—评价**弧线，映照了布鲁姆层级自身——一个从未被显式强制、却与经典布鲁姆序列一致的涌现排序。

"Outputs, by contrast, compress this richness into recall and execution ... Evaluating drops from 18.8% to 5.4%." 相比之下，**输出把这份丰富度压缩成了回忆与执行**……评价从 18.8% 掉到 5.4%。

"Applying → evaluating is the strongest positive coefficient, suggesting that correct solutions often move from execution-oriented reasoning into explicit assessment of intermediate results." **应用→评价是最强的正系数**，说明正确的解答常常从执行导向的推理转入对中间结果的显式评估。

"total token count is the strongest predictor of incorrectness, indicating that longer traces are generally associated with lower solution quality." **总 token 数是最强的错误预测因子**，说明更长的轨迹普遍与更低的解答质量相关联。

"unsuccessful traces more frequently oscillate between analysis and evaluation without converging on a stable solution." 不成功的轨迹更频繁地在分析与评价之间振荡，而不收敛到一个稳定的解。

"this work does not explicitly enforce or shape such structural patterns to improve reasoning performance, which we plan to explore in future work." 本工作并未显式地强制或塑造这些结构模式来改进推理性能，我们计划在未来工作中探索。

全文翻译

摘要

大型推理模型革新了大模型中的推理，而推理轨迹日益公开**创造了在单个推理步骤的粒度上、而不只是在表层研究模型行为的宝贵机会**。然而，理解推理过程中所使用的**思维类型**——这能提供对模型推理模式的关键洞察并使实际应用成为可能——**仍未被充分探索**。

为填补这个空白，我们引入一个**通过布鲁姆分类法的透镜自动标注推理步骤**的框架，该分类法把思维划分为记忆、应用、评价等六个认知层级。用这个框架，我们跨模型与数据集做了大规模分析，**揭示了不同模型与任务之间思维模式的相似与差异**。此外我们表明，**从推理轨迹导出的思维类型信息与正确性相关**，为改进推理铺路。

一、引言

初期方法依赖思维链提示，鼓励模型逐步展开文本化的推理依据；近期注意力转向大型推理模型，它们**把自生成的思维链依据当作训练信号**，在生成最终回答之前进行显式推理。

论文把自己放在已有工作的什么位置上，说得很清楚（见「核心内容」里与 Schoenfeld 情节理论的那处对照）。

四个研究问题：不同模型在数学解题上的认知画像有何异同；内部轨迹与输出轨迹的认知画像有何差别；认知画像如何随数学问题类型与跨任务变化；**布鲁姆层级特征是否与正确性相关，哪些认知转移刻画了正确与错误的推理**。

二、方法

（三步流水线、标注器选择的理由、人机一致性检验的设计与结果，均见「核心内容」。）

关于为何采用大模型切分而非按句切分，论文明确称之为**「标注一致性与语义保真度之间的权衡」**。

实验设置：三个数学数据集共 3138 个样本，覆盖三档难度——小学水平、计算密集、竞赛级。七个模型。
对所有模型都使用提供方推荐的默认设置，避免因实验设置在推理轨迹中引入伪影或畸变。

三、结果

（四个研究问题的结果见「核心内容」的四个发现与补充。）

关于创造层级近乎缺席，论文的措辞是：这表明大模型**很少从事那种合成真正新颖的模式或结构的思维——与所用基准的性质一致**。

关于 Phi-4-Reasoning 的异常行为，论文在附录里论证了**这是模型自身的性质、而非其系统提示词造成的**。

四、结论与局限

结论重申五条：数学推理上有共享的记忆—理解—应用—评价弧线且带模型特有的特征；内部轨迹在认知上比输出思维链更宽广，后者压缩为回忆与执行；随难度上升认知努力从执行转向分析；跨任务的认知画像依任务而变，**但末端拉升的验证保持一致**；布鲁姆特征与正确性相关，**提示有改进推理的潜力**。

局限两条：本工作**没有显式地强制或塑造这些结构模式来改进推理性能**；把研究扩展到更广、更多样的任务集将带来更全面的分析。

参考链接

- [论文 arXiv 2608.23205](#) — 2026-08-24，代码与数据以 Apache 2.0 许可发布
- [布鲁姆分类法修订版 \(Anderson & Krathwohl, 2001\)](#) — 六个层级的出处
- [GSM8K](#) — 小学数学应用题基准
- [MATH500](#) — 竞赛级数学基准
- [DeepSeek-R1](#) — 被分析的教师模型，发表于 Nature
- [大模型遇上布鲁姆分类法：大模型评测的认知视角 \(COLING 2025\)](#) — 同一方向的先行工作