

约束也要在图上跑一遍 Compositional Chain-of-Relations for Faithful Knowledge Graph Question Answering with Large Language Models

本篇范围说明：这是一篇 13 页正文的 IEEE 期刊投稿（中山大学 Chenhui Liu、Jianpeng Zhou、王甲海，arXiv 2608.22762v1，2026-08-24），是作者此前会议论文 CoR 的扩展版。下面「全文翻译」按原文章节推进，覆盖摘要、§1 引言、§2 相关工作、§3 预备、§4 CCoR 框架（四个小节）、§5 忠实性指标、§6 实验（主结果／复杂查询／效率／深度／消融／案例）、§7 结论。[符号定义表（表 I）与 78 条参考文献不逐条译](#)，表 II - IX 的完整数值在「核心内容」里给。

核心内容

Q：这篇要解决的问题是什么？ A：知识图谱问答（KGQA）里，**复杂查询的求解分成两个互相耦合的阶段**：

- **候选检索（candidate retrieval）**：从问题里的主题实体出发，在图上找出答案候选
- **约束处理（constraint handling）**：用问题里的约束把这些候选过滤掉一部分

论文的核心观察是：**要做到忠实推理，这两个阶段都必须落在图上。而现有的 agent 类方法只落实了第一个，把第二个丢给了大模型的内部知识。**

举例说明两者的分工。简单查询「谁获得过奥斯卡最佳男主角？」一跳就能答（`award.winner`）。复杂查询「哪些**美国**导演与获得过奥斯卡最佳男主角的演员合作过？」要拆成两段：候选检索走 `award.winner` → `work.with` 拿到候选导演，约束处理用 `nationality.of` 配上约束目标「America」把候选筛成最终答案。

Q：现有方法的两个缺陷具体是什么？ A：**缺陷一：不可靠的实体剪枝（unreliable entity pruning）**。以实体为搜索单元的探索，每一跳都必须把实体剪成固定大小的子集。而**剪枝决定必须在收集到足够实体信息之前做出，但那些信息经常是缺的**。两个互相独立的原因：

- **剪不了**：图里很多实体没有可读的字面名字，只以不透明 ID 出现（比如 `m.0f4vbz` 而没有「Adrien Brody」这个名字）。这类实体无从评估，只能跳过——于是和这位获奖演员合作过的导演全部丢失。
- **剪早了**：为控制组合爆炸，通常在证据不足时就做 top-k 剪枝。**97 位最佳男主角得主，在束宽 k=3 下被剪到只剩 3 位，丢掉 94 位，只和那 94 位有连接的导演从此不可达。**

缺陷二：无根据的约束处理（ungrounded constraint handling）。agent 类方法走了捷径，把约束处理卸给大模型、用它的内部知识隐式解决，而不去图上查。后果是约束从未被图验证过。论文给的例子很具体：模型可能凭参数记忆断言导演 Tom Hooper 是美国人，而他实际上是英国人——这个国籍判断没有经过图验证，于是一个错的候选被保留下来。

作者在这里下了一句挺重的话：这恰恰是「用知识图谱增强大模型推理」这件事本来要防的那个弱点。

Q：解决思路是什么？ A：换搜索单元：从实体换成关系（relation-centric exploration）。

因为中间实体在探索过程中不再被评估、也不再被剪枝，这个范式从结构上就避免了不可靠的实体剪枝——不是把剪枝做得更准，是让它不存在。

论文把中间实体处理成隐式变量，类比 SPARQL 里的变量绑定，于是搜索发生在紧凑的关系空间而不是庞大的实体空间里。

在这个范式上，CCoR 用两条关系链分别对应两个阶段：

	主链 <code>c_main</code>	约束链 <code>c_con</code>
从哪到哪	主题实体 → 目标实体	约束源 → 约束目标 τ
产出	候选集 <code>E_cand</code>	可行集 <code>E_con</code>
什么时候建	总是	按需，只在识别出显式约束时激活

最终答案是两者的交： $E_{\text{final}} = E_{\text{cand}} \cap E_{\text{con}}$ ；没有显式约束时退化成 $E_{\text{final}} = E_{\text{cand}}$ 。

两条链最后都编译成 SPARQL 在图上执行。这是「落在图上」的具体含义。

Q：那个共享的探索引擎怎么工作？ A：两条链共用一个引擎，每轮迭代四步：

1. **关系搜索**：给定当前关系链，向图查询可扩展的关系候选 `R_cand`，不实例化中间实体
2. **关系剪枝**：按三条标准给每个关系打分——与问题意图的语义对齐、与链上下文的逻辑一致、与可能答案区域的目标接近度——保留 top-k
3. **记忆更新**：把候选链按分数升序压进记忆栈，于是最高分的链在栈顶、最先被弹出。这样既优先走有希望的分支，又把备选分支留着，能系统性地回溯
4. **推理**：选下一个动作

主链有四个动作：Forward（再探一轮）／Backtrack（当前分支逻辑不一致就丢弃、从栈里弹下一个）／Stop（链完整且无剩余约束，收尾）／Constraint（收尾主链，交给约束链）。

动作选择用分层推理，拆成两个顺序提问，降低多跳规划的复杂度：

- **问一：当前主链在逻辑上正确且完整吗？** 三种结果——正确且完整且无约束 → Stop；逻辑不一致 → Backtrack；到目前为止正确但不完整 → 进入问二
- **问二：当前的目标实体到达问题的答案空间了吗？** 这一问检查的是类型：「如果问题问的是一个地点，当前目标实体就该是地点。」否 → 主推理路径还没走完，Forward；是 → 候选空间已建立，剩下的不完整是因为有未处理的显式约束，Constraint

约束链分两步：

- **初始化**：给定问题和主链，输出一个**未解约束查询**（把原问题里剩下的约束改写成一个独立的子问题）并抽出**约束源**。例子：从「哪些美国导演与获奥斯卡最佳男主角的演员合作过？」提炼出「在所有导演里，谁来自美国？」；约束源是主链已检索出的那批导演。**这里有个细节值得注意**：主链先产出演员 `e1`、再产出导演 `e2`，而「谁来自美国」的主语是导演 `e2` 不是中间的演员 `e1`，所以选 `e2`
- **探索**：复用同一个引擎，三个动作 Forward/Backtrack/Stop，同样用两问分层——「当前约束链对这个未解约束查询在逻辑上正确吗？」「能从当前选项里选出一个有效的约束目标吗？」

Q：探索失败了怎么办？ A：两层回退机制，**触发的层级和原因都会被记录下来供忠实性分析**——这一点是后面那个指标能算出来的前提。

层	触发条件	做什么	保留多少图依据
Layer 1 全局实体过滤 GEF	主链建成但 约束链失败	大模型直接从问题识别约束，一次性过滤 <code>E_cand</code>	部分 —— <code>E_cand</code> 仍来自主链的图执行
Layer 2 直接生成	主链本身不可恢复地失败	退回思维链直接作答	无

作者对 Layer 1 的定位说得很清楚：**它不如约束链忠实，但更鲁棒**——它能处理那些难以形式化成关系链的约束（比如时间类、比较类，图里根本没有对应的直接谓词）。

Q：两个新指标是什么？为什么需要它们？ A：动机很直接：一个方法可能靠参数记忆背出正确答案，推理过程完全不可验证。答案正确率一个数分不出这两条路径。

KGR (Knowledge Grounded Rate, 知识落地率)：给每个样本按最终答案的证据来源打一个状态，三档权重：

状态	含义	权重	在 CCoR 里对应
<code>structured</code>	最终答案 完全 来自显式图执行，产生答案那一步没有参数推断	1.0	未触发任何回退
<code>synthesis</code>	图执行只给了部分中间结果（如候选集），最终答案还需大模型结合参数知识去推	0.5	回退到 Layer 1
<code>parametric</code>	最终答案直接由参数知识产生，无可执行的图证据	0	回退到 Layer 2

KGR = N 个样本的权重均值。作者强调三个状态是**按方法无关的方式定义**的，所以能套到任何「图增强大模型」方法上。

FF1 (Faithful-F1) = KGR × F1。用意是惩罚「答案对但落地弱」的情况。

这两个指标也是本文相对会议版 CoR 的三处扩展之一：**KGR 从一个二值指示器被重定义成三档加权分**。

Q：实验结果怎样？ A：四个数据集、两个图谱（Freebase 的 WebQSP／CWQ／GrailQA，Wikidata 的 QALD10-EN）。约束占比差别很大，这决定了各数据集的难度：

数据集	题量	1 跳	2 跳	≥3 跳	带约束
WebQSP	1639	1033	595	6	402 (24.5%)
CWQ	3520	1363	1597	560	2266 (64.4%)
GrailQA	1000	769	222	9	974 (97.4%)

设置：温度 0.01；束宽 k=3；最大深度 WebQSP／QALD10／GrailQA 为 3、CWQ 为 4。

准确率 (GPT-3.5-turbo)：CCoR 在 CWQ 和 QALD10 上最好（含那些用了监督训练的方法），WebQSP 和 GrailQA 上是免训练方法里最强、仅略逊于最好的监督方法。

一个很说明问题的对照：**Pangu 全量微调后 WebQSP 79.6 F1、GrailQA 81.7，略胜 CCoR（WebQSP 差 1.7 F1）。但把微调去掉，它在 GrailQA 上从 81.7 崩到 62.7（100-shot）、56.3（10-shot），远低于 CCoR。**作者据此说：微调类方法的优势绑死在「对每个目标图谱重新训练」上。

对比 agent 类（全部免训练，CCoR 四个数据集上 Hits@1 和 F1 全面最好）有两处增益来源：把大模型接上图谱带来一大跳（IO-Prompt 和 CoT-Prompt 完全不碰图，表现最差）；关系中心的 CCoR 稳定强于实体中心的 ToG 和 PoG。**而且这个优势在约束密集 CWQ 上最大（Hits@1 63.2 → 66.0），在约束稀疏的 WebQSP 上则很小。**

忠实性（这部分是全文最有信息量的），GPT-4.1-mini 下：

方法	WebQSP F1 / KGR / FF1	CWQ F1 / KGR / FF1
IO-Prompt	47.7 / 0.0 / 0.0	32.1 / 0.0 / 0.0
CoT-Prompt	46.4 / 0.0 / 0.0	35.2 / 0.0 / 0.0
ToG†	57.5 / 56.5 / 32.5	41.2 / 30.3 / 12.5
PoG†	64.0 / 63.3 / 40.5	42.2 / 37.1 / 15.7
CCoR	78.0 / 90.4 / 70.5	57.8 / 69.1 / 39.9

（† 为作者从官方代码库复现）

三个层次分得很干净：不碰图的两个方法**F1 并不低**（WebQSP 47.7 和 46.4），但 KGR 和 FF1 都是 0.0——作者的评论是「**答案正确率本身可以把「完全没有落地」这件事彻底掩盖掉**」。实体中心的 ToG／PoG 把 KGR 抬离了零，但在 CWQ 上也只有 30.3 和 37.1，**很大一部分答案仍然落回参数知识。**

复杂查询专项（从 CWQ 里筛出带约束的、随机抽 500 题）：

方法	Hits@1	F1	KGR	FF1
ToG† (4.1-mini)	50.8	48.8	24.2	11.8
PoG† (4.1-mini)	54.2	51.6	36.4	18.8

方法	Hits@1	F1	KGR	FF1
CCoR (4.1-mini)	68.4	62.3	61.9	38.6
CCoR (5.4-mini)	70.2	65.1	77.3	50.3

作者对「换更强骨干后提升更明显」给的解释值得记：[因为约束验证落在图执行上，CCoR 把推理质量和「参数记忆在不同模型间的波动」解耦了](#)，所以更强的骨干直接转化成更忠实也更准的约束处理。

效率（每题平均大模型调用次数，GPT-4.1-mini）：

	WebQSP	QALD10	CWQ
ToG†	7.76	15.26	19.43
PoG†	7.38	11.83	19.75
CCoR	4.51	5.51	10.20

token 消耗上，CWQ 的 CCoR 是 5917 万、PoG 是 1.13 亿（约一半）；QALD10 是 249 万对 571 万；[但 WebQSP 上 CCoR 略多（1220 万 vs 1134 万）](#)——因为那里很少触发约束链，额外探索只是纯开销。

深度实验（CWQ，Cum. Ratio 指所需深度不超过配置上限的题目占比）：

深度	覆盖率	Hits@1	F1	KGR
2	84.1%	47.8	43.7	50.3
3	96.0%	62.8	50.6	63.0
4	100.0%	67.0	57.8	69.1
5	100.0%	64.7	53.9	68.2

消融（累积移除，CWQ / GPT-4.1-mini）：

	Hits@1	F1	KGR
CCoR	67.0	57.8	69.1
– 约束链（即 CoR）	60.3	52.0	49.8
– 关系回溯	57.2	50.0	42.6
– 全局实体过滤 GEF	48.2	42.8	29.8

案例研究（CWQ 一道带约束的两跳题，问「战歌是《Bow Down to Washington》、Nate Robinson 效力过的是哪支队伍」，金标是华盛顿哈士奇橄榄球队）：CoT、ToG、PoG 三个都答成了「**华盛顿大学**」——粒度停在大学一级、没有执行战歌这个约束，Hits@1 全是 0，而 ToG 和 PoG 分别花了 32 次和 30 次调用。CCoR 主链走 `pro_athlete.teams → team_roster.team` 拿到 8 支候选队伍（含金标），约束链执行 `?team --fight_song--> Bow Down to Washington` 把 8 支筛成 1 支，**6 次调用**，Hits@1 = 1、F1 = 1.00。

几个概念的位置

KGQA 的三条技术路线，本文在相关工作里分得很清楚，各自的软肋也说到了：

路线	做法	软肋
调优类	用图谱派生的监督数据微调模型，把推理模式内化	约束在微调后的参数里隐式解决；重训绑定单一图谱与 schema，迁移代价高
	推理模型冻结，把子图或推理路径作为上下文喂进去	答案质量取决于一个单独的检索模块（通常是监督训练的神经检索器，图谱一变就泛化不了）；证据只是提示词，最终答案还是模型生成的，仍会幻觉
检索类	推理模型冻结，把子图或推理路径作为上下文喂进去	答案质量取决于一个单独的检索模块（通常是监督训练的神经检索器，图谱一变就泛化不了）；证据只是提示词，最终答案还是模型生成的，仍会幻觉
agent 类	让模型迭代地遍历图谱、边收集证据边调整	本文指出的那两条

ToG (Think-on-Graph) 在实体路径上跑束搜索，PoG (Plan-on-Graph) 事先规划推理路线再靠自我纠错修正——两者都是实体中心，是本文的直接对手。StructGPT 是把结构化接口暴露给模型让它一步步查。

Freebase 的不透明 ID 是这篇论文的一个真实痛点而不是假想：Freebase 里大量实体的主键形如 `m.0f4vbz`，名字要另查 `type.object.name`。实体中心的方法在剪枝那一刻拿到的常常就是这串 ID，读都读不懂，自然剪不对。

GrailQA 的设计目的是考组合泛化和零样本泛化，所以它 97.4% 的题带约束——这解释了为什么它是本文的天然主场。

这篇的真贡献，和一处很漂亮的设计

真贡献是那句「两个阶段都要落在图上」，而不是关系中心这个技巧本身。关系中心是手段（避免实体剪枝），约束链才是这一版相对会议版的新东西。论文自己的结论段也这么写：三个方面里「忠实性的提升是最独特的那一个」。

最漂亮的设计是主链推理的问二：「当前的目标实体到达问题的答案空间了吗？」它做的是一个类型检查——问地点就该拿到地点。这实际上是把 `domain/range` 当停机判据用，而不是当约束校验用。我 8/25 读的那篇讲过 `rdfs:domain` 本质是推理规则不是约束，很多人误用它做校验；这篇反过来，把类型信息用在它真正合适的位置上：决定「还要不要再走一跳」。这是同一个东西的正确用法。

第二漂亮的是回退机制被记录下来。「触发的层级和原因都会被记录供忠实性分析」——正因为有这行日志，KGR 才算得出来。很多系统有回退但不记，于是事后完全说不清一个答案是怎么来的。

五处该打折扣的地方

一、消融是累积移除的，所以它给不出「每个部件贡献多少」，而作者按那个读法下了结论。

作者说三次移除呈现「**清晰的贡献层级**」。但累积移除的第三行「- 全局实体过滤」是在**已经没有约束链、也没有回溯**的基础上再去掉 GEF，那 48.2 / 29.8 是三者共同缺失的结果，**无法归因给 GEF 单独**。要做 per-component 归因得用留一法（每次只去掉一个），不是累积法。

二、更要紧的是，消融里掉得最狠的那一项恰恰是最不忠实的那条路径，而论文没有正视。

GEF 是 **Layer 1 回退**，它按定义就是「用参数知识判断约束、不做额外的图落地」。移除它导致 CWQ 上 Hits@1 掉到 48.2、KGR 掉到 29.8——是三次移除里最大的一次。也就是说，**CCoR 在 CWQ 上那些漂亮数字里，有相当一部分重量压在一条作者自己承认「不忠实」的兜底路径上**。这和全文主张（约束必须显式在图上执行）是有张力的，论文把它读成「约束处理是瓶颈」——这句没错，但它绕开了「**承担约束处理的那一部分里，有多少其实是不落地的那种**」这个更尖锐的问题。KGR 69.1 的意思正是：**平均每个样本只有约七成落地**，剩下三成靠回退。

三、KGR 对 CCoR 自己而言接近定义式，对基线则是解释式，这个不对称没有被标注。

三个状态与 CCoR 的回退层**一一对应**（structured = 没回退、synthesis = Layer 1、parametric = Layer 2）。所以 CCoR 的 KGR 实际上度量的是「**我自己的回退有多久没触发**」，而基线的状态得从外部推断归类。作者说定义是「方法无关」的，但映射关系在自家方法上是精确的、在别人身上是解释性的。

同理，IO-Prompt 和 CoT-Prompt 的 KGR = 0.0 **是构造决定的**（它们根本不碰图），把它当成一个「发现」来报（「正确率可以掩盖没有落地」）作为**演示**是成立的，作为**测量结果**则不是。对比我昨天读的那篇 FAIR 数字对象论文，它在 100% 那一行明写「† 由构造导致，非测量」——**同样的结构，那篇标了，这篇没标**。

四、**FF1 = KGR × F1** 这个乘积形式没有论证。

两个量纲不同、关系未经论证的东西相乘，后果是 **F1 0.6/KGR 0.5 和 F1 0.3/KGR 1.0 得分相同**——而这是两种性质完全不同的系统（一个答得准但半数靠猜，一个答得差但全程可查）。论文没说为什么用乘积而不是直接报这一对数。而且既然 KGR 对 CCoR 接近定义式，FF1 把这个性质一并继承了。

五、「关系空间是紧凑的」这个前提全文没有量化。

整个范式立在「关系空间远小于实体空间」上，但**没有给出任何一跳上 R_cand 的规模数字**。Freebase 的关系有数千个，top-k=3 在关系上剪是否真比在实体上剪安全，取决于这个分布长什么样，而论文没展示。另外 ToG/PoG 在忠实性表和复杂查询表里全部是作者**复现的**（标了 †），而复现基线低于原论文报告值是很常见的形态——这一点在解读增益幅度时要打折。

深度 5 的退化（Hits@1 67.0 → 64.7）被报告了但**没有诊断**，给的解释「引入了噪声分支」只是把现象换了个说法。这对要部署的人是实际问题：深度有内部最优点，而论文没给找到它的规则。

对我的启示

一、「候选检索」与「约束处理」这个二分，正对上我知识图谱里「捞节点」和「按企业/场景筛」这两件事。

论文最硬的一句是：**如果第二半交给模型判断，那么无论第一半做得多好，整件事都不可验证**。我的模型里 `applies_to`、`owner`、`comparator` 这几个字段**就是约束谓词**——它们应该被当成过滤器执行，而不是

当成提示读给模型看。

具体一点：我此前设想的用法是把这些字段塞进上下文让模型参考，那等于走了本文批评的 GEF 路线。正确的形态是先用它们在图上做确定性过滤、再把剩下的交给模型。而且哪些查询走了确定性过滤、哪些落回模型判断，要分开记。

二、「记录回退层级与触发原因」这条纪律，我该直接抄。

CCoR 之所以能算出 KGR，前提就是它记了每次回退的层和原因。我手上两条流水线都缺这个：

- LL 拆书 eval 里，判官给出档位之后，它是「明确指出了错在哪」还是「只是标了无支撑」，昨天就是靠补一轮短调用才分开的——如果一开始就把判定路径记下来，不用事后补
- 标注流水线里，一条语义点是「按判据 X 判的」还是「判据没覆盖、凭直觉判的」，现在只有结论没有路径

共同形状：只留判决、不留路径，会把过程里已经有的信息销毁掉。这和昨天那条「档位标签把片段层面的正确判断压没了」是同一件事的两个实例。

三、要主动检查自己的指标里有没有「由构造决定」的部分。

这篇的 KGR 对自家方法接近定义式却没标注，而昨天那篇 FAIR 论文标了。我的 LL eval 里也有同构的风险：判官成绩是在我自己造的考题上测的，考题的难度分布由我决定；「判官检出率 97%」这个数在多大程度上是我把考题造得可检出造成的，得写清楚。昨天已经记了一条相关偏差（对照组比真题信息密度略高，所以冤枉率偏低），这条要一起写进报告的指标说明里。

四、累积消融不能做部件归因，这条以后设计实验时直接用。

如果我想说「判据修订第 14 条贡献了多少」，得是留一法：只去掉那一条、其余不动。累积法只能说明「这几个合起来重要」。

五、类型检查当停机判据，是个便宜又强的守卫。

「问地点就该拿到地点」——这个检查几乎零成本，但能挡住一整类「链走岔了但看起来还在推进」的情况。对应到我的场景：一条语义点被归到 K 域某一格之后，可以反过来检查「这一格应该长什么样」和它实不匹配。这比只看判据条文更能抓出错归类，而且和 8/25 那篇讲的「domain/range 是推理规则不是约束」并不矛盾——用在停机判断上是对的，用在数据校验上才是误用。

六、效率的来源是「取消了一整类决策」，不是「把决策做得更快」。

CCoR 的调用次数减半，不是因为把剪枝优化了，是因为它根本不实例化中间实体、于是不需要剪枝。这个形状可以推广：一条流水线贵的时候，先问能不能从结构上消掉一整类判断，再去想怎么把那类判断做便宜。我那条 backlog 越积越多的本体论精读流水线，也许该按这个思路想一遍——不是「怎么读得更快」，而是「哪一类论文根本不该进队列」。

七、一个要防的诱惑：别把「约束密集」当成默认假设。

本文的优势在 GrailQA (97.4% 带约束) 和 CWQ (64.4%) 上最明显, 在 WebQSP (24.5%) 上很小, 甚至在 token 上略亏。[方法的收益和数据的结构强相关](#)。我在评估任何「在某个基准上提升 N%」的方案时, 要先问那个基准的结构是不是和我的数据像。

文中金句

"Faithful reasoning requires grounding both phases in the KG. However, existing agent-based methods ground candidate retrieval through entity-centric exploration, while leaving constraint handling to the LLM's internal knowledge." [忠实推理要求两个阶段都落在知识图谱上](#)。然而现有的 agent 类方法通过实体中心探索让候选检索落了地, 却把约束处理留给了大模型的内部知识。

"these pruning decisions are inherently unreliable: they must be made before sufficient entity information is collected, yet such information is frequently missing" [这些剪枝决定在本质上就不可靠](#): 它们必须在收集到足够的实体信息之前做出, 而那些信息经常是缺失的。

"Because this nationality judgment is made without KG verification, the method retains a wrong candidate and produces incorrect final answers." [因为这个国籍判断是在没有图谱验证的情况下做出的](#), 该方法保留了一个错误的候选、并产出了错误的最终答案。

"constraints are never verified against the KG, resulting in unfaithful reasoning and hallucination, precisely the weakness that KG-augmented LLM reasoning is intended to prevent." 约束从未被对照图谱验证过, 导致不忠实的推理和幻觉, [而这恰恰是「用知识图谱增强大模型推理」本来要防的那个弱点](#)。

"Since intermediate entities are no longer evaluated or pruned during exploration, CoR structurally avoids unreliable entity pruning." [由于中间实体在探索过程中不再被评估或剪枝](#), CoR 从结构上避免了不可靠的实体剪枝。

"This shows that answer correctness alone can fully hide the absence of grounding, which is exactly what the faithfulness metrics are designed to reveal." [这说明答案正确率本身可以把「完全没有落地」这件事彻底掩盖掉](#), 而这正是那两个忠实性指标要揭示的东西。

"Because constraint verification is grounded in KG execution, CCoR decouples reasoning quality from the variability of parametric memory across models." 因为约束验证落在图谱执行上，CCoR 把推理质量与「参数记忆在不同模型间的波动」解耦了。

全文翻译

摘要

Knowledge graph question answering (KGQA) is a key task for evaluating KG-augmented Large Language Models (LLMs), and complex KGQA that requires multi-hop reasoning is especially challenging. Solving a complex query involves two coupled phases: candidate retrieval, which locates answer candidates over the KG, and constraint handling, which filters these candidates against the query constraints. Faithful reasoning requires grounding both phases in the KG.

知识图谱问答 (KGQA) 是评估「图谱增强的大语言模型」的一项关键任务，其中需要多跳推理的复杂 KGQA 尤其困难。求解一个复杂查询涉及两个互相耦合的阶段：候选检索，在图谱上定位答案候选；以及约束处理，用查询中的约束过滤这些候选。忠实推理要求这两个阶段都落在图谱上。

However, existing agent-based methods ground candidate retrieval through entity-centric exploration, while leaving constraint handling to the LLM's internal knowledge, which leads to two critical limitations. (1) Unreliable entity pruning: entity-centric exploration uses entities as search units and must prune them to a fixed-size subset at each hop. Because entity information in KGs is often incomplete and a fixed-size subset cannot retain all valid entities, such pruning inevitably drops valid entities and ultimately leads to wrong answers. (2) Ungrounded constraint handling: query constraints are resolved from the LLM's internal knowledge rather than the KG, leaving the final answers unverifiable and prone to hallucination.

然而现有的 agent 类方法通过实体中心探索让候选检索落了地，却把约束处理留给大模型的内部知识，由此产生两个关键局限。(1) 不可靠的实体剪枝：实体中心探索以实体为搜索单元，每一跳都必须把它们剪到一个固定大小的子集。由于图谱中的实体信息常常不完整、而固定大小的子集无法保留所有有效实体，这种剪枝不可避免地丢掉有效实体，最终导致错误答案。(2) 无根据的约束处理：查询约束是从大模型的内部知识而非图谱中解决的，使最终答案不可验证且易于幻觉。

To address these limitations, this paper introduces a relation-centric exploration paradigm, which uses relations rather than entities as search units and thus avoids unreliable entity pruning. Built on this paradigm, this paper proposes Compositional Chain-of-Relations (CCoR), a simple and effective framework that grounds both phases in the KG with two relation chains: a main chain for candidate retrieval and a constraint chain that verifies query constraints through explicit KG exploration.

为解决这些局限，本文提出**关系中心探索范式**，它以关系而非实体作为搜索单元，从而避免不可靠的实体剪枝。在此范式上，本文提出**组合式关系链（CCoR）**，一个简单有效的框架，用两条关系链把两个阶段都落到图谱上：一条用于候选检索的主链，和一条通过显式图谱探索来验证查询约束的约束链。在四个 KGQA 基准上的实验表明，CCoR 在准确率、忠实性和效率上都稳定优于强基线，**在复杂查询上增益更为明显。**

1. 引言：两种局限的来源

大模型的知识**隐式地存储在参数里**，使事实核验困难，并留下知识过时、幻觉、可解释性有限这些长期问题。知识图谱与之相反，把事实**显式地**表示为实体-关系三元组，支持可查询、可验证、可更新的知识，推理路径透明可控。这些性质使图谱成为大模型的自然补充。

Existing methods devote mostly their design to candidate retrieval, casting it as the central problem. ... most still follow an entity-centric exploration paradigm dominated by entity pruning. Under this paradigm, entities serve as the primary search units, and at each step only a small subset of entities is retained for further expansion.

现有方法把大部分设计投在候选检索上，把它当作核心问题。……多数仍遵循由实体剪枝主导的实体中心探索**范式**。在这个范式下，实体是主要的搜索单元，每一步只保留一小部分实体继续扩展。

不可靠的实体剪枝有两个截然不同的成因。 第一，剪枝决定可能**根本不可行**，因为许多图谱实体缺少可读的字面名称、只以不透明 ID 出现（例如只有 `m.0f4vbz` 而没有「Adrien Brody」）。这类实体无法被评估、可能被跳过，从而丢掉与这位奥斯卡得主合作过的导演。第二，即便实体可读，剪枝决定也可能**过早**。为控制探索的组合增长，实体中心方法常在收集到足够图谱证据之前就做 top-k 剪枝：**把 97 位奥斯卡最佳男主角得主在束宽 k=3 下剪到只剩 3 位，丢掉 94 位，使得只与那些人相连的导演变得不可达。**

约束处理得到的关注则少得多。 早期工作通过语义解析或基于嵌入的过滤来处理约束——把约束翻译成可执行的逻辑形式，或在学到的向量空间里给候选打分——但这些做法依赖**预定义的 schema 或固定的表示**，限制了对多样复杂查询的灵活约束解决。近来 agent 类方法走了一条捷径：**把约束处理卸给大模型，从其内部知识隐式解决，而不在图谱上探索。**

（那个 Tom Hooper 的例子见「核心内容」。）

本文分两步处理这两个局限。 为解决不可靠的实体剪枝，引入关系中心探索范式并提出 Chain-of-Relations（CoR）框架，以关系而非实体作为搜索单元；为解决无根据的约束处理，进一步把 CoR 扩展成 CCoR，引入**约束链**——一条从约束源到约束目标的关系链，把约束处理落在显式的图谱探索上。**约束链按需构建，只在复杂查询中识别出显式约束时才激活。**

Additionally, existing answer correctness metrics (e.g., Hits@1, F1) are insufficient to characterize model faithfulness. A method may produce correct answers by relying on parametric memory recall rather than explicit KG exploration, resulting in an unverifiable reasoning process.

此外，**现有的答案正确率指标（如 Hits@1、F1）不足以刻画模型的忠实性。一个方法可能靠参数记忆的回忆而非显式的图谱探索产出正确答案，其推理过程是不可验证的。**为填补这一空缺，本文引入两个忠实性指标区分这两条路径：KGR 度量答案有多少落在显式图谱探索上，FF1 联合刻画答案准确性与落地推理质量。

相对会议版 CoR 的三处扩展：方法层面，CCoR 瞄准无根据的约束处理，引入约束链探索并与主链组合；评估层面，KGR 从一个二值指示器被重定义为细粒度的加权落地分，区分完全来自图谱、部分来自图谱、完全来自参数记忆三档，并在此基础上引入 FF1；实验层面，增加了 GPT-3.5-turbo 与 GPT-5.4-mini 等骨干模型、更丰富的基线对比、更广的基准覆盖。

2. 相关工作

（三条技术路线及其软肋见「背景补充」的表。）

In contrast to the entity-centric agent-based methods above, CoR removes entity pruning from the exploration loop and instead uses relations as the basic search unit, building executable relation chains that avoid discarding valid intermediate entities and thus make KG exploration more reliable. Building upon relation-centric exploration paradigm, CCoR further models each constraint as a relation chain and grounds it over the KG, replacing parametric constraint judgment with explicit KG execution.

与上述实体中心的 agent 方法相反，**CoR 把实体剪枝从探索循环里移除**，改用关系作为基本搜索单元，构建可执行的关系链，避免丢弃有效的中间实体，从而使图谱探索更可靠。在关系中心范式之上，**CCoR 进一步把每条约束建模为一条关系链并将其落在图谱上，用显式的图谱执行替代参数化的约束判断**，由此得到忠实的结果。

3. 预备

图谱记作 $G = (E, R, T)$ ，E 是实体集、R 是关系集、T 是三元组集。给定问题 q 和图谱 G ，KGQA 要从 G 中识别答案实体：从 q 里提到的主题实体 E_{topic} 出发，CCoR 先做关系中心探索构建候选集，再做显式的约束执行得到最终答案集 E_{final} 。

主链的执行定义为 $E_{cand} = F_{main}(G, E_{topic}, c_{main})$ ；对于未解的显式约束 κ （如果有），约束链 c_{con} 连接约束源与约束目标 τ ，两条链一旦确定就组合起来在 G 上联合执行： $E_{con} = F_{con}(G, c_{main}, c_{con}, \tau)$ 。最终答案在约束链被触发时由组合过滤得到： $E_{final} = E_{cand} \cap E_{con}$ ；没有抽出显式约束时退化为 $E_{final} = E_{cand}$ 。

This decomposition separates candidate-space construction from constraint verification while preserving end-to-end compositional reasoning.

这个分解把候选空间构建与约束验证分开，同时保留了端到端的组合式推理。

4. CCoR 框架

CCoR 由两个组件和一个辅助机制构成：主链探索（候选构建）、约束链探索（显式约束执行），两者建立在**共享的关系中心探索引擎**上；辅助机制是探索失败时保持鲁棒的两层回退策略。

Through this design, CCoR converts constraint handling into auditable and executable KG operations.

通过这一设计，CCoR 把约束处理转换成了可审计、可执行的图谱操作。

4.A 共享的关系中心探索引擎。 状态初始化为 $s_0 = (c_0, h_0)$ ， c_0 是空链、 h_0 是空的记忆栈。每步更新为 $s_t = (c_t, h_t)$ ， c_t 是当前关系链， h_t 存放已探索的分支与备选以供回溯。每轮四步（关系搜索、关系剪枝、记忆更新、推理）的细节见「核心内容」。

其中关系搜索这一步的关键句：Similar to variable binding in SPARQL, intermediate entities are treated as implicit variables. The search is therefore conducted in compact relation space rather than large entity space.

类似 SPARQL 中的变量绑定，中间实体被当作隐式变量处理。因此搜索是在紧凑的关系空间而非庞大的实体空间中进行的。

记忆更新那一步的设计也值得原样记下：候选链**按分数升序**压栈，于是最高分的链位于栈顶、最先被弹出扩展。这个策略在优先走有希望的链的同时保留了备选分支，使系统性的回溯恢复成为可能。

4.B 主链探索与 **4.C 约束链探索**的动作集与两问分层推理见「核心内容」。两者收尾时都由 agent 从当前链构造一条 SPARQL 查询并在图谱上执行。

约束链那一节的收束句：This component directly addresses ungrounded constraints by converting constraint handling from implicit memory-based judgment to explicit KG execution.

这个组件通过把约束处理从「基于记忆的隐式判断」转换成「显式的图谱执行」，直接解决了无根据约束的问题。

4.D 回退机制。 在复杂查询设定下图谱探索可能失败（如链构造失败、路径不可达）。

Unlike constraint-chain exploration, which executes each constraint through explicit KG queries, GEF relies on the LLM's parametric knowledge to judge constraint satisfaction without additional KG grounding. This makes GEF less faithful but more robust: it can handle constraints that are difficult to formalize as relation chains (e.g., temporal or comparative constraints with no direct KG predicate). Because E_{cand} is still derived from explicit KG execution through the main chain, this layer retains partial KG grounding.

与通过显式图谱查询执行每条约束的约束链探索不同，**全局实体过滤（GEF）依赖大模型的知识来判断约束是否满足，没有额外的图谱落地。这使 GEF 不如前者忠实，但更鲁棒**：它能处理那些难以形式化成关系链的约束（例如没有直接图谱谓词的时间类或比较类约束）。由于 E_{cand} 仍然来自主链的显式图谱执行，这一层保留了部分图谱落地。

Layer 2 在主链推理不可恢复地失败时退回思维链直接生成，[此层不提供任何图谱落地的证据](#)。

Fallback stage and trigger cause are logged for faithfulness analysis.

[回退的层级与触发原因都被记录下来，供忠实性分析使用。](#)

5. 忠实性指标

Answer correctness alone cannot distinguish explicit KG reasoning from parametric memory recall.

[答案正确率本身无法区分「显式的图谱推理」与「参数记忆的回忆」。](#)

三个状态、三档权重与 KGR、FF1 的定义见「核心内容」。作者强调：The three states are defined in a method-agnostic manner so that they can be applied to any KG-augmented LLM method. [（这三个状态以方法无关的方式定义，因而能应用于任何图谱增强的大模型方法。）](#)

FF1 的动机：This metric penalizes cases where answer correctness is high but KG grounding is weak. [（这个指标惩罚那些答案正确率高但图谱落地弱的情况。）](#)

6. 实验

数据集、基线、实现细节、各表数值与案例研究见「核心内容」。这里只留几处结论句。

关于调优类方法：This contrast indicates that the strength of tuning-based methods is tied to retraining on each target KG and does not transfer once such supervision is unavailable. [（这一对比表明，调优类方法的长处绑定在「对每个目标图谱重新训练」上，一旦缺少这种监督就无法迁移。）](#)

关于增益出现在哪里：This pattern indicates that the gain of CCoR grows precisely when queries involve explicit constraints, where explicit KG execution replaces unreliable parametric judgment. [（这个模式表明，CCoR 的增益恰恰在查询涉及显式约束时增长，因为那里显式的图谱执行替代了不可靠的参数判断。）](#)

关于忠实性与准确率的关系：This confirms that faithfulness and accuracy improve together rather than trading off. [（这证实了忠实性与准确率是一同提升的，而不是此消彼长。）](#)

关于深度：depth 4 provides the best trade-off between exploration completeness and error accumulation. Although depth 5 keeps full coverage, performance declines ... suggesting that deeper exploration introduces noisy branches without expanding the reachable question set. [（深度 4 在探索完整性与误差累积之间提供了最佳权衡。虽然深度 5 保持了完整覆盖，性能却下降……说明更深的探索引入了噪声分支，却没有扩大可达的问题集合。）](#)

关于消融：Overall, the three removals show a clear hierarchy of contributions. Constraint handling is the dominant source of both accuracy and grounding, while relation-level

backtracking acts as a secondary robustness mechanism. (总体而言，三次移除展现了清晰的贡献层级。约束处理是准确率与落地性的主导来源，而关系级回溯充当次要的鲁棒性机制。)

关于案例：This case therefore provides direct evidence that explicit constraint-chain execution is the key mechanism behind CCoR's accuracy and faithfulness improvement. (因此这个案例为「显式的约束链执行是 CCoR 准确率与忠实性提升背后的关键机制」提供了直接证据。)

7. 结论

本文提出 CCoR，一个用于忠实复杂 KGQA 的 agent 类框架。建立在关系中心探索范式上，CCoR 组合两条关系链来映射复杂查询求解的两个阶段：一条用于候选检索的主链，和一条按需触发、在图谱上显式执行约束的约束链。

Among these three aspects, the faithfulness improvement is the most distinctive.

在准确率、忠实性、效率这三个方面中，忠实性的提升是最独特的那一个。

Although relation-centric exploration requires fewer LLM calls than entity-centric methods by avoiding entity pruning, CoR/CCoR still requires multiple LLM calls in complex KG reasoning. At the current stage, this cost is a necessary trade-off for maintaining faithfulness through explicit KG grounding. Reducing call cost while preserving faithfulness remains a key direction for future work.

尽管关系中心探索通过避免实体剪枝而比实体中心方法需要更少的大模型调用，CoR/CCoR 在复杂图谱推理中仍然需要多次调用。在现阶段，这个成本是「通过显式图谱落地来维持忠实性」所必需的权衡。在保持忠实性的前提下降低调用成本，仍是未来工作的一个关键方向。

资助：国家自然科学基金（62472461）、广东省基础与应用基础研究基金（2025A1515010129）。作者单位为中山大学。

参考链接

- [arXiv 2608.22762](#) — 本文预印本
- [WebQSP](#) — 1639 题、主要 1 - 2 跳、仅 24.5% 带约束，是本文四个基准里最简单的，也是 CCoR 增益最小、token 反而略亏的那一个
- [ComplexWebQuestions \(CWQ\)](#) — 3520 题、2 跳为主且 560 题 ≥ 3 跳、64.4% 带约束，本文的主战场
- [GrailQA](#) — 1000 题、97.4% 带约束，专为考组合泛化与零样本泛化而设计
- [QALD-10](#) — 333 题、基于 Wikidata，用来验证方法能否跨异构图谱迁移
- [Freebase](#) — 前三个数据集所用图谱；它大量实体只有 `m.` 前缀的不透明 ID，正是本文「剪不了」那一条的现实来源

- [Wikidata SPARQL endpoint](#) — QALD-10 所用的官方查询端点
- [Think-on-Graph \(ToG\)](#) — 实体路径上跑束搜索，本文的直接对手之一
- [Plan-on-Graph \(PoG\)](#) — 事先规划推理路线并自我纠错，本文的另一个直接对手