

候选集干扰：图谱长大本身就会让旧答案掉名次 Matched Excess-Outranker Regularization for Candidate-Set Interference in Continual Knowledge Graph Embedding

源文档：arXiv 2608.24273v1 (2026-08-25 提交)，作者 Hao Ren、Junbin Gao、Jiaojiao Jiang (新南威尔士大学 / 悉尼大学)，投稿 ACM 会议格式，正文 11 页。本文的「全文翻译」一节按原文小节推进，覆盖摘要、§1 引言、§2.4 候选集干扰的定义、§3.3 评测口径、§4 方法（四个小节）、§5 实验（设置、主结果、机制分析、迁移）、§6 局限与 §7 结论的核心正文段落；数学推导的完整符号展开、算法伪代码逐行、以及参考文献条目不译。

核心内容

Q：这篇论文发现了什么以前没被单独命名的问题？ A：知识图谱会不断长大。持续学习 (continual KGE) 领域一直盯着一个病叫**灾难性遗忘**——学了新事实，把老表示改坏了。作者说这个解释**不完整**。还有另一件事在同时发生：每进来一个新实体，它就自动进入了**所有兼容查询的候选集**。于是一个历史答案会掉名次，**哪怕**它的分数一点没变、它相对于所有老实体的排序也一点没变。作者给这个效应起名叫**候选集干扰** (candidate-set interference)。

Q：为什么说它和灾难性遗忘是两件事？ A：作者给了一个很干净的判别方式：在**同一个模型 checkpoint** 上，把**同一个历史查询**在**两套候选集**上各评一次。「旧宇宙」只含更新前就已知的实体，「当前宇宙」额外包含新进来的实体。两者的排名差 $D_MCI = H_old - H_cur$ ，就是纯粹由新实体挤占造成的排名损失。它不要求任何参数变化。反过来，候选集固定不变时也照样能发生遗忘。**两者可以互不发生，是两条独立的因果链。**

Q：既然能测出来，为什么还需要新方法？ A：这是全文最值得记的一句话——**当前宇宙评测能暴露这个效应，但它不提供任何控制它的训练规则**。会测 $\neq$ 会治。已有的 replay、蒸馏、参数正则都是冲着遗忘去的，没有一个直接调节「新实体对历史查询造成的排名压力」。

Q：Meor 是怎么治的？ A：核心是**只罚超出部分**。对每个历史查询，算两个量：一是新实体相对于正确答案的「竞争压力」（把每个新实体比答案高出多少分，取正部，做一个 $\beta=5$ 的 log-sum-exp 平滑聚合，并按数量归一化）；二是一个**结构匹配的老实体参照组**产生的同样的量。然后只罚前者超过后者的那部分（平方 hinge，边界处值和梯度都为 0）。**如果新实体的竞争压力和一个结构上可比的老实体组差不多，罚 0**——因为那说明这是正常的竞争，不是入场带来的额外干扰。

Q: 「结构匹配」和「score-blind」是什么意思，为什么关键？ A: 参照组不能随便挑。作者用三级嵌套的键来给每个新实体找对应的老实体：最细一级是 (预测方向, 端点度数分箱, 关联的 relation-role 签名)，找不到就退到丢掉 relation-role，再找不到就只留预测方向。关键是**这三个键全部只依赖图结构，不依赖模型分数** (score-blind)。这样参照组的身份是先于比较就固定下来的，配对的各个方法共用同一批候选 ID，各自只是往上填自己的分数。否则「新实体和老实体的差异」会和「新实体这个身份本身」混在一起，分不清是哪个在起作用。

Q: 效果有多大？该怎么看这个数字？ A: 主实验 ENTITY - ComplEx 上，H_cur 从 replay 的 0.0830 提到 0.0887，配对提升 **0.0057**，单侧 95% 下界 0.0052，8 次配对全赢。但这个 **0.0057** 里有 **0.0055** 来自 D_MCI 的下降，只有 **0.0002** 来自 H_old 的变化——这个分解是全文最有说服力的一处：它证明收益确实来自「减少了新实体的挤占」，而不是顺带改善了别的。迁移实验 10 个设置（两个数据流 × ComplEx/DistMult/TransE/LKGE/IncDE）全部为正，每个 95% 区间都不含 0。

Q: 绝对数值这么小 (MRR 0.08 级别、提升 0.006 级别)，意味着什么？ A: 得诚实地说：**这是小效应**，而且论文自己承认 H_old 的下界是负的 (-0.0001 到 -0.0011，只是没跌破预设的 -0.005 保全线)。它的说服力不来自效应大小，而来自**配对设计的严格性**——同一初始化、同一图流、同一事实顺序、同一 replay 样本、同一负采样、同一停止决策、同一评测查询，8 次全赢。这是「小而稳」，不是「大」。

背景补充 / 点评

几个术语先落地：

- **MRR (mean reciprocal rank, 平均倒数排名)**：链接预测的标准指标。正确答案排第 1 得 1 分、第 2 得 0.5、第 10 得 0.1，再对所有查询取平均。所以 $MRR = 0.08$ 大致对应「正确答案平均排在十几名」——FB15K-237 这类数据集上这属于正常量级。
- **filtered 评测**：算排名时，把图里其他已知的正确答案先剔除，只留当前这个，免得被自己的同伴挤下去。
- **ENTITY / FBInc-S / FBInc-L / WN-CKGE**：四个「实体增长流」数据集，各切成 5 个快照。ENTITY 的实体数从 2909 一路涨到 14541（涨 5 倍），FBInc-S 只从 2909 涨到 2950（几乎不涨），FBInc-L 涨到 3312。这个梯度是故意设计的——用来看方法在不同增长速率下的表现。
- **replay / LKGE / IncDE**：持续学习的三种「宿主」。Meor 不替换它们，是往它们的损失函数上加一项。

我的判断——洞察在哪：这篇最值钱的东西不是 Meor 这个正则项，而是**它证明了一类性能下降被长期归错了因**。整个持续学习社区把历史性能下滑默认记在「遗忘」头上，然后去修模型参数。作者用一个 checkpoint 双宇宙对照，把其中一部分切出来说：这块跟参数没关系，是**评测的候选池变大了**。这是一次归因的重新划分，比方法本身重要。

论文的 §6 局限里还有一处特别诚实的地方：在 WN-CKGE 上，Meor 的 64 条校准记录里**零条被激活**——因为那个数据流上新实体的聚合压力从来没超过匹配参照组，hinge 一直是 0，正则项既不产生损失也不产生梯度。作者没把这个藏起来，而是明确写成「这是一个方法不适用的区间，不是一次效果对比的失败」。一个**只在出手时才出手、其余时候完全退出的机制**，比一个总在施加压力的机制干净得多。

留白在哪：三处。第一，**效应量太小**， H_{cur} 0.0830→0.0887 在实际部署里意味着什么，论文没说。第二，**成本没交代**：每个历史查询都要构造 $J=4$ 个结构匹配参照组、每组最多 256 个老实体的采样池，这个开销随图增长会怎样，全文没有一张训练时间或显存的表。第三，**它只处理实体增长**——作者自己承认，纯关系更新或纯事实更新照样会改坏老表示，但那不产生 D_{MCI} ，Meor 管不着。

对我的启示：这篇讲的是一件我在股票统计上反复踩的事，只是换了个领域的皮。**当比较的基准池本身在变化时，一个指标的变化不能直接归因给被测对象**。论文的做法是把同一个查询在两套候选宇宙上各评一次，用差值把「池子变大」这个因素单独切出来。这跟我 2026-08-05 踩过的那个坑是同一件事：「当日巨量」组个股次 5 日 +2.591%，看着远高于基准，但巨量的日子集中在市场大涨那几天，**按日期配对后差值只剩 +0.032%**。配对，就是构造那个「另一套宇宙」。

更直接可搬的是它的**配对实验设计**：8 次配对里共享初始化、数据顺序、采样、停止条件，只让被测的那一个因素变。我以后做任何「加了这个信号有没有用」的验证，都该照这个形状来——**不是跑两次看谁高，是把除被测因素外的一切都焊死**。以及它报的是**单侧 95% 下界 + W/T/L 计数**，而不是只报一个均值，这个习惯值得抄。

还有一条负面教训值得记：论文的效应量小到 0.005 量级，但它没有做多重比较校正——作者自己在 § 5.1 结尾写了「这些区间是**未经校正的**、针对预先设定的单元格的比较，不是同时置信区间」。**主动声明自己没做校正，比不声明强，但仍然意味着表 5 那 10 个『区间全部不含 0』不能当成 10 个独立的成功证据来数。**

文中金句

"A historical answer can therefore lose rank even when its score and its ordering among old entities are preserved." 因此，一个历史答案会掉名次——即便它的分数、以及它在老实体之间的排序，都被完整保住了。

"Current-universe evaluation exposes candidate-set interference, but the continual objectives reviewed above do not directly regulate the ranking pressure that admitted entities create for each historical fact." 当前宇宙评测能暴露候选集干扰，但上文回顾的那些持续学习目标函数，并不直接调节新入场实体对每一条历史事实造成的排名压力。

"Candidate-set interference can occur without forgetting, and forgetting can occur while the candidate universe remains fixed." 候选集干扰可以在没有遗忘的情况下发生，而遗忘也可以在候选集完全不变的情况下发生。

"Thus Meor controls excessive competition on historical queries rather than treating every newcomer as an error." 因此 Meor 控制的是历史查询上的**过度**竞争，而不是把每一个新实体都当成

错误。

"The suppression mechanism had no direct optimization effect because there was no excess candidate pressure to remove." 该抑制机制没有产生任何直接的优化效果——因为根本不存在需要被移除的超额候选压力。

全文翻译

覆盖范围：摘要、§1 引言、§2.4 候选集干扰、§3.3 评测口径、§4.1 - 4.4 方法、§5.1 - 5.4 实验、§6 局限、§7 结论。数学符号的完整展开与算法伪代码逐行、参考文献条目不译；关键公式以中文解释其含义。

摘要 Abstract

Continual knowledge graph embedding updates entity and relation representations as a graph grows. Existing methods primarily address catastrophic forgetting, but entity admission also changes the candidate universe of every compatible query. A historical answer can therefore lose rank even when its score and its ordering among old entities are preserved. We formalize this effect as candidate-set interference and introduce Matched Excess-Outranker Regularization (Meor), a host-level objective that compares smooth answer-relative newcomer pressure with score-blind, structurally matched old references.

持续知识图谱嵌入（continual KGE）在图谱增长时更新实体与关系的表示。已有方法主要针对[灾难性遗忘](#)，但[实体入场同时也改变了每一个兼容查询的候选宇宙](#)。因此，一个历史答案会掉名次——即便它的分数、以及它在老实体之间的排序，都被完整保住了。我们把这个效应形式化为[候选集干扰](#)，并提出[匹配超额压制者正则化 \(Meor\)](#)：一个宿主层级的目标函数，它把「平滑的、相对于答案的新实体压力」与「不看分数的、结构上匹配的老实体参照」做比较。

Its one-sided penalty acts only when newcomer competition exceeds the matched reference, preserving the host learner's signal for legitimate new entities. Across eight paired runs on ENTITY - ComplEx, Meor improves historical current-universe mean reciprocal rank (MRR) by 0.0057 over replay and reduces candidate-set interference by 0.0055, with one-sided 95% lower bounds of 0.0052 and 0.0051, respectively.

它的[单边惩罚只在新实体的竞争超过匹配参照时才生效](#)，从而保住宿主学习器对那些正当的新实体的学习信号。在 ENTITY - ComplEx 上的 8 次配对实验中，Meor 相对 replay 把历史查询在当前宇宙下的 MRR 提升了 0.0057，并把候选集干扰减少了 0.0055，两者的单侧 95% 下界分别是 0.0052 和 0.0051。

These results establish candidate admission as a distinct source of continual rank loss and show that it can be controlled without replacing the underlying embedding architecture or continual learner.

这些结果确立了[候选实体入场是持续学习中排名损失的一个独立来源](#)，并表明它可以在不替换底层嵌入架构、也不替换持续学习器的前提下被控制住。

引言：遗忘不是全部 Introduction

Knowledge graphs in deployed systems expand as new entities and facts become available, while link prediction must remain reliable for knowledge already represented. Continual knowledge graph embedding supports this process by updating a model without retraining it from the beginning. Existing continual KGE research has focused primarily on catastrophic forgetting, in which learning from new facts changes representations acquired earlier. This account is incomplete when graph growth expands the entity set.

已部署系统中的知识图谱会随着新实体和新事实的到来而扩张，与此同时，链接预测对已表示的知识必须保持可靠。持续知识图谱嵌入通过增量更新模型（而非从头重训）来支撑这个过程。已有的持续 KGE 研究主要聚焦于[灾难性遗忘](#)——即从新事实中学习会改变先前习得的表示。当图谱增长扩大了实体集合时，这个解释是不完整的。

Every admitted entity joins the candidate universe of each compatible query and can displace an established answer even when the answer score and its ordering relative to every previously known entity remain unchanged. The research problem addressed in this paper is how to control this admission-induced historical rank loss without materially weakening the model's ability to learn newly admitted entities when they are correct answers.

[每一个入场的实体都会加入每一个兼容查询的候选宇宙](#)，并且可能挤掉一个已确立的答案——即便该答案的分数、以及它相对于每一个此前已知实体的排序都没有变化。本文要解决的研究问题是：[如何控制这种由入场引起的历史排名损失](#)，同时又不实质性削弱模型在新实体本身就是正确答案时学习它们的能力。

候选集干扰的定义 Candidate-Set Interference

Candidate-set interference is a distinct source of historical rank loss. When new entities enter the graph, they become eligible answers to earlier queries. A historical answer can therefore move down in the ranking even when its score and its ordering relative to every old entity remain unchanged. The loss arises because the query faces additional competitors, not because the model has forgotten how to rank established entities.

候选集干扰是历史排名损失的一个[独立](#)来源。当新实体进入图谱，它们就成为了早先那些查询的合格答案。因此，一个历史答案会在排名中下滑——即便它的分数、以及它相对于每一个老实体的排序都没有变化。这个损失的成因是查询面对了更多竞争者，而不是模型忘记了怎么给已确立的实体排序。

A same-checkpoint comparison makes the distinction precise. Evaluating the same historical query first over the old candidate universe and then over the expanded current universe isolates the rank loss attributable to admitted candidates. Catastrophic forgetting instead concerns changes caused by model updating. Candidate-set interference can occur without forgetting, and forgetting can occur while the candidate universe remains fixed. The two mechanisms are complementary explanations for historical degradation.

同一 checkpoint 上的对照能把这个区分做精确：把同一个历史查询先在旧候选宇宙上评一次、再在扩张后的当前宇宙上评一次，就把归因于新入场候选的排名损失隔离了出来。而灾难性遗忘关心的是模型更新所导致的变化。****候选集干扰可以在没有遗忘的情况下发生，而遗忘也可以在候选宇宙完全不变的情况下发生。***这两个机制是对历史性能退化的互补解释。

The two ranks satisfy: $r_{\text{cur}}(x) = r_{\text{old}}(x) + \sum_{[e \in \Delta C_x] \mid [e > a]}$. This identity isolates the rank loss attributable to newly admitted candidates. It holds even when the ordering among old entities is unchanged and makes no assumption about whether their representations also change.

两个排名满足恒等式：**当前宇宙排名 = 旧宇宙排名 + 新入场候选中排在答案之前的个数**。这个恒等式把归因于新入场候选的排名损失干净地隔离了出来。它在老实体之间的排序完全不变时仍然成立，且对老实体的表示是否也发生变化不作任何假设。

Current-universe evaluation exposes candidate-set interference, but the continual objectives reviewed above do not directly regulate the ranking pressure that admitted entities create for each historical fact.

当前宇宙评测能暴露候选集干扰，但上文回顾的那些持续学习目标函数，并不直接调节新入场实体对每一条历史事实造成的排名压力。

评测口径：三种查询角色与四个端点指标 Query Roles and Evaluation Objectives

We distinguish three query roles. A historical occurrence comes from a fact observed before the current update. A target newcomer occurrence has an answer in ΔE_u . A query newcomer occurrence has a known query entity in ΔE_u and an answer in $E_{\{u-1\}}$. The latter roles capture different learning requirements and are therefore evaluated separately.

我们区分三种查询角色：**历史查询**来自当前更新之前就已观察到的事实；**目标新实体查询**的答案落在本次新增实体集合 ΔE_u 中；**查询端新实体查询**的已知查询实体在 ΔE_u 中、而答案在旧实体集 $E_{\{u-1\}}$ 中。后两种角色刻画的是不同的学习需求，因此分开评测。

Historical current-universe MRR H_{cur} measures the ranking of established answers against every entity available at the current update. Historical old-universe MRR H_{old} restricts the same evaluation to previously known candidates. Their difference, $D_{\text{MCI}} = H_{\text{old}} - H_{\text{cur}}$,

measures the rank loss caused by candidate admission. Target-newcomer MRR A_{TN} evaluates queries whose correct answer is newly admitted.

H_{cur} (历史查询、当前宇宙 MRR) 衡量已确立答案对抗当前更新时刻全部可用实体的排名。 H_{old} (历史查询、旧宇宙 MRR) 把同样的评测限制在此前已知的候选上。两者之差 $D_{MCI} = H_{old} - H_{cur}$ 衡量由候选入场造成的排名损失。 A_{TN} (目标新实体 MRR) 评测那些正确答案本身就是新入场实体的查询。

(这四个指标的关系是本文全部实验的骨架： H_{cur} 是要提升的主指标， D_{MCI} 是要压低的干扰量， H_{old} 和 A_{TN} 是**保全指标**——它们不能被明显牺牲，论文预设的保全线是下界不低于 -0.005 。)

方法一：相对于答案的新实体竞争 Answer-Relative Newcomer Competition

Equation (4) motivates an answer-relative training signal. Newly admitted entities matter when they move above a historical answer. A raw outranker count is discontinuous, while an unnormalized score gap is not comparable across queries. Penalizing newcomers against zero or an arbitrary old sample also confounds cohort identity with visible structural differences.

排名恒等式启发了一个**相对于答案**的训练信号：新入场实体之所以要紧，是因为它们爬到了历史答案之上。但直接数「压过答案的个数」是不连续的（没法求梯度），而未归一化的分数差在不同查询之间又不可比。另一方面，把新实体拿去和 0 比、或者和一个随便选的老样本比，会把「**新实体这个身份**」和「**可观察到的结构差异**」混在一起。

Meor combines a smooth, normalized measure of newcomer competition relative to the answer with an old reference matched on observable structure. It penalizes only the portion of newcomer competition that exceeds this reference. Consequently, a large newcomer aggregate incurs no penalty when a structurally comparable old cohort produces a similar value.

Meor 把两样东西结合起来：一个**平滑的、归一化的、相对于答案的新实体竞争度量**，和一个**在可观察结构上做了匹配的老实体参照**。它只惩罚新实体竞争中**超出该参照的那一部分**。因此，当一个结构上可比的老实体组产生了相近的数值时，即便新实体的聚合量很大，也不会受到任何惩罚。

For a nonempty ordered candidate multiset $C = (e_1, \dots, e_n)$, define $U_\beta(x, C) = (1/\beta) \cdot \log((1/n) \cdot \sum_i \exp\{\beta \cdot [z_x(e_i)]_+\})$, $\beta > 0$. The normalization by n prevents cohort size alone from increasing the aggregate. The aggregate is zero exactly when no member scores above the answer, and it never exceeds the largest positive normalized gap in C . The parameter β determines how strongly the largest active gaps influence the smooth aggregate. The quantity is neither an outranker count nor a probability.

对一个非空的有序候选多重集 C ，定义聚合量 U_β 为：把每个候选相对答案的归一化分数差取正部（低于答案的一律算 0），乘以 β 后取指数、**按数量 n 求平均**、再取对数除以 β 。**除以 n 这一步很关键**：它防止了「参照组人多」本身就把聚合量抬高，也使聚合量对整个多重集的原样复制保持不变。这个量**当且仅当没有任何成员分数高于答案时为 0**，且永远不超过 C 中最大的那个正向归一化差。参数 β 决定了最大的那几个活跃差值对平滑聚合的影响强度。**这个量既不是压过者的计数，也不是概率。**

方法二：不看分数的结构匹配参照 Score-Blind Matched References

We assume old reference should resemble the newcomer cohort in observable structural characteristics while remaining independent of the scores being compared. For entity e and prediction mode d , let $b_u(e,d)$ be its endpoint-degree bin and let $\rho_u(e,d)$ be its set of incident relation-role pairs, both computed from the cumulative training prefix. Matching uses three nested, score-blind keys. The finest key retains $(d, b_u(e,d), \rho_u(e,d))$, the next drops the relation-role signature, and the terminal key retains only d . For each newcomer, we select the first key whose corresponding old-entity cell is nonempty.

我们的假设是：**老实体参照应当在可观察的结构特征上与新实体组相像，同时与正在被比较的分数无关**。对实体 e 和预测方向 d ，令 $b_u(e,d)$ 为它的端点度数分箱、 $\rho_u(e,d)$ 为它的关联 relation-role 对集合，两者都从累积的训练前缀中计算得出。匹配使用**三层嵌套的、不看分数的键**：最细的键保留（预测方向，度数分箱，relation-role 签名）；次一级丢掉 relation-role 签名；最末一级只保留预测方向。对每个新实体，选取**第一个对应老实体单元格非空的键**。

We construct J matched draws. Their candidate identifiers are fixed independently of scores and shared by paired methods. Each model then supplies its own scores for those candidates. This design reduces observable cohort imbalance without treating the matched references as causal counterfactuals.

我们构造 J 组匹配抽样。**它们的候选标识符是独立于分数确定的，并由配对的各个方法共享**；随后每个模型只是为这些候选填上自己的分数。这个设计减少了可观察到的组间失衡，同时**不把匹配参照当作因果反事实来看待**。

（作者在这里很克制：他没有声称这是因果推断，只说是减少可观察的失衡。这个分寸值得注意——结构匹配能控制的只有你观察得到的那几个变量。）

方法三：超额目标与它为什么这样求平均 Matched Excess Objective

The mean old reference is $U_O(x) = (1/J) \cdot \sum_j U_\beta(x, O_x^{(j)})$. The mean in Equation (14) is computed before applying the hinge to positive excess. If the newcomer aggregate equals the mean reference, its contribution is zero even when it exceeds an individual draw. Applying a separate hinge to each draw before averaging would impose downward pressure in that case. The squared hinge has both value and gradient zero at the boundary, and its penalty increases with positive excess.

老实体参照的均值是 J 组抽样各自聚合量的平均。**这个平均是在对正的超额量施加 hinge 之前算的**——这个顺序很讲究：如果新实体的聚合量恰好等于参照均值，那么它的贡献就是 0，**即便它超过了其中某一组个别抽样**。反过来，如果先对每一组分别施加 hinge 再平均，这种情况下就会产生一股向下的压力（把本不该罚的也罚了）。平方 hinge 在边界处**值和梯度都为 0**，且惩罚随正的超额量递增。

With regularization coefficient $\lambda \geq 0$, the complete refinement objective is $L = L_{\text{host}} + \lambda \cdot L_{\text{Meor}}$. The host objective retains its positive learning signal for newly admitted entities. Thus Meor controls excessive competition on historical queries rather than treating every newcomer as an error.

带上正则系数 $\lambda \geq 0$ ，完整的精调目标是「宿主损失 + $\lambda \times$ Meor 损失」。宿主目标函数原封不动地保留了它对新入场实体的正向学习信号。因此 Meor 控制的是历史查询上的过度竞争，而不是把每一个新实体都当成错误。

方法四：两个用来隔离机制的对照 Controls for the Proposed Mechanism

The central contribution of Meor is to combine smooth answer-relative aggregation with score-blind structural matching. Two controls isolate these components. The Matched Maximum Regularizer (MMR) replaces the smooth aggregate with $V(x, C) = \max[z_x(e_i)]_+$ and uses the same matched reference cohorts. This comparison isolates the effect of distributing pressure across the active score tail rather than controlling only the largest gap. The Unmatched Old Regularizer (UOR) retains U_β but replaces each matched reference with an equal-cardinality multiset drawn from the terminal role-only old pool. This comparison isolates the contribution of structural matching.

Meor 的核心贡献是把平滑的、相对答案的聚合与不看分数的结构匹配两者结合起来。作者设计了两个对照来分别隔离这两个成分：

- **MMR（匹配最大值正则）**：保留同样的匹配参照组，但把平滑聚合换成只取最大值。这个对比隔离出的是「把压力分摊到整个活跃分数尾部」相对于「只控制最大的那个差」的效果。
- **UOR（非匹配老实体正则）**：保留平滑聚合 U_β ，但把每个结构匹配参照换成从最末一级（只按角色）老实体池里抽的等基数多重集。这个对比隔离出的是结构匹配本身的贡献。

Replay uses the same host refinement with zero regularization and therefore isolates the contribution of the intervention. A persistent admission-cohort calibrator provides a score-only control. All controls share the host model, update data, replay information, optimization budget, and trainable parameter scope.

Replay 用同样的宿主精调但正则系数为 0，因此它隔离出的是这次干预本身的贡献。另外还有一个持续入场群校准器作为「只动分数」的对照。所有对照共享宿主模型、更新数据、replay 信息、优化预算和可训练参数范围。

实验设置 Experimental Setting

Our experiments use four five-snapshot entity-growth streams. ENTITY is the primary FB15K-237 stream introduced with LKGE. FBInc-S and FBInc-L are the small-growth and large-growth streams distributed with the informed-initialization benchmark. WN-CKGE is the WordNet stream

used by FastKGE. It represents the applicability boundary discussed in Section 6 and is not treated as a positive efficacy setting.

我们的实验使用四个「五快照实体增长流」。**ENTITY** 是随 LKGE 提出的主 FB15K-237 数据流；**FBInc-S** 和 **FBInc-L** 是随「知情初始化」基准发布的小增长流与大增长流；**WN-CKGE** 是 FastKGE 使用的 WordNet 流，它代表了 § 6 讨论的**适用性边界**，不被当作一个正向的效果对比设定。

表 1：数据集统计（实体数与关系数为累积，Facts 为该快照新引入的三元组数）

数据集	快照0 实体/关系/ 事实	快照1	快照2	快照3	快照4
ENTITY	2,909 / 233 / 46,388	5,817 / 236 / 72,111	8,725 / 236 / 73,785	11,633 / 237 / 70,506	14,541 / 237 / 47,326
FBInc-S	2,909 / 233 / 46,388	2,919 / 233 / 235	2,930 / 233 / 152	2,940 / 233 / 180	2,950 / 233 / 239
FBInc-L	2,909 / 233 / 46,388	3,010 / 233 / 3,110	3,110 / 234 / 2,736	3,211 / 234 / 2,908	3,312 / 234 / 3,105
WN-CKGE	24,567 / 11 / 55,801	28,660 / 11 / 9,300	32,754 / 11 / 9,300	36,848 / 11 / 9,300	40,943 / 11 / 9,302

（这张表值得停一下：ENTITY 的实体数翻了 5 倍，FBInc-S 几乎没涨。**方法在 ENTITY 上有效、在 FBInc-S 上也有效、在 WN-CKGE 上完全不激活**，这三种情况恰好构成了一条从「强增长」到「不适用」的连续谱。）

The primary study uses ComplEx with 200 complex coordinates and float64 arithmetic. We instantiate Meor with $\beta = 5$, four matched reference cohorts, and at most 256 old entities in each scale sample. The primary, ablation, and transfer studies each use eight paired runs. Within a pair, the compared methods share initialization, graph stream, fact order, replay sample, negative samples, stopping decisions, and evaluation queries.

主实验使用 ComplEx（200 个复数坐标、float64 运算）。Meor 的实例化参数为 $\beta = 5$ 、4 组匹配参照、每个尺度样本最多 256 个老实体。主实验、消融和迁移实验**各用 8 次配对运行**。在一个配对内部，被比较的方法共享初始化、图流、事实顺序、replay 样本、负采样、停止决策和评测查询。

For the primary and ablation studies, LB denotes the one-sided 95% lower confidence bound computed from the eight unrounded paired effects. Preservation requires the lower bound for ΔH_{old} or ΔA_{TN} to remain above -0.005 . These intervals are unadjusted summaries of prespecified, cell-specific comparisons rather than simultaneous family-wise intervals.

主实验和消融实验中，LB 表示从 8 个未取整的配对效应计算出的**单侧 95% 置信下界**。保全性要求 ΔH_{old} 或 ΔA_{TN} 的下界保持在 -0.005 以上。这些区间是未经校正的、针对预先设定的特定单元格的比较摘要，而不是同时（family-wise）置信区间。

主结果 Primary Results on ENTITY

表 2: ENTITY - ComplEx 上各方法的绝对端点表现

方法	H_cur ↑	H_old ↑	D_MCI ↓	A_TN ↑
Replay	0.0830	0.1199	0.0369	0.1700
持续校准	0.0816	—	—	0.1753
MMR	0.0836	0.1200	0.0364	0.1695
UOR	0.0842	0.1200	0.0358	0.1698
Meor	0.0887	0.1201	0.0314	0.1715

At 0.0887, Meor attains the highest H_cur. It also records the highest H_old and the lowest D_MCI, while increasing A_TN above replay, MMR, and UOR. Persistent calibration attains the highest A_TN but a lower H_cur.

Meor 以 0.0887 取得最高的 H_cur，同时也取得最高的 H_old 和最低的 D_MCI，并且 A_TN 也高于 replay、MMR 和 UOR。持续校准取得了最高的 A_TN，但 H_cur 更低。

表 3: Meor 相对各机制对照的配对效应（8 次配对训练）

对照	ΔH_cur 均值/下界	ΔH_old 均值/下界	D_MCI 减少 均值/下界	ΔA_TN 均值/下界	胜/平/负
Replay	0.0057 / 0.0052	0.0002 / -0.0001	0.0055 / 0.0051	0.0015 / 0.0008	8/0/0
持续校准	0.0071 / 0.0065	—	—	-0.0038 / -0.0043	8/0/0
MMR	0.0051 / 0.0047	0.0001 / -0.0003	0.0050 / 0.0049	0.0020 / 0.0015	8/0/0
UOR	0.0045 / 0.0030	0.0001 / -0.0011	0.0044 / 0.0041	0.0017 / 0.0012	7/0/1

The decomposition against replay locates the gain in candidate admission rather than parameter retention. The 0.0057 increase in H_cur combines a much smaller 0.0002 change in H_old with a 0.0055 reduction in D_MCI. These paired decompositions indicate that the gains arise primarily from reduced competition by newly admitted entities, while the mean changes in old-universe ranking are small.

相对 replay 的分解把收益定位在了「候选入场」而非「参数保持」上：H_cur 提升的 0.0057，是由一个小得多的 H_old 变化（0.0002）与一个 D_MCI 减少（0.0055）合成的。这些配对分解表明，收益主要来自新入场实体竞争的减少，而旧宇宙排名的均值变化很小。

The H_old lower bounds against replay, MMR, and UOR are -0.0001, -0.0003, and -0.0011, respectively, all above the -0.005 margin.

相对 replay、MMR 和 UOR 的 H_old 下界分别为 -0.0001、-0.0003 和 -0.0011，全都在 -0.005 的保安全线之上。（注意：三个下界都是负的，只是没跌破预设的线。这是「未证明其无害」，不是「证明其无害」。）

机制分析：每个成分各贡献多少 Mechanism Analysis

表 4: Meor 参照构造与聚合方式的直接消融 (ENTITY - ComplEx)

被隔离的性质	对照方案	ΔH_{cur} 均值/下界	D_MCI 减少 均值/下界	ΔA_{TN} 均值/下界
平滑尾部聚合	MMR (取最大值)	0.0051 / 0.0047	0.0050 / 0.0049	0.0020 / 0.0015
结构匹配	UOR (只按角色的参照)	0.0045 / 0.0030	0.0044 / 0.0041	0.0017 / 0.0012
查询专属的参照分配	打乱的匹配参照	0.0008 / 0.0005	0.0007 / 0.0002	0.0002 / -0.0002
老参照的中心化	不做减法的平滑惩罚	0.0011 / 0.0006	0.0009 / 0.0003	0.0003 / -0.0002

Each component makes a distinct contribution. Smooth tail aggregation produces the largest gain over its matched alternative, with a mean H_{cur} effect of 0.0051. Structural matching follows closely with a mean effect of 0.0045. Old-reference centering contributes 0.0011, and query-specific assignment contributes 0.0008. Every ablation also yields a positive lower bound for reducing D_MCI.

每个成分都有其独立贡献。**平滑尾部聚合**相对其匹配替代方案带来最大增益 (H_{cur} 均值效应 0.0051)；**结构匹配**紧随其后 (0.0045)；**老参照中心化**贡献 0.0011；**查询专属分配**贡献 0.0008。每一项消融在减少 D_MCI 上都给出了正的下界。

(读这张表要注意量级差：前两项在 0.005 量级，后两项在 0.001 量级——**真正撑起效果的是前两项，后两项属于锦上添花**，而且它们的 ΔA_{TN} 下界已经是负的。)

迁移实验 Transfer Across Streams, Backbones, and Hosts

The transfer study treats Meor as an intervention within a named host rather than as a replacement continual KGE architecture. Replay is evaluated with ComplEx, DistMult, TransE, LKGE - TransE, and IncDE - TransE.

迁移实验把 Meor 当作**在某个具名宿主内部的一次干预**，而不是一个替代性的持续 KGE 架构。Replay 分别搭配 ComplEx、DistMult、TransE，以及 LKGE - TransE 和 IncDE - TransE 两个持续学习更新流程来评测。

Adding Meor improves H_{cur} in all ten transfer settings, and every 95% interval excludes zero. The replay gains range from 0.0020 to 0.0026 across the two streams and three backbones. The gains within LKGE are 0.0023 on FBInc-S and 0.0026 on FBInc-L, while those within IncDE are 0.0029 and 0.0032. Four settings improve in all eight paired runs, and each remaining setting improves in at least seven. The A_{TN} effects are slightly negative, ranging from -0.0001 to -0.0015, but every lower bound remains above the -0.005 preservation margin.

****加上 Meor 后，10 个迁移设定的 H_{cur} 全部提升，且每个 95% 区间都不含 0。 ****在两个数据流和三个骨干上，replay 的增益在 0.0020 到 0.0026 之间；LKGE 内部的增益是 FBInc-S 上 0.0023、FBInc-L 上 0.0026；IncDE 内部则是 0.0029 和 0.0032。4 个设定在全部 8 次配对中都提升，其余每个设定至少在 7 次中提升。**A_TN 的效应轻微为负**，范围在 -0.0001 到 -0.0015 之间，但每个下界都仍在 -0.005 的保全线之上。

局限：一个只在出手时才出手的机制 Limitations

Meor is designed for entity-growth streams in which newly admitted entities become overly competitive answers to historical queries. WN-CKGE defines the complementary boundary. In the registered WN-CKGE diagnostic, Meor and MMR each had zero active records among 64 calibration records, indicating that aggregate newcomer pressure did not exceed the matched old-candidate reference under the fixed construction. Their regularization terms therefore contributed neither loss nor gradient in the evaluated records.

Meor 是为「新入场实体成为历史查询的过度竞争性答案」这类实体增长流设计的。**WN-CKGE 定义了它的互补边界**：在预先登记的 WN-CKGE 诊断中，Meor 和 MMR 在 64 条校准记录里**各自都是零条被激活**，说明在固定的构造下，新实体的聚合压力从未超过匹配的老候选参照。因此在被评测的记录中，它们的正则项**既没有贡献损失、也没有贡献梯度**。

The suppression mechanism had no direct optimization effect because there was no excess candidate pressure to remove. This selective activation is central to the method. Meor intervenes when entity admission disturbs historical ranking and otherwise leaves refinement governed by the host objective. WN-CKGE thus documents an inactive applicability regime rather than a positive efficacy comparison.

该抑制机制没有产生任何直接的优化效果——**因为根本不存在需要被移除的超额候选压力**。这种**选择性激活正是方法的核心**：Meor 只在实体入场扰乱了历史排名时才介入，其余时候把精调完全交还给宿主目标函数。因此 WN-CKGE 记录的是一个**不激活的适用区间**，而不是一次效果对比的失败。

The method does not address every source of degradation in a continual knowledge graph. Relation-only or fact-only updates can still alter established representations, but they do not create the entity-candidate expansion captured by D_MCI. Meor is consequently a complement to replay, distillation, and parameter-stability methods rather than a replacement for them.

该方法并不处理持续知识图谱中的每一种退化来源。**纯关系更新或纯事实更新仍然会改变已确立的表示，但它们不产生 D_MCI 所刻画的那种实体候选扩张。因此 Meor 是 replay、蒸馏和参数稳定性方法的补充而非替代。**

The quality of the reference depends on the structural information available for matching. Prediction role, degree, and incident relation-role signatures provide a score-blind basis for comparison.

参照的质量取决于可用于匹配的结构信息。预测角色、度数、以及关联的 relation-role 签名，共同提供了一个不看分数的比较基础。

结论 Conclusions

We formalized this effect as candidate-set interference and separated it from catastrophic forgetting. Meor suppresses only the excess competition attributable to admission, while the host learner remains responsible for retaining prior knowledge and acquiring new facts. These findings establish candidate-set interference as a distinct source of continual rank loss.

我们把这个效应形式化为[候选集干扰](#)，并把它与灾难性遗忘分离开。Meor 只压制那部分可归因于入场的超额竞争，而保留旧知识与习得新事实的职责仍然由宿主学习器承担。这些发现确立了候选集干扰是持续学习中排名损失的一个独立来源。

参考链接

- [arXiv 2608.24273](#) — 本文预印本
- [FB15K-237](#) — 本文 ENTITY/FBInc 数据流的底座图谱，去除了 FB15K 中的逆关系泄漏
- [LKGE](#) — 提出 ENTITY 数据流的持续 KGE 方法，本文的宿主之一
- [IncDE](#) — 另一个持续 KGE 宿主，本文迁移实验中 Meor 增益最大的宿主
- [ComplEx](#) — 主实验使用的复数嵌入模型