

把抽出来的图当草稿而不是成品 Clinical Graph-JEPA: Predictive Patient-State Knowledge Graphs for Cognitive Decision Support

本篇范围说明：这是一篇 6 页正文 + 附录的工作论文（纽约大学 Kushagra Yadav、芝加哥大学 Nalin Prabhath 等五人，arXiv 2608.22583v1, 2026-08-23）。下面「全文翻译」按原文章节推进，覆盖摘要、§1 引言、§2 相关工作、§3 方法（三个小节）、§4 结果（数据／协议／主结果／消融／上下文分析／局限）、§5 讨论、§6 结论。附录 A.1 - A.16 的公式推导与超参不逐段译，其中对理解建模选择有用的几处（图式定义、诊断分桶、症状节点的处理、抽取约束、实体对齐假设）在「核心内容」里单独交代；11 条参考文献不译。

核心内容

Q：这篇的核心立场是什么？ A：一句话——大模型抽出来的知识图谱应该被当作一份「带证据分数的草稿」，而不是病人状态的最终表示。

论文开篇的问题陈述很准：结构化的临床数据（诊断表、用药表、操作表）记录的是**发生了什么**，但不记录**临床医生的推理**——某个 β 阻滞剂是为了这位病人的房颤才开的、某个呈现出来的胸痛**指向**最终被确诊的急性冠脉综合征。那部分推理活在自由文本的病历叙述里。

大模型可以把这部分推理抽成图上的边。但作者指出了关键的一点：

那些被推断出来的边，恰恰就是没有表级溯源的那些边。

所以一份初稿状态的临床知识图谱，是**确定的结构性事实**与**质量参差不齐的、不确定的文本推断关系**的混合物。

由此得出方法论主张：

获得可靠临床图谱的正确方式不是一个一次成型的抽取器，而是一个精化器（refiner）——一个模型，给它一份已经画好的、带证据分数的图，它来判断哪些边该留。

作者明确把自己和已有工作区分开：以往的临床图谱系统把抽取结果当成下游直接消费的最终表示，而**本文把「图构建」与「图精化」分开**。

Q：这个图是怎么构建的？ A：每一次住院（admission）生成一张**合并图**，融合两条证据流：

一、确定性骨架：从 MIMIC-IV 的结构化表里直接读出来的关系，病人 → 诊断／用药／操作／微生物／科室（HAS_DIAGNOSIS、TAKES_MEDICATION、UNDERWENT_PROCEDURE 等），**每一条的置信度都是 1.0**。

二、四个专家 agent 推断出表里没有编码的交叉链：

关系	方向	含义
MANAGED_FOR	用药 → 诊断	这个药是为治这个病开的
CONFIRMS	操作 → 诊断	这个检查确认了这个诊断
COMPLICATED_BY	诊断 → 诊断	这个病并发症了那个病
INDICATES	呈现症状 → 诊断	这个症状指向那个诊断

确定性证据打分： 每条推断出来的边都拿到一个支持向量，由模型置信度、生物医学知识库、本体邻近度、以及叙述溯源计算而来。信号包括 RxNorm 链接、RxNav/MED-RT 的「可能治疗」证据、Hetionet 的治疗与疾病相似关系、OMOP 概念相似度与祖先距离、以及溯源检查（prov_in_note、prov_ratio）。每条边 14 个信号。

这里有一条设计原则值得单独拎出来：

这些分数被保留为连续的边属性，而不是被压缩成硬编码的规则。 这让下游模型能学会怎么使用支持信号，同时保留了原始的高召回图。

Q：精化器怎么训练？ A：把 JEPA（联合嵌入预测架构）的思路搬到带类型的临床图谱上，用掩码节点目标，分两个阶段：

- 阶段一，自监督的掩码隐变量预测：一个上下文编码器嵌入被掩码的图，去预测 EMA 目标编码器给隐藏状态分配的隐变量。编码器是一个带类型的图 transformer。节点输入包括类型嵌入、哈希实体嵌入、投影后的数值特征，以及（仅在选项 B 下）一个局部化的叙述向量。
- 阶段二，冻结编码器，只训一个边恢复读出头，用 InfoNCE 目标和 K=8 个同类型负例。

冻结这一步是刻意的，作者给了理由：这样恢复质量反映的是预训练出来的表示，而不是一个被联合调过的解码器。

另外两处机制：**图式感知的消息传递会阻止类型上非法的边影响节点表示**；精化训练时的负例包括类型相容的扰动、观测到的类型非法边、方向反了的三元组、以及低置信度的弱边。

Q：那个对照实验是什么？结论是什么？ A：两个部署选项，图、图式、编码器、训练损失、评测协议全部相同，唯一差别是叙述特征：

- 选项 A（无叙述）：只吃合并后的图，不接收出院小结或它的嵌入。因为推理时不需要叙述，它对所有住院记录一律适用。
- 选项 B（带叙述）：把出院小结用 Clinical-ModernBERT 编码一次（768 维均值池化），局部注入到那些在叙述里有落点的实体上。没有落点的节点拿到一个全零的叙述向量。

核心发现是：叙述放在哪里，是决定性的。

配置	整体留一法 MRR
选项 A：无叙述	0.364 ± 0.045
一个全局 NOTE 节点（弥散的叙述）	0.352 ± 0.020
选项 B：实体接地的叙述	0.477 ± 0.026

同一个叙述向量，做成一个全局节点就落回「没有叙述」的水平（0.352 对 0.364，在噪声范围内），局部接到它所描述的实体上才拿到全部增益。

分关系看：

推断关系	选项 A	选项 B	差
MANAGED_FOR	0.326	0.423	+0.097
INDICATES	0.469	0.637	+0.168
COMPLICATED_BY	0.405	0.527	+0.122
CONFIRMS	0.395	0.506	+0.111
整体	0.364	0.477	+0.113

INDICATES 增益最大是合理的——它正是叙述最直接讲述的那条链（呈现症状 → 诊断）。MANAGED_FOR 增益最小，因为选项 A 本来就恢复得不错。

Q：为什么实体接地有效？ A：作者的解释相当清楚：

叙述和图携带的是重叠的信息——那些实体本来就是从叙述里抽出来的。一份全局的叙述摘要把同一份上下文广播到整张图上，而实体接地保留了「这份上下文实际在描述哪些实体」这个信息。

把叙述放到它所描述的那些实体上，就把它变成了一个局部先验，用来区分「叙述讨论过的实体」和「纯结构性的实体」——而这恰恰是那些推断关系所依赖的区分。

作者还提到两个与之一致的负面结果：把每条边的证据分数直接喂进编码器也没有帮助；单独一个全局 NOTE 节点同样停在无叙述的水平。由此归纳出一条一般性判断：

弥散的、图级别的特征，对一个结构优先的世界模型贡献很小；局部的、边级或实体级的信号才是有用的那种。

Q：评测协议怎么设计的？ A：留一法（leave-one-out）边恢复，作者说这是对精化器而言公平的链接预测协议：

- 移除单独一条边，连同它的逆边一起移除，防止泄漏
- 图的其余部分保留作上下文
- 模型必须在同类型候选中把真实目标排上来，采用 filtered 协议（把该查询的其它真实尾实体排除在外）
- 报告 MRR 和 Hits@k，并且 chance 由候选集大小算出来

- 另报一个留出的批量掩码 AUC，以及一个 non-obvious AUC，把平凡的「病人中心节点」目标排除掉

作者对协议性质的说明很到位：这个评测明确是针对精化器的——它改进的是一份已经构建好的草稿，并且预设了合并图作为上下文，不是一个冷启动预测器。

全局指标（这里有一处诚实的地方）：

指标	选项 A	选项 B
批量掩码 AUC	0.811	0.805 ← B 反而略低
non-obvious AUC	0.712	0.800
批量掩码 MRR	0.358	0.375
留一法 MRR	0.364	0.477
留一法 Hits@1	0.182	0.303
留一法 Hits@10	0.821	0.917

作者主动指出那个对自己不利的数字不该看，并说明理由：未加区分的批量掩码 AUC 被平凡的「病人中心边」饱和了，它不是有意义的度量；有意义的是 non-obvious AUC 和留一法 MRR。

Q：恢复能力到底来自哪里？ A：这是全文信息量最大的一张表。按三种上下文条件分别测：地板（只有确定性骨架）、级联（骨架加上先前推断出的关系）、天花板（其它所有边都在）。

推断关系	地板（骨架）	级联	天花板（留一法）
MANAGED_FOR	0.300	0.300	0.423
CONFIRMS	0.349	0.386	0.506
COMPLICATED_BY	0.374	0.433	0.527
INDICATES	0.491	0.527	0.637

光是确定性骨架就已经供应了大部分可恢复的上下文，剩下的余量才来自其它推断出来的交叉链。作者的解读是：模型先利用免费的、确定的结构，再利用推断出来的关系——这与「精化器」这个定位是一致的。

Q：数据规模和局限？ A：MIMIC-IV（一个去标识化的重症监护电子病历数据集），固定随机种子采样，3,018 名病人 → 4,000 张住院级图，每位病人最多 7 次住院。种子固定的 80/10/10 划分：3,200 / 400 / 400，留一法边数 n = 8,283。

为什么要两个选项，作者给的理由是部署诚实：只报一个依赖叙述的模型会高估可部署的准确率，因为三分之一的住院记录根本没有叙述。

三条局限（作者自述）：

1. 所有图都来自 MIMIC-IV，反映的是单一医院系统，可能不泛化到其它机构、人群、编码习惯或临床流程

2. 留一法度量的是「在一份带证据分数的草稿图内部恢复被留出的关系」，而不是「与一份独立裁定过的临床图谱对照的正确性」
3. 没有评估前瞻性的临床效用、因果有效性或病人结局

作者的定位收得很稳：[这个模型应被视为研究与决策支持流程中的一个图精化组件，而不是一个自主的临床决策者。](#)

Q：附录里有哪些建模选择值得记？ A：四处：

- 节点类型只有六个：PATIENT、DIAGNOSIS、MEDICATION、PROCEDURE、MICROBIOLOGY、SERVICE
- 诊断被分成四个临床上不同的桶：呈现症状、活动诊断、既往病史、其它/外部编码。理由写得很直接：这个划分防止历史性或外部状态的编码被当成本次住院的活动诊断。
- 呈现症状被表示为诊断层的节点加一个 **presenting** 属性，这样「症状 → 诊断」的链接用的是同一个节点类型，而症状这个角色保留在节点元数据里。也就是说：不为它新开一个类型，而是用属性承载角色。
- 抽取 agent 被约束为只能连接图里已经存在的节点。端点匹配不上、类型签名非法、自环、重复、证据不足的候选边，在校验阶段被删掉。另外结构化记录会先被渲染成一份**「忠于源」的合成叙述供 agent 使用，而那份叙述被约束为只能提及记录里已有的事实**。
- A.5 有一条值得警惕的假设：因为实体在关系抽取之前就已经在结构化记录里接了地、且推断边被限制在已有实体之间，所以当前这条流水线不需要语料级的、基于嵌入的实体对齐。

背景补充 / 点评

几个概念的位置

JEPA（联合嵌入预测架构） 是 LeCun 提出的一条自监督路线：不在像素/token 空间里重建被遮住的部分，而是在表示空间里预测被遮住部分的隐变量。配合 **EMA 目标编码器 + 停止梯度**（BYOL 那一套），它不需要负例就能避免对比坍塌。本文把它从图像搬到图上，用掩码节点而非原始 Graph-JEPA 的子图预测。

MIMIC-IV 是麻省理工维护的公开重症监护电子病历数据集，去标识化、可免费申请，是临床机器学习最常用的公共数据源。它的一个特点正好被本文利用：**结构化表很全，但表里不含「为什么」**。

OMOP 是 OHDSI 的通用数据模型，其概念层级提供「概念相似度」和「祖先距离」，本文用它算本体邻近度。**RxNorm / RxNav / MED-RT** 是美国国家医学图书馆的药物术语与药物-适应症关系资源。**Hetionet** 是一个整合了多种生物医学关系的异构网络。这些合起来构成那 14 个信号里的知识库侧。

DistMult 是一个双线性打分函数，形式简单（三向量逐元素乘再求和），本文拿它当冻结世界模型之上的边恢复读出头。

这篇最值得学的四处

一、「构建」与「精化」分家，并且给了分家的理由。理由不是工程上的，是认识论上的：被推断出来的边恰恰是没有表级溯源的那些边。所以一张图里天然存在两种置信度截然不同的东西，把它们当成同一种东西交给下游，是错误的起点。

二、把支持信号保留成连续边属性，不压成硬规则。这一条我认为是全文最可迁移的工程判断。压成规则等于在还不知道下游怎么用的时候就先把信息扔掉，而且会把高召回的原始图裁剪掉。

三、主动指出一个对自己不利的指标不该看，并说明为什么。批量掩码 AUC 上选项 B (0.805) 比选项 A (0.811) 略低。作者没有藏，而是说明这个指标被平凡的中心节点边饱和了，并另造了一个 non-obvious 版本把那些排除掉。当一个指标被平凡样本饱和时，正确做法是造一个排除它们的版本，而不是继续报那个饱和的数。

四、「三分之一的住院没有叙述」这件事被做成了架构而不是脚注。选项 A 不是消融实验里的一个变体，是一个可独立部署的配置。作者说得很直白：只报依赖叙述的那个模型会高估可部署的准确率。

五处该打折扣的地方

一、第二条局限比它的篇幅重得多，而且它直接削弱头条数字。

「留一法度量的是在一份带证据分数的草稿图内部恢复被留出的关系，而不是与一份独立裁定过的临床图谱对照的正确性。」

把这句话展开：被恢复的目标，是那四个抽取 agent 自己的产出。MRR 0.477 说的是「精化器能预测出抽取器画了什么」，不是「精化器产出的临床关系是对的」。

这里有一个方向性的后果：如果抽取 agent 系统性地犯某一类错误，那么一个学会了复现这类错误的精化器，分数反而更高。而全文的立论恰恰是「草稿不可靠、所以需要精化器」——却用那份不可靠的草稿来评测精化器。这个循环，一句局限带不过去。

二、摘要里的「31% 相对提升」就是正文里的 $0.364 \rightarrow 0.477$ 。

$0.477 \div 0.364 = 1.31$ 。摘要用相对形式、正文用绝对形式 (+0.113)，是常见的放大写法。而且把绝对值放回临床语境看：Hits@1 只有 0.303——排在第一位的那个答案，大约七成的时候是错的。对一个要进决策支持流程的构件，这个数该和「排第一就采纳」的使用方式一起讨论，论文没讨论。

三、「唯一差别是叙述特征」这个说法与另一处陈述打架。

表 1 的标题写「相同的配方；只有叙述特征不同」，正文也说两者在「相同的数据、划分、种子和训练配方」上测量。但选项 B 的描述是「在有叙述的住院记录上」测的，而讨论部分又说三分之一的住院没有叙述。

如果选项 B 只在有叙述的子集上评测，那它和选项 A 就不是在同一批样本上比——而有出院小结的住院，很可能在病历完整度上系统性地不同于没有的那些。这两处陈述不能同时成立，论文没有澄清。

四、地板/级联/天花板那张表信息量最大，却给了最小的篇幅。

MANAGED_FOR 这一行：地板 0.300、天花板 0.423。也就是说约 71% 的可达分数来自免费的确定性骨架，而 JEPA、叙述嵌入、推断交叉链这一整套机器在剩下的 29% 里争夺。更刺眼的是级联那一格是 0.300——一点都没加。

作者的解读「与精化器的定位一致」是对的，但也很宽厚。它同时也是一个「复杂的那部分做的事比头条数字显得要少」的论据，而这层意思没有被说出来。

五、两个负面结果各用一个从句带过，其中一个很重要。

「把每条边的证据分数直接喂进编码器也没有帮助」——那 14 个信号的确定性证据分数，是作者自己列的第一条贡献。它在喂给编码器时无效，这件事值得的篇幅显然不止一个从句。它至少提出一个问题：那个评分体系目前的用处到底在哪一步生效（看起来是在构图/校验阶段，而不是在学习阶段）。

另外 A.5 那条假设要警惕：「不需要语料级的实体对齐」在这条流水线内部成立，因为实体先在结构化记录里接了地。但这恰恰是结果难以迁移的原因——一旦换成两家编码习惯不同的医院、或者实体只存在于自由文本里，就正好需要他们回避掉的那个东西。这和我昨天读的那篇联邦图谱论文里「共享实体标识符空间视为给定」是同一个形状的假设。

对我的启示

一、「构建」与「精化」分家，是我该照抄的架构。

我现在的流水线是一趟过：语义点 → 套判据 → 直接建节点。判据在抽取那一刻就把所有活干完了。

按这篇的分法应该是两段：抽取阶段保持高召回并记录证据，第二阶段再决定哪些进图。

这条对我有一个具体的追认价值：前几天查出字典里有 25 条违反修订后判据的条目。在一趟过的架构里，这些只能靠回标去修；在两段架构里，它们本来就该在精化阶段被拦下——判据修订只需要重跑精化，不需要重标原始数据。

二、「支持信号保留成连续属性、不压成硬规则」——这条直接对上我的 note 字段问题。

我此前承认 note 是个「杂物抽屉」，混了标注过程记录、与其它字段重复的信息、归并候选、数据质量问题四类，只能靠子串匹配。当时给的修法是「拆成三列」。

这篇给了一个更好的判据：不只是拆列的问题，而是每一类支持信号都该是它自己的带类型属性，让后面的阶段去学怎么用它，而不是我在标注时就替下游决定了权重。原文那句「保留了原始的高召回图」是关键——压成规则等于在不知道下游怎么用的时候先扔信息。

三、「确定性骨架 vs 推断交叉链」这个二分，我有对应物但现在没有标出来。

这篇

我的图谱

骨架（置信度 1.0，来自表） 作者配置的原始内容：语义点原文、评分要点原文、所属环节

推断交叉链（带分数，不确定） 标注者推断的：K 域 / S 域 / 通用行为名 / applies_to / comparator

现在这两类躺在同一个 CSV 的相邻列里，没有任何置信度标记。下游拿到会当成同一种东西。而实测数据支持这个区分是必要的——行为名的 κ 只有 0.55（两人对同一条要点起的名字四成对不上），而「这条要点原文是什么」是零分歧的。这两个不该有同等地位。

四、「用属性承载角色，而不是新开一个类型」——正好支持我手上一个悬而未决的选择。

这篇把呈现症状做成**诊断层节点加一个 presenting 属性**，而不是新建一个症状类型。

我手上对应的悬案是：**教练场景的技能（经理辅导下属）要不要单开一个域？** peer 会话提议的是标 `scope=coaching` 暂存、不进销售 S 域。这篇的选择支持属性路线——保持类型系统小，角色放元数据里。两个独立来源指向同一个做法，这条可以定了。

五、「诊断分四桶」这个手法我要用在语义点上。

「这个划分防止历史性或外部状态的编码被当成本次住院的活动诊断。」

对应到我：**语义点里混着「本次拜访要传递的知识」和「背景事实」**。如果不分桶，后者会被当成前者来算覆盖率和掌握度。这和「判否的语义点里 48% 其实是技能」是同一类问题的不同侧面——**都是因为不同性质的东西被放进了同一个容器。**

六、评测协议里有三个细节我要抄。

- 删边时连同逆边一起删，防止泄漏
- 候选限定同类型，且用 filtered 协议（排除该查询的其它真实尾实体）
- chance 由候选集大小算出来并报告——没有基线参照的 MRR 没有意义

还有那个 **non-obvious AUC**：当一个指标被平凡样本饱和时，造一个排除它们的版本，而不是继续报那个饱和的数。我在 LL eval 的覆盖性上正好有同构的问题——第 12、13 章是全书回顾章，反复提及前面各章的框架，它们就是那种「平凡的中心节点」，会把覆盖率顶高。修法已经在做（要求指出具体是哪一句），但这篇提示我还可以另报一个把回顾章排除掉的版本。

七、一个我必须警惕的形状：用草稿评估精化器。

这篇的第二条局限，对应到我这边是：**判官成绩是在我自己造的考题上测的**。两遍法漏判率 1/30，说的是「在我造的那 30 条错误上」。

如果我造错的方式和拆书真实的出错方式不同，这个 1/30 不能外推。这和前天记的那条偏差（对照组比真题信息密度略高，所以冤枉率偏低）是同一个方向，**两条要一起写进报告的指标说明**，而且按前天定下的规矩——**免责要挨着数字写，不能放到局限那一节。**

"Structured clinical data (diagnosis, medication, and procedure tables) record what happened to a patient but not the clinician's reasoning" 结构化的临床数据（诊断表、用药表、操作表）记录的是病人身上发生了什么，而不是临床医生的推理。

"A large language model can extract it as graph edges, but those inferred edges are exactly the ones with no table-level provenance" 大模型可以把它抽成图上的边，但那些被推断出来的边，恰恰就是没有表级溯源的那些边。

"the initial LLM-generated clinical knowledge graph should be treated as an evidence-scored draft rather than a final representation of patient state." 初次由大模型生成的临床知识图谱，应当被当作一份带证据分数的草稿，而不是病人状态的最终表示。

"the right way to obtain a reliable clinical knowledge graph is not a one-shot extractor but a refiner" 获得一份可靠临床知识图谱的正确方式，不是一个一次成型的抽取器，而是一个精化器。

"These scores are retained as continuous edge attributes rather than collapsed into hard-coded rules. This allows downstream models to learn how to use support signals while preserving the original high-recall graph." 这些分数被保留为连续的边属性，而不是被压缩成硬编码的规则。这让下游模型能学会怎么使用支持信号，同时保留了原始的高召回图。

"A global note summary broadcasts the same context across the graph, whereas entity grounding preserves which entities that context actually describes." 一份全局的叙述摘要把同一份上下文广播到整张图上，而实体接地保留了「这份上下文实际在描述哪些实体」。

"Diffuse, graph-level features add little to a structure-first world model; localised, edge- or entity-specific signal is what helps." 弥散的、图级别的特征，对于一个结构优先的世界模型贡献很小；局部的、边级或实体级的信号才是有用的那种。

"The undifferentiated batch-mask AUC is saturated by trivial patient-hub edges and is not the meaningful measure" 未加区分的批量掩码 AUC 被平凡的「病人中心边」饱和了，它不是有意义的度量。

"Reporting a single note-dependent model would overstate deployable accuracy, since a third of admissions have no note." 只报一个依赖叙述的模型会高估可部署的准确率，因为三分之一

的住院记录没有叙述。

"the leave-one-out evaluation measures recovery of held-out relations within an evidence-scored draft graph rather than correctness against an independently adjudicated clinical graph." 留一法评测度量的是「在一份带证据分数的草稿图内部恢复被留出的关系」，而不是「与一份独立裁定过的临床图谱对照的正确性」。

全文翻译

摘要

Clinical records contain rich evidence about patient state, but converting that evidence into reliable, structured knowledge graphs remains difficult because extraction errors, ontology mismatch, missing relations, and temporal ambiguity can propagate into downstream systems.

临床记录包含关于病人状态的丰富证据，但把这些证据转换成可靠的、结构化的知识图谱仍然困难，因为抽取错误、本体不匹配、关系缺失和时间上的歧义都会传播到下游系统里。

We propose a clinical knowledge graph construction and refinement framework that combines multi-agent relation proposal, ontology-aware normalization, deterministic evidence scoring, and JEPA-based latent refinement. Rather than treating a clinical knowledge graph as a static extraction artifact, we treat it as a predictive patient-state representation.

我们提出一个临床知识图谱的构建与精化框架，结合了多 agent 关系提议、本体感知的规范化、确定性证据打分，以及基于 JEPA 的隐空间精化。我们不把临床知识图谱当作一件静态的抽取产物，而把它当作一个可预测的病人状态表示。

对每一次住院，系统从结构化的 MIMIC-IV 记录和推断出的临床交叉链构建一张带证据分数的图，然后学习从观测到的图上下文中恢复被留出的临床关系。我们用无泄漏的留一法边恢复（MRR 与 Hits@k）和留出的批量掩码评测（AUC 与 MRR）来评估精化器。为了隔离出院小结上下文的贡献，我们比较了一个无叙述嵌入的配置与一个带叙述的配置——后者只把真实的出院小结表示注入到那些在叙述里有落点的实体上。在相同的队列与评测协议下，实体接地的叙述注入把整体留一法 MRR 提升了 31%（相对）。

1. 引言：表里记的是「发生了什么」，不是「为什么」

（那个 β 阻滞剂与胸痛的例子、以及「推断边恰恰没有表级溯源」的论证见「核心内容」。）

We take the position that the right way to obtain a reliable clinical knowledge graph is not a one-shot extractor but a refiner: a model that, given an already-drafted, evidence-scored graph, predicts which edges belong.

我们持这样的立场：获得一份可靠临床知识图谱的正确方式，不是一个一次成型的抽取器，而是一个精化器——一个模型，给它一份已经画好的、带证据分数的图，它来预测哪些边是该有的。

我们把它实例化为一个 **Clinical Graph-JEPA 世界模型**：一个由掩码隐变量预测训练出来的自监督图编码器，配一个轻量的读出头来恢复被留下的边。模型支持两种输入配置：选项 A 是**无叙述的**，只依赖合并后的带证据分数的图；选项 B 在同一张图上增补局部化到「叙述接地实体」的 Clinical-ModernBERT 表示。

This distinction preserves a note-independent deployment path while allowing us to quantify the contribution of note context. The results further show that injection strategy is important: a diffuse admission-level note vector lands at the no-note level, whereas localizing the same representation to note-grounded entities substantially improves inferred-edge recovery.

这个区分保留了一条不依赖叙述的部署路径，同时让我们能量化叙述上下文的贡献。结果进一步表明注入策略是重要的：一个弥散的、住院级别的叙述向量落在「没有叙述」的水平上，而把同一个表示局部化到叙述接地的实体上，则显著改善了推断边的恢复。

四条贡献：（1）一个合并的、带证据分数的临床图构建，把确定性的 MIMIC-IV 骨架与大模型推断出的关系、以及一个**每边 14 信号**的分数融合起来。（2）一个精化这些草稿的 Clinical Graph-JEPA 世界模型，用**无泄漏的留一法边恢复协议**评测。（3）两个部署选项。（4）一项实证发现：**真实的出院小结信息，在被局部注入到它所接地的实体上时最有用**，把选项 B 相对选项 A 的整体留一法 MRR 从 0.364 提到 0.477。

2. 相关工作

临床图谱抽取。以往的临床图谱系统通常把图构建分解成实体识别、实体规范化、关系抽取、以及图式或证据校验。近期基于大模型和多 agent 的方法进一步细分这些阶段以提高覆盖、减少实体识别与关系推理之间的混淆。

However, these methods generally treat the extracted graph as the final representation consumed by downstream systems. Such a graph may combine directly observed structural facts with uncertain text-inferred relations that are incomplete, weakly supported, or incorrectly linked. Our work separates graph construction from graph refinement.

然而，这些方法通常把抽取出来的图当作下游系统消费的最终表示。这样一张图可能把直接观测到的结构性事实，与不完整、支持薄弱或链接错误的、不确定的文本推断关系混在一起。我们的工作把图构建与图精化分开。

自监督与世界模型。JEPA 和 BYOL 式的隐变量预测，通过在 **EMA 目标 + 停止梯度**下预测被掩码的隐变量来学习表示，**无需负例即可避免对比坍塌**。我们把这个目标适配到图上作为精化器的预训练阶段，得到一个共享编码器，我们把它当作一个关于临床状态的世界模型。

知识图谱补全。DistMult 这类双线性打分函数提供了高效的边恢复读出。We apply one over the frozen world-model encoder, trained with an InfoNCE objective and type-matched negative sampling, so that recovery quality reflects the pre-trained representation rather than a jointly-tuned decoder.

（我们把它用在冻结的世界模型编码器之上，以 InfoNCE 目标和同类型负采样训练，从而使恢复质量反映的是预训练出来的表示，而不是一个被联合调过的解码器。）

临床语言模型。 Our contribution is not the note encoder but where its output is injected into the graph.（我们的贡献不是叙述编码器本身，而是它的输出被注入到图的什么位置。）

3. 方法：把临床图谱当作可预测的世界模型

我们把临床知识图谱的精华表述为一个在结构化病人状态记忆之上的世界建模问题。**观测**是一条结构化的 MIMIC-IV 住院记录连同其忠于源的临床叙述，**状态**是一张带类型的临床知识图谱，**修订动作**对应于保留、复核、剪除或提议关系。

The graph acts as an externalized patient-state representation that organizes diagnoses, medications, procedures, microbiology, and admission context into an auditable structure. Our system does not make autonomous clinical decisions; it improves the structured representation used by downstream retrieval and decision-support systems.

这张图充当一个外化的病人状态表示，把诊断、用药、操作、微生物和住院上下文组织成一个可审计的结构。我们的系统不做自主的临床决策；它改进的是下游检索与决策支持系统所使用的那个结构化表示。

（3.1 合并图、3.2 世界模型、3.3 两个部署选项的细节见「核心内容」。）

4. 结果

（数据与队列、评测协议、主结果表、叙述位置消融、上下文分析的完整数值见「核心内容」。）

关于协议性质：The evaluation is explicitly of a refiner: it improves an already-constructed draft and presupposes the consolidated graph as context, not a cold-start predictor.（**这个评测明确是针对精化器的：它改进的是一份已经构建好的草稿，并预设了合并图作为上下文，而不是一个冷启动预测器。**）

关于选项 A 的独立价值：Option A stays well above chance on every relation, which makes it a viable standalone configuration and the fallback inside Option B for note-less admissions.（**选项 A 在每一种关系上都明显高于随机水平，这使它成为一个可行的独立配置，同时也是选项 B 内部针对无叙述住院记录的兜底。**）

关于叙述位置：Isolating the note feature on identical data confirms that where the note is placed is decisive. A diffuse global note lands at the no-note level, while entity-grounding delivers the gain — where the note is placed is what matters.（**在相同数据上隔离叙述特征，证实了叙述被放在哪里是决定性的。一个弥散的全局叙述落在无叙述的水平上，而实体接地带来了增益——重要的是叙述被放在哪里。**）

关于恢复来自哪里：This indicates the model exploits the free, certain structure first and the inferred relations second — consistent with the refiner framing.（**这表明模型先利用免费的、确定的**

结构，其次才是推断出来的关系——这与精化器这个定位是一致的。)

4.6 局限（三条完整内容见「核心内容」）：The model should therefore be viewed as a graph-refinement component for research and decision-support workflows, not as an autonomous clinical decision-maker.（因此这个模型应被视为研究与决策支持流程中的一个图精化组件，而不是一个自主的临床决策者。）

5. 讨论

为什么实体接地有效。 The note and the graph carry overlapping information—the entities were extracted from the note.（叙述和图携带的是重叠的信息——那些实体本来就是从叙述里抽出来的。）

Placing the note on the specific entities it grounds turns it into a localised prior that distinguishes note-discussed entities from purely structural ones, which is exactly the distinction the inferred relations depend on.

把叙述放到它所接地的那些具体实体上，就把它变成了一个局部先验，用来区分「叙述讨论过的实体」与「纯结构性的实体」——而这恰恰是那些推断关系所依赖的区分。

这与我们观察到的另外两个结果一致：把每条边的证据分数直接喂进编码器同样没有帮助；一个单独的全局 NOTE 节点也没有超出无叙述的水平。

为什么要两个选项。（理由见「核心内容」。）This framing supports deployment in settings with or without note access while providing a controlled estimate of the note contribution.（这个框架既支持在有或没有叙述访问权的场景下部署，又提供了一个受控的叙述贡献估计。）

6. 结论

Clinical Graph-JEPA treats an LLM-drafted clinical knowledge graph as an evidence-scored representation to be refined rather than accepted as final.

Clinical Graph-JEPA 把大模型起草的临床知识图谱当作一个有待精化的、带证据分数的表示，而不是当作可以直接接受的最终结果。

未来工作将针对**独立由临床医生标注的关系**、以及跨外部机构与病人群体来评估精化器。其它方向包括**强制病人不相交与时间上分离的评测**、发展经过校准的分级边修订策略、以及评估下游检索与决策支持的效用。

参考链接

- [arXiv 2608.22583](#) — 本文预印本
- [MIMIC-IV 数据集论文](#) — 本文全部图谱的唯一来源；也是作者自述第一条局限（单一医院系统）的出处
- [JEPA \(LeCun 团队图像版\)](#) — 在表示空间预测被掩码部分的隐变量，本文把它从图像搬到图

- [A Path Towards Autonomous Machine Intelligence](#) — LeCun 的世界模型纲领，本文「把图当作世界模型」这个提法的思想来源
- [BYOL](#) — EMA 目标 + 停止梯度，**无需负例避免对比坍塌**的那套机制
- [Graph-level JEPA](#) — 图级 JEPA 的原始子图预测流水线；本文**没有直接沿用**，改成了掩码节点
- [Clinical-ModernBERT](#) — 本文选项 B 用的叙述编码器（768 维均值池化）
- [Hetionet](#) — 整合多种生物医学关系的异构网络，提供本文证据分数里的治疗与疾病相似信号
- [DistMult](#) — 冻结世界模型之上的边恢复读出头
- [InfoNCE / 对比预测编码](#) — 阶段二训练读出头所用的目标