

部分知识下的候选实体筛选 Constrained Entity Selection under Partial Knowledge for LLM-Based KGQA

源文档: arXiv 2608.24824v1 (2026-08-25 提交), 作者 Emanuel Kitzelmann (Aalen 应用科技大学)。正式版收录于 KI 2026: Advances in Artificial Intelligence, LNCS vol 16830, Springer。全文 7 页正文 + 参考文献。本文的「全文翻译」一节按原文小节推进, 覆盖摘要、引言、方法 (§2)、实验 (§3)、相关工作 (§4) 与结论 (§5) 的全部正文段落, 不含参考文献条目。

核心内容

Q: 这篇论文要解决什么问题? A: 让大模型基于知识图谱回答问题 (KGQA), 今天有两条路, 各有各的病。一条是把问题翻译成 SPARQL 查询去执行——答案精确、可验证, 但真实图谱的 schema 复杂又残缺, 查询经常写不对。另一条是让模型直接在图上边走边推理——鲁棒, 但没有任何形式化保证, 会编。作者不选边站, 而是加**第三样东西**: 在上游产出候选答案之后, 再挂一层轻量的事后校验。

Q: CES-PK 具体做了什么? A: 从问题里抽出若干条**必要条件** (不是完整的逻辑式, 只是必要条件), 拿去逐个检查候选答案。三类约束: 类型约束 $\text{type}(x, T)$ 、关系约束 $R(x, y)$ 、排除约束 $\neg R(x, y)$ 。只要某个候选**明确违反**了任一条约束, 就把它删掉; 没被明确违反的一律保留。

Q: 「三值语义」是什么, 为什么非要它不可? A: 约束求值的结果不是真/假两档, 而是三档: 满足 (sat)、违反 (viol)、**未知 (unk)**。原因是开放世界假设——图谱里的三元组都是真的, 但真的事实不一定都在图谱里。如果按两值来做, 「图里没有这条边」会被判成「假」, 于是正确答案会因为图谱缺边而被误删, 召回率直接掉。三值语义把「查不到」单独归为 unk, **只有在有显式违反证据时才拒绝**, 所以召回率一分不掉。

Q: 三类约束在系统里的分工是不是一样的? A: 完全不一样, 这是全文最实用的一条结论。排除约束 $\neg R(x, y)$ 是**唯一能产生 viol 的负向信号** (图里查到这条边就是违反), 它承担绝大部分过滤工作。关系约束 $R(x, y)$ 在开放世界下**永远产生不了违反** (查不到只能算 unk), 所以它不过滤, 只在被满足时提供**正向支持证据**。类型约束介于两者之间: 类型对不上就是 viol, 能稳定过滤。

Q: 支持分 (support) 怎么算, 有什么用? A: 取那些「有可能被满足」的约束子集 $C^+(q)$, 候选 x 的支持分 = 它满足的约束数 $\div |C^+(q)|$, 是个 0 到 1 的比例。它不参与过滤, 只用来排序和区分。实验里金标答案的平均支持分是 1.00, 非金标是 0.42 (Q1) 和 0.74 (Q2) ——**在过滤已经失效的地方, 支持分仍然能把对错分开**。

Q: 实验结论有多硬? A: 结论方向可信, 但强度要打折。在 Hetionet 生物医学图谱上, Q1 (哪些化合物治疗疾病 D) 精确率 0.66→0.70, 只涨 0.04; Q2 (哪些化合物治疗 D 但不引起副作用 S) 精确率 0.17→0.62, 涨 0.45。合计 0.41→0.66, 召回恒为 1.0。**但这是一个受控实验**: 候选集不是真的 LLM 生成的, 是作者从图里采金标答案再人工掺假答案造出来的; 而且因为方法只删有显式违反的候选, 作者干脆没模拟假阴性, 所以「召回不变」在这个设定下是设计保证而非实验发现。

背景补充 / 点评

Hetionet 是什么: 一个整合了 29 个公开数据源的生物医学异构知识图谱, 节点有化合物、疾病、基因、副作用等 11 类, 边有 24 类, 最有名的用途是药物重定位 (找已上市药的新适应症)。选它做实验有个便利: `treats` (治疗) 和 `causes` (引起副作用) 这两类边现成存在, 正好对应论文的关系约束和排除约束, Q2 那种「治 D 但不引起 S」的问题可以直接从图里构造。代码和实验产物在 <https://github.com/ekitzelmann/ces-pk>。

这篇在文献里的位置: 作者自己在相关工作里划得很清楚。有一支工作 (文献 9) 也用约束, 但用法是**约束 LLM 的解码过程**, 引导它生成格式良好的推理链——那是事前干预。本文是**事后校验**, 模型爱怎么生成怎么生成, 产出之后再查。作者还引了一条支撑性的结论 (文献 12): LLM 擅长生成候选解, 但**不擅长验证自己的候选解**。这是整篇论文的立论根基——既然验证不能交给模型自己, 那就交给一个符号层。

我的判断——洞察在哪: 真正有价值的不是 CES-PK 这个具体方法 (三类约束、一个比例分, 简单到有点单薄), 而是它把「验证」从「解析」里拆出来了。传统思路认为要验证就得先完整解析成可执行查询, 本文说不用: 完整解析很难, 但抽几条必要条件很容易, 而必要条件足够删掉一大批错答案。这是一次代价与收益的重新配平, 方向上是对的。

留白在哪: 三处。第一, **约束是怎么从问题里抽出来的, 全文没讲**——这一步交给谁做? 如果还是交给 LLM, 那验证层的可靠性就重新被模型的可靠性绑住了, 只是把风险挪了个位置。第二, 实验的候选集是人工造的, 端到端跑真实 LLM 会怎样完全未知。第三, 作者自己在局限里承认: **方法假设图谱事实全对**, 一旦图里有错误三元组, 那个错误的边会直接产生一个假的 viol, 把正确答案删掉——错误图谱下这套机制会从「保守」变成「有害」。

对我的启示: 这条思路可以直接搬到我做的东西上。我常年在做的一件事是让脚本/模型产出一个结论, 然后判断这个结论能不能信。这篇给的是一个可复用的形状——**不要试图重建完整的正确性, 只抽必要条件来做否定**。放到股票统计上就是: 与其试图验证「这个信号有效」(要完整重做一遍分析, 很贵), 不如列几条必要条件去否定它 (样本是否按日期配对? BH 校正后还剩几个? 零信号基准是多少?), 任何一条明确不成立就直接毙掉, 查不到的一律留着不下结论。这跟我记住的那条「观测不等于判断」是同一件事的两面: **查不到证据 ≠ 证据为假**, 把这两种情况混成一档, 结论就会整个反过来。

三值语义还有一个隐含的态度值得记: **它把「我不知道」显式建模成了一个值, 而不是让它掉进「假」里**。我的很多脚本没有这个档位——取数失败、字段缺失、样本不足, 最后都被静默折算成了某个默认值。8/25 那次 intraday build 部分失败仍然存盘退出 0, 就是这个病。

文中金句

"Such methods enable precise and verifiable answers, but remain brittle in practice as generating correct queries over complex schemas is challenging." 这类方法（语义解析成可执行查询）能给出精确且可验证的答案，但实践中很脆弱——在复杂 schema 上生成正确的查询本身就很困难。

"This strategy relies solely on explicit violations and is therefore robust under incomplete knowledge." 这个策略只依据显式的违反，因此在知识不完整的条件下是鲁棒的。

"Relation constraints (C2) do not lead to violations under OWA but contribute to verification by providing support if satisfied." 关系约束在开放世界假设下不会导致违反，但在被满足时能提供支持，从而贡献于验证。

"LLMs are effective at generating solution candidates but unreliable at verifying them." 大模型擅长生成候选解，却不擅长验证它们。

全文翻译

覆盖范围：摘要、§1 引言、§2 方法（问题设定、图谱假设、约束、三值语义、过滤与支持）、§3 实验（设置、结果、讨论与局限）、§4 相关工作、§5 结论。参考文献条目不译。

摘要 Abstract

Knowledge graph question answering with LLMs is typically approached either by semantic parsing into executable queries, which is precise but brittle in practice due to complex schemas or incompleteness of real-world KGs, or by LLM reasoning over the KG, which is more robust but lacks formal guarantees. We propose a complementary post-hoc verification layer that uses lightweight necessary constraints extracted from the question to filter and verify candidate answers.

用大模型做知识图谱问答，通常走两条路之一：一是语义解析成可执行查询，精确，但由于真实图谱 schema 复杂或本身不完整，实践中很脆弱；二是让大模型在图谱上推理，更鲁棒，但缺少形式化保证。我们提出一个互补的**事后校验层**，用从问题中抽取的轻量必要条件来过滤并验证候选答案。

To avoid false rejections under the open-world assumption, constraints are evaluated under a three-valued semantics distinguishing satisfied, violated, and unknown. Instantiated over the Hetionet biomedical knowledge graph, our approach improves precision while preserving recall.

为了避免开放世界假设下的误拒，约束在三值语义下求值，区分**满足**、**违反**、**未知**三种状态。我们在 Hetionet 生物医学知识图谱上做了实例化，方法在保持召回不变的前提下提升了精确率。

引言：两条既有路线各自的病 Introduction

KGQA with LLMs is approached in different ways. In semantic parsing approaches, an LLM translates natural language questions into executable logical forms. Such methods enable precise and verifiable answers, but remain brittle in practice as generating correct queries over complex schemas is challenging. They typically involve fine-tuning, require complete KGs and leave LLM knowledge unexploited that could help to reason more robustly over incomplete KGs.

大模型做 KGQA 有几种不同路线。在语义解析类方法中，大模型把自然语言问题翻译成可执行的逻辑形式。这类方法能给出精确且可验证的答案，但实践中很脆弱——在复杂 schema 上生成正确的查询本身就很难。它们通常需要微调，要求图谱是完整的，而且**没有利用起大模型自身的知识**——那些知识本可以帮助在不完整图谱上做更鲁棒的推理。

Another line of work uses LLMs for reasoning over knowledge graphs and generating answers. Relevant triples are retrieved from the KG by entity linking which are then verbalized and injected as additional context into the prompt. Think-on-Graph allows LLMs to iteratively explore graph neighborhoods and construct reasoning paths. These methods typically work without additional training and are more robust but can produce hallucinated or non-grounded answers. Moreover, incomplete KGs remain challenging.

另一条线让大模型在图谱上推理并直接生成答案。做法是通过实体链接从图谱中检索相关三元组，把它们语言化后作为额外上下文注入 prompt。Think-on-Graph 则允许大模型迭代地探索图的邻域、构造推理路径。这类方法通常不需要额外训练，也更鲁棒，但**会产生幻觉或无依据的答案**。此外，不完整的图谱依然是难点。

方法一：问题设定与图谱假设 Problem Setting and Assumptions

Given a question q and a candidate answer set $C(q)$, compute a subset $C^*(q) \subseteq C(q)$ such that no retained candidate violates any constraint under incomplete knowledge, and associate remaining answers in $C^*(q)$ with support scores reflecting the degree of constraint satisfaction.

给定问题 q 和候选答案集合 $C(q)$ ，计算一个子集 $C^*(q) \subseteq C(q)$ ，使得在知识不完整的条件下，保留下来的候选**都不违反任何约束**；并给 $C^*(q)$ 中剩下的答案配一个**支持分**，反映其约束满足的程度。

We assume that the KG is factually correct but may be incomplete, i.e., all represented triples are true, while some true facts may be missing (open-world assumption). Furthermore, all candidate entities are assumed to be present in the graph.

我们假设图谱在事实上是正确的、但可能不完整——即图中出现的三元组都为真，但有些为真的事实可能缺失（开放世界假设）。此外，假设所有候选实体都已存在于图中。

方法二：三类约束与三值语义 Constraints and Three-Valued Semantics

We consider lightweight necessary constraints extracted from the question with respect to a known schema (this set of constraint types can be extended, e.g., to capture joins or cardinality constraints): Type constraints $\text{type}(x, T)$; Relation constraints $R(x, y)$; Exclusion constraints $\neg R(x, y)$.

我们考虑依据已知 schema 从问题中抽取的**轻量必要条件**（这组约束类型可以扩展，例如加入 join 或基数约束）：类型约束 $\text{type}(x, T)$ ；关系约束 $R(x, y)$ ；排除约束 $\neg R(x, y)$ 。

Due to incompleteness, constraints $c(x)$ for candidate answers x over graph G are evaluated under a three-valued semantics: $\llbracket c(x) \rrbracket_G \in \{\text{sat}, \text{viol}, \text{unk}\}$. Relation constraints: $\llbracket R(x, y) \rrbracket = \text{sat}$ if $(x, R, y) \in E$, unk otherwise. Exclusion constraints: $\llbracket \neg R(x, y) \rrbracket = \text{viol}$ if $(x, R, y) \in E$, unk otherwise. Type constraints: $\llbracket \text{type}(x, T) \rrbracket = \text{sat}$ if $\text{type}(x) = T$, viol otherwise.

由于图谱不完整，候选答案 x 在图 G 上的约束 $c(x)$ 在**三值语义**下求值：结果属于 $\{\text{sat}, \text{viol}, \text{unk}\}$ 。

- **关系约束**：若边 (x, R, y) 在图中，为 **sat**；否则为 **unk**（注意：不是 **viol**）。
- **排除约束**：若边 (x, R, y) 在图中，为 **viol**；否则为 **unk**。
- **类型约束**：若 x 的类型等于 T ，为 **sat**；否则为 **viol**。

（这张表本身就是全文的关键：**关系约束永远产生不了 viol**，**排除约束永远产生不了 sat**。前者只能提供正向证据，后者只能提供过滤能力，两者分工完全不重叠。）

方法三：过滤与支持 Filtering and Support

We retain only candidates that do not violate any constraint: $C^*(q) = \{x \in C(q) \mid \forall c \in C(q): \llbracket c(x) \rrbracket_G \neq \text{viol}\}$. This strategy relies solely on explicit violations and is therefore robust under incomplete knowledge.

我们只保留不违反任何约束的候选： $C^*(q) = \{x \in C(q) \mid \text{对所有约束 } c, \llbracket c(x) \rrbracket \neq \text{viol}\}$ 。这个策略**只依据显式的违反**，因此在知识不完整的条件下是鲁棒的。

Further, let $C^+(q) = \{c \in C(q) \mid \text{sat} \in \text{range}(c)\}$ denote the subset of constraints that can provide positive evidence by being satisfied. The support of a candidate x is defined as the fraction of constraints in $C^+(q)$ that evaluate to **sat**.

此外，令 $C^+(q)$ 表示那些**有可能通过被满足来提供正向证据**的约束子集（即值域里包含 **sat** 的那些）。候选 x 的支持分定义为： $C^+(q)$ 中求值为 **sat** 的约束所占的比例。

实验设置：为什么是受控实验 Experimental Setup

We evaluate the proposed constraint-based verification approach on entity-centric KGQA tasks using the Hetionet biomedical knowledge graph. This evaluation is designed as a controlled study to isolate the effect of constraint-based verification independently of upstream candidate generation. Therefore, we simulate answer generation by sampling queries and gold answers from the Hetionet KG and then generate candidate answers from gold answers by systematically adding incorrect answers (false positives). Since our method only removes candidates with explicit constraint violations, recall is unaffected and we do not simulate false negatives.

我们在 Hetionet 生物学知识图谱上，针对以实体为中心的 KGQA 任务评估这套基于约束的校验方法。[这个评估被设计成一项受控研究](#)，目的是把「约束校验的效果」从「上游候选生成」中隔离出来。因此我们模拟答案生成：从 Hetionet 中采样问题与金标答案，再在金标答案基础上系统性地掺入错误答案（假阳性）来构造候选集。由于我们的方法只删除有显式约束违反的候选，召回率不受影响，所以我们没有模拟假阴性。

We consider two query types that fit our constraints: Q1: Which compounds treat disease D? Q2: Which compounds treat disease D but do not cause side effect S? Constraints include type (C1), relation (C2), and exclusion (C3) constraints. Since all gold answers are included in the candidate sets, recall remains constant at 1.0. In the present experiments, $C^+(q)$ consists of the type and positive relation constraints, such that $|C^+(q)| = 2$ for both Q1 and Q2.

我们考虑两类契合上述约束的问题：**Q1**「哪些化合物治疗疾病 D？」；**Q2**「哪些化合物治疗疾病 D、但不引起副作用 S？」。约束包括类型（C1）、关系（C2）和排除（C3）三类。由于所有金标答案都被包含在候选集中，召回率恒定为 1.0。在本实验里， $C^+(q)$ 由类型约束和正向关系约束组成，因此 Q1 和 Q2 的 $|C^+(q)|$ 都等于 2。

实验结果：过滤靠排除约束，区分靠支持分 Results

表 1：过滤与支持校验的表现

问题	过滤前精确率	过滤后精确率	Δ	召回	金标支持分	非金标支持分
Q1	0.66	0.70	+0.04	1.00	1.00	0.42
Q2	0.17	0.62	+0.45	1.00	1.00	0.74

For Q1, constraint-based filtering yields a modest precision improvement (+0.04) due to removed type-inconsistent candidates. For Q2, we achieve a substantial precision increase from 0.17 to 0.62 (+0.45) due to exclusion constraints that eliminate candidates violating the negated condition. Overall, precision improves from 0.41 to 0.66 while recall remains unaffected.

对 Q1，基于约束的过滤只带来温和的精确率提升（+0.04），来源是删掉了类型不一致的候选。对 Q2，精确率从 0.17 大幅提升到 0.62（+0.45），来源是[排除约束](#)干掉了那些违反否定条件的候选。整体上精确率从

0.41 提升到 0.66，而召回率不受影响。

The results show distinct roles of constraint types. Type constraints (C1) provide consistent filtering signals, while exclusion constraints (C3) are the primary driver of filtering in Q2. Relation constraints (C2) do not lead to violations under OWA but contribute to verification by providing support if satisfied. Support scores provide additional discrimination between candidates. Gold answers achieve a mean support of 1.0 compared to 0.42 (Q1) and 0.74 (Q2) for non-gold candidates. This indicates that positive constraints contribute useful verification signals even when filtering is limited.

结果显示三类约束的角色截然不同。类型约束（C1）提供稳定的过滤信号，而排除约束（C3）是 Q2 中过滤的主要驱动力。关系约束（C2）在开放世界假设下不会导致违反，但在被满足时能提供支持、从而贡献于验证。**支持分为候选之间提供了额外的区分度**：金标答案的平均支持分为 1.0，而非金标候选是 0.42（Q1）和 0.74（Q2）。这说明——**即使过滤能力有限，正向约束仍然贡献了有用的验证信号。**

表 2：模拟图谱不完整（随机删除 10% 相关边）的影响

问题	过滤后精确率	召回	金标支持分	非金标支持分
Q1	0.70	1.00	0.95	0.42
Q2	0.53	1.00	0.95	0.69

To further analyze the impact of KG incompleteness, in a second experiment we randomly removed 10% of the relevant treats and causes edges after constructing the gold answer sets. Precision and support scores decrease, as missing edges reduce the number of detectable violations and verifications, while the method continues to preserve recall.

为进一步分析图谱不完整性的影响，第二个实验在构造完全金标答案集之后，随机删除了 10% 的相关 `treats` 和 `causes` 边。精确率和支持分都下降了——因为缺失的边减少了**可检测到的违反与验证的数量**——但方法**仍然完整保住了召回**。

（读这两张表要注意方向：图谱越残缺，这套方法越接近「什么都不做」，但它**不会掉到「做坏事」那一侧**。这正是三值语义的设计目的：退化路径是失效，不是有害。）

讨论与局限 Discussion and Limitations

The results show that lightweight constraints improve precision without requiring full semantic parsing. Negative constraints provide filtering signals when explicit violations are present, while positive constraints contribute evidence for verification. The three-valued semantics preserves recall under incomplete knowledge.

结果表明，轻量约束能在**不需要完整语义解析**的前提下提升精确率。负向约束在存在显式违反时提供过滤信号，正向约束则为验证贡献证据。三值语义在知识不完整的条件下保住了召回。

The evaluation is based on controlled candidate sets rather than capturing end-to-end KGQA performance. The KG is assumed to be factually correct but incomplete. In the presence of incorrect triples or missing entities, constraint evaluation may lead to false rejections and support.

本评估基于受控的候选集，并未刻画端到端的 KGQA 表现。图谱被假设为事实正确但不完整。**若图谱中存在错误的三元组或缺失的实体，约束求值可能导致误拒和错误的支持分。**

相关工作 Related Work

To address the issue of unreliable LLM-based reasoning, prior work introduces constraints constructed from the KG that guide the LLM decoding to generate well-formed reasoning chains. In contrast, the method proposed in this paper uses constraints to post-hoc verify answer candidates. Elsewhere, integration of link prediction into LLM-based reasoning over KGs is suggested to address incomplete KGs. Our work is also related to research on generation followed by verification, where it is shown that LLMs are effective at generating solution candidates but unreliable at verifying them.

为应对大模型推理不可靠的问题，已有工作从图谱中构造约束，用来**引导大模型的解码过程**、生成格式良好的推理链。与之相对，本文方法用约束来**事后校验答案候选**。另有工作建议把链接预测集成进大模型的图谱推理中，以应对图谱不完整。我们的工作还与「先生成后验证」这一支研究相关——那支研究表明，**大模型擅长生成候选解，却不擅长验证它们**。

结论 Conclusions

We introduced Constrained Entity Selection under Partial Knowledge (CES-PK), a framework for post-hoc verification of candidate answers in knowledge graph question answering. Instead of relying on full semantic parsing or unconstrained neural generation, our approach uses lightweight necessary constraints together with a three-valued semantics to filter invalid candidates and provide symbolic support for valid ones under incomplete knowledge.

我们提出了**部分知识下的受约束实体筛选 (CES-PK)**，一个用于知识图谱问答中候选答案事后校验的框架。我们的方法不依赖完整的语义解析，也不依赖无约束的神经生成，而是用轻量必要条件配合三值语义，在知识不完整的条件下过滤无效候选，并为有效候选提供符号化的支持证据。

Our experimental results demonstrate that constraint-based verification can substantially improve precision while preserving recall in a controlled setting. In particular, we show that exclusion constraints provide strong negative signals for filtering, whereas positive relation constraints contribute to verification through support.

实验结果表明，在受控设定下，基于约束的校验能在保持召回的同时显著提升精确率。特别地，我们表明**排除约束提供强的负向过滤信号，而正向关系约束通过支持分贡献于验证**。

Future work includes integrating the proposed verification layer into full KGQA pipelines, studying robustness under incomplete and noisy graphs, and extending constraint extraction to more complex query types and schemas.

未来工作包括：把这个校验层集成进完整的 KGQA 流水线；研究在不完整且有噪声的图谱下的鲁棒性；以及把约束抽取扩展到更复杂的问题类型和 schema。

参考链接

- [CES-PK 代码与实验产物](#) — 作者公开的实现与实验脚本
- [arXiv 2608.24824](#) — 本文预印本
- [Hetionet](#) — 整合 29 个数据源的生物学异构知识图谱，本文实验的图谱底座
- [Think-on-Graph](#) — 让大模型迭代探索图邻域、构造推理路径的代表工作，本文在相关工作中作为「LLM 在图上推理」路线的例子引用