

知识存得进权重，却取不出来 A Storage - Retrieval Gap in Parametric Knowledge Graph Memory

源文档：Martino M. L. Pulici、Cuong Xuan Chu、Evgeny Kharlamov、Volker Tresp（博世人工智能中心 / 慕尼黑大学 / 奥斯陆大学）。发表于 [SKGi 2026](#) (Scaling Knowledge Graphs for Industry Workshop)，与 SEMANTiCS'26 第 22 届语义系统国际会议同期，2026 年 9 月 15 - 17 日，比利时根特。本文的「全文翻译」一节按原文小节推进，覆盖摘要、§1 引言、§2 方法、§3 实验设置、§4 实验（存储 / 检索 / 组合）、§5 讨论（机制解释与成本部署）、§6 相关工作与 §7 结论。图 2 的坐标细节、附录 A（SVD 距离算法）与附录 B（指令模板）、参考文献条目不译。

核心内容

Q：这篇论文在试什么东西？ A：现在把知识图谱接进大模型的标准做法叫 graph RAG——查询来了，检索一个相关子图，序列化成本文塞进 prompt，让模型从上下文里读出答案。这个做法有效，但有两笔**按使用次数增长**的开销：每次查询都要花 token（子图占上下文预算），每次查询都要把**原始子图运到推理发生的地方**（图谱里若是敏感或专有的工程知识，这就是暴露）。作者试的是把这笔钱**一次性离线付掉**：把图谱按实体逐个编译成一组 LoRA adapter，一个实体一个。查询时不塞文本，而是**注入权重**，上下文 token 成本为零。

Q：LoRA adapter 是什么？为什么用它？ A：LoRA（低秩适配）是给大模型做微调的一种轻量办法：不动原模型的权重，只额外学一个很小的低秩扰动矩阵 ΔW ，用的时候加上去。它小、可插拔、可以为每个实体单独训一个然后攒成一个「库」。这里的设想是**每个 adapter 就是一个实体的子图被压进权重后的样子**。

Q：整套流程具体怎么走？ A：离线阶段——取每个锚实体的 k 跳邻域子图 S_i ，用一个模板把它**语言化**成文本 $v(S_i)$ （一条三元组一个陈述句），拿这段文本在冻结的基座模型上微调出一个 adapter $\Delta \theta_i$ ，攒成库 $\mathcal{B}$ 。在线阶段——来了问题 q ，(a) 从库里选一个或多个 adapter，(b) 组成 $\theta = \theta_0 + \sum_i \lambda_i \Delta \theta_i$ ，(c) 在上下文里**没有任何子图文本**的情况下解码出答案。

Q：论文的三个问题和三个答案分别是什么？ A：作者把问题拆得很干净：① 子图 adapter 到底把知识存进权重了吗（还是只学会了「文本在场时怎么用它」）？② 能不能从查询找到对的那个 adapter？③ 多跳问题能不能靠合并多个 adapter 解决？

结论**分离得非常干净**：①**能存**，而且泛化到没训练过的问题；②**取不出来**，按相似度检索是随机水平；③**做不了**，而且和②是同一个坑。

Q：「存得进」有多硬？ A：基座模型（Qwen3.5-2B）对这批电影**几乎全盲**——闭卷只答对 1%，150 个实体里 147 个得零分。在这个底子上，单值关系的精确匹配（EM）提升 **+0.243**（95% 置信区间 [+0.174, +0.319]， $p < 0.001$ ）。而且做了三个对照：**只有自己那个 adapter 有用**（比基座 +0.283）；**别的实体的**

adapter 效果恰好等于基座（增益 0.000）；随机初始化的未训练 adapter 反而更差（-0.017）。第三个对照特别重要——它证明LoRA 这个结构本身什么也没贡献，全部收益来自在该实体数据上的梯度更新。

Q：「取不出来」是什么意思？这是本文的核心发现。 A：查询到来时手上没有子图，所以必须只凭问题文本去库里挑 adapter。作者试了两种：按问题的句向量相似度挑，按 ΔW 的权重空间几何距离挑。两种都恰好等于基座，增益 0.000， $p=1.000$ ，和随机挑没有区别；而 oracle（直接给对的那个）是 +0.283。

关键在于失败的原因不是检索器找错了近邻。 句向量找到的近邻是语义上真正相关的电影（同一个导演、同一类型），每个实体的最近邻就是它自己。失败在于——一个语义上再贴切的邻居，它的 adapter 里也没有你要的那个答案。知识是局部存储的，不迁移。

Q：权重几何和语义有相关性吗？ A：有，但没用。 ΔW 的 Frobenius 距离与子图语义距离的 Spearman $\rho = +0.329$ （前 8 层是 +0.352），两个零假设对照（打乱实体标签、按列洗牌破坏低秩结构）都在 $|\rho| \leq 0.157$ 以下，所以这个相关是真的。但它不转化为功能上的可检索性—— ΔW 检索的表现和句向量、和随机完全一样。作者把这个叫几何—功能解离：权重几何编码了「哪些实体相似」，但没编码「哪个 adapter 答得了这个问题」。

这两件事是真正不同的关系： 实体相似性 $\neq$ 答案包含性。

Q：成本上到底划不划算？ A：这张账要分两头看。上下文 token：graph RAG 每次查询 60 个 token，参数化方案是 0——这一项是定义性的胜利。字节：graph RAG 每次运 188 字节，参数化方案是一次性 10.4 MiB，比值约 58,000 倍。所以只有当一个实体被查询得足够频繁、能把 adapter 摊销掉，或者瓶颈本来就是上下文预算而不是存储，才划算。作者自己把这个比值当成对可扩展性的诚实约束：一百万个实体的库要占约 10 TiB，所以这套方案适合稳定、高频查询的子图，不适合网络规模或频繁变动的图谱。

背景补充 / 点评

MetaQA 是什么： 一个电影领域的知识图谱问答基准，实体级问答。作者在这里做了一处值得注意的数据清洗：MetaQA 没有唯一影片标识符，只能拿片名当实体键，而不同影片可能重名——如果直接按片名建 adapter，会把两部电影合成一个、拿互相矛盾的标签去训练。所以他们只保留「片名唯一对应一个上映年份」的影片，得到 150 个干净实体。作者顺带记了一个观察：用重名片名建出来的 adapter 连自己的训练答案都复现不了，而干净的能可靠复现。这条附带发现本身就有价值——它说明这类参数化记忆对实体键的唯一性极其敏感。

这篇在文献里的位置： 已有一支工作把检索到的文档编码进参数而不是上下文——Parametric RAG（每个文档一个 adapter，推理时平均）、DyPRAG（训一个超网络把文档实时映射成 adapter）、Poly-PRAG（学一组共享的 adapter 基 + 按文档路由）。这些系统都隐含假设了「文档编码出来的 adapter 携带该文档的知识」。本文的贡献是把这个假设直接拿去测——用闭卷评测隔离出真正驻留在权重里的那部分，用「自己的 adapter vs 别人的 adapter」的对照确认识是实体特异的。

我的判断——这篇最值钱的地方： 不是它提出的方案，而是它把一个大家默认成立的前提拆成了两半，并且证明这两半会分离。「知识在里面」和「知识取得出来」被当成一件事很久了；这篇用一个干净的实验把它们劈

开，然后说：前一半成立，后一半不成立。

更进一步，它还识别出**失败的层次**。检索失败通常有三种解释：检索器不行、表示不行、任务本身不可解。作者逐个排除了前两个——句向量找到的近邻语义上完全正确（不是检索器不行）， ΔW 几何与语义显著相关（不是表示没有结构）——最后落到第三个：「相似」和「含有答案」在这个任务上根本是两种关系。这个排除过程比结论本身更值得学。

作者的诚实值得单独记。这篇有好几处主动收窄自己的主张：

- 60 个 token 的节省，他明说「应当读作**下限而非标题数字**」——因为 MetaQA 的子图本来就稀疏（六七个单行字段），工业图谱的稠密子图会大得多。
- 零 token 只声称**上下文成本的节省**，不声称**端到端加速**——因为注入和切换 adapter 本身也是开销，而他们**没有测过延迟和能耗**。
- 数据不外泄这件事，他框成**「减少原始上下文暴露」而不是「抗泄漏」**——因为他自己的正面结果恰恰证明了事实可以从权重里被恢复出来，**adapter 本身就是一个潜在的泄漏面**，而他们没测过抗提取。
- 「错误 adapter 的 $p=1.000$ 」他专门说**不能读作等价性证据**——因为基座在闭卷上已经触底（0.017），注入无关 adapter 不足以翻转任何一个答案，所以这个对照**没有检出小正效应的功效**。承载结论的是自己 adapter 那个对照。
- 语言化格式的消融是**空结果**，而且用的是另一个 120 实体的库，所以「视作提示性而非结论性」。

留白在哪：三处。第一，**组合实验根本没做成**——MetaQA 的两跳问题问的是中间实体（「哪些电影和这部片子是同一个导演」），答案既不在要合并的那两个子图里、也不在把两个子图同时放进上下文里，所以**连 oracle 都触底**，实验无法隔离出组合效应。作者选择不报结果，只把问题说清楚，这是对的，但也意味着第三个问题**完全没有证据**。第二，单基准、单模型、单领域（电影）、workshop 规模，而且**问答对是模型生成的**。第三，多值关系（标签、演员表）的 EM 恒为 0，是评测指标的产物不是学习失败（任意匹配 0.854、集合召回 0.793），但**集合值的参数化记忆整个留给了未来工作**。

对我的启示：这篇给的是一个我可以直接复用的**诊断形状**——把「有没有」和「找不找得到」分开测。

这跟我 8/27 读的那篇 CES-PK 是同一件事的两面。那篇说「图里查不到 $\neq$ 事实为假」，这篇说「权重里存着 $\neq$ 能被取到」。两篇都在同一个位置上做区分：**存在性与可达性不是一回事**，把它们混成一档，结论方向会整个反过来。

放到我自己的东西上，最直接的对应是**受控词表和学员画像**。我们在 user_profile 里做的判重、消解、返回策略，本质上都在回答「这条知识在不在库里」；但真正决定教练能不能用上的是「提问时能不能把它取出来」。这两件事今天在 spec 里**没有分开测**——判重保证了一个键只有一条当前版本（存储侧），但「按语义相似度返回」能不能把对的那条捞出来（检索侧），我们从来没有验证过。这篇论文给的警告正好落在这里：**语义相似的邻居，可能恰恰不含答案**。

还有一条更硬的：**几何—功能解离**这个概念可以直接搬到我的股票统计上。我反复验证过「板块量比与后续收益相关性」这类东西——相关性存在（大盘量能 $r=+0.103$ 、 $p=0.0040$ 显著）但 r^2 只有 1.06%，也就是统

计上真实、功能上没用。这篇论文的 $\rho=+0.329$ 是同一个形状：显著 $\neq$ 可用。我已经在 skill 里写了「引用时必须带上强度」，这篇给了这条纪律一个更好的名字。

文中金句

"The failure is that a neighbour's adapter, however semantically apt, does not contain the answer to the query entity's questions. Knowledge is stored locally in each adapter and does not transfer." 失败之处在于：一个邻居的 adapter，无论语义上多么贴切，都不包含查询实体那些问题的答案。知识被局部地存在每个 adapter 里，不发生迁移。

"Weight geometry thus encodes which entities are similar but not which adapter answers a given question — a geometry - function dissociation, in which a real geometric signal carries no matching functional advantage." 因此权重几何编码的是「哪些实体相似」，而不是「哪个 adapter 答得了这个问题」——这是一种几何与功能的解离：一个真实的几何信号，并不携带与之相称的功能优势。

"We therefore read the ρ - retrieval gap not as a weak or noisy geometric signal, but as evidence that entity similarity and answer containment are genuinely different relations." 因此我们把「相关系数与检索表现之间的落差」读作一个证据——实体相似性与答案包含性是两种真正不同的关系——而不是读作几何信号太弱或太噪。

"Our results establish that parametric knowledge graph memory is feasible for storing knowledge, and identify selecting and composing the right adapters by a mechanism other than semantic similarity as the central open problem." 我们的结果确立了参数化知识图谱记忆在存储知识上是可行的，并把「用语义相似度之外的机制来选择和组合正确的 adapter」认定为核心的开放问题。

"The open problem is not storage but composition." 尚未解决的问题不在存储，而在组合。

全文翻译

覆盖范围：摘要、§1 引言、§2 方法、§3 实验设置、§4.1 权重级存储、§4.2 检索、§4.3 组合、§5.1 解离的解释、§5.2 成本与部署、§6 相关工作、§7 结论。图 2 坐标细节、附录 A/B、参考文献条目不译。

摘要 Abstract

Graph retrieval-augmented generation places retrieved subgraphs into the model's context window at query time, paying a recurring token cost and exposing source data on every call. We study an alternative: compiling a knowledge graph offline into a bank of LoRA adapters, one per entity, that serve as a parametric knowledge layer queried by injecting weights rather than text, at zero query-time context cost.

图检索增强生成 (graph RAG) 在查询时把检索到的子图放进模型的上下文窗口，因而**每次调用都要重复支付 token 成本、并且暴露源数据**。我们研究一种替代方案：离线把知识图谱编译成一组 LoRA adapter，**一个实体一个**，作为参数化的知识层；查询它的方式是注入权重而非注入文本，**查询时的上下文成本为零**。

On the MetaQA dataset, we find that subgraph-trained adapters encode context-free factual knowledge that generalizes to unseen questions: on single-valued relations the adapter gains +0.243 exact-match score over a base model that is nearly blind closed-book (0.007), and only the correct adapter recovers this knowledge (an oracle gap of +0.283 over the base model).

在 MetaQA 数据集上我们发现，用子图训练出来的 adapter **确实编码了不依赖上下文的事实知识，并且能泛化到没见过的问题**：在单值关系上，相对于一个闭卷条件下几乎全盲的基座模型 (0.007)，adapter 取得了 +0.243 的精确匹配提升；而且**只有正确的那个 adapter 能把这份知识取出来**（相对基座的 oracle 落差为 +0.283）。

However, the stored knowledge is not recoverable by similarity: given a query with no subgraph, embedding-based and weight-space geometry retrieval both perform at chance, because a semantically neighbouring entity's adapter does not contain the answer — knowledge is stored locally and does not transfer. Weight geometry correlates with subgraph semantics ($\rho = +0.329$) but not with functional retrievability.

然而，存进去的知识无法通过相似度取回：给定一个不带子图的查询，基于句向量的检索和基于权重空间几何的检索**都只有随机水平**——因为一个语义上相邻的实体，它的 adapter 里并不包含答案。**知识是局部存储的，不发生迁移**。权重几何与子图语义是相关的 ($\rho = +0.329$)，但与功能上的可检索性不相关。

Our results establish that parametric knowledge graph memory is feasible for storing knowledge, and identify selecting and composing the right adapters by a mechanism other than semantic similarity as the central open problem — motivating a learned, query-conditioned composition mechanism.

我们的结果确立了：**参数化的知识图谱记忆在存储知识这件事上是可行的**；并把「用语义相似度之外的机制来选择与组合正确的 adapter」认定为**核心的开放问题**——这促使我们去寻找一种可学习的、以查询为条件的组合机制。

引言：两笔按使用次数增长的开销 Introduction

Knowledge graphs give industrial AI systems a structured, auditable substrate of facts, and a now-standard way to put that substrate to work with large language models is graph retrieval-augmented generation: retrieve a relevant subgraph for a query, serialize it into the prompt, and let the model read the answer out of context. This pattern is effective but carries two recurring costs that scale with usage rather than with the size of the graph.

知识图谱为工业 AI 系统提供了一个**结构化、可审计**的事实基底；而现在把这个基底与大模型结合起来的标准做法是 graph RAG：为查询检索一个相关子图，序列化进 prompt，让模型从上下文里读出答案。这个模式是有效的，但它带有**两笔重复发生的成本，而且这两笔成本随使用量增长、而非随图谱规模增长**。

First, every query pays a token cost: the serialized subgraph consumes context-window budget, inflating latency, memory, and energy. Second, every query incurs a data-exposure cost: the raw subgraph is shipped to wherever inference runs, which is problematic when the graph encodes sensitive or proprietary engineering knowledge.

第一，**每次查询都付 token 成本**：序列化后的子图消耗上下文窗口预算，推高延迟、内存与能耗。第二，**每次查询都付数据暴露成本**：原始子图被运到推理发生的任何地方——当图谱编码的是敏感或专有的工程知识时，这是个问题。

We investigate an alternative in which the cost is paid once, offline. A KG is compiled, entity neighbourhood by entity neighbourhood, into a bank of low-rank adaptation (LoRA) adapters. Each adapter is a small weight perturbation ΔW that encodes one subgraph. At query time the system retrieves one or more adapters, injects them into a frozen base model, and answers with no subgraph text in the context window. The knowledge graph thus becomes a parametric memory: a set of weights, not a corpus of text.

我们研究一种**把成本一次性离线付掉**的替代方案：把知识图谱**逐个实体邻域**地编译成一组 LoRA adapter。每个 adapter 是一个小的权重扰动 ΔW ，编码一个子图。查询时，系统取出一个或多个 adapter，注入冻结的基座模型，在上下文窗口里没有任何子图文本的情况下作答。知识图谱于是变成了一种**参数化记忆：一组权重，而不是一堆文本**。

Whether this works at all turns on a question that prior parametric RAG systems leave largely implicit: when an adapter is fine-tuned on a piece of text, does it store that text's facts in its weights, or does it only learn to use the text when the text is present at inference? The distinction is decisive for parametric memory, because at query time the model has no subgraph in context — so only knowledge that resides in the weights is available at all.

这套东西能不能成立，取决于一个此前的参数化 RAG 系统大都默认掉、没有明说的问题：当一个 adapter 在一段文本上被微调之后，它是把这段文本的**事实存进了权重**，还是只学会了「当这段文本在场时怎么使用它」？这个区分对参数化记忆是决定性的——因为查询时模型上下文里没有子图，**所以只有驻留在权重里的知识才是可用的**。

（这段是全文的枢纽。作者点出：整条技术路线建立在一个从没被直接检验过的假设上，而这篇论文就是去检验它。）

Our findings separate cleanly. Subgraph adapters do store generalizable closed-book knowledge. However, the stored knowledge turns out to be local and non-retrievable: given a query with no subgraph, neither question-embedding nor weight-space geometry finds the right adapter above chance, because a semantically similar entity's adapter simply does not contain the answer. Our central finding is therefore a dissociation.

我们的发现分离得很干净。 子图 adapter **确实**存储了可泛化的闭卷知识。然而，存进去的知识是**局部的、不可检索的**：给定一个不带子图的查询，无论是问题句向量还是权重空间几何，都无法以高于随机的水平找到正确的 adapter——因为一个语义相似的实体，它的 adapter **就是不包含那个答案**。因此我们的核心发现是一种「解离」。

方法：离线编译，在线注入 Method

For a chosen set of anchor entities $\{e_1, \dots, e_N\} \subseteq E$ we extract for each e_i its k -hop neighbourhood subgraph $S_i \subseteq G$. Each subgraph is verbalized into text as $v(S_i)$ and used to fine-tune a LoRA adapter $\Delta \theta_i$ on a frozen base model θ_0 , producing a bank $\mathcal{B} = \{\Delta \theta_i\}$. At query time, given a question, we: (a) retrieve one or more adapters $\Delta \theta_i \in \mathcal{B}$; (b) form $\theta = \theta_0 + \sum_i \lambda_i \Delta \theta_i$; and (c) decode the answer from θ with no subgraph text in its context.

对选定的一组锚实体，我们为每个实体抽取它的 **k 跳邻域子图** S_i 。每个子图被**语言化**成本文 $v(S_i)$ ，用来在冻结的基座模型 θ_0 上微调出一个 LoRA adapter $\Delta \theta_i$ ，攒成一个库 $\mathcal{B}$ 。查询时，给定一个问题：(a) 从库中取出一个或多个 adapter；(b) 组成 $\theta = \theta_0 + \sum_i \lambda_i \Delta \theta_i$ ；(c) **在上下文中没有任何子图文本的情况下**从 θ 解码出答案。单实体问题用单个 adapter，多实体问题需要**合并**（见 § 4.3）。

We use a fixed, fact-dense template that enumerates the entity's triples with minimal surface variation (one declarative clause per triple), so that the adapter is trained on a compact, consistent rendering of the subgraph. We did not find weight-level storage to depend on the choice, and use the templated function throughout.

我们使用一个固定的、**事实密集**的模板，把该实体的三元组逐条列举出来、表层变化最小（**一条三元组一个陈述小句**），使 adapter 是在一份紧凑一致的子图呈现上训练的。我们**没有发现权重级存储依赖于这个选择**，全文都使用模板化的语言化函数。

Each adapter's perturbation $\Delta W = BA$ per layer - module is stored via its truncated singular value decomposition, and pairwise distances are computed as normalized Frobenius distances directly from the SVD factors without materializing ΔW . Critically, in deployment the query carries no subgraph, so the retrieval signal must come from the question text alone.

每个 adapter 在每一层每一模块上的扰动 $\Delta W = BA$ 通过**截断奇异值分解**存储，两两距离直接从 SVD 因子上算成归一化的 Frobenius 距离，不必把 ΔW 显式展开。**关键在于：部署时查询不携带子图，所以检索信**

号只能来自问题文本本身。

实验设置：一个刻意选来「几乎全盲」的基座 Experimental Setup

We use Qwen3.5-2B, a compact model inexpensive to train yet able to answer the benchmark's questions when the relevant facts are available. All adapters share this frozen base, loaded in 4-bit QLoRA, with a standard LoRA configuration ($r = 8$, $\alpha = 16$, 0.05 dropout, all seven projection types) trained to convergence with AdamW. Of each entity's QA pairs, eight are used for training and four held out for evaluation.

我们使用 [Qwen3.5-2B](#)——一个紧凑、训练成本低，但在相关事实可得时能答出该基准问题的模型。所有 adapter 共享这个冻结的基座，以 4-bit QLoRA 加载，LoRA 配置为 $r=8$ 、 $\alpha=16$ 、dropout 0.05、七种投影类型全上，用 AdamW 训到收敛。每个实体的问答对中，**八条用于训练、四条留出用于评测**。

MetaQA has no unique film identifiers, so the film title is necessarily the entity key; because distinct films can share a title, keying naively on the title would merge them into a single adapter trained on contradictory labels. We therefore retain only films whose title maps to exactly one release year, excluding multi-film title collisions; adapters built from collided titles often fail to reproduce even their own training answers, whereas clean single-film adapters do so reliably. This yields 150 clean single-film entities.

MetaQA [没有唯一的影片标识符](#)，所以片名不得不充当实体键；而不同影片可能重名，**直接按片名建键会把它们合并成一个 adapter，用互相矛盾的标签去训练**。因此我们只保留片名恰好对应一个上映年份的影片，排除重名冲突。**用重名片名建出来的 adapter 常常连自己的训练答案都复现不了**，而干净的单片 adapter 能可靠复现。这样得到 **150 个干净的单片实体**。

（这一处清洗步骤本身就是个可迁移的教训：[参数化记忆对实体键的唯一性极其敏感](#)，键一脏，adapter 连自己训过的东西都答不出来。）

We evaluate each adapter closed-book (CB), with no subgraph in the context, and open-book (OB), with the subgraph in the context. MetaQA relations are set-valued, so we report three metrics: EM as primary, plus any match (AM) and set recall. We distinguish single-valued relations (director, writer, release year), where EM is meaningful, from multi-valued relations (tags, cast), where set metrics are required.

我们对每个 adapter 做[闭卷](#)（上下文里没有子图）和[开卷](#)（上下文里有子图）两种评测。MetaQA 的关系是集合值的（一部电影有很多标签、若干演员），所以报三个指标：主指标是**精确匹配 EM**，另加**任意匹配 AM**（预测里是否包含任一有效对象）和**集合召回**。我们区分**单值关系**（导演、编剧、上映年份，EM 有意义）与**多值关系**（标签、演员表，必须用集合指标）。

实验一：知识确实存进了权重 Weight-level Storage

表 1：闭卷 EM 相对基座的提升（150 个干净实体上的均值）

设定	基座	加 adapter	提升	95% 置信区间	p
单值关系	0.007	0.250	+0.243	[+0.174, +0.319]	<0.001***
全部关系	0.010	0.137	+0.127	[+0.083, +0.170]	<0.001***

The base model is nearly blind on CB questions: it answers 1% of held-out questions (147 of 150 entities score zero), confirming the films are outside its parametric knowledge and leaving substantial headroom for the adapter to fill.

基座模型在闭卷问题上**几乎全盲**：只答对留出问题的 1%（150 个实体里 **147 个得零分**），这确认了这些影片不在它的参数化知识范围内，也给 adapter 留出了充足的提升空间。

The all-relations gain of +0.127 is lower only because it pools in multi-valued relations that exact match scores at zero by construction: the single-valued figure is the fair measure of weight-level storage.

「全部关系」那一行的 +0.127 之所以更低，**仅仅**是因为它把多值关系也并了进来，而 EM 对多值关系**按构造就是零分**。单值关系那个数字才是对权重级存储的公允度量。

表 2：注入不同 adapter 的闭卷 EM（30 个查询上的均值）

注入的 adapter	精确匹配	提升	95% 置信区间	p
基座（不注入）	0.017	—	—	—
随机初始化的未训练 adapter	0.000	-0.017	[-0.050, 0.000]	<0.001***
别的实体的（错误） adapter	0.017	0.000	[0.000, 0.000]	1.000
自己的（正确） adapter	0.300	+0.283	[+0.183, +0.400]	<0.001***

The two negative controls separate in an informative way. An unrelated but trained adapter leaves performance exactly at base: it encodes real facts, just the wrong entity's. An untrained adapter with randomly initialized weights scores 0.000, below base, destroying even the residual pretraining knowledge the base model has. The LoRA structure therefore contributes nothing on its own; the recovered knowledge comes entirely from gradient updates on entity-specific data.

两个负对照以一种很有信息量的方式分开了。 一个无关但**训练过**的 adapter 让表现**恰好停在基座水平**——它编码的是真实的事实，只不过是错误实体的事实。一个**未训练、随机初始化的** adapter 得 0.000，**低于基座**，连基座模型残留的那点预训练知识都被破坏了。**因此 LoRA 这个结构本身什么也没贡献；被取回的知识完全来自在实体特定数据上的梯度更新。**

The wrong adapter never changes any outcome relative to base — every paired difference is exactly zero, hence $p = 1.000$ — because the base model is at floor on CB QA. That floor also means the wrong-adapter contrast has little power to detect a small positive effect, so its p-

value should not be read as evidence of equivalence; the contrast that carries the claim is the own-adapter gain.

错误 adapter 相对基座**从未改变任何一个结果**——每一个配对差都恰好为零，所以 $p=1.000$ ——因为基座在闭卷问答上已经触底。这个地板也意味着「错误 adapter」这个对照几乎没有检出小正效应的功效，所以它的 p 值不应被读作等价性的证据；承载结论的是「自己的 adapter」那个对照。

表 3：多值关系在三种闭卷指标下的表现

关系	精确匹配	任意匹配	集合召回
有标签	0.000	0.854	0.793
主演	0.000	0.500	0.389

EM registers zero while AM and set recall show the adapter produces valid answers; the zero is a scoring artefact, not a learning failure.

EM 记为零，而任意匹配与集合召回显示 adapter **产出了有效答案**；这个零是评分方式的产物，不是学习失败。

表 4：各单值关系的闭卷 EM 提升

关系	EM 提升	95% 置信区间	p
导演	+0.274	[+0.161, +0.387]	<0.001***
编剧	+0.269	[+0.115, +0.462]	0.001**
上映年份	+0.196	[+0.089, +0.321]	0.001**
类型	+0.182	[0.000, +0.455]	0.218
语言	+0.091	[-0.182, +0.364]	0.769

导演、编剧、上映年份三项的置信区间都不含零；更稀疏的「类型」和「语言」则不显著。

关于**语言化格式**的消融是一个**空结果**：在一个更早的 120 实体库上，用模板化与自然散文两种语言化训练配对的 adapter，配对差为 +0.019（置信区间 [-0.013, +0.050]， $p=0.275$ ）。作者明确表示「**把它报为一个空结果，而不是对任一格式的支持**」，而且因为用的是不同的库，「**视作提示性而非结论性**」。

实验二：取不出来——本文的核心发现 Retrieval

A parametric memory is only useful if the right adapter can be selected for a query without its subgraph in hand. The answer is a clean negative for similarity-based selection: the knowledge stored in an adapter does not transfer to, and cannot be recovered from, a semantically neighbouring entity's adapter.

只有在没有子图在手的情况下仍能为查询选出正确 adapter 时，参数化记忆才是有用的。 对于基于相似度的选择，答案是一个**干净的否定**：存在一个 adapter 里的知识**不迁移到、也无法从语义上相邻的实体的**

adapter 里取回。

表 5：由查询驱动的 adapter 检索，闭卷 EM 相对基座的提升（30 个查询）

检索方法	精确匹配	提升	95% 置信区间	p
基座（不注入）	0.017	—	—	—
问题句向量	0.017	0.000	[0.000, 0.000]	1.000
ΔW Frobenius 几何	0.017	0.000	[0.000, 0.000]	1.000
随机（全局）	0.010	-0.007	[-0.047, +0.023]	0.778
随机（域内）	0.007	-0.010	[-0.050, +0.020]	0.533
Oracle（自己的 adapter）	0.300	+0.283	[+0.183, +0.400]	<0.001***

The two query-driven methods are not merely both at chance but exactly equivalent to each other, their paired difference being identically 0.000: weight-space geometry adds nothing over a sentence embedding for this task.

两种由查询驱动的方法不只是双双处于随机水平，而且彼此完全等价，配对差恒等于 0.000：在这个任务上，权重空间几何相对句向量没有增加任何东西。

Crucially, this is not a failure of the retriever to identify similar entities. Question embeddings identify semantically appropriate neighbours cleanly: each entity is its own nearest neighbour, and near neighbours are genuinely related films (e.g. two films by the same director). The failure is that a neighbour's adapter, however semantically apt, does not contain the answer to the query entity's questions.

关键在于，这不是检索器识别相似实体失败了。问题句向量干净地识别出了语义上恰当的近邻：每个实体的最近邻就是它自己，而近邻确实是相关的影片（比如同一导演的两部片子）。失败之处在于：一个邻居的 adapter，无论语义上多么贴切，都不包含查询实体那些问题的答案。

作者对这个否定结论的范围很小心：这是关于「基于相似度的路由」的否定结论，不是关于「adapter 选择」整体的否定结论。一个常规的实体消解步骤——按片名或标识符匹配、或在实体索引上做词法检索——能把很多 MetaQA 问题正确路由，因为问题通常会点名它的锚定影片，而库里每部影片恰好一个 adapter。他们的论点更窄：一个参数化系统可能寄望用来检索的那两种几何（句向量的与权重空间的），并不编码「答案包含性」，因此无法替代实体消解。

表 6：几何与语义的相关性及零假设对照

设定	Spearman ρ
全部层	+0.329
前 8 层	+0.352
标签置换（零对照）	+0.157
按列洗牌（零对照）	+0.036

Weight geometry thus encodes which entities are similar but not which adapter answers a given question — a geometry - function dissociation. We therefore read the ρ - retrieval gap not as a weak or noisy geometric signal, but as evidence that entity similarity and answer containment are genuinely different relations.

因此权重几何编码的是「哪些实体相似」，而不是「哪个 adapter 答得了这个问题」——这是一种几何与功能的解离。因此我们把相关系数与检索表现之间的落差，读作「实体相似性与答案包含性是两种真正不同的关系」的证据，而不是读作几何信号太弱或太噪。

作者还诚实交代了一处统计功效不足：在 120 个 adapter 的画廊里只有一个是正确的，随机的 Recall@1 低于 1%，所以观察到一次命中在统计上与随机不可区分。因此结论建立在 oracle 与所有查询驱动方法之间的下游 EM 落差上，而不是建立在排名统计上。

实验三：组合——实验没做成，但问题说清楚了 Composition

Multi-hop questions require combining knowledge across entities, and the natural mechanism is to merge the relevant adapters. The obstacle we encounter is not interference but the benchmark and the retrieval result above.

多跳问题需要跨实体组合知识，自然的机制是合并相关的 adapter。我们遇到的障碍不是（权重）干扰，而是基准本身，以及上面那个检索结果。

Concretely, MetaQA's two-hop questions ask about an intermediate entity (e.g. 'what films share a director with this film?'), and their answers require knowledge contained in neither of the two entity subgraphs a merge would combine, nor in the two subgraphs placed jointly in context. In our tests every condition, including the both-subgraphs-in-context oracle, scored at floor, so the experiment could not isolate a composition effect: the information needed was absent from the inputs by construction. We therefore do not report a composition result and instead state the problem precisely.

具体来说，MetaQA 的两跳问题问的是一个中间实体（例如「哪些电影和这部片子共用一个导演？」），而它们的答案所需的知识，既不在合并会组合起来的那两个实体子图里，也不在把这两个子图一起放进上下文的情况里。在我们的测试中，包括「两个子图都在上下文里」的 oracle 在内，每一种条件都触底，所以这个实验无法隔离出组合效应：所需信息按构造就不在输入中。因此我们不报告组合结果，而是把问题精确地陈述出来。

Both point to the same gap: knowledge is stored locally in per-entity adapters, and neither query-driven retrieval nor naive merging assembles the right knowledge for a multi-entity question.

两者指向同一个缺口：知识被局部地存在每实体的 adapter 里，而无论是查询驱动的检索还是朴素的合并，都没能为一个多实体问题组装出正确的知识。

讨论一：解离该怎么解释 Interpreting the Dissociation

Three facts hold with statistical support. First, the correct adapter carries entity-specific knowledge. Second, similarity does not imply transfer: the question-embedding retriever selects genuinely related neighbours, yet applying those neighbours' adapters recovers nothing over random. Third, the failure is not a failure of the geometry to organize by semantics — but a failure of that organization to predict answer containment.

有三个事实是有统计支持的。 第一，正确的 adapter 携带**实体特定**的知识。第二，**相似不蕴含迁移**：问题句向量检索器选出的是真正相关的近邻，然而应用这些邻居的 adapter 相对随机什么也没有取回。第三，**失败不是几何未能按语义组织起来**（ ΔW 距离与子图语义在 $\rho=+0.329$ 上相关，远高于置换零对照的 $|\rho| \leq 0.157$ ）——而是这种组织无法预测答案包含性。

We can point to at least two mechanisms our experiments do not distinguish. One is answer non-overlap: two similar films rarely share the specific object a question asks for (given two similar films, their directors are almost always different), so even perfect transfer would not help — a property of the QA task, not of the adapters. The other is storage locality: fine-tuning may write each entity's facts into a subspace a different entity's adapter does not activate. Both predict the same retrieval curve, and separating them would require shared-answer cases at a scale MetaQA's single domain does not allow.

我们至少能指出两种我们的实验无法区分的机制。 一是**答案不重叠**：两部相似的影片很少共享问题所问的那个具体对象（给定两部相似的电影，它们的导演几乎总是不同的），所以**即便迁移是完美的也帮不上忙**——这是问答任务的性质，不是 adapter 的性质。二是**存储局部性**：微调可能把每个实体的事实写进了一个另一个实体的 adapter 不会激活的子空间，使知识在机制上跨 adapter 不可达。**两者预测出同样的检索曲线**，要把它们分开需要「共享答案」的案例，而 MetaQA 的单一领域达不到那个规模。

（这一段是本文诚实度的顶点：作者明确说自己**无法区分**两种解释，并说明了区分它们需要什么数据。）

讨论二：成本与部署 Cost and Deployment

表 7：成本对比

	Graph RAG（放上下文）	参数化（本文）
每次查询的上下文 token	60	0
每次查询运送的字节	188 B	10.4 MiB（一次性）

On MetaQA this cost is modest: a serialized one-hop subgraph is a median of 60 tokens, because the benchmark's entities are sparse. The 60 tokens should therefore be read as a floor rather than a headline: the saving is small here precisely because MetaQA subgraphs are small, and it would scale up on the dense, multi-hop, property-rich subgraphs of industrial KGs.

在 MetaQA 上这个成本是有限的：序列化后的一跳子图中位数是 **60 个 token**，因为该基准的实体很稀疏（通常六七个单行字段）。因此这 60 个 token 应当读作一个下限，而不是标题数字：这里节省得少，恰恰是因为 MetaQA 的子图小；在工业知识图谱那种稠密、多跳、属性丰富的子图上，它会放大。

We are careful not to overclaim it as a latency or energy win: injecting and swapping a per-query adapter is itself a cost that graph RAG does not pay, and we have not measured end-to-end latency or energy, so we claim the context-token saving only, not a net speedup.

我们很小心，不把它夸成延迟或能耗上的胜利：为每次查询注入和切换 adapter 本身就是 graph RAG 不需要付的成本，而**我们没有测过端到端的延迟或能耗**，所以我们只主张上下文 token 的节省，不主张净加速。

An adapter is far larger than the subgraph it encodes (10.4 MiB of weights versus 188 B of serialized triples, a ratio of roughly 58 000 times more) so, on bytes alone, parametric memory is favourable only when an entity is queried often enough to amortize its adapter. That ratio also bounds scalability honestly: a bank covering one million entities would occupy on the order of 10 TiB of checkpoints.

一个 adapter 远大于它所编码的子图（**10.4 MiB 的权重 vs 188 字节的序列化三元组，约 58,000 倍**），所以单看字节，参数化记忆只有在一个实体被查询得足够频繁、足以摊销它的 adapter 时才划算，或者当约束本来就是上下文预算而非存储时。这个比值也诚实地界定了可扩展性：一个覆盖一百万实体的库将占用约 10 TiB 的检查点，外加每个实体一次性的离线训练成本。因此这套方案适合稳定、高频查询的子图，而不是网络规模或快速变化的图谱。

We frame this as reduced raw-context exposure rather than leakage resistance: our own positive result shows that facts are recoverable from the weights, so the adapter is itself a potential leakage surface, and we do not test resistance to extraction.

我们把这一点框成**「减少了原始上下文的暴露」而不是「抗泄漏」**：**我们自己的正面结果恰恰表明事实可以从权重里被恢复出来，所以 adapter 本身就是一个潜在的泄漏面**，而**我们没有测试它对提取的抵抗力**。

Parametric KG memory is not free. It pays a one-time offline encoding cost and, once compiled, a fact update requires re-encoding the affected adapter. For graphs that change continuously, or for one-shot queries over a graph that is never reused, in-context graph RAG remains the better trade-off.

参数化知识图谱记忆不是免费的。它付一次性的离线编码成本，而且一旦编译完成，一次事实更新就需要重新编码受影响的那个 adapter。对于持续变化的图谱，或者对一个从不复用的图谱做一次性查询，放在上下文里的 graph RAG 仍然是更好的取舍。

相关工作 Related Work

A line of work encodes retrieved documents directly into model parameters rather than into context: Parametric RAG fine-tunes a LoRA adapter per document and averages retrieved

adapters at inference, DyPRAG trains a hypernetwork to map documents to adapters on the fly, and Poly-PRAG learns a shared adapter basis with per-document routing. These systems target document-level, single-hop RAG and implicitly assume that document-encoded adapters carry the document's knowledge — which presumes that fine-tuning stores facts in the weights rather than only teaching the model to exploit in-context text. We apply the parametric-memory idea to KG subgraphs and test that assumption directly.

已有一支工作把检索到的文档直接编码进模型参数而非上下文：Parametric RAG 为每个文档微调一个 LoRA adapter，推理时对检索到的 adapter 求平均；DyPRAG 训练一个超网络，实时把文档映射成 adapter；Poly-PRAG 学习一组共享的 adapter 基，配合按文档的路由。这些系统面向文档级的单跳 RAG，并且隐含地假设：文档编码出的 adapter 携带该文档的知识——这预设了微调把事实存进了权重，而不只是教会模型去利用上下文中的文本。我们把参数化记忆的想法用到知识图谱子图上，并直接检验这个假设。

结论 Conclusion

We found that subgraph-trained adapters encode context-free, CB-recoverable knowledge that generalizes to unseen questions. Only the correct adapter recovers this knowledge, but no query-driven method finds it: embedding and ΔW geometry retrieval both perform at chance, because knowledge is stored locally and does not transfer to semantically neighbouring adapters.

我们发现，用子图训练的 adapter 编码了不依赖上下文、闭卷可取回、并能泛化到未见问题的知识（单值关系上相对近乎全盲的基座 +0.243 EM）。只有正确的那个 adapter 能取回这份知识（oracle 落差 +0.283），但没有任何由查询驱动的方法能找到它：句向量与 ΔW 几何检索都处于随机水平，因为知识是局部存储的，不迁移到语义上相邻的 adapter。

These findings come with scope conditions. This is a single-benchmark, single-model, workshop-scope study with model-generated QA pairs. The headline CB claim is restricted to single-valued relations. Our single-domain (film) entities leave open whether the retrieval negative persists across broad domains. Within these bounds, storing knowledge in weights is feasible at zero query-time token cost. The open problem is not storage but composition.

这些发现带有适用范围。这是一项单基准、单模型、workshop 规模的研究，问答对是模型生成的。核心的闭卷主张限于单值关系，多值关系需要一种集合值的参数化记忆概念，留给未来工作。我们的**单一领域（电影）**实体使得「检索的否定结论在宽领域下是否依然成立」仍是开放的——在宽领域下 ΔW 几何可能分离得更强。在这些边界之内，把知识存进权重、以零查询时 token 成本使用，是可行的。尚未解决的问题不在存储，而在组合。

参考链接

- [arXiv 检索页 / SKGi 2026](#) — SEMANTiCS'26 会议主页, 本文所属的 SKGi 工业知识图谱扩展研讨会与之同期
- [LoRA: Low-Rank Adaptation of Large Language Models](#) — 本文的基础方法, 每个实体一个低秩扰动 ΔW
- [QLoRA](#) — 本文加载基座所用的 4-bit 量化微调方案
- [MetaQA](#) — 本文使用的电影领域知识图谱问答基准
- [Task Arithmetic](#) — 权重扰动的组合与干扰研究, 本文组合实验的方法背景
- [TIES-Merging](#) — 模型合并中处理参数干扰的代表工作