

给图配的上下文不是越多越好 Multi-Granularity Context-Enhanced RAG over Multimodal Knowledge Graphs

本篇范围声明：这是一篇 11 页的会议投稿 (arXiv 2608.25986v1, 2026-08-26 提交)。下面的「全文翻译」按章节推进，覆盖摘要与正文第 1 - 6 节的主体 (引言、相关工作、背景与预备、方法、实验、结论)，四张示意图保留其结构与含义说明，两张结果表逐格给出；文末的生成式 AI 使用声明、伦理声明与 69 条参考文献列表不逐条翻译。

核心内容

Q: 这篇要解决的是什么问题？ A: 文档里的图表，被拿去建**多模态知识图谱 (MMKG)**时，要先让多模态大模型看图写描述，再从描述里抽实体和关系。而模型看图的时候能拿到什么文字帮助理解，直接决定了抽出来的图谱有多准。

现有方法只给它「图周围的那几段文字」。 但一张图在文档里通常是在一个地方被引入、在另一个地方被详细讨论，讨论它的那段话往往比它的位置邻居信息量大得多。论文把这个问题概括成一句话：**上下文是按「挨得近」选的，不是按「相关」选的。**

Q: 他们怎么改？ A: 核心动作是按「提到它」而不是「挨着它」来找上下文。

具体做法：文档解析时每张图会拿到一个标识符 (比如「Figure 3」「Table 2」)，然后在全文里搜所有提到这个标识符的句子，组成**引用集合 R_i** 。论文特别强调： **R_i 是按「提及」而不是按「位置」确定的，所以它的元素可能离图很远。**

Q: 上下文分几种？ A: 分**局部**和**全局**两层。

局部有四个成分。第一个是沿用已有做法的「周围文本」，始终保留；后三个都基于引用集合 R_i ，是**同一批**引用的三种不同粒度，三选一而不是一起用：

成分	是什么	覆盖面 vs 信息密度
周围文本	图在文档中紧邻的前后文本块	已有方法用的就是这一个
参考句	R_i 里的每个句子，加上它紧邻的前一句和后一句	覆盖最窄、密度最高
参考段落	R_i 里那些句子所在的完整段落	覆盖最宽、密度最低

成分	是什么	覆盖面 vs 信息密度
参考段落摘要	让大模型把那些段落压缩一遍	介于两者之间：想要段落的覆盖面、句子的密度

全局有两种，二选一：文档原本的**摘要**（有就用），或者让大模型对全文生成的**文档摘要**（没有摘要时的兜底）。论文明确说了兜底才是常态——**很多真实文档不是学术论文，根本没有摘要。**

Q：这些上下文喂到哪里？ A：两个注入点，而且**两处喂的东西不一样**：

- **图转图谱（Image2Graph）阶段**：喂**完整上下文**（局部 + 全局）。理由是这一步要理解这张图讲什么，图本身的细节和文档整体主题都有用。
- **模态融合阶段**：只喂**局部上下文**。理由是这一步的目标变了——不是理解图，而是把图里抽出的实体和文本里抽出的实体对上号，**对齐只需要足够的文字来命名涉及的实体。**

Q：效果怎么样？最重要的那个结果是什么？ A：**最重要的结果是一个负面结果**：给的上下文更多，反而比什么都不加更差。

在 MMGraphRAG 这个骨干上（严格准确率 / 官方软准确率）：

配置	严格 / 软
直接问多模态大模型	11.32 / 11.32
MMGraphRAG（基线）	23.58 / 24.17
+ 参考段落 + 文档级全局	22.64 / 22.64 ← 比基线还低
+ 参考段落摘要 + 文档级全局	31.13 / 32.82
+ 参考句 + 文档级全局	34.91 / 36.84 ← 最好

作者自己点出了这一条：**「简单地引入更多文本上下文，并不必然带来更好的性能。」** 给出的解释是完整段落里含有与图只有微弱关联的信息，引入了无关或冗余的上下文。

Q：这个结论能不能照单全收？ A：**结论的方向可信，但那些具体数字撑不起论文的语气。** 我把每一格的题数反推出来了——**整个测试集只有 106 道题，最好配置比基线只多做对 12 道。** 详见点评。

背景补充 / 点评

几个术语，先说清楚

MMKG（Multimodal Knowledge Graph，多模态知识图谱）：把图像等非文本内容也当成图里的节点。论文按两个维度给它分了类，这个分类值得记：

- 按**表示方式**：**属性式**把图像作为附加属性挂在符号实体上，不显式建模图内部的细粒度内容；**节点式**把视觉内容提升为一等节点，让物体和它们的关系被显式建模、可被遍历。**这篇用的是节点式。**

- 按来源：百科式是在一个已有知识图谱上做增补，覆盖面因此受限、也容易过时；文档派生式是从目标语料构建——先把文档解析成文本、表格、图、公式，再从这些单元里抽实体和关系。这篇用的是文档派生式。

GraphRAG：检索增强生成的一种，外部知识源是知识图谱而不是一堆文本片段。好处是实体和实体之间的关系被显式建模了，检索时能顺着关系走。论文指出**现有 GraphRAG 绝大多数仍是纯文本的**。

MinerU：文档解析器，把 PDF 拆成文本、表格、图、公式等不同模态的内容。这篇和它对比的两个方法都用它。

MMLongBench-Doc：一个覆盖多种文档类型的文档问答基准。这篇从里面挑了一个子集叫 VisionHeavy。

ANLS：一种字符串相似度评分，允许部分正确（所以会出现小数分）。这篇的「软准确率」里字符串和列表类答案用 ANLS，整数、浮点、精确匹配类答案是 0/1 打分。

那个子集是怎么挑的，这一步做得好

VisionHeavy 的筛选有两条明确标准，都是为了让测试集真的能考出想考的东西：

- 文档必须是视觉密集的——它的可回答问题里，需要图表证据的占比要高。
- 文档必须存在非局部的证据依赖——回答它的问题，需要把视觉元素和「超出其邻近文本」的证据连起来。

第二条尤其关键：这篇的整个方法就是「找远处的相关文字」，如果测试集里的答案都在图的旁边，那这个方法天然测不出优势。先把测试集筛成能暴露差异的样子，再去比，这一步的思路是对的。

筛出来的结果：106 道题，可回答问题里 80.2% 需要视觉信息、43.2% 依赖跨页分布的信息，覆盖原基准七种文档类型里的六种。

我的判断

这篇最有价值的是那个负面结果，而不是它的最好成绩。

「参考段落」这一行（22.64 / 22.64）比什么都不加的基线（23.58 / 24.17）还低。这是全文最有信息量的一个数——它否掉了一个非常自然的直觉：既然上下文有用，那给全一点总没错。

而且这个否定不是孤例，在另一个骨干 RAG-Anything 上也复现了，甚至更明显：

配置	严格 / 软
RAG-Anything（基线）	28.89 / 36.18
+ 参考段落	28.89 / 34.49 ← 软准确率低于基线
+ 参考段落摘要	31.11 / 33.13 ← 软准确率更低

配置	严格 / 软
+ 参考句	35.56 / 41.12

这张表里论文的表达有一处过头了。原文写的是「性能从参考段落、到它们的大模型摘要、再到参考句依次递进地提升」。这句话只在严格准确率上成立（28.89 → 31.11 → 35.56）；在软准确率上，段落和摘要两行都低于基线，而且摘要比段落还更低（34.49 → 33.13）——是递减的。论文没有提这一点。

那些数字撑不起论文的语气：我把题数反推了出来

论文只给百分比，不给题数。但百分比是可以反解的——找一个分母 n ，使得同一列所有百分比乘以 n 都接近整数。结果很干净：

类别	题数	各配置答对题数（严格）
Figure	32	2 → 4 → 5 → 7
Table	25	1 → 5 → 4 → 6
Chart	16	0 → 5 → 4（三个配置里最好的也只有 5）
Misc	41	9 → 14 → 11 → 18 → 21
总计	106	12 → 25 → 24 → 33 → 37

所以最好配置比基线多做对的是 12 道题。

按两比例检验粗算（我自己算的，非论文提供）： $p_1 = 0.349$ 、 $p_2 = 0.236$ 、 $n=106$ ，标准误 0.062， $z = 1.83$ ，双侧 $p \approx 0.068$ 。没过 0.05。

Figure 类那个被论文称为「提升最显著」的结果更薄：7 题对 2 题，多做对 5 道， $z = 1.85$ 、 $p \approx 0.065$ ，同样没过。

而论文用来排序三种粒度的那个差距——参考句 34.91% 对段落摘要 31.13%——是 37 题对 33 题，差 4 道。拿 4 道题的差距去论证「参考句这个粒度更优」，这个结论不成立。

需要说清楚的一点：上面这个检验是非配对的，偏保守。同一批题目在两个配置下作答，配对检验（比如 McNemar）的功效会更高。但论文没有给出不一致对的数量，所以配对检验做不了——而这恰恰是应该报告的东西。论文也没有报告置信区间、没有做多次重复、没有任何显著性检验。

方向我信，幅度我不信。「越多不一定越好」这个定性结论在两个骨干上一致复现，而且有机理解释；但「参考句 > 摘要 > 段落」这个排序，在 106 道题上分不出来。

还有两处实验设计的缺口

第一，没有把局部和全局拆开测。表 1 里 CEMMKG 的三行全都带着「文档级」全局上下文，而基线两行一个都没有。所以「+参考句+全局 34.91%」对「基线 23.58%」这个比较，同时改了两件事：加了引用式局部上下文、加了全局上下文。

论文在方法一节花了大量篇幅论证局部和全局各自的作用（局部给细粒度证据、全局给文档级语义参照），**但实验里没有任何一行能支撑这个划分**——没有「只加全局」，也没有「只加局部」。那两段论证是没有实验对应物的。

第二，最大的那个提升出现在最不该出现的地方。 Misc 类的软准确率从 34.15% 涨到 54.01%，是全表最大的单项涨幅（21 题对 14 题）。而 Misc 的定义是「不带 Figure、Chart、Table 任何标签的问题」——也就是最不依赖视觉上下文的那一类。

论文注意到了这一点，给的解释是「设计的上下文不仅增强了单个图的图谱表示，也增强了它们与文本知识的融合，所以对依赖文本知识的问题也有帮助」。**这个解释是合理的猜测，但论文没有测它。**而另一个同样合理的解释是：这些提升根本不来自「更好的视觉理解」，而来自别的什么——比如那个被顺带改掉的检索策略（见下）。

第三，有一处改动混在实现细节里，没有被单独评估。实现细节那一节写着：他们修改了 MMGraphRAG 的检索阶段，引入了一个「优先选取被显式引用的 Figure/Table 标识符」的视觉选择策略，没有显式引用时用 BM25 做词面匹配，再没有才回到原本的稠密图检索。

这是对检索环节的改动，而论文全篇声称自己只动构建环节、不动检索环节（第 3.2 节原话是「我们聚焦于 G_M 的构建，而不是检索阶段」）。这个改动可能贡献了相当一部分提升，但它从未被单独消融。

论文做得好的三处

一、把「上下文长了会有害」这件事在设计里就防住了。他们明确写了两条约束：只保留文档顺序上靠前的若干引用位点，且融合阶段用的比图转图谱阶段更少（理由给得很清楚——对齐只需要足够的文字来命名实体）；以及分别给引用式上下文和全局上下文设长度上限，使得两者谁也挤不掉谁。

第二条尤其值得抄。**如果只设一个总长度上限，那么引用多的图会把全局上下文挤没，而这件事是静默发生的。**

二、两个注入点喂不同的东西，理由说得住。图转图谱要理解一张图，所以给全；融合要对齐实体，所以只给局部。这个区分背后是「这一步的目标是什么」，不是「哪个效果好就用哪个」。

三、骨干原样不动，只换上下文参数。原文写得很明确：「我们保持骨干 f_v 不变，只替换它的上下文参数」。这让改动的作用面是清楚的——至少在图转图谱这一步是清楚的（检索那处改动破坏了这个干净性，见上）。

对我的启示

第一条，直接对应我们评估侧那个方案。

我们正在评估的「用向量召回替代全量转写」，问的是同一类问题：**给模型多少证据、以什么粒度给。**这篇给了一个可以直接借用的经验：**粒度错了会比不给还差**，而且差的方式是「引入了弱相关的内容稀释了强相关的内容」。

更具体的可借用点是他们那三档粒度：**句子 / 段落 / 段落的摘要**。我们现在的召回是按片段切的，没有「把召回到的片段再压一遍」这一档。这篇的数据说这一档在两个骨干上都排第二——**不是最好，但比整段好**。值得作为一个候选配置。

第二条，「按提及找」这个思路可以搬。

他们的关键动作是：**不按位置找上下文，按「谁提到了它」找**。靠的是解析时保留下来的标识符（Figure 3、Table 2）。

放到我们的场景：评分时要找「学员讲到某个语义点的证据」，现在是按转写的时间顺序或片段相邻性找。**如果语义点和话轮之间有显式的引用关系可以建立（比如某个话轮明确回应了某条关注点），那就应该按那个关系找，而不是按前后位置找**。这条和我在 roleplay 那边发现的「关注点不带实例归属」是同一个缺口——缺的是显式的引用关系，所以只能退回按位置猜。

第三条是方法论的，也是今天最该记住的。

我从百分比反推题数只花了几行算术，就把「显著提升」变成了「多做对 12 道、 $p \approx 0.068$ 」。**这个动作应该变成读任何实验论文的固定步骤：先问总样本量是多少，再把百分比换算成绝对个数**。

判据很简单：**如果一个百分比差距换算成个数之后是个位数，那它多半是噪声**。这篇 Figure 类的「提升最显著」是 5 道题，三种粒度之间的排序是 4 道题。

顺带一条：论文只给百分比不给分母，这本身就是个信号。给了分母，读者一算就知道差距有多薄。

文中金句

"Context is thus selected by proximity rather than relevance, admitting unrelated neighboring text while ignoring a sentence that explicitly discusses the target figure from elsewhere in the document." 因此上下文是按**邻近程度**而不是按**相关程度**选取的——它收进了无关的邻近文本，却忽略了文档别处一句明确讨论该图的话。

"Note that R_i is determined by mention rather than by position. Hence, its elements may lie far away from I_i in the document." 注意 R_i 是由**提及**而非由**位置**确定的。因此它的元素在文档中可能离该视觉元素很远。

"This result suggests that simply introducing more textual context does not necessarily lead to better performance." 这个结果表明：**简单地引入更多文本上下文，并不必然带来更好的性能**。

"Second, we cap the length of the reference-based component and that of the global context separately, so that neither can crowd out the other." 第二，我们**分别**给基于引用的成分和全局上下文设置长度上限，使得两者谁也不能把对方挤掉。

全文翻译

摘要

Retrieval-augmented generation (RAG) is widely used to mitigate hallucination issues in large language models (LLMs) and multimodal large language models (MLLMs). In particular, knowledge graph (KG)-based RAG leverages structured knowledge to provide (M)LLMs with high-quality external information. Building on these works, recent studies have explored multimodal knowledge graphs (MMKGs) as knowledge bases for GraphRAG.

检索增强生成（RAG）被广泛用于缓解大语言模型（LLM）和多模态大语言模型（MLLM）的幻觉问题。其中，**基于知识图谱（KG）的 RAG** 利用结构化知识为模型提供高质量的外部信息。在此基础上，近期研究开始探索把**多模态知识图谱（MMKG）**作为 GraphRAG 的知识库。

However, existing MMKG-based RAG methods generally follow a common pipeline in which different modalities are largely processed independently before being fusion. As a result, textual context is only used to a limited extent during visual information extraction and subsequent multimodal knowledge fusion. This brings a semantic gap between images and text which limits the multimodal GraphRAG performance.

然而，现有基于 MMKG 的 RAG 方法通常遵循一条共同的流水线：**不同模态在融合之前基本是各自独立处理的**。其结果是，在视觉信息抽取以及后续的多模态知识融合过程中，文本上下文只被有限地利用。这带来了**图像与文本之间的语义鸿沟**，限制了多模态 GraphRAG 的性能。

To address this issue, we propose a novel framework for constructing a Context-Enhanced MMKG (CEMMKG) to better support multimodal GraphRAG. The proposed CEMMKG enriches each image with complementary textual context at both local and global scopes. Local context goes beyond the surrounding text by incorporating sentences that are semantically related to the image, while global context provides a summary of the entire passage. We further introduce a multi-granularity design for the local context.

为解决这个问题，我们提出一个构建**上下文增强 MMKG（CEMMKG）**的新框架。**CEMMKG 在局部和全局**两个范围上，为每张图像补充互补的文本上下文。**局部上下文超出了「周围文本」的范围，纳入了与图像语义相关的句子**；全局上下文则提供整段内容的摘要。我们进一步为局部上下文引入**多粒度设计**，使其能在不同的细节层次上捕捉语义相关的信息。

在挑选出的以视觉为中心的数据集上做的大量实验验证了 CEMMKG 能有效利用上下文信息来提升基于 MMKG 的 RAG 性能。此外，它在不同的基于 MMKG 的 RAG 方法上都有效，表明其适用面较广。

一、引言：上下文按位置选还是按相关性选

Although Multimodal Large Language Models (MLLMs) have demonstrated strong performance across a wide range of domains, they are still prone to generate hallucinated content due to several factors such as outdated training knowledge.

尽管多模态大语言模型（MLLM）在广泛领域展现出强劲性能，它们仍然容易产生幻觉内容，原因包括训练知识过时等若干因素。

Despite the success of KGs to represent knowledge, most existing GraphRAG methods primarily operate on textual KGs, with graph construction and retrieval largely centered on textual information. This text-centric paradigm leaves rich information from other modalities, such as visual content and tabular data, largely underexplored.

尽管知识图谱在表示知识上很成功，**大多数现有 GraphRAG 方法主要作用于纯文本知识图谱**，图构建与检索基本围绕文本信息展开。这种以文本为中心的范式，使得视觉内容、表格数据等其它模态的丰富信息基本未被开发。

However, existing MMKG-based RAG methods typically follow a pipeline in which information from each modality is largely processed separately before being fused into a unified MMKG. Such modality-specific processing may overlook the rich contextual relationships between information from different modalities. For example, when processing visual information, existing methods often utilize only limited textual context, such as surrounding text chunks.

然而，现有基于 MMKG 的 RAG 方法通常遵循这样一条流水线：**各模态的信息基本分开处理，然后才融合成统一的 MMKG**。这种按模态分别处理的做法，可能忽略不同模态信息之间丰富的上下文关系。例如在处理视觉信息时，现有方法往往只利用有限的文本上下文，比如周围的文本块。

Visual information is often closely related to textual information distributed across different parts of a document. Such textual information may provide important context for interpreting the semantics of visual elements. Simply incorporating more textual context does not necessarily improve the quality of MMKG.

视觉信息往往与散布在文档不同部分的文本信息密切相关，这些文本信息可能为解释视觉元素的语义提供重要上下文。而简单地纳入更多文本上下文，并不必然提升 MMKG 的质量。

论文由此提出三个尚未被充分探索的问题：**** (i) 应当选取哪些文本信息作为视觉元素的上下文；(ii) 构建这种上下文最合适的粒度是什么；(iii) ****设计出来的上下文如何在 MMKG 构建过程中被有效利用。

主要贡献三条：对 MMKG 构建过程中多模态元素之间的多粒度上下文映射做了一次全面研究；提出 CEMMKG，在不同粒度上系统地设计视觉元素的文本上下文，并灵活地把所得上下文用在 MMKG 构建的不

同阶段；在从 MMLongBench-Doc 挑出的以视觉为中心的子集上，跨不同上下文配置做了大量实验。

二、相关工作

2.1 多模态大语言模型：MLLM 通过把视觉编码器与 LLM 主干对齐，把 LLM 的能力扩展到视觉领域——对齐方式或是轻量投影层，或是交叉注意力与可学习的查询模块。由于能在交错的图文上联合推理，MLLM 成为把视觉信息翻译成文本内容的常用工具，被广泛用于给多模态知识图谱填充视觉实体和关系。

However, MLLMs inherit the hallucination problem of LLMs and may describe objects, attributes, and relations that are absent from or inconsistent with the input image. Simply providing more textual information may not effectively address these errors, since these models may under-utilize evidence in the middle of long inputs and could be distracted by irrelevant passages.

然而 MLLM 继承了 LLM 的幻觉问题，可能描述出输入图像中不存在或与之不一致的物体、属性和关系。**简单地提供更多文本信息未必能有效解决这些错误——**因为这些模型可能对长输入中间部分的证据利用不足，也可能被无关段落干扰。

2.2 多模态 RAG：早期工作用联合训练的编码器检索图文对。对于含丰富视觉信息的文档，出现了两条主要策略：一条**直接在视觉内容上操作**，用视觉-语言检索器编码渲染后的文档页面，从而在检索中保留版式和视觉信息；另一条**用解析器把文档转成文本**再做标准文本检索，代价是丢失细粒度的视觉信息，好处是更高效、与模态无关。

Nevertheless, these approaches rely on flat retrieval of independently scored units, without explicitly modeling the relations among the retrieved information.

尽管如此，**这些方法依赖对「各自独立打分的单元」做扁平检索，没有显式建模被检索信息之间的关系。**而且拼接起来的证据未必能被模型充分利用。

2.3 GraphRAG：通过在结构上检索来解决一般 RAG 的碎片化和冗余问题。现有方法分两类：一类在非结构化语料上**归纳出一张图**，然后在不同粒度上检索（从社区、摘要树到关系路径）；另一类假定已有一张**人工策展的图**，聚焦于在它上面推理（路径规划、agent 式探索、子图选择等）。**两类都仍以文本为中心。**

Nevertheless, these methods majorly share one indexing pipeline in which visual and textual graphs are produced independently and merged only at a later fusion stage, so the textual context accompanying visual-to-graph conversion is either absent or restricted to a fixed window of positionally adjacent chunks. Context is thus selected by proximity rather than relevance.

尽管如此，**这些方法基本共用一条索引流水线：视觉图和文本图独立产生，只在后面的融合阶段才合并，**因此伴随「视觉转图谱」这一步的文本上下文，要么根本没有，要么被限制在一个由位置相邻的块构成的固定窗口内。**因此上下文是按邻近程度而不是按相关程度选取的——**它收进了无关的邻近文本，却忽略了文档别处一句明确讨论该图的话，这就造成了我们要处理的模态鸿沟。

2.4 多模态知识图谱 (分类见「背景补充」一节)。这篇最后总结：现有工作在处理视觉信息时往往只利用有限的文本上下文，可能不足以捕捉视觉元素与文本信息之间的语义联系。与以往工作不同，我们给出文本上下文的细粒度定义，并研究不同形式的文本上下文如何支撑 MMKG 构建。

三、背景与问题定义

3.1 基于 MMKG 的 RAG

给定一份多模态文档 D，用 MinerU 这类解析器抽出它的文本内容 T 和视觉元素集合 $I = \{I_1, \dots, I_N\}$ 。系统基于 D 构建一个 MMKG，即 $G_M = (V, E)$ ，V 和 E 分别是实体集和关系集。给定用户查询 q，从 G_M 中检索出相关的多模态知识，作为外部证据提供给 LLM 或 MLLM 来产生更准确的回答：

$$\hat{y} = F_model(q, R(q, G_M)) \quad \dots (1)$$

其中 R 表示检索器， $\hat{y}$ 是生成的答案。

3.2 多模态知识图谱的构建

Eq. (1) highlights two key factors that influence the quality of the final answer: the retriever R and the underlying knowledge graph G_M on which it operates. Since retrieval can only operate on the knowledge represented in the graph, the quality of G_M plays a fundamental role.

公式 (1) 凸显了影响最终答案质量的两个关键因素：**检索器 R**，以及它所作用的**底层知识图谱 G_M** 。由于检索只能在图中已表示的知识上进行， G_M 的质量起着根本作用。因此我们聚焦于从文档 D 构建 G_M ，而不是检索阶段。

现有方法分模态处理再合并：从 T 构建文本图 G_t ，从 I 构建图像图 G_v ，两者相互独立，然后整合成统一的 MMKG：

$$G_M = f_fusion(G_t, G_v) \quad \dots (2)$$

其中 f_fusion 是模态融合模块，它能识别出 G_v 和 G_t 中指代同一底层对象的实体并配对。**这篇沿用已有工作的融合流程并全程保持不变**：对每个视觉实体，从邻近文本块中收集候选文本实体并通过聚类划分，再由 LLM 从最相关的簇中识别出它的文本对应物；未匹配的视觉实体用文本上下文补充，最终用得到的跨模态对齐把图像图和文本图融合成统一的 MMKG。

Among the two branches, textual graph construction inherits the well-established pipeline of text-based GraphRAG, whereas vision-based graph construction encounters a greater challenge, as visual information is more susceptible to information loss during its transformation into graph representations.

在两条分支里，**文本图构建沿用了成熟的纯文本 GraphRAG 流水线，而视觉图构建面临更大挑战**——因为视觉信息在转换成图表示的过程中更容易丢失。视觉信息也需要被转换成实体和关系，而在这一过程中未被捕捉到的信息，对后续阶段（包括模态融合和信息检索）就不再可用。

Building G_v , however, is not a purely visual problem. Although the pipeline above treats each modality largely independently, a figure or table can rarely be interpreted on its own, since much of its meaning is carried by the prose that introduces and discusses it.

然而构建 G_v 并不是一个纯视觉问题。 尽管上述流水线基本上把各模态独立对待，**一张图或一个表格很少能被单独解释**，因为它的大部分含义是由「引入并讨论它的那些文字」承载的。

于是问题被定义为：**给定含文本内容 T 和视觉元素集合 I 的多模态文档 D ，如何为每个视觉元素从 T 中建立有意义且全面的文本上下文，并有效利用这种上下文来构建质量更高的 MMKG？**

四、方法：多粒度上下文与多阶段注入

4.1 多粒度文本上下文

上下文由两类互补信息构成，区别在于**它们取自 T 的哪一部分**：**局部上下文**捕捉与特定视觉元素绑定的细粒度细节；**全局上下文**在粗粒度上捕捉整篇文档的内容。

4.1.1 局部上下文

For each visual element I_i , we define its local context as textual information drawn from a specific region of T . We draw it from two complementary sources: the text that immediately surrounds a visual element, and the text that explicitly refers to it.

对每个视觉元素 I_i ，我们把它的局部上下文定义为「取自 T 中某个特定区域的文本信息」。局部上下文聚焦于文档的具体细节而非整体内容，**这对理解视觉信息尤其重要，因为图和表往往无法被孤立地充分解释**。我们从两个互补的来源取它：**紧邻**该视觉元素的文本，以及**明确引用**它的文本。

A visual element is typically introduced at one point of a document and then discussed in detail elsewhere, and the discussing text is often far more informative about it than its positional neighbors.

一个视觉元素通常在文档的某处被引入，然后在别处被详细讨论，而讨论它的那段文字往往比它的位置邻居信息量大得多。 利用文档解析时得到的标识符 $id(I_i)$ ，我们把 I_i 的**引用集合**定义为：

$$R_i = \{ s \in S \mid id(I_i) \text{ 在句子 } s \text{ 中被提及} \} \quad \dots (3)$$

也就是所有包含对 I_i 的文本引用的句子，比如「Figure 3 展示了……」。注意 R_i 是由提及而非由位置确定的。因此它的元素在文档中可能离 I_i 很远。

局部上下文的四个成分（第一个沿用已有工作并始终保留，后三个基于引用集合、以不同范围和**信息密度**描述同一批引用）：

- **周围文本**：紧邻 I_i 之前和之后的文本块。已有工作已证明把图像周围的文本作为其有意义的上下文是重要的，因为视觉元素和它相邻的叙述通常是一起被引入的。

- **参考句**：对 R_i 中的每个句子，取该句加上紧邻它的前一句和后一句。这是基于引用的上下文最简洁的形式，提供直接描述或补充该图信息的细粒度文本。
- **参考段落**： R_i 中那些句子所在的完整段落。**段落覆盖面更广**，提供参考句本身可能没有完全涵盖的额外背景和支撑信息，**代价是信息密度更低**。
- **参考段落摘要**：由大模型对参考段落生成的摘要，设计目标是保留与目标图像相关的信息、同时滤掉原段落中的冗余内容。**它因此处于前两者之间：追求段落的覆盖面，同时把密度做到接近句子。**

Since the three reference-based components provide contextual information for the same references at different granularities, they are considered alternative context configurations rather than being used jointly.

由于这三个基于引用的成分是对同一批引用在不同粒度上提供上下文，它们被视为可互相替代的配置，而不是同时使用。

局部上下文因此定义为「周围文本 + 三选一的引用式成分」。**最优粒度并不是一目了然的**——更宽的上下文可能提供更多支撑信息，但也可能稀释掉与该图最相关的信息。因此我们把粒度当作 CEMMKG 的一个设计维度，用实验来刻画它的影响。

Because a visual element may be referenced multiple times throughout a long document, R_i can become large, resulting in a correspondingly long context. As overly long context degrades how effectively (M)LLMs utilize the supplied evidence, we bound the local context in two ways.

由于一个视觉元素在长文档中可能被多次引用， R_i 可能变得很大，导致上下文相应地很长。**由于过长的上下文会降低模型利用所给证据的有效程度，我们用两种方式给局部上下文设界：**

1. 只保留文档顺序上靠前的若干引用位点，并且在融合阶段用的比图转图谱阶段更少——因为对齐只需要足够的文字来命名涉及的实体。
2. 分别给基于引用的成分和全局上下文设置长度上限，使得两者谁也不能把对方挤掉。

4.1.2 全局上下文

全局上下文定义为从整个文本内容 T 导出的文本信息，指的是一种**文档级的语义表示**，捕捉整篇文档的统摄性知识。两种可选形式：

- **摘要 (Abstract)**：从 T 中抽取的文档原有摘要，直接用作全局上下文。
- **文档总结 (Document Summary)**：由大模型对全部文本内容 T 生成的总结，把散布在全文各处的信息整合成一个统一的总结。

Unlike the local components, which are used jointly, the two global forms are interchangeable and are determined by document availability. Since many real-world documents fall outside the academic domain and may not contain an abstract, the latter case is common in practice.

与「联合使用」的局部成分不同，**两种全局形式是互换的，取决于文档有没有摘要**。由于许多真实世界的文档不属于学术领域、可能没有摘要，后一种情况（用大模型生成总结）在实践中很常见。

注意全局上下文定义在文档层级，因此被 D 中所有视觉元素共享；而局部上下文是每张图专有的。

4.2 多阶段上下文利用

As illustrated in Figure 4, an MMKG is assembled along two branches that meet at modality fusion, and the constructed context can be injected at the two points marked by $\oplus$. Rather than incorporating the constructed context only once, we propose multi-stage context utilization, where different construction stages utilize different components according to their specific objectives.

MMKG 沿两条分支组装、在模态融合处汇合，构建好的上下文可以在图中标记为 $\oplus$ 的两个点注入：**视觉元素被转成图像图谱时**，以及**该图谱与文本图谱融合时**。我们提出**多阶段上下文利用**——不同的构建阶段**根据各自的目标使用上下文的不同成分**：

- **图转图谱**：图像本身的信息和文档级上下文都有助于更全面地理解视觉元素，因此这一阶段提供**完整上下文**。
- **融合阶段**：目标是在图像导出的实体和文本导出的实体之间建立对应关系，因此**只提供局部上下文**，它为实体对齐提供更聚焦的证据。

4.2.1 上下文增强的图转图谱构建

现有方法把视觉元素 l_i 的图像图谱构建为 $G_{v,i} = f_v(l_i, C_i)$ ，其中 f_v 是图转图谱模块（比如 MMGraphRAG 的 Image2Graph 模块）， C_i 是有限的周围文本。

We leave the backbone f_v unchanged and replace only its context argument with the constructed context. Inside f_v , the context conditions the MLLM that describes the visual element before entities and relations are extracted from that description, so a richer context propagates into every node and edge.

我们保持骨干 f_v 不变，只把它的上下文参数替换成构建好的上下文。 在 f_v 内部，上下文对「描述该视觉元素的 MLLM」起条件作用，而实体和关系是从那段描述里抽取的，**所以更丰富的上下文会传播到图谱的每一个节点和边上**。我们的修改因此被限制在「提供给骨干的上下文」这一处。

两级上下文提供互补的语义信息：**局部上下文提供与目标图像直接相关的细粒度证据**，支撑对图像特有概念和关系的解释；**全局上下文提供文档级的语义参照**，把图像与文档的更大主题连接起来。

4.2.2 上下文引导的多模态知识图谱融合

统一的 MMKG 由下式得到：

$$G_M = f_{\text{fusion}}(G_t, \{G_{v,i}\}, \{c^L_i\}) \quad \dots (7)$$

相对公式 (2) 的一般形式，**局部上下文被作为额外的参数提供进去**。回顾 3.2 节， f_{fusion} 把每个视觉实体与「从其关联文本上下文导出的候选文本实体」对齐。在骨干方法里这个上下文被限制在 l_i 周围的文本块，

可能排除掉散布在文档别处的相关信息。因此我们用设计好的局部上下文来增补可用上下文，使得更广范围的相关文本实体能被纳入候选对齐。最终对齐仍由 LLM 按原融合流程确定。

跨两个阶段，构建好的上下文承担两个互补角色：[在图转图谱时支撑对每个视觉元素更全面的理解](#)；[在模态融合时为「把视觉实体与其文本对应物对齐」提供相关的文本证据](#)。

五、实验

5.1 实验设置

数据集：在 MMLongBench-Doc 上评估。但该基准中有一部分问题要么不可回答，要么无需视觉信息即可回答；同时在完整基准上做一次实验非常耗时，评估所有模型配置不现实。因此挑选了一个名为 **VisionHeavy** 的子集，标准两条：

1. 文档应当是**视觉密集**的——其可回答问题中，需要图等视觉证据的比例要高。
2. 文档应当含有**非局部的证据依赖**——回答其问题需要把视觉元素与「超出其邻近文本上下文」的证据连接起来。

得到的 VisionHeavy 子集含 106 道题。在可回答问题中，**80.2%** 需要视觉信息，**43.2%** 依赖跨多页分布的信息。该子集覆盖原基准七种文档类型中的六种：学术论文、行政与工业文件、宣传册、指南、研究报告、教程/工作坊材料。

基线：**直接推理**（多模态大模型直接基于所给文档回答）；**基于 MMKG 的 RAG**（RAG-Anything 和 MMGraphRAG）。

评估指标：按 MMLongBench-Doc 已发布的评估协议，先用 Llama-3.1-70B-Instruct 从每个自由形式的回答中抽出规范答案，再套用已发布的类型感知确定性打分器。报告**软准确率**（官方基准准确率）和一个派生的**严格全额准确率**（只有得满分才算对）。**小数分来自对字符串和列表类答案适用的 ANLS，而整数、浮点和精确匹配情形按 0/1 打分。**

实现细节：实验在配四块 NVIDIA A6000 48GB 显卡的服务器上进行，用 MinerU 解析 PDF。

以 MMGraphRAG 为骨干时：**Qwen2.5-72B-Instruct-AWQ** 做文本知识图谱构建、文本摘要和文本生成；**InternVL2.5-38B-MPO-AWQ** 生成图像描述并做多模态问答；**stella-en-1.5B-v5** 编码图节点和用户查询；**Llama-3.1-70B-Instruct** 从生成的回答中抽取最终答案。所有生成阶段用确定性解码（temperature = 0, top-p = 1），答案抽取器最大输出 1024 token。**图像描述最多保留五个显式文本引用，图谱融合最多保留三个。**

We modify the retrieval stage in MMGraphRAG by introducing a visual selection policy that prioritizes explicitly referenced Figure or Table identifiers. When no such reference is available, BM25 is used to identify visuals with strong lexical matches to the query; otherwise, the original dense graph retrieval results are retained.

我们修改了 MMGraphRAG 的检索阶段，引入一个优先选取「被显式引用的 Figure 或 Table 标识符」的视觉选择策略。当没有这样的引用时，用 BM25 找出与查询有强词面匹配的视觉元素；再没有则保留原本的稠密图检索结果。

对 RAG-Anything，保留其原生的混合模式检索，骨干模型用 GPT-4o-mini。为保证公平比较，对每个骨干框架，所有 CEMMKG 上下文配置使用相同的检索流程和超参数。

5.2 多模态 GraphRAG 性能

表 1 (VisionHeavy 子集，严格全额准确率 / 官方软准确率，%)：

方法	额外局部 上下文	全局上 下文	Figure	Table	Chart	Misc	总体
直接推理	—	—	6.25 / 6.25	4.00 / 4.00	0.00 / 0.00	21.95 / 21.95	11.32 / 11.32
MMGraphRAG	—	—	6.25 / 6.25	20.00 / 22.46	31.25 / 31.25	34.15 / 34.15	23.58 / 24.17
本文 + MMGraphRAG	参考段落	文档级	12.50 / 12.50	16.00 / 16.00	31.25 / 31.25	26.83 / 26.83	22.64 / 22.64
本文 + MMGraphRAG	参考段落 摘要	文档级	15.63 / 15.63	24.00 / 26.46	25.00 / 25.00	43.90 / 46.76	31.13 / 32.82
本文 + MMGraphRAG	参考句	文档级	21.88 / 24.70	24.00 / 24.00	31.25 / 31.25	51.22 / 54.01	34.91 / 36.84

(表中按视觉内容类型分列以便细粒度比较，每道题可能同时带有多个类型标签；Misc 是不带 Figure、Chart、Table 任一标签的其余问题。)

Among all evaluated configurations, incorporating the reference sentence(s) as additional local context together with document-level global context delivers the best overall performance.

在所有评估的配置中，把参考句作为额外的局部上下文、配合文档级全局上下文，取得了最好的总体性能——严格准确率 34.91%、软准确率 36.84%，大幅超过 MMGraphRAG 的 23.58% 和 24.17%。用参考段落摘要时表现也不错 (31.13% / 32.82%)。

However, we can observe that directly using the full reference paragraph(s) as additional local context achieves an overall soft accuracy of only 22.64%, even lower than the 24.17% of MMGraphRAG. This result suggests that simply introducing more textual context does not necessarily lead to better performance.

然而我们可以观察到，直接把完整的参考段落用作额外局部上下文，总体软准确率只有 22.64%，甚至低于 MMGraphRAG 的 24.17%。这个结果表明：简单地引入更多文本上下文，并不必然带来更好的性能。

可能的原因是完整段落可能包含与相应视觉内容只有微弱关联的信息，在 MMKG 构建过程中引入了无关或冗余的上下文，从而影响视觉信息处理和模态融合两方面。**这一观察表明，局部上下文的有效性不仅取决于所提供上下文信息的数量，也取决于它的粒度和信息密度。**

5.2.2 分类型的表现

参考句上下文在 **Figure 类问题上带来最大提升**，软准确率从 6.25% 升到 24.70%；在 **Chart 类问题上与 MMGraphRAG 持平**（同为 31.25%）。**Table 类问题上，参考段落摘要取得最好的软准确率 26.46%**，对比 MMGraphRAG 的 22.46%。这些结果表明不同的文本上下文设计，对不同类别的视觉信息可能带来不同的收益。

Interestingly, the proposed context design also yields substantial improvements on the Misc questions, increasing soft accuracy from 34.15% to 54.01%. One possible explanation is that the designed contextual information enhances not only the representation of individual image-based graphs but also their integration with textual knowledge.

有意思的是，所提出的上下文设计在 Misc 问题上也带来了大幅提升，软准确率从 34.15% 升到 54.01%、严格准确率从 34.15% 升到 51.22%。**注意 Misc 指的是不带 Figure、Chart、Table 标签的问题**，但这些问题仍可能涉及多模态信息。**一种可能的解释是：**设计的上下文信息不仅增强了单个图像图谱的表示，也增强了它们在 MMKG 构建过程中与文本知识的整合，因此这些改进也可能惠及那些依赖文本知识或跨模态语义联系的问题，即使它们并不显式需要视觉内容。

5.3 对不同方法的适用性

表 2（RAG-Anything 为骨干，跨页引用子集，严格 / 软准确率 %）：

方法	额外局部上下文	严格 / 软
RAG-Anything	—	28.89 / 36.18
本文 + RAG-Anything	参考段落	28.89 / 34.49
本文 + RAG-Anything	参考段落摘要	31.11 / 33.13
本文 + RAG-Anything	参考句	35.56 / 41.12

集成方式是：在 RAG-Anything 的视觉表示阶段，用文档级总结和可用的显式参考句增补每张图或表的描述提示词，然后再生成结构化视觉描述，所得描述再交给 RAG-Anything 原本的多模态图构建流水线。

Unlike MMGraphRAG, RAG-Anything already supplies each visual with native contextual text that can span neighboring pages. Therefore, to better evaluate the effectiveness of the designed textual context, we select from VisionHeavy a subset of questions that require cross-page references.

与 MMGraphRAG 不同，RAG-Anything 本身即为每个视觉元素提供了可跨越相邻页面的原生上下文文本。 因此为更好地评估所设计文本上下文的有效性，我们从 VisionHeavy 中挑出一个**需要跨页引用**的问题子集。

We also observe a trend consistent with MMGraphRAG: performance improves progressively from reference paragraphs, to their LLM-generated summaries, and further to reference-sentence context.

我们还观察到与 MMGraphRAG 一致的趋势：[性能从参考段落、到它们的大模型生成摘要、再到参考句上下文，依次递进地提升。](#)

六、结论

In this work, we systematically investigate the role of textual context in GraphRAG-oriented MMKG construction. We introduce CEMMKG, a framework that systematically defines and utilizes textual context in both visual information processing and modality fusion.

在这项工作中，我们系统研究了文本上下文在「面向 GraphRAG 的 MMKG 构建」中的作用。我们引入 CEMMKG——一个在[视觉信息处理](#)和[模态融合](#)两方面系统地定义并利用文本上下文的框架。具体而言，CEMMKG 从互补的角度为视觉元素设计文本上下文，包括不同粒度的局部上下文，以及基于不同文档级表示的全局上下文。

Overall, our findings highlight the importance of explicitly considering and leveraging contextual information when constructing MMKGs for multimodal Graph RAG. Future work could extend our framework to a broader range of modalities, such as video and audio.

总体而言，[我们的发现凸显了在为多模态 GraphRAG 构建 MMKG 时，显式考虑并利用上下文信息的重要性](#)。未来工作可以把该框架扩展到更广的模态范围，比如视频和音频，并研究不同模态组合下上下文信息应当如何定义和利用。

参考链接

- [arXiv:2608.25986](#) — 本文原文 (cs.AI, 2026-08-26 提交)
- [MMLongBench-Doc](#) — 本文的评估基准，VisionHeavy 子集从它挑出
- [MinerU](#) — 本文用的 PDF 解析器，把文档拆成文本、表格、图、公式
- [RAG-Anything](#) — 对比方法之一，也是第二个骨干框架
- [MMGraphRAG](#) — 主要骨干框架，本文沿用它的融合流程并保持不变
- [Qwen2.5-72B-Instruct](#) — 文本知识图谱构建与文本生成
- [InternVL2.5-38B-MPO](#) — 生成图像描述与多模态问答