

用受控词表把大模型的幻觉挡在门外，代价是一整类关系抽不出来

pro-team at LLMs4OL 2026: RAG and Vocabulary-Constrained Filtering for Ontology Learning

源文档：Shivam Mishra、Dhannu Ram Meena、Muneendra Ojha、Krishna Pratap Singh、Kuldeep Singh（[印度信息技术学院阿拉哈巴德分校](#)信息技术系）。arXiv 2608.27101v1, 2026-08-27 提交。发表于 LLMs4OL 2026——第 3 届「大模型用于本体学习」挑战赛，与第 25 届国际语义网大会（ISWC）同期。这是一篇参赛系统报告，不是方法论文。代码：

https://github.com/shivam07041/team-pro-integration_OntoLearner_Submission 本文的「全文翻译」一节按原文小节推进，覆盖摘要、§1 引言、§3 方法（问题定义、稠密语义检索、提示构造、混合抽取与词表约束过滤、输出）、§4 实验与结果（Task B、Task A、非分类关系瓶颈的深入分析）、§5 结论与「局限」一节。§2 相关工作的文献综述、图 1 架构图的版式细节、参考文献条目不译。

核心内容

Q: LLMs4OL 是什么？这篇在里面做了什么？ A: LLMs4OL 是一个本体学习（Ontology Learning）挑战赛，考的是「能不能让大模型自动从文本里把本体建出来」。第 3 届把任务重组成三条赛道：**Task A 旗舰任务**（从原始文本端到端建出一个初级本体）、**Task B 复用任务**（给一个已有的部分本体，增量扩展它）、Task C 分类法任务（跨领域分类法归纳）。这篇做了 A 和 B 两条。

Q: 本体学习为什么难？ A: 作者列了三条大模型在这件事上的具体毛病：**幻觉出不属于预定义词表的术语、输出格式不一致、偏好层级关系而冷落联想关系**。第三条最要命——大模型在预测「A 是 B 的一种」这类层级关系上表现不错，但在识别需要更深上下文理解的非分类关系上差得多。

Q: 他们的做法是什么？ A: 一条完全离线的 RAG 流水线，四个环节：

- 稠密语义检索**：用 `all-MiniLM-L6-v2` 把每篇训练文档编码成向量，来了新文档就按余弦相似度取最像的几篇当上下文示例。Task A 取 top-5，Task B 取 top-2。
- 左截断的上下文管理**：模型是 `Qwen2.5-72B-Instruct`，上下文窗口本来有 32,768 token，但他们故意限制到 3,072。超长时从左边（最老的检索示例）开始丢，保证系统指令和末尾的目标查询完整无损。

3. 邻近度模式匹配（仅 Task B）：扫描文档找预定义术语和类型在句子级别的共现，词法距离在高置信阈值内就判定一条 `instance-of` 关系。这一步是召回补丁，用来补生成式模型漏判的分类。
4. 词表约束过滤（仅 Task B）：一条候选三元组 `[h, r, t]` 只有在至少一个端点属于该样本的已知词表时才保留——词表 = 给定的术语 $\cup$ 给定的类型 $\cup$ 初始本体里已出现的全部实体。严格精确匹配，端点对不上就直接丢弃，不做词法修补。

Q：为什么 Task A 不用词表约束？ A：因为旗舰任务根本不提供封闭候选词表，没有东西可约束。这个对照本身就是本文最有价值的部分。

Q：效果如何？ A：Task B 很强，Task A 明显弱：

	Task B（有词表）	Task A（无词表）
图相似度（精确匹配）	0.8480	0.5353
图相似度（语义匹配）	0.8692	0.7416
两者之差	仅 0.0212	0.2063
术语类型标注 F1	0.9200	0.4956
分类法发现 F1	0.8540	0.5926

Q：那个 0.0212 的差值说明了什么？这是全文最关键的一个数字。 A：精确匹配要求字符串完全一致，语义匹配允许「意思对但字面不同」。两者差得越小，说明模型输出的字面形式越贴合标准答案。Task B 只差 0.0212，证明词表约束确实把词表外的幻觉挡住了；而 Task A 差了 0.2063——模型抓到了概念，但复现不出所要求的确切字面形式。

Q：代价是什么？ A：非分类关系抽取 F1 在两条赛道上都是 0.0000。一条都没抽出来。

Q：为什么会是零？ A：作者的解释很诚实，分两层。直接原因是他们自己的设计：关系映射指令定义了一个封闭的六元关系集合——`is-a`、`instance-of`、`disjoint with`、`equivalent class`、`part of`、`has part`，全部是分类与类型关系。这个选择是经验性的：早期探查训练数据发现层级关系压倒性地占多数，为了防止大模型幻觉出五花八门的谓词，就把生成空间限死了。结果是模型压根没有任何机制可以吐出一个非分类关系标签。

第二层作者自己也不确定：这个限制到底压掉了多少性能，取决于金标数据里真正的非分类关系有多普遍——而他们没有金标关系类型分布的完整统计，所以无法把「提示设计的局限」和「基准数据本身的性质」分开。他们把 0.0 作为观察结果报出来，并把封闭关系词表标为「从我们这条流水线能得到的、最直接可验证的解释」。

背景补充 / 点评

这篇的分量要先说清楚：它是一篇挑战赛参赛系统报告，不是方法创新论文。用的全是现成组件（Qwen2.5-14B-Instruct、MiniLM-L6-v2、RapidFuzz），贡献是工程组合与一份诚实的错误分析。作者自己在「局限」一节里承认没做消融实验——检索、提示配置、规则抽取三个部件各自贡献多少，「难以明确量化」；3,072

token 的截断上限和 top-5/top-2 的示例数量，都是「基于硬件约束和初步开发集评估经验性设定的，不是网格搜索优化出来的」。

所以读它不该读方法，该读那个 0.0000。

我的判断——这篇真正的价值在于它把一个取舍量化了。 受控词表这件事的直觉好处很清楚：挡住幻觉、保证输出可用。但它的代价一直是模糊的、口头的。这篇给了一组可以并排看的数字：

- **好处有多大：**精确匹配与语义匹配之差从 0.2063 压缩到 0.0212，术语类型标注 F1 从 0.4956 提到 0.9200
- **代价有多大：**一整类关系的 F1 从未知变成确定的 0

关键在于这两个数字来自同一套流水线的两条赛道，唯一的结构差别就是「有没有封闭词表」。这是一个近乎干净的对照。

留白在哪：三处，作者认了两处半。第一，**没有消融**，所以「词表约束贡献了多少」严格讲仍是推断而非测量——那 0.0212 也可能部分来自邻近度模式匹配那个召回补丁。第二，**0.0000 的归因未能封闭**：作者明确说分不开「我们的提示限制」与「基准里本来就没多少非分类关系」。第三，**后处理只过滤了实体词表，没有过滤谓词**——他们的理由是把标准化提前到生成阶段做了（强制把「type of」「category of」都映射成 `is-a`），所以不需要事后再滤，但这也意味着**如果生成阶段的映射错了，后面没有任何一道关卡能拦住**。

这里有一个我认为作者没有点破、但数据摆在那里的东西：Task B 的分类法发现精确率 0.9369、召回 0.7846，**精确率比召回高出 15 个百分点**；术语类型标注则是精确率 0.9324、召回 0.9079，两者接近。这说明词表约束的代价不是均匀分布的——它在「发现层级关系」上砍掉的召回，远多于在「给术语标类型」上砍掉的。层级关系需要两个端点同时在词表里才更可能被留下，而术语标注只要一个端点在就行。**约束的严格程度随任务的元数增加而放大。**

对我的启示：这篇几乎是为我正在做的**受控词表**（`docs/spec/2026-08-23-受控词表-proposal.md`）写的一份提前的失败报告。

我们的五张清单——动作、能力类别、认知动作、内容条件、教学手段——本质上就是**封闭关系/取值词表**。这篇给的警告非常具体：**闭词表会让某一整类东西彻底消失，而且消失得无声无息**（F1 是 0，不是低）。

对应到我们的设计上，有三处应当立刻检查：

第一，「动作」那张清单会不会重演这个 0.0000。 它只有六条左右（苦于、掌握、适用于……），而真实语料里的动作是开放的——GUMO 那个例子「Peter 在教学 / 很喜欢教学 / 很懂教学」，三句话对象都是 `teaching`，**差别全在动词上**。如果动作被限死在六条里，那些落在六条之外的关系会像这篇的非分类关系一样，**不是被标错，是根本不存在**。我们的 anchors（真实场景）已经定了「动作开放」，那是对的；但另外四个子画像用的是闭表。

第二，验收指标要按「格子」分开看，不能只看总体。 这篇如果只报「Task B 语义图相似度 0.8692」，那个 0.0000 就被完全掩盖了。**总体指标高，掩盖不了某一类为零。** 我们的受控词表提案里目前没有覆盖度验

收——这正是我昨天给同事方案提的第六条意见（「词表没有覆盖度验收，拒收的值没有去向」），**现在这篇论文给了那条意见一个真实案例。**

第三，被拒收的值必须有去向。这篇的过滤是「端点对不上就直接丢弃，不做词法修补」。丢弃是对的（不该猜），但丢到哪里去了没有记录。如果记录下来，就能回答「该不该给词表加一条」——而现在他们只能说「我们不知道基准里有多少非分类关系」。这个信息本来是可以攒下来的，只是没攒。

还有一条方法上的小东西值得抄：**左截断**。当提示词超长时从最老的检索示例开始丢，保证系统指令和目标查询完整。这比「整体截断」或「右截断」都合理，因为**指令是不能丢的那部分**。我们的抽取器提示词也在变长（PM 的词表在往里塞），这条现在可以直接用上。

文中金句

"By forcing the LLM to map all textual relationships to this strict set, we implicitly handled relational redundancies directly during the generation phase... However, under this strict prompt design, the model had no mechanism by which to emit a non-taxonomic relation label." 通过强制大模型把所有文本关系映射到这个严格集合，我们在生成阶段就隐式地处理掉了关系冗余……**然而在这套严格的提示设计下，模型没有任何机制可以吐出一个非分类关系标签。**

"Because the generative outputs were strictly filtered against the predefined canonical vocabulary, the delta between the Exact Match Graph Similarity (0.8480) and Semantic Match Graph Similarity (0.8692) is remarkably narrow. This confirms that the model successfully avoided out-of-vocabulary hallucinations." 由于生成结果被严格地对照预定义的规范词表做了过滤，精确匹配图相似度（0.8480）与语义匹配图相似度（0.8692）之间的差值**窄得引人注目**。这证实模型成功避开了词表外的幻觉。

"This is a strict exact-match membership filter; a triple whose endpoints do not exactly match a known vocabulary entry is dropped outright rather than lexically repaired." 这是一个严格的精确匹配成员过滤器；**端点无法与已知词表条目精确匹配的三元组会被直接丢弃，而不是做词法修补。**

"Without a full accounting of the gold relation-type distribution, we cannot fully separate our prompt-design limitation from a property of the benchmark data. We report the 0.0 score as an observed result and flag the closed relation vocabulary as the most direct, verifiable explanation available from our pipeline." 在没有金标关系类型分布完整统计的情况下，**我们无法把提示设计的局限与基准数据本身的性质完全分开**。我们把 0.0 分作为一个观察结果报出，并把封闭关系词表标为**从我们这条流水线能得到的、最直接可验证的解释**。

覆盖范围：摘要、§ 1 引言、§ 3.1 问题定义、§ 3.2 稠密语义检索、§ 3.3 提示构造与本体生成、§ 3.4 混合抽取与词表约束过滤、§ 3.5 输出生成、§ 4.1 Task B 结果、§ 4.2 Task A 结果、§ 4.3 非分类关系抽取瓶颈的深入分析、§ 5 结论、「局限」一节。§ 2 相关工作的文献综述、图 1 架构图版式、参考文献条目不译。

摘要 Abstract

Ontology learning from text remains challenging despite significant progress in Large Language Models (LLMs), which can hallucinate domain terms, produce inconsistent formats, and favor hierarchical over associative relations.

尽管大语言模型已有长足进步，**从文本中做本体学习仍然困难**——模型会幻觉出领域术语、产出不一致的格式、并且偏好层级关系而非联想关系。

In the LLMs4OL 2026 Challenge, we address both the End-to-End Flagship Task (Task A) and Ontology Extension Reuse Task (Task B) using an offline retrieval-augmented few-shot prompting pipeline. Our system employs Qwen2.5-14B-Instruct with all-MiniLM-L6-v2 for demonstration retrieval, selecting the top-5 examples for Task A and top-2 for Task B. A left-truncated context-windowing strategy preserves task instructions within long prompts.

在 LLMs4OL 2026 挑战赛中，我们用一条**离线的检索增强少样本提示流水线**同时处理**端到端旗舰任务 (Task A) 与本体扩展复用任务 (Task B)**。系统使用 Qwen2.5-14B-Instruct，配合 all-MiniLM-L6-v2 做示例检索，Task A 取前 5 个示例、Task B 取前 2 个。**左截断的上下文窗口策略**在长提示中保住了任务指令。

For Task B, generated triples undergo deterministic vocabulary-constrained filtering, retaining triples when at least one endpoint belongs to the sample's closed term/type vocabulary and removing duplicates of the initial ontology.

对 Task B，生成的三元组要经过**确定性的词表约束过滤**：当至少一个端点属于该样本的封闭术语/类型词表时才保留，并移除与初始本体重复的三元组。

The approach achieves Semantic Graph Similarity of 0.8692, Term-Typing F1 of 0.9200, and Taxonomy Discovery F1 of 0.8540 on Task B, while Task A achieves 0.7416 Semantic Graph Similarity. However, no non-taxonomic relations are extracted, highlighting limitations of closed, taxonomy-oriented relation vocabularies.

该方法在 Task B 上取得语义图相似度 0.8692、术语类型标注 F1 0.9200、分类法发现 F1 0.8540；Task A 上语义图相似度 0.7416。**然而，没有抽取任何非分类关系，这凸显了封闭的、面向分类法的关系词表的局限。**

引言：三条具体的毛病 Introduction

Constructing and maintaining ontologies remains a labor-intensive process that requires substantial domain expertise and continuous refinement as domain knowledge evolves. With the rapid growth of scientific literature and unstructured textual resources, manual ontology engineering has become increasingly difficult to scale.

构建与维护本体仍然是**劳动密集**的过程，需要大量领域专业知识，并随领域知识演进而持续精化。随着科学文献与非结构化文本资源的快速增长，**手工本体工程越来越难以规模化**。

Despite the remarkable reasoning capability of modern LLMs, several challenges continue to limit their effectiveness in ontology learning. Generative models frequently produce hallucinated or lexically inconsistent outputs that do not belong to the predefined ontology vocabulary, thereby reducing semantic consistency and increasing post-processing complexity. Existing studies also show that while LLMs perform well on hierarchical taxonomy prediction, they remain considerably less effective at identifying complex semantic and non-taxonomic relationships that require deeper contextual understanding. Furthermore, retrieval-based prompting often requires long contextual prompts containing multiple demonstrations, increasing the likelihood of context-window truncation and loss of important task instructions during inference.

尽管现代大模型推理能力出色，仍有几项挑战限制它们在本体学习上的效果：

- **生成式模型常常产出幻觉的、或词法不一致的输出**，这些输出不属于预定义的本体词表，从而降低语义一致性、增加后处理复杂度。
- 已有研究表明，**大模型在层级分类法预测上表现良好，但在识别需要更深上下文理解的复杂语义与非分类关系上，效果差得多**。
- 基于检索的提示往往需要包含多个示例的长上下文提示，**增加了上下文窗口截断、以及推理时丢失重要任务指令的可能**。

（第三条是很实际的工程观察：为了给模型更多示例而把提示撑长，结果反而把指令挤掉了。这直接催生了后面的左截断策略。）

For tasks with closed-world assumptions, we introduce a deterministic vocabulary-constrained filtering step that strictly evaluates generated outputs against the predefined ontology vocabulary using exact lexical matching, dropping any invalid triples.

对于**采用封闭世界假设**的任务，我们引入一个**确定性的词表约束过滤**步骤：用精确的词法匹配严格地对照预定义本体词表来评估生成结果，**丢弃任何无效三元组**。

方法一：问题定义 Problem Formulation

For the Flagship Task (Task A), the objective is to construct a primitive ontology represented as $O = \{(h, r, t)\}$, where h , r , and t denote the head entity, ontology relation, and tail entity.

对**旗舰任务 (Task A)**，目标是构建一个初级本体 $O = \{(h, r, t)\}$ ，其中 h 、 r 、 t 分别是**头实体**、**本体关系**、**尾实体**。

For the Reuse Task (Task B), an existing ontology O_{base} is provided together with new textual evidence. The objective is to infer only the ontology triples required to extend the existing ontology, rather than reconstructing it from scratch: $O_{final} = O_{base} \cup O_{new}$.

对**复用任务 (Task B)**，给定一个已有本体 O_{base} 和新的文本证据。目标是**只推断出扩展已有本体所需的那些三元组，而不是从头重建**：最终本体 = 已有本体 $\cup$ 新推断的三元组。

方法二：稠密语义检索 Dense Semantic Retrieval

Each training document is encoded with the sentence-transformers/all-MiniLM-L6-v2 model to obtain a fixed-length embedding. The semantic similarity between the input document and each indexed example is computed using cosine similarity. Training documents are ranked according to their similarity scores, and the most relevant examples are selected as in-context demonstrations.

每篇训练文档用 all-MiniLM-L6-v2 编码成定长向量。输入文档与每个已索引示例之间的语义相似度用**余弦相似度**计算。训练文档按相似度排序，**最相关的若干篇被选作上下文示例**。

The number of retrieved demonstrations is tuned separately per task: top-5 for Task A and top-2 for Task B. Task A retrieves more demonstrations because the flagship setting requires the model to jointly reason across term extraction, typing, taxonomy, and relation extraction from raw text with no provided vocabulary, so broader in-context coverage was found to help; Task B provides an explicit candidate vocabulary and a partial ontology as additional grounding context, so fewer demonstrations were needed while also keeping prompts shorter and reducing truncation risk.

检索示例的数量按任务分别调参：**Task A 取前 5，Task B 取前 2**。Task A 取得更多，是因为旗舰设定要求模型在**没有给定词表**的情况下，从原始文本里同时对术语抽取、类型标注、分类法、关系抽取做联合推理，**更宽的上下文覆盖被发现是有帮助的**；Task B 则提供了明确的候选词表和一个部分本体作为额外的接地上下文，**所以需要的示例更少，同时还能让提示更短、降低截断风险**。

Unlike static few-shot prompting, this retrieval strategy dynamically adapts the demonstrations to each input document, providing task-specific guidance without modifying the parameters of the underlying language model.

与**静态**少样本提示不同，这个检索策略为**每篇输入文档动态适配示例**，在不修改底层语言模型参数的前提下提供任务特定的引导。

方法三：提示构造与左截断 Prompt Construction

The system prompts explicitly guide the model's behavior. For Task A: "You are an expert ontology engineer. Extract ALL ontology triples from the passage. A triple is [subject, relation, object]... Copy each subject and object EXACTLY as it appears in the text." It also maps natural language phrases directly to a closed set of relations (e.g., "subclass of" maps to "is-a"). For Task B, the prompt enforces strict hierarchy constraints: "Predict only DIRECT parent relationships — connect a term to its MOST SPECIFIC correct type."

系统提示明确引导模型行为。Task A 的提示是：「你是一位本体工程专家。从这段文字中抽取**所有**本体三元组。一条三元组是 [主语, 关系, 宾语]……**逐字照抄**文中出现的每个主语和宾语。」它还把自然语言短语**直接映射到一个封闭的关系集合**（例如「subclass of」映射到「is-a」）。Task B 的提示则强制层级约束：「**只预测直接父级关系**——把一个术语连到它**最具体**的正确类型。」

Generation utilizes Qwen2.5-14B-Instruct in 16-bit precision with greedy decoding (sampling disabled) for deterministic outputs, a batch size of 10, and task-specific output budgets: 900 maximum new tokens for Task A and 320 for Task B.

生成使用 16 位精度的 Qwen2.5-14B-Instruct, **贪心解码（关闭采样）以获得确定性输出**, 批大小 10; 输出预算按任务定: Task A 最多 900 个新 token (以容纳更多三元组、防止最长的 10 个样本被截断), Task B 最多 320 个。

Although Qwen2.5-14B-Instruct supports a default context window of 32,768 tokens, we empirically restricted the maximum input length to 3,072 tokens. This threshold was selected to bound the Key-Value (KV) cache memory footprint and cap logits scaling spikes during batched inference on 80GB VRAM hardware. To ensure critical instructions were never lost, we employed a left-truncation strategy. If a dynamically constructed prompt exceeded 3,072 tokens, the oldest retrieved in-context demonstrations were dropped first, guaranteeing that the system instructions and the target query at the end of the prompt remained completely intact.

尽管 Qwen2.5-14B-Instruct 默认支持 32,768 token 的上下文窗口, **我们凭经验把最大输入长度限制到 3,072 token**。选这个阈值是为了约束 KV 缓存的内存占用、并在 80GB 显存硬件上的批量推理中抑制 logits 缩放尖峰。

为确保关键指令永不丢失, 我们采用左截断策略: 如果动态构造的提示超过 3,072 token, **最先丢掉的是最老的那些检索示例**, 从而保证系统指令与位于提示末尾的目标查询**完整无损**。

The generated response is parsed into ontology triples using a three-stage fallback parser: direct JSON parsing, regex extraction of the first well-formed array, and line-by-line regex recovery of quoted triples as a last resort. This improves robustness to minor formatting deviations without inferring or altering any content beyond what the model generated.

生成的响应用一个**三级回退解析器**解析成三元组: 直接 JSON 解析 → 正则抽取第一个格式良好的数组 → 最后手段是逐行正则恢复带引号的三元组。这提升了对轻微格式偏差的鲁棒性 (例如模型把 JSON 包在散文里), **同时不推断、不改动模型生成内容之外的任何东西**。

方法四：混合抽取与词表约束过滤 Hybrid Extraction and Vocabulary-Constrained Filtering

Task B provides each sample with an explicit closed vocabulary of candidate terms and types, together with a partial ontology. To respect this closed-world assumption and maximize performance, we implement a two-stage post-processing pipeline.

Task B 为每个样本提供**候选术语与类型的明确封闭词表**，外加一个部分本体。为尊重这个封闭世界假设并最大化性能，我们实现了**两阶段后处理**。

First, to mitigate the inherent limitations of generative LLMs—particularly regarding omitted classifications—we supplement the LLM predictions with deterministic pattern-matching heuristics. We employ a proximity-based term-typing heuristic that scans the document for sentence-level co-occurrences of predefined terms and types, assigning an instance-of relation when the lexical distance between them falls within a high-confidence threshold. The triples extracted via this heuristic are merged with the generative LLM outputs to serve as a critical recall booster.

第一阶段：召回补丁。 为缓解生成式大模型固有的局限——尤其是漏判分类——我们用确定性的模式匹配启发式来补充模型预测。具体是一个**基于邻近度的术语类型标注启发式**：扫描文档，寻找预定义术语与类型在句子级别的共现，当两者之间的词法距离落在高置信阈值内时，赋予一条 `instance-of` 关系。这些三元组与生成结果合并，**充当关键的召回提升器**。

Second, the merged triples are passed through a deterministic vocabulary-constrained filter. A candidate triple $[h, r, t]$ is retained only if at least one endpoint (h or t) is a member of the sample's known vocabulary—the union of the provided terms, the provided types, and all entities already appearing in the sample's initial ontology triples. Triples that duplicate a relationship already present in the initial ontology are discarded. This is a strict exact-match membership filter; a triple whose endpoints do not exactly match a known vocabulary entry is dropped outright rather than lexically repaired.

第二阶段：词表约束过滤。 一条候选三元组 $[h, r, t]$ 只有在至少一个端点是该样本已知词表的成员时才被保留——已知词表 = 给定术语 $\cup$ 给定类型 $\cup$ 该样本初始本体三元组中已出现的全部实体。与初始本体中已有关系重复的三元组被丢弃。这是一个严格的精确匹配成员过滤器；端点无法与已知词表条目精确匹配的三元组会被直接丢弃，而不是做词法修补。

No equivalent vocabulary constraint is applied to Task A, since the flagship setting provides no closed candidate vocabulary to constrain against.

Task A 不施加等价的词表约束，因为旗舰设定根本没有提供可供约束的封闭候选词表。

实验一：Task B 结果 Results on Task B

表 1: Task B 图相似度

匹配方式	边 F1	邻域相似度	分类法相似度	图相似度
精确匹配	0.8776	0.8500	0.8165	0.8480
模糊匹配	0.8945	0.8690	0.8332	0.8656
语义匹配	0.8988	0.8727	0.8359	0.8692

表 2: Task B 任务导向指标

指标	精确率	召回	F1
术语类型标注	0.9324	0.9079	0.9200
分类法发现	0.9369	0.7846	0.8540
非分类关系抽取	0.0000	0.0000	0.0000

The results demonstrate the critical importance of deterministic post-processing. Because the generative outputs were strictly filtered against the predefined canonical vocabulary, the delta between the Exact Match Graph Similarity (0.8480) and Semantic Match Graph Similarity (0.8692) is remarkably narrow. This confirms that the model successfully avoided out-of-vocabulary hallucinations.

结果证明了[确定性后处理的关键重要性](#)。由于生成结果被严格地对照预定义规范词表过滤，**精确匹配 (0.8480)** 与 **语义匹配 (0.8692)** 之间的差值窄得引人注目。这证实模型成功避开了词表外的幻觉。

We note, however, that the absence of strict ablation studies limits our ability to precisely quantify the isolated performance gains provided by the RAG module versus the rule-based extraction and filtering components.

然而我们注意到，[缺少严格的消融实验](#)，[限制了我们精确量化 RAG 模块相对于规则抽取与过滤部件各自孤立性能收益的能力](#)。

实验二: Task A 结果 Results on Task A

表 3: Task A 图相似度

匹配方式	边 F1	邻域相似度	分类法相似度	图相似度
精确匹配	0.5891	0.5152	0.5017	0.5353
模糊匹配	0.7365	0.6765	0.6538	0.6889
语义匹配	0.7854	0.7319	0.7076	0.7416

表 4: Task A 任务导向指标

指标	精确率	召回	F1
术语类型标注	0.5952	0.4245	0.4956
分类法发现	0.6161	0.5708	0.5926
非分类关系抽取	0.0000	0.0000	0.0000

In the unconstrained setting of Task A, we observe a significant divergence between exact and semantic metrics. The Exact Match Graph Similarity drops to 0.5353, while the Semantic Match Graph Similarity reaches a much stronger 0.7416. This 20-point difference highlights a known limitation of unconstrained generative models: although they successfully capture the underlying semantic concepts, they often fail to reproduce the exact lexical forms required by strict exact-match evaluation protocols.

在 Task A 的**无约束设定**下，我们观察到精确指标与语义指标之间的**显著背离**：精确匹配图相似度掉到 0.5353，而语义匹配图相似度达到强得多的 0.7416。这 20 个百分点的差距凸显了无约束生成式模型的一个已知局限：它们成功抓住了底层的语义概念，却常常无法复现严格精确匹配评测协议所要求的确切字形形式。

实验三：非分类关系抽取瓶颈的深入分析 The Non-Taxonomic Extraction Bottleneck

A review of the evaluation logs across both Task A and Task B shows that the F1-score for Non-Taxonomic Relation Extraction is exactly 0.0000 in both tracks. Two factors contribute to this result.

对 Task A 与 Task B 评测日志的审查显示，**非分类关系抽取的 F1 在两条赛道上都恰好是 0.0000**。有两个因素造成这个结果。

First, our relation-mapping instructions defined a closed set of six strictly taxonomic and typing relation strings (is-a, instance-of, disjoint with, equivalent class, part of, has part). This design choice was empirical: early exploration of the training data revealed that hierarchical relations overwhelmingly dominated the dataset. To prevent the LLM from hallucinating diverse, unstandardized predicates, we restricted its generation space. By forcing the LLM to map all textual relationships to this strict set (e.g., standardizing "type of" and "category of" to "is-a"), we implicitly handled relational redundancies directly during the generation phase, which is why we did not employ a post-processing predicate filter to catch impossible co-occurring relations. However, under this strict prompt design, the model had no mechanism by which to emit a non-taxonomic relation label.

第一，我们自己的关系映射指令定义了一个封闭的六元关系集合： is-a 、 instance-of 、 disjoint with 、 equivalent class 、 part of 、 has part ——**全部是严格的分类与类型关系。**

这个设计选择是**经验性的**：早期对训练数据的探查显示层级关系**压倒性地**主导了数据集。为防止大模型幻觉出五花八门、不标准的谓词，我们限制了它的生成空间。通过强制模型把所有文本关系映射到这个严格集合（例

如把「type of」「category of」都标准化成 `is-a`), 我们在生成阶段就隐式地处理掉了关系冗余——这也是我们没有再用一个后处理谓词过滤器去捕捉不可能共现关系的原因。

然而, 在这套严格的提示设计下, 模型没有任何机制可以吐出一个非分类关系标签。

Second, the extent to which this constrains performance depends on how prevalent genuinely non-taxonomic relations are in the gold data itself for these two tasks. Without a full accounting of the gold relation-type distribution, we cannot fully separate our prompt-design limitation from a property of the benchmark data. We report the 0.0 score as an observed result and flag the closed relation vocabulary as the most direct, verifiable explanation available from our pipeline.

第二, 这个限制究竟压掉了多少性能, 取决于金标数据里真正的非分类关系有多普遍。在没有金标关系类型分布完整统计的情况下, 我们无法把提示设计的局限与基准数据本身的性质完全分开。我们把 0.0 分作为一个观察结果报出, 并把封闭关系词表标为从我们这条流水线能得到的、最直接可验证的解释。

(这一段的处理方式值得单独记: 他们没有把 0.0 归给「基准数据的问题」来推卸, 也没有断言「一定是我们的词表害的」, 而是说清楚两种解释目前分不开, 然后指出哪一种是自己这边能验证的。)

结论 Conclusion

By combining left-side context window management with deterministic vocabulary-constrained filtering for Task B, our approach effectively prevented out-of-vocabulary hallucinations from entering the final generated outputs and stabilized overall predictions.

通过把左侧上下文窗口管理与 Task B 的确定性词表约束过滤结合起来, 我们的方法有效阻止了词表外幻觉进入最终输出, 并稳定了整体预测。

However, error analysis revealed a major bottleneck: a 0.0000 F1-score in Non-Taxonomic Relation Extraction across both tasks, highlighting both a limitation of our current prompt design—which defines only a closed taxonomic/typing relation vocabulary—and an open question about how prevalent non-taxonomic relations are in the benchmark data itself. Moving forward, future work will focus on hybrid neuro-symbolic integration, schema-guided constrained decoding, and ontology-aware relation extraction techniques.

然而错误分析揭示了一个重大瓶颈: 两条赛道上非分类关系抽取的 F1 都是 0.0000。这既凸显了我们当前提示设计的局限 (只定义了一个封闭的分类/类型关系词表), 也留下一个开放问题——基准数据本身里非分类关系到底有多普遍。未来工作将聚焦于混合神经符号集成、schema 引导的约束解码, 以及本体感知的关系抽取技术。

局限 Limitations

While the proposed framework achieved strong results, several limitations remain. First, the individual performance contributions of dynamic retrieval, prompt configuration, and hybrid rule-

based extraction were not isolated through formal ablation studies, making it difficult to definitively quantify each component's distinct impact. Second, our post-processing focused entirely on entity vocabulary filtering rather than explicit semantic predicate filtering. Finally, critical hyperparameters—such as the 3,072-token truncation limit and the varying in-context demonstration counts (top-5 vs. top-2)—were set empirically based on hardware constraints and preliminary dev-set evaluations, rather than through exhaustive grid search optimization.

虽然本框架取得了不错的结果，仍有几处局限：

- **第一，没有做正式的消融实验**——动态检索、提示配置、混合规则抽取三者各自的性能贡献未被隔离，因此难以明确量化每个部件的独立影响。
- **第二，后处理完全聚焦于实体词表过滤，而非显式的语义谓词过滤。**
- **第三，关键超参数**——如 3,072 token 的截断上限、以及不同的上下文示例数量（top-5 与 top-2）——**是基于硬件约束与初步开发集评估凭经验设定的，不是通过穷举网格搜索优化得到的。**

参考链接

- [arXiv 2608.27101](#) — 本文预印本
- [参赛代码仓库](#) — pro-team 的提交实现
- [ISWC 2026](#) — 第 25 届国际语义网大会，LLMs4OL 2026 挑战赛与之同期
- [Qwen2.5-14B-Instruct](#) — 本文使用的生成模型
- [all-MiniLM-L6-v2](#) — 本文用于示例检索的句向量模型