

建本体之前先把要回答的问题写下来 An Ontology Development Methodology Based on Ontology-Driven Conceptual Modeling and Natural Language Processing: Tourism Case Study

本篇范围说明：这是一篇 23 页的期刊论文（开罗艾因夏姆斯大学 Shaimaa Haridy 等四人，*Big Data and Cognitive Computing* 2023, 7, 101，MDPI 开放获取、CC BY 许可）。下面「全文翻译」按原文章节推进，覆盖摘要、§1 引言、§2 文献综述、§3 方法（七个模块逐节）、§4 结果与讨论、§5 结论。**表 1** 那张 20 方法 × 20 判据的对照矩阵、**表 9** 的 11 条指标公式推导、以及 66 条参考文献不逐条译，关键数值在「核心内容」里给。原文图表多为图片，正文里引用的数字以文字部分为准。

核心内容

Q：这篇要解决什么问题？ A：建领域本体是一件**复杂且耗时**的活。已有的开发方法论不少，但作者指出两处缺口：**覆盖的活动不够全**（比如「富化」这一步很多方法论根本没有），以及**有些活动做得不够好**（尤其是「概念化」）。

论文对现状有一句很中肯的判断：

关于理想的方法论没有共识；但「建这个本体是为了什么」这个目的，有助于选出最合适的那一个。

作者提出的方法叫 **ON-ODM**，建在两块基础上：**ODCM**（本体驱动的概念建模）和 **NLP**（自然语言处理）。案例是埃及旅游本体（EGYTOUR）。

Q：为什么把「概念化」单拎出来加强？ A：作者给的理由很硬：

任何基于模型的产物，它的质量都被模型本身的质量严格约束住。

所以改善概念化这一步，对最终本体的质量影响最大。

ODCM 的定义是「运用各领域的本体论思想来构建工程产物，以改进概念建模的理论与实践」。它用的语言是 **OntoUML**——一种「元模型被设计为符合一个理论基础扎实的基础本体 **UFO**（统一基础本体）的本体论区分与公理化」的语言。而 **UFO** 本身是「一个建立在哲学中的形式本体论、哲学逻辑、认知心理学和语言学贡献之上的公理化形式理论」。

一句话：OntoUML 不是随便画的类图，它的每个构造子背后有一套哲学上的区分撑着，所以用它画出来的模型天然具备可复用、可集成、可互操作的共同结构。

Q：整个方法论有几个模块？ A：七个。

模块一：需求获取——产出三种并存的需求形态

这是我认为全文最值得抄的一节。它把需求做成三份同时存在、互不替代的东西：

步骤	产出	给谁看、解决什么
识别	领域描述文档（DDD）	用自然语言写清领域是什么、目标、范围、用户需求、资源
分析	用例图（UML）	把 DDD 里松散的条目变成「去掉重复与不切实际的、明确定义的功能」
规格化	能力问题（CQ）	本体的完整版本必须能回答这些问题，它们既指导开发也用于评估

DDD 的模板包含：领域、描述、目标、范围、用户需求（每条带「角色」和「说明」）、资源。旅游案例里目标写的是游客满意度、社区发展、资源保护、经济发展。

用例图的价值作者说得很实在：它「提供了一种把领域画成图的技术，便于不同角色理解、评审和评估」。案例里公民这个角色有 15 个功能，其中 12 个由公民直接发起、3 个从其它用例扩展而来。

CQ 那一步有一句关键的：

这些问题对指导本体开发至关重要，因为本体的完整版本必须能够回答它们。此外，它们可以与预期结果结合起来，供日后在本体评估中使用。

案例里的 CQ 分成五大类，每类若干条，例如「某文物的可用信息有哪些」「历史博物馆有哪些、在哪里」「某公司的联系方式是什么」「某地有哪些酒店」「某活动的完整信息是什么」。

这个模块结束时，需求同时以三种形态存在（DDD、用例图、CQ）。

模块二：本体开发——沿用 METHONTOLOGY 的骨架

四个活动：

1. 规格化：用 OMV（本体元数据词表）写一份文本描述。案例里的 OMV 字段有：本体名、所在地、组织、许可模式、本体类型（领域本体）、领域、工程工具（OLED）、语言（OWL）、语法（rdfs xml）、任务、工程方法论、以及知识来源——后者明确分成「非本体资源」（领域文档、在线资源、专家知识、语料）和「本体资源」（已有本体）两类。
2. 概念化（作者称这是本方法论的强项）：用 OntoUML 在 OLED 工具里画模型。案例里用到的构造子包括 ROLE（角色）、ROLEMIXIN、CATEGORY（范畴）、SUBKIND（子类）、组合关系。例如消费者这个 ROLEMIXIN 可以对「地点」的若干 SUBKIND（酒店、度假村、餐厅、咖啡馆、游轮）和

「交通」的若干 SUBKIND（飞机、船、巴士、汽车）分别做两种 CATEGORY 的预订；酒店由楼层组合而成、楼层由房间组合而成。

3. **形式化**：用 OLED 的代码生成功能把只有人能读的模型转成机器能解释的 **OWL**。产出的 EGYTOUR 有 228 个类。
4. **实现**：在 Protégé 里手工添加数据属性和个体并归到相应的类。案例只用了部分数据：246 个数据属性、1602 个个体。

模块三：本体富化——作者认为这是与众不同的一步

和许多以往的方法论不同，ON-ODM 把富化模块视为开发本体中不可或缺的一步。

理由是它能给工程师提供「初版本体里缺失的类和关系」的建议。三个活动：

预处理：类名要先整理，因为只有这一步定下来的词才会进入后续活动。四步：去停用词、去非字母字符、取词元。例子：Museum-Ticket → Museum Ticket，Activities-and-Events → Activity Event，Fees → Fee。工具是 SpaCy。

关系抽取：从文本语料里抽出类之间新关系的候选。语料用的是 OANC（开放美国国家语料库），8832 个文件、约 1500 万词。因为语料太大，只用了 15 个类做样本，抽出 1661 个候选。

富化：由工程师对每个候选做决定，也可以请领域专家参谋。作者强调「人在这一步的介入至关重要，为避免歧义与冗余」。判据是六条：

批准，如果	拒绝，如果
(1) 是新的	(1) 这个关系已经在本体里了
(2) 有意义	(2) 没有意义
(3) 两个类都已存在于本体中	(3) 其中一个类在本体里没有定义

批准的候选作为**对象属性**加在参与的两个类之间。结果：那 15 个类新增了 71 个对象属性。

模块四：本体评估——两套并用

一、基于 CQ 的验证。工程师为每条 CQ 写 SPARQL 查询、在产出的本体上执行、把结果与此前定义好的预期结果比对。作者指出这一步之所以容易做，正是因为 CQ 的规格化本来就是前面的必经步骤。

二、基于指标的评估。用 OntoMetrics 这个免费在线平台算 11 个指标，分三组（Schema、Knowledgebase、Graph）：

指标	公式	含义
AR 属性丰富度	属性总数 ÷ 类总数	

指标	公式	含义
IR 继承丰富度	子类关系数 $\div$ 类总数	
RR 关系丰富度	非继承关系 $\div$ (继承 + 非继承)	非继承关系占比
AP 平均填充度	实例总数 $\div$ 类总数	
CR 类丰富度	有实例的类数 $\div$ 类总数	
ARC 绝对根基数	根节点个数	不接收 is-a 关系的根
AC 绝对叶基数	叶节点个数	
AD / MD	平均深度 / 最大深度	
AB / MB	平均宽度 / 最大宽度	

这 11 个指标被归到**四个维度**：准确性、可理解性、内聚性、简洁性。

模块五、六、七

- **发布**：做一份翻译文件并发到网上。EGYTOUR 目前只有英文版，正式发布会加阿拉伯语
- **维护**：评估之后或发布之后做更新与纠错
- **文档化**：从第一个活动起就在产出文档，**一直持续到本体完成并发布**

Q：结果如何？ A: **CQ 验证**：为五组 CQ 各写一条 SPARQL 查询在 Protégé 上执行，**全部成功回答**。

指标对比 (EGYTOUR 与四个已有旅游本体)：

本体	类数	AR	IR	RR	AP	CR	ARC	AC	AD	MD	AB	MB
HONTOLOGY	284	0.109	0.961	0.321	0	0	17	247	2.73	5	7.38	29
IMHO_EVENTS	88	3.989	0.977	0.637	1.489	0.011	2	87	1.98	2	44	86
IMHO	138	4.304	0.986	0.680	1.464	0.007	2	137	1.99	2	69	136
TRAVEL	35	0.114	0.857	0.434	0.400	0.229	12	24	2.08	4	3	12
EGYTOUR	228	1.079	1.693	0.322	7.026	0.461	4	189	3.14	6	5.78	69

四个维度的排名：

维度	EGYTOUR 排名	第一名
准确性	第 3	IMHO
可理解性	第 2	HONTOLOGY
内聚性	第 2	HONTOLOGY
简洁性	第 1	EGYTOUR (3.74, 第二名 0.75)

作者的自我诊断也很坦白：AB 和 MB 低说明「本体侧重于层级的**纵向**建模而非**横向**建模，可以通过在同一层定义更多兄弟类来改进」；AR 和 RR 偏低是因为只用了部分数据属性和抽取关系，用完整数据会提高；

ARC 低是因为含有大量 is-a 关系。

背景补充 / 点评

几个概念的位置

能力问题 (competency question, CQ) 是本体工程里一个 1995 年就提出的老做法：先把「这个本体建成之后应该能回答哪些问题」列出来，再去建。它同时起两个作用——开发时当边界（不在 CQ 范围内的概念不必建），验收时当测试用例。我在 8/20 那批精读里已经见过这个概念，这篇给出了它在一套完整方法论里的确切位置。

METHONTOLOGY 是 1997 年马德里理工提出的经典本体开发方法论，把过程分成规格化、概念化、形式化、实现、维护。本文的模块二明说「沿用 METHONTOLOGY 的基本结构」，因为两者对概念化这一活动的重视程度相同。

UFO (统一基础本体) 是 Giancarlo Guizzardi 提出的**基础本体** (foundational ontology)。基础本体和领域本体的区别在于：领域本体描述某个具体领域（旅游、医药），**基础本体描述「任何领域都要用到的那些最一般的范畴」**——什么是对象、什么是事件、什么是角色、什么是内在属性。UFO 的特别之处是它明确建在哲学的形式本体论、哲学逻辑、认知心理学和语言学之上。

OntoUML 就是把 UFO 的这些区分做成 UML 的构造子。所以画 OntoUML 模型时，选 KIND 还是 SUBKIND 还是 ROLE 不是风格问题，**是在声明这个概念在本体论上属于哪一类**——例如「学生」是 ROLE（一个人在某段关系里扮演的角色，可以不再是学生），而「人」是 KIND（本质类型，不会变）。

OANC (开放美国国家语料库) 是一个完全开放的美式英语电子文本库。本文用它做关系抽取的语料来源。

这篇最值得学的三处

一、需求做成三种并存形态，而不是三选一。

DDD 是自然语言、给领域专家读；用例图是图、**便于不同角色一起评审**；CQ 是可执行的、给工程师当验收条件。三份服务三批人，**同一批需求换三种呈现，而不是选一种。**

二、CQ 要和预期结果一起写下来。

原文那句「它们可以与预期结果结合起来，供日后在本体评估中使用」是关键。**只有 CQ 没有预期结果，验证的只是「查得出东西」，验证不了「查出来的对不对」。**

三、富化那一步的六条准入判据是现成可用的。

尤其是「**其中一个类在本体里没有定义就拒绝**」这条——它防止**通过加关系的方式偷偷引入新概念**。加一条关系看起来只是加了条边，但如果它的一端是个未定义类，实际上是在绕过类的准入流程往本体里塞东西。

四处该打折扣的地方

一、四个维度的「平均分」是把量纲不同的数直接相加，排名由最大的那个量决定。

准确性那一栏平均了七个指标：AR (0.1 - 4.3)、IR (0.86 - 1.69)、RR (0.32 - 0.68)、AD (1.98 - 3.14)、MD (2 - 6)、AB (3 - 69)、**MB (12 - 136)**。

MB 的量级比 AR 大 20 到 100 倍，所以那个「准确性平均分」基本等于 $MB \div 7$ 。IMHO 以 30.71 排第一，它的 MB 是 136——**这个排名测的是横向宽度，不是准确性。**

内聚性那一栏同理：平均 ARC (2 - 17) 和 AC (24 - 247)，结果基本等于 $AC \div 2$ 。

跨量纲的平均必须先归一化，否则排名由最大那个量单独决定。

二、头条结论「简洁性第一」恰恰是最站不住的那个。

简洁性 = 平均填充度 (实例 ÷ 类) 与类丰富度 (有实例的类 ÷ 类) 的平均。**这两个量测的都是「本体被填充得多满」，不是「有多简洁」。**

EGYTOUR 赢是因为它有 1602 个个体铺在 228 个类上 ($AP=7.03$)，而 HONTOLOGY **一个实例都没有** ($AP=0$ 、 $CR=0$ ，于是简洁性得 0 分排最后)。HONTOLOGY 排最后的真正原因是它是一个只有 schema 没有实例数据的本体，这和简洁不简洁毫无关系。

而作者据此下的结论是「EGYTOUR 不提供任何不必要或重复的信息」——**可是 AP 和 CR 这两个公式里没有任何一处在看重复。**

三、对照组本身不可比。

拿一个有 1602 个实例的本体，去和零实例的 HONTOLOGY、35 个类的 TRAVEL 比那些对填充量敏感的指标，**结果在选定对照组的那一刻就定了**。而且作者自己也说 EGYTOUR 「只用了部分数据」，却仍然拿它去排名。

四、CQ 验证是自证的，而论文没有标出这一点。

CQ 在 §3.1.3 由团队写出，在 §3.2 用来驱动开发，然后在 §4.1 验证「本体能回答它们」。**一个为了回答某组固定问题而建的本体，能回答那组问题，这接近于构造保证。**

而且实际执行的只有**五条查询**——每组 CQ 各取一条。以此支撑「覆盖了领域专家指定的全部 CQ 组」这个说法，验证密度是很薄的。真正的检验应当是：CQ 由别人写，或者在本体冻结之后再写。

另外富化这一步的产出比很低，而论文没有讨论这个代价。 15 个类抽出 1661 个候选、最终批准 71 个对象属性——**批准率 4.3%**，也就是人工过了 1661 条留下 71 条。按 228 个类外推大约要审两万五千条候选。

论文承认关系抽取用的是「简单直接的方法」（因为 NLP 不是本文重点），表 6 的例子也确实很噪：一句关于《星球大战》电影票被黄牛抢购的话，被当成了「博物馆门票」类的候选；「那个男人会去取车」被当成「汽

车」类的候选。但富化模块的全部价值恰恰压在这个被作者主动降级的步骤上。

顺带一提，表 1 那张 20 方法 × 20 判据的对照矩阵里，ON-ODM 在全部 20 项上都是 ✓，其它每一个方法论至少有一项 ✕。判据是作者自己选定的（部分来自文献、部分是本研究新提的）。当一套新方法的作者自行设计对照判据并在全部项上给自己打满分时，那张表是一个主张，不是证据。

对我的启示

一、需求的三种并存形态，正好治我手上那份判据文档的一个毛病。

我现在只有一种形态：判据文档。它同时承担两件事——给人解释这套分类为什么这么分，以及给标注者当逐条操作规则。两边都不够好：讲解的部分让操作的人要跳着读，操作的部分让第一次接触的人看不懂为什么。

按这篇的分法应该拆成三份并存：

形态	我这边对应什么	给谁
领域描述	这套图谱是干什么用的、覆盖哪些企业与场景、边界在哪	第一次接触的人、业务方
角色 × 能力	医药代表 / 经理 / 医学职能各自要从图里拿到什么	各角色一起评审
能力问题 CQ	「某企业某产品在某适应症上有哪些可考的证据」这类可直接翻成查询的问题	工程师，当验收条件

三份并存，不是三选一。

二、CQ 必须带预期结果——这条直接接上我这几天反复撞到的那个形状。

我现在没有 CQ，更没有预期结果。而这几天已经从三个独立来源确认了同一件事：一致性检查回答不了「这条是不是真的」。

没有预期结果的 CQ 是同一个毛病的第四个实例——它只能验证「图里查得出东西」，验证不了「查出来的对不对」。所以 CQ 要成对写：问题 + 这个问题应该查出什么。

三、「其中一个类未定义就拒绝」这条，我的归并候选审核正缺。

我手上有 92 个跨企业归并候选待审，但没有一份成文的批准/拒绝判据。这篇的六条可以直接改造：

批准	拒绝
是新的（图里还没有等价断言）	这条断言已经存在
有意义（是可考的知识命题）	无意义（对话动作、销售论点）
两端的 K 域 / 行为都已在受控词表里 有一端的域或行为尚未定义	

最后那条最有用：它防止通过「加一条关系」的方式偷偷往受控词表里塞新概念。我的 applies_to 现在就是自由文本，随时可能引入未定义的主题，这正是那个漏洞。

四、「纵向 vs 横向」这个自我诊断，让我看到自己结构上的反面问题。

作者从 AB/MB 低推出「本体偏纵向、横向兄弟类不足」。

我的问题正好相反：K1 - K8 和 S1 - S12 是扁平的一层，没有任何子类——全是横向、没有纵向。后果是我无法表达「这条知识属于 K3 之下的某个更细的类」，只能把细分塞进 `applies_to` 这样的自由文本列里。

这是一个我此前没有命名过的结构缺陷。它也解释了为什么 `applies_to` 会变成「三类语义混用一列」——那一列在替一个不存在的层级承担工作。

五、指标的名字和它的公式可能是两回事，报告里要把两者并列写。

这篇的「简洁性」用填充度指标算出来、却被用来下「不含重复信息」的结论。

对应到我：「句级支撑率」这个名字听起来像在测忠实性，但它的公式是「判官能在证据里找到支持句的句数 ÷ 知识点正文的机械分句数」——分母由机械分句决定、分子由判官决定。名字和公式要一起写进报告，这样读者不会把它当成「这条知识点有多少比例是真的」。

六、跨量纲平均，和对照组可比性，是两条我做对比表时要先过的检查。

- 把几个量级差 100 倍的指标直接平均，等于只报了最大那个
- 拿一个满实例的对象去和一个零实例的对象比填充度，结论在选对照组时就定了

我近期要做的跨书、跨企业对比都会撞上这两条。做对比表之前先问：这些数在同一个量纲上吗？这两边在这个指标上本来就可比吗？

文中金句

"Ontology is defined as an 'explicit specification of a conceptualization'." 本体被定义为「一个概念化的显式规格说明」。

"there is no common consensus on an ideal methodology; however, the purpose of developing the ontology may aid in the selection of the most suitable methodology." 关于理想的方法论没有共识；但「建这个本体是为了什么」这个目的，有助于选出最合适的那一个。

"Enhancing the activity of conceptualization has a significant impact on the final ontology's quality. The reason for this is that the quality of any model-based artifact is highly constrained by the quality of the model itself." 加强概念化这一活动对最终本体的质量有重大影响。原因在于：任何基于模型的产物，它的质量都被模型本身的质量严格约束住。

"These questions are crucial for guiding the ontology development process, since the ontology in its complete version must be capable of answering them. Furthermore, they can be combined with expected results to be employed later in the ontology's evaluation."

这些问题对指导本体开发过程至关重要，因为本体的完整版本必须能够回答它们。此外，它们可以与预期结果结合起来，供日后在本体的评估中使用。

"The use case's most significant advantage is that it offers a technique to represent the domain in a diagram that is easy for different roles to comprehend, review, and evaluate."

用例图最显著的优势在于，它提供了一种把领域表示成图的技术，便于不同角色理解、评审和评估。

"the intervention of a human in this step is crucial in order to avoid ambiguity and redundancy." 人在这一步的介入至关重要，为的是避免歧义与冗余。

"Low values of AB and MB indicate that the ontology concentrates on the vertical rather than the horizontal modeling of hierarchies. This can be improved by defining additional classes at the same level (siblings)." AB 与 MB 的低值表明该本体侧重于层级的纵向建模而非横向建模。可以通过在同一层定义更多兄弟类来改进。

全文翻译

摘要

Ontologies provide a powerful method for representing, reusing, and sharing domain knowledge. ... For several reasons, developing domain ontologies is a challenging task. One of these reasons is that it is a complicated and time-consuming process. Multiple ontology development methodologies have already been proposed. However, there is room for improvement in terms of covering more activities during development (such as enrichment) and enhancing others (such as conceptualization).

本体为表示、复用和共享领域知识提供了一种强有力的方法……由于若干原因，开发领域本体是一项有挑战的任务，其中之一是这个过程复杂且耗时。已经有多种本体开发方法论被提出。然而，在「覆盖开发过程中更多的活动」（例如富化）和「加强其中一些活动」（例如概念化）这两方面，仍有改进空间。

本研究提出一种增强的本体开发方法论 **ON-ODM**。本体驱动的概念建模（ODCM）与自然语言处理（NLP）作为该方法论的基础。ODCM 被定义为运用来自各领域的本体论思想来构建工程产物，以改进概念建模。NLP 指的是运用计算技术分析人类语言的科学学科。

所提出的 ON-ODM 被应用于构建一个旅游本体……产出的本体基于能力问题（CQ）和质量指标进行评估。已验证该本体能够回答覆盖领域专家所指定的全部 CQ 组的 SPARQL 查询。质量指标被用来把产出的本体与四个已有的旅游本体作比较。例如，在与简洁性相关的指标上，产出的本体排名第一；而在可理解性上排名第二。

1. 引言

语义网关注的是把网络从一个人类可读内容的仓库，转变成一种机器可以轻易理解的格式。本体与知识图谱这类语义数据模型近年来大幅普及，本体被认为是语义网的骨干。

Given that ontologies provide context and meaning to data, they are essential for efficient knowledge extraction and reuse. Additionally, they offer a remedy for syntactic and semantic interoperability problems, which hinder efficient information exchange and collaboration among heterogenous systems.

鉴于本体为数据提供上下文与含义，它们对高效的知识抽取与复用是必需的。此外，它们为句法与语义上的互操作性问题提供了一种补救——那些问题妨碍了异构系统之间高效的信息交换与协作。

本体工程被定义为「关注本体开发过程、本体生命周期，以及构建本体的方法论、工具与语言的那一组活动」。本体开发方法论提供的是关于「活动与任务如何组织、它们之间如何过渡、每个任务采用什么方法、推荐什么工具」的指导。

（关于「没有理想方法论的共识」与「概念化决定最终质量」的两段，见「文中金句」。）

2. 文献综述

已有多种本体开发方法论被定义。之所以如此，是因为并不存在一种唯一正确的本体构建方法论——目标应用与所需特性有助于选出最合适的那一个。因此各家竞相从不同视角、聚焦不同方面提出方法论。

本节汇总了过去五年间提出的一些方法论。表 1 用 20 项判据把 20 种方法论与本文的 ON-ODM 作对比，这些判据覆盖开发过程的全部阶段，部分采自已有文献、部分是本研究新提出的。

（表 1 为图片形式的矩阵，判据清单在原文图中，此处不逐项列。ON-ODM 在全部 20 项上均为 ✓。）

3. 提出的方法论

The study proposes an enhanced ontology development methodology (ON-ODM) that offers detailed guidelines for all crucial activities, from requirements specification to ontology assessment. ON-ODM is domain-independent and can be applied to any domain.

本研究提出一种增强的本体开发方法论（ON-ODM），它为从需求规格化到本体评估的全部关键活动提供了详细指导。ON-ODM 是领域无关的，可应用于任何领域。

（七个模块的完整内容见「核心内容」。以下只保留承载设计判断的原文句子。）

3.1 需求获取。 本模块的输入是以各种形式存在的领域文档、相关在线资源、以及来自专家的领域知识；输出是三种不同形态的**本体需求清单**。

关于 DDD：这份文档的意义体现在若干点上，它用自然语言陈述来勾勒领域描述与用户需求。

关于分析：Now, it is time to analyze these needs and turn them from their present form into a set of distinct and well-defined functions that are devoid of repetitions and impractical requirements. **（现在该分析这些需求，把它们从当前的形态转变成一组明确、定义良好、且不含重复与不切实际内容的功能。）**

关于 CQ：见「文中金句」。At this point, the requirements acquisition module is complete, and three alternative versions of the requirements (DDD, use case diagram, and CQs) are available. **（至此需求获取模块完成，需求的三种可替代版本——DDD、用例图和 CQ——都已具备。）**

3.2 本体开发。 ON-ODM's development module adheres to the fundamental structure proposed in METHONTOLOGY, as this research places the same emphasis on the conceptualization activity. **（ON-ODM 的开发模块沿用 METHONTOLOGY 提出的基本结构，因为本研究对概念化活动给予同样的重视。）**

关于概念化：OntoUML reliance on UFO foundational ontology aids in the application of a common structure that guarantees easy reusability, integration, and interoperability. **（OntoUML 对 UFO 这个基础本体的依赖，有助于应用一种共同结构，从而保证易于复用、集成与互操作。）**

关于形式化：前一活动的模型是用一种只有人能理解的建模语言表达的；**本活动的目的是把这种形态转换成计算机程序可以解释的形态。**

3.3 本体富化。 Unlike many previous methodologies, ON-ODM considers the enrichment module as an essential step in developing ontologies. This is because it assists the ontology engineer with suggestions for classes and relationships that were missing in the initial version of the ontology.

与许多以往的方法论不同，ON-ODM 把富化模块视为开发本体中不可或缺的一步。这是因为它能为本体工程师提供「初版本体中缺失的类与关系」的建议。

关于预处理：The preprocessing step is essential, because only the words that are determined at this stage will go through the subsequent activities. **（预处理这一步是必需的，因为只有在这一阶段被确定下来的词，才会进入后续的活动。）**

关于富化的人工判断与六条判据，见「核心内容」。

3.4 本体评估。 两种方法各有诸多优点。CQ 验证这一侧：the ontology engineer writes SPARQL queries to answer CQs, executes the queries on the produced ontology, and then compares the outcomes with the expected results, which were also defined in Section 3.1.3. **（本体工程师为 CQ 编写 SPARQL 查询、在产出的本体上执行、然后把结果与同样在 3.1.3 节定义好的预期结果作比较。）**

3.5 - 3.7 发布、维护、文档化。 关于文档化：The ON-ODM methodology gives the utmost importance to documentation. ... The documentation activity continues until the completion of the ontology and its publication on the Internet with documents that explain all of its components to facilitate ontology reusability, integration, and interoperability. (ON-ODM 方法论对文档化给予最高重视……文档化活动一直持续到本体完成并发布到互联网上，并附有解释其全部组成部分的文档，以便于本体的复用、集成与互操作。)

4. 结果与讨论

4.1 基于 CQ 的评估结果。 3.4.1 节定义的 SPARQL 查询在 Protégé 上执行。这些查询代表领域专家在 3.1.3 节定义的每一组 CQ 各一个问题。结果显示 EGYTOUR 能够成功回答全部查询。

4.2 基于指标的评估结果。 (完整数值表见「核心内容」。)

四个维度的定义：**准确性**相关指标衡量的是「本体在多大程度上表示了真实世界的领域」；**可理解性**相关指标决定的是「对本体各元素的理解程度」；**内聚性**相关指标指的是「本体中的类彼此关联的程度」；**简洁性**相关指标衡量的是「本体论信息有用的程度」。

作者的三条自我说明：

Low values of AB and MB indicate that the ontology concentrates on the vertical rather than the horizontal modeling of hierarchies. (AB 与 MB 的低值表明该本体侧重于层级的纵向建模而非横向建模。)

In EGYTOUR, only a sample of the data properties and extracted relations were used. Applying the complete case study data will raise the AR and RR values. (在 EGYTOUR 中只使用了数据属性与抽取关系的一个样本。应用完整的案例数据会提高 AR 与 RR 的值。)

Regarding the ARC metric, it counts the number of roots that do not receive is-a relations. Therefore, EGYTOUR's ARC value is low because it contains numerous is-a relations. (ARC 指标统计的是不接收 is-a 关系的根的数量。因此 EGYTOUR 的 ARC 值低，是因为它含有大量 is-a 关系。)

5. 结论

Ontologies are widely used in a variety of applications and domains. Nonetheless, developing domain ontologies is a difficult and time-consuming process, which is a significant challenge. Many ontology development methodologies have already been proposed; however, there are still certain activities that have not yet been covered and others that could be enhanced. Furthermore, the scarcity of details and applications provided with the methodologies makes most of them challenging to put into practice.

本体被广泛用于各种应用与领域。尽管如此，**开发领域本体是一个困难且耗时的过程**，这是一项重大挑战。已有许多本体开发方法论被提出；**然而仍有某些活动尚未被覆盖，另一些则有待加强**。此外，这些方法论所提供

的细节与应用示例稀缺，使得其中大多数难以付诸实践。

未来工作的几个方向：采用不同的先进 NLP 技术并观察它如何影响抽出的候选清单、进而影响所开发的本体；采用其它的本体评估方法，例如基于应用的方法；以及在效率、易用性、对不同且更复杂领域的适应性这些维度上考察 ON-ODM。

参考链接

- [论文原文 \(MDPI, 开放获取 CC BY\)](#) — *Big Data and Cognitive Computing* 2023, 7, 101
- [OntoUML](#) — 本文概念化活动所用的建模语言，元模型符合 UFO 的本体论区分
- [UFO 统一基础本体](#) — OntoUML 背后的基础本体，建立在形式本体论、哲学逻辑、认知心理学与语言学之上
- [OntoMetrics](#) — 本文指标评估所用的免费在线平台，算 11 个指标分三组
- [Protégé](#) — 斯坦福的本体编辑器，本文用于实现活动（加数据属性与个体）；Web Protégé 用于发布
- [OANC 开放美国国家语料库](#) — 关系抽取所用语料，8832 个文件约 1500 万词
- [SpaCy](#) — 本文预处理与关系抽取所用的 NLP 库
- [METHONTOLOGY 原始论文](#) — 1997 年马德里理工提出的经典方法论，本文模块二沿用其骨架