

改在哪里比改了多少重要 Surgical Alignment in Knowledge Graph Training for Clinical Diagnosis with Large Language Models

本篇范围说明：这是一篇会议投稿（科罗拉多大学安舒茨医学院 Saksham Khatwani、Yanjun Gao 等五人，arXiv 2608.26587v1，2026-08-27）。下面「全文翻译」按原文章节推进，覆盖摘要、§1 引言、§2 相关工作、§3 数据、§4 预处理、§5 训练范式、§6 任务级结果、§7 梯度分析（含 2×2 消融）、§8 结论、§10 局限。[奖励函数的公式推导](#)、[附录里的训练超参与 \$\delta\$ 敏感性分析](#)、以及[百余条参考文献不逐条译](#)，表 2 - 6 的关键数值在「核心内容」里给。

核心内容

Q：这篇要回答什么问题？ A：生物医学知识图谱能为大模型的临床诊断推理提供结构化的医学知识做支撑，但「图谱信号应该怎么注入大模型」至今没有定论。

作者做了一次系统性研究：[5 种图谱任务形式](#) × [3 种训练范式](#) × [2 个知识图谱](#) × [3 个基座模型](#)。

而全文的核心发现是一句话：

在任务层面，所有范式都比未微调的基线好；但那些「域内准确率相当」的方法，知识迁移行为差别巨大。

更要命的是：[它们的相对排序在不同基准上会反转](#)。

Q：所以准确率这一个数漏掉了什么？ A：漏掉了[优化器到底把预训练模型改动了多大范围](#)。作者为此造了两个诊断量：

指标	全称	测什么
GID	梯度介入密度 (Gradient Intervention Density)	相对预训练基线，优化器 更新足迹的稀疏程度 ——被改动的层内分量占比
GD	梯度扭曲 (Gradient Distortion) = $1 - \text{余弦相似度}$	参数相对预训练基线的 方向偏离程度

GID 的设计有一处很巧：作者把优化过程当成一个[离散的介入过程](#)来看。对每一层，定义「介入事件」为参数增量的 L2 范数位移超过一个严格容差 $\delta = 10^{-9}$ （这个值是为了把优化更新和浮点噪声分开）。在这个定

义下，一个分量要么被碰过、要么在数学上纹丝不动。附录给了 δ 从 10^{-6} 到 10^{-10} 的敏感性分析，趋势稳定。

为什么不直接用原始的方向和幅度？作者说得很清楚：

原始的方向与幅度是连续量，对任何单层里的离群值都很敏感。更重要的是，它们并不直接回答我们真正关心的那个问题：优化器到底改动了预训练模型里的哪些分量？

所以 GID 捕捉的是优化器活动的「范围」，不是「幅度」——幅度和方向由 GD 那一侧覆盖。

Q：发现是什么？「外科式对齐」指什么？ A：一条清晰的分界：

在 KL 正则化下的「图谱判断式训练」产生稀疏、局部的更新（作者把这个状态称为「外科式对齐」），而任务专用的 SFT 产生稠密的更新。

具体的梯度分析结果：

训练范式	更新足迹
任务专用 SFT	几乎改动每一层的每一个分量，且扭曲度很高（GD 接近 1.0）
KG-SFT、GRPO（图谱引导）	保守地改动，GD 远低于 1.0
RM-R1	介于两者之间——与它没有显式 KL 正则化这一点一致

而且「即便图谱引导方法的 GID 偏高，它的 GD 仍然是低的」。

这个排序在三个基座模型上都成立，说明这个模式反映的是训练范式而不是模型。

然后是那句最要紧的结论：

GID 最稀疏的那几种范式（KG-SFT 和 GRPO），正是在 PDSQI-9 的高阶推理维度上带来提升的那几种。任务专用 SFT 尽管赢下了域内的 ROUGE-L，却没有改善那些维度。
一句话：对临床推理质量而言，优化器把更新放在哪里，比它更新了多少更重要。

Q：那个 2×2 消融怎么设计的？这部分方法论最硬 A：作者先提了一个很好的自问：

外科式对齐的稀疏更新足迹，是由图谱判断目标驱动的，还是由 KL 正则化驱动的，还是两者都有？如果不把这两个因素拆开，§ 7.2 的发现就会塌缩成一个人尽皆知的事实：KL 正则化总是产生小更新。

于是做了一个受控的 2×2 ：两种目标（ProbSum 上的任务专用 SFT、多任务图谱判断 SFT） $\times$ 两档 KL 强度（ $\lambda = 0$ 和 0.1 ）。

控住的变量列得很干净：同一个基座（Qwn7B）、**训练数据量对齐**（多任务图谱 SFT 下采样到与 ProbSum 同样大小）、相同的 LoRA 配置、**固定学习率且不逐格调参**、相同的训练步数、**3 个随机种子**。

三条结果：

	$\lambda=0$	$\lambda=0.1$	判断
ProbSum SFT (ProbSum ROUGE-L)	22.92	19.48	对 KL 敏感
ProbSum SFT (MedQA)	64.54	63.61	连域外也掉
ProbSum SFT (MedMCQA)	59.18	57.82	连域外也掉
KG SFT (ProbSum ROUGE-L)	18.88	18.94	对 KL 稳健
KG SFT (MedQA)	64.14	64.01	基本持平
KG SFT (MedMCQA)	57.82	57.14	基本持平

- 1. **任务专用监督在域内占优：** $\lambda=0$ 时 ProbSum SFT 拿到最高的域内 ROUGE-L (22.92 对 KG SFT 的 18.88)，这是预期之中的
- 2. **ProbSum SFT 对 KL 敏感：**加上 KL 之后**每一项都掉**，连域外测试集也掉
- 3. **KG SFT 对 KL 稳健：**三项评估上基本持平

梯度分析解释了为什么：

图谱判断式 SFT 在 $\lambda=0$ 、任何 KL 正则化施加之前，就已经产生了稀疏的更新足迹。优化器只碰一部分分量，所以再加 KL 几乎没有额外效果。而 ProbSum SFT 在 $\lambda=0$ 时就广泛地改动参数集合，KL 必须随后去约束它——代价是域内准确率。

结论：**目标函数本身就贡献了稀疏性，KL 只是叠在上面。** 所以外科式对齐是图谱判断目标的一个性质，不是正则化的产物。实践含义是：**目标的选择才是获得外科式更新的主要杠杆。**

Q：五种任务形式是什么？ A：分两族。

路径判断族（判别式，判断推理路径是否有效）：

说明

- P@10 给 10 条候选图谱路径，找出一条有效的
- P@2 给 2 条候选，找出一条有效的
- PN@10 给 10 条候选，找出**多条**有效的

生成族（补全部分推理链）：

说明

- NHP 下一跳预测 给一条不完整的路径，预测下一跳

说明

PC 路径补全 给一条不完整的路径，补完剩下的部分

跨任务泛化的发现值得单记：

即便不做图谱训练，P@2 在两个图谱下都表现很好（**知识本来就已经编码在模型里了**），而 NHP 这类生成任务仍然困难，说明它**更依赖显式的图谱监督**。在路径判断任务上训练的模型，在同族内泛化良好，**但迁移到生成任务很差，反之亦然**。这种不对称说明**路径判别目标引入了更多任务特定的偏置，泛化能力有限**。

Q：数据与评测怎么搭的？ A：两个图谱：UMLS（采用其诊断推理版本，保留 107 种与诊断相关的 SNOMED CT 语义关系）和 PrimeKG（聚焦疾病、表型、药物三类节点）。

图谱路径抽取：对每份病历，把病历中的实体映射到图谱节点（起始概念）、把金标诊断映射到图谱节点（目标概念），从每个起始概念做**最多两跳的广度优先搜索**。抵达目标概念的路径标为正样本，其余为负样本。

一处干净的隔离值得记：

概念唯一标识符（CUI）用于锚定跨图谱对齐，**但不作为模型输入提供**；它们只用于概念级的评估。

训练数据：ProbSum（1,005 份医生标注的 ICU 病程记录，来自 MIMIC-III）、DDXPlus（合成数据集，覆盖 49 种病理、110 种症状、113 项既往史）。**下游评测：**MedQA（筛出诊断相关的 1,796 训练 / 251 测试）、MedMCQA（筛出 2,560 条诊断相关）。

不在问答基准上微调，作者说明理由是**避免与预训练数据造成排行榜污染**。

指标：ROUGE-L（词面重叠）、CUI-F（把生成文本映射回图谱 CUI 后的概念级重叠）、问答用精确匹配。另外用 **PDSQI-9**——一个九条判据的临床评分量表，由大模型充当评审打分，该量表此前被验证与人类评分高度相关。

PDSQI-9 的结果模式很有意思：

图谱训练的模型改善的是**高阶推理维度（组织性、可理解性、综合/抽象）**，而在抽取式准确性或详尽性上没有一致的增益。这种**结构性而非表层的增益**，正是促使我们去做梯度级分析的原因。

Q：作者怎么定位自己的贡献？ A：说得很克制：

我们提出的**不是一个新的强化学习架构**，而是一套用于图谱-大模型集成的**分析框架与洞见……优化几何**，应当与任务准确率并列，成为一个一等的评估维度。虽然我们在临床用例上评估这个框架，它是领域无关的。

几个概念的位置

UMLS（统一医学语言系统） 是美国国立医学图书馆维护的医学术语整合系统，把几百个来源词表统一到一套概念上，每个概念有一个 **CUI（概念唯一标识符）**。**SNOMED CT** 是其中最大的临床术语集。**PrimeKG** 是哈佛 Zitnik 组做的精准医学知识图谱。

GRPO（组相对策略优化） 是 DeepSeek 提出的强化学习方法：对同一个提示采样一组候选输出，用组内相对好坏来优化，**不需要单独训练一个价值模型**。本文用它的理由正好在这：它「在 KL 正则化下优化候选组内的相对偏好，因而鼓励局部的、比较驱动的更新，而不是稠密的 token 级拟合」。

KL 正则化在这里的作用是把微调后模型的输出分布**拉住不要离预训练分布太远**。本文的损失是交叉熵加上一个 λ 加权的 KL 项， λ 从 0.01 到 1。

LoRA（低秩适配） 是只训练一组低秩增量矩阵、冻结原权重的微调方法。本文所有模型都用 LoRA 训练，在算梯度前先把适配器权重合并回基座权重。

PDSQI-9 是一个为「大模型生成的医疗文档摘要」设计的九条判据量表，由本文作者团队的合作者开发并验证过。本文用到其中七条：抽取准确性、详尽性、有用性、组织性、可理解性、简洁性、综合/抽象。

这篇最值得学的三处

一、当主指标分不出两个方法时，造一个正交的诊断量，并列报。

这是全文的方法论主张，作者把它明说了：**优化几何应当与任务准确率并列成为一等评估维度**。

它的价值在于：**准确率在它设计要测的维度上没有错，它只是对「优化器改动了多大范围」完全失明**——而后者才决定这个模型在训练目标之外还剩多少能力。

二、那个「会不会塌缩成一个平凡事实」的自问。

如果不把这两个因素拆开，§ 7.2 的发现就会塌缩成一个人尽皆知的事实：**KL 正则化总是产生小更新**。

在做消融之前先问「**我的发现有没有一个平凡的解释**」，这个自问本身比消融结果更值得抄。而且他们的消融设计把该控的都控住了：同基座、**数据量对齐**、同 LoRA 配置、**固定学习率不逐格调参**、同训练步数、3 个种子。

三、把连续量离散成「碰过 / 没碰过」，并说明为什么这么做。

GID 不测幅度只测范围，因为要回答的问题是「**哪些分量被改了**」而不是「改了多少」。幅度和方向另有 GD 负责。**两个量各答一个问题，不互相掺和**，这比造一个混合指标干净得多。

五处该打折扣的地方

一、下游数字的增益很小，而主表没有给标准差。

ProbSum 上 Qwn7B：未微调基线 ROUGE-L **22.14**，最好的 UMLS 训练模型 **22.96**——差 0.8 个点。Qwn8B 上是 4.15 对 4.33。

主表（表 2、3、4）报的是单次结果，没有标准差；只有消融那张表（表 6）给了 $\pm sd$ 。所以表 3 里加粗的「最优」值，在统计上是否可区分，论文没有交代。

二、RAG 基线比「完全不微调」还差，这件事从头到尾没有被讨论。

ProbSum 上 Qwn7B：未微调 22.14 $\rightarrow$ RAG-UMLS 14.09 $\rightarrow$ RAG-PrimeKG 12.23。

把检索到的图谱路径加进提示词，让结果大幅变差了。可能是检索质量差、可能是提示格式伤了模型、也可能那些路径就是噪声。

而这值得追问的地方在于：喂给 RAG 的路径，和喂给训练的路径，用的是同一套「两跳 BFS」抽取。如果这些路径在推理时是噪声，那它们作为训练信号时是什么，论文没有回答。

三、有几个基准格子是退化的，却被当成结果报了。

MedMCQA 上 Qwn8B 和 Gem7B：未微调 36.73、RAG-UMLS 36.73、RAG-PrimeKG 36.73、最优 UMLS 模型 36.73、最优 PrimeKG 模型 36.73——**五个条件下完全相同**。MedQA 上 Qwn8B 同样五连 26.29。

这是一个对任何干预都不响应的模型（很可能在恒定作答或者输出解析失败）。论文的表注写的是「不同方法之间性能相近，多个方法达到最高值」——但精确到小数点后两位的五连相同不叫「相近」，那叫没有区分力，这些行不该计入证据。

这 and 前几天读到的「未加区分的 AUC 被平凡样本饱和」是同一件事：当一个指标在所有条件下给出同一个数时，它在这个对比里携带零信息。

四、LoRA 的配置可能混淆 GID，而主对比没有说清。

GID 数的是「哪些分量被碰过」。但 LoRA 的更新按构造就是低秩的，而且只作用在选定的目标模块上——所以「哪些分量被碰」有一部分是由 LoRA 的秩与目标模块选择决定的，不只由目标函数决定。

消融那 4 个格子明确说了用相同的 LoRA 配置，那部分是控住的；但 § 7.2 的主对比横跨 SFT、GRPO、RM-R1、Comp-GRPO 多种范式，它们各自的 LoRA 配置只写在附录里，主文没有交代是否一致。

五、PDSQI-9 的增益小、方向不齐，而且由大模型评审打分。

表 5 里 $\uparrow$ 标记分布得很散。举一个反例：Gem7B 的「综合/抽象」一项，未微调是 0.76，任务 SFT 升到 1.14（标了 $\uparrow$ ），而最优的 UMLS 模型是 0.60——比未微调还低。整张表没有给聚合的显著性。

另外那个「与人类评分高度相关」的说法引自量表自己的验证论文，本文没有重新验证。

最后一处措辞：「它是领域无关的」这句是断言不是展示。GID/GD 作为算术确实领域无关，但**「判断式目标产生外科式更新」这个结论只在生物医学图谱、且只在一族特定的路径判断任务上被演示过**。这个泛化主张该带一句限定，论文没有给。

对我的启示

一、这是我这周第五次碰到同一个形状了，可以收成一条通则。

来源	主指标	它看不见什么
FAIR 数字对象	图连通性	节点是不是可解析、有没有类型
联邦图谱	端任务 MRR	召回率已经把上界钉死了
Clinical Graph-JEPA	留一法恢复率	恢复的是草稿自己，不是真值
Neo4j payload	自动闸门	「这条是不是真的」
本篇	域内准确率	优化器改动了多大范围

共同结构：主指标在它设计要测的那个维度上没有错，但它对另一个同样决定成败的维度完全失明。

而这篇给出的解法最干净：**造一个正交的诊断量，和主指标并列报，而不是去修主指标。**

对应到我的 LL 拆书评测：句级支撑率是主指标，**它看不见的是「判官的判定路径有多依赖某一个窗口」**。我可以照这个思路补一个诊断量——比如**一条知识点的判定，是被几个窗口独立支持的**。一条只靠单个窗口支撑的结论，和一条被三个窗口都支持的结论，句级支撑率上完全一样。

二、「改在哪里比改了多少重要」直接对应我统计判据修订影响面的方式。

我现在统计的是「这条修订影响多少条数据」，**没有统计「它影响哪几类」**。

- 修订 14（对话动作标否）影响 205 条，但**集中在同一类**
- 修订 16（comparator 限定为可处方治疗选择）只影响约 30 条，但它把 K3 和 K4 的边界整个挪了

按条数算，14 远大于 16；按范围算，16 的影响更深。 我该把「触及的类别数」和「触及的条数」并列报。

三、「这个发现会不会塌缩成一个平凡事实」应该成为我做实验前的固定自问。

对应到我前天那件事：「两遍法比批量版好」会不会塌缩成「一条一判总是比批量好」？——**会，而且那是个人尽皆知的事实。**

所以真正的发现不是「两遍法好」，而是**「窗口切分本身没问题，是批量把它拖垮的」**——而这句话必须靠隔离实验才说得出口。我当时确实做了隔离实验，**但没有把这个自问明确写出来**，所以差点把一个平凡结论当成发现报出去。

四、这篇的 2×2 设计正是我前天那个错误的反面教材。

我从按章版改到滑窗版时**同时改了「切分方式」和「一次判几条」**，结果归因不了、只能补做隔离实验。

而这篇一开始就控住了：同基座、**数据量对齐**（把多任务数据下采样到和单任务一样大）、同 LoRA 配置、**固定学习率不逐格调参**、同训练步数、3 个种子。

其中「不逐格调参」这条我以前没想过要写出来——如果每个格子各自调到最优，那比的就不是变量本身而是调参的功夫了。

五、「判断型任务与生成型任务之间迁移很差」，这对我有一个中期含义。

原文的发现：在判断类任务上训练的模型在同族内泛化良好，**但迁移到生成类任务很差**，因为判别目标引入了更多任务特定的偏置。

对应到我：**我的标注任务全是判断型**（这条语义点算不算知识？属于哪个 K 域？这两条是不是同一事实？）。而**图谱最终要支撑的场景很可能是生成型**（给定一次拜访场景，生成该覆盖哪些知识点）。

所以「用这批判断型标注数据去训练一个生成型的东西」这条路，不能默认可行。这是一条我此前没有意识到的风险。

六、「CUI 只用于评估、不作为模型输入」这条隔离，我该写进 spec。

评估用的锚点与模型能看到的東西完全分开。对应到我：**金标的 gold 标记、裁定结果、一致率的计算依据，绝不能进入给标注者或给模型的输入。**我现在实际是分开的，**但这是习惯不是制度**，没有写进 SOP。一旦哪天有人为了「提高一致率」把裁定结果做成提示，一致率就自证了。

七、退化的对照格子要单独标出来，不能并列报最优。

五个条件给出同一个数，说明这个基准在这个对比里没有区分力。**这类行要标成「无区分力」而不是「多个方法并列最优」。**

我在 LL 评测里也有对应物：**如果某一章的所有 chunk 在所有配置下都判成同一结果，那一章在这个对比里不提供信息**，应该单独标出来而不是计入分母。

文中金句

"all paradigms improve over the non-finetuned baseline, but methods with comparable in-domain accuracy show substantially different knowledge transfer behavior." **所有范式都优于未微调基线，但那些域内准确率相当的方法，表现出差别巨大的知识迁移行为。**

"accuracy alone does not reveal how a given objective actually reshapes the model." **准确率本身揭示不了一个给定的目标函数究竟如何重塑了模型。**

"Raw direction and magnitude are continuous quantities sensitive to outliers in any single layer. More importantly, they do not directly answer the question we care about: which components in the pretrained model has the optimizer actually changed?" 原始的方向与幅度是连续量，对任何单层里的离群值都很敏感。更重要的是，它们并不直接回答我们真正关心的那个问题：优化器究竟改动了预训练模型里的哪些分量？

"In short: where the optimizer puts its updates matters more for clinical reasoning quality than how much it updates." 一句话：对临床推理质量而言，优化器把更新放在哪里，比它更新了多少更重要。

"Without disentangling these factors, the § 7.2 finding could collapse into a familiar fact: KL regularization always produces small updates." 如果不把这些因素拆开，§ 7.2 的发现就可能塌缩成一个人尽皆知的事实：KL 正则化总是产生小更新。

"The objective alone contributes to sparsity, which KL just stacks on top off. This further confirms that surgical alignment is a property of the KG-judgment objective, not an artifact of regularization." 目标函数本身就贡献了稀疏性，KL 只是叠在它上面。这进一步证实外科式对齐是图谱判断目标的一个性质，而不是正则化造成的产物。

"Optimization geometry, alongside task accuracy, becomes a first-class evaluation dimension." 优化几何，与任务准确率并列，成为一个一等的评估维度。

"Concept Unique Identifiers (CUIs) anchor cross-KG alignment but are not provided as model input; they are used only for concept-level evaluation." 概念唯一标识符用于锚定跨图谱的对齐，但不作为模型输入提供；它们只用于概念级的评估。

全文翻译

摘要

Biomedical knowledge graphs (KGs) offer structured medical knowledge that can ground large language model (LLM) reasoning in clinical diagnosis application, yet how KG signal should be integrated into LLMs remains an open question.

生物医学知识图谱提供结构化的医学知识，能够为大语言模型在临床诊断应用中的推理提供支撑，然而「图谱信号应当如何被整合进大模型」仍是一个悬而未决的问题。

我们呈现一项系统研究，跨越五种图谱任务形式、三种训练范式、两个知识图谱和三个基座大模型。在任务层面，所有范式都优于未微调的基线，但那些域内准确率相当的方法，表现出差别巨大的知识迁移行为。

我们引入**梯度介入密度（GID）**与**梯度扭曲（GD）**，用以度量一个优化器对预训练模型的修改有多广。GID与GD合起来揭示了一条清晰的分界：在KL正则化下的图谱判断式训练产生稀疏、局部的更新（我们把这一状态称为「外科式对齐」），而任务专用的SFT产生稠密的更新。

一项受控消融表明，**目标函数与KL各自独立地贡献了稀疏性**；而产生稀疏更新的那些范式同时也改善了推理质量——即便它们的域内准确率低于任务专用SFT。因此，评估图谱与大模型的集成，需要在准确率之外补上优化几何的诊断。

1. 引言

大模型在临床诊断上展现出显著潜力，但它们的输出仍然倾向于事实性错误，而不是有根据的医学逻辑。生物医学知识图谱以经过策展的结构化形式编码临床概念及其关系，为大模型推理提供了可信推理所需的天然脚手架。

现有做法的差别在于**图谱从哪里进入流水线**：

- **推理时方法**把图谱当作检索上下文（基于提示的检索增强生成，或作为agent系统的外部记忆）
- **训练时方法**直接用图谱派生的信号监督大模型，或通过对图结构的监督微调，或通过基于偏好的强化学习

在训练时方法内部，各家在**任务形式**上还有分歧：模型可以被训练去**判断候选推理路径**，也可以被训练去**从部分输入生成路径**。

As existing work is largely optimized and evaluated on narrow benchmarks and task-specific targets, the field lacks a unified understanding of which task formulations and objectives produce KG-grounded reasoning that generalizes beyond the supervision task.

由于现有工作大多在狭窄的基准与任务专用的目标上做优化和评估，这个领域缺少一个统一的理解：**究竟哪些任务形式与目标函数，能产生「泛化到监督任务之外」的、有图谱依据的推理。**

本文考察两个互补的问题：（一）任务形式与训练范式的每种组合，如何塑造向其它图谱任务和下游临床基准的迁移；（二）**每种训练目标如何重塑预训练模型本身。**

对第二个问题：we move beneath task performance, since accuracy alone does not reveal how a given objective actually reshapes the model. **（我们下潜到任务性能之下，因为准确率本身揭示不了一个给定目标究竟如何重塑了模型。）**

贡献三条：图谱-大模型集成的实证图景；**优化几何这一视角**（首次把梯度级的优化几何分析用于图谱-大模型集成）；**外科式对齐这一概念的确立**——把GID与GD分析和一项「独立变动目标函数与KL强度」的受控

消融结合起来。

Our proposal is not a new RL architecture, but a novel analytical framework and insights for KG-LLM integration.

我们提出的不是一个新的强化学习架构，而是一套面向图谱-大模型集成的新的分析框架与洞见。

2. 相关工作

图谱作为上下文。 这一类在推理时通过检索、提示和记忆把图谱当作动态上下文：用图谱知识生成并排序候选诊断、把检索增强生成与结构化诊断图谱结合以改进基于电子病历的预测、抽取相关子图来构造上下文感知的提示、让模型先构建并校验一个加权图谱再做摘要。图谱也被用作长期推理的结构化记忆。**这些方法把图谱当作外部上下文，而不是显式的训练信号。**

图谱作为训练监督。 近期工作用图谱派生的监督信号来训练：通过参数高效的适配器注入图结构（需要修改架构）、把图谱路径当作强化学习的隐式奖励模型、以及证明图谱增强的微调能在低数据场景下改善知识操纵能力。

奖励模型作为推理。 近期工作把奖励模型重新框定为隐式的推理器而非单纯的打分器。

3. 数据概览 / 4. 预处理 / 5. 训练范式

（两个图谱、三个数据集、五种任务形式、路径抽取方式，以及 SFT / GRPO / RM-R1 / Comp-GRPO 四种范式的细节，见「核心内容」。）

关于 SFT 的定位：SFT serves as an initial alignment stage that exposes the model to KG structure; we treat any resulting memorization of graph patterns as an expected property of this stage. **（SFT 充当一个初始的对齐阶段，让模型接触图谱结构；由此产生的对图模式的记忆，我们视为这一阶段的预期性质。）**

关于多任务 SFT 的用意：提供对多样图谱结构与任务形式**更均匀的接触，减少对任何单一推理模式的偏向。**做法是把五种任务形式的训练数据合并，并下采样以保持每个任务的训练量一致。

关于 GRPO 为何合适：because GRPO optimizes relative preferences within candidate groups under KL regularization, it encourages localized, comparison-driven updates rather than dense token-level fitting. **（因为 GRPO 在 KL 正则化下优化候选组内的相对偏好，它鼓励的是局部的、比较驱动的更新，而不是稠密的 token 级拟合。）**

关于不在问答基准上微调：We do not fine-tune on QA benchmarks to avoid leaderboard contamination with pretraining data. **（我们不在问答基准上微调，以避免与预训练数据造成排行榜污染。）**

6. 任务级结果

路径判断 vs 生成、多任务稳健性、下游任务性能、临床推理质量四小节的结论，见「核心内容」。其中两句原文：

Across paradigms, SFT, GRPO, and RM-R1 achieve comparable in-domain performance, indicating that task-level accuracy alone cannot distinguish their reasoning behavior.

跨范式来看，SFT、GRPO 和 RM-R1 达到了相当的域内性能，这表明单靠任务级准确率无法区分它们的推理行为。

关于 PDSQI-9: KG-trained models improve higher-level reasoning dimensions (organization, comprehensibility, synthesis), while showing no consistent gains on extractive accuracy or thoroughness. This pattern, structural rather than surface-level gains, motivates the gradient-level analysis.

图谱训练的模型改善了高阶推理维度（组织性、可理解性、综合），而在抽取式准确性或详尽性上没有一致的增益。这种「结构性而非表层」的增益模式，促成了梯度级的分析。

7. 梯度分析

The task-level patterns in §6 raise a deeper question: what has each training paradigm actually done to the pretrained model?

§6 的任务级模式引出一个更深的问题：每种训练范式究竟对预训练模型做了什么？

作者沿两个维度刻画层级参数更新相对未微调基线的几何：**方向**（余弦对齐）与**幅度**（范数比）。对每个微调模型 A 与基线 B，计算每一层注意力参数的归一化梯度。对 LoRA 训练的模型，先把适配器权重合并回基座权重再计算梯度。

方向用余弦相似度衡量，**余弦越低表示方向偏离越大**；幅度用「能量位移」衡量，即 L2 范数的对数差，**正的位移表示模型 A 在该层展现出更激进的优化能量**。

然后是那段关键的设计说明（原文见「文中金句」），以及 GID 的定义：the fraction of layer components classified as touched. GID provides a single scalar per layer that captures the scope, not the magnitude, of optimizer activity: the structural property that, we argue, governs how training reshapes pretrained representations.

被判定为「碰过」的层内分量所占的比例。GID 为每一层提供一个标量，捕捉的是优化器活动的范围而非幅度——我们主张，正是这个结构性质决定了训练如何重塑预训练表示。

与多任务学习里的梯度冲突分析相比：那类分析刻画的是多个目标在训练中如何相互干扰，而 GID 隔离的是单个训练目标相对预训练锚点的离散足迹，提供一个可在不同训练检查点之间比较的直接诊断。

（§7.2 的结果与 §7.3 的 2×2 消融，见「核心内容」。）

8. 结论

Through Gradient Intervention Density (GID) and Gradient Distortion (GD), we identify surgical alignment as a property of judgment-based KG training: sparse, localized parameter updates that preserve the pretrained model's broader reasoning. Optimization geometry should be a first-class evaluation dimension alongside task accuracy for clinical KG-LLM integration.

通过梯度介入密度与梯度扭曲，我们把「外科式对齐」识别为判断式图谱训练的一个性质：稀疏的、局部的参数更新，它保全了预训练模型更广泛的推理能力。对于临床场景下的图谱-大模型集成，优化几何应当与任务准确率并列，成为一个一等的评估维度。

10. 局限

作者自述三条：本研究聚焦于跨任务形式、训练范式和知识图谱的系统评估，[这一评估可以进一步扩展到更多领域](#)；只覆盖了三个常用大模型，[可以扩展到更广的评估](#)；以及——

while we introduce a mechanistic perspective for understanding KG - LLM integration through GID, we do not propose a novel RL training framework aimed at improving performance metrics.

虽然我们通过 GID 引入了一个理解图谱-大模型集成的机制性视角，我们并没有提出一个旨在改进性能指标的新的强化学习训练框架。

伦理说明：ProbSum 建立在 MIMIC-III 之上，是去标识化的临床数据集，不含个人可识别信息；推理轨迹的生成与 PDSQI-9 的评分都在符合 HIPAA 的云环境中进行，因而符合 MIMIC 的数据使用协议。

参考链接

- [arXiv 2608.26587](#) — 本文预印本
- [Surgical-Alignment 实现](#) — 作者公开的代码
- [UMLS 统一医学语言系统](#) — 本文两个图谱之一，保留 107 种与诊断相关的 SNOMED CT 语义关系；CUI 概念标识符来自它
- [PrimeKG](#) — 本文另一个图谱，聚焦疾病、表型、药物三类节点
- [GRPO \(DeepSeekMath\)](#) — 组相对策略优化，本文的强化学习范式之一；选它的理由是「组内相对偏好 + KL」天然导向局部更新
- [LoRA](#) — 本文全部模型的微调方式；算梯度前先把适配器合并回基座
- [PDSQI-9](#) — 面向大模型医疗文档摘要的九判据评分量表，本文用其七条评估推理质量
- [MIMIC-III](#) — ProbSum 数据集的来源，去标识化的重症监护电子病历