

用大模型自动建本体：2026 年两篇的合读 LLM-Driven Ontology Construction: Two 2026 Papers Read Together

这份文档合读两篇 2026 年的论文，因为它们问的是同一个问题、给的答案一正一反，分开看反而不好判断。

- **OntoEKG**: LLM-Driven Ontology Construction for Enterprise Knowledge Graphs (arXiv 2602.01276, 2026-02-01, Liber AI Research)
- **LOM**: Construct, Align, and Reason: Large Ontology Models for Enterprise Knowledge Management (arXiv 2602.00029, 2026-01-18, 用友)

核心内容

Q: 这两篇都在解决什么问题? A: 同一个——**建本体太费人**。两篇的引言都说了同一件事：企业本体的构建至今仍是重人工、要反复迭代、严重依赖领域专家的活。它们想用大模型把这活自动化。**区别在于野心**：OntoEKG 只做「从文本生成本体」，LOM 要连「建完之后在本体上做推理」一起做。

Q: OntoEKG 是怎么做的? A: **拆成两步**。第一步「抽取」，用一个模型从非结构化文本里找出核心的类和属性；第二步「蕴含」，用另一个模型把这些元素组织成层级，再序列化成 RDF。**两步用了不同的模型**——抽取用 Gemini 3 Flash，蕴含用 Claude 4.5 Opus。

Q: OntoEKG 的成绩怎么样? A: **这是全文最值得看的地方，因为它诚实**。精确匹配的分数几乎是零：数据领域 0.102，金融领域 **0.000**，物流领域 0.048。换成模糊匹配（用向量相似度对齐，阈值 0.94 到 0.95）才好看一些：数据 0.724、物流 0.431、金融 0.121。**也就是说，模型生成的东西「意思差不多」，但一个字都对不上。**

Q: 金融那个 0.000 是怎么回事? A: 作者自己给了解释：**对输入文本的理解不同**，具体说是「哪些词该进本体、哪些词属于范围之外」这个判断分歧太大。这不是模型笨，是范围界定这件事本身没有唯一答案。

Q: LOM 是怎么做的? A: 三块。一、**从结构化库建本体**——很多老库的外键是缺的，它用一个多因子置信度函数去猜隐含外键，四个因子是列名语义相似度、数据类型是否兼容、取值分布重叠度、基数模式（比如一对多），加权超过阈值就连一条边。二、**从非结构化文本建本体**——切成 2000 词一块、重叠 150 词，抽实体和关系，再用三层规则消歧（编辑距离、领域归一化、向量相似度）。三、**把两边融合**，用标签与描述的匹配把文本那一侧的节点接到结构化那一侧。

Q: LOM 的成绩和消融实验说明了什么? A: 它的 40 亿参数模型在自建的图推理测评上拿到 89.47%，比 DeepSeek-V3.2 高约 10 个百分点。**但真正有信息量的是消融表：**

拿掉什么	准确率
完整模型	89.47%
拿掉思维链	78.42% (掉 11 个点)
再拿掉指令微调	61.66%
再拿掉图编码器	18.95%

最后那一行是关键：一个没有结构编码、没有针对性微调的标准大模型，在图推理上是 18.95%。作者的原话是这类模型「从根本上不具备做图推理的条件」。

Q：两篇合起来，能得出什么？ A：大模型能生成本体的草稿，但生成不了能直接用的本体。OntoEKG 那个「模糊匹配 0.724、精确匹配 0.102」的落差说明了这一点——意思对得上，词对不上，而本体这东西恰恰是词对不上就没用（判重靠的就是词一致）。LOM 从另一头证明了同一件事：要让模型在本体上推理得准，得专门训练它，通用模型不行。

背景补充 / 点评

先说这两篇的分量：都是 2026 年初的预印本，被引都是零。所以下面的判断只能基于它们自己报的数字，没有第三方复现。

OntoEKG 的作者是伦敦一家叫 Liber AI Research 的小机构，两个人。LOM 那篇的通讯作者邮箱是 yonyou.com——用友，中国的企业软件公司。所以这两篇一个是学术小团队、一个是产业界，视角不同：前者关心「能不能自动生成」，后者关心「生成完之后能不能用起来」。

我认为 OntoEKG 最有价值的不是它的方法，是它那**张精确匹配表**。一篇论文肯把 0.000 印出来，说明作者没有藏。而且它顺手解释了原因——**范围界定的分歧**。这一条比方法本身重要：**建本体最难的不是抽出概念，是决定哪些概念该进来**。这个判断需要业务方拍板，模型替不了。

OntoEKG 还报了一处很具体的失败，值得记：生成的图里「政策」和「治理标准」互为子类，那在逻辑上等于说这两个是同一个东西；另外还冒出一个含义不明的属性，在 RDF 里分不清它是「子类」还是「实例」关系。这正是我们前几轮讨论「类当实例用」时提到的那种坑，模型自己撞上了。

LOM 那篇我认为最有用的是**隐含外键那个四因子函数**，因为它是可以直接抄的工程办法。四个因子——列名语义相似、类型兼容、取值重叠、基数模式——**每一个都是可算的，不需要模型判断**。它用模型的地方只有一处：识别「number」这类关键词匹配抓不到的语义变体。

留白最大的地方，两篇都一样：没有一篇说清「生成出来的本体，人要花多少时间改」。这才是「省不省人力」的真问题。OntoEKG 说自己是个「本体设计的副驾驶」，但没测过副驾驶到底省了多少。

对我本人的启示，四条。

第一条最直接，也最扫兴：这两篇现在帮不上我们的忙。 我们建学员画像本体那几周是纯手工的，读完这两篇我原以为能找到自动化的路，结果是「模糊匹配 0.724、精确匹配 0.102」——这个成绩拿不到我们的场

景里用。我们的判重键靠的就是词一致，词对不上，整套机制就是空的。

第二条是个反向的确认。 OntoEKG 在金融领域拿 0.000，原因是「哪些词该进本体」的判断分歧。这恰好是我给学员画像定的那条纪律的外部佐证——新增字段、新增词表条目必须先问业务方，因为「这个口径业务上是否真的存在」只有懂业务的人能拍板。一篇论文用 0.000 证明了同一件事。

第三条对 prove 有用：LOM 那个隐含外键的四因子函数，值得对照我们的 `physical-registry`。 我们现在的关系是人工登记在 `rbox.yaml` 里的，没有任何机制去发现「这两列其实应该连起来但没人登记」。那四个因子都是可算的，做一个一次性的扫描脚本，用它去查我们已登记的关系有没有漏，是可行的。不是拿它自动建关系，是拿它查漏。

第四条是个警告。 LOM 的消融表说：没有结构编码和针对性微调的标准大模型，图推理准确率是 18.95%。我们的路由和链路里有若干处让模型在本体结构上做判断的地方——比如选口径、判概念归属。这个数字提醒我：凡是要求模型「沿着结构走对」的地方，都不该指望通用模型做对。我们现在的做法是把这些判断编译成确定性的规则，方向是对的；这篇给了一个量化的理由。

文中金句

"the construction of their underlying ontologies remains a resource-intensive, manual process that relies heavily on domain expertise." (OntoEKG) 这些企业知识图谱底下的本体，其构建至今仍是一个耗费资源的手工过程，严重依赖领域专业知识。

"The Finance use case was the most challenging with only 0.121 F1-score; this is likely due to different interpretations of the input text, specifically choosing which terms should be included in the ontology and which ones are out of context." (OntoEKG) 金融这个用例最具挑战性，F1 分数只有 0.121；这很可能源于对输入文本的不同理解，**具体说就是判断哪些术语该被纳入本体、哪些属于范围之外。**

"the baseline model without both the graph encoder and instruction tuning collapses to a mere 18.95%. This drastic decline confirms that standard LLMs, lacking specific structural embeddings and task adaptation, are fundamentally ill-equipped for graph reasoning."

(LOM) 同时去掉图编码器和指令微调的基线模型，准确率崩塌到区区 18.95%。**这个剧烈的下滑证实：缺少专门的结构嵌入与任务适配的标准大模型，从根本上不具备做图推理的条件。**

"graph neural networks capture topology but lack the reasoning depth for complex business questions, whereas large language models possess semantic knowledge but often

fail to adhere to rigorous graph structures." (LOM) 图神经网络能捕捉拓扑结构，但对复杂业务问题缺乏推理深度；而大语言模型拥有语义知识，**却常常无法严格遵循图的结构。**

全文翻译

第一篇 OntoEKG：把建本体拆成抽取和蕴含两步

摘要

Enterprise Knowledge Graphs have become essential for unifying heterogeneous data and enforcing semantic governance. However, the construction of their underlying ontologies remains a resource-intensive, manual process that relies heavily on domain expertise. This paper introduces OntoEKG, a LLM-driven pipeline designed to accelerate the generation of domain-specific ontologies from unstructured enterprise data.

企业知识图谱已经成为统一异构数据、施行语义治理的必需品。然而，**这些图谱底下的本体，其构建至今仍是一个耗费资源的手工过程，严重依赖领域专业知识。** 本文提出 OntoEKG，一条由大模型驱动的流水线，用于加速从非结构化企业数据生成领域专属本体。

Our approach decomposes the modelling task into two distinct phases: an extraction module that identifies core classes and properties, and an entailment module that logically structures these elements into a hierarchy before serialising them into standard RDF.

我们的方法把建模任务拆成两个不同的阶段：**一个抽取模块，负责识别核心的类与属性；一个蕴含模块，负责把这些元素在逻辑上组织成层级，然后序列化成标准 RDF。**

Experimental results highlight both the potential and the challenges of this approach, achieving a fuzzy-match F1-score of 0.724 in the Data domain while revealing limitations in scope definition and hierarchical reasoning.

实验结果同时凸显了这个方法的潜力与挑战：在数据领域取得了 0.724 的模糊匹配 F1 分数，**同时暴露出在范围界定与层级推理上的局限。**

引言：为什么要做这件事

Yet ontology construction in enterprises remains largely manual, iterative, and resource-intensive. Domain stakeholders, data architects, and semantic engineers must repeatedly negotiate conceptual boundaries, align schemas, and document modelling decisions. This motivates the development of an AI-based copilot for ontology design — one that collaborates with human experts while maintaining rigour, transparency, and governance compliance.

然而企业里的本体构建仍然基本是手工的、反复迭代的、耗费资源的。**领域相关方、数据架构师和语义工程师必须反复协商概念边界、对齐模式、记录建模决策。**这促使我们去开发一个面向本体设计的 AI 副驾驶——它与人类专家协作，同时保持严谨、透明与治理合规。

方法：形式化与流水线

Given an input text T , we infer the set of classes and the set of properties from the corpus. Each class is associated with a label and a description. Each property is associated with a label, a domain class, and a range class. Classes may also exist in a hierarchy.

给定一段输入文本，我们从语料中推断出类的集合与属性的集合。**每个类关联一个标签和一段描述。每个属性关联一个标签、一个定义域类、一个值域类。**类之间也可以存在层级关系。

The pipeline transforms unstructured enterprise text into a structured Ontology ready for Knowledge Graphs. It utilises a two-step LLM process: first to extract classes and properties, and second to reason about the hierarchical relationships between those classes.

这条流水线把非结构化的企业文本转换成一个可用于知识图谱的结构化本体。**它使用两步大模型流程：第一步抽出类与属性，第二步对这些类之间的层级关系做推理。**

评估：现有基准都不能用

To the best of our knowledge, there is a lack of comprehensive benchmarks for evaluating Ontology Construction from text. According to our findings, previous works either have failed to address the task in its entirety or do not meet the required quality standards.

据我们所知，**评估「从文本构建本体」这件事缺少全面的基准。**依我们的调查，此前的工作要么没有完整覆盖这个任务，要么达不到所需的质量标准。

Benchmarks such as Text2KGBench and OSKGC emphasise instance-level extraction within an existing framework, treating the ontology as a constraint rather than the end product.

像 Text2KGBench 和 OSKGC 这样的基准，强调的是在一个已有框架内做实例级的抽取，**它们把本体当作一种约束，而不是最终产物。**

Moreover, Task C mixes class terms with individuals, making no distinction between T-Box and A-Box.

此外，(LLMs4OL 挑战赛的) 任务 C **把类术语和个体混在一起，完全不区分 TBox 与 ABox。**

实验与结果

For the Ontological Extraction step, we chose Google Gemini 3 Flash (preview); for the Entailment step, we chose Anthropic Claude 4.5 Opus.

抽取步骤我们选用 Google Gemini 3 Flash（预览版）；[蕴含步骤我们选用 Anthropic Claude 4.5 Opus](#)。

Table I shows OntoEKG's performance considering only triples that match exactly. In Table II, we adopted embedding-based fuzzy matching to align predicted triples with their gold standard; we set a similarity threshold of (0.94, 0.94, 0.95) for the three use cases. The best performances were reached in the Data use case, where we had an F1-score of 0.724 in the fuzzy setting.

表一显示的是只算完全精确匹配的三元组时 OntoEKG 的表现（[数据领域 0.102](#)、[金融领域 0.000](#)、[物流领域 0.048](#)）。表二中我们采用基于向量的模糊匹配来对齐预测的三元组与标准答案，三个用例的相似度阈值分别设为 0.94、0.94、0.95。[表现最好的是数据这个用例，模糊匹配下 F1 分数为 0.724。](#)

The Finance use case was the most challenging with only 0.121 F1-score; this is likely due to different interpretations of the input text, specifically choosing which terms should be included in the ontology and which ones are out of context.

金融这个用例最具挑战性，F1 分数只有 0.121；[这很可能源于对输入文本的不同理解，具体说就是判断哪些术语该被纳入本体、哪些属于范围之外。](#)

Here, we can see two issues arising from the graph: "Policy" and "GovernanceStandard" were declared one the subclass of the other, implying an equivalence; also, a property was introduced, which remains ambiguous in RDF terms between `rdf:subClassOf` and `rdf:type`.

这里我们能看到生成的图里出现的两个问题：[「政策」和「治理标准」被声明为互为子类，这在逻辑上意味着两者等价](#)；另外还引入了一个属性，它在 RDF 的意义上模棱两可，分不清是「子类」还是「实例」关系。

结论

The initial results suggest that a tedious and resource-intensive task such as semantic modelling can be supported by automated techniques. We have also underscored the need for a comprehensive benchmark for Ontology Construction from unstructured data.

初步结果表明，语义建模这样繁琐且耗费资源的任务，是可以被自动化技术辅助的。[我们同时强调了「从非结构化数据构建本体」这件事需要一个全面基准。](#)

Furthermore, we expect to enable progressive construction of enterprise ontologies by feeding the existing proposed model to OntoEKG itself together with the input text, so that the model stays consistent across different source documents.

此外，我们期望实现企业本体的[渐进式构建](#)——把已经生成的模型连同输入文本一起再喂给 OntoEKG，使得模型在不同来源文档之间保持一致。

第二篇 LOM：从建到用，加上专门训练

摘要与问题

We first build a dual-layer enterprise ontology from structured databases and unstructured text, subsequently fusing these sources into a comprehensive enterprise ontology. To enable instruction-aligned reasoning, we propose a unified three-stage training pipeline.

我们首先从结构化数据库与非结构化文本构建一个**双层的**企业本体，随后把这两个来源融合成一个完整的企业本体。为了实现指令对齐的推理，我们提出一条统一的三阶段训练流水线。

On the reasoning side, a significant semantic gap persists: graph neural networks capture topology but lack the reasoning depth for complex business questions, whereas large language models possess semantic knowledge but often fail to adhere to rigorous graph structures. This disconnect hampers the ability to perform reliable, multi-hop reasoning over heterogeneous enterprise data.

在推理这一侧，存在一道显著的语义鸿沟：**图神经网络能捕捉拓扑结构，但对复杂业务问题缺乏推理深度；而大语言模型拥有语义知识，却常常无法严格遵循图的结构。**这种脱节妨碍了在异构企业数据上做可靠的多跳推理。

从结构化库建本体：靠四个因子猜隐含外键

For structured databases, where explicit foreign keys are frequently missing, we propose a multi-factor relationship discovery algorithm that analyzes both schema metadata and data content overlap to uncover implicit connections.

对结构化数据库而言，**显式外键常常是缺失的**，为此我们提出一个多因子关系发现算法，**同时分析模式元数据与数据内容的重叠，去发掘隐含的连接。**

First, we extract schemas from the source tables to identify explicit keys (e.g., fields containing 'id' or 'code'). To complement this, we utilize LOMs to detect implicit associations, capturing semantic variants like 'number' that elude simple keyword matching. Second, we perform a sliding-window deep scan to infer implicit foreign keys, utilizing a random sample of 1,000 records to assess value overlap.

第一步，我们从源表中抽取模式，识别显式的键（比如含有 id 或 code 的字段）。作为补充，**我们用模型去发现隐含关联，捕捉像「number」这类简单关键词匹配抓不到的语义变体。**第二步，我们做一次滑动窗口的深度扫描来推断隐含外键，**用 1000 条随机抽样的记录来评估取值重叠。**

We define a multifactor confidence function to quantify the relationship between columns, where S_name measures semantic similarity, l_type ensures data type compatibility, S_overlap quantifies value distribution overlap, and S_card infers cardinality patterns (e.g., one-to-many). An edge is established if the score exceeds a threshold.

我们定义一个多因子置信度函数来量化两列之间的关系，其中**四个因子分别是：列名的语义相似度、数据类型是否兼容、取值分布的重叠程度、以及基数模式的推断（比如一对多）。**加权得分超过阈值就建立一条边。

从文本建本体：切块、抽三元组、三层消歧

We deploy a locally hosted vLLM-accelerated Qwen3 model (temperature set to 0.1) to process documents segmented into 2,000-token chunks with a 150-token overlap. This model is tasked with extracting entities along with their descriptive attributes and identifying relationships.

我们部署一个本地托管、用 vLLM 加速的 Qwen3 模型（温度设为 0.1），处理被切成 **2000 词一块、重叠 150 词** 的文档。这个模型的任务是抽取实体及其描述性属性，并识别关系。

To resolve non-standard entity mentions and ambiguity, we apply layered merging rules: (1) initial surface matching via edit distance (≥ 0.85) and substring containment ($\geq 60\%$); (2) domain-specific normalization; and (3) deep semantic matching using embedding cosine similarity (≥ 0.85).

为了处理不规范的实体提及与歧义，我们应用**分层的合并规则**：一、先做表层匹配，用编辑距离（不低于 0.85）与子串包含（不低于 60%）；二、领域专属的归一化；三、用向量余弦相似度做深层语义匹配（不低于 0.85）。

结果与消融：那个 18.95%

LOM-4B demonstrates superior performance across the benchmark, achieving the top rank with an overall accuracy of 89.47%. The second-tier models, including DeepSeek-V3.2, GraphInstruct, and Doubao-1.8, achieve comparable results in the range of 78.42% to 79.47%, yet they trail LOM-4B by approximately 10%.

LOM-4B 在整个基准上表现优异，以 89.47% 的总体准确率排名第一。第二梯队的模型（包括 DeepSeek-V3.2、GraphInstruct、豆包 1.8）成绩相当，落在 78.42% 到 79.47% 之间，**但都落后 LOM-4B 约 10 个百分点**。

On fundamental graph traversal and property retrieval tasks—such as BFS, DFS, neighbor queries, and degree calculation—most advanced models achieve near-perfect accuracy (100%). However, a significant divergence in performance emerges on computationally intensive and global reasoning tasks. For PageRank and minimum spanning tree tasks, where other leading models score near 0%, LOM-4B maintains high accuracy (80% and 60% respectively).

在基础的图遍历与属性检索任务上——比如广度优先、深度优先、邻居查询、度数计算——**大多数先进模型都能达到接近满分的准确率**。然而在计算密集与全局推理的任务上，表现出现了显著分化：**在 PageRank 和最小生成树这类任务上，其他领先模型得分接近 0%，而 LOM-4B 保持了 80% 和 60% 的准确率**。

Removing the CoT reasoning mechanism leads to a significant drop of over 11%, reducing accuracy to 78.42%. Without instruction tuning, performance further degrades to 61.66%. Most strikingly, the baseline model without both the graph encoder and instruction tuning collapses to a mere 18.95%. This drastic decline confirms that standard LLMs, lacking specific structural embeddings and task adaptation, are fundamentally ill-equipped for graph reasoning.

去掉思维链推理机制会导致超过 11 个百分点的显著下滑，准确率降到 78.42%。[没有指令微调，性能进一步退化到 61.66%。最惊人的是，同时去掉图编码器和指令微调的基线模型，崩塌到区区 18.95%。](#) 这个剧烈的下滑证实：[缺少专门的结构嵌入与任务适配的标准大模型，从根本上不具备做图推理的条件。](#)

结论

By integrating a dual-layer ontology construction method with a three-stage instruction alignment pipeline, we enable the model to perform complex, structure-aware reasoning over heterogeneous enterprise data. In future work, we plan to enhance the performance of LOM on complex ontology reasoning tasks, particularly focusing on challenging tasks like MST and PageRank where current models consistently achieve low scores.

通过把双层本体构建方法与三阶段指令对齐流水线结合起来，我们使模型能够在异构企业数据上执行复杂的、结构感知的推理。未来工作中，我们计划提升 LOM 在复杂本体推理任务上的表现，[尤其聚焦于最小生成树和 PageRank 这类当前模型普遍得分很低的困难任务。](#)

参考链接

- [OntoEKG 代码与数据](#) — 论文自建的评估数据集，来自数据、金融、物流三个行业的企业内部政策文本
- [Schema.org 的数据类型](#) — OntoEKG 把数据类型「具化」成独立的类，做法参照它
- [LLMs4OL 挑战赛](#) — 本体学习方向的公开挑战赛，分四个任务；OntoEKG 指出它的任务不成串联、且任务 C 混淆了类与个体