

学员是怎么走到「求助」这一刻的 TutorTrace: A Dataset and Taxonomy for Classifying Learner Behavioral States during AI-Assisted Programming Education

源文档：David Barron、Xiaohang Tang、Rezky Dwisantika、Minsun Kim、David H. Smith IV、Jiaming Cui、Yan Chen。发表于 [UIST '26](#)——第 39 届 ACM 用户界面软件与技术研讨会，2026 年 11 月 2 - 5 日，美国底特律。ACM，21 页。DOI 10.1145/3830398.3830712。数据集公开：https://github.com/divadbaroon/TutorTrace_dataset_and_benchmark 本文的「全文翻译」一节按原文小节推进，覆盖摘要、§ 1 引言与三项贡献、§ 2.1 计算机教育中的既有分类法、§ 7.1 三个窗口的构建方法、§ 7.2 各行为画像的特征、课堂初步对比与两项预测任务。§ 3 - § 6 的数据采集实现细节、分类器规则全表、图表版式、参考文献条目不译。

核心内容

Q：这篇要解决什么问题？ A：人类家教的比较优势，在于学员开口求助之前那一段行为上下文。人类家教回应的不只是学员明确说出来的话，还有他们可观察的行为所暗示的、他们隐含需要的东西。而现在的 AI 辅导系统通常只看到问题本身，看不到问题之前的挣扎或者不挣扎。

作者把后果说得很具体：[两个学员有相似的代码、相似的错误、相似的问题，可能会得到相似的支持——尽管他们到达那一刻的过程从根本上不同。](#)

Q：TutorTrace 是什么？ A：一个数据集加一条自动化的行为抽象流水线，把低层 IDE 遥测实时变成可计算的行为上下文。规模：

项	数量
学员	480 人（四次部署，两门 Python 入门课）
细粒度 IDE 遥测事件	约 18 万条
自动分类的行为片段	13,633 个
连续计算的可观测指标	27 个
AI 交互	1,386 次

作者的对比表说明了它的位置：既有数据集要么只有静态代码提交（CSEDM）、要么只有 AI 交互日志（CodeAid）、要么是格式规范而非数据集（ProgSnap2）、要么只是演示工具（CodeWatcher 只有 3 个

开发者)。TutorTrace 是唯一一个同时具备「真实课堂部署 + 原始 IDE 遥测 + AI 问答日志 + 任务结果数据 + 专家验证过的行为分类」的。

Q: 那个「三窗口分类法」是什么？ A: 这是全文的核心产出——把学员活动按「求助周期里的三个不同时刻」切开，每个窗口有不同的行为信号、也需要不同的干预策略。

窗口 1：首次提问之前（每个学员贡献一组聚合指标）

画像	人数	特征	任务完成率
Cold Start（冷启动）	31（20%）	零代码编辑、零终端运行，但提问前平均花了 72 秒	97%
Oriented（有方向）	100（66%）	中等程度的提问前活动	92%
Struggling（挣扎）	21（14%）	平均 165 秒、4.2 次终端运行、2.5 个错误	67%

窗口 2：两次连续提问之间（每个间隔贡献一组指标，同一个学员在一次会话里可以呈现不同画像）

画像	数量	特征	完成率
Passive（被动）	318（46%）	收到上一条 AI 回答后既不编辑也不运行代码，直接又问了一个	81%
Iterating（迭代）	290（42%）	思考时间较短、有适度执行	84%
Debugging（调试）	56（8%）	平均 3.7 次终端运行、2.8 个错误	79%
Spinning（空转）	22（3%）	思考时间显著更长，平均 149 秒，但执行活动相对有限	最低

窗口 3：整个会话的重复提问模式（聚合每个学员的窗口 2 间隔，要求至少两个以保证捕捉到的是重复模式而非单次观察）

画像	人数	特征	建议干预	完成率
Passive Re-querying（被动重问）	47（42%）	反复提问，几乎没有可观的编码或执行	要求先做一个具体动作（编辑或运行代码）再给下一条回答	79%
Active Testing（主动测试）	31（28%）	提问之间常规地编辑并执行代码	用最新的测试结果指出具体错误、引导下一步	81%
Untested Editing（未测试就编辑）	34（30%）	写代码但常常没测就来问	提示学员先跑一下当前代码、看结果，再做进一步解释	88%

Q: 这套画像最反直觉的一条是什么？ A: Cold Start 学员（提问前一行代码都没写）的完成率是 97%，而 Struggling 学员（花时间最多、遇到错误最多）的完成率只有 67%。

作者对此的处理很克制：「这并不意味着低投入是有益的」，而是这个对比指向不同的教学需求——Cold Start 学员可能需要被推着独立参与，而 Struggling 学员可能已经把现有策略用尽了、需要更直接脚手架。

结论一句话：「一个自适应的辅导系统不仅应当回应先前活动的『量』，还应当回应这些活动『指示了学员处在什么进度上』。」

Q：这些画像是怎么定出来的？ A：不是拍脑袋。方法是：先用规则定义那几个极端类别（零编辑零运行 → Cold Start / Passive），剩下的活跃样本做穷举搜索式聚类——对候选指标组合跑 K-means（K 从 2 到 6，100 次初始化），丢掉任何一个簇少于 15 个观测的解，然后按下式排序：

`score = 轮廓系数 × 完成率跨度`

这里有一处方法论上的自觉，值得单独记：窗口 1 和窗口 2 的方案选择用到了完成率，所以作者明确声明「各簇之间完成率的差异是描述性的，而不是确证性的」。而窗口 3 的构建与选择完全没有用到完成率（只按最高轮廓系数选），所以它的完成率同样只作描述报告。

窗口 3 的最优解在 K=3（轮廓系数 0.399），20 个随机种子下分配完全相同（调整兰德指数 = 1.000）。

Q：有没有证据说这套东西真有用？ A：三层证据，强度递减，作者标得很清楚。

第一，分类器与专家的一致性：分类器基于专家开发的规则，对照专家标注与学生自述双重验证，总体两两一致率 78% - 87%。

第二，课堂初步对比：把「行为感知的提示」用上去之后，Passive（被动）的提问间窗口从基线部署的 50.0% 降到干预部署的 20.7%（-29.3 个百分点），Iterating 从 39.1% 升到 56.0%（+16.9pp）。整体窗口 2 画像分布差异显著（ $\chi^2(3)=27.55$, $p<.0001$ ），按学员层面比较各自的 Passive 窗口占比也显著（ $U=1533$, $p<.0001$ ）。

但作者立刻声明：「这项初步评估不测量学习增益，也不确立因果效应。」

第三，两项留出预测任务：60 秒内学员是否会发起 AI 提问（AUROC = .726）；即将到来的提问反映的是引导型还是依赖型求助（AUROC = .717）。

背景补充 / 点评

几个术语先落地：

- UIST 是 ACM 用户界面软件与技术研讨会，人机交互领域的顶级会议之一，偏系统与交互技术。
- 轮廓系数（silhouette）衡量聚类质量：一个点与自己簇内其他点的距离，相对于它与最近的其他簇的距离。越接近 1 说明簇越紧凑分离。
- 调整兰德指数（ARI）衡量两次聚类结果的一致程度，1.000 表示完全相同。作者用它来说明结果不依赖随机种子。
- AUROC 是二分类模型的判别能力，0.5 是随机，1.0 是完美。.72 左右属于「有信号但不强」——作者用它来展示下游可用性，没有声称它可以直接部署做决策。
- ProgSnap2 / CSEDM / CodeAid / CodeWatcher 是计算机教育领域既有的数据集或格式规范，作者用一张表说明各自缺什么。

有一条背景对使用布鲁姆分类法的人是个警告。作者在相关工作里写道：计算机教育过去用教育分类法来设计学习目标、评估学习效果，但研究者已经论证过——布鲁姆分类法与 SOLO 这类通用框架，并不能完全捕

捉计算机科学学习的独特特征，在编程相关情境下尤其如此。

我的判断——这篇最值钱的不是那十个画像，是「三窗口」这个切法本身。

同一个学员在同一次会话里，**在窗口 2 的不同时刻可以呈现不同画像**（作者明说「学员可以贡献多个窗口 2 观测，并可能在会话的不同点上表现出不同画像」）。这意味着行为状态不是一个人的属性，是一个时刻的属性。而窗口 3 才把它聚合回学员层面——并且要求至少两个间隔，明确是为了「捕捉重复模式而非单次观察」。

「什么东西挂在人身上、什么东西挂在时刻上」这个区分，比画像本身可迁移得多。

留白在哪：三处，作者认了两处半。

第一，**纵向覆盖是缺的**。作者自己那张对比表里，「Longitudinal coverage (semester)」那一行 TutorTrace 打的是 **x**——CSEDM、ProgSnap2、CodeAid 都有整学期覆盖，它没有。所以这些画像是会话内的，不能回答「一个学员在一学期里怎么变化」。

第二，**因果性完全没有**。课堂对比是「初步的」，**不测学习增益、不确立因果**。50.0% → 20.7% 这个数字很好看，但它证明的只是「行为感知提示与更少的被动重问相关联」。

第三，**这一条作者没说而我认为要紧**：三个窗口的画像都是用完成率来命名和解读的（哪怕窗口 3 没用它做选择），而完成率本身是一个很粗的成功指标。Cold Start 完成率 97% 但一行代码没写——**这更可能说明那些任务对这批学员偏简单，而不是说明「不写代码先问」是好策略**。作者虽然警告了「不意味着低投入有益」，但没有讨论任务难度这个混淆因素。

对我的启示：这篇几乎是为 user_profile 的学情子画像写的，而且它把我们还没做的几件事做出来了。

第一，「行为状态属于时刻、不属于人」这个区分，我们现在没有。 我们的学情子画像记的是「学员 u_10086 掌握框架型判断，已有基础」——这是一条挂在人身上的断言。而这篇提示的是：同一个学员在不同时刻的行为状态可以完全不同，把它压成一个人的属性会丢掉信息。窗口 2 与窗口 3 的分工正是这件事：先在时刻上分类，再要求「至少出现两次」才聚合成人的特征。

这对我们那条「多次观察累积」的设计是个具体的实现范式——**不是简单地把多次观察加起来，而是先在事件层面分类、再要求重复出现才提升为画像**。

第二，「不同画像需要不同干预」这条我们已经在做，但缺一张对照表。 窗口 3 那三个画像各自配了一句干预建议（被动重问 → 先要求一个具体动作；未测试就编辑 → 先跑一下看结果）。我们的「教学适配规则」子画像装的正是这类东西，但目前是散的，没有「画像 → 干预」这种一一对应的结构。这篇给了一个可抄的形状。

第三，那条方法论自觉我该抄：「用来选模型的指标，不能同时当作验证模型的证据。」 作者因为窗口 1、2 的聚类方案选择用到了完成率，就明确声明各簇的完成率差异只是描述性的；而窗口 3 完全不用完成率选，所以它的地位更硬。

这和我 8/30 记的那条是同一件事的另一面——那条是「用来验证一个机制的证据，不能是那个机制自己产生的」，这条是「用来做选择的指标，不能同时当作那个选择的证据」。两条合起来是一个完整的纪律。

第四，那个 78% - 87% 的一致率给了我一个参照点。我们做受控词表和判重时，「多少一致率算够用」一直没有标尺。这篇是 UIST 收录的工作，分类器与专家的两两一致率在 78 - 87% 就被认为可以支撑后续分析。这不是标准，但至少是一个可引用的量级。

第五，那条布鲁姆的警告要认真对待。我们把布鲁姆认知六级当学情的取值域，而这篇引的研究说通用框架捕捉不了特定学科的独特特征。我们的场景是企业培训不是编程，但这个警告的形状是一样的：一个跨领域通用的分类法，落到具体学科时可能不够用。至少应当在 spec 里留一句：布鲁姆是起点不是终点，如果发现某个业务领域的掌握度用六级说不清，那是预期之内的，该补领域特定的维度。

文中金句

"Human tutors respond not only to what learners explicitly say, but also to what their observable behaviors suggest they implicitly need." 人类家教回应的不只是学员明确说出来的话，还有他们可观察的行为所暗示的、他们隐含需要的东西。

"Two learners with similar code, errors, and questions may receive similar support despite arriving at that moment through fundamentally different processes." 两个学员有相似的代码、错误和问题，可能会得到相似的支持——尽管他们到达那一刻的过程从根本上不同。

"Unlike existing datasets that capture only what learners submit or ask, TutorTrace captures the story of how they got there." 与只捕捉「学员提交了什么、问了什么」的既有数据集不同，TutorTrace 捕捉的是「他们是怎么走到那一步的」这个故事。

"Because completion informs the selection of the final solution, the resulting differences in completion rates across clusters are descriptive rather than confirmatory." 由于完成率参与了最终方案的选择，各簇之间完成率的差异是描述性的，而不是确证性的。

"An adaptive tutor should therefore respond not only to the amount of prior activity, but also to what that activity indicates about the learner's progress." 因此一个自适应的辅导系统不仅应当回应先前活动的量，还应当回应这些活动指示了学员处在什么进度上。

全文翻译

覆盖范围：摘要、§ 1 引言与三项贡献、§ 2.1 计算机教育中的既有分类法、§ 7.1.1 - 7.1.3 三个窗口的构建、§ 7.2 各画像的特征、课堂初步对比、两项预测任务。§ 3 - § 6 的数据采集与分类器实现细节、规则全表、图表版式、参考文献条目不译。

摘要 Abstract

AI programming tutors provide scalable support, yet lack the behavioral context human tutors rely on to adapt support to learners' needs. We present TutorTrace, a dataset and behavioral abstraction pipeline that makes learners' behavioral context visible and computable in real time from low-level IDE telemetry.

AI 编程助教提供了可规模化的支持，**却缺少人类家教赖以按学员需求调整支持的那种行为上下文**。我们提出 TutorTrace——一个数据集与行为抽象流水线，**把学员的行为上下文从低层 IDE 遥测中实时地变得可见、可计算**。

Across four deployments in two introductory Python courses (N=480), TutorTrace captures approximately 180K telemetry events, 13,633 behavioral segments, and 27 continuously computed metrics. From this foundation, we derive a taxonomy of learner activity before the first AI query, between consecutive queries, and across the full session, enabling systems to respond not just to what learners say, but to what they have done leading up to the help-seeking moment.

在两门 Python 入门课的四次部署中（**N=480**），TutorTrace 采集了约 **18 万条**遥测事件、**13,633 个**行为片段与 **27 个**连续计算的指标。在此基础上，我们导出一套分类法，刻画学员在**首次 AI 提问之前、在连续提问之间、以及贯穿整个会话的活动**，**使系统能够回应的不只是学员说了什么，还有他们在走到求助那一刻之前做过什么**。

In a preliminary classroom evaluation, behavior-aware prompts were associated with a decrease in intervals between queries with no independent work from 50.0% to 20.7%.

在一次初步的课堂评估中，**行为感知的提示与「提问之间没有独立工作的间隔占比」从 50.0% 降到 20.7% 相关联**。

引言：人类家教的比较优势在哪 Introduction

Large Language Models have improved personalized computing education by providing learners with near-instant, in-depth responses built on a knowledge base no single tutor can compete with. Yet, one-on-one human tutoring remains the gold standard for improving learner outcomes.

大模型通过提供近乎即时、深入、且建立在**任何单个家教都无法比拟的知识库**之上的回答，改善了个性化的计算教育。然而，**一对一的人类辅导仍然是提升学员成效的黄金标准**。

One key reason is that human tutors respond not only to what learners explicitly say, but also to what their observable behaviors suggest they implicitly need.

一个关键原因是：人类家教回应的不只是学员明确说出来的话，还有他们可观察的行为所暗示的、他们隐含需要的东西。

作者随后给了一段设想（原文以引文块排版）：

设想一下，一门 400 人的编程课上，每个学生旁边都坐着一位家教，观察他们在做什么、在哪里卡住。这位家教知道什么时候该推他们一把、什么时候该放慢并给予支持。他能分辨出「一个正在挣扎的学生」和「一个还没下过功夫的学生」之间的差别。

要实现这个愿景，需要能够从细粒度交互数据中实时推断学员不断演变的行为上下文的系统——而这既是一种能力，也是一种数据资源，我们这个社区目前还没有。

The human tutor's comparative advantage lies in the behavioral context that precedes the learner's help-seeking moment. Current AI tutoring systems are typically limited to the question itself, missing the struggle or lack thereof that preceded it.

人类家教的比较优势，在于学员求助那一刻之前的行为上下文。现有的 AI 辅导系统通常局限于问题本身，错过了在它之前的挣扎、或者没有挣扎这一事实。

Prior work shows that the behavioral context surrounding a help-seeking moment is associated with learning outcomes, and specific interaction patterns distinguish effective from ineffective AI use. Students who invest independent effort before receiving instruction learn more from it, and a student's behavioral context directly informs the tutor's pedagogical strategy for intervening.

已有工作表明，围绕求助时刻的行为上下文与学习成效相关，而特定的交互模式能区分有效与无效的 AI 使用。在接受讲授之前投入过独立努力的学生，从讲授中学到的更多；而一个学生的行为上下文直接决定了家教介入时的教学策略。

Yet current AI tutoring systems typically respond to the information learners explicitly provide rather than the behavioral process that preceded it. As a result, two learners with similar code, errors, and questions may receive similar support despite arriving at that moment through fundamentally different processes.

然而现有的 AI 辅导系统通常回应的是学员明确提供的信息，而不是在它之前的行为过程。结果是：两个有着相似代码、错误和问题的学员，可能会得到相似的支持——尽管他们到达那一刻的过程从根本上不同。

三项贡献：

- **TutorTrace 数据集**：来自两门 Python 入门课四次部署的 480 名学员，约 18 万条细粒度 IDE 遥测事件，映射到 13,633 个自动分类的行为片段，外加环绕 1,386 次 AI 交互的 27 个连续计算的可观测指

标。

- **TutorTrace 分类器**：一个把原始 IDE 遥测实时转换成带标签行为序列的自动分类器。它建立在专家开发的规则之上，并对照专家标注与学生自述做了验证，总体两两一致率在 78% 到 87% 之间。
- **TutorTrace 分类法与下游可用性**：三窗口行为分类法（十个画像）；一次课堂初步对比；两项留出预测任务。

相关工作：通用教育分类法在编程情境下不够用 Prior Taxonomies

Taxonomies typically organize distinct, non-overlapping categories across one or more dimensions while also revealing relationships among the taxa. Past studies in CS education have employed educational taxonomies to design learning objectives and assess learning effectiveness, though researchers have argued that general-purpose frameworks such as Bloom's taxonomy and SOLO do not fully capture the distinctive characteristics of computer science learning, particularly in programming-related contexts.

分类法通常在一个或多个维度上组织互不重叠的类别，同时揭示各分类单元之间的关系。 计算机教育领域过去用教育分类法来设计学习目标、评估学习效果，**尽管研究者已经论证过：布鲁姆分类法与 SOLO 这类通用框架，并不能完全捕捉计算机科学学习的独特特征，在编程相关情境下尤其如此。**

（这一句对任何打算把布鲁姆当作通用刻度的项目都是一个提醒。）

三个窗口是怎么构建出来的 Constructing the Three Windows

共用的搜索方法：对候选指标组合做穷举搜索，用 K-means ($K \in \{2,3,4,5,6\}$ ，100 次初始化) 聚类。**丢弃任何一个簇少于 15 个观测的解。** 对每个剩余解计算其轮廓系数与「最高、最低任务完成率之间的跨度」，按下式排序：

$$\text{score} = \text{轮廓系数} \times \text{完成率跨度}$$

We perform clustering using behavioral metrics only. Completion rates are used to select among candidate solutions that produce behaviorally distinct groups. Because completion informs the selection of the final solution, the resulting differences in completion rates across clusters are descriptive rather than confirmatory.

我们仅使用行为指标做聚类。完成率只用于在那些产出行为上可区分的候选方案之间做选择。由于完成率参与了最终方案的选择，各簇之间完成率的差异是描述性的，而不是确证性的。

窗口 1（首次提问之前）：每位学员贡献一组聚合指标。**提问前零代码编辑且零终端运行的学员，被规则直接判为 Cold Start (n=31)**；其余 121 名活跃学员进入穷举搜索。最高排名的解使用

`time_in_editor_s`、`time_in_terminal_s`、`time_in_chat_s`，在 $K=2$ （轮廓系数 0.420，完成率跨度 25.3 个百分点），得到 **Oriented (n=100)** 与 **Struggling (n=21)**。

加上 Cold Start, 这三个画像区分出: 完全没有可观察编程尝试就来求助 / 有中等程度的主动尝试 / 经历了一段较长但不成功的努力。

窗口 2 (两次连续提问之间): 每个间隔贡献一组聚合指标, 因此同一学员可以贡献多个窗口 2 观测, 并可能在会话的不同点上表现出不同画像。收到上一条 AI 回答后零编辑零运行的间隔, 被规则判为 **Passive** (n=318); 其余 368 个活跃窗口进入搜索。最高排名解使用 `time_in_editor_s`、`thinking_time_s`、`error_self_fix`, 在 K=3 (轮廓系数 0.547, 完成率跨度 33.8 个百分点), 得到 **Iterating** (n=290)、**Debugging** (n=56)、**Spinning** (n=22)。

窗口 3 (整个会话的重复提问模式): 窗口 2 刻画的是单个提问间时刻, 窗口 3 概括的是「某种提问间行为是否在会话中反复出现」。聚合每位学员的有效窗口 2 间隔, 只保留至少有两个这类间隔的学员, 以确保该表示捕捉的是一个重复模式而不是单次观察, 得到 112 名合格学员。

每个提问间间隔被分入三个互斥的行为类别之一: **Passive** (无代码编辑也无终端运行)、**Tested** (至少一次终端运行)、**Active Untested** (有代码编辑但无终端运行)。然后用四个会话层面的量表示每位学员: Passive 间隔占比、Tested 间隔占比、Active Untested 间隔占比, 以及按该学员有效间隔数归一化后的最长连续 Passive 连击。

Unlike Windows 1 and 2, task completion is not used for either clustering or model selection; we select the eligible solution with the highest silhouette score.

与窗口 1 和窗口 2 不同, 任务完成率在聚类与模型选择中都没有被使用; 我们选择轮廓系数最高的合格方案。

最高轮廓系数出现在 K=3 (s=0.399), 产出 **Passive Re-querying** (n=47)、**Active Testing** (n=31)、**Untested Editing** (n=34)。在 20 个随机种子下分配完全相同 (ARI=1.000)。

各画像的特征与教学含义 Characteristics of Behavioral Profiles

窗口 1: Cold Start 学员占窗口 1 人群的 20% (n=31)。这些学员在首次提问前没有做任何代码编辑或终端运行, 尽管他们的提问前时段平均有 72 秒。对应会话的完成率是 97%。Oriented 学员 (n=100, 66%) 表现出中等的提问前活动, 完成率 92%。相比之下, **Struggling** 学员 (n=21, 14%) 在提问前花的时间显著更长, 平均 165 秒、4.2 次终端运行、2.5 个错误。他们对应会话的完成率是 67%。

These profiles complicate the assumption that greater pre-query effort necessarily signals better progress. Rather than implying that low effort is beneficial, this contrast suggests different pedagogical needs: Cold Start learners may require prompting to engage independently, while Struggling learners may have exhausted their current strategies and require more direct scaffolding.

这些画像使「提问前投入越多就代表进展越好」这个假设变得复杂。Cold Start 学员在没有任何可观察编程尝试的情况下高比例完成任务, 而 Struggling 学员投入了最多时间、遇到最多错误, 完成率却最低。

这并不意味着低投入是有益的；这个对比指向的是不同的教学需求：Cold Start 学员可能需要被促使去独立参与，而 Struggling 学员可能已经把当前策略用尽了，需要更直接的脚手架。因此一个自适应的辅导系统不仅应当回应先前活动的量，还应当回应这些活动指示了学员处在什么进度上。

窗口 2: Passive 行为占有效提问间窗口的 46% (n=318) ——在这些窗口里，学员在收到上一条 AI 回答后既没有编辑也没有执行代码，就又发了一个问题。对应会话完成率 81%。

在活跃窗口中，Iterating 最常见 (n=290, 42%)：思考时间相对短、执行活动适中，完成率 84%。Debugging 窗口 (n=56, 8%) 执行与错误恢复更频繁，平均 3.7 次终端运行、2.8 个错误，完成率 79%。Spinning 窗口 (n=22, 3%) 思考时段显著更长，平均 149 秒，但执行活动相对有限，完成率在窗口 2 各画像中最低。

窗口 3 的三个画像各配一条干预建议 (原文以图 3 呈现)：

画像	行为描述	建议干预
Passive Re-querying	反复重问，几乎没有可观察的编码或执行	在给出下一条回答之前，要求一个具体动作，例如编辑或运行代码
Active Testing	在提问之间规律地编辑并执行代码	用最新的测试结果指出具体错误、引导下一步
Untested Editing	写代码但常常没测就来问	提示学员先运行当前代码并检视结果，再做进一步解释

课堂初步对比 Preliminary Classroom Comparison

This preliminary evaluation does not measure learning gains or establish a causal effect.

这项初步评估不测量学习增益，也不确立因果效应。

Passive 提问间窗口在基线部署中占有效窗口的 50.0%，在干预部署中占 20.7% (-29.3 个百分点)；Iterating 窗口分别为 39.1% 与 56.0% (+16.9pp)。整体窗口 2 画像分布在两次部署之间存在差异 ($\chi^2(3)=27.55$, $p<.0001$)。由于同一学员可以贡献多个窗口，我们还比较了每位学员各自的 Passive 窗口占比，这个学员层面的比较同样显著 ($U=1533$, $p<.0001$)。干预部署也表现出更多的代码编辑。

两项预测任务 Two Held-out Prediction Tasks

作为下游可用性的额外展示，作者在两个留出任务上评测 TutorTrace：

- 学员是否会在接下来 60 秒内发起提问：AUROC = .726
- 即将到来的提问反映的是引导型还是依赖型求助：AUROC = .717

Together, these findings show how behavioral context can enable adaptive AI tutoring at scale.

这些结果合起来展示了行为上下文如何能在规模上支撑自适应的 AI 辅导。

参考链接

- [TutorTrace 数据集与基准](#) — 本文公开的数据集与代码
- [DOI 10.1145/3830398.3830712](#) — 本文在 ACM 数字图书馆的正式条目
- [UIST 2026](#) — 第 39 届 ACM 用户界面软件与技术研讨会
- [ProgSnap2](#) — 计算机教育领域的编程过程数据格式规范，本文对比表中的基线之一
- [CSEDM Data Challenge](#) — 计算机教育数据挖掘数据挑战赛，本文对比表中的基线之一