

让大模型装成差生，它装不像 From Mastery Profile to Simulated Response: Stochastic Student Knowledge Graph

源文档：Drexel 大学团队（含暑期实习生）。arXiv 预印本，2026-08。本文的「全文翻译」一节按原文小节推进，覆盖摘要、§I 引言与四项贡献、§II 相关工作（教育知识图谱、随机与概率知识图谱）、§IX 四段消融的设计、§X 评测（实验设计、数据集、指标、四个问题的结果）、§XI 讨论。§III - §VIII 的形式化定义与构建细节、图表版式、参考文献条目不译。

核心内容

Q：这篇要解决什么问题？ A：合成学生答题数据在真实课堂数据昂贵、缓慢或因伦理限制难以规模采集时很有价值——用途包括在课程开课前就训练知识追踪模型、在各种掌握度上压测智能辅导系统、以及在题目送到真实学生手上之前先做试测。

大模型是生成这类数据的诱人引擎，但**真正的问题是控制**。作者把它问得很干脆：「给定一个基本能完美解出整个课程题目的大模型，你怎么让它表现得像一个解不出来的学生？」

Q：现在大家怎么做？为什么不行？ A：文献和实践中常见的做法是在提示词里描述你想要的那种学生——指定技能水平、考试成绩、或者一个原型学生画像——然后让大模型自己决定答案和解释。

作者用一个具体、现实的基准证明这个做法失败了。

379 道 SAT 代数选择题、5 个原型画像（从接近专家到严重缺漏）、三个厂商的三个模型（Gemini 3.1 Flash Lite、Claude Haiku 4.5、GPT-5.4-mini）：

画像	直接提示法的准确率
P1（高掌握）	100.0%
P2	99.7%
P3（提示词明写「低掌握度的吃力学生」）	96.8%
P4（早期章节有缺口）	100.0%
P5（后期章节有缺口）	100.0%

无论画像是什么，准确率都在 **96.8 - 100%**，和「完全不加约束的 100% 天花板」无法区分。而且不是某一个厂商或模型家族的毛病——Claude Haiku 4.5 和 GPT-5.4-mini 更平，每个画像都在 99.2 - 99.7%，GPT 的 P3 甚至超过了它自己的 P2。

更糟的一条：两个被特意设计成「带结构化、章节局部化缺口」的诊断画像（P4、P5），对每一个被测模型来说，都与高掌握画像在统计上无法区分。

作者注明这不是孤立的新观察——它复现并扩展了一个此前在 GPT-3.5 上、在非数学领域报告过的「能力偏置」发现，这次是在更大规模、数学推理题、跨多个模型上确认的。

Q：他们的办法是什么？ A：随机学生知识图谱（SSKG）。四步：

- 1. 从一本开放的代数教材里抽出课程知识图谱（CKG），864 条细粒度三元组。
- 2. 把每道 SAT 题的解法分解成一条「所需三元组的链」。
- 3. 一个学生画像被表示成 SSKG——给 CKG 里每一条三元组在某个时间点赋一个掌握概率。
- 4. 模拟时，拿这道题所需的三元组链去对着画像的掌握向量做显式采样，这一步解析地决定了两件事：这个模拟学生答对没有；以及如果答错，是哪一个知识单元先崩的。最后才叫大模型生成一段与已经定好的结果相一致的第一人称说理。

关键的架构差别在这里：传统做法（图 1a）把题目和画像直接丢给大模型，由它同时决定答案和对错；SSKG 做法（图 1b）由采样先定对错，大模型只负责把已定的结果讲成人话。

Q：效果如何？ A：准确率从平坦的 96.8 - 100% 掉到 44.1 - 85.2%，并且出现了清晰的单调掌握度梯度：

画像	arm-d 准确率
P1（高）	85.2%
P2（中）	57.8%
P3（低）	44.1%

相邻两档的差距都是决定性的；而直接提示法唯一一个非零的差距是 P2 与 P3 之间的 2.9%——那就是它能产生的全部掌握度信号。

作者的评价很准：「直接提示法并不是在任何有用的意义上『更准确』；它是对画像不敏感。」

Q：四段消融各自贡献了什么？ A：他们把方法设计成四个累积的消融臂，好让任何增益都能归因到具体机制：

臂	加了什么	效果
arm-a	单次抽样：每条所需三元组抛一次伯努利，链上每一条同等要紧	基线
arm-b	检索/执行分解（知识追踪）：把「这条事实对该学生是否可得」与「它是否被无误地应用」分开	-9.5 到 +0.0pp
arm-c	分类法加权：漏掉一条纯定义性事实（比如忘了变量是什么），后果不该和漏掉一条程序性或关系性的（比如多步方法用错、解题路径选错）一样重	+14.0 到 +19.5pp, 最大的一档

臂	加了什么	效果
arm-d	干扰项路由：不是均匀地随便选一个错误选项，而是由「在哪条三元组上失败」决定选中那个失败会导出的特定错误选项	准确率 0.0pp，但改善诊断价值

arm-b 那一档的方向很有说服力：P1 的准确率降了 9.5%，其他画像最多降 2.1%——效果恰好集中在该集中的地方。而且 P1 在 arm-b 下新失败的全部 36 道题，都被归类为「执行失败」，没有一道被归成「检索失败」。作者的解释一句话：「一个从不失手的准专家不是一个现实的顶尖学生。」

arm-d 不改准确率是按构造必然的（ $\text{arm-d} = \text{arm-c}$ ），它只贡献诊断能力：1,895 条记录里有 19 条（1.0%）的执行失败被路由到了它对应的那个错误选项，而每一条的叙述都描述了那个具体的单步错误，而不是一个笼统的「做错了」。

Q：诊断能力有多真？ A：这是我认为最该记的一处，因为作者刻意绕开了自己的标注机制去验证。

arm-d 会**按构造**给每个错误答案打上 `first_failed_triple_id` 和 `failure_kind`（检索 or 执行）。但如果只用这套标注来证明「我们能诊断」，那是循环论证。所以他们改用独立于该机制的经验相关性：

- 汇集 525 个（三元组，画像）配对（限定该三元组至少出现在 3 条题目链里），某画像下某条三元组的掌握度，与该画像在需要这条三元组的题目上的错误率，Spearman $\rho = -0.459$ ($p \approx 10^{-28}$)。
- 单题层面，链上的瓶颈三元组（掌握度最低那条）与该题结果的相关是 $\rho = 0.318$ ——这个更弱是预期之内的，因为单个瓶颈值无法完全刻画一条合取链。

另外，**全部 1,895 条 arm-d 叙述中，叙述给出的最终答案与采样器定下的答案完全一致，零违反**，包括那 19 条触发了干扰项路由、叙述必须自己推导出那个特定错误选项的记录。

背景补充 / 点评

几个术语先落地：

- **知识追踪 (knowledge tracing)**：教育数据挖掘里的经典任务，根据学生的答题序列估计他对各知识点的掌握状态。这篇借用的是它的**「检索 vs 执行」二分**——一条知识取不出来和取出来了但用错了，是两种不同的失败。
- **合取链 (conjunctive chain)**：一道题需要 N 条知识全都到位才能做对，所以正确概率是各条掌握概率的乘积。这带来一个副作用，作者在 P5 那里专门解释了：链越长，每多一步就多乘一个存活概率，所以「混合章节」的题目对 P5 最难，不是因为它插值在早期与后期之间，而是因为它「两个band都要用到，且总步数更多」。
- **PR-OWL / NELL / 不确定知识图谱嵌入**：相关工作里列的三条概率知识图谱路线——分别是给 OWL 加贝叶斯语义、给开放信息抽取的每条信念附置信度并只提升过阈值的、以及给每条三元组附置信度并学习能预测未见三元组置信度的嵌入。

我的判断——这篇最值钱的是那张「直接提示法在六个格子里全部 100.0%」的表。

技能特异性检验 (Q2) 把 379 道题按链的覆盖范围切成三份 (140 道只用早期、143 道混合、96 道只用后期)，然后看 P4 (早期弱) 和 P5 (后期弱) 会不会在各自该弱的地方弱：

画像	方法	早期	混合	后期
P4 (早期弱)	直接提示	100.0%	100.0%	100.0%
P4	arm-d	39.3%	39.9%	75.0%
P5 (后期弱)	直接提示	100.0%	100.0%	100.0%
P5	arm-d	70.0%	48.3%	62.5%

直接提示法在全部六个格子里都是 100.0%——它根本无法表达一个技能局部化的缺口。这比「准确率太高」严重得多：它不是把差生装得不够差，是压根没有「差在哪」这个维度。

还有一处设计值得单独夸：难度检验是「标签盲」的。SAT 官方难度标签从来不是第一阶段的输入，所以输出里出现的任何难度模式都是涌现的。结果是 P3 显示出清晰的单调斜率 (易 48.3% > 中 40.8% > 难 39.2%)，而其他画像平坦或非单调——这与「难度标签只和链长及组成弱相关 (Spearman 0.209)」这个事实一致，而链长与组成才是真正驱动采样器的东西。用一个模型没见过的外部标签去检查输出，是比自证更强的验证。

留白在哪：三处。第一，arm-b 的方向虽然对，但幅度很小 (-9.5 到 +0.0pp)，作者自己说「因为它只改了一个参数」。第二，P5 的模式没有走出预期形状——它最弱的格子是「混合」而不是「后期」，虽然作者给了合理的机制解释 (链长惩罚)，但这意味着技能特异性这个性质只在 P4 上干净地成立。第三，只有 P3 显示出清晰的难度梯度，其余画像平坦或非单调，作者也承认「技能特异性与涌现难度的结果比较混杂」。

我要补一条作者没说的：这套方法把「对错」从大模型手里拿走了，但「说理」还在大模型手里。论文验证了叙述的最终答案与采样器一致 (0 违反)，但没有验证叙述的推理过程是否真的体现了那条失败的三元组。一个模型完全可以给出正确的最终错误答案，同时编一段与 first_failed_triple_id 无关的理由。这正是生成合成训练数据时最要紧的那部分质量——如果下游要拿这些说理去训练诊断模型，那段说理的忠实度就是核心，而它目前只被验证到了「答案一致」这一层。

对我的启示：这篇和我在 user_profile 上做的学情子画像几乎是同一件事，而且它把我们还没想清楚的几处直接做出来了。

第一，也是最重要的一条：如果我们打算用大模型模拟学员来测系统，这条路按这篇的证据是走不通的。三个厂商、五个画像、379 道题，准确率全部 96.8 - 100%，连提示词里明写「低掌握度的吃力学生」都不管用。「在提示词里描述一个学生」不是一个有效的控制手段。这条结论对我们要不要做「学员模拟」这类功能是直接的。

第二，「检索 vs 执行」这个二分我们没有。我们的学情子画像现在用布鲁姆六级当掌握度的取值域，但那是一个维度上的程度。这篇提示的是另一个正交的维度：一条知识取不出来 (retrieval) 和取出来了但用错 (execution) 是不同的失败，而且它们对应不同的教学干预。我们的「学情」记录目前无法区分这两者。

第三，arm-c 那个「分类法加权」正是我们已经有的东西，但我们没用它做加权。作者说「漏掉一条纯定义性事实不该和漏掉一条程序性/关系性的一样重」——这正是布鲁姆的知识维度四类 (事实性、概念性、程序

性、元认知) 在起作用, 而这是我们受控词表提案里「内容条件」那张清单的四条取值。我们把它当成了分类标签, 这篇把它当成了权重。而且它是四段消融里增益最大的一档 (+14.0 到 +19.5pp)。

第四, 那个「**绕开自己的标注机制去验证诊断能力**」的做法, 是我该抄的验证纪律。他们本可以拿

`first_failed_triple_id` 自证「我们能诊断」, 但那是循环的; 他们改用独立的经验相关性 ($\rho = -0.459$, $p \approx 10^{-28}$)。我们做判重、做消解时, 也很容易用「我们自己打的标签」去证明「我们标得对」。这条要记: 用来验证一个机制的证据, 不能是那个机制自己产生的。

第五, 「**合取链的长度惩罚**」这个副作用对我们也成立。如果我们把一个能力拆成多个细粒度条目、再要求全部满足, **条目越细, 达标概率越低**——这不是学员变差了, 是我们的建模粒度在制造难度。P5 那个「混合最弱」的现象就是这个。

文中金句

"The open question is control: given an LLM that can solve a curriculum's questions essentially perfectly, how does one make it behave like a student who cannot?" **真正的问题是控制: 给定一个基本能完美解出整个课程题目的大模型, 你怎么让它表现得像一个解不出来的学生?**

"Three LLMs spanning three vendors answer at 96.8-100% accuracy regardless of profile, including under a profile explicitly labeled 'struggling student who has low mastery of most algebra concepts.'" 横跨三个厂商的三个大模型**无论画像是什么, 准确率都在 96.8 - 100%**——包括在一个明写着「大多数代数概念掌握度都很低的吃力学生」的画像之下。

"Method 1 is not 'more accurate' in any useful sense; it is insensitive to the profile." **直接提示法并不是在任何有用的意义上「更准确」; 它是对画像不敏感。**

"Method 1 is 100.0% in every one of the six cells: direct prompting cannot express a skill-localized gap at all." 直接提示法在**六个格子里每一个都是 100.0%: 它根本无法表达一个技能局部化的缺口。**

"A near-expert who never slips is not a realistic top student." **一个从不失手的准专家, 不是一个现实的顶尖学生。**

全文翻译

覆盖范围：摘要、§ I 引言与四项贡献、§ II.A 教育知识图谱、§ II.B 随机与概率知识图谱、§ IX 四段消融的设计、§ X.A 实验设计、§ X.B 数据集、§ X.C 指标、§ X.D 四个问题的结果、§ XI 讨论。§ III - § VIII 的形式化定义与构建细节、图表版式、参考文献条目不译。

摘要 Abstract

Large language models are increasingly used to simulate students at different mastery levels. These simulations can generate synthetic training data and stress-test tutoring systems. However, common prompt-based approaches leave the answer decision to the LLM, which tends to perform according to its built-in capabilities even when instructed to simulate a student with low mastery. As a result, these approaches may have difficulty distinguishing students with low and high levels of mastery.

大模型越来越多地被用于[模拟不同掌握度的学生](#)。这类模拟可以生成合成训练数据、并压测辅导系统。然而常见的基于提示词的做法把「答案决策」留给了大模型，而大模型即便被指示去模拟一个低掌握度的学生，仍倾向于按它自己的内建能力来表现。结果是，这些做法可能难以区分低掌握与高掌握的学生。

We demonstrate this limitation using 379 SAT Algebra items and five archetypal mastery profiles. Three LLMs from three vendors achieve 96.8-100% accuracy across all profiles.

我们用 [379 道 SAT 代数题与五个原型掌握画像](#)展示了这个局限：来自三个厂商的三个大模型在[所有画像上都达到 96.8 - 100% 的准确率](#)。

To address this limitation, we introduce a method grounded in a Stochastic Student Knowledge Graph (SSKG). A curriculum knowledge graph (CKG) is extracted from an open algebra textbook, and each SAT solution is decomposed into a chain of required triples. The SSKG assigns a mastery probability to each triple, which is sampled to determine question correctness. An LLM then generates a first-person rationale consistent with the outcome. The simulation reduces accuracy to 44.1-85.2% across profiles and produces a clear monotone mastery gradient.

为解决这个局限，我们引入一个基于[随机学生知识图谱 \(SSKG\) 的方法](#)。从一本开放代数教材抽出课程知识图谱 (CKG)，并把每道 SAT 题的解法分解成一条所需三元组的链。SSKG 为每条三元组赋一个掌握概率，采样它来决定答题正确与否。随后大模型生成一段与该结果相一致的第一人称说理。该模拟把准确率降到 44.1 - 85.2%，并产生清晰的单调掌握度梯度。

引言 Introduction

Synthetic student response data is valuable when real classroom data is expensive, slow, or difficult to collect at scale due to ethical or practical constraints. Applications include training knowledge-tracing models before a course has run, stress-testing an intelligent tutoring system

across a spread of mastery levels, or piloting new assessment items before they reach real students.

当真实课堂数据昂贵、缓慢、或因伦理与实际约束难以规模采集时，合成的学生答题数据是有价值的。 应用包括：在课程开跑之前就训练知识追踪模型、在一个掌握度谱系上压测智能辅导系统、在新的测评题送到真实学生手上之前先做试测。

举例说明（原文的运行示例）：给定 N 道 SAT 代数题，我们希望模拟三类学生——对这些题所需的代数知识分别掌握在高、中、低三个水平。一个忠实的模拟应当让第一位学生答对高比例的题、第二位中等、第三位低。而且，如果某个学生在课程的某个特定部分有缺口，他模拟出的错误应当集中在需要那部分知识的题上。每一个错误答案还应当能被追溯到该学生没能应用的那个具体代数概念或技能。

A common LLM-based approach in the literature and in practice is to describe the desired student in the prompt, for example, by specifying a skill level, an exam grade, or an archetypal student profile, and let the LLM decide both the answer and the explanation. We show this approach fails on a concrete, realistic benchmark.

文献与实践常见的做法是**在提示词里描述你想要的那种学生**（指定技能水平、考试成绩、或一个原型画像），并让大模型同时决定答案与解释。我们证明这个做法在一个具体、现实的基准上失败了。

Two diagnostic profiles designed to carry structured, chapter-localized gaps are statistically indistinguishable from the high-mastery profile for every LLM tested. This is not a new observation in isolation, it replicates and extends a competency-bias finding first reported for GPT-3.5 on non-math domains. Here, we confirmed at larger scale, on math reasoning items, and across different LLMs.

两个被设计成带有结构化、章节局部化缺口的诊断画像，对每一个被测大模型来说，都与高掌握画像在统计上无法区分。 这不是一个孤立的新观察——它复现并扩展了此前在 GPT-3.5 上、在非数学领域首次报告的「能力偏置」发现。这里我们在更大规模上、在数学推理题上、跨不同大模型做了确认。

四项贡献：① 描述一种人工引导的抽取方法，从给定来源构建课程知识图谱；② 开发一个基于 SSKG 的方法来模拟分层画像的学生，该方法产生画像—准确率的单调性与技能特定的错误模式；③ 给出该模拟方法的理论基础与实际实现；④ 做一项四臂累积消融研究，把方法的增益归因到具体机制。

相关工作：概率知识图谱的三条路线 Related Work

教育知识图谱：MOOCCube 从 700 多门真实 MOOC 里构建了一个包含课程概念、视频、习题的大规模知识图谱，专门用于支撑下游的自然语言处理与学习分析任务。Pan 等人详细编目了「用大模型构建知识图谱」的各种模式。因为一条大模型提出的三元组不自动就是正确的，人工验证是必要的；Tsaneva 等人的工作显示，单靠大模型做验证是弱的，而人机混合验证给出最好的总体结果。

随机与概率知识图谱：给一条事实附上概率、而不是当作普遍为真，在几个表示层次上都被研究过——PR-OWL 这类概率本体语言给 OWL 加上贝叶斯语义，使得类归属与关系可以带着某种置信程度被断言，而不是

作为确定的公理；NELL 这类由开放信息抽取构建的概率知识图谱，为每条自动抽取的信念附上置信分，只提升置信度过阈的那些；**不确定知识图谱嵌入**为每条三元组附置信分，并学习能为未见三元组预测该置信度的嵌入。

四段消融的设计 The Four Ablation Arms

We design this SSKG-based method into four cumulative ablation arms (a-d) so that any gain can be attributed to a specific mechanism.

我们把这个基于 SSKG 的方法**设计成四个累积的消融臂（a 到 d），以便任何增益都能被归因到某个具体机制。**

arm-a 是单次抽样器。 每条所需三元组做一次伯努利抽样，因此一道题的链上每一条三元组都与其他每一条同等要紧。

arm-b 加入检索/执行（知识追踪）分解，把「一条事实对该学生是否根本可得（检索）」与「它是否被无误地应用（执行）」分开。

arm-c 加入分类法条件下的题目加权，使得漏掉一条纯定义性事实（例如忘了变量是什么）不像漏掉一条程序性或关系性的那样严重（例如误用一个多步方法、或选错了解题路径）。

arm-d 加入干扰项路由。不是均匀地选一个错误选项，而是在某条特定三元组上的失败，去选中「那次失败会导出的那个特定错误选项」，用的是该题的干扰项映射表。

评测 Evaluation

我们在两种方法下评测该模拟：

- **方法 1（直接提示）：**让大模型仅从对画像的自然语言描述出发，联合决定答案 y 与说理 r 。
- **方法 2（基于 SSKG）：**由（题目的三元组链，画像）解析地决定 y ，随后由大模型生成叙述。

实验设计的四个问题：Q1 单调性——准确率是否随掌握度下降而下降？Q2 技能特异性——结构化缺口画像 P4 与 P5 是否恰在其缺口所在处失败？Q3 可诊断性——每个错误答案能否被追溯到一条特定的低掌握三元组？Q4 归因——消融阶梯的哪一级带来了保真度增益？

数据集：379 道 SAT 代数选择题、一个 864 条三元组的 CKG、五个画像。方法 1 在 $379 \times 5 = 1,895$ 个（题目，画像）配对上对三个大模型各跑一遍；arm-a 到 arm-d 每个也跑 1,895 条记录。方法 2 的准确率按构造与大模型无关，因为决定正确与否的是被采样的轨迹，而不是叙述者。

结果一：单调性（Q1）——直接提示崩了，SSKG 接地恢复了梯度

Method 1 is flat at 96.8-100% for every profile, indistinguishable from the 100% unconstrained ceiling, including under P3, whose prompt explicitly describes a "struggling student who has low mastery of most algebra concepts."

方法 1 对每个画像都平坦在 **96.8 - 100%** (P1 - P5 依次为 100.0%、99.7%、96.8%、100.0%、100.0%)，与不加约束的 100% 天花板无法区分——包括 P3 在内，而 P3 的提示词明确描述的是「一个大多数代数概念掌握度都很低的吃力学生」。

这次崩塌并不特定于某个厂商或模型家族：Claude Haiku 4.5 与 GPT-5.4-mini 更平，每个画像都在 99.2 - 99.7%，GPT 的 P3 实际上还超过了它的 P2。

方法 2 的每一个臂都把五个画像铺开在 30 - 55% 的区间上；**arm-d 跨越 44.1 - 85.2%**。在 Q1 直接关心的那三个按掌握度排序的画像上，arm-d 呈 **85.2% (P1) > 57.8% (P2) > 44.1% (P3)**，每一个相邻差距都是决定性的；而方法 1 唯一非零的差距 (P2 与 P3 之间的 2.9%) 就是它所能产生的全部掌握度信号。

另需注意：**SSKG 的准确率顺序中 P5 高于 P4，尽管 P5 的平均掌握度更低**——这反映的是每个画像的掌握度相对于题目链的位置，而这正是一个单一的「熟练度旋钮」表达不了的结构。

结果二：技能特异性 (Q2)

(六格表见前文点评一节。)

Method 1 is 100.0% in every one of the six cells: direct prompting cannot express a skill-localized gap at all.

方法 1 在六个格子中的每一个都是 100.0%：直接提示根本无法表达一个技能局部化的缺口。

在 arm-d 下，**P4 显示出干净的预测模式**：在早期与混合题上弱，在只用后期的题上强 35.7 个百分点。P5 在早期题上最强 (70.0%)，如设计所愿，但它最弱的格子是混合 (48.3%) 而不是后期 (62.5%)。

混合链平均更长，而在一条合取规则下，每多一步就多乘一个存活概率，所以一道混合题迫使 P5 经过它薄弱的后期步骤，外加一个长度惩罚。混合那一列应当读作「两个 band 都要用到、总步数更多」，而不是读作一种插值。

一项标签盲的难度检查：SAT 难度标签从来不是第一阶段的输入，所以输出里的任何难度模式都是涌现的。在 arm-d 下，P3 呈现干净的单调「易 > 中 > 难」斜率 ($48.3\% > 40.8\% > 39.2\%$)，而其他画像平坦或非单调——这与「该标签只与链长及组成弱相关 (Spearman 0.209)」这一事实一致，而链长与组成才是真正驱动采样器的东西。

结果三：可诊断性 (Q3)

Under arm-d, every wrong answer is assigned a first_failed_triple_id and a failure_kind by construction. We therefore evaluate diagnosability empirically, independent of this labeling mechanism.

在 arm-d 下，**每个错误答案都按构造被赋予一个 first_failed_triple_id 与一个 failure_kind (检索或执行)**。因此我们独立于这套标注机制、以经验方式评估可诊断性。

汇集 525 个 (三元组, 画像) 配对 (限定每条三元组至少出现在 3 条题目链中)，**某画像下的三元组掌握度，与该画像在需要这些三元组的题目上的错误率，相关系数为 Spearman $\rho = -0.459$ ($p \approx 10^{-28}$)**。因

此对某条特定三元组的更低掌握度，与需要它的那些题目上的更多错误相关联。

在单题层面，**链上的瓶颈三元组**（掌握度最低的那条）与题目结果的相关为 $\rho = 0.318$ 。这个更弱的相关是预期之内的，因为单个瓶颈值无法完全刻画一条合取链。

诊断标签也**忠实地反映在生成的回答中**：在全部 1,895 条 arm-d 叙述里，**被叙述出的最终答案与采样器决定的答案在每一条记录上都一致（0 违反）**，包括那 19 条触发了干扰项路由、叙述必须自行导出那个特定被映射错误选项的记录。

结果四：归因（Q4）

阶梯	Δ 范围	状态
a→b	-9.5 到 +0.0pp	经验的（执行噪声效应）
b→c	+14.0 到 +19.5pp	经验的（分类法去漫画化）
c→d	0.0pp，每个画像	按构造精确为零

a→b（执行噪声）：P1 准确率下降 9.5%，其他任何画像至多下降 2.1%。效果集中在该集中的地方。P1 在 arm-b 下新失败的**全部 36 道题都被归类为执行失败**，没有一道被归为检索失败。一个从不失手的准专家不是一个现实的顶尖学生。滑手机制因此是必要的。

c→d：这一级因此只贡献于诊断。在 1,895 条记录中的 19 条（1.0%）里，一次执行失败被路由到了它所映射的那个错误选项、而不是被均匀选取。**在每一例中，叙述描述的都是那个具体的单步错误，而不是一个笼统的失误。**

讨论 Discussion

The results show that direct prompting tends toward a high-accuracy ceiling across all three vendors, regardless of the target mastery level. In contrast, explicit stochastic sampling over the curriculum graph produces the monotone accuracy gradient and skill-specific error patterns required by the Problem of Faithful Simulation.

结果显示，**直接提示在全部三个厂商上都趋向一个高准确率的天花板，与目标掌握度无关**。相比之下，在课程图谱上做显式的随机采样，产生了「忠实模拟问题」所要求的单调准确率梯度与技能特定的错误模式。

The ablation study shows that these gains come from different mechanisms. The knowledge-tracing decomposition (a→b) mainly moves high-mastery profiles away from an unrealistic near-ceiling while having little effect on already-low profiles. This is the expected direction. However, this mechanism has a relatively small effect because it changes only one parameter. Taxonomy awareness (b→c) produces the largest gain and has a somewhat stronger effect on lower-mastery profiles. Distractor routing (c→d) does not change accuracy, as expected, but improves the diagnostic value of wrong answers.

消融研究显示这些增益来自不同机制。知识追踪分解 ($a \rightarrow b$) 主要是把高掌握画像从一个不现实的近天花板位置拉下来，而对本来就低的画像影响很小——这是预期的方向。然而这个机制效果相对较小，因为它只改了一个参数。分类法感知 ($b \rightarrow c$) 产生最大的增益，并且对更低掌握的画像作用略强。干扰项路由 ($c \rightarrow d$) 如预期不改变准确率，但改善了错误答案的诊断价值。

The results for skill specificity and emergent difficulty are more mixed. P4 shows a clear early/late split, P5's pattern is affected by chain length, and only P3 shows a clear difficulty gradient.

技能特异性与涌现难度的结果则比较混杂：P4 显示出清晰的早期/后期分裂，P5 的模式受链长影响，而只有 P3 显示出清晰的难度梯度。

参考链接

- [MOOCCube](#) — 从 700 多门真实 MOOC 构建的大规模教育知识图谱，本文相关工作引用
- [PR-OWL](#) — 给 OWL 加贝叶斯语义的概率本体语言
- [NELL \(Never-Ending Language Learning\)](#) — 为每条自动抽取的信念附置信度的概率知识图谱
- [SAT Practice Questions \(College Board\)](#) — 本文 379 道代数题的来源类型