

专家写的说明文字能不能还原他们定的层级 Bridging Reactome's Ontology with LLM Semantic Embeddings

本篇范围声明：这是一篇 6 页的会议论文（CIBB 2026, arXiv 2608.28178v1, 2026-08-28）。下面的「全文翻译」按章节推进，覆盖摘要与正文第 1 - 4 节的主体（引言、数据与方法的五个小节、结果、结论），两张数据表与一张谱密度图保留其数值与含义说明；文末利益冲突、致谢与 10 条参考文献列表不逐条翻译。

核心内容

Q: 这篇在问一个什么问题？ A: Reactome 是一个生物通路知识库，里面每个节点（Pathway 通路 / Reaction 反应）既有专家手工定的层级关系，又有专家手写的一段文字说明。这篇问的是：如果把层级关系全部盖住，只拿那些文字说明去算语义相似度，能不能把专家定的那张层级图重新拼出来？

Q: 为什么这个问题值得问？ A: 因为人工策展不可扩展。Reactome 的质量靠人一条一条从原始文献里读出来、写下来，这保证了可信度，但跟不上文献增长的速度。如果文字说明里本来就编码了层级信息，那就意味着可以用文本自动扩充知识库，人只需要复核。作者说已有工作分别做过“把描述转成可执行动力学模型”“把新基因映射到已有通路”“做个对话式检索助手”，但没人验证过“文字之间的关系是否映射了更高阶的生物学关系”——这是这篇的空白点。

Q: 怎么做的？ A: 四步。① 从 Reactome V95 查出人类（Homo sapiens）的通路-反应层级，叫 RH (Reactome Hierarchy)，18,732 个节点、19,613 条边。② 用 SPECTER2（一个在科学文献标题+摘要上、按引用图做对比学习训练的句向量模型）把每个节点的「标题 [SEP] 描述」编码成 768 维向量。③ 用改造过的层次聚类 + 一个图重建算法，拼出 SH (Semantic Hierarchy)。④ 拿 SH 和 RH 比。

Q: 那个“改造过的层次聚类”改在哪？ A: 标准的凝聚层次聚类（AGNES）只产出二叉树——每次只合并两个节点。但真实本体是多叉的：一个通路下面可以直接挂七八个反应。作者的改法是：对每个节点，算「当前合并高度」和「该节点当初形成时的高度」之差，如果差小于一个数据驱动的阈值 ϵ （取连接矩阵里最小的非零距离），就把这个节点吸收掉、让它的孩子直接挂到新父节点上；否则保留它作为中间分支。这样就能一次合并多个节点。

Q: 结果怎么样？ A: 作者报了三组数字。全局谱距离 $LSD = 0.085$ ，而理论上界是 $\ln(2) \approx 0.693$ ；把 SH 的边全部随机重连之后，LSD 涨到 0.224。自举检验 $p < 0.005$ 。密度 0.00011 对 0.00011，平均度 2.00 对 2.09。作者的结论是“全局层级结构可以由专家的文字元数据推断出来”。

Q：这个结论能不能照单全收？ A：不能，有三处要打折扣，其中一处是我自己按论文的数字算出来的。见下面的点评——最要紧的一条是：论文自己报的局部指标，换个分母算，说明只有约 38% 的参考边被真的还原了。

背景补充 / 点评

先把几个东西说清楚

Reactome 是什么：一个人工策展的生物通路知识库。它的组织方式值得注意——**Reaction（反应）是基本单位**，指的是日常语言里的结合、磷酸化、分子运输这类事件加上参与的分子；**Pathway（通路）是一串相互连接的 Reaction 的聚合**；Pathway 再往上层层组织成一张大图。最顶上有 29 个 TopLevelPathway（细胞周期、免疫系统、代谢等），它们是整棵树的根。这套东西存在 Neo4j 图数据库里，可以直接查。

SPECTER2 是什么、为什么选它：一个句向量模型，训练方式是在科学论文的引用图上做对比学习——被互相引用的论文，标题和摘要的向量要靠近。所以它编码的不是"字面相似"，而是"在科学文献的引用结构里靠得近"。作者选它而不选通用模型，理由是它更贴生物医学领域。**这个选择本身其实值得注意：**SPECTER2 的训练信号来自引用图，而引用图和生物学层级图是两种不同的结构，用前者去恢复后者，中间这一跳论文没有论证。

LSD (Laplacian Spectral Distance) 是什么：拿两张图各自的归一化拉普拉斯矩阵，求特征值谱，再比两个谱分布的差异（这里用的是基于 Jensen-Shannon 的版本）。它是个**全局形状**指标——不看具体哪条边接在哪，只看整张图的"频谱指纹"像不像。取值范围 $[0, \ln(2)]$ 。

Frobenius 距离（论文里叫 Edit Distance）是什么：两个邻接矩阵逐元素相减，再取矩阵的 Frobenius 范数（所有元素平方和开根号）。它是**局部**指标——直接数有多少条边对不上。

三处要打折扣的地方

第一处：那个"1.16%"的分母选错了，而且换个分母结论就翻过来。

论文说 Frobenius 距离是 216.88，"约占该规模图理论最大距离 ($\sqrt{N(N-1)} = 18,731.5$) 的 1.16%"。

问题在于： **$\sqrt{N(N-1)}$ 是"完全图"对应的上界**——即两张图一张全连、一张全空。而 RH 和 SH 都是极度稀疏的树状图（近两万节点、不到两万条边，平均度 2）。**拿完全图当分母，任何两张稀疏图比出来的相对距离都会小得可怜**，这个数字不携带信息。

换个有意义的分母试试。我按论文自己的数字算了一遍（无向 0/1 邻接矩阵）：

$$\|A_{SH} - A_{RH}\|_F = 216.88$$

$$216.88^2 = 47,037 \quad \leftarrow \text{邻接矩阵里不同的元素个数}$$

$$\text{无向图每条不同的边贡献 2 个元素} \rightarrow \text{不同的边数} = 23,518$$

两图边数之和 = $19,613 + 18,703 = 38,316$ ← 对称差的上限

共有边 C: $19,613 + 18,703 - 2C = 23,518 \rightarrow C \approx 7,399$

(顺带说明: 如果按有向读, 不同的元素就是 47,037 条, 超过了 38,316 这个上限, 不成立。所以只能按无向读, 上面这条算法是被数字逼出来的唯一一致解释。)

结论是: SH 只还原了 RH 的 19,613 条边里的约 7,399 条, 占 37.7%。 也就是说, 具体的父子关系, 有六成没对上。

这和论文的全局结论并不矛盾——**"整张图的形状像"和"具体每条边接对了"是两回事**, 前者成立不蕴含后者。但论文摘要写的是"通路的全局层级结构可以由专家文字元数据推断出来", 读者很容易把它理解成后者。这个 38% 应该出现在正文里, 而不是要读者自己从 Frobenius 范数反推。

第二处: 零信号基准选错了——它破坏的不只是要检验的那个信号。

自举检验的做法是: **把 SH 的边全局随机重连 (保持度分布), 生成 500 个零模型**, 算每个和 RH 的 LSD, 看真实的 0.085 是不是显著地小。结果 $p < 0.005$ 。

但**随机重连一棵树, 破坏的是"树"这个性质本身**, 不只是"语义信号"。重连之后得到的是一张度分布相同但没有层级的乱图, 它和 RH 的谱当然差得远 (0.224)。所以这个检验证明的是"SH 不是一张随机图", 而不是"SH 里的结构来自语义"。

正确的零信号基准应该**只破坏被检验的那一个信号, 保留其余一切**。这里至少有两个更硬的选法:

- **打乱描述与节点的对应关系** (把 A 节点的描述贴到 B 节点上), 然后**原封不动地跑完同一条流水线** (同样的 SPECTER2、同样的多叉 AGNES、同样的图重建)。这样产出的仍然是一棵由同一算法造出来的树, 唯一被抽掉的是"描述和节点匹配"这个语义信号。
- **用随机向量替换 embedding**, 同样跑完整条流水线。

如果在这两个基准下 LSD 仍然远大于 0.085, 那结论才立得住。**现在这个检验, 一棵用随机向量长出来的树大概率也能通过。**

第三处, 也是我认为最要紧的一处: 重建流程里读了参考答案。

第 2.4 节的图重建算法, 对每个聚类节点分三种情形处理。前两种没问题。**第三种情形是这样写的:**

多个 Pathway 共存时, Pathway 与 Reaction 之间的层级关系**使用一个源自 Reactome 的祖先—后代映射**来解决, 其中每个节点被指派给它兄弟节点中最近的合法祖先。

"源自 Reactome 的祖先—后代映射"就是 RH 本身。 也就是说, SH 并不是纯粹从文字里长出来的——**在最需要判断层级的那种情形 (多个通路挤在一个簇里) 下, 算法直接去查了参考答案。**

这是评估设计上的信息泄漏。要检验"A 能不能重建 B", 重建流程里就一步也不能读 B。论文没有报告第三种情形占多大比例, 所以**泄漏的程度无法从文中判断**——如果它只在极少数簇里发生, 影响有限; 如果它是常

态，那 37.7% 这个已经不高的还原率里还有一部分不是文字挣来的。

这一条我认为作者应该在方法一节里显式声明并给出触发比例。

论文做对的地方

上面挑了三处，但这篇有两点我认为做得好，得说清楚。

一是多叉层次聚类那个改造是真问题真解法。 标准 AGNES 只出二叉树，而任何真实本体都是多叉的——拿二叉树去比多叉本体，差异里有一大半是算法产物而不是语义偏差。用「合并高度差小于 ε 就吸收」来收拢， ε 取连接矩阵里最小的非零距离，是个数据驱动、不引入超参的做法。**这个模块可以脱离本文单独复用。**

二是它明确把自己定位成可行性验证，不是完整研究。 结论里写得很直白：只做了单一物种、只用了有限几个比较指标、评估完全是计算和拓扑层面的、还没有请领域专家从生物学角度看结果。**作者没有把一个初步结果包装成定论**，这个分寸在今天的论文里不常见。

三是未来工作里那条真正有用的应用，被写在了最后。 作者说：如果能看清两张层级在哪里分歧，**那些分歧点可以用来定位"研究不足/策展不充分"的区域，直接反馈给策展人。**

这条比论文的主结论有价值得多。 因为它不需要"文字能完整还原层级"这个强假设——**恰恰相反，它把"还原不了的地方"当成产出。** 文字和结构对不上的节点，要么是描述写得不好，要么是层级放错了，两种都是策展人该看的。这是一个不用等准确率达标就能上线的用法。

对我的启示

第一条，直接可用在 prove 上。

我们的语义层里，每个指标和实体都有一段人写的口径说明，同时又有 `rbox.yaml` 里人工登记的关系结构。这篇的问法可以原样搬过来：**如果只拿口径文字算相似度，能不能还原出我们登记的那张关系图？**

但我要抄的是它的"未来工作"，不是它的主结论。 目标不是"用文本自动生成 rbox"——那个准确率不会够，而且错了不报错。目标是**用分歧做体检**：文字说明彼此很近、但结构上离得很远的两个指标，是可疑对；结构上是父子、但描述毫不相干的，也是可疑对。**这是个不需要高准确率就能用的用法**，因为它的产出是"这几对值得人看一眼"，而不是"这就是答案"。

第二条是评估设计上的，今天这两篇论文合起来给了我一个完整的对照。

上一篇（OWL 类表达式化简）我夸它诚实：**它不敢证的东西就说不敢证，改用"比对检索出的个体集合"这种可执行的验证。** 这一篇的问题正好在对称的位置：**它的验证做了，但基准选松了，而且流程里读了参考答案。**

把两篇合起来，我得到一条可以直接用的检查清单——**每次看到"我们验证了 X"，问三个问题：**

1. 验证的对象是不是 X 本身？（这篇验的是"SH 不是随机图"，不是"SH 来自语义"）

2. 零信号基准破坏的，是不是只有 X 这一个信号？（随机重连破坏了树结构本身，多破坏了）

3. 产生 X 的流程里，有没有读到用来评判 X 的那个答案？（第 2.4 节读了）

第 3 条尤其值得记住，因为**它是最难自查的一条**——泄漏往往藏在一个为了"让结果好看一点"而加的兜底分支里，而写的人当时觉得那只是个工程细节。

第三条是关于怎么读别人报的指标。

"占理论最大值的 1.16%" 这句话，单看没有任何毛病，甚至显得严谨。**但分母是完全图，而两张图都是稀疏树。**我花了三行算术就把它翻成了"六成的边没对上"。

教训是：看到一个被归一化过的比例，先问分母是什么，以及这个分母在当前场景下可不可能被接近。如果分母是一个物理上到不了的上界，那个百分比就是装饰。这条我以后看任何"提升了 X%" "只占 Y%" 的战报都要过一遍——**包括我自己写的报告。**

文中金句

"However, little exploration has been done so far to assess whether relationships among textual descriptions mirror higher order biological relationships." 然而，迄今为止很少有人去评估：文字描述之间的关系，是否映射了更高阶的生物学关系。

"Multiple Pathways coexist, in which case hierarchical relationships among Pathways and Reactions are resolved using a Reactome-derived ancestor - descendant mapping, where each node is assigned to its closest valid ancestor among its siblings." （第三种情形是）多个 Pathway 共存，此时 Pathway 与 Reaction 之间的层级关系使用一个**源自 Reactome 的祖先—后代映射**来解决，其中每个节点被指派给它兄弟节点中最近的合法祖先。（——这句是全文最需要注意的一句：重建流程在这里读了参考答案。）

"This work represents the first attempt to check the feasibility and the accuracy of this workflow rather than an exhaustive study." 这项工作是对该流程可行性与准确性的首次尝试性检查，而非一项详尽的研究。

"This type of information can be relevant in the identification of understudied/less curated areas, with a direct feedback to the curators." 这类信息可以用于识别研究不足/策展不充分的区域，并直接反馈给策展人员。

全文翻译

摘要

Biological knowledgebases like Reactome provide high-quality pathways that include biological elements' relationships and textual descriptions (metadata). The quality of such pathways is granted by manual curation, that presents, however, significant scalability challenges. Lately, numerous NLP tools have been proposed to cope with this issue, leveraging textual information to automatically expand biological knowledgebases.

像 Reactome 这样的生物知识库提供高质量的通路数据，其中既包含生物学元素之间的关系，也包含文字描述（元数据）。这些通路的质量由[人工策展](#)来保证，但人工策展带来了严重的可扩展性挑战。近来已有大量 NLP 工具被提出来应对这个问题，它们利用文本信息来自动扩充生物知识库。

However, little exploration has been done so far to assess whether relationships among textual descriptions mirror higher order biological relationships. This study explores whether human-written descriptions in Reactome can be used to infer the experts' defined global hierarchical structure.

然而，迄今为止很少有人去评估：[文字描述之间的关系，是否映射了更高阶的生物学关系](#)。本研究探讨的是：Reactome 中由人撰写的描述，能否被用来推断出专家所定义的全局层级结构。

To test this, we extracted from Reactome the Homo Sapiens hierarchy of pathways and their reactions (Reactome Hierarchy), and used textual metadata to reconstruct a Semantic Hierarchy, combining a sentence transformer model (SPECTER2) with a modified agglomerative nesting algorithm and a graph reconstruction algorithm. Quantitative (Laplacian Spectral Distance and Bootstrapping) and qualitative (global topological metrics) analyses confirm our hypothesis and indicate that the global hierarchical structure of pathways can be inferred by experts textual metadata.

为检验这一点，我们从 Reactome 中提取了人类（Homo sapiens）通路及其反应的层级结构（称为 [Reactome Hierarchy](#)），并利用文字元数据重建出一个 **Semantic Hierarchy**——具体做法是把一个句向量模型（SPECTER2）与一个改造过的凝聚嵌套（agglomerative nesting）算法、以及一个图重建算法组合起来。定量分析（拉普拉斯谱距离与自举法）和定性分析（全局拓扑指标）都支持我们的假设，表明通路的全局层级结构可以由专家的文字元数据推断出来。

关键词：知识库、Reactome、LLM、层级、embedding。

一、引言：人工策展的可扩展性困境

Biological pathways are essential conceptual tools for mapping the complex biochemical interactions that drive biological processes. To manage this vast amount of information (molecules and associated relations) they are often collected in comprehensive knowledgebases like Reactome that ensures high quality and structured pathway data by manual curation from the primary literature.

生物通路是用来刻画驱动生命过程的复杂生化相互作用的基本概念工具。为了管理如此庞大的信息量（分子以及相关的关系），它们通常被收集到像 Reactome 这样的综合知识库中——Reactome 通过从原始文献进行人工策展，保证了通路数据的高质量 and 结构化。

In Reactome, a Pathway is defined as a series of interconnected Reactions, based on biological relevance. Reactome Reactions are the basic units of this knowledgebase, defined as the ensemble of everyday language reactions (binding, phosphorylation, molecular transport, etc.) and the involved molecules. The Reactions are then aggregated to form Pathways, which are further organized hierarchically into a large interconnected graph that can be accessed using the Neo4j Reactome Graph Database, here named Reactome Hierarchy (RH).

在 Reactome 中，**Pathway（通路）**被定义为一系列基于生物学相关性而相互连接的 [Reaction（反应）](#)。Reactome 的 Reaction 是这个知识库的基本单位，定义为日常语言意义上的反应（结合、磷酸化、分子运输等等）与所涉分子的集合体。（论文用首字母大写来区分这两个概念与日常用词。）这些 Reaction 再被聚合成 Pathway，Pathway 又被进一步组织成层级化的大型互联图——可以通过 [Neo4j Reactome 图数据库](#) 访问，本文称之为 **Reactome Hierarchy (RH)**。

In addition to strictly structured information, Reactome contains rich textual metadata. In fact, each Pathway and the Reactions that compose it, are provided with a title and a descriptive human-written summary of their purpose.

除了严格结构化的信息之外，Reactome 还包含丰富的文字元数据。事实上，每一个 Pathway 以及组成它的每一个 Reaction，都配有一个标题和一段由人撰写的、描述其作用的说明性摘要。

Although manual curation guarantees high fidelity, it presents a significant scalability challenge. Recent advances in Natural Language Processing (NLP) and Large Language Models (LLMs) suggest that textual metadata may offer a route toward more automated knowledge integration and interaction.

尽管人工策展保证了高保真度，它带来了严重的可扩展性挑战。自然语言处理（NLP）和大语言模型（LLM）的最新进展提示我们：文字元数据也许提供了一条通向更自动化的知识集成与交互的路径。

Maeda et al. employed GPT-derived models to translate natural language descriptions of the metadata into Antimony strings, a domain-specific markup language for biological models, which were then converted into executable kinetic models. Wu et al. instead, advanced computer-assisted curation by proposing a pipeline that maps new genes to existing pathways and refines functional annotations through literature-supported entity extraction. Regarding the interaction, Mohammadi et al. developed React-to-Me, a conversational assistant that combines hybrid retrieval-augmented generation (RAG) with constrained decoding to ground user queries in Reactome content. These tools demonstrate that textual metadata can support the retrieval of structured biological information.

Maeda 等人用 GPT 系模型把元数据的自然语言描述翻译成 **Antimony** 字符串（一种面向生物模型的领域专用标记语言），再转换成可执行的动力学模型。Wu 等人则推进了计算机辅助策展，提出一条流水线，把新基因映射到已有通路，并通过有文献支撑的实体抽取来精化功能注释。在交互方面，Mohammadi 等人开发了 **React-to-Me**，一个把混合式检索增强生成（RAG）与受约束解码结合起来的对话式助手，用于把用户查询锚定在 Reactome 的内容上。这些工具表明，文字元数据能够支撑结构化生物信息的检索。

In this study, we investigate the Reactome case to assess how well semantic embeddings derived solely from human-written annotations' titles and descriptions can reconstruct Reactome's biological hierarchy. Complementing prior efforts focused on kinetic modeling, conversational interfaces, or new literature ingestion, our contribution is twofold: (1) we focus exclusively on structural reconstruction, measuring how semantic similarity among existing textual metadata alone can recover hierarchical relationships, (2) we introduce a graph-theoretic evaluation framework to quantify the topological alignment between the resulting Semantic Hierarchy (SH) and the expert-curated RH.

在本研究中，我们以 Reactome 为对象，评估**仅仅从人写注释的标题和描述中导出的语义 embedding**，能在多大程度上重建 Reactome 的生物学层级。相对于此前聚焦于动力学建模、对话界面或新文献摄入的工作，我们的贡献有两点：**(1) 我们只关注结构重建**，衡量仅凭已有文字元数据之间的语义相似度能恢复多少层级关系；**(2) 我们引入一个图论评估框架**，量化所得到的 Semantic Hierarchy (SH) 与专家策展的 RH 之间的拓扑对齐程度。

By isolating the informational signal within pre-existing curated annotations, this work provides a preliminary and scalable opening towards text-driven pathway reconstruction.

通过把信息信号隔离在既有的策展注释之内，这项工作为文本驱动的通路重建提供了一个初步的、可扩展的切入点。

二、数据与方法

The proposed approach is structured in four phases: (i) we extract the RH from the Reactome database Version V95 December 2025; (ii) we build the semantic embeddings of Pathways and Reactions textual descriptions; (iii) we use the generated embeddings to build a SH, by combining a clustering technique with a graph reconstruction algorithm, (iv) we compare SH to the reference RH.

所提方法分四个阶段：**(i)** 从 Reactome 数据库 V95 版（2025 年 12 月）提取 RH；**(ii)** 为 Pathway 和 Reaction 的文字描述构建语义 embedding；**(iii)** 用生成的 embedding，结合一种聚类技术与一个图重建算法，构建 SH；**(iv)** 把 SH 与作为参考的 RH 做比较。

2.1 Reactome 层级的获取

To extract the RH we queried the database filtering for Homo sapiens using it as the reference species given its popularity and renown quality in the scientific reference community. We then

retrieved all Pathway and Reaction nodes, along with their hierarchical relationships and textual descriptions. In Reactome, Pathways and Reactions are categorized as Event nodes and further divided into subclasses to represent specific biological scenarios; we included all such subclasses in our retrieval.

为提取 RH，我们在查询数据库时按 **Homo sapiens（人类）** 过滤，选它作为参考物种是因为它在科研参考社群中使用最广、质量公认。随后我们取出全部 Pathway 与 Reaction 节点，以及它们的层级关系和文字描述。在 Reactome 中，Pathway 和 Reaction 都被归类为 **Event 节点**，并进一步划分成若干子类以表示特定的生物学情形；我们在检索中包含了所有这些子类。

We aggregated all elements into a graph with textual description as node attributes to support downstream semantic embedding.

我们把所有元素聚合成一张图，把文字描述作为节点属性，以支撑下游的语义 embedding。

2.2 描述数据库的语义 embedding 与数据预处理

Based on RH, we created a tabular dataset of textual descriptions extracting for each node: Reactome ID, entity type (class or subclass), title and textual description.

基于 RH，我们建了一个文字描述的表格数据集，为每个节点抽取：Reactome ID、实体类型（类或子类）、标题、文字描述。（表 1 给了样例，例如 **R-HSA-9612973 / TopLevelPathway / Autophagy / "Autophagy is an intracellular..."**，以及 **R-HSA-5682388 / BlackBoxEvent / Autophagosome maturation / "The mechanisms involved in..."**。该数据集用于生成句向量，做法是把 Name 列和 Description 列拼接起来。）

For SH, we employed SPECTER2, a sentence transformer model pre-trained on titles and abstracts of scientific publications using contrastive learning on a scientific citation graph. Consequently, it is better suited for the biomedical domain than general-purpose model.

对于 SH，我们采用了 **SPECTER2**——一个句向量 transformer 模型，它在科学出版物的标题与摘要上预训练，训练方式是在科学引用图上做对比学习。因此它比通用模型更适合生物医学领域。

Pre-processing includes a rigorous cleaning process and removal of bibliographic citations and the concatenation of node name and description with [SEP] to reduce number of duplicate descriptions. For entities with descriptions exceeding the maximum token limit (512), we splitted it in sentences using the 12-layer (sat-12l-sm) model in the SaT (Segment any Text) library to preserve sentence boundaries while incorporating 10% overlap to guarantee contextual continuity.

预处理包括一套严格的清洗流程、去除文献引用标记，以及用 **[SEP]** 把节点名称和描述拼接起来——这样做是为了减少重复描述的数量。对于描述超过最大 token 上限（512）的实体，我们用 **SaT（Segment any Text）** 库中的 12 层模型（sat-12l-sm）把它切成句子，以保持句子边界完整，同时引入 **10% 的重叠** 来保证上下文连续性。

2.3 改造过的层次聚类

To construct the SH, we extend an Agglomerative Nesting (AGNES) clustering algorithm, to allow for the simultaneous merging of multiple nodes which cannot be performed by standard binary hierarchical clustering. This approach is named in the following multiway hierarchy.

为构建 SH，我们扩展了[凝聚嵌套（AGNES）聚类算法](#)，使其允许同时合并多个节点——这是标准的二叉层次聚类做不到的。下文把这种做法称为[多叉层级（multiway hierarchy）](#)。

A standard linkage matrix stores all pairwise distances between the initial data points (Pathways and Reaction-Like Events). Then, to support a non-binary hierarchy, for each node the difference between the current merge height and the height at which the node was originally formed is evaluated. For differences smaller than a data-driven threshold ϵ (minimum distance different from zero in the linkage matrix), the node is absorbed and its children are directly attached to the new parent; otherwise, the node is retained as an intermediate branch. A new parent node is then created to group the resulting children.

一个标准的连接矩阵存储所有初始数据点（Pathway 与 Reaction-Like Event）之间的两两距离。然后，为支持非二叉的层级，对每个节点计算[当前合并高度](#)与该节点最初形成时的高度之差。当这个差小于一个数据驱动的阈值 ϵ （取连接矩阵中最小的非零距离）时，该节点被吸收，它的子节点直接挂到新的父节点上；否则该节点被保留为一个中间分支。随后创建一个新的父节点来把这些子节点归组在一起。

The linkage distances between the newly formed cluster and all remaining active clusters are updated iteratively using the Lance-Williams formula.

新形成的簇与所有剩余活跃簇之间的连接距离，用 [Lance-Williams 公式](#) 迭代更新。

Although the algorithm generates a multi-way hierarchical tree, the resulting topology is not yet suitable for direct comparison with the RH, since the newly generated clusters are mathematical aggregation nodes (named Clusters in the following), but may not represent true pathways. To bridge this structural gap, we implemented the following reconstruction strategy.

尽管该算法生成了一棵多叉层级树，但所得拓扑还不适合与 RH 直接比较——因为新生成的这些簇只是[数学上的聚合节点](#)（下文称为 **Cluster**），未必对应真实的通路。为弥合这个结构上的落差，我们实现了下面的重建策略。

2.4 从 Cluster 到图的重建

To replace Clusters with the most appropriate Pathway nodes, thereby connecting the corresponding Reactions and Sub-Pathways directly to their correct parents, we explore the tree using a post-order depth-first search (DFS), visiting descendant nodes before their parent nodes. This bottom-up approach ensures that, at each iteration, the Cluster node under evaluation is connected exclusively to Pathway or Reaction nodes, as nested sub-clusters have already been resolved and removed in earlier iterations.

为了把 Cluster 替换成最合适的 Pathway 节点、从而把对应的 Reaction 与子 Pathway 直接连到正确的父节点上，我们用**后序深度优先搜索（post-order DFS）**遍历这棵树，先访问后代节点再访问父节点。这种自底向上的做法保证：每一轮迭代中，正在被处理的 Cluster 节点只连接到 Pathway 或 Reaction 节点，因为嵌套的子簇在更早的迭代里已经被解析并移除了。

For each Cluster, three distinct scenarios can occur: (i) Only Reactions are present, in which case they are linked directly to the parent Cluster; (ii) At most one Pathway is present, in which case any Reactions become its children, and it is linked directly to the parent Cluster; (iii) Multiple Pathways coexist, in which case hierarchical relationships among Pathways and Reactions are resolved using a Reactome-derived ancestor - descendant mapping, where each node is assigned to its closest valid ancestor among its siblings, while nodes with no such ancestor are linked directly to the parent Cluster.

对每个 Cluster，可能出现三种不同情形：**(i)** 只有 Reaction，此时它们被直接连到父 Cluster；**(ii)** 至多有一个 Pathway，此时所有 Reaction 成为它的子节点，而它被直接连到父 Cluster；**(iii) 多个 Pathway 共存，此时 Pathway 与 Reaction 之间的层级关系使用一个源自 Reactome 的祖先—后代映射来解决**，其中每个节点被指派给它兄弟节点中最近的合法祖先；没有这样的祖先的节点则被直接连到父 Cluster。

At this stage, all children of the Cluster node have been sorted and linked to the Cluster parent. The current Cluster node is then deleted and the algorithm moves to the next one according to the previously defined order.

到这一步，Cluster 节点的所有子节点都已被整理好并连接到该 Cluster 的父节点上。当前 Cluster 节点随即被删除，算法按前面定义的顺序转向下一个。

2.5 层级的比较

To quantify the similarity between SH and RH we used Edit Distance, based on the Frobenius norm between adjacency matrices, to quantify edge-level changes; and Laplacian Spectral Distance (LSD in $[0, \ln(2)]$), computed from the normalized graph Laplacian, to assess global topological divergence.

为量化 SH 与 RH 之间的相似度，我们使用了两个指标：**编辑距离**（基于两个邻接矩阵之间的 Frobenius 范数），用于量化边一级的变化；以及**拉普拉斯谱距离（LSD，取值在 $[0, \ln(2)]$ 之间**），由归一化图拉普拉斯算子计算得出，用于评估全局拓扑上的偏离。

We first computed global topological measures to qualitatively explore their order of magnitude in the two hierarchies. Then, we assessed the significance of the observed LSD by bootstrapping. We generated 500 null models by globally rewiring SH while preserving the degree distribution, and computed the LSD between each rewired graph and RH.

我们首先计算全局拓扑度量，定性地考察这些量在两个层级中的数量级。然后，我们用**自举法**评估所观察到的 LSD 的显著性：**通过在保持度分布的前提下对 SH 做全局重连，生成 500 个零模型**，并计算每个重连后的图与 RH 之间的 LSD。

三、结果

RH is composed of 18,732 nodes (2,848 Pathways and 15,884 Reactions) and 19,613 edges. The 29 nodes classified as TopLevelPathway denote high-level biological themes (e.g., Cell Cycle, Immune System, and Metabolism), and serve as roots of the RH and macro-level anchors for hierarchical alignment evaluation.

RH 由 **18,732 个节点** (2,848 个 Pathway 和 15,884 个 Reaction) 与 **19,613 条边** 构成。节点计数包含 Pathway 和 Reaction 的所有子类。被归为 **TopLevelPathway** 的 **29 个节点** 代表高层级的生物学主题 (例如细胞周期、免疫系统、代谢), 它们既是 RH 的根, 也是层级对齐评估中的宏观锚点。

(表 2 给出按本体类划分的节点构成: Pathway 超类下有 Pathway 本身 2,807、CellLineagePath 12、TopLevelPathway 29, 合计 2,848; ReactionLikeEvent 超类下有 BlackBoxEvent 2,894、CellDevelopmentStep 22、Depolymerisation 6、FailedReaction 454、Polymerisation 43、Reaction 12,465, 合计 15,884。)

To construct SH, high-dimensional embeddings were generated for each entity, resulting in a feature matrix of size $[18,732 \times 768]$ that served as the primary input for the clustering and hierarchical construction phases. The result is a graph with the same number of nodes as RH (18,732), but fewer edges (18,703).

为构建 SH, 我们为每个实体生成了高维 embedding, 得到一个 **$[18,732 \times 768]$ 的特征矩阵**, 作为聚类与层级构建阶段的主要输入。结果是一张与 RH 节点数相同 (18,732)、但边数更少 (**18,703**) 的图。

Computations were performed on a node equipped with 64 Intel Xeon Gold 6883 CPU cores (2.00 GHz) and 4 NVIDIA A30 GPUs with 24 GB of memory each. This corresponds to the following computational times: embedding generation processed 18,732 descriptions in ~2m (~167 row/s), and clustering completed in ~46s (~407 row/s), graph reconstruction required ~6s (~6,230 node/s).

计算在一个配备 64 核 Intel Xeon Gold 6883 CPU (2.00 GHz) 与 4 块 24 GB 显存的 NVIDIA A30 GPU 的节点上进行。对应的计算耗时是: **embedding 生成处理 18,732 条描述约 2 分钟** (约 167 行/秒), **聚类约 46 秒** (约 407 行/秒), **图重建约 6 秒** (约 6,230 节点/秒)。

The structural alignment between the reconstructed SH and the reference RH was validated through both local and global graph comparison metrics, yielding highly robust results. The local structural divergence, measured by the Frobenius distance, was 216.88; even though this reflects specific edge-level variations between the SH ($|E| = 18,703$) and the RH ($|E| = 19,613$), it represents a minimal fraction (approximately 1.16%) of the theoretical maximum distance for graphs of this order ($\sqrt{N(N-1)} = 18,731.5$).

重建出的 SH 与参考 RH 之间的结构对齐, 通过局部和全局两类图比较指标做了验证, 结果相当稳健。由 **Frobenius 距离度量的局部结构偏离为 216.88**; 尽管这反映了 SH (边数 18,703) 与 RH (边数 19,613)

之间在具体边一级上的差异，但它只占该规模图理论最大距离 ($\sqrt{N(N-1)} = 18,731.5$) 的极小一部分 (约 1.16%)。

Further topological characterization shows that the SH effectively preserves the quality of RH, maintaining a density of 0.00011 and an average degree of 2.00 (compared to 0.00011 and 2.09 in the RH, respectively).

进一步的拓扑刻画表明 SH 有效保持了 RH 的性质：密度维持在 0.00011、平均度 2.00 (RH 对应为 0.00011 和 2.09)。

More importantly, the Laplacian Spectral Distance (LSD) calculated is 0.085, indicating an high degree of global topological conservation against the normalized upper bound of $\ln(2) \approx 0.693$. This topological alignment is visually confirmed in Figure 3, where the spectral density of SH nearly overlaps with RH, particularly preserving the dominant peak at $\lambda = 1$.

更重要的是，计算出的拉普拉斯谱距离 (LSD) 为 0.085，相对于归一化上界 $\ln(2) \approx 0.693$ 而言，表明全局拓扑得到了高度保持。这种拓扑对齐在谱密度图中得到了直观印证：SH 的谱密度与 RH 几乎重叠，尤其保留了 $\lambda = 1$ 处的主峰。

As noted by Banerjee and Jost, biological networks, such as metabolic and transcription networks, characteristically exhibit this distinctive spectral shape with a pronounced peak at $\lambda = 1$. Unlike generic random or scale-free models, this specific spectral profile indicates underlying vertex or motif duplications that fundamentally drive the evolution of these biological structures.

正如 Banerjee 与 Jost 所指出的，代谢网络、转录网络这类生物网络，其特征就是呈现这种在 $\lambda = 1$ 处有明显尖峰的独特谱形。与一般的随机网络或无标度模型不同，这种特定的谱轮廓意味着底层存在顶点或模体的重复 (duplication)，而这正是驱动这些生物结构演化的根本机制。

As illustrated in the spectral profiles, the global rewiring results in a significant distortion of the density distribution and a suppression of the primary peak, characteristic of tree-like structure. The bootstrapping test yielded statistically significant p-value ($p < 0.005$), demonstrating that the observed similarity between the semantic reconstruction and the biological reference is not the result of random chance but reflects a successful reconstruction of the underlying organizational logic of the Reactome database.

如谱轮廓图所示，全局重连导致密度分布显著扭曲、主峰被压制——而那个主峰正是树状结构的特征。自举检验给出了统计显著的 p 值 ($p < 0.005$)，表明所观察到的语义重建与生物学参考之间的相似性并非随机所致，而是反映了对 Reactome 数据库底层组织逻辑的一次成功重建。

(图 1 为拉普拉斯谱图：三个网络的归一化图拉普拉斯谱密度，分别是 (a) RH、(b) SH、(c) 全部边被重连后的 SH。密度由特征值谱与高斯核 ($\sigma = 0.01$) 卷积后按特征值数目归一化得到。三张图共用同一 y 轴以便直接比较。RH 与各变体之间基于 Jensen - Shannon 的拉普拉斯谱距离分别是 **0.085 (SH) **和 0.224 (完全重连的 SH)。

四、结论：一次可行性验证，以及它指向的下一步

In this work, we first obtained the manually curated biological hierarchy of Pathways and Reactions from Reactome related to Homo sapiens by querying the Reactome Graph Database, which we named Reactome Hierarchy. Then, we extracted and concatenated the names and the description of the retrieved elements, and created the corresponding vector representations using SPECTER2. These embeddings served as the foundation to create a Semantic Hierarchy leveraging a combination of clustering and graph reconstruction algorithms that we designed.

在这项工作中，我们首先通过查询 Reactome 图数据库，取得了与人类相关的、经人工策展的 Pathway 与 Reaction 生物学层级，称之为 Reactome Hierarchy。然后我们抽取并拼接了这些元素的名称与描述，用 SPECTER2 生成对应的向量表示。这些 embedding 成为构建 Semantic Hierarchy 的基础——具体是借助我们自己设计的聚类算法与图重建算法的组合。

The two hierarchies were finally compared, and results indicate that the reconstructed Semantic Hierarchy can reasonably reproduce the reference Reactome structure, making a step towards bridging the gap between unstructured textual descriptions and structured biological information.

最后我们比较了这两个层级，结果表明重建出的 Semantic Hierarchy 能够**较为合理地再现**参考的 Reactome 结构，这向弥合"非结构化文字描述"与"结构化生物学信息"之间的鸿沟迈出了一步。

This work represents the first attempt to check the feasibility and the accuracy of this workflow rather than an exhaustive study. The analysis was performed on a single species and relied on a limited set of comparison metrics, so the present findings should be read as a preliminary contribution within a broader research agenda. The current evaluation is largely computational and topological, while in future developments we plan to evaluate the results also from a biological perspective from a domain expert.

这项工作是对该流程可行性与准确性的首次尝试性检查，而非一项详尽的研究。 分析只在单一物种上进行，并且依赖于一组有限的比较指标，因此当前的发现应被视为一个更大研究议程中的初步贡献。目前的评估在很大程度上是计算性和拓扑性的；在后续发展中，我们计划**也从领域专家的生物学视角**来评估结果。

Future work include validating these findings with additional metrics that capture different aspects of graph similarity. Furthermore, the results are obtained exclusively from Reactome and the Homo sapiens hierarchy, and their generalisability to other species and biological databases remains to be assessed. Additionally, incorporating information like node-to-node similarity and graph alignment techniques could help better understand where the two hierarchies diverge.

未来工作包括：用能捕捉图相似性不同侧面的更多指标来验证这些发现。此外，本文结果完全来自 Reactome 和人类层级，其向其它物种和其它生物数据库的**可推广性尚待评估**。另外，引入节点对节点的相似度以及图对齐技术，能帮助我们**更好地理解两个层级在哪里发生了分歧**。

This type of information can be relevant in the identification of understudied/less curated areas, with a direct feedback to the curators. Taken together, these directions position the current results as a concrete step within a larger effort to bridge unstructured textual descriptions and structured biological knowledge, where the SH can be used to test and refine automatic curation tools which could greatly reduce the burden of manual curation, while preserving quality.

这类信息可以用于识别研究不足/策展不充分的区域，并直接反馈给策展人员。综合来看，这些方向使当前结果成为一项更大努力中的一个具体步骤——即弥合非结构化文字描述与结构化生物知识之间的鸿沟；在这一努力中，SH 可以被用来测试和改进自动策展工具，从而在保持质量的同时大幅降低人工策展的负担。

参考链接

- [arXiv:2608.28178](#) — 本文原文 (cs.AI, 2026-08-28 提交, CIBB 2026 会议论文集)
- [semhier 代码仓库](#) — 作者公开的实现代码 (意大利国家研究委员会自建的 GitLab 实例)
- [Reactome](#) — 本文的数据来源, 人工策展的生物通路知识库; 本文用的是 V95 版 (2025 年 12 月)
- [Reactome Graph Database](#) — Reactome 的 Neo4j 图数据库接口, RH 就是从这里查出来的
- [SPECTER2](#) — 本文用的句向量模型, 在科学引用图上做对比学习训练
- [SaT / Segment any Text](#) — 用于把超过 512 token 的长描述按句子边界切分的库