

分布式用户建模：UserML 与 GUMO Decentralized

User Modeling with UserML and GUMO

原文：Dominik Heckmann, Tim Schwartz, Boris Brandherm, Alexander Kröner（德国人工智能研究中心 DFKI + 萨尔兰大学），DASUM 2005 工作坊论文，共 4 页。

核心内容

Q：这篇论文到底提出了什么东西？ A：两样东西加一个服务。UserML 是一种基于 RDF 的用户模型交换语言，负责「怎么写」；GUMO 是通用用户模型本体，负责「写的内容是什么意思」；u2m.org 是一个用户模型服务，负责存和取。三者的分工是：UserML 提供语法，GUMO 提供语义，服务提供存取通道。

Q：一条关于用户的陈述，在这套东西里长什么样？ A：拆成三段。辅助词（auxiliary）、谓词（predicate）、取值域（range）。「用户对足球有兴趣」这句话拆成 `hasInterest / football / 低-中-高`。论文列出的辅助词除了 `hasInterest` 和 `hasKnowledge`，还有 `hasBelieve`、`hasPlan`、`hasProperty`、`hasGoal`、`hasRegularity`。三段之外还有三组元数据，合起来 25 个属性。

Q：那 25 个属性都是什么？ A：分三组。情境组（situation）装 start、end、durability、location、position，说明这条陈述在什么时空条件下成立。隐私组（privacy）装 key、owner、access、purpose、retention，说明谁能看、留多久。解释组（explanation）装 creator、method、evidence、confidence，说明这条陈述是谁写的、用什么方法得出的、依据是什么、有多可信。论文强调一条陈述不必填满 25 个属性，但每个属性都有预定义含义，有专门的元数据推理模块在上面工作。

Q：这套做法和「给用户建一张属性表」的本质区别在哪？ A：区别在于稳定性被写进了本体，而不是写进业务代码。GUMO 给每个用户维度定义一个 `gumo:expiry`，写的是这个维度上的陈述预期能有效多久：心率是秒级，「有创造力」这类特征是月级，「内向」这类人格特质是年级，出生地基本不变。设计用意是，如果过了有效期还没拿到新值，仍然可以继续用旧值，只是要配合降低置信度。属性表做不到这件事，因为属性表没有地方安放「这一列多久会过期」。

Q：论文自己承认了什么问题？ A：承认了一个很要紧的坑：实际上任何东西都能当 `hasInterest` 或 `hasKnowledge` 的谓词，不做模块化就会出问题。他们给的解法是划一条界——本体只负责识别「基本用户维度」，一般的世界知识交给已有的其他本体去管（他们用 SUMO 和 UbisWorld）。这是全文最有价值的一句自我批评。

Q：作者的态度是什么？ A：谨慎乐观。他们在博物馆导览、定位服务、通知管理三个应用里试过，认为这条路「看起来有前景」（seems to be promising），并且明确说学生模型标准化能不能搬到普适计算领域，还需要深入研究。2005 年的论文，没有把话说满。

背景补充 / 点评

先交代人物与时代。Dominik Heckmann 是 DFKI（德国人工智能研究中心）的研究者，2005 年前后普适计算（ubiquitous computing）正热，那时候设想的场景是：一个人带着 PDA 走进一栋装了红外信标和 RFID 标签的楼里，楼里的设备和手上的设备各自持有一部分用户模型，需要互相交换。所以这篇论文所有的设计决策都是围绕「分布式」展开的——语言要能在 XML、RDF、SQL 三种存储里表达，合并多份局部用户模型要靠过滤器和冲突消解策略。今天我们做画像通常是集中式的，这一层动机不成立，但它逼出来的那套元数据结构反而更有用：分布式环境下你不得不给每条陈述标来源、标置信度、标有效期，集中式环境下人会偷懒不标。

文中出现的几个外部本体值得知道来历。SUMO（Suggested Upper Merged Ontology）是 IEEE 标准化工作组做的通用上层本体，目的是给「实体」「过程」「属性」这类最顶层的概念一个公认定义；UbisWorld 是同一批人做的、专门描述智能环境（房间、设备、位置）的本体；OWL 是 W3C 定的本体描述语言，用 XML 写，支持多重继承，论文里那段 `PhysiologicalState` 的代码就是 OWL。

我的判断：这篇论文最深的洞察不在三段式，而在两处不起眼的设计。

第一处是 `gumo:expiry` 挂在维度上而不是挂在数据上。绝大多数画像系统把「这条数据什么时候过期」当成一条数据的属性，于是每次写入都要有人判一次，判不准就全局设一个默认值糊过去。GUMO 的做法是承认「多久会变」是维度的固有性质：心率天生秒级变化，出生地天生不变，这跟具体是谁的心率无关。判断从每条数据挪到了一次性的维度定义上，成本从 $O(\text{数据量})$ 降到 $O(\text{维度数})$ 。

第二处是 `gumo:privacy` 也挂在类上。哪些维度敏感，是维度的性质，不是记录的性质。

留白的地方也很明显。论文说合并多份用户模型靠「过滤器和冲突消解策略」，但一个字都没写具体策略是什么，只画了三张示意图。冲突消解恰恰是最难的那一块——同一个人在两个设备上留下矛盾的陈述，谁赢？靠 confidence 比大小，还是靠时间取新的，还是靠 method 分优先级？论文避开了。另外那 25 个属性只给了名字，没给取值规范，`method` 该填什么粒度、`evidence` 该指向什么，都是空的。

对我自己的启示，有三条能直接用在正在做的学员画像本体上。

第一条，「相对稳定」这个卡了很久的词，答案是把它拆到维度上。我们讨论学员画像时反复卡在「什么叫相对稳定」，试图找一个全局阈值。这篇论文说明找不到，也不该找：岗位是年级，「最近在谈一个大客户」是周级，「这次想精学还是略学」是单次会话级。有效期写进维度定义，写入时不再判。

第二条，来源和置信度不用自己设计，抄它的解释组四个字段。creator 记谁写的，method 记「从对话抽取」还是「学习平台同步」，evidence 记具体哪一轮对话，confidence 记置信度。这四个分开的好处在离线数据上立刻显现：离线刷回来的画像可以只填 method 不填 evidence，不用为了凑格式编一条假证据。

第三条，也是最该警惕的一条：这篇论文自己踩的那个坑，我们正走在同一条路上。「任何东西都能当 hasInterest 的谓词」翻译成我们的语境就是——如果画像本体既登记「掌握度」这个维度，又登记「GROW 模型」这个知识点，那么每上一门新课都要往画像本体里加概念，本体会被课程内容撑爆。界必须

划在：画像本体只管维度和取值域，知识点归课程侧的知识体系，画像只引用不复制。这条界如果一开始不划，事后划不回来。

文中金句

"A central conceptual idea in USERML's approach is the division of user model dimensions into the three parts auxiliary, predicate and range." UserML 方法的一个核心概念是：把用户模型维度划分成辅助词、谓词、取值域三个部分。

"However, it turned out that actually everything can be a predicate for the auxiliary hasInterest or hasKnowledge, what leads to a problem if one does not work modularized." 然而事实表明，任何东西实际上都可以充当 hasInterest 或 hasKnowledge 这两个辅助词的谓词；如果不做模块化，这会导致问题。

"The attribute gumo:expiry provides a default value for the average expiry which carries the qualitative time span of how long the statement is expected to be valid." gumo:expiry 这个属性给出平均过期时长的默认值，它承载的是一个定性的时间跨度，表示这条陈述预期能保持有效多久。

"The idea behind gumo:expiry is that if no new actual value is available on the user model server after a while, one can still work with old values, probably combined with reduced confidence values." gumo:expiry 背后的想法是：如果过了一段时间，用户模型服务器上仍然没有新的实际值，那么旧值依然可以继续使用，只是可能要配合调低置信度。

全文翻译

摘要

We present a new architecture for decentralized user modeling and briefly discuss the user model markup language USERML, the general user model ontology GUMO for the uniform interpretation of decentralized user models, and the integration of ubiquitous applications with the u2m.org user model service. The motivation is that ubiquitous evaluation of user behavior with a variety of systems in the web or the physical world might lead to attractive new services.

我们提出一种用于分布式用户建模的新架构，并简要讨论三样东西：用户模型标记语言 USERML；用于统一解释分布式用户模型的通用用户模型本体 GUMO；以及普适计算应用与 u2m.org 用户模型服务的集成。动

机在于，如果能在 Web 上或物理世界中，用各种各样的系统对用户行为做普适的评估，可能会催生有吸引力的新服务。

一、方法与架构

We developed the RDF-based user model exchange language UserML to enable decentralized systems to communicate over user models. The idea is to spread the information among all adaptive systems, either with a mobile device or via ubiquitous networks. UserML statements can be arranged and stored in distributed repositories in XML, RDF or SQL. Each mobile and stationary device has an own repository of situational statements, either local or global, dependent on the network accessibility.

我们开发了基于 RDF 的用户模型交换语言 UserML，让分布式的各系统之间能就用户模型进行通信。基本想法是把信息散布到所有自适应系统中去，可以借助移动设备，也可以通过普适网络。UserML 陈述可以用 XML、RDF 或 SQL 的形式，组织并存放在分布式的仓库里。每一个移动设备和固定设备都有自己的一份「情境陈述」仓库，视网络可达性而定，这份仓库可能是本地的，也可能是全局的。

A mobile device can perfectly be integrated via wireless lan or bluetooth into the intelligent environment, while a stationary device could be isolated without network access. The different applications or agents produce or use UserML statements to represent the user model information. UserML forms the syntactic description in the knowledge exchange process.

移动设备可以通过无线局域网或蓝牙很好地集成进智能环境，而固定设备则可能因为没有网络接入而处于孤立状态。不同的应用或 agent 生产或使用 UserML 陈述，用来表示用户模型信息。在知识交换的过程中，UserML 承担的是语法层面的描述。

Each concept like the user model auxiliary hasProperty and the user model dimension timePressure points to a semantical definition of this concept which is either defined in the general user model ontology GUMO, the UbisWorld ontology, which is specialized for ubiquitous computing, or the general SUMO/MILO ontology. The merging of partial, decentralized user models is realized by combining the different user model repositories, while the inferential integration is done by filters and conflict resolution strategies.

每一个概念，比如用户模型辅助词 hasProperty，或者用户模型维度 timePressure，都指向这个概念的一个语义定义；这个定义要么在通用用户模型本体 GUMO 里，要么在专门面向普适计算的 UbisWorld 本体里，要么在通用的 SUMO/MILO 本体里。局部的、分布式的用户模型的合并，是通过组合不同的用户模型仓库来实现的；而推理层面的整合，则由过滤器和冲突消解策略来完成。

二、UserML 与 GUMO 的背景

UserML has been introduced as user model exchange language. A central conceptual idea in UserML's approach is the division of user model dimensions into the three parts auxiliary,

predicate and range. For example, if one wants to say something about the user's interest in football, one could divide this so-called user model dimension into the auxiliary part has interest, the predicate part football and the range part low-medium-high.

UserML 最初是作为用户模型交换语言被提出的。USERML 方法的一个核心概念是：把用户模型维度划分成辅助词、谓词、取值域三个部分。举例来说，如果想表述用户对足球的兴趣，可以把这个所谓的用户模型维度切成三段——辅助词部分是 has interest，谓词部分是 football，取值域部分是 low-medium-high（低、中、高）。

Apart from these so called mainpart attributes, further important meta attributes have been identified for the user modeling domain. These are situation (like start, end, durability, location and position), privacy (like key, owner, access, purpose, retention) and explanation (like creator, method, evidence, confidence). UserML statements need not to use all 25 attributes that have been arranged into groups. However each of these have a predefined meaning on which specialized meta-data inference modules work.

除了这些所谓的「主体部分」属性之外，我们还为用户建模这个领域识别出了另外一些重要的元属性，分别是：情境组（如 start 开始、end 结束、durability 持续性、location 地点、position 位置）、隐私组（如 key 密钥、owner 所有者、access 访问权、purpose 用途、retention 留存期）、解释组（如 creator 创建者、method 方法、evidence 证据、confidence 置信度）。一条 UserML 陈述不必用上全部 25 个已经分好组的属性。但这些属性每一个都有预先定义好的含义，有专门的元数据推理模块在这些含义上工作。

The advantage of using UserML to model the user model statements is the uniform syntactical relational data structure that allows apart from the representation in an ontology also the storage of mass data in a database.

用 UserML 来给用户模型陈述建模，好处在于它有统一的、语法层面的关系型数据结构；这样一来，除了能在本体里表示之外，还能把海量数据存进数据库。

GUMO is designed according to the approach of dividing basic user model dimensions into triples. The advantage of using GUMO in decentralized settings is the semantical uniformity. Loads of auxiliaries, predicates and ranges have so far been identified and inserted into the ontology that can be inspected with a foldable tree browser at the web page <http://www.gumo.org>. However, it turned out that actually everything can be a predicate for the auxiliary hasInterest or hasKnowledge, what leads to a problem if one does not work modularized.

GUMO 的设计遵循的是「把基本用户模型维度切成三元组」这一思路。在分布式场景里使用 GUMO 的好处是语义上的统一。到目前为止，大量的辅助词、谓词和取值域已经被识别出来并加入本体，可以在 <http://www.gumo.org> 上用一个可折叠的树形浏览器查看。然而事实表明，任何东西实际上都可以充当 hasInterest 或 hasKnowledge 这两个辅助词的谓词；如果不做模块化，这会导致问题。

The suggested solution is to identify basic user model dimensions on the one hand while leaving the more general world knowledge open for already existing other ontologies on the other hand. Candidates are the general suggested upper merged ontology SUMO and the UBISWORLD ontology to model intelligent environments. This insight leads to a modular approach which forms a key feature of GUMO.

我们建议的解法是：一方面只去识别基本的用户模型维度，另一方面把更一般的世界知识留给已经存在的其他本体。候选者包括通用的上层合并本体 SUMO，以及用于给智能环境建模的 UBISWORLD 本体。这个洞察引出了一种模块化的做法，而模块化构成了 GUMO 的一个关键特性。

A commonly accepted top level ontology for user models could be of great importance for the user modeling research community. But which groups of user dimensions can be identified? Furthermore, this ontology should be represented in a modern semantic web language like OWL and thus via internet be available for all user-adaptive systems at the same time. The major advantage would be the simplification for exchanging interpretable user model information between different user-adaptive systems.

一个被广泛接受的用户模型上层本体，对用户建模研究社区可能有重大意义。但是，能识别出哪些用户维度的分组呢？此外，这个本体应当用 OWL 这类现代语义网语言来表示，从而能通过互联网同时供所有用户自适应系统使用。最大的好处在于，不同的用户自适应系统之间交换可解释的用户模型信息会变得简单。

We are collecting the user's dimensions that are modeled within user-adaptive systems like the user's heart beat, the user's age, the user's current position, the user's birthplace or the user's ability to swim. Furthermore, the modeling of the user's interests and preferences like reading poems, playing adventure games or drinking certain French Bordeaux wines is analyzed. Identified user model auxiliaries apart from hasKnowledge and hasInterest are for example hasBelieve, hasPlan, hasProperty, hasGoal, hasPlan and hasRegularity. User model predicates that fit to the auxiliary "hasProperty" are called BasicUserDimensions. Examples are Emotional States, Characteristics and Personality.

我们正在收集那些被用户自适应系统建模过的用户维度，比如用户的心跳、年龄、当前位置、出生地，或者游泳能力。此外我们也分析了对用户兴趣与偏好的建模，比如读诗、玩冒险游戏，或者喝某些法国波尔多葡萄酒。除了 hasKnowledge 和 hasInterest 之外，已经识别出的用户模型辅助词还有 hasBelieve、hasPlan、hasProperty、hasGoal、hasRegularity 等。适配 hasProperty 这个辅助词的用户模型谓词被称为「基本用户维度」(BasicUserDimensions)，例子有情绪状态、特征、人格。

Every concept has a unique rdf:ID, that can be resolved into a complete URI. The attribute gumo:privacy defines the default privacy status for this class of user dimensions. The attribute gumo:website points towards a web site, that has its purpose in presenting this ontology concept, to a human reader.

每个概念都有唯一的 rdf:ID，可以解析成一个完整的 URI。gumo:privacy 这个属性定义了这一类用户维度的默认隐私状态。gumo:website 这个属性指向一个网页，该网页的用途是把这个本体概念呈现给人类读

者。

The attribute `gumo:expiry` provides a default value for the average expiry which carries the qualitative time span of how long the statement is expected to be valid. In most cases when user model dimensions are measured, one has a rough idea about the expected expiry. For instance, emotional states hold normally no longer than 15 minutes, however personality traits won't change within months. Since this qualitative time span is dependent from every user model dimension, it should be defined within GUMO. Some examples of rough expiry-classifications are: `physiologicalState.heartbeat` - can change within seconds; `characteristics.inventive` - can change within months; `personality.introvert` - can change within years; `demographics.birthplace` - can't normally change at all.

`gumo:expiry` 这个属性给出平均过期时长的默认值，它承载的是一个定性的时间跨度，表示这条陈述预期能保持有效多久。在多数情况下，当我们测量某个用户模型维度时，对预期的过期时长是有大致概念的。举例来说，情绪状态通常维持不超过 15 分钟，而人格特质在几个月内不会改变。既然这个定性时间跨度取决于每一个具体的用户模型维度，那它就应该在 GUMO 内部定义。几个粗略的过期分类的例子是：生理状态-心跳，能在几秒内变化；特征-有创造力，能在几个月内变化；人格-内向，要以年为单位才会变化；人口统计学-出生地，通常根本不会变。

The idea behind `gumo:expiry` is that if no new actual value is available on the user model server after a while, one can still work with old values, probably combined with reduced confidence values. The semantic web ontology language OWL allows to construct complex, graph-like hierarchies of user model concepts with multiple-inheritance, which is especially important for ontology integration. For example, happiness is defined as `rdf:type` of the class `EmotionalState` and `FiveBasicEmotions`.

`gumo:expiry` 背后的想法是：如果过了一段时间，用户模型服务器上仍然没有新的实际值，那么旧值依然可以继续使用，只是可能要配合调低置信度。语义网本体语言 OWL 允许构造复杂的、图状的用户模型概念层级，并支持多重继承，这一点对本体集成尤其重要。举例来说，「快乐」既被定义为 `EmotionalState`（情绪状态）这个类的 `rdf:type`，也被定义为 `FiveBasicEmotions`（五种基本情绪）这个类的 `rdf:type`。

To support the distributed construction and refinement of GUMO, we developed a specialized online editor to introduce new concepts, to add their definitions and to transform the information automatically into the required semantic web language. Related ontologies and knowledge-sharing projects have been analyzed. However, a profound investigation of the possible application of student model standardizations into the domain of ubiquitous computing has to be undertaken.

为了支撑 GUMO 的分布式构建与精化，我们开发了一个专门的在线编辑器，用来引入新概念、添加它们的定义，并把这些信息自动转换成所需的语义网语言。我们已经分析过相关的本体和知识共享项目。不过，把学生模型标准化的成果应用到普适计算领域这件事究竟可行到什么程度，还需要做深入的考察。

三、分布式与移动服务及应用

A user model service manages information about users and contributes additional benefit compared to a user model server. The u2m.org user model service consists of a set of application-independent servers with a distributed approach for accessing and storing user information, the possibility to exchange and understand data between different applications, as well as adding privacy and transparency to the statements about the user.

用户模型服务负责管理关于用户的信息，与单纯的用户模型服务器相比，它提供了额外的价值。u2m.org 用户模型服务由一组与应用无关的服务器构成，采用分布式的方式来访问和存储用户信息，使不同应用之间能够交换并理解数据，同时为关于用户的陈述加上隐私性与透明性。

Applications can retrieve or add information by HTTP requests like:

```
http://www.u2m.org/UbisWorld/UserModelService.php?  
subject=Peter&auxiliary=hasProperty&predicate=Happiness
```

应用可以通过如下形式的 HTTP 请求来获取或添加信息：

```
http://www.u2m.org/UbisWorld/UserModelService.php?  
subject=Peter&auxiliary=hasProperty&predicate=Happiness
```

We have tested the approach in a MOBILE MUSEUMS GUIDE, in a POSITIONING SERVICE and in an ALARM MANAGER application. The latter one is a notification service for instrumented environments that adapts the presentation of announcements to the user's state of arousal and the user's location. Both are retrieved from the UserML and GUMO enabled user model service. The location is derived from the POSITIONING SERVICE application. This service runs on the user's PDA and uses infrared beacons and active RFID tags that are installed in the environment to estimate the location of the user which is then send via WiFi to the user model service.

我们在三个应用里检验了这套方法：移动博物馆导览、定位服务、以及通知管理器。最后这个面向被仪器化的环境的通知服务，它会根据用户的唤醒状态和所在位置，来调整通告的呈现方式。这两项信息都从支持 UserML 与 GUMO 的用户模型服务里取得。位置来自定位服务这个应用：该服务运行在用户的 PDA 上，利用安装在环境中的红外信标和有源 RFID 标签来估计用户位置，再通过 WiFi 发送给用户模型服务。

四、总结

We presented architectural modules for decentralized user modeling, especially the user model exchange language UserML and the general user model ontology GUMO. We discussed the possibilities for semantic integration and briefly demonstrated the approach with ubiquitous user-adaptive applications. The combination of the GUMO ontology with the exchange language UserML together with the decentralized u2m.org user model service seems to be promising.

我们介绍了用于分布式用户建模的若干架构模块，特别是用户模型交换语言 UserML 和通用用户模型本体 GUMO。我们讨论了语义集成的可能性，并用普适的用户自适应应用简要演示了这套方法。GUMO 本体、

UserML 交换语言、以及分布式的 u2m.org 用户模型服务三者的组合，看起来是有前景的。

参考链接

- [GUMO 本体浏览器](#) — 论文中给出的 GUMO 在线树形浏览器地址，用于查看已登记的辅助词、谓词、取值域（该站点已停止维护，仅作出处标注）
- [UbisWorld 本体](#) — 同一批作者做的智能环境本体，负责论文里划出去的那部分「世界知识」
- [SUMO 上层本体](#) — 论文引用的 Suggested Upper Merged Ontology，IEEE 标准化工作组维护的通用上层本体