



(12) 发明专利申请

(10) 申请公布号 CN 121958327 A

(43) 申请公布日 2026. 05. 01

(21) 申请号 202511877748.4

G06F 40/30 (2020.01)

(22) 申请日 2025.12.12

(71) 申请人 上海宝信软件股份有限公司

地址 200120 上海市浦东新区自由贸易试
验区郭守敬路515号(72) 发明人 杨勇 郑应根 徐永军 吴毅平
李辉 杨海荣(74) 专利代理机构 上海锻创知识产权代理有限
公司 31448

专利代理师 陈少凌

(51) Int. Cl.

G06F 16/2453 (2019.01)

G06F 16/2455 (2019.01)

G06F 16/2458 (2019.01)

G06F 16/248 (2019.01)


权利要求书2页 说明书16页 附图3页

(54) 发明名称

基于语言模型和不确定性评估的多路径信
息检索方法及系统

(57) 摘要

本发明提供了一种基于语言模型和不确定性评估的多路径信息检索方法及系统,包括:接收用户查询;利用预训练的语言模型对用户查询进行语义分析,以无监督地输出一个量化不确定性指标;基于该指标,动态确定用于控制查询生成的数量配比和用于控制结果排序的平衡参数;基于用户查询和策略参数,生成并执行至少包括探索性查询和利用性查询的两组差异化查询,以获得多路检索结果;将多路结果合并,并采用排序机制依据平衡参数在结果相关性与多样性之间进行动态平衡的重排序。本发明能够根据查询的不确定性自适应调整检索策略,显著提升结果的覆盖度与多样性。



1. 一种基于语言模型和不确定性评估的多路径信息检索方法, 其特征在于, 包括以下步骤:

接收用户查询;

利用预训练的语言模型对所述用户查询进行语义分析, 以无监督地输出一个量化不确定性指标;

基于所述量化不确定性指标, 动态地确定至少一个策略参数, 所述策略参数包括用于控制后续查询生成的查询生成数量配比, 以及用于控制结果排序的排序平衡参数;

基于所述用户查询和所述策略参数, 生成至少两组存在差异化的查询, 其中至少包括一组旨在拓宽搜索广度的探索性查询和一组旨在加深搜索深度的利用性查询, 并执行所述至少两组查询以获得多路检索结果;

将所述多路检索结果合并, 并采用一种排序机制进行重排序, 其中, 所述排序机制依据所述排序平衡参数在结果相关性与多样性之间进行动态平衡;

输出经重排序后的结果。

2. 根据权利要求1所述的方法, 其特征在于, 所述预训练的语言模型为大型语言模型。

3. 根据权利要求1或2所述的方法, 其特征在于, 所述利用预训练的语言模型对所述用户查询进行语义分析, 包括:

指令所述预训练的语言模型对所述用户查询的语义模糊性、领域专业性和信息需求广度进行综合评估。

4. 根据权利要求1所述的方法, 其特征在于, 所述生成至少两组存在差异化的查询的步骤之前, 还包括:

使用所述用户查询执行一次基准搜索, 以获得基准结果集;

并且, 所述生成至少两组存在差异化的查询的步骤, 是基于所述用户查询和所述基准结果集生成的。

5. 根据权利要求4所述的方法, 其特征在于,

所述探索性查询的生成, 是通过指令所述预训练的语言模型进行语义扩展、条件放宽或多视角重构来实现;

所述利用性查询的生成, 是通过指令所述预训练的语言模型进行精准化、添加具体限定条件或问题分解来实现。

6. 根据权利要求1所述的方法, 其特征在于, 所述排序机制为最大边际相关性MMR算法, 所述排序平衡参数为所述MMR算法中用于平衡相关性与多样性的平衡参数 λ 。

7. 根据权利要求1所述的方法, 其特征在于, 所述动态地确定至少一个策略参数的步骤, 包括:

将所述量化不确定性指标与至少一个预设阈值进行比较, 以根据比较结果确定所述查询生成数量配比和所述排序平衡参数。

8. 根据权利要求7所述的方法, 其特征在于, 包括以下至少一项:

当所述量化不确定性指标高于预设的高不确定性阈值时, 确定所述查询生成数量配比为探索性查询数量多于利用性查询数量, 并确定所述排序平衡参数为倾向于多样性的数值;

当所述量化不确定性指标低于预设的低不确定性阈值时, 确定所述查询生成数量配比

为利用性查询数量多于探索性查询数量,并确定所述排序平衡参数为倾向于相关性的数值。

9.一种基于语言模型和不确定性评估的多路径信息检索系统,其特征在于,包括:

接收单元,用于接收用户查询;

评估单元,用于利用预训练的语言模型对所述用户查询进行语义分析,以无监督地输出一个量化不确定性指标;

策略确定单元,用于基于所述量化不确定性指标,动态地确定至少一个策略参数,所述策略参数包括用于控制后续查询生成的查询生成数量配比,以及用于控制结果排序的排序平衡参数;

查询执行单元,用于基于所述用户查询和所述策略参数,生成至少两组存在差异化的查询,其中至少包括一组旨在拓宽搜索广度的探索性查询和一组旨在加深搜索深度的利用性查询,并执行所述至少两组查询以获得多路检索结果;

排序单元,用于将所述多路检索结果合并,并采用一种排序机制进行重排序,其中,所述排序机制依据所述排序平衡参数在结果相关性与多样性之间进行动态平衡;

输出单元,用于输出经重排序后的结果。

10.根据权利要求9所述的系统,其特征在于,所述预训练的语言模型为大型语言模型;

所述利用预训练的语言模型对所述用户查询进行语义分析,包括:

指令所述预训练的语言模型对所述用户查询的语义模糊性、领域专业性和信息需求广度进行综合评估。

基于语言模型和不确定性评估的多路径信息检索方法及系统

技术领域

[0001] 本发明涉及信息检索技术领域,尤其涉及一种基于语言模型和不确定性评估的多路径信息检索方法及系统。

背景技术

[0002] 信息检索技术,例如常见的搜索引擎,是用户获取信息的重要工具。现有的信息检索系统主要依赖于关键词匹配、链接分析以及传统的机器学习模型进行结果排序。这些方法在处理用户意图明确、结构化的查询时能够取得较好的效果。然而,当面对语义复杂、含义模糊或涉及多维信息需求的用户查询时,其局限性便日益凸显。例如,用户可能输入一个宽泛的主题,希望了解该主题下的不同方面,此时仅靠关键词匹配往往难以全面覆盖所有相关信息。

[0003] 为了改善检索效果,业界提出了一些优化技术,例如查询扩展或相关性反馈。这些技术通常通过分析用户查询或初步的检索结果,自动地增加同义词、相关词或对查询进行重构,以期扩大检索范围。但这些技术在很大程度上依赖于预先构建的知识库或大量人工标注的训练数据,不仅部署和维护成本高,灵活性差,而且其本质上仍停留在对查询字符串或特征权重的表层调整,缺乏对用户查询意图的深层语义理解。

[0004] 随着大型语言模型技术的发展,其强大的自然语言理解和生成能力为信息检索领域带来了新的可能性。一些研究开始尝试利用语言模型进行简单的查询重写或生成摘要。更有甚者,有技术方案提出利用语言模型对文本的某些属性,如复杂度、专业度等进行评估,并根据评估结果选择不同级别的后续处理策略。然而,这类现有技术存在明显的缺陷:首先,其策略调整是笼统和单向的,例如仅能决定进行“轻量级分析”或“深度分析”,并未揭示如何将评估结果转化为对信息检索中“探索”(拓宽搜索广度)与“利用”(加深搜索深度)这一核心权衡过程的具体、量化和协同的控制。其次,现有技术缺乏一个将查询不确定性评估、多路径查询生成与最终结果排序融合在一起的闭环控制框架。具体而言,现有技术未能提供一种机制,能够利用单一的查询不确定性指标,同时动态地指导前端的查询生成策略(例如,探索性查询与利用性查询的数量配比)和后端的排序融合策略(例如,在结果的相关性与多样性之间进行平衡),从而无法系统性地解决复杂查询下的信息覆盖不全和多样性不足的问题。

发明内容

[0005] 针对现有技术中的缺陷,本发明的目的是提供一种基于语言模型和不确定性评估的多路径信息检索方法及系统,旨在解决现有技术在处理复杂、模糊查询时,因缺乏由深层语义理解驱动、能够根据查询内在不确定性动态、协同地平衡搜索广度与深度的智能决策机制,而导致信息覆盖不全面且结果多样性不足的技术问题。

[0006] 根据本发明提供的一种基于语言模型和不确定性评估的多路径信息检索方法,包括以下步骤:首先,接收用户查询;然后,利用预训练的语言模型对所述用户查询进行语义

分析,以无监督地输出一个量化不确定性指标;接着,基于所述量化不确定性指标,动态地确定至少一个策略参数,所述策略参数包括用于控制后续查询生成的查询生成数量配比,以及用于控制结果排序的排序平衡参数;随后,基于所述用户查询和所述策略参数,生成至少两组存在差异化的查询,其中至少包括一组旨在拓宽搜索广度的探索性查询和一组旨在加深搜索深度的利用性查询,并执行所述至少两组查询以获得多路检索结果;之后,将所述多路检索结果合并,并采用一种排序机制进行重排序,其中,所述排序机制依据所述排序平衡参数在结果相关性与多样性之间进行动态平衡;最后,输出经重排序后的结果。

[0007] 可选地,所述预训练的语言模型为大型语言模型。

[0008] 可选地,所述利用预训练的语言模型对所述用户查询进行语义分析,包括:指令所述预训练的语言模型对所述用户查询的语义模糊性、领域专业性和信息需求广度进行综合评估。

[0009] 可选地,在所述生成至少两组存在差异化的查询的步骤之前,还包括:使用所述用户查询执行一次基准搜索,以获得基准结果集;并且,所述生成至少两组存在差异化的查询的步骤,是基于所述用户查询和所述基准结果集生成的。此举能够为后续的查询生成提供更丰富的上下文信息,从而提高所生成查询的质量。

[0010] 可选地,所述探索性查询的生成,是通过指令所述预训练的语言模型进行语义扩展、条件放宽或多视角重构来实现;所述利用性查询的生成,是通过指令所述预训练的语言模型进行精准化、添加具体限定条件或问题分解来实现。通过向语言模型提交差异化的指令,可以有效地控制生成查询的类型,以分别满足探索和利用的需求。

[0011] 可选地,所述排序机制为最大边际相关性MMR算法,所述排序平衡参数为所述MMR算法中用于平衡相关性与多样性的平衡参数 λ 。

[0012] 可选地,所述动态地确定至少一个策略参数的步骤,包括:将所述量化不确定性指标与至少一个预设阈值进行比较,以根据比较结果确定所述查询生成数量配比和所述排序平衡参数。

[0013] 可选地,所述根据比较结果确定策略参数的步骤,包括以下至少一项:当所述量化不确定性指标高于预设的高不确定性阈值时,确定所述查询生成数量配比为探索性查询数量多于利用性查询数量,并确定所述排序平衡参数为倾向于多样性的数值;当所述量化不确定性指标低于预设的低不确定性阈值时,确定所述查询生成数量配比为利用性查询数量多于探索性查询数量,并确定所述排序平衡参数为倾向于相关性的数值。

[0014] 根据本发明提供的一种基于语言模型和不确定性评估的多路径信息检索系统,包括:接收单元,用于接收用户查询;评估单元,用于利用预训练的语言模型对所述用户查询进行语义分析,以无监督地输出一个量化不确定性指标;策略确定单元,用于基于所述量化不确定性指标,动态地确定至少一个策略参数,所述策略参数包括用于控制后续查询生成的查询生成数量配比,以及用于控制结果排序的排序平衡参数;查询执行单元,用于基于所述用户查询和所述策略参数,生成至少两组存在差异化的查询,其中至少包括一组旨在拓宽搜索广度的探索性查询和一组旨在加深搜索深度的利用性查询,并执行所述至少两组查询以获得多路检索结果;排序单元,用于将所述多路检索结果合并,并采用一种排序机制进行重排序,其中,所述排序机制依据所述排序平衡参数在结果相关性与多样性之间进行动态平衡;以及输出单元,用于输出经重排序后的结果。

[0015] 可选地,所述预训练的语言模型为大型语言模型;
所述利用预训练的语言模型对所述用户查询进行语义分析,包括:
指令所述预训练的语言模型对所述用户查询的语义模糊性、领域专业性和信息需求广度进行综合评估。

[0016] 与现有技术相比,本发明具有如下的有益效果:

1、本发明通过构建一个以查询不确定性为统一控制信号的闭环自适应检索框架,将大型语言模型的深层语义理解能力与信息检索的“探索-利用”权衡决策深度融合。对于语义模糊的复杂查询,系统能自动拓宽搜索广度,提供更多样化的信息视角;对于意图明确的具体查询,则能自动加深搜索深度,提供更精准的答案,提升了检索结果的覆盖广度、内容深度和多样性,从而改善了用户体验。

[0017] 2、本发明主要通过向预训练的语言模型提交结构化指令的方式实现复杂的策略调整,代替了传统方法中复杂的特征工程和模型训练过程,无需复杂的初始配置或训练即可应用,降低了系统的实现、部署和维护成本,并对新领域、新形态的查询具有良好的泛化能力和鲁棒性。

[0018] 3、本发明将查询不确定性评估结果作为统一的控制信号,协同地调控了查询生成(输入端)和结果排序(输出端)两个关键环节,实现了端到端的策略自适应。这种系统性的整合和耦合设计,是对现有技术中单向、孤立的优化策略的显著改进,使得信息检索系统更具智能化。

附图说明

[0019] 通过阅读参照以下附图对非限制性实施例所作的详细描述,本发明的其它特征、目的和优点将会变得更明显:

图1为本发明实施例提供的一种信息检索系统的结构示意图;

图2为本发明实施例提供的一种信息检索方法的流程示意图;

图3为图2中两阶段搜索步骤的详细流程示意图;

图4为本发明实施例中各实体间信令交互的时序图。

具体实施方式

[0020] 下面结合具体实施例对本发明进行详细说明。以下实施例将有助于本领域的技术人员进一步理解本发明,但不以任何形式限制本发明。应当指出的是,对本领域的普通技术人员来说,在不脱离本发明构思的前提下,还可以做出若干变化和改进。这些都属于本发明的保护范围。

[0021] 实施例 1

本实施例详细阐述了一种基于语言模型和不确定性评估的多路径信息检索方法及其系统的基础实现方案,特别地,该方案适用于用户输入具有较高不确定性的复杂查询的场景。本实施例旨在完整地展示该方法如何通过评估查询的不确定性,自适应地调整搜索策略以侧重于“探索”,从而为用户提供一个覆盖面广、多样性高的信息结果集。

[0022] 请参阅图1,其示出了本发明实施例提供的一种信息检索系统的优选结构示意图。该系统可部署于云服务器、本地服务器集群或任何具备足够计算能力的计算设备。具体而

言,系统主要包括:查询理解与不确定性评估模块10、两阶段搜索模块20、自适应策略调控模块30以及结果融合与多样性排序模块40。需要说明的是,这些模块可实现为软件程序模块、硬件电路或其组合。系统通过大型语言模型接口50与外部预训练的语言模型(例如,一个拥有数百亿或更多参数的大型语言模型)进行通信,并通过数据索引库60访问待检索的信息资源。其中,数据索引库60可以是网页索引、企业内部文档库、学术论文数据库等任何形式的结构化或非结构化数据集合。

[0023] 下面将结合图2所示的本发明实施例提供的一种信息检索方法的总体流程图,以及图4所示的各实体间信令交互的时序图,对本实施例的工作过程进行详细说明。

[0024] 该方法首先执行步骤S100,接收用户查询。在本实施例中,假设用户通过用户终端设备(如图1中的用户终端)向系统提交查询请求,其内容为:“新能源汽车电池技术最新发展”。可以理解的是,这是一个典型的具有较高不确定性的查询,因为它涉及一个快速发展的技术领域,内含多个子主题(如不同类型的电池、技术瓶颈、商业应用等),且“最新发展”这一表述本身即具有开放性与模糊性。

[0025] 相应地,在步骤S200中,对查询不确定性进行评估。查询理解与不确定性评估模块10在接收到该查询后,其核心任务在于无监督地输出一个量化的不确定性指标。在本发明的一个具体实现中,该过程通过与大型语言模型交互来完成。如图4所示,系统向大型语言模型(LLM)发起一个评估不确定性请求。具体而言,查询理解与不确定性评估模块10构建一个结构化的指令(亦称为提示词),并通过大型语言模型接口50将其发送给大型语言模型。该指令用以引导模型利用其内部蕴含的庞大世界知识和推理能力,对查询进行深层语义分析。一个示例性的指令可设计如下:

“【角色扮演与任务指令】你现在是一位顶尖的信息检索分析专家。你的任务是评估以下用户查询的‘不确定性’。在评估时,请你从以下三个维度进行综合考量:1. 语义模糊性:查询中是否存在多义词、指代不明或宽泛的概念?2. 领域专业性:查询是否涉及需要深度专业知识才能完全理解的领域?3. 信息需求广度:查询是否暗示了用户希望了解多个方面、不同视角或一个完整的主题图景,而非单一事实?请基于你的综合判断,输出一个介于0.0到1.0之间的小数作为最终的量化不确定性评分。评分越高,代表不确定性越大。需要注意的是,只需要输出评分数值,无需提供任何解释或分析过程。【待评估的用户查询】:新能源汽车电池技术最新发展”

大型语言模型在接收到此指令后,会对查询“新能源汽车电池技术最新发展”进行分析。可能识别出“电池技术”是一个宽泛的上位概念,可细分为锂离子电池、固态电池、钠离子电池、氢燃料电池等;而“最新发展”则暗示了对前沿、动态信息的需求,而非一个静态的事实。综合这些因素,模型判断该查询的语义模糊性中等、领域专业性较高、信息需求广度极大。因此,模型通过大型语言模型接口50返回一个较高的不确定性评分,例如,量化不确定性指标 $U(q) = 0.75$ 。需要说明的是,此过程为无监督过程,其不依赖任何预先标注的(查询,不确定性分数)训练样本对,而是直接利用了预训练语言模型自身的能力。

[0026] 在确定了查询不确定性之后,流程进入步骤S300,确定策略参数。自适应策略调控模块30接收由查询理解与不确定性评估模块10传递来的不确定性指标 $U(q) = 0.75$ 。该模块内部预设了至少一个、通常是两个不确定性阈值,例如高不确定性阈值 θ_{high} (如0.7)和低不确定性阈值 θ_{low} (如0.25)。自适应策略调控模块30将接收到的 $U(q)$ 与这些阈值进行比较。

在本例中,由于 $0.75 > \theta_{\text{high}} (0.7)$,系统判定当前查询属于高不确定性类别,因此应采取“侧重探索”的检索策略。

[0027] 基于此判断,自适应策略调控模块30动态地确定一组策略参数。这些策略参数至少包括:1. 查询生成数量配比,即后续需要生成的探索性查询数量 N_{explore} 和利用性查询数量 N_{exploit} 。对于高不确定性查询,系统会分配更多资源给探索路径,例如设定 $N_{\text{explore}} = 3$, $N_{\text{exploit}} = 1$ 。2. 排序平衡参数 λ ,该参数将用于后续的结果融合与排序阶段。对于高不确定性查询,为了鼓励结果的多样性,应设置一个较小的 λ 值,例如 $\lambda = 0.3$ 。这个较小的 λ 值意味着在排序时,系统会更强烈地惩罚与已选结果相似的候选项,从而优先选择能够带来新信息的文档。这些确定的策略参数($N_{\text{explore}}=3$, $N_{\text{exploit}}=1$, $\lambda=0.3$)将被分发给后续的相关模块。

[0028] 继而,在步骤S400中,执行由两阶段搜索模块20负责的两阶段搜索。其详细流程可参考图3。

[0029] 第一阶段为基准搜索,对应于图3中的步骤S410。两阶段搜索模块20首先使用用户输入的原始查询“新能源汽车电池技术最新发展”,直接在数据索引库60中执行一次常规的关键词匹配或向量检索。此举旨在快速获取一个与查询字面意义最相关的基础结果集合,即基准结果集。如图3步骤S420所示,系统获取了该基准结果集,例如包含20篇最相关的技术文档、新闻报道或研究论文。该基准结果集不仅本身是最终结果的一部分,更重要的是,它为第二阶段的增强查询生成提供了宝贵的上下文信息。

[0030] 第二阶段为并行双路径搜索,对应于图3中的并行生成增强查询步骤S430。两阶段搜索模块20利用大型语言模型,基于原始查询和第一阶段获得的基准结果集(或其摘要),并行地生成两组存在差异化的新查询。

[0031] 在探索路径上,根据自适应策略调控模块30设定的 $N_{\text{explore}} = 3$,两阶段搜索模块20向大型语言模型提交一个专门为“探索”任务设计的指令,以执行步骤S431。该指令要求模型基于原始查询和基准结果摘要,通过语义扩展、视角切换或条件放宽等方式,生成3个旨在拓宽搜索边界的查询。例如,指令可能如下:“**【探索性查询生成指令】**基于用户查询‘新能源汽车电池技术最新发展’和以下初步检索结果摘要,请生成3个相关的、但视角不同或领域更宽泛的查询,以帮助用户探索相关主题。查询应避免与原始查询过于相似。示例摘要:‘…固态电池能量密度突破…热失控安全研究…’”。模型可能会生成如下探索性查询:1. “电动汽车下一代储能系统技术创新”(从“电池”扩展到“储能系统”);2. “氢燃料电池在汽车领域的技术突破与挑战”(切换到替代技术路线);3. “全球动力电池产业链关键材料研究进展”(从技术本身扩展到产业链上游)。随后,在步骤S432中,系统使用这3个新生成的探索性查询,并行地向数据索引库60发起检索,获得三路探索性检索结果。

[0032] 与此同时,在利用路径上,根据设定的 $N_{\text{exploit}} = 1$,两阶段搜索模块20向大型语言模型提交一个为“利用”任务设计的、存在差异化的指令,以执行步骤S441。该指令要求模型通过增加限定、问题分解或精准化等方式,生成1个旨在深化核心主题的查询。例如,指令可能为:“**【利用性查询生成指令】**基于用户查询‘新能源汽车电池技术最新发展’和初步结果摘要,请生成1个更具体、更深入的查询,聚焦于当前最核心的技术方向。”。模型可能会生成如下利用性查询:“固态锂电池能量密度与循环寿命的最新提升路径分析”。随后,在步骤S442中,系统使用这个新查询向数据索引库60发起检索,获得一路利用性检索结果。

[0033] 至此,步骤S400完成,系统共获得了1路基准搜索结果、3路探索性搜索结果和1路利用性搜索结果,共计5路检索结果。

[0034] 此后,在步骤S500中,结果融合与多样性排序模块40负责将上述5路检索结果进行合并,并进行去重处理,形成一个庞大的候选结果总集。

[0035] 接着,在关键的步骤S600中,执行动态加权排序。结果融合与多样性排序模块40采用一种动态加权的最大边际相关性算法对候选结果总集进行重排序。该算法的目标是从候选文档集D中迭代地选择文档d,以最大化一个目标函数。该目标函数的数学表达式为:

$$\text{MMR}(D) = \arg \max_{d \in D \setminus S} \left[\lambda \cdot \text{Sim}_1(d, q) - (1 - \lambda) \cdot \max_{d_i \in S} \text{Sim}_2(d, d_i) \right]$$

[0036] 其中,D是候选文档集,S是已经选出的结果集,q是原始用户查询。 $\text{Sim}_1(d, q)$ 计算候选文档d与原始查询q的相关性得分,这可以通过传统的BM25算法或现代的向量余弦相似度计算得出。 $\text{Sim}_2(d, d_i)$ 计算候选文档d与已选结果集S中某个文档 d_i 的相似度得分,同样可以通过向量相似度等方法计算。

[0037] 需要说明的是,在本发明的方案中,平衡参数 λ 并非一个固定的超参数,而是由步骤S300中自适应策略调控模块30根据不确定性评分 $U(q)$ 动态确定的值。在本实施例中, λ 被设定为0.3。这个较小的 λ 值增大了公式中第二项,即多样性惩罚项 $(1 - \lambda) \cdot \max_{d_i \in S} \text{Sim}_2(d, d_i)$ 的权重。也就是说,在排序过程中,如果一个候选文档与已选出的结果非常相似,它将受到较大的惩罚,其最终得分会降低,从而不容易被选中。反之,与已选结果差异较大但与原始查询仍有一定相关性的文档,则有更大机会被排在前面。这种机制有效地促进了结果的多样性。

[0038] 最后,在步骤S700中,输出结果。结果融合与多样性排序模块40将经过动态加权MMR算法重排序后的最终结果序列呈现给用户。由于采取了“侧重探索”的策略和多样性优先的排序方式,最终输出的结果列表不仅包含了关于固态锂电池等核心技术的深度文章(来自利用路径),还广泛覆盖了储能系统创新、氢燃料电池、产业链材料等相关或替代性技术方向的内容(来自探索路径),从而为用户构建了一个更全面、多维度的信息图景,以满足其对一个复杂主题进行探索性了解的需求。

[0039] 实施例 2

本实施例旨在说明本发明提供的技术方案在处**理低不确定性**、事实型查询时的自适应能力。在此类场景下,用户意图非常明确,系统应自动切换到“侧重利用”的策略,以提供精准、直接的答案,避免不必要的信息发散。

[0040] 本实施例所采用的系统结构与实施例1中图1所示的结构相同,同样包含查询理解与不确定性评估模块10、两阶段搜索模块20、自适应策略调控模块30和结果融合与多样性排序模块40,并与大型语言模型接口50和数据索引库60进行交互。其整体方法流程亦遵循图2所示的步骤。

[0041] 在步骤S100中,系统接收到一个新的用户查询:“苹果公司的现任CEO是谁”。这是一个典型的事实型查询,其不确定性极低。

[0042] 在步骤S200中,查询理解与不确定性评估模块10将此查询打包成与实施例1类似的指令,发送给大型语言模型进行评估。大型语言模型分析该查询指向一个非常具体、单一的实体属性,语义清晰,无模糊性,信息需求广度极窄。因此,模型会返回一个极低的不确定

性评分,例如, $U(q) = 0.1$ 。

[0043] 在步骤S300中,自适应策略调控模块30接收到 $U(q) = 0.1$,并将其与预设的低不确定性阈值 θ_{low} (例如0.25)进行比较。由于 $0.1 < \theta_{low}$ (0.25),系统判定当前查询属于低不确定性类别,应采取“侧重利用”的检索策略。

[0044] 据此,自适应策略调控模块30动态地确定了一组与实施例1不同的策略参数。具体而言,设定探索性查询数量 $N_{explore} = 1$,利用性查询数量 $N_{exploit} = 3$,以及一个倾向于相关性的排序平衡参数 $\lambda = 0.7$ 。此处的参数设置逻辑在于:对于明确的查询,仅需少量甚至无需探索,而应将资源集中于对核心主题的深度挖掘;同时,排序时应优先保证最相关结果的排名,因此 λ 值较大,增大了相关性项 $\text{Sim}_1(d, q)$ 在MMR公式中的权重。

[0045] 在步骤S400中,两阶段搜索模块20开始执行搜索。首先,在步骤S410和S420,系统以“苹果公司的现任CEO是谁”为查询词进行基准搜索,获得一个包含“蒂姆·库克”相关信息的基准结果集。

[0046] 接着,在并行双路径搜索阶段(步骤S430),两阶段搜索模块20根据新的策略参数($N_{explore}=1$, $N_{exploit}=3$)向大型语言模型请求生成查询。对于探索路径(步骤S431),模型被指令生成1个轻度相关的探索性查询,例如“苹果公司历史上的CEO列表”。对于利用路径(步骤S441),模型则被指令生成3个旨在深度挖掘核心事实的利用性查询,例如:“1. 蒂姆·库克的任职时间是从哪年到哪年”;“2. 蒂姆·库克领导下的苹果公司主要业绩”;“3. 蒂姆·库克最近的公开讲话内容”。随后,系统并行执行这4个新查询以及基准查询的检索(步骤S432和S442)。

[0047] 在步骤S500中,所有检索结果被合并去重。

[0048] 在步骤S600中,结果融合与多样性排序模块40应用MMR算法进行排序。此时,平衡参数 λ 被设定为0.7。这个较大的 λ 值使得MMR公式更侧重于最大化候选文档与原始查询的相关性得分 $\text{Sim}_1(d, q)$,而对多样性的惩罚则相对较小。

[0049] 最终,在步骤S700中,系统输出的结果列表将高度聚焦于关于“蒂姆·库克”本人及其作为CEO的相关信息,其个人简介、任期、业绩等最直接相关的文档会排在最顶端。而关于苹果公司其他前任CEO或公司其他方面的信息,则因与原始查询相关性较低而被置于次要位置或被过滤。这一结果快速、精准地满足了用户对特定事实信息的需求,体现了本发明方案的自适应性与高效性。

[0050] 实施例 3

本实施例展示了本发明技术方案的一种变型实现,具体地,是对步骤S400中“并行双路径搜索”的一种混合实现方式。本实施例旨在证明,本发明的核心思想框架具有良好的开放性与兼容性,其“利用路径”的查询生成不局限于必须使用大型语言模型,亦可与信息检索领域的其他成熟技术(如伪相关反馈)相结合,从而在特定场景下可能获得更高的效率或效果。

[0051] 本实施例的系统结构与实施例1基本相同,但在两阶段搜索模块20中,除与大型语言模型接口50交互的能力外,还集成了实现伪相关反馈算法的功能。

[0052] 作为一种可选的实现方式,本发明们再次以前述高不确定性查询“新能源汽车电池技术最新发展”为例,其不确定性评估(步骤S200)和策略确定(步骤S300)过程与实施例1完全相同。即,系统评估出 $U(q) = 0.75$,并确定了“侧重探索”的策略,参数为 $N_{explore} = 3$,

$N_{\text{exploit}} = 1, \lambda = 0.3$ 。

[0053] 本实施例的差异体现在步骤S400的第二阶段,即并行生成增强查询步骤S430。

[0054] 对于探索路径,其实现方式与实施例1保持一致。两阶段搜索模块20仍然调用大型语言模型,根据指令(步骤S431)生成3个语义扩展的探索性查询,如“电动汽车储能系统最新创新”等,并执行检索(步骤S432)。

[0055] 然而,对于利用路径,本实施例采用了不同的技术。两阶段搜索模块20不再调用大型语言模型来生成利用性查询,而是启动传统的伪相关反馈机制来执行步骤S441。具体流程如下:

首先分析在第一阶段基准搜索(步骤S410)中获得的基准结果集。

[0056] 然后,选取该结果集中排名最高的K个文档(例如K=5),并假定这K个文档是高度相关的。

[0057] 接着,系统对这K个文档的全文或摘要进行文本分析,提取其中出现频率高且具有较高区分度的专业术语或关键词。例如,系统可能会提取出“能量密度”、“热失控”、“硅碳负极”、“循环寿命”、“BMS”等术语。

[0058] 最后,将这些提取出的核心术语与用户的原始查询进行组合,自动地构造出一个或多个利用性查询。根据策略参数 $N_{\text{exploit}} = 1$,系统可生成一个组合查询,如:“新能源汽车电池 能量密度 热失控 安全性”。或者,在 $N_{\text{exploit}} > 1$ 的情况下,可生成多个查询,如“新能源汽车电池 能量密度 提升”、“新能源汽车电池 热失控 解决方案”等。

[0059] 在生成了利用性查询后,系统在步骤S442中执行该查询的检索。

[0060] 后续的步骤S500(结果融合)和步骤S600(动态加权排序, $\lambda=0.3$)与实施例1完全相同。最终输出的结果(步骤S700)同样能够实现探索与利用的平衡,为用户提供全面的信息。

[0061] 本实施例证明了本发明所提出框架的灵活性。通过将利用性查询的生成方式替换为伪相关反馈,一方面可以降低对大型语言模型API的调用成本,另一方面,由于伪相关反馈生成的查询术语直接来源于数据索引库60中的高质量文档,这些查询在某些情况下可能与数据源的特征分布更加匹配,从而有望获得相当或更优的利用效果。这表明本发明的保护范围不应局限于仅使用语言模型来生成所有增强查询,而是涵盖了利用不确定性评估结果来指导任何形式的、存在差异化的探索性与利用性查询生成的场景。

[0062] 实施例 4

本实施例在前述实施例的基础上,引入了一个可选的反馈优化机制,展示了本发明的系统如何利用大型语言模型的“反思”和“元认知”能力进行自本发明迭代和优化。该机制旨在通过分析历史检索案例,自动或半自动地调整系统内部的策略参数,从而持续提升检索性能,并降低对人工经验调参的依赖和长期运维成本。

[0063] 作为一种可选的实现方式,本实施例的系统在图1所示的结构基础上,增加了一个离线的“策略优化模块”。该模块不参与实时的在线查询处理,而是定期(例如每天或每周)执行优化任务。其工作过程可描述如下:

数据收集:系统在正常运行期间,记录每次检索会话的关键信息,包括:用户原始查询、系统评估出的不确定性评分 $U(q)$ 、当时采用的策略参数(N_{explore} , N_{exploit} , λ)、最终生成的排序结果,以及用户的交互行为(如点击了哪些链接、在多长时间后发起了新的查询等)。策略优化模块会筛选出其中的低效检索案例。可以理解的是,低效案例的判断标准可

以是多样的,例如:用户在结果页面的点击率极低;用户在查看结果后极短时间内就发起了新的、语义相似的查询(表明初次结果未能满足需求);或者用户在结果页上快速翻页至多页之后才发生点击。

[0064] 反馈与反思:策略优化模块定期将一批收集到的低效检索案例打包。对于每一个案例,它会整理成一段结构化的文本,包含所有在第一步收集到的信息。

[0065] 优化建议生成:策略优化模块将这些打包好的案例,通过大型语言模型接口50提交给大型语言模型,并附上一段精心设计的“系统优化指令”。该指令要求模型扮演一个系统诊断专家的角色,分析检索失败的可能原因,并提出具体的优化建议。一个示例性的优化指令可能如下:

“【系统优化与诊断指令】你是一个信息检索系统的高级优化专家。以下是一些近期效果不佳的检索案例。对于每一个案例,本发明都提供了[原始查询]、[系统评估的不确定性 $U(q)$]、[当时采用的策略参数(N_{explore} , N_{exploit} , λ)]以及[效果不佳的描述,如用户点击率低]。你的任务是:1. 分析导致效果不佳的可能原因。是因为不确定性评估不准?还是查询生成策略不当?或是排序参数不合适?2. 基于你的分析,请提出具体的、可操作的调整建议。建议可以针对以下几点:a) 调整用于区分高/低不确定性的阈值 θ_{high} 和 θ_{low} 。b) 调整不同不确定性等级下(高/中/低)对应的策略参数(N_{explore} , N_{exploit} , λ)的默认值。请以清晰的格式给出你的分析和建议。

[0066] 【案例1】[原始查询]:“AI在药物研发中的最新应用”

[不确定性 $U(q)$]: 0.65 (被判定为中等不确定性)

[策略参数]: $N_{\text{explore}}=2$, $N_{\text{exploit}}=2$, $\lambda=0.5$ - [效果描述]: 用户未点击前10条结果,并在30秒后搜索了“AlphaFold3技术细节”。

策略更新:大型语言模型在接收到上述指令后,可能会进行如下推理:“对于案例1,原始查询包含‘最新应用’,暗示了较强的探索需求。系统评估的 $U(q)=0.65$ 虽然是中等,但可能低估了其探索性。用户后续搜索‘AlphaFold3技术细节’表明其对具体技术进展的深度需求未被满足。原因可能是中等不确定性下的策略过于平衡,未能充分探索前沿技术。建议:对于包含‘最新’、‘进展’、‘趋势’等词语的查询,即使 $U(q)$ 评估为中等,也应考虑将其策略向‘侧重探索’偏移。例如,可将 $U(q)$ 在 $[0.6, 0.7]$ 区间的策略参数调整为 $N_{\text{explore}}=3$, $N_{\text{exploit}}=1$, $\lambda=0.4$ 。”

系统管理员或自动化的策略更新脚本,可参考大型语言模型给出的这些富有洞察力的调整建议,对自适应策略调控模块30中的阈值(θ_{high} , θ_{low})或参数映射规则进行微调。

[0067] 通过引入这种反馈优化机制,本发明的系统具备了自本发明演进和持续学习的能力。它能够从历史经验中学习,不断优化其核心的决策逻辑,使得不确定性评估与后续策略制定的匹配度越来越高。这不仅能逐步提升系统的检索效果和用户满意度,也极大地减少了需要人工介入进行繁琐调参的工作,从而提高了系统的长期稳定性和可维护性。

[0068] 实施例 1

本实施例详细阐述了一种基于语言模型和不确定性评估的多路径信息检索方法及其系统的基础实现方案,特别地,该方案适用于用户输入具有较高不确定性的复杂查询的场景。本实施例旨在完整地展示该方法如何通过评估查询的不确定性,自适应地调整搜索策略以侧重于“探索”,从而为用户提供一个覆盖面广、多样性高的信息结果集。

[0069] 请参阅图1,其示出了本发明实施例提供的一种信息检索系统的优选结构示意图。该系统可部署于云服务器、本地服务器集群或任何具备足够计算能力的计算设备。具体而言,系统主要包括:查询理解与不确定性评估模块10、两阶段搜索模块20、自适应策略调控模块30以及结果融合与多样性排序模块40。需要说明的是,这些模块可实现为软件程序模块、硬件电路或其组合。系统通过大型语言模型接口50与外部预训练的语言模型(例如,一个拥有数百亿或更多参数的大型语言模型)进行通信,并通过数据索引库60访问待检索的信息资源。其中,数据索引库60可以是网页索引、企业内部文档库、学术论文数据库等任何形式的结构化或非结构化数据集。

[0070] 下面将结合图2所示的本发明实施例提供的一种信息检索方法的总体流程图,以及图4所示的各实体间信令交互的时序图,对本实施例的工作过程进行详细说明。

[0071] 该方法首先执行步骤S100,接收用户查询。在本实施例中,假设用户通过用户终端设备(如图1中的用户终端)向系统提交查询请求,其内容为:“新能源汽车电池技术最新发展”。可以理解的是,这是一个典型的具有较高不确定性的查询,因为它涉及一个快速发展的技术领域,内含多个子主题(如不同类型的电池、技术瓶颈、商业应用等),且“最新发展”这一表述本身即具有开放性与模糊性。

[0072] 相应地,在步骤S200中,对查询不确定性进行评估。查询理解与不确定性评估模块10在接收到该查询后,其核心任务在于无监督地输出一个量化的不确定性指标。在本发明的一个具体实现中,该过程通过与大型语言模型交互来完成。如图4所示,系统向大型语言模型(LLM)发起一个评估不确定性请求。具体而言,查询理解与不确定性评估模块10构建一个结构化的指令(亦称为提示词),并通过大型语言模型接口50将其发送给大型语言模型。该指令用以引导模型利用其内部蕴含的庞大世界知识和推理能力,对查询进行深层语义分析。一个示例性的指令可设计如下:

“【角色扮演与任务指令】你现在是一位顶尖的信息检索分析专家。你的任务是评估以下用户查询的‘不确定性’。在评估时,请你从以下三个维度进行综合考量:1. 语义模糊性:查询中是否存在多义词、指代不明或宽泛的概念?2. 领域专业性:查询是否涉及需要深度专业知识才能完全理解的领域?3. 信息需求广度:查询是否暗示了用户希望了解多个方面、不同视角或一个完整的主题图景,而非单一事实?请基于你的综合判断,输出一个介于0.0到1.0之间的小数作为最终的量化不确定性评分。评分越高,代表不确定性越大。需要注意的是,只需要输出评分数值,无需提供任何解释或分析过程。**【待评估的用户查询】:**新能源汽车电池技术最新发展”

大型语言模型在接收到此指令后,会对查询“新能源汽车电池技术最新发展”进行分析。可能识别出“电池技术”是一个宽泛的上位概念,可细分为锂离子电池、固态电池、钠离子电池、氢燃料电池等;而“最新发展”则暗示了对前沿、动态信息的需求,而非一个静态的事实。综合这些因素,模型判断该查询的语义模糊性中等、领域专业性较高、信息需求广度极大。因此,模型通过大型语言模型接口50返回一个较高的不确定性评分,例如,量化不确定性指标 $U(q) = 0.75$ 。需要说明的是,此过程为无监督过程,其不依赖任何预先标注的(查询,不确定性分数)训练样本对,而是直接利用了预训练语言模型自身的能力。

[0073] 在确定了查询不确定性之后,流程进入步骤S300,确定策略参数。自适应策略调控模块30接收由查询理解与不确定性评估模块10传递来的不确定性指标 $U(q) = 0.75$ 。该模

块内部预设了至少一个、通常是两个不确定性阈值,例如高不确定性阈值 θ_{high} (如0.7)和低不确定性阈值 θ_{low} (如0.25)。自适应策略调控模块30将接收到的 $U(q)$ 与这些阈值进行比较。在本例中,由于 $0.75 > \theta_{\text{high}}$ (0.7),系统判定当前查询属于高不确定性类别,因此应采取“侧重探索”的检索策略。

[0074] 基于此判断,自适应策略调控模块30动态地确定一组策略参数。这些策略参数至少包括:1. 查询生成数量配比,即后续需要生成的探索性查询数量 N_{explore} 和利用性查询数量 N_{exploit} 。对于高不确定性查询,系统会分配更多资源给探索路径,例如设定 $N_{\text{explore}} = 3$, $N_{\text{exploit}} = 1$ 。2. 排序平衡参数 λ ,该参数将用于后续的结果融合与排序阶段。对于高不确定性查询,为了鼓励结果的多样性,应设置一个较小的 λ 值,例如 $\lambda = 0.3$ 。这个较小的 λ 值意味着在排序时,系统会更强烈地惩罚与已选结果相似的候选项,从而优先选择能够带来新信息的文档。这些确定的策略参数($N_{\text{explore}}=3$, $N_{\text{exploit}}=1$, $\lambda=0.3$)将被分发给后续的相关模块。

[0075] 继而,在步骤S400中,执行由两阶段搜索模块20负责的两阶段搜索。其详细流程可参考图3。

[0076] 第一阶段为基准搜索,对应于图3中的步骤S410。两阶段搜索模块20首先使用用户输入的原始查询“新能源汽车电池技术最新发展”,直接在数据索引库60中执行一次常规的关键词匹配或向量检索。此举旨在快速获取一个与查询字面意义最相关的基础结果集合,即基准结果集。如图3步骤S420所示,系统获取了该基准结果集,例如包含20篇最相关的技术文档、新闻报道或研究论文。该基准结果集不仅本身是最终结果的一部分,更重要的是,它为第二阶段的增强查询生成提供了宝贵的上下文信息。

[0077] 第二阶段为并行双路径搜索,对应于图3中的并行生成增强查询步骤S430。两阶段搜索模块20利用大型语言模型,基于原始查询和第一阶段获得的基准结果集(或其摘要),并行地生成两组存在差异化的新查询。

[0078] 在探索路径上,根据自适应策略调控模块30设定的 $N_{\text{explore}} = 3$,两阶段搜索模块20向大型语言模型提交一个专门为“探索”任务设计的指令,以执行步骤S431。该指令要求模型基于原始查询和基准结果摘要,通过语义扩展、视角切换或条件放宽等方式,生成3个旨在拓宽搜索边界的查询。例如,指令可能如下:“【探索性查询生成指令】基于用户查询‘新能源汽车电池技术最新发展’和以下初步检索结果摘要,请生成3个相关的、但视角不同或领域更宽泛的查询,以帮助用户探索相关主题。查询应避免与原始查询过于相似。示例摘要:‘…固态电池能量密度突破…热失控安全研究…’”。模型可能会生成如下探索性查询:1. “电动汽车下一代储能系统技术创新”(从“电池”扩展到“储能系统”);2. “氢燃料电池在汽车领域的技术突破与挑战”(切换到替代技术路线);3. “全球动力电池产业链关键材料研究进展”(从技术本身扩展到产业链上游)。随后,在步骤S432中,系统使用这3个新生成的探索性查询,并行地向数据索引库60发起检索,获得三路探索性检索结果。

[0079] 与此同时,在利用路径上,根据设定的 $N_{\text{exploit}} = 1$,两阶段搜索模块20向大型语言模型提交一个为“利用”任务设计的、存在差异化的指令,以执行步骤S441。该指令要求模型通过增加限定、问题分解或精准化等方式,生成1个旨在深化核心主题的查询。例如,指令可能为:“【利用性查询生成指令】基于用户查询‘新能源汽车电池技术最新发展’和初步结果摘要,请生成1个更具体、更深入的查询,聚焦于当前最核心的技术方向。”。模型可能会生成

如下利用性查询：“固态锂电池能量密度与循环寿命的最新提升路径分析”。随后，在步骤S442中，系统使用这个新查询向数据索引库60发起检索，获得一路利用性检索结果。

[0080] 至此，步骤S400完成，系统共获得了1路基准搜索结果、3路探索性搜索结果和1路利用性搜索结果，共计5路检索结果。

[0081] 此后，在步骤S500中，结果融合与多样性排序模块40负责将上述5路检索结果进行合并，并进行去重处理，形成一个庞大的候选结果总集。

[0082] 接着，在关键的步骤S600中，执行动态加权排序。结果融合与多样性排序模块40采用一种动态加权的最大边际相关性算法对候选结果总集进行重排序。该算法的目标是从候选文档集D中迭代地选择文档d，以最大化一个目标函数。该目标函数的数学表达式为：

$$\text{MMR}(D) = \arg \max_{d \in D \setminus S} \left[\lambda \cdot \text{Sim}_1(d, q) - (1 - \lambda) \cdot \max_{d_i \in S} \text{Sim}_2(d, d_i) \right]$$

[0083] 其中，D是候选文档集，S是已经选出的结果集，q是原始用户查询。 $\text{Sim}_1(d, q)$ 计算候选文档d与原始查询q的相关性得分，这可以通过传统的BM25算法或现代的向量余弦相似度计算得出。 $\text{Sim}_2(d, d_i)$ 计算候选文档d与已选结果集S中某个文档 d_i 的相似度得分，同样可以通过向量相似度等方法计算。

[0084] 需要说明的是，在本发明的方案中，平衡参数 λ 并非一个固定的超参数，而是由步骤S300中自适应策略调控模块30根据不确定性评分 $U(q)$ 动态确定的值。在本实施例中， λ 被设定为0.3。这个较小的 λ 值增大了公式中第二项，即多样性惩罚项 $(1 - \lambda) \cdot \max_{d_i \in S} \text{Sim}_2(d, d_i)$ 的权重。也就是说，在排序过程中，如果一个候选文档与已选出的结果非常相似，它将受到较大的惩罚，其最终得分会降低，从而不容易被选中。反之，与已选结果差异较大但与原始查询仍有一定相关性的文档，则有更大机会被排在前面。这种机制有效地促进了结果的多样性。

[0085] 最后，在步骤S700中，输出结果。结果融合与多样性排序模块40将经过动态加权MMR算法重排序后的最终结果序列呈现给用户。由于采取了“侧重探索”的策略和多样性优先的排序方式，最终输出的结果列表不仅包含了关于固态锂电池等核心技术的深度文章（来自利用路径），还广泛覆盖了储能系统创新、氢燃料电池、产业链材料等相关或替代性技术方向的内容（来自探索路径），从而为用户构建了一个更全面、多维度的信息图景，以满足其对一个复杂主题进行探索性了解的需求。

[0086] 实施例 2

本实施例旨在说明本发明提供的技术方案在处理低不确定性、事实型查询时的自适应能力。在此类场景下，用户意图非常明确，系统应自动切换到“侧重利用”的策略，以提供精准、直接的答案，避免不必要的信息发散。

[0087] 本实施例所采用的系统结构与实施例1中图1所示的结构相同，同样包含查询理解与不确定性评估模块10、两阶段搜索模块20、自适应策略调控模块30和结果融合与多样性排序模块40，并与大型语言模型接口50和数据索引库60进行交互。其整体方法流程亦遵循图2所示的步骤。

[0088] 在步骤S100中，系统接收到一个新的用户查询：“苹果公司的现任CEO是谁”。这是一个典型的事实型查询，其不确定性极低。

[0089] 在步骤S200中，查询理解与不确定性评估模块10将此查询打包成与实施例1类似

的指令,发送给大型语言模型进行评估。大型语言模型分析该查询指向一个非常具体、单一的实体属性,语义清晰,无模糊性,信息需求广度极窄。因此,模型会返回一个极低的不确定性评分,例如, $U(q) = 0.1$ 。

[0090] 在步骤S300中,自适应策略调控模块30接收到 $U(q) = 0.1$,并将其与预设的低不确定性阈值 θ_{low} (例如0.25)进行比较。由于 $0.1 < \theta_{low}$ (0.25),系统判定当前查询属于低不确定性类别,应采取“侧重利用”的检索策略。

[0091] 据此,自适应策略调控模块30动态地确定了一组与实施例1不同的策略参数。具体而言,设定探索性查询数量 $N_{explore} = 1$,利用性查询数量 $N_{exploit} = 3$,以及一个倾向于相关性的排序平衡参数 $\lambda = 0.7$ 。此处的参数设置逻辑在于:对于明确的查询,仅需少量甚至无需探索,而应将资源集中于对核心主题的深度挖掘;同时,排序时应优先保证最相关结果的排名,因此 λ 值较大,增大了相关性项 $\text{Sim}_1(d, q)$ 在MMR公式中的权重。

[0092] 在步骤S400中,两阶段搜索模块20开始执行搜索。首先,在步骤S410和S420,系统以“苹果公司的现任CEO是谁”为查询词进行基准搜索,获得一个包含“蒂姆·库克”相关信息的基准结果集。

[0093] 接着,在并行双路径搜索阶段(步骤S430),两阶段搜索模块20根据新的策略参数($N_{explore}=1$, $N_{exploit}=3$)向大型语言模型请求生成查询。对于探索路径(步骤S431),模型被指令生成1个轻度相关的探索性查询,例如“苹果公司历史上的CEO列表”。对于利用路径(步骤S441),模型则被指令生成3个旨在深度挖掘核心事实的利用性查询,例如:“1. 蒂姆·库克的任职时间是从哪年到哪年”;“2. 蒂姆·库克领导下的苹果公司主要业绩”;“3. 蒂姆·库克最近的公开讲话内容”。随后,系统并行执行这4个新查询以及基准查询的检索(步骤S432和S442)。

[0094] 在步骤S500中,所有检索结果被合并去重。

[0095] 在步骤S600中,结果融合与多样性排序模块40应用MMR算法进行排序。此时,平衡参数 λ 被设定为0.7。这个较大的 λ 值使得MMR公式更侧重于最大化候选文档与原始查询的相关性得分 $\text{Sim}_1(d, q)$,而对多样性的惩罚则相对较小。

[0096] 最终,在步骤S700中,系统输出的结果列表将高度聚焦于关于“蒂姆·库克”本人及其作为CEO的相关信息,其个人简历、任期、业绩等最直接相关的文档会排在最顶端。而关于苹果公司其他前任CEO或公司其他方面的信息,则因与原始查询相关性较低而被置于次要位置或被过滤。这一结果快速、精准地满足了用户对特定事实信息的需求,体现了本发明方案的自适应性与高效性。

[0097] 实施例 3

本实施例展示了本发明技术方案的一种变型实现,具体地,是对步骤S400中“并行双路径搜索”的一种混合实现方式。本实施例旨在证明,本发明的核心思想框架具有良好的开放性与兼容性,其“利用路径”的查询生成不局限于必须使用大型语言模型,亦可与信息检索领域的其他成熟技术(如伪相关反馈)相结合,从而在特定场景下可能获得更高的效率或效果。

[0098] 本实施例的系统结构与实施例1基本相同,但在两阶段搜索模块20中,除与大型语言模型接口50交互的能力外,还集成了实现伪相关反馈算法的功能。

[0099] 作为一种可选的实现方式,本发明们再次以前述高不确定性查询“新能源汽车电

池技术最新发展”为例,其不确定性评估(步骤S200)和策略确定(步骤S300)过程与实施例1完全相同。即,系统评估出 $U(q) = 0.75$,并确定了“侧重探索”的策略,参数为 $N_{\text{explore}} = 3$, $N_{\text{exploit}} = 1$, $\lambda = 0.3$ 。

[0100] 本实施例的差异体现在步骤S400的第二阶段,即并行生成增强查询步骤S430。

[0101] 对于探索路径,其实现方式与实施例1保持一致。两阶段搜索模块20仍然调用大型语言模型,根据指令(步骤S431)生成3个语义扩展的探索性查询,如“电动汽车储能系统最新创新”等,并执行检索(步骤S432)。

[0102] 然而,对于利用路径,本实施例采用了不同的技术。两阶段搜索模块20不再调用大型语言模型来生成利用性查询,而是启动传统的伪相关反馈机制来执行步骤S441。具体流程如下:

首先分析在第一阶段基准搜索(步骤S410)中获得的基准结果集。

[0103] 然后,选取该结果集中排名最高的K个文档(例如 $K=5$),并假定这K个文档是高度相关的。

[0104] 接着,系统对这K个文档的全文或摘要进行文本分析,提取其中出现频率高且具有较高区分度的专业术语或关键词。例如,系统可能会提取出“能量密度”、“热失控”、“硅碳负极”、“循环寿命”、“BMS”等术语。

[0105] 最后,将这些提取出的核心术语与用户的原始查询进行组合,自动地构造出一个或多个利用性查询。根据策略参数 $N_{\text{exploit}} = 1$,系统可生成一个组合查询,如:“新能源汽车电池 能量密度 热失控 安全性”。或者,在 $N_{\text{exploit}} > 1$ 的情况下,可生成多个查询,如“新能源汽车电池 能量密度 提升”、“新能源汽车电池 热失控 解决方案”等。

[0106] 在生成了利用性查询后,系统在步骤S442中执行该查询的检索。

[0107] 后续的步骤S500(结果融合)和步骤S600(动态加权排序, $\lambda=0.3$)与实施例1完全相同。最终输出的结果(步骤S700)同样能够实现探索与利用的平衡,为用户提供全面的信息。

[0108] 本实施例证明了本发明所提出框架的灵活性。通过将利用性查询的生成方式替换为伪相关反馈,一方面可以降低对大型语言模型API的调用成本,另一方面,由于伪相关反馈生成的查询术语直接来源于数据索引库60中的高质量文档,这些查询在某些情况下可能与数据源的特征分布更加匹配,从而有望获得相当或更优的利用效果。这表明本发明的保护范围不应局限于仅使用语言模型来生成所有增强查询,而是涵盖了利用不确定性评估结果来指导任何形式的、存在差异化的探索性与利用性查询生成的场景。

[0109] 实施例 4

本实施例在前述实施例的基础上,引入了一个可选的反馈优化机制,展示了本发明的系统如何利用大型语言模型的“反思”和“元认知”能力进行自本发明迭代和优化。该机制旨在通过分析历史检索案例,自动或半自动地调整系统内部的策略参数,从而持续提升检索性能,并降低对人工经验调参的依赖和长期运维成本。

[0110] 作为一种可选的实现方式,本实施例的系统在图1所示的结构基础上,增加了一个离线的“策略优化模块”。该模块不参与实时的在线查询处理,而是定期(例如每天或每周)执行优化任务。其工作过程可描述如下:

数据收集:系统在正常运行期间,记录每次检索会话的关键信息,包括:用户原始查询、系统评估出的不确定性评分 $U(q)$ 、当时采用的策略参数(N_{explore} , N_{exploit} , λ)、最终生

成的排序结果,以及用户的交互行为(如点击了哪些链接、在多长时间后发起了新的查询等)。策略优化模块会筛选出其中的低效检索案例。可以理解的是,低效案例的判断标准可以是多样的,例如:用户在结果页面的点击率极低;用户在查看结果后极短时间内就发起了新的、语义相似的查询(表明初次结果未能满足需求);或者用户在结果页上快速翻页至多页之后才发生点击。

[0111] 反馈与反思:策略优化模块定期将一批收集到的低效检索案例打包。对于每一个案例,它会整理成一段结构化的文本,包含所有在第一步收集到的信息。

[0112] 优化建议生成:策略优化模块将这些打包好的案例,通过大型语言模型接口50提交给大型语言模型,并附上一段精心设计的“系统优化指令”。该指令要求模型扮演一个系统诊断专家的角色,分析检索失败的可能原因,并提出具体的优化建议。一个示例性的优化指令可能如下:

“【系统优化与诊断指令】你是一个信息检索系统的高级优化专家。以下是一些近期效果不佳的检索案例。对于每一个案例,本发明都提供了[原始查询]、[系统评估的不确定性 $U(q)$]、[当时采用的策略参数(N_{explore} , N_{exploit} , λ)]以及[效果不佳的描述,如用户点击率低]。你的任务是:1. 分析导致效果不佳的可能原因。是因为不确定性评估不准?还是查询生成策略不当?或是排序参数不合适?2. 基于你的分析,请提出具体的、可操作的调整建议。建议可以针对以下几点:a) 调整用于区分高/低不确定性的阈值 θ_{high} 和 θ_{low} 。b) 调整不同不确定性等级下(高/中/低)对应的策略参数(N_{explore} , N_{exploit} , λ)的默认值。请以清晰的格式给出你的分析和建议。

[0113] 【案例1】[原始查询]:“AI在药物研发中的最新应用”

[不确定性 $U(q)$]: 0.65 (被判定为中等不确定性)

[策略参数]: $N_{\text{explore}}=2$, $N_{\text{exploit}}=2$, $\lambda=0.5$ - [效果描述]: 用户未点击前10条结果,并在30秒后搜索了“AlphaFold3技术细节”。

策略更新:大型语言模型在接收到上述指令后,可能会进行如下推理:“对于案例1,原始查询包含‘最新应用’,暗示了较强的探索需求。系统评估的 $U(q)=0.65$ 虽然是中等,但可能低估了其探索性。用户后续搜索‘AlphaFold3技术细节’表明其对具体技术进展的深度需求未被满足。原因可能是中等不确定性下的策略过于平衡,未能充分探索前沿技术。建议:对于包含‘最新’、‘进展’、‘趋势’等词语的查询,即使 $U(q)$ 评估为中等,也应考虑将其策略向‘侧重探索’偏移。例如,可将 $U(q)$ 在 $[0.6, 0.7]$ 区间的策略参数调整为 $N_{\text{explore}}=3$, $N_{\text{exploit}}=1$, $\lambda=0.4$ 。”

系统管理员或自动化的策略更新脚本,可参考大型语言模型给出的这些富有洞察力的调整建议,对自适应策略调控模块30中的阈值(θ_{high} , θ_{low})或参数映射规则进行微调。

[0114] 通过引入这种反馈优化机制,本发明的系统具备了自本发明演进和持续学习的能力。它能够从历史经验中学习,不断优化其核心的决策逻辑,使得不确定性评估与后续策略制定的匹配度越来越高。这不仅能逐步提升系统的检索效果和用户满意度,也极大地减少了需要人工介入进行繁琐调参的工作,从而提高了系统的长期稳定性和可维护性。

[0115] 本领域技术人员知道,除了以纯计算机可读程序代码方式实现本发明提供的系统及其各个装置、模块、单元以外,完全可以通过将方法步骤进行逻辑编程来使得本发明提供的系统及其各个装置、模块、单元以逻辑门、开关、专用集成电路、可编程逻辑控制器以及嵌

入式微控制器等的形式来实现相同功能。所以,本发明提供的系统及其各项装置、模块、单元可以被认为是一种硬件部件,而对其内包括的用于实现各种功能的装置、模块、单元也可以视为硬件部件内的结构;也可以将用于实现各种功能的装置、模块、单元视为既可以是实现方法的软件模块又可以是硬件部件内的结构。

[0116] 以上对本发明的具体实施例进行了描述。需要理解的是,本发明并不局限于上述特定实施方式,本领域技术人员可以在权利要求的范围内做出各种变化或修改,这并不影响本发明的实质内容。在不冲突的情况下,本申请的实施例和实施例中的特征可以任意相互组合。




图1




图2




图3




图4