



(12) 发明专利申请

(10) 申请公布号 CN 122388163 A

(43) 申请公布日 2026. 07. 14

(21) 申请号 202610849028.5

(22) 申请日 2026.06.12

(71) 申请人 北京优幕科技有限责任公司

地址 100190 北京市海淀区中关村大街18
号8层05-609

(72) 发明人 崔扬 余洋 李东朔

(74) 专利代理机构 北京力致专利代理事务所
(特殊普通合伙) 11900

专利代理师 李博洋

(51) Int. Cl.

G06F 16/335 (2019.01)

G06F 16/2455 (2019.01)

G06F 16/334 (2025.01)

G06F 16/36 (2019.01)

G06N 5/04 (2023.01)


权利要求书3页 说明书13页 附图1页

(54) 发明名称

一种多维路由决策检索方法及设备

(57) 摘要

本发明涉及数据检索技术领域,公开了一种多维路由决策检索方法及设备,本方法包括获取用户输入的查询文本;基于查询文本生成若干系统指令信息;利用预训练的大语言模型基于若干系统指令信息对查询文本进行单次推理调用,得到多维度结构化路由决策数据;对多维度结构化路由决策数据进行逐字段校验,得到目标结构化路由决策数据;基于目标结构化路由决策数据执行多路径检索,得到目标检索结果。本发明提升了决策和检索结果的准确性。



1. 一种多维路由决策检索方法,其特征在于,所述方法包括:

获取用户输入的查询文本;

基于所述查询文本生成若干系统指令信息;

利用预训练的大语言模型基于所述若干系统指令信息对所述查询文本进行单次推理调用,得到多维度结构化路由决策数据;

对所述多维度结构化路由决策数据进行逐字段校验,得到目标结构化路由决策数据;

基于所述目标结构化路由决策数据执行多路径检索,得到目标检索结果。

2. 根据权利要求1所述的方法,其特征在于,所述系统指令信息包括查询意图类型指令信息、检索范围指令信息、图遍历策略指令信息、检索路径融合权重值指令信息和时间约束指令信息中的至少一个;

所述利用预训练的大语言模型基于所述若干系统指令信息对所述查询文本进行单次推理调用,得到所述多维度结构化路由决策数据,包括:

利用预训练的大语言模型基于所述若干系统指令信息对所述查询文本进行单次推理调用,以在一次推理中联合生成所述多维度结构化路由决策数据,所述多维度结构化路由决策数据包括与所述系统指令信息中各指令对应的查询意图类型、检索范围、图遍历策略、检索路径融合权重值、时间约束信息中的至少一个,所述检索路径包括关键词全文检索路径、向量语义检索路径、知识图谱全文检索路径、表格结构化检索路径和时间序列检索路径。

3. 根据权利要求1所述的方法,其特征在于,若所述大语言模型的输出无法解析为合法的所述多维度结构化路由决策数据,则利用正则表达式模式在原始输出文本提取首个符合所述正则表达模式的多维度结构化路由决策数据片段,并对所述多维度结构化路由决策数据片段进行二次解析;若二次解析后仍然无法得到合法的多维度结构化路由决策,则将预设默认路由决策确定为对应检索路径的所述目标结构化路由决策数据。

4. 根据权利要求2所述的方法,其特征在于,所述对所述多维度结构化路由决策数据进行逐字段校验,得到目标结构化路由决策数据,包括:

对所述多维度结构化路由决策数据中每个字段分别进行单独校验,若任意字段校验不通过,则对应字段进行回退处理;若任意字段校验通过,则保留对应字段,直到将所述多维度结构化路由决策数据中的所有字段校验完成,基于校验通过的字段得到所述目标结构化路由决策数据;其中,所述对所述多维度结构化路由决策数据中每个字段分别进行单独校验,若任意字段校验不通过,将对应字段进行回退处理,包括以下过程中的至少之一:

判断查询意图类型字段是否属于预设意图类型集合,若所述查询意图类型字段不属于所述预设意图类型集合,则将所述查询意图类型字段回退为预设默认意图类型;

判断检索范围字段中每个值是否属于预设范围值集合,若所有值均不属于所述预设范围值集合,则将所述检索范围字段回退为预设默认检索范围;

判断图遍历策略字段是否属于预设图遍历策略集合,若所述图遍历策略字段不属于所述预设图遍历策略集合,则将所述图遍历策略字段回退为预设默认图遍历策略;

判断检索路径融合权重值字段的每个键名是否属于预设检索路径标识集合,若任意键名不属于所述预设检索路径标识集合,则对应键名进行去除;

判断时间约束信息字段是否符合预设时间格式规则,若所述时间约束信息字段不符合

所述预设时间格式规则,则将所述时间约束信息字段进行去除。

5. 根据权利要求4所述的方法,其特征在于,若所述键名属于所述预设检索路径标识集合,则判断所述检索路径融合权重值字段的权重值是否为浮点数;

若所述权重值不是浮点数,则将所述权重值去除;若所述权重值是浮点数,则判断所述权重值是否超出预设权重值域;

若所述权重值超出预设权重值域,则将所述权重值裁剪至所述预设权重值域的最近边界值,得到校验检索路径融合权重值。

6. 根据权利要求5所述的方法,其特征在于,在基于校验通过的字段得到所述目标结构化路由决策数据之后,还包括判断是否对所述目标结构化路由决策数据中的所述校验检索路径融合权重值进行调整,包括:

获取所述用户的历史画像检索路径权重集合和所述查询文本所属的数据集主题集合;

基于所述历史画像检索路径权重集合中的权重值计算所述用户的用户画像置信度;

判断所述用户画像置信度和所述数据集主题集合是否满足预设激活条件,若所述用户画像置信度和所述数据集主题集合满足所述预设激活条件,则对所述校验检索路径融合权重值进行调整,得到目标检索路径融合权重值。

7. 根据权利要求6所述的方法,其特征在于,所述预设激活条件包括:

所述历史画像检索路径权重集合为非空集合;

所述用户画像置信度大于预设置信度阈值;

所述数据集主题集合为非空集合;

以所述数据集主题集合为约束过滤所述历史画像检索路径权重集合后得到的过滤检索路径权重集合为非空集合。

8. 根据权利要求7所述的方法,其特征在于,所述对所述校验检索路径融合权重值进行调整,得到目标检索路径融合权重值,包括:

判断所述校验检索路径融合权重值的键名和所述过滤检索路径权重集合中是否存在相同检索路径;

若所述校验检索路径融合权重值的键名和所述过滤检索路径权重集合中存在相同检索路径,则将所述校验检索路径融合权重值和所述过滤检索路径权重集合中的权重值进行乘性叠加计算,得到所述目标检索路径融合权重值;

若所述校验检索路径融合权重值的键名和所述过滤检索路径权重集合中不存在相同检索路径,则将所述检索路径对应的权重值确定为所述目标检索路径融合权重值。

9. 根据权利要求2所述的方法,其特征在于,所述基于所述目标结构化路由决策数据执行多路径检索,得到目标检索结果,包括:

基于所述目标结构化路由决策数据分别对每个检索路径进行对应的决策检索和排序,得到每个检索路径的若干检索结果及每个检索结果在对应检索路径中的排名;

基于所述每个检索结果在每条检索路径中的排名和所述检索路径融合权重值进行融合得分计算,得到若干检索结果的融合得分;

基于所述融合得分对所述若干检索结果进行降序排序,得到排序结果;

选取所述排序结果中第一预设数量的检索结果,并基于各检索结果在所述每条检索路径中的所述检索路径融合权重值对所述第一预设数量的检索结果进行重排序,得到重排序

结果;

在所述重排序结果中选取第二预设数量的检索结果作为所述目标检索结果,所述第一预设数量大于所述第二预设数量。

10.一种多维路由决策检索设备,其特征在于,包括:处理器以及与所述处理器连接的存储器;其中,所述存储器存储有可被所述处理器执行的指令,所述指令被所述处理器执行,以使所述处理器执行如权利要求1-9中任意一项所述的多维路由决策检索方法。

一种多维路由决策检索方法及设备

技术领域

[0001] 本发明涉及数据检索技术领域,具体而言,涉及一种多维路由决策检索方法及设备。

背景技术

[0002] 多路混合检索为一种通过调用多种检索路径并对结果进行融合排序的技术,从而在应对结构复杂、意图多样的用户查询时,显著提升信息召回覆盖度,为现代智能检索系统提供核心支撑能力。

[0003] 现有的多路混合检索方法主要包括两类:一类采用预设的固定决策规则,对所有查询使用相同的检索路径激活与融合策略,无法适应查询语义的动态变化,导致检索决策与用户真实意图偏差较大;另一类通过多次调用大语言模型分步完成检索决策,决策过程前后割裂,影响最终检索决策输出的可靠性。因此,现有方法存在决策检索精度低、准确性差的问题,难以满足复杂查询场景下的高质量检索需求。

发明内容

[0004] 有鉴于此,本发明提供了一种多维路由决策检索方法及设备,以解决决策检索精度低、准确性差的问题。

[0005] 第一方面,本发明提供了一种多维路由决策检索方法,该方法包括:获取用户输入的查询文本;基于查询文本生成若干系统指令信息;利用预训练的大语言模型基于若干系统指令信息对查询文本进行单次推理调用,得到多维度结构化路由决策数据;对多维度结构化路由决策数据进行逐字段校验,得到目标结构化路由决策数据;基于目标结构化路由决策数据执行多路径检索,得到目标检索结果。

[0006] 在一种可选的实施方式中,系统指令信息包括查询意图类型指令信息、检索范围指令信息、图遍历策略指令信息、检索路径融合权重值指令信息和时间约束指令信息中的至少一个;利用预训练的大语言模型基于若干系统指令信息对查询文本进行单次推理调用,得到多维度结构化路由决策数据,包括:利用预训练的大语言模型基于若干系统指令信息对查询文本进行单次推理调用,以在一次推理中联合生成多维度结构化路由决策数据,多维度结构化路由决策数据包括与系统指令信息中各指令对应的查询意图类型、检索范围、图遍历策略、检索路径融合权重值、时间约束信息中的至少一个,检索路径包括关键词全文检索路径、向量语义检索路径、知识图谱全文检索路径、表格结构化检索路径和时间序列检索路径。

[0007] 在一种可选的实施方式中,若大语言模型的输出无法解析为合法的多维度结构化路由决策数据,则利用正则表达式模式在原始输出文本提取首个符合正则表达模式的多维度结构化路由决策数据片段,并对多维度结构化路由决策数据片段进行二次解析;若二次解析后仍然无法得到合法的多维度结构化路由决策,则将预设默认路由决策确定为对应检索路径的目标结构化路由决策数据。

[0008] 在一种可选的实施方式中,对多维度结构化路由决策数据进行逐字段校验,得到目标结构化路由决策数据,包括:对多维度结构化路由决策数据中每个字段分别进行单独校验,若任意字段校验不通过,则将对对应字段进行回退处理;若任意字段校验通过,则保留对应字段,直到将多维度结构化路由决策数据中的所有字段校验完成,基于校验通过的字段得到目标结构化路由决策数据;其中,对多维度结构化路由决策数据中每个字段分别进行单独校验,若任意字段校验不通过,将对对应字段进行回退处理,包括以下过程中的至少之一:判断查询意图类型字段是否属于预设意图类型集合,若查询意图类型字段不属于预设意图类型集合,则将查询意图类型字段回退为预设默认意图类型;判断检索范围字段中每个值是否属于预设范围值集合,若所有值均不属于预设范围值集合,则将检索范围字段回退为预设默认检索范围;判断图遍历策略字段是否属于预设图遍历策略集合,若图遍历策略字段不属于预设图遍历策略集合,则将图遍历策略字段回退为预设默认图遍历策略;判断检索路径融合权重值字段的每个键名是否属于预设检索路径标识集合,若任意键名不属于预设检索路径标识集合,则将对对应键名进行去除;判断时间约束信息字段是否符合预设时间格式规则,若时间约束信息字段不符合预设时间格式规则,则将时间约束信息字段进行去除。

[0009] 在一种可选的实施方式中,若键名属于预设检索路径标识集合,则判断检索路径融合权重值字段的权重值是否为浮点数;若权重值不是浮点数,则将权重值去除;若权重值是浮点数,则判断权重值是否超出预设权重值域;若权重值超出预设权重值域,则将权重值裁剪至预设权重值域的最近边界值,得到校验检索路径融合权重值。

[0010] 在一种可选的实施方式中,在基于校验通过的字段得到目标结构化路由决策数据之后,还包括判断是否对目标结构化路由决策数据中的校验检索路径融合权重值进行调整,包括:获取用户的历史画像检索路径权重集合和查询文本所属的数据集主题集合;基于历史画像检索路径权重集合中的权重值计算用户的用户画像置信度;判断用户画像置信度和数据集主题集合是否满足预设激活条件,若用户画像置信度和数据集主题集合满足预设激活条件,则对校验检索路径融合权重值进行调整,得到目标检索路径融合权重值。

[0011] 在一种可选的实施方式中,预设激活条件包括:历史画像检索路径权重集合为非空集合;用户画像置信度大于预设置信度阈值;数据集主题集合为非空集合;以数据集主题集合为约束过滤历史画像检索路径权重集合后得到的过滤检索路径权重集合为非空集合。

[0012] 在一种可选的实施方式中,对校验检索路径融合权重值进行调整,得到目标检索路径融合权重值,包括:判断校验检索路径融合权重值的键名和过滤检索路径权重集合中是否存在相同检索路径;若校验检索路径融合权重值的键名和过滤检索路径权重集合中存在相同检索路径,则将校验检索路径融合权重值和过滤检索路径权重集合中的权重值进行乘性叠加计算,得到目标检索路径融合权重值;若校验检索路径融合权重值的键名和过滤检索路径权重集合中不存在相同检索路径,则将检索路径对应的权重值确定为目标检索路径融合权重值。

[0013] 在一种可选的实施方式中,基于目标结构化路由决策数据执行多路径检索,得到目标检索结果,包括:基于目标结构化路由决策数据分别对每个检索路径进行对应的决策检索和排序,得到每个检索路径的若干检索结果及每个检索结果在对应检索路径中的排名;基于每个检索结果在每条检索路径中的排名和检索路径融合权重值进行融合得分计

算,得到若干检索结果的融合得分;基于融合得分对若干检索结果进行降序排序,得到排序结果;选取排序结果中第一预设数量的检索结果,并基于各检索结果在每条检索路径中的检索路径融合权重值对第一预设数量的检索结果进行重排序,得到重排序结果;在重排序结果中选取第二预设数量的检索结果作为目标检索结果,第一预设数量大于第二预设数量。

[0014] 第二方面,本发明提供了一种多维路由决策检索设备,包括:处理器以及与处理器连接的存储器;其中,存储器存储有可被处理器执行的指令,指令被处理器执行,以使处理器执行上述任意一项的多维路由决策检索方法。

[0015] 本发明提供的一种多维路由决策检索方法,首先通过获取用户查询文本并生成若干系统指令信息,为大语言模型提供了完整的决策环境描述,奠定了后续单次推理的基础,避免了多次调用中重复描述系统配置所带来的资源浪费与信息遗漏;接着利用大语言模型进行单次推理调用,在一次前向传播中联合生成多维度结构化路由决策数据,各维度之间相互交叉参考,有效解决了分步多次调用导致的上下文割裂、决策冲突及延迟累积问题,显著提升了路由决策的一致性与实时性;然后对生成的决策数据进行逐字段校验与容错处理,在部分字段异常时仅局部回退而保留合法信息,克服了对模型输出鲁棒性差的缺陷,保证了检索决策的可靠性;最后依据路由决策执行多路径检索,实现了检索策略与路径特性的深度适配,且仅在语义一致的决策指导下按需激活各路径,避免了固定规则下全量激活的计算浪费,从而在提升检索效率的同时确保了结果的准确性。总体而言,本方法通过单次推理、多维联合生成、交叉参考以及容错校验等机制,有效克服了传统多路混合检索中决策割裂、精度低、适应性差的问题,能够以低延迟、高一致性、高鲁棒性的方式完成复杂查询场景下的动态检索路由决策,提升检索结果的准确性。

附图说明

[0016] 为了更清楚地说明本发明具体实施方式或现有技术中的技术方案,下面将对具体实施方式或现有技术描述中所需要使用的附图作简单地介绍,显而易见地,下面描述中的附图是本发明的一些实施方式,对于本领域普通技术人员来讲,在不付出创造性劳动的前提下,还可以根据这些附图获得其他的附图。

[0017] 图1是根据本发明实施例的一种多维路由决策检索方法的流程示意图;
图2是根据本发明实施例的另一种多维路由决策检索方法的流程示意图。

具体实施方式

[0018] 为使本发明实施例的目的、技术方案和优点更加清楚,下面将结合本发明实施例中的附图,对本发明实施例中的技术方案进行清楚、完整地描述,显然,所描述的实施例是本发明一部分实施例,而不是全部的实施例。基于本发明中的实施例,本领域技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于本发明保护的范围。

[0019] 根据本发明实施例,提供了一种多维路由决策检索方法实施例,需要说明的是,在附图的流程图示出的步骤可以在诸如一组计算机可执行指令的计算机系统中执行,并且,虽然在流程图中示出了逻辑顺序,但是在某些情况下,可以以不同于此处的顺序执行所示出或描述的步骤。

[0020] 在本实施例中提供了一种多维路由决策检索方法,可用于上述的移动终端,如手机、平板电脑等,图1是根据本发明实施例的多维路由决策检索方法的流程图,如图1所示,该流程包括如下步骤:

步骤S101,获取用户输入的查询文本。

[0021] 本实施例中获取的查询文本是指用户通过输入界面(如搜索框、语音转文字接口或API调用)提交的自然语言字符串,其长度不限,可以是一个词语、一句话或一段描述。该文本的获取时机可以是实时在线检索场景,也可以是离线批处理场景。本步骤不限定查询文本的来源语言、领域或长度,仅作为后续路由决策的输入基础。例如,“某产品的价格是多少”、“2024年第一季度的销售额变化趋势”。

[0022] 步骤S102,基于查询文本生成若干系统指令信息。

[0023] 在本实施例中,系统指令信息是为大语言模型提供的路由决策引导信息,用于向模型说明当前多路检索系统中各检索路径的基本特性、模型输出所需遵守的格式与取值范围,以及不同决策维度之间的依赖关系。

[0024] 步骤S103,利用预训练的大语言模型基于若干系统指令信息对查询文本进行单次推理调用,得到多维度结构化路由决策数据。

[0025] 本实施例的大语言模型作为核心推理引擎,经过大规模文本语料的预训练,具备了理解复杂语义与生成结构化输出的能力。大语言模型用于根据若干系统指令信息和用户查询文本,一次性生成多维度决策信息。大语言模型单次推理调用是指仅执行一次模型前向传播,从而避免了多次串行调用带来的延迟累积与资源浪费。而且,大语言模型在一次推理中同时完成多个不同路由决策维度的联合生成,各维度在同一推理上下文中相互交叉参考,例如大语言模型在推理某个维度时,能够动态利用其他维度的中间推理结果进行协同调整。这种联合生成与交叉参考机制,有效解决了分步多次调用中常见的上下文割裂、决策冲突以及信息利用不充分等问题,确保最终输出的多维决策在语义上保持内在一致,从而显著提升了路由决策的整体准确性与可靠性。

[0026] 步骤S104,对多维度结构化路由决策数据进行逐字段校验,得到目标结构化路由决策数据。

[0027] 本实施例对大语言模型生成的多维度结构化路由决策数据进行校验与容错处理。例如,首先对各字段分别进行独立检查,若某字段不符合预设规范,则仅对该字段执行回退处理,合格的字段即可保留。该容错机制确保了大语言模型在不同异常形态下(例如格式错误、局部字段非法等)均能以最小代价恢复有效决策,最大限度保留大语言模型已成功生成的信息,同时保证检索路由决策的鲁棒性。

[0028] 步骤S105,基于目标结构化路由决策数据执行多路径检索,得到目标检索结果。

[0029] 本实施例中,经过校验后的多维度结构化路由决策数据作为可靠的检索指令,被用于驱动底层多种数据源的实际查询操作。由于这些数据已在先前步骤中完成了逐字段校验与容错处理,从而显著降低了因模型输出异常导致的检索失效风险。多路检索不是盲目的全量调用,而是基于经过验证的决策指令进行按需、高效、可靠的信息获取,最终在保证结果质量的前提下提升了检索的整体响应速度与稳定性。

[0030] 本实施例提供的一种多维路由决策检索方法,首先通过获取用户查询文本并生成若干系统指令信息,为大语言模型提供了完整的决策环境描述,奠定了后续单次推理的基

础,避免了多次调用中重复描述系统配置所带来的资源浪费与信息遗漏;接着利用大语言模型进行单次推理调用,在一次前向传播中联合生成多维度结构化路由决策数据,各维度之间相互交叉参考,有效解决了分步多次调用导致的上下文割裂、决策冲突及延迟累积问题,显著提升了路由决策的一致性与实时性;然后对生成的决策数据进行逐字段校验与容错处理,在部分字段异常时仅局部回退而保留合法信息,克服了对模型输出鲁棒性差的缺陷,保证了检索决策的可靠性;最后依据路由决策执行多路径检索,实现了检索策略与路径特性的深度适配,且仅在语义一致的决策指导下按需激活各路径,避免了固定规则下全量激活的计算浪费,从而在提升检索效率的同时确保了结果的准确性。总体而言,本方法通过单次推理、多维联合生成、交叉参考以及容错校验等机制,有效克服了传统多路混合检索中决策割裂、精度低、适应性差的问题,能够以低延迟、高一致性、高鲁棒性的方式完成复杂查询场景下的动态检索路由决策,提升检索结果的准确性。

[0031] 在一些可选的实施方式中,上述步骤S102中的系统指令信息包括查询意图类型指令信息、检索范围指令信息、图遍历策略指令信息、检索路径融合权重值指令信息和时间约束指令信息中的至少一个。

[0032] 在本实施例中,查询意图类型指令信息用于指示大语言模型输出查询文本的语义意图分类;检索范围指令信息用于指示大语言模型输出应检索的信息源类型(例如外部知识库、用户个人记忆或无需检索);图遍历策略指令信息用于指示知识图谱检索路径所采用的遍历算法类型及其适用场景;检索路径融合权重值指令信息用于说明各检索路径权重的取值域(如 $[0, w_{\max}]$)及物理含义(权重越高对最终排序贡献越大,权重为零的路径将被跳过);时间约束指令信息用于指示当查询文本包含时间表达时,输出结构化的时间范围或排序要求。

[0033] 进一步地,步骤S103中利用预训练的大语言模型基于若干系统指令信息对查询文本进行单次推理调用,得到多维度结构化路由决策数据的过程,具体包括:

利用预训练的大语言模型基于若干系统指令信息对查询文本进行单次推理调用,以在一次推理中联合生成多维度结构化路由决策数据,多维度结构化路由决策数据包括与系统指令信息中各指令对应的查询意图类型、检索范围、图遍历策略、检索路径融合权重值、时间约束信息中的至少一个,检索路径包括关键词全文检索路径、向量语义检索路径、知识图谱遍历路径、表格结构化检索路径和时间序列检索路径。

[0034] 本实施例大语言模型仅执行一次前向传播,同时输出多个维度的决策结果,避免了分步多次调用导致的延迟累积与上下文割裂。得到的多维度结构化路由决策数据包括包含以下维度的部分或全部:查询意图类型,用于表示查询文本的语义分类(例如事实型、分析型、多跳推理型、时间型等);检索范围,用于确定应检索的信息源类型(例如外部知识库、用户个人记忆或无需检索);图遍历策略,用于指定知识图谱检索路径所采用的遍历算法类型;各检索路径的融合权重值,是一个为每条检索路径分别赋值的连续浮点数集合,权重值域为 $[0, w_{\max}]$,其中权重大于零的路径将在后续检索中被激活,权重为零的路径被跳过以节省资源;时间约束信息,当查询文本包含时间表达时,提取为结构化的时间范围或排序要求,否则为空。各维度在同一次推理过程中相互交叉参考,例如意图分类结果直接影响融合权重的分配,时间约束的识别则提升时间序列路径的权重,从而确保多维决策在语义上协调一致。

[0035] 例如,用户的查询文本为“产品X的价格是多少”,大语言模型在一次推理中联合生成的路由决策仅包含查询意图类型(事实型)、检索范围(外部知识库)和融合权重值(例如{关键词全文检索路径:0.5,知识图谱全文检索路径:0.2,向量语义检索路径:0.2,表格结构化检索路径:0.1,时间序列检索路径:0.0}),而不包含图遍历策略和时间约束信息,因为该查询不涉及知识图谱多跳推理或时间范围过滤。这种灵活的字段生成机制,结合单次推理中多维联合与交叉参考,使得模型能够根据查询内容自适应地输出最相关的决策信息,既避免了不必要的计算开销,又保证了路由指令的精准性。

[0036] 本实施例通过单次推理联合生成多维度路由决策,避免了分步多次调用的延迟与上下文割裂;各维度之间交叉参考,确保了意图、范围、策略、权重和时间约束等决策在语义上协调一致;同时,根据查询内容灵活选择多维度路由决策,避免了不必要的计算开销,提升了推理效率与路由指令的精准性。

[0037] 在一些可选的实施方式中,步骤S103在利用预训练的大语言模型基于系统指令信息对查询文本进行单次推理调用时,若大语言模型的输出无法解析为合法的多维度结构化路由决策数据,则利用正则表达式模式在原始输出文本提取首个符合正则表达模式的多维度结构化路由决策数据片段,并对多维度结构化路由决策数据片段进行二次解析;若二次解析后仍然无法得到合法的多维度结构化路由决策,则将预设默认路由决策确定为对应检索路径的目标结构化路由决策数据。

[0038] 本实施例中,大语言模型输出无法解析为合法结构化数据的原因可能包括:模型调用服务不可用、返回空响应、输出文本完全非结构化、JSON格式错误、字段命名不符合预期、数值越界或枚举值非法等。针对这些异常形态,本发明设计了层级化的默认路由决策机制,共包含三个层级:

层级一为基础默认决策,用于大语言模型调用整体失败或服务不可用时的兜底回退。该路由决策包含:查询意图类型默认设为“关键词检索型”,检索范围默认设为“仅外部知识库”,图遍历策略默认设为“暴力枚举”,不依赖路径相关性优化,各检索路径融合权重默认为空集合,时间约束信息默认为空,不施加时间过滤;并附加决策来源标记“rule_fallback”以用于事后审计与观测。

[0039] 层级二为系统配置默认权重,当层级一返回的各检索路径融合权重集合为空时启用。本实施例中,为五条检索路径预设了默认权重:关键词全文检索路径:0.35、表格结构化检索路径:0.35、知识图谱遍历路径:0.15、向量语义检索路径:0.15、时间序列检索路径:0.0(即不激活)。这些默认值可根据实际业务场景调整。

[0040] 层级三为字段级局部降级规则,当大语言模型输出的原始文本无法解析为合法的结构化数据(即整体JSON格式错误)时,首先使用正则表达式模式{...}从输出文本中提取首个符合该模式的结构化数据片段,并对该片段进行二次解析。例如,若大语言模型输出为“根据分析,推荐配置:{“intent”:“factual”,“weights”:{“es”:0.5}}”,正则提取将获得结构化数据片段为{“intent”:“factual”,“weights”:{“es”:0.5}},并尝试二次解析。若二次解析成功,则得到合法的结构化数据,继续后续字段校验;若二次解析仍然失败(如提取不到任何{...}片段或提取片段仍不合法),则回退至层级一的基础默认决策,并由层级二提供系统配置的默认权重。该规则确保在整体格式异常时能够尽力恢复有效信息,仅在无法恢复时才进行全局兜底,避免因微小格式问题导致整个路由决策失效。

[0041] 在一些可选的实施方式中,步骤S104中对多维度结构化路由决策数据进行逐字段校验,得到目标结构化路由决策数据的过程,包括:

步骤S1041,对多维度结构化路由决策数据中每个字段分别进行单独校验,判断多维度结构化路由决策数据中每个字段是否校验通过,若任意字段校验不通过,则执行步骤S1042;若任意字段校验通过,则执行步骤S1043。

[0042] 步骤S1042,将对应字段进行回退处理。

[0043] 步骤S1043,保留对应字段。

[0044] 步骤S1044,直到将多维度结构化路由决策数据中的所有字段校验完成,基于校验通过的字段得到目标结构化路由决策数据。

[0045] 本实施例首先对每个字段进行独立检查,若字段合法则进入步骤S1043予以保留,若字段非法则进入步骤S1042对该字段执行局部回退(例如替换为默认值或直接丢弃)。步骤S1044在所有字段处理完毕后,基于校验通过的字段(包括回退后合格的字段)组装成最终的目标结构化路由决策数据。该流程实现了单字段异常不波及整体的精细容错,最大限度保留大语言模型已成功生成的合法信息,避免因个别字段错误而丢弃全部决策,从而提升了路由决策的鲁棒性和可用性。

[0046] 其中,步骤S1042中对多维度结构化路由决策数据中每个字段分别进行单独校验,若任意字段校验不通过,将对应字段进行回退处理的过程,包括以下过程中的至少之一:

步骤S1042a1,判断查询意图类型字段是否属于预设意图类型集合,若查询意图类型字段不属于预设意图类型集合,则执行步骤S1042a2。

[0047] 步骤S1042a2,将查询意图类型字段回退为预设默认意图类型。

[0048] 在本实施例中,预设意图类型集合包括事实型、分析型、多跳推理型、时间型等。若大语言模型输出了集合外的意图(例如“闲聊型”),步骤S1042a2会将其回退为默认的“关键词检索型”。该回退仅影响意图字段,保留其他合法字段(例如检索范围、权重等),避免因意图图分类错误导致整个路由决策被丢弃。

[0049] 步骤S1042b1,判断检索范围字段中每个值是否属于预设范围值集合,若所有值均不属于预设范围值集合,则执行步骤S1042b2。

[0050] 步骤S1042b2,将检索范围字段回退为预设默认检索范围。

[0051] 在本实施例中,预设范围值集合包括外部知识库、用户个人记忆、无需检索。若大语言模型输出的所有范围值均不在该集合内,步骤S1042b2会将其回退为默认的“外部知识库”。若部分值合法,则保留合法值、丢弃非法值,实现最小代价修正。

[0052] 步骤S1042c1,判断图遍历策略字段是否属于预设图遍历策略集合,若图遍历策略字段不属于预设图遍历策略集合,则执行步骤S1042c2。

[0053] 步骤S1042c2,将图遍历策略字段回退为预设默认图遍历策略。

[0054] 在本实施例中,预设图遍历策略集合包括{sa、ppr、sa_ppr、default}。若大语言模型输出了不支持的策略,步骤S1042c2会将其回退为“default”策略。该字段仅对知识图谱路径有效,回退不影响其他路径的决策。

[0055] 步骤S1042d1,判断检索路径融合权重值字段的每个键名是否属于预设检索路径标识集合,若任意键名不属于预设检索路径标识集合,则执行步骤S1042d2。

[0056] 步骤S1042d2,将对应键名进行去除。

[0057] 在本实施例中,预设检索路径标识集合包括{es、graph、chunks、table、temporal}(对应关键词、知识图谱、向量语义、表格、时间序列路径)。对于不存在的键名(如拼写错误“vec”),直接丢弃该键值对,保留其他合法键名。对于合法键名对应的权重数值,需进一步校验数值合法性。

[0058] 步骤S1042e1,判断时间约束信息字段是否符合预设时间格式规则,若时间约束信息字段不符合预设时间格式规则,则执行步骤S1042e2。

[0059] 步骤S1042e2,将时间约束信息字段进行去除。

[0060] 在本实施例中,预设时间格式规则采用ISO 8601标准(例如“2024-01-01”)。若大语言模型输出非结构化时间表达(例如“很久以前”),无法提取出明确的结构化时间范围或排序要求,则直接丢弃该字段,视为无时间约束。避免后续检索因格式错误或语义模糊而出现过滤异常。需要说明的是,上述校验步骤仅在大语言模型实际生成了对应字段时才执行;若模型未输出某字段,则直接跳过相应校验,无需任何回退处理。

[0061] 通过上述步骤S1042a1至S1042e2的逐字段处理,本实施例实现了字段级局部降级规则,每个字段的非法判定仅触发该字段自身的回退或丢弃,不影响其他合法字段。该机制最大程度地保留了大语言模型已成功生成的有效信息,同时确保了所有字段经过校验后均处于合法、可用状态,为后续多路径检索提供了可靠的路由决策。

[0062] 在一些可选的实施方式中,在步骤S1042d1判断检索路径融合权重值字段的每个键名是否属于预设检索路径标识集合时,若键名属于预设检索路径标识集合,则执行步骤S1042d3。

[0063] 步骤S1042d3,判断检索路径融合权重值字段的权重值是否为浮点数,若权重值不是浮点数,则执行步骤S1042d4;若权重值是浮点数,则执行步骤S1042d5。

[0064] 步骤S1042d4,将权重值去除。

[0065] 步骤S1042d5,判断权重值是否超出预设权重值域,若权重值超出预设权重值域,则执行步骤S1042d6。

[0066] 步骤S1042d6,将权重值裁剪至预设权重值域的最近边界值,得到校验检索路径融合权重值。

[0067] 在本实施例中,针对检索路径融合权重值的校验采用了两阶段处理:首先校验键名合法性(步骤S1042d1),对于属于预设检索路径标识集合的合法键名,进一步校验其对应的权重数值。步骤S1042d3判断该权重值是否为浮点数,若无法转换为浮点数(例如大语言模型输出字符串“高”或布尔值true),则执行步骤S1042d4将该键值对整体丢弃,避免非数值数据干扰后续融合计算。若权重值是合法浮点数,则进入步骤S1042d5判断该数值是否超出预设权重值域 $[0, w_{\text{MAX}}]$ 。例如 $w_{\text{MAX}}=3.0$, $[0, 3.0]$ 表示权重为零的检索路径将不被激活,从而跳过后续检索过程,实现按需计算资源分配;3.0采用非对称值域设计,远大于常规归一化权重的上限(通常为1.0),其目的在于为时间敏感型等特定路径在被大语言模型识别为主导路径时,保留充足的头部空间。

[0068] 对于未超出值域的权重值,直接保留;对于超出值域的数值,执行步骤S1042d6将其裁剪至最近的边界值(小于0的置为0,大于3.0的置为3.0),最终得到校验后的合法检索路径融合权重值。该流程确保了每条路径的权重既符合数据类型要求,又落在系统可接受的物理范围内,为后续的加权融合计算提供了可靠输入,同时避免了因权重值异常导致检

索阶段出现不可预期的行为。

[0069] 在一些可选的实施方式中,在步骤S1044基于校验通过的字段得到目标结构化路由决策数据之后,还包括:

步骤S1045,判断是否对目标结构化路由决策数据中的校验检索路径融合权重值进行调整,具体包括:

步骤S10451,获取用户的历史画像检索路径权重集合和查询文本所属的数据集主题集合。

[0070] 本实施例获取的历史画像检索路径权重集合记录了用户在不同检索路径上的长期关注偏好(例如{知识图谱遍历路径:0.8,时间序列检索路径:0.3}),而数据集主题集合是对当前检索目标数据源预标注的主题标签(例如{科技,专利})。这两个集合分别来源于用户行为分析模块和主题路由模块。本实施例为后续个性化调整提供了基础数据,其效果在于将用户行为模式与当前检索上下文关联起来。

[0071] 步骤S10452,基于历史画像检索路径权重集合中的权重值计算用户的用户画像置信度。

[0072] 在本实施例中,用户画像置信度是根据用户交互频次、行为一致性和画像更新时间等因素计算出的0-1之间的分数,例如活跃用户经1000次交互后置信度为0.85,而新用户仅有5次交互时置信度为0.2。该置信度用于衡量画像的可靠性,避免低质量画像污染检索决策。

[0073] 步骤S10453,判断用户画像置信度和数据集主题集合是否满足预设激活条件,若用户画像置信度和数据集主题集合满足预设激活条件,则执行步骤S10454。

[0074] 步骤S10454,对校验检索路径融合权重值进行调整,得到目标检索路径融合权重值。

[0075] 本实施例通过条件激活机制确保了仅当用户画像可靠且与当前检索主题相关时才启用个性化调整,避免了低质量画像或跨数据集偏好的污染,同时通过对权重进行调整,从而提升了检索个性化水平。

[0076] 本实施例首先通过置信度阈值过滤掉不可靠画像,接着通过数据集主题过滤确保仅相关偏好被使用,然后通过对校验后权重进行再次调整。在不牺牲基础检索精度的前提下,实现个性化且鲁棒的权重调整。

[0077] 具体地,步骤S10453中的预设激活条件包括:

条件一:历史画像检索路径权重集合为非空集合。

[0078] 在本实施例中,条件一要求用户的历史画像中至少存在一条检索路径的注意力权重记录。例如,需检测到用户画像中包含{知识图谱遍历路径:0.8}或{关键词全文检索路径:0.6,向量语义检索路径:0.4}等非空数据,而非{}或null。其效果在于:如果用户从未产生任何历史行为(例如新注册用户或从未使用过检索功能),则画像为空,此时无需也无法进行个性化调整,从而避免无效计算。

[0079] 条件二:用户画像置信度大于预设置信度阈值。

[0080] 在本实施例中,置信度是根据用户交互次数、行为一致性、画像更新时间等因素计算出的0-1之间的分数。以预设置信度阈值=0.5为例,如果活跃用户有1000次稳定行为记录,置信度为0.85,满足大于0.5的条件,则需要对其权重进行调整;而新用户仅有5次行为,

置信度为0.2,则低于阈值。由于用户画像会不可靠(例如新用户冷启动期、画像数据陈旧、跨场景使用),因此,需要在画像足够可靠时才启用调整,在置信度低于阈值时主动放弃画像调整,避免因冷启动、行为稀疏或数据陈旧导致的低质量画像污染检索决策。

[0081] 条件三:数据集主题集合为非空集合。

[0082] 在本实施例中,要求当前查询识别出至少一个明确的数据集主题标签。例如,查询“人工智能最新进展”被判定为属于{科技, AI},主题集合非空;而查询“你好”可能无法映射到任何预定义主题,导致主题集合为空。本条件确保检索上下文具有明确的领域范围,若无主题信息,则无法判断画像注意力是否与当前场景相关,此时不宜进行个性化调整,防止跨域混淆。

[0083] 条件四:以数据集主题集合为约束过滤历史画像检索路径权重集合后得到的过滤检索路径权重集合为非空集合。

[0084] 示例性地,利用如下方式数据集主题集合过滤:

$$W_{attention_filtered} = \{(k, v) | (k, v) \in W_{attention}, k \in DatasetTopics\},$$

其中, $W_{attention_filtered}$ 表示经过数据集主题过滤后得到的过滤检索路径权重集合, k 表示用户画像注意力权重集合中的键名,可以表示业务语义维度(例如产品规格、客户案例等),也可以表示映射后的检索路径标识; v 表示键名 k 对应的注意力权重值,通常是一个介于0和1之间的浮点数,代表用户对该维度的偏好强度(值越大偏好越强); $W_{attention}$ 表示历史画像检索路径权重集合, $DatasetTopics$ 表示当前查询文本所属的数据集主题集合,包含对数据集预标注的一个或多个主题标签(例如{科技, 专利})。

[0085] 本条件仅保留用户画像中键名同时属于当前数据集主题集合的项。例如,用户在不同数据集(例如不同课程或不同主题域)中可能形成不同的注意力偏好:在数据集A(主题为“医疗”)中画像为{知识图谱遍历路径:0.8},而在数据集B(主题为“金融”)中画像可能为空或完全不同。若不加过滤,直接将用户在数据集A中的偏好应用到主题不重叠的数据集B,会导致知识图谱路径权重被错误提升,造成跨数据集的注意力污染。本实施例通过条件四要求过滤后的集合非空,即确保当前数据集主题下确实存在用户相关的注意力项。若过滤后为空(例如用户从未在当前主题领域活动),则条件不满足,不进行权重调整。该条件通过主题交集过滤,仅保留与当前数据上下文一致的注意力项,从而防止用户在其他领域形成的偏好错误地影响本次检索,实现个性化调整的场景化精准隔离。

[0086] 本实施例通过上述四个条件的层层筛选,确保仅当用户存在历史画像、画像可靠、当前检索有明确主题、且画像中存在与主题相关的注意力项时,才激活权重调整。这实现了个性化与场景化的精准隔离,既提升了检索结果与用户长期偏好的契合度,又避免了低质量或跨场景画像的负面影响。

[0087] 在一些可选的实施方式中,步骤S10454中对校验检索路径融合权重值进行调整,得到目标检索路径融合权重值的过程,具体包括:

步骤S104541,判断校验检索路径融合权重值的键名和过滤检索路径权重集合中是否存在相同检索路径;若校验检索路径融合权重值的键名和过滤检索路径权重集合中存在相同检索路径,则执行步骤S104542;若校验检索路径融合权重值的键名和过滤检索路径权重集合中不存在相同检索路径,则执行步骤S104543。

[0088] 本实施例中,遍历所有检索路径融合权重值的键名,区分同时存在、仅画像中存在、仅校验后存在三种情况。例如,校验后权重有{关键词全文检索路径,知识图谱全文检索路径,向量语义检索路径},过滤后画像有{关键词全文检索路径,知识图谱全文检索路径},则关键词全文检索路径和知识图谱全文检索路径作为相同路径。

[0089] 步骤S104542,将校验检索路径融合权重值和过滤检索路径权重集合中的权重值进行乘性叠加计算,得到目标检索路径融合权重值。

[0090] 本实施例中,对于同时存在的检索路径,使用如下公式进行乘性叠加计算:

$$W_{final}[k] = W_{clipped}[k] \times (1 + \alpha \times W_{filtered}[k]),$$

其中, $W_{final}[k]$ 表示同时存在的检索路径的目标检索路径融合权重值, $W_{clipped}[k]$ 表示校验检索路径融合权重值(步骤S1042d6校验后的结果), α 为预设调节系数,控制用户画像对权重的影响强度,本实施例取0.5, $W_{filtered}[k]$ 表示经过数据集主题集合过滤后得到的用户画像注意力权重值(仅在键名同时存在于用户画像和当前数据集主题集合中时保留)。

[0091] 例如,关键词全文检索路径: $0.4 \times (1 + 0.5 \times 0.6) = 0.52$,知识图谱全文检索路径: $0.3 \times (1 + 0.5 \times 0.4) = 0.36$ 。该乘性叠加的效果是以温和因子增强用户偏好的路径,增强幅度受 α 和画像权重双重控制,不会无限放大,且不降低其他路径的权重。

[0092] 步骤S104543,将检索路径对应的权重值确定为目标检索路径融合权重值。

[0093] 本实施例对于校验检索路径融合权重值的键名和过滤检索路径权重集合中不存在相同检索路径时,直接以各检索路径的权重作为目标权重,本实施例是补全模型可能遗漏但对用户重要的路径,同时避免无关路径被错误引入。

[0094] 本实施例通过乘性叠加与补全机制,实现了对校验后权重的安全个性化增强,大语言模型已输出的路径被温和提升,遗漏的重要路径被补充,无关路径保持不变。整个调整过程受条件激活机制严格约束,仅在可靠且主题相关时生效,从而在提升检索结果个性化程度的同时,确保了基础检索的稳定性和安全性。

[0095] 例如,用户A为销售人员,历史画像置信度为0.85,注意力权重为{产品规格:0.8,客户案例:0.6}。用户A查询“产品X在制造业的应用案例”,识别当前数据集主题集合为{产品规格,客户案例,销售流程}。

[0096] 首先,大语言模型单次推理输出各检索路径的原始权重: $W_{llm} = \{es:0.3, chunks:0.3, graph:0.2, table:0.2, temporal:0.0\}$ 。

[0097] 其中,es表示关键词全文检索路径,chunks表示向量语义检索路径,graph表示知识图谱遍历路径,table表示表格结构化检索路径,temporal表示时间序列检索路径。

[0098] 接着,对原始权重进行值域校验与非法键过滤后的校验检索路径融合权重值: $W_{clipped} = \{es:0.3, chunks:0.3, graph:0.2, table:0.2, temporal:0.0\}$

然后,进行预设条件激活判定:置信度0.85>0.5,符合;注意力权重非空,符合;数据集主题非空,符合;经数据集主题过滤:保留键名在主题集合中的项,得到{产品规格:0.8,客户案例:0.6} (“销售流程”不在画像中,未引入;若画像中有“竞争对手分析”则会被过滤)。

[0099] 由于画像键名(业务语义)与路径键名(技术标识)不同,本实施例采用映射:产品

规格映射graph (知识图谱遍历路径), 客户案例映射chunks (向量语义检索路径), 得到 {graph:0.8, chunks:0.6}。

[0100] 最后进行个乘性叠加($\alpha=0.5$): $W_{\text{final}}[\text{graph}] = 0.2 \times (1 + 0.8 \times 0.5) = 0.28$, $W_{\text{final}}[\text{chunks}] = 0.3 \times (1 + 0.6 \times 0.5) = 0.39$;

其他路径保持不变: es:0.3, table:0.2, temporal:0.0。

[0101] 最终 $W_{\text{final}} = \{\text{es}:0.3, \text{chunks}:0.39, \text{graph}:0.28, \text{table}:0.2, \text{temporal}:0.0\}$ 。

[0102] 对比用户B: 用户B画像置信度为0.2 (低于阈值), 相同查询跳过调整, 最终权重等于 W_{clipped} 。

[0103] 本实施例体现不同用户对相同查询可产生差异化的权重分配; 低置信度画像会自动跳过调整以避免污染检索决策; 通过数据集主题过滤机制有效防止跨数据集的注意力扩散; 同时支持业务语义到技术路径的映射, 使得个性化调整更贴合实际应用场景。

[0104] 如图2所示, 步骤S105中基于目标结构化路由决策数据执行多路径检索, 得到目标检索结果的过程, 具体包括:

步骤S1051, 基于目标结构化路由决策数据分别对每个检索路径进行对应的决策检索和排序, 得到每个检索路径的若干检索结果及每个检索结果在对应检索路径中的排名。

[0105] 在本实施例中, 各检索路径 (例如关键词全文检索路径、向量语义检索路径、知识图谱遍历路径等) 依据步骤S104校验后得到的目标路由决策数据 (包括检索范围、融合权重、时间约束等) 独立执行检索, 并各自按内部相关度算法对返回的候选文档进行降序排序。例如, 关键词全文检索路径采用BM25词频-逆文档频率得分对每个候选文档进行排序, 向量语义检索路径采用嵌入向量余弦相似度得分对每个候选文档进行排序, 知识图谱全文检索路径采用可达性得分 (例如语义引导遍历、个性化随机游走、暴力枚举各自的算法得分) 对每个候选文档进行排序, 表格结构化检索路径采用词法匹配与向量相似度的混合得分对每个候选文档进行排序, 时间序列检索路径采用时间相关度与时间距离的加权得分对每个候选文档进行排序。每个路径输出一个有序列表, 其中位置序号从0开始计数 (即第1名 rank=0, 第2名 rank=1, 依此类推)。本实施例通过各路径基于自身特性生成高质量的排序列表, 且排名信息作为后续融合的基础特征, 无需重新计算路径内相关度, 降低了计算开销。

[0106] 步骤S1052, 基于每个检索结果在每条检索路径中的排名和检索路径融合权重值进行融合得分计算, 得到若干检索结果的融合得分。

[0107] 在本实施例中, 对每条被至少一条路径召回的候选文档d, 采用加权倒数排名融合公式计算其融合得分:

$$Score(d) = \sum_{i \in Paths(d)} \frac{w_i}{k + rank_i(d) + 1},$$

其中, $Score(d)$ 表示候选文档d的融合得分, $Paths(d)$ 表示召回了候选文档d的路径集合, w_i 表示检索路径i的融合权重 (由步骤S103生成并经步骤S104校验、经用户画像调整得到的目标检索路径融合权重值), $rank_i(d)$ 表示候选文档d在检索路径i列表中的位置序号 (从0起), k 表示平滑常数, $k = 60$ 。

[0108] 例如, 某文档同时被关键词全文检索路径 (rank=0, $W=0.35$) 和知识图谱全文检索路径 (rank=2, $W=0.15$) 召回, 则得分为融合得分为

$0.35/(60+0+1)+0.15/(60+2+1)\approx 0.00574+0.00238=0.00812$ 。平滑常数k的作用是降低排名差异在长尾位置的敏感度,避免单个路径的极靠前结果过度主导总分。本实施例将多路径的排序信息与动态权重融合为一个统一的、可比较的相关性分数。

[0109] 步骤S1053,基于融合得分对若干检索结果进行降序排序,得到排序结果。

[0110] 本实施例将所有候选文档按融合得分从高到低进行排序,形成一个粗排列表,以快速筛选出可能相关的文档,为后续精排提供高质量的候选子集。

[0111] 步骤S1054,选取排序结果中第一预设数量的检索结果,并基于各检索结果在每条检索路径中的检索路径融合权重值对第一预设数量的检索结果进行重排序,得到重排序结果。

[0112] 本实施例从粗排列表中选取前第一预设数量(例如前2N个,N为最终返回数量,实施例中N=10,即选取20个)的候选文档,送入重排序模块。重排序模块使用更精细的模型(例如交叉编码器)对查询与文档的关联性进行重新打分,并基于各路径的融合权重值(可选)进行二次排序。本实施例利用计算复杂但精度更高的模型对有限候选进行精排,纠正粗排可能存在的误差,同时控制计算开销。

[0113] 步骤S1055,在重排序结果中选取第二预设数量的检索结果作为目标检索结果,第一预设数量大于第二预设数量。

[0114] 本实施例从重排序后的列表选取前第二预设数量(例如前N个,即10个)的候选文档作为最终的目标检索结果返回给用户,以确保最终输出数量符合用户预期,同时通过粗排和精排两阶段策略,在响应延迟和排序质量之间取得最佳平衡。

[0115] 本实施例首先通过各路径独立检索并输出带排名的结果列表;接着通过加权倒数排名融合公式将多路径结果合并为统一的粗排列表;然后选取扩展候选集进行重排序;最后返回精排后的前几名的检索结果。该流程充分利用了多路径异构检索的互补性,通过动态权重与平滑常数实现了公平的融合,并通过重排序提升了最终结果的准确性,同时通过分层截断控制了计算复杂度,实现了效率与精度的兼顾。

[0116] 本发明的一部分可被应用为计算机程序产品,例如计算机程序指令,当其被计算机执行时,通过该计算机的操作,可以调用或提供根据本发明的方法和/或技术方案。本领域技术人员应能理解,计算机程序指令在计算机可读介质中的存在形式包括但不限于源文件、可执行文件、安装包文件等,相应地,计算机程序指令被计算机执行的方式包括但不限于:该计算机直接执行该指令,或者该计算机编译该指令后再执行对应的编译后程序,或者该计算机读取并执行该指令,或者该计算机读取并安装该指令后再执行对应的安装后程序。在此,计算机可读介质可以是可供计算机访问的任意可用的计算机可读存储介质或通信介质。

[0117] 虽然结合附图描述了本发明的实施例,但是本领域技术人员可以在不脱离本发明的精神和范围的情况下做出各种修改和变型,这样的修改和变型均落入由所附权利要求所限定的范围之内。




图1




图2